Fichas de datasets para Orange

Un catálogo visual para escoger con qué datos practicar en cada sesión: qué contiene cada dataset, de dónde viene, qué se suele estudiar con él y cómo montar el flujo de trabajo en Orange.

---

135 datasets en 14 capítulos · 367 ficheros en CSV y XLSX en github.com/gualbe/datasets/tree/main/ciencia_de_datos · versión del 10/11/2026

Índice

Cómo usar este libro 8

Las etiquetas 9

Guía rápida de selección 10

1. Clasificación: introductorios y de juguete 16

1.01 Iris (Fisher) 16

1.02 Tennis / Weather (Quinlan) 20

1.03 Sailing 24

1.04 Lenses (lentes de contacto) 27

1.05 Naughty or nice 30

1.06 Gnomes (gnomos) 33

1.07 Zoo 36

1.08 Titanic (supervivientes) 41

1.09 Car Evaluation 45

1.10 MONK's problems 49

1.11 Mushroom (setas) 53

1.12 Soybean (enfermedades de la soja) 58

1.13 Congressional Voting Records 1984 63

1.14 Bicycle rides (gravel vs mountain) 67

2. Clasificación: salud y medicina 71

2.01 Pima Indians Diabetes 71

2.02 Heart Disease (Cleveland) 75

2.03 Breast Cancer (Ljubljana) 79

2.04 Breast Cancer Wisconsin (original) 83

2.05 Breast Cancer Wisconsin Diagnostic (WDBC) 87

2.06 Prostate Cancer (Kaggle) 92

2.07 Cervical Cancer Risk Factors (cáncer de útero) 96

2.08 Stroke Prediction (ictus) 100

2.09 Dermatology 104
2.10 Lymphography 109
2.11 Primary Tumor 113
2.12 BUPA Liver Disorders 117
2.13 Mice Protein Expression (ratones con síndrome de Down) 120
2.14 Health survey (encuesta de hábitos) 124

3. Clasificación: negocio, sociedad y equidad 127

3.01 Adult (Census Income) 127
3.02 Bank Marketing (bank-additional) 132
3.03 German Credit 137
3.04 COMPAS (reincidencia a dos años) 143
3.05 Telco Customer Churn 149
3.06 IBM HR Employee Attrition 153
3.07 Kickstarter 159
3.08 NBA players 164

4. Clasificación: ciencias naturales y físicas 168

4.01 Glass Identification 168
4.02 Ionosphere 172
4.03 Vehicle Silhouettes 175
4.04 Wine (cultivares italianos) 179
4.05 E. coli promoter gene sequences 183
4.06 Poker Hand 186

5. Regresión 190

5.01 Boston Housing 190
5.02 California Housing 194
5.03 Ames Iowa Housing 198
5.04 Auto MPG 203
5.05 Automobile (imports-85) 207
5.06 Abalone 211

5.07 Body Fat (Brozek) 214
5.08 Advertising (ISLR) 218
5.09 Diabetes (progresión, Efron et al.) 221
5.10 Forest Fires (Montesinho) 225
5.11 Wine Quality (vinho verde) 229
5.12 Energy Efficiency (ENB2012) 234
5.13 Hitters (salarios de béisbol, ISLR) 238
5.14 Multitarget synthetic 242

6. No supervisado: clustering, exploración y datos geográficos 245

6.01 Grades (notas de estudiantes) 245
6.02 Mathematics and football 249
6.03 Human Development Index (HDI) 252
6.04 Clima mensual por continentes 260
6.05 Climate of European cities (Köppen) 266
6.06 Frecuencias de letras por idioma 270
6.07 Machine learning conferences 274
6.08 Food nutrition info 277
6.09 Pittsburgh Bridges 281
6.10 Banking crises 284
6.11 UL Rector Elections 2009 287
6.12 Slovenian National Assembly (votaciones) 290
6.13 Slovenian surnames 294
6.14 Slovenska naselja (localidades de Eslovenia) 298
6.15 Celine (países y continentes) 301
6.16 Cyber security breaches (EE. UU.) 304
6.17 Philadelphia crime 308
6.18 EWBA: vertederos ilegales en Eslovenia 312
6.19 Accidentes de tráfico en Eslovenia 2016 317
6.20 Renovables por país (Socioeconomic Indices, Banco Mundial) 324
6.21 COVID-19: casos confirmados por país (JHU CSSE) 328

7. Reglas de asociación (cesta de la compra) **333**

7.01 Market basket (ejemplo) 333

7.02 Foodmart 2000 336

7.03 Online Retail (cestas) 339

8. Análisis de supervivencia **343**

8.01 Veterans' Administration Lung Cancer 343

8.02 Melanoma (Odense) 347

8.03 German Breast Cancer Study Group 2 350

8.04 Political regimes (democracias y dictaduras) 353

8.05 Dental fillings (empastes) 357

8.06 Survival data (juguete) 360

8.07 TCGA: cáncer de cuello uterino (CESC) y de mama (BRCA) 363

8.08 METABRIC (cáncer de mama) 367

8.09 SCAN-B GSE96058 (cáncer de mama) 370

9. Series temporales y ventas **373**

9.01 Airline passengers (Box-Jenkins) 373

9.02 Australian wine sales 377

9.03 Nacimientos y defunciones trimestrales 381

9.04 Sarampión en Nueva York (1928-1972) 385

9.05 Superstore sales 389

9.06 Meteorología diaria de Huelva (humedad relativa) 395

9.07 Ozono y contaminantes horarios en Aljarafe (Sevilla) 400

10. Minería de textos **405**

10.01 BBC news (3 categorías) 405

10.02 ParlaMint-GB (1000 discursos) 408

10.03 SentiNews (noticias eslovenas) 412

10.04 Medical transcriptions (mtsamples) 415

10.05 Cuentos de Grimm y Andersen (en esloveno) 418

10.06 Words y words-food 421

11. Análisis de imágenes **424**

11.01 Ánforas romanas 424

11.02 Bone healing (consolidación de fracturas) 429

11.03 Dictyostelium: desarrollo 433

11.04 Hojas del parque de Luxemburgo 437

11.05 Competencia de ovocitos 442

11.06 Perros de razas tibetanas 445

11.07 Señales de tráfico 449

11.08 Localización de proteínas de levadura (YPL+) 453

11.09 Animales domésticos 458

11.10 Photographers (fotos personales por temas) 461

11.11 Hollywood faces (caras de 17 famosos) 466

11.12 Paintings (15 cuadros de 14 pintores) 470

11.13 Satellite (imágenes de satélite en 4 clases) 474

12. Espectroscopía **479**

12.01 TKI resistance (espectroscopía IR) 479

12.02 Hair (FTIR hiperespectral) 482

12.03 Liver cirrhosis (FTIR hiperespectral) 485

12.04 Liver cells (FTIR) 488

13. Expresión génica (bulk) **491**

13.01 GDS360: resistencia a docetaxel en cáncer de mama 491

13.02 GDS3713: linfocitos B de fumadores 495

13.03 GDS4168: linfocitos B en leucemia linfática crónica 498

13.04 Brown et al.: expresión génica de levadura 501

14. Single-cell **504**

14.01 Células dendríticas y monocitos (Villani 2017) 504

14.02 AML: médula ósea con leucemia mieloide aguda 508

14.03 Páncreas humano (Baron 2016) 512

14.04 Páncreas humano y diabetes tipo 2 (Xin 2016) 516

14.05 PBMC estimuladas con interferón beta (Kang 2018) 519
14.06 Médula ósea en AML y sana (van Galen 2019) 523
14.07 Linfocitos T CD8+ agotados (Miller 2019) 526
14.08 Células madre hematopoyéticas de ratón (Nestorowa 2016) 529
14.09 Neuronas de proyección de Drosophila (Li 2017) 531
14.10 Retina de ratón, Drop-seq (Macosko 2015) 535
14.11 Células bipolares de retina de ratón (Shekhar 2016) 538
14.12 Ciclo celular: conjuntos de referencia (ccp) 541

Índice por etiquetas **546**

Anexo A. De cada fichero original a su ficha **553**

Anexo B. Formatos de fichero en Orange **561**

Anexo C. Add-ons de Orange **563**

Anexo D. Glosario de métricas **565**

Cómo usar este libro

Cada dataset tiene una ficha con la misma estructura, para que puedas comparar de un vistazo. Los capítulos agrupan los datasets por el tipo de tarea con el que más se usan; las etiquetas permiten buscarlos por cualquier otra característica.

> **Cabecera**
> Número de ficha (capítulo.posición), nombre, resumen en una frase y etiquetas.

> **Datos clave y ficheros**
> Filas, columnas, variable objetivo, nivel y add-on de Orange necesario, con enlaces a cada CSV y XLSX.

> **Radiografía**
> Gráficos calculados sobre los ficheros reales: la distribución de la variable objetivo y un dato revelador del dataset.

> **1–7. Las siete secciones**
> Descripción, contexto y fuente, variable objetivo, diccionario de columnas, particularidades técnicas, flujo en Orange y otras consideraciones.

Para abrir un dataset en Orange, usa el widget *File*: puedes elegir el fichero descargado o pegar en el campo *URL* la dirección «para Orange» que aparece en cada ficha (funciona en cuanto la carpeta esté publicada en GitHub). Un CSV no guarda el tipo ni el rol de cada columna, así que, nada más abrirlo, revisa en *File* qué columna es la variable objetivo (*target*) y si alguna categoría codificada con números se ha leído como numérica. La hoja `variables` del XLSX indica los roles originales.

El flujo en Orange de cada ficha se dibuja como en el lienzo de Orange: cada círculo es un widget, coloreado por su categoría, y cada flecha lleva el nombre de la señal que pasa (*Data*, *Learner*, *Model*…).

Las etiquetas

Las etiquetas de **tarea** (color sólido) dicen para qué se suele usar el dataset; puede tener varias. Las de **característica** (contorno) avisan de rasgos que condicionan el modelado. Las características de tamaño, faltantes, desbalance y tipo de atributos se calculan automáticamente sobre los ficheros; el resto se asignan a mano.

Clasificación binaria 33 datasets

Clasificación multiclase 44 datasets

Regresión 18 datasets

Clustering 46 datasets

Reglas de asociación 3 datasets

Análisis de supervivencia 9 datasets

Predicción de series temporales 8 datasets

Minería de textos 6 datasets

Exploración y visualización 26 datasets

? Valores faltantes Hay al menos un valor faltante en algún fichero.

⚖ Desbalanceado La clase minoritaria tiene como mucho 1/4 de los casos de la mayoritaria (en binaria, un 20 % o menos).

◷ Temporal Hay fechas, horas o un orden en el tiempo que importa.

⌖ Espacial Hay coordenadas, lugares o posiciones en un mapa o en una imagen.

▣ Imágenes Cada fila corresponde a una imagen.

¶ Texto Hay columnas de texto libre o secuencias de símbolos.

⋮ Alta dimensionalidad Más variables que filas, o más de 500 variables.

▤ Grande Más de 10.000 filas.

∘ Juguete Menos de 100 filas: se puede revisar entero a mano.

◇ Solo categóricos Todos los atributos son categóricos.

◈ Mixto num. + cat. Hay atributos numéricos y categóricos.

✎ Sintético Datos inventados o simulados con fines didácticos.

⚑ Sesgo y equidad Incluye atributos sensibles (sexo, raza, edad…) y se usa para estudiar sesgos.

⊣ Datos censurados Tiempos de supervivencia con casos censurados.

⊕ Multiobjetivo Tiene más de una variable objetivo.

Guía rápida de selección

Los 135 datasets, capítulo a capítulo. El punto ● marca los que se usan en el curso de nivel intermedio. Los nombres con número de página tienen ficha en esta edición.

Nº	Dataset	Etiquetas	Filas × col.
1. Clasificación: introductorios y de juguete			
1.01	● **Iris (Fisher)** · p. 16	Clasificación multiclase	150 × 5
1.02	**Tennis / Weather (Quinlan)** · p. 20	Clasificación binaria · Juguete · Sintético · Solo categóricos	14 × 6
1.03	**Sailing** · p. 24	Clasificación binaria · Juguete · Sintético · Solo categóricos	20 × 4
1.04	**Lenses (lentes de contacto)** · p. 27	Clasificación multiclase · Juguete · Solo categóricos	24 × 5
1.05	**Naughty or nice** · p. 30	Clasificación binaria · Juguete · Sintético	30 × 8
1.06	**Gnomes (gnomos)** · p. 33	Clasificación multiclase · Valores faltantes · Juguete · Sintético · Solo categóricos	21 × 10
1.07	**Zoo** · p. 36	Clasificación multiclase · Desbalanceado · Valores faltantes · Solo categóricos	100 × 18
1.08	**Titanic (supervivientes)** · p. 41	Clasificación binaria · Solo categóricos	2.201 × 4
1.09	**Car Evaluation** · p. 45	Clasificación multiclase · Desbalanceado · Sintético · Solo categóricos	1.728 × 7
1.10	**MONK's problems** · p. 49	Clasificación binaria · Sintético · Solo categóricos	556 × 8
1.11	**Mushroom (setas)** · p. 53	Clasificación binaria · Valores faltantes · Solo categóricos	8.124 × 23
1.12	**Soybean (enfermedades de la soja)** · p. 58	Clasificación multiclase · Desbalanceado · Valores faltantes · Solo categóricos	683 × 36
1.13	**Congressional Voting Records 1984** · p. 63	Clasificación binaria · Valores faltantes · Solo categóricos	435 × 17
1.14	**Bicycle rides (gravel vs mountain)** · p. 67	Clasificación binaria · Juguete	98 × 6
2. Clasificación: salud y medicina			
2.01	**Pima Indians Diabetes** · p. 71	Clasificación binaria · Valores faltantes	768 × 9
2.02	**Heart Disease (Cleveland)** · p. 75	Clasificación binaria · Valores faltantes · Mixto num. + cat.	303 × 14
2.03	**Breast Cancer (Ljubljana)** · p. 79	Clasificación binaria · Valores faltantes · Solo categóricos	286 × 10
2.04	**Breast Cancer Wisconsin (original)** · p. 83	Clasificación binaria	683 × 10
2.05	● **Breast Cancer Wisconsin Diagnostic (WDBC)** · p. 87	Clasificación binaria	569 × 32
2.06	● **Prostate Cancer (Kaggle)** · p. 92	Clasificación binaria	100 × 10
2.07	**Cervical Cancer Risk Factors (cáncer de útero)** · p. 96	Clasificación binaria · Valores faltantes · Mixto num. + cat. · Multiobjetivo	858 × 36
2.08	● **Stroke Prediction (ictus)** · p. 100	Clasificación binaria · Desbalanceado · Valores faltantes · Mixto num. + cat.	5.110 × 12

Nº	Dataset	Etiquetas	Filas × col.
2.09	**Dermatology** · p. 104	Clasificación multiclase · Desbalanceado · Valores faltantes · Mixto num. + cat.	366 × 35
2.10	**Lymphography** · p. 109	Clasificación multiclase · Desbalanceado · Mixto num. + cat.	148 × 19
2.11	**Primary Tumor** · p. 113	Clasificación multiclase · Desbalanceado · Valores faltantes · Solo categóricos	339 × 18
2.12	**BUPA Liver Disorders** · p. 117	Clasificación binaria	345 × 7
2.13	**Mice Protein Expression (ratones con síndrome de Down)** · p. 120	Clasificación multiclase · Clustering · Valores faltantes · Mixto num. + cat.	1.080 × 82
2.14	**Health survey (encuesta de hábitos)** · p. 124	Exploración y visualización · Clustering · Regresión · Juguete · Mixto num. + cat. · Sintético	41 × 9
3. Clasificación: negocio, sociedad y equidad			
3.01	**Adult (Census Income)** · p. 127	Clasificación binaria · Sesgo y equidad · Valores faltantes · Grande · Mixto num. + cat.	48.842 × 15
3.02	**Bank Marketing (bank-additional)** · p. 132	Clasificación binaria · Desbalanceado · Valores faltantes · Mixto num. + cat.	4.119 × 21
3.03	**German Credit** · p. 137	Clasificación binaria · Sesgo y equidad · Mixto num. + cat.	1.000 × 21
3.04	**COMPAS (reincidencia a dos años)** · p. 143	Clasificación binaria · Sesgo y equidad · Valores faltantes · Mixto num. + cat. · Temporal	7.214 × 52
3.05	**Telco Customer Churn** · p. 149	Clasificación binaria · Valores faltantes · Mixto num. + cat.	7.043 × 21
3.06	**IBM HR Employee Attrition** · p. 153	Clasificación binaria · Desbalanceado · Mixto num. + cat. · Sintético	1.470 × 33
3.07	**Kickstarter** · p. 159	Clasificación binaria · Mixto num. + cat. · Texto	1.163 × 21
3.08	**NBA players** · p. 164	Clasificación multiclase · Clustering · Valores faltantes · Mixto num. + cat.	248 × 17
4. Clasificación: ciencias naturales y físicas			
4.01	**Glass Identification** · p. 168	Clasificación multiclase · Desbalanceado	214 × 11
4.02	**Ionosphere** · p. 172	Clasificación binaria	351 × 35
4.03	**Vehicle Silhouettes** · p. 175	Clasificación multiclase	846 × 19
4.04	**Wine (cultivares italianos)** · p. 179	Clasificación multiclase · Clustering	178 × 14
4.05	**E. coli promoter gene sequences** · p. 183	Clasificación binaria · Solo categóricos · Texto	106 × 58
4.06	**Poker Hand** · p. 186	Clasificación multiclase · Desbalanceado · Grande · Mixto num. + cat. · Sintético	1.025.010 × 12
5. Regresión			
5.01	**Boston Housing** · p. 190	Regresión · Sesgo y equidad	506 × 14
5.02	**California Housing** · p. 194	Regresión · Espacial · Grande	20.640 × 9
5.03	**Ames Iowa Housing** · p. 198	Regresión · Valores faltantes · Mixto num. + cat.	2.930 × 81
5.04	**Auto MPG** · p. 203	Regresión · Valores faltantes · Mixto num. + cat.	398 × 9

Nº	Dataset	Etiquetas	Filas × col.
5.05	**Automobile (imports-85)** · p. 207	Regresión · ? Valores faltantes · ◈ Mixto num. + cat.	205 × 26
5.06	**Abalone** · p. 211	Regresión · Clasificación multiclase · ◈ Mixto num. + cat.	4.177 × 9
5.07	**Body Fat (Brozek)** · p. 214	Regresión	252 × 16
5.08	**Advertising (ISLR)** · p. 218	Regresión	200 × 4
5.09	**Diabetes (progresión, Efron et al.)** · p. 221	Regresión	442 × 11
5.10	**Forest Fires (Montesinho)** · p. 225	Regresión · ⌖ Espacial · ◈ Mixto num. + cat. · ◷ Temporal	517 × 15
5.11	**Wine Quality (vinho verde)** · p. 229	Regresión · Clasificación multiclase · ⚖ Desbalanceado	1.599 × 12
5.12	**Energy Efficiency (ENB2012)** · p. 234	Regresión · ⊕ Multiobjetivo	768 × 10
5.13	**Hitters (salarios de béisbol, ISLR)** · p. 238	Regresión · ? Valores faltantes · ◈ Mixto num. + cat.	322 × 21
5.14	**Multitarget synthetic** · p. 242	Regresión · ⊕ Multiobjetivo · ✎ Sintético	100 × 7
6. No supervisado: clustering, exploración y datos geográficos			
6.01	**Grades (notas de estudiantes)** · p. 245	Clustering · Exploración y visualización · ∘ Juguete · ✎ Sintético	16 × 8
6.02	**Mathematics and football** · p. 249	Clustering · ∘ Juguete · ✎ Sintético	11 × 3
6.03	● **Human Development Index (HDI)** · p. 252	Clustering · Exploración y visualización · ⌖ Espacial · ? Valores faltantes	188 × 54
6.04	**Clima mensual por continentes** · p. 260	Clustering · Exploración y visualización · ⌖ Espacial · ? Valores faltantes · ∘ Juguete	40 × 28
6.05	**Climate of European cities (Köppen)** · p. 266	Clustering · Clasificación multiclase · ⌖ Espacial · ? Valores faltantes · ∘ Juguete	41 × 16
6.06	**Frecuencias de letras por idioma** · p. 270	Clustering · Exploración y visualización · ? Valores faltantes · ¶ Texto	167 × 30
6.07	**Machine learning conferences** · p. 274	Exploración y visualización · Clustering · ∘ Juguete · ◈ Mixto num. + cat.	42 × 5
6.08	**Food nutrition info** · p. 277	Clustering · Clasificación multiclase · ∘ Juguete	61 × 25
6.09	**Pittsburgh Bridges** · p. 281	Exploración y visualización · Clasificación multiclase · ? Valores faltantes · ◈ Mixto num. + cat. · ⊕ Multiobjetivo	108 × 13
6.10	**Banking crises** · p. 284	Exploración y visualización · Clustering · ? Valores faltantes · ◈ Mixto num. + cat. · ◷ Temporal	211 × 73
6.11	**UL Rector Elections 2009** · p. 287	Exploración y visualización · Clustering · ∘ Juguete	26 × 7
6.12	**Slovenian National Assembly (votaciones)** · p. 290	Clustering · Exploración y visualización · ? Valores faltantes · ∘ Juguete · ◇ Solo categóricos	84 × 32
6.13	**Slovenian surnames** · p. 294	Exploración y visualización · Clustering · ⌖ Espacial · ▤ Grande	103.530 × 4
6.14	**Slovenska naselja (localidades de Eslovenia)** · p. 298	Exploración y visualización · ⌖ Espacial · ? Valores faltantes · ◈ Mixto num. + cat.	6.002 × 8
6.15	**Celine (países y continentes)** · p. 301	Exploración y visualización · ? Valores faltantes · ◇ Solo categóricos	229 × 2
6.16	**Cyber security breaches (EE. UU.)** · p. 304	Exploración y visualización · ⌖ Espacial · ? Valores faltantes · ◈ Mixto num. + cat. · ◷ Temporal · ¶ Texto	1.055 × 10

Nº	Dataset	Etiquetas	Filas × col.
6.17	● **Philadelphia crime** · p. 308	Exploración y visualización · Clustering · Espacial · Mixto num. + cat. · Temporal	9.666 × 4
6.18	**EWBA: vertederos ilegales en Eslovenia** · p. 312	Exploración y visualización · Clustering · Espacial · Valores faltantes · Grande · Mixto num. + cat. · Temporal	13.165 × 29
6.19	**Accidentes de tráfico en Eslovenia 2016** · p. 317	Exploración y visualización · Clustering · Espacial · Valores faltantes · Grande · Mixto num. + cat. · Temporal	17.931 × 21
6.20	● **Renovables por país (Socioeconomic Indices, Banco Mundial)** · p. 324	Exploración y visualización · Clustering · Espacial · Juguete	54 × 3
6.21	● **COVID-19: casos confirmados por país (JHU CSSE)** · p. 328	Exploración y visualización · Predicción de series temporales · Alta dimensionalidad · Espacial · Valores faltantes · Temporal	289 × 1.147
7. Reglas de asociación (cesta de la compra)			
7.01	**Market basket (ejemplo)** · p. 333	Reglas de asociación · Juguete · Sintético · Solo categóricos	5 × 6
7.02	**Foodmart 2000** · p. 336	Reglas de asociación · Grande	62.560 × 126
7.03	**Online Retail (cestas)** · p. 339	Reglas de asociación · Espacial · Temporal	914 × 50
8. Análisis de supervivencia			
8.01	**Veterans' Administration Lung Cancer** · p. 343	Análisis de supervivencia · Datos censurados · Mixto num. + cat.	137 × 8
8.02	**Melanoma (Odense)** · p. 347	Análisis de supervivencia · Datos censurados · Mixto num. + cat.	205 × 7
8.03	**German Breast Cancer Study Group 2** · p. 350	Análisis de supervivencia · Datos censurados · Mixto num. + cat.	686 × 10
8.04	**Political regimes (democracias y dictaduras)** · p. 353	Análisis de supervivencia · Datos censurados · Espacial · Valores faltantes · Temporal	1.808 × 11
8.05	**Dental fillings (empastes)** · p. 357	Análisis de supervivencia · Datos censurados · Juguete · Mixto num. + cat. · Sintético	20 × 6
8.06	**Survival data (juguete)** · p. 360	Análisis de supervivencia · Datos censurados · Juguete · Sintético	10 × 3
8.07	**TCGA: cáncer de cuello uterino (CESC) y de mama (BRCA)** · p. 363	Análisis de supervivencia · Alta dimensionalidad · Datos censurados · Mixto num. + cat.	306 × 23.371
8.08	**METABRIC (cáncer de mama)** · p. 367	Análisis de supervivencia · Alta dimensionalidad · Datos censurados	1.904 × 24.403
8.09	**SCAN-B GSE96058 (cáncer de mama)** · p. 370	Análisis de supervivencia · Alta dimensionalidad · Datos censurados	3.273 × 23.804
9. Series temporales y ventas			
9.01	● **Airline passengers (Box-Jenkins)** · p. 373	Predicción de series temporales · Temporal	144 × 2
9.02	**Australian wine sales** · p. 377	Predicción de series temporales · Valores faltantes · Multiobjetivo · Temporal	180 × 7
9.03	**Nacimientos y defunciones trimestrales** · p. 381	Predicción de series temporales · Juguete · Multiobjetivo · Temporal	52 × 5
9.04	**Sarampión en Nueva York (1928-1972)** · p. 385	Predicción de series temporales · Temporal	534 × 2

Nº	Dataset	Etiquetas	Filas × col.
9.05	**Superstore sales** · p. 389	Predicción de series temporales · Regresión · Exploración y visualización · Espacial · ? Valores faltantes · Mixto num. + cat. · Temporal	8.399 × 21
9.06	● **Meteorología diaria de Huelva (humedad relativa)** · p. 395	Predicción de series temporales · Regresión · ? Valores faltantes · Temporal	3.148 × 17
9.07	● **Ozono y contaminantes horarios en Aljarafe (Sevilla)** · p. 400	Predicción de series temporales · Regresión · Grande · Temporal	96.408 × 6
10. Minería de textos			
10.01	**BBC news (3 categorías)** · p. 405	Minería de textos · Clasificación multiclase · Texto	1.407 × 3
10.02	**ParlaMint-GB (1000 discursos)** · p. 408	Minería de textos · Clasificación multiclase · ? Valores faltantes · Temporal · Texto	1.000 × 18
10.03	**SentiNews (noticias eslovenas)** · p. 412	Minería de textos · Clasificación multiclase · ? Valores faltantes · Texto	2.000 × 8
10.04	**Medical transcriptions (mtsamples)** · p. 415	Minería de textos · Clasificación multiclase · ? Valores faltantes · Texto	950 × 5
10.05	**Cuentos de Grimm y Andersen (en esloveno)** · p. 418	Minería de textos · Clasificación binaria · Juguete · Texto	41 × 3
10.06	**Words y words-food** · p. 421	Minería de textos · Clasificación multiclase · Sintético · Texto	150 × 1
11. Análisis de imágenes			
11.01	**Ánforas romanas** · p. 424	Clasificación multiclase · Clustering · ? Valores faltantes · Imágenes · Solo categóricos	164 × 16
11.02	● **Bone healing (consolidación de fracturas)** · p. 429	Clasificación binaria · Clustering · ? Valores faltantes · Imágenes · Juguete	37 × 9
11.03	**Dictyostelium: desarrollo** · p. 433	Clasificación multiclase · Clustering · ? Valores faltantes · Imágenes · Temporal	152 × 7
11.04	**Hojas del parque de Luxemburgo** · p. 437	Clasificación multiclase · Clustering · Imágenes · Juguete	79 × 2
11.05	**Competencia de ovocitos** · p. 442	Clasificación binaria · Imágenes	131 × 3
11.06	**Perros de razas tibetanas** · p. 445	Clasificación multiclase · Clustering · Imágenes · Juguete	72 × 6
11.07	● **Señales de tráfico** · p. 449	Clasificación multiclase · Clustering · Imágenes · Juguete	70 × 3
11.08	**Localización de proteínas de levadura (YPL+)** · p. 453	Clasificación multiclase · Desbalanceado · ? Valores faltantes · Imágenes	2.569 × 4
11.09	● **Animales domésticos** · p. 458	Clustering · Imágenes · Juguete	20 × 2
11.10	● **Photographers (fotos personales por temas)** · p. 461	Clasificación multiclase · Clustering · Imágenes · Juguete	70 × 6
11.11	● **Hollywood faces (caras de 17 famosos)** · p. 466	Clasificación multiclase · Clustering · Imágenes	1.800 × 6
11.12	● **Paintings (15 cuadros de 14 pintores)** · p. 470	Clustering · Imágenes · Juguete	15 × 5
11.13	● **Satellite (imágenes de satélite en 4 clases)** · p. 474	Clasificación multiclase · Clustering · Imágenes	5.631 × 6
12. Espectroscopía			

Nº	Dataset	Etiquetas	Filas × col.
12.01	**TKI resistance (espectroscopía IR)** · p. 479	Clasificación multiclase · Alta dimensionalidad	280 × 468
12.02	**Hair (FTIR hiperespectral)** · p. 482	Clustering · Exploración y visualización · Alta dimensionalidad · Espacial	3.250 × 833
12.03	**Liver cirrhosis (FTIR hiperespectral)** · p. 485	Clustering · Exploración y visualización · Alta dimensionalidad · Espacial	1.078 × 546
12.04	**Liver cells (FTIR)** · p. 488	Clasificación multiclase	731 × 235
13. Expresión génica (bulk)			
13.01	**GDS360: resistencia a docetaxel en cáncer de mama** · p. 491	Clasificación binaria · Alta dimensionalidad · Juguete	24 × 9.486
13.02	**GDS3713: linfocitos B de fumadores** · p. 495	Clasificación binaria · Alta dimensionalidad · Juguete	79 × 3.001
13.03	**GDS4168: linfocitos B en leucemia linfática crónica** · p. 498	Clasificación binaria · Alta dimensionalidad · Juguete	52 × 16.468
13.04	**Brown et al.: expresión génica de levadura** · p. 501	Clasificación multiclase · Clustering · Desbalanceado · Valores faltantes	186 × 81
14. Single-cell			
14.01	**Células dendríticas y monocitos (Villani 2017)** · p. 504	Clasificación multiclase · Clustering · Alta dimensionalidad	1.140 × 26.595
14.02	**AML: médula ósea con leucemia mieloide aguda** · p. 508	Clasificación multiclase · Clustering · Alta dimensionalidad	1.000 × 1.004
14.03	**Páncreas humano (Baron 2016)** · p. 512	Clasificación multiclase · Clustering · Alta dimensionalidad · Desbalanceado	8.569 × 20.130
14.04	**Páncreas humano y diabetes tipo 2 (Xin 2016)** · p. 516	Clasificación multiclase · Clustering · Alta dimensionalidad · Desbalanceado	1.492 × 35.900
14.05	**PBMC estimuladas con interferón beta (Kang 2018)** · p. 519	Clasificación binaria · Clustering · Alta dimensionalidad · Grande	13.019 × 35.637
14.06	**Médula ósea en AML y sana (van Galen 2019)** · p. 523	Clustering · Exploración y visualización · Alta dimensionalidad · Temporal	2.328 × 27.701
14.07	**Linfocitos T CD8+ agotados (Miller 2019)** · p. 526	Clustering · Exploración y visualización · Alta dimensionalidad	9.197 × 22.193
14.08	**Células madre hematopoyéticas de ratón (Nestorowa 2016)** · p. 529	Clustering · Exploración y visualización · Alta dimensionalidad	774 × 23.930
14.09	**Neuronas de proyección de Drosophila (Li 2017)** · p. 531	Clustering · Exploración y visualización · Alta dimensionalidad · Valores faltantes	1.842 × 13.920
14.10	**Retina de ratón, Drop-seq (Macosko 2015)** · p. 535	Clasificación multiclase · Clustering · Alta dimensionalidad · Valores faltantes	6.243 × 6.862
14.11	**Células bipolares de retina de ratón (Shekhar 2016)** · p. 538	Clasificación multiclase · Clustering · Alta dimensionalidad · Desbalanceado · Grande	12.606 × 4.982
14.12	**Ciclo celular: conjuntos de referencia (ccp)** · p. 541	Clasificación multiclase · Clustering · Alta dimensionalidad · Juguete	81 × 38.293

1 Clasificación: introductorios y de juguete

14 datasets en el capítulo; en esta edición, 14 con ficha.

1.01
Clasificación: introductorios y de juguete

Iris (Fisher)

`01_clasificacion_introductorios/iris/`

150 flores de tres especies de lirio, medidas en cuatro dimensiones de sépalos y pétalos: el dataset más clásico del aprendizaje automático.

Clasificación multiclase

> **En el curso:** Tema 1 (conceptos básicos) y Actividad 7.1 de explicabilidad (árbol, nomograma y explicación de modelos).

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
150	**5**	`iris`	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`iris`	150 × 5	CSV 4 KB · XLSX

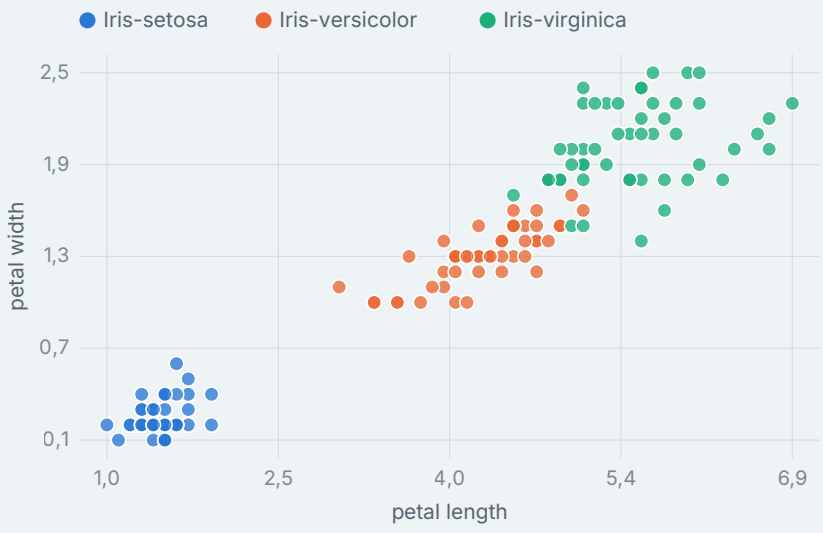
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/01_clasificacion_introductorios/iris/` seguido del nombre del fichero CSV.

Radiografía

iris en iris



Largo y ancho del pétalo (cm) por especie



1 Descripción general y estudios habituales

Cada fila es una flor de lirio (*Iris*) de una de tres especies: *setosa*, *versicolor* o *virginica*, 50 de cada una. De cada flor se midieron en centímetros el largo y el ancho del sépalo (la «hoja» verde exterior) y del pétalo.

Es el «hola, mundo» de la clasificación: pocas filas, cuatro números, clases equilibradas y patrones que se ven en un gráfico de dispersión. Los estudios habituales son:

- **Clasificar la especie** (clasificación multiclase) con árboles, kNN, Naive Bayes o regresión logística.
- **Visualizar** con gráficos de dispersión, de coordenadas paralelas o de proyección (PCA, t-SNE, FreeViz).
- **Agrupar sin etiquetas** (k-means, jerárquico) y comparar los grupos con las especies reales.
- **Explicar modelos**: con tan pocas variables, las explicaciones (importancia, nomograma, SHAP) se entienden enteras.

2 Contexto y fuente original

Las medidas las tomó el botánico estadounidense Edgar Anderson para estudiar la variación entre especies de lirio, y el estadístico británico Ronald A. Fisher las usó en 1936 en su artículo *The use of multiple measurements in taxonomic problems* para presentar el análisis discriminante lineal. Desde entonces es el ejemplo de referencia en estadística multivariante y aprendizaje automático, y viene incluido en casi todas las herramientas (Orange, R, scikit-learn, Weka).

La versión que circula (UCI y Orange) tiene **dos errores de transcripción** respecto a la tabla de Fisher, documentados en el repositorio UCI: la flor 35 debería tener un ancho de pétalo de 0,2 (no 0,1) y la flor 38 un ancho de sépalo de 3,6 y un largo de pétalo de 1,4 (no 3,1 y 1,5). No cambian ninguna conclusión, pero conviene saberlo si se comparan resultados con la literatura.

- Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. Annals of Eugenics, 7(2), 179–188.
- Iris en el repositorio UCI (con la nota sobre las dos filas erróneas)

3 Variable objetivo

La variable objetivo es `iris`, la especie: `Iris-setosa`, `Iris-versicolor` o `Iris-virginica`, con 50 flores cada una. Al estar equilibradas, decir siempre la misma especie acierta solo un 33,3 %.

Setosa se separa de las otras dos sin error con una sola medida: tiene pétalos de 1,0 a 1,9 cm de largo, cuando *versicolor* empieza en 3,0. La dificultad está en distinguir *versicolor* de *virginica*, que se solapan (largo de pétalo de 3,0–5,1 frente a 4,5–6,9 cm). Casi todos los errores de cualquier modelo están en esa frontera.

4 Diccionario de columnas

Columnas de `iris` (valores observados en el fichero)

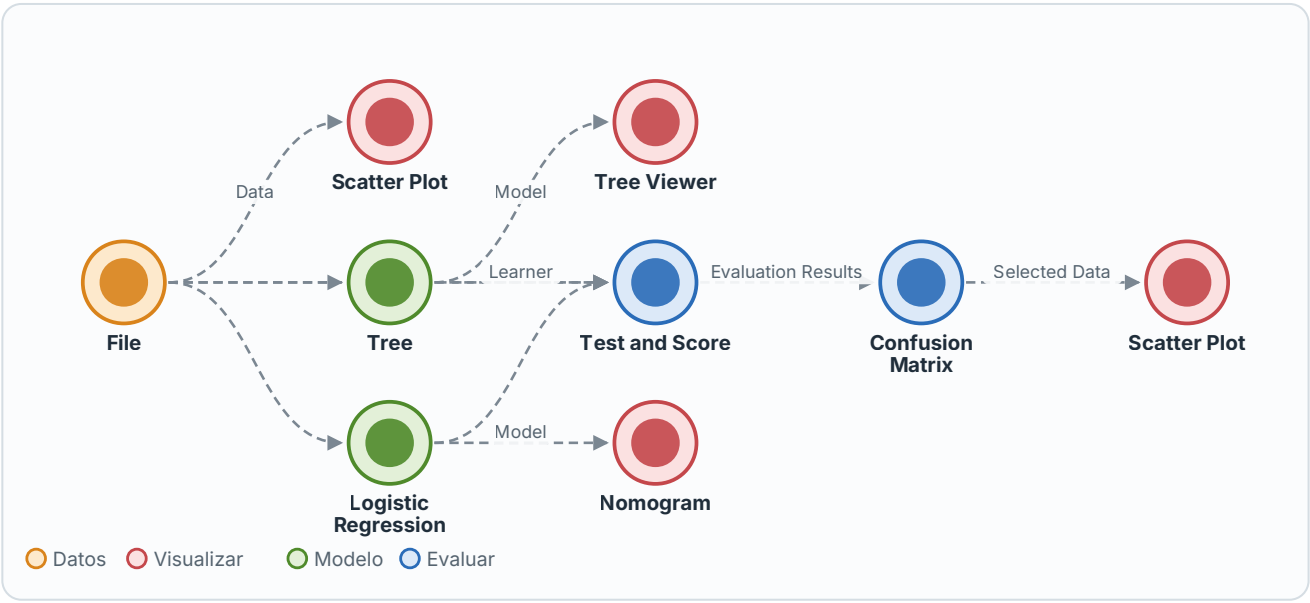
Columna	Tipo	Significado	Valores
`sepal length`	numérica	Largo del sépalo, en cm.	4,3 – 7,9
`sepal width`	numérica	Ancho del sépalo, en cm.	2 – 4,4
`petal length`	numérica	Largo del pétalo, en cm. Es, con el ancho del pétalo, la medida que mejor separa las especies.	1 – 6,9
`petal width`	numérica	Ancho del pétalo, en cm.	0,1 – 2,5

Columna	Tipo	Significado	Valores
`iris` `objetivo`	categórica	Especie de lirio: `Iris-setosa`, `Iris-versicolor` o `Iris-virginica`. Es la variable objetivo.	Iris-setosa (50), Iris-versicolor (50), Iris-virginica (50)

5 Particularidades técnicas al modelar

- **Es un problema fácil**: la mayoría de modelos pasan del 93–96 % de acierto en validación cruzada. Sirve para aprender a usar los widgets, no para comparar algoritmos: las diferencias entre modelos son de una o dos flores y no son significativas.
- **Pocas filas**: con 150 flores, una partición de prueba del 20 % son 30 flores y cada fallo vale 3,3 puntos. Usa validación cruzada (10 particiones) en vez de una sola partición.
- **Atributos muy correlacionados**: el largo y el ancho del pétalo tienen una correlación de 0,96. Para explicar modelos, la importancia se reparte entre ambos de forma algo arbitraria.
- **Todas las medidas están en centímetros** y en rangos parecidos, así que normalizar cambia poco; aun así, kNN y SVM lo agradecen.
- **Filas repetidas**: hay tres flores idénticas a otra (dos de *setosa* y una de *virginica*). No afectan a nada salvo a quien espere 150 combinaciones distintas.
- **Al abrir el CSV en Orange**, comprueba en *File* que `iris` tiene el rol *target*. Desde el widget *Datasets* ya viene configurado.

6 Flujo de trabajo en Orange



1. **File** (o **Datasets** buscando «iris»): la especie ya viene como *target*.
2. **Scatter Plot** con `petal length` y `petal width`: pulsa *Find Informative Projections* y verás que esa pareja es la que mejor separa las especies.
3. **Tree** + **Tree Viewer**: un árbol de dos o tres niveles explica casi todo; la primera división separa a *setosa*.
4. **Logistic Regression** + **Nomogram**: muestra cómo empuja cada medida hacia cada especie.
5. **Test and Score**: validación cruzada de 10 particiones con ambos modelos.
6. **Confusion Matrix** → **Scatter Plot**: selecciona en la matriz las flores mal clasificadas y míralas resaltadas sobre la nube de puntos; casi todas están en la frontera entre *versicolor* y *virginica*.

7 Otras consideraciones

- **Para explicabilidad**, el add-on *Explain* (widgets *Explain Model* y *Explain Prediction*) da explicaciones con valores SHAP que con cuatro variables se pueden comprobar a mano.
- **Para clustering**, quita la especie (en *File*, rol *skip*), agrupa con *k-Means* (k = 3) y compara los grupos con la especie real en una tabla de contingencia: *setosa* sale casi perfecta y las otras dos se mezclan.
- La versión del repositorio del curso (`iris.arff`) es idéntica a esta, por eso no se duplica.
- Fisher publicó su artículo en *Annals of Eugenics*; en algunos cursos se aprovecha para hablar de la historia de la estadística y de sus usos.

En la carpeta	`iris` ← `iris.tab` (datasets.biolab.si)
Duplicado, no se copia	`iris.arff` (curso_ciencia_datos (GitHub))

1.02
Clasificación: introductorios y de juguete

Tennis / Weather (Quinlan)

`01_clasificacion_introductorios/tennis/`

Catorce días con el tiempo que hacía y si se jugó al tenis: el ejemplo con el que se explica cómo se construye un árbol de decisión, en versión categórica y en versión con temperatura y humedad numéricas.

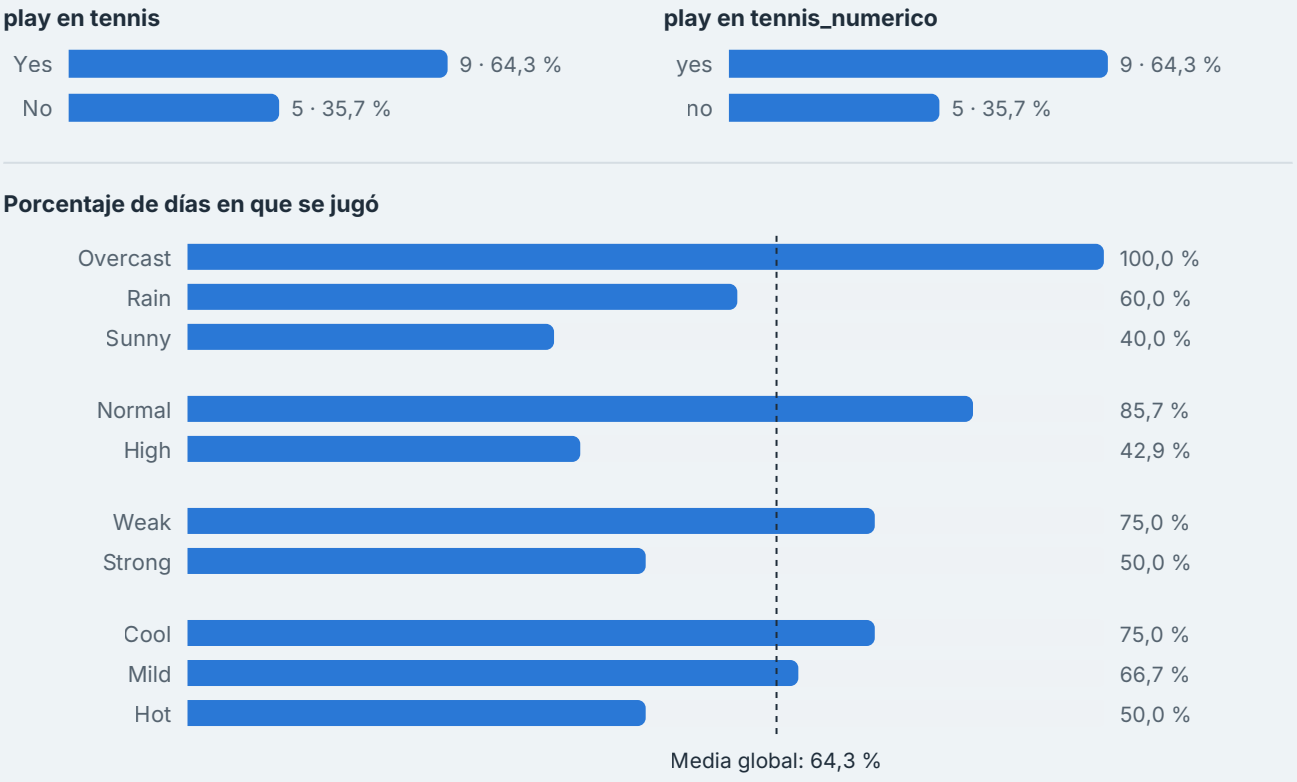
Clasificación binaria · ◦ Juguete · ✎ Sintético · ◇ Solo categóricos

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
14	**6**	`play`	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`tennis`	14 × 6	CSV 1 KB · XLSX
`tennis_numerico`	14 × 5	CSV 1 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/01_clasificacion_introductorios/tennis/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Son **14 días** descritos por cuatro variables del tiempo: el cielo (`outlook`), la temperatura, la humedad y el viento. La clase dice si ese día se jugó al tenis (`play`): 9 días sí y 5 no.

Hay dos versiones:

- `tennis`: todo categórico (temperatura *Hot/Mild/Cool*, humedad *High/Normal*…), con un identificador del día (`D1` a `D14`).
- `tennis_numerico`: los mismos 14 días con la temperatura (°F) y la humedad (%) como números, y el viento como verdadero o falso.

Los estudios habituales son:

- **Calcular a mano un árbol de decisión**: entropía, ganancia de información y elección del mejor atributo.
- **Comparar el árbol con Naive Bayes** o con reglas, sobre un conjunto que cabe en una pizarra.
- **Ver cómo trata un árbol las variables numéricas** (umbrales) con la segunda versión.

2 Contexto y fuente original

Es el ejemplo de **Ross Quinlan** para presentar su algoritmo ID3 en el artículo *Induction of decision trees* (1986), y después en el libro de C4.5 (1993), donde aparece la versión con temperatura y humedad numéricas. La versión con los días `D1` – `D14` es la de la tabla 3.2 del libro *Machine Learning* de **Tom Mitchell** (1997), con el nombre *PlayTennis*. La numérica es la que distribuye Weka como `weather.arff`.

Los datos son inventados para explicar el método: no corresponden a días reales.

- Quinlan, J. R. (1986). Induction of decision trees. Machine Learning, 1, 81–106.
- Mitchell, T. M. (1997). Machine Learning. McGraw-Hill, capítulo 3 (tabla 3.2, PlayTennis).

3 Variable objetivo

La clase es `play` (*Yes* o *No* en la versión categórica; *yes* o *no* en la numérica). Hay 9 días de juego y 5 sin juego, así que acertar siempre «sí» da un 64 %.

El árbol que sale (el de ID3) es corto y explica los 14 días sin error: si el cielo está cubierto (*Overcast*), siempre se juega; si hace sol, se juega cuando la humedad es normal; si llueve, se juega cuando el viento es débil.

4 Diccionario de columnas

Columnas de `tennis` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`day`	texto	Identificador del día (`D1` … `D14`). No es una variable del tiempo: en Orange va como *meta*.	D1 (1), D2 (1), D3 (1), D4 (1), D5 (1), D6 (1) …
`outlook`	categórica	Estado del cielo: `Sunny` (sol), `Overcast` (cubierto) o `Rain` (lluvia).	Sunny (5), Rain (5), Overcast (4)
`temp`	categórica	Temperatura: `Hot`, `Mild` o `Cool`.	Mild (6), Hot (4), Cool (4)
`humidity`	categórica	Humedad: `High` o `Normal`.	High (7), Normal (7)
`wind`	categórica	Viento: `Weak` (débil) o `Strong` (fuerte).	Weak (8), Strong (6)

Columna	Tipo	Significado	Valores
`play` `objetivo`	categórica	**Clase**: si se jugó al tenis ese día (`Yes` / `No`).	Yes (9), No (5)

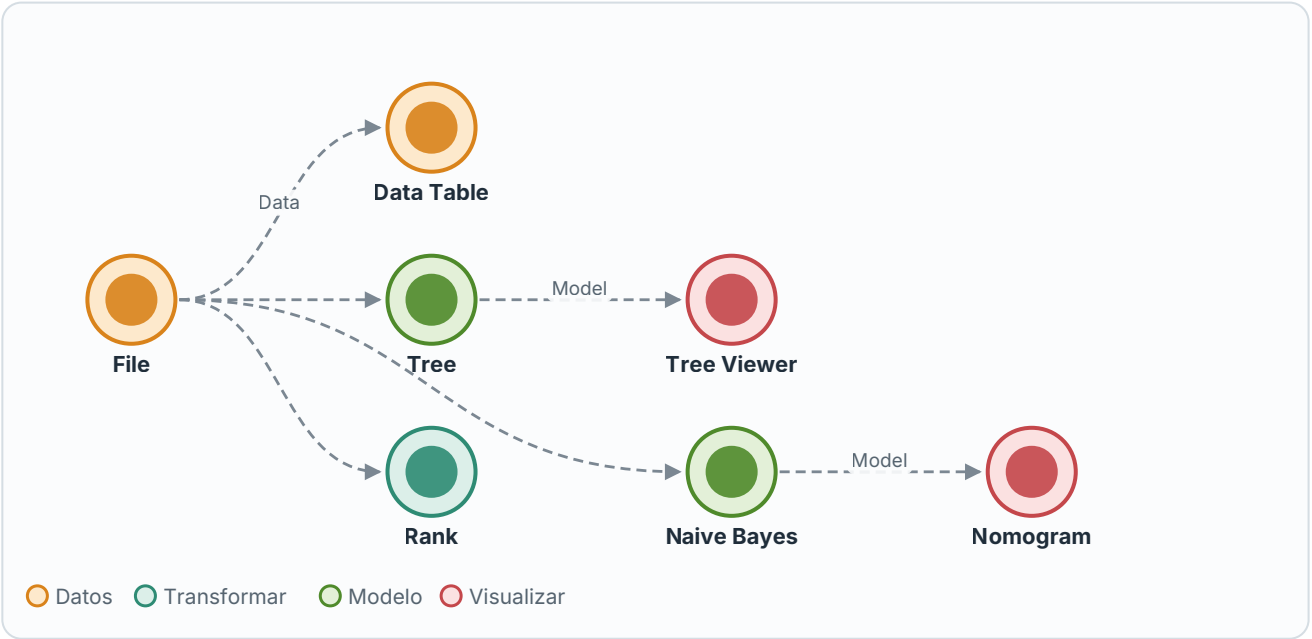
Columnas de `tennis_numerico` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`outlook`	categórica	Estado del cielo: `sunny` , `overcast` o `rainy` .	sunny (5), rainy (5), overcast (4)
`temperature`	numérica	Temperatura en grados Fahrenheit (de 64 a 85).	64 – 85
`humidity`	numérica	Humedad relativa en % (de 65 a 96).	65 – 96
`windy`	categórica	Si hacía viento (`TRUE` / `FALSE`).	False (8), True (6)
`play` `objetivo`	categórica	**Clase**: si se jugó (`yes` / `no`).	yes (9), no (5)

5 Particularidades técnicas al modelar

- **Muy pocos casos**: con 14 días, cualquier medida de acierto es casi aleatoria. En una prueba con validación cruzada de 5 bolsas, el árbol acierta un 71 % y Naive Bayes un 64 %, lo mismo que decir siempre «sí». El dataset sirve para explicar cómo se construye un modelo, no para compararlos.
- **El identificador del día es una trampa**: si `day` se usa como atributo, tiene 14 valores distintos y separa los días a la perfección, así que el criterio de ganancia de información lo elegiría primero. Es el ejemplo clásico de por qué C4.5 usa la razón de ganancia. Orange lo carga como *meta*; déjalo así.
- **Los dos ficheros son los mismos días** en el mismo orden: el día `D1` es el de 85 °F y 85 % de humedad. Comparar el árbol de las dos versiones muestra cómo elige umbrales un árbol con variables numéricas.
- Todos los valores están presentes y no hay días repetidos con clase distinta.

6 Flujo de trabajo en Orange



1. **File** con `tennis` (`day` como *meta*, `play` como *target*) → **Data Table**.
2. **Rank** con *Information Gain*: `outlook` es el atributo que más informa. Prueba a poner `day` como atributo y mira cómo se dispara su ganancia.

3. **Tree** (sin poda: profundidad libre y mínimo de 1 caso por hoja) → **Tree Viewer**: el árbol de ID3.
4. **Naive Bayes** → **Nomogram**: cuánto suma cada valor a la probabilidad de jugar.
5. Repite con `tennis_numerico` y mira los umbrales que elige el árbol para la humedad.

7 Otras consideraciones

- **Ejercicio de pizarra**: calcula a mano la entropía de la clase (0,94 bits) y la ganancia de `outlook` (0,25 bits), y comprueba el resultado con *Rank*.
- **Predecir un día nuevo**: crea una tabla con un día (por ejemplo, sol, frío, humedad alta y viento fuerte) y pásala a *Predictions* junto al árbol.
- Para practicar con más datos y la misma idea, *Sailing* tiene 20 casos y clases que se contradicen, y *Car Evaluation* tiene 1.728.

En la carpeta	`tennis` ← `tennis.csv` (curso_ciencia_datos (GitHub))
En la carpeta	`tennis_numerico` ← `tennis.arff` (curso_ciencia_datos (GitHub))

1.03
Clasificación: introductorios y de juguete

Sailing

`01_clasificacion_introductorios/sailing/`

Veinte fines de semana de Sara, aficionada a la vela: con qué tiempo, compañía y barco salió a navegar. Un ejemplo inventado para explicar árboles de decisión, con casos que se contradicen.

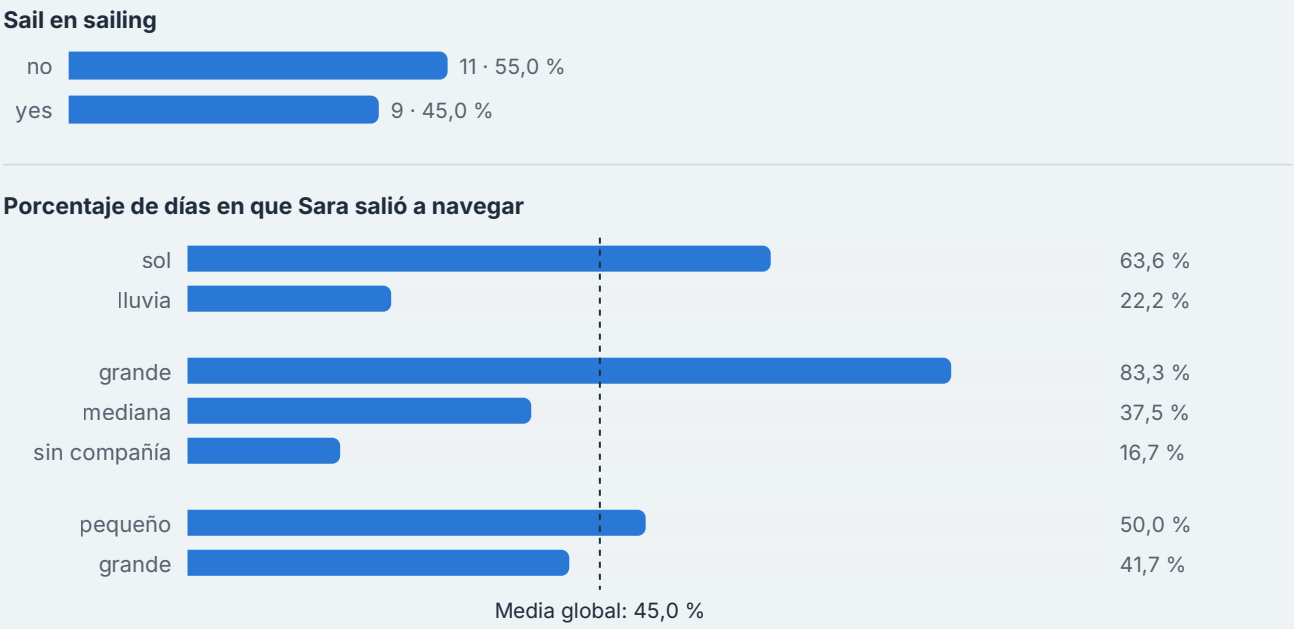
Clasificación binaria · Juguete · Sintético · Solo categóricos

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
20	**4**	`Sail`	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`sailing`	20 × 4	CSV 1 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/01_clasificacion_introductorios/sailing/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Son **20 registros** de una persona, Sara, que navega los fines de semana. Cada uno dice qué tiempo hacía (`Outlook`), con qué compañía contaba (`Company`) y qué barco tenía disponible (`Sailboat`), y si finalmente salió a navegar (`Sail`): 9 veces sí y 11 no.

Los estudios habituales son:

- **Construir un árbol de decisión a mano** y comprobarlo con Orange.
- **Ver qué pasa cuando los datos se contradicen**: hay días iguales en todo con decisión distinta.

- **Explicar la diferencia entre ajustar los datos y generalizar**, con un conjunto tan pequeño que se ve entero.

2 Contexto y fuente original

Es un conjunto hecho a mano en 2003 por el laboratorio de bioinformática de la Universidad de Liubliana (los autores de Orange) para explicar la inducción de árboles de clasificación. Viene con Orange y se carga con el widget *Datasets*. No hay fuente externa ni artículo asociado.

- Sailing, en datasets.biolab.si (widget Datasets de Orange)

3 Variable objetivo

La clase es `Sail`: si Sara salió a navegar (`yes`) o no (`no`). Está casi equilibrada: 9 frente a 11.

El tiempo es lo que más pesa: con lluvia salió 2 de 9 veces y con sol, 7 de 11. Con compañía grande salió 5 de 6 veces y sin compañía, 1 de 6.

4 Diccionario de columnas

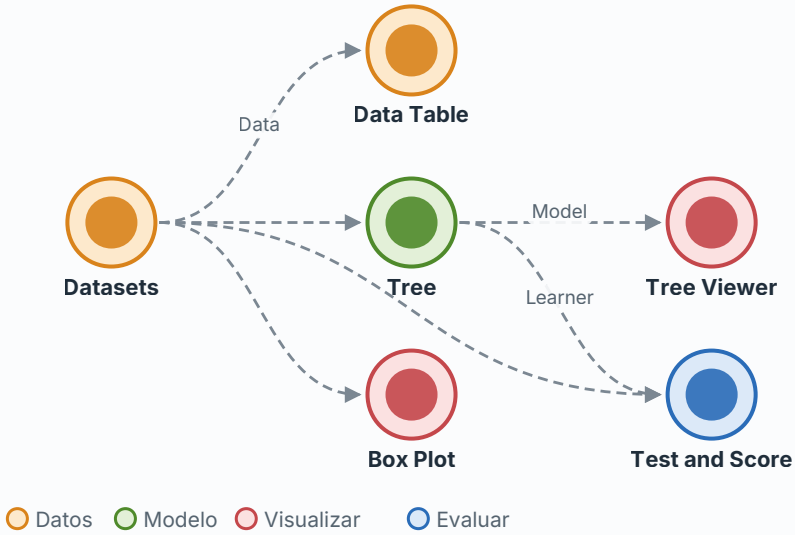
Columnas de `sailing` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Outlook`	categórica	Tiempo: `rainy` (lluvia) o `sunny` (sol).	sunny (11), rainy (9)
`Company`	categórica	Compañía: `big` (grupo grande), `med` (mediana) o `no` (sola).	med (8), big (6), no (6)
`Sailboat`	categórica	Barco disponible: `big` (grande) o `small` (pequeño).	big (12), small (8)
`Sail` `objetivo`	categórica	**Clase**: si salió a navegar (`yes` / `no`).	no (11), yes (9)

5 Particularidades técnicas al modelar

- **Casos contradictorios**: hay días iguales con decisión distinta. Con sol, compañía mediana y barco grande salió dos veces y no salió otras dos; con sol, compañía grande y barco pequeño, una vez sí y otra no. Ningún modelo puede acertar los 20 casos: el máximo posible es 17.
- **Muy pocos casos**: en una prueba con validación cruzada, un árbol acierta un 60 % y Naive Bayes un 65 %, frente al 55 % de decir siempre «no». Sirve para explicar, no para comparar modelos.
- **Árbol sin poda**: para que el árbol de Orange se parezca al que se hace a mano, en *Tree* quita el límite de profundidad y deja en 1 el mínimo de casos por hoja. Con los valores por defecto el árbol sale más corto.
- Todas las variables son categóricas y no hay valores ausentes.

6 Flujo de trabajo en Orange



1. **Datasets** → «Sailing» (o **File** con el CSV) → **Data Table**: ordena por las tres variables y busca los días repetidos con decisión distinta.
2. **Box Plot** con `Sail` como variable de agrupación: qué valores de cada variable acompañan a las salidas.
3. **Tree** sin poda → **Tree Viewer**: hojas que no son puras, porque los datos se contradicen.
4. **Test and Score** con *Leave one out*: el acierto real está lejos del 85 % que se ve sobre los propios datos.

7 Otras consideraciones

- **Ejercicio**: pide a los alumnos que escriban sus propias reglas para Sara antes de ver el árbol, y que cuenten cuántos casos fallan.
- **Añadir variables**: inventar una cuarta variable (por ejemplo, la temperatura) y ver si resuelve las contradicciones es una buena forma de explicar que a veces faltan datos, no modelos mejores.
- Con la misma idea y algo más de complejidad: *Tennis* (14 casos, sin contradicciones) y *Car Evaluation* (1.728).

En la carpeta `sailing` ← `sailing.tab` (datasets.biolab.si)

1.04
Clasificación: introductorios y de juguete

Lenses (lentes de contacto)

`01_clasificacion_introductorios/lenses/`

Las 24 combinaciones posibles de edad, graduación, astigmatismo y lagrimeo, con el tipo de lente de contacto recomendado: un problema pequeño, completo y sin ruido para aprender reglas y árboles.

Clasificación multiclase · Juguete · Solo categóricos

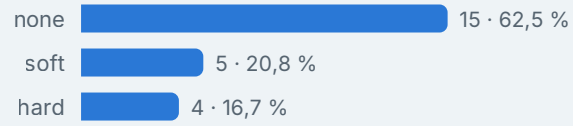
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
24	**5**	`lenses`	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`lenses`	24 × 5	CSV 1 KB · XLSX

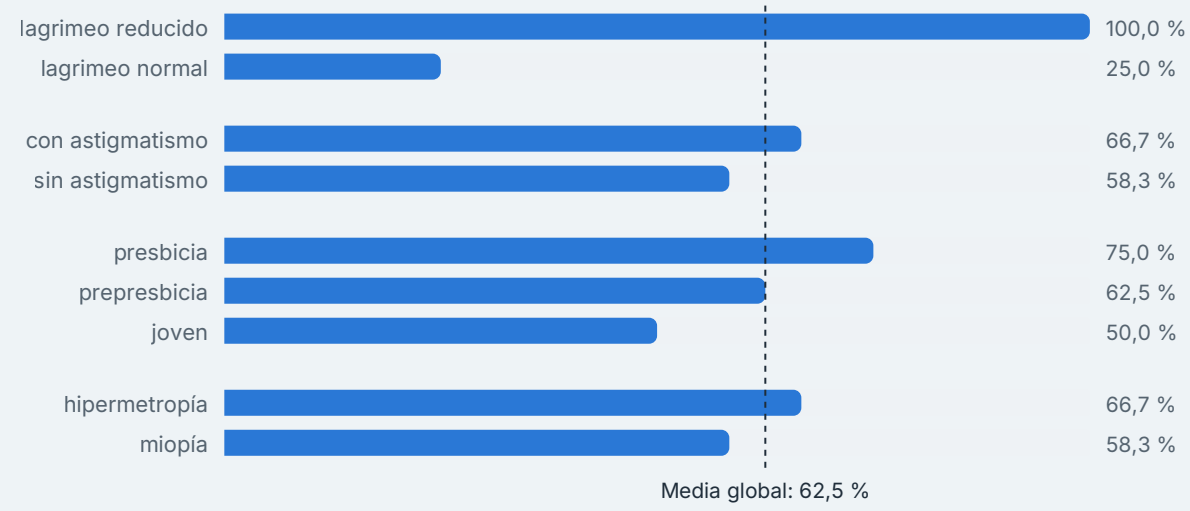
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/01_clasificacion_introductorios/lenses/` seguido del nombre del fichero CSV.

Radiografía

lenses en lenses



Porcentaje de casos sin lente recomendada



1 Descripción general y estudios habituales

Son **24 pacientes ficticios**, uno por cada combinación de cuatro características: la edad (tres grupos), el tipo de graduación (miopía o hipermetropía), si hay astigmatismo y la producción de lágrima (normal o reducida). Para cada uno se indica qué lente de contacto le conviene: **dura**, **blanda** o **ninguna**.

Los estudios habituales son:

- **Aprender reglas de decisión** (es el ejemplo original del algoritmo PRISM) y compararlas con un árbol.
- **Clasificación multiclase** con muy pocos datos.
- **Ver la diferencia entre describir y predecir**: el árbol describe los 24 casos sin error, pero al quitar uno no siempre lo acierta.

2 Contexto y fuente original

Lo publicó **Jadzia Cendrowska** en 1987 para presentar PRISM, un algoritmo que induce reglas modulares, y está en el repositorio UCI desde 1990. Viene del campo de la óptica oftálmica y es una simplificación: las 24 filas son la tabla completa de combinaciones, no pacientes reales, y la recomendación sigue reglas fijas.

- Cendrowska, J. (1987). PRISM: An algorithm for inducing modular rules. International Journal of Man-Machine Studies, 27(4), 349–370.
- Lenses en el repositorio UCI

3 Variable objetivo

La clase es `lenses`, con tres valores: `none` (ninguna lente, 15 casos), `soft` (blanda, 5) y `hard` (dura, 4).

La regla más fuerte es la primera del árbol: **si la producción de lágrima es reducida, ninguna lente** (los 12 casos). Con lagrimeo normal, el astigmatismo separa las lentes duras de las blandas, y la edad y la graduación resuelven los casos que quedan.

4 Diccionario de columnas

Columnas de `lenses` (valores observados en el fichero)

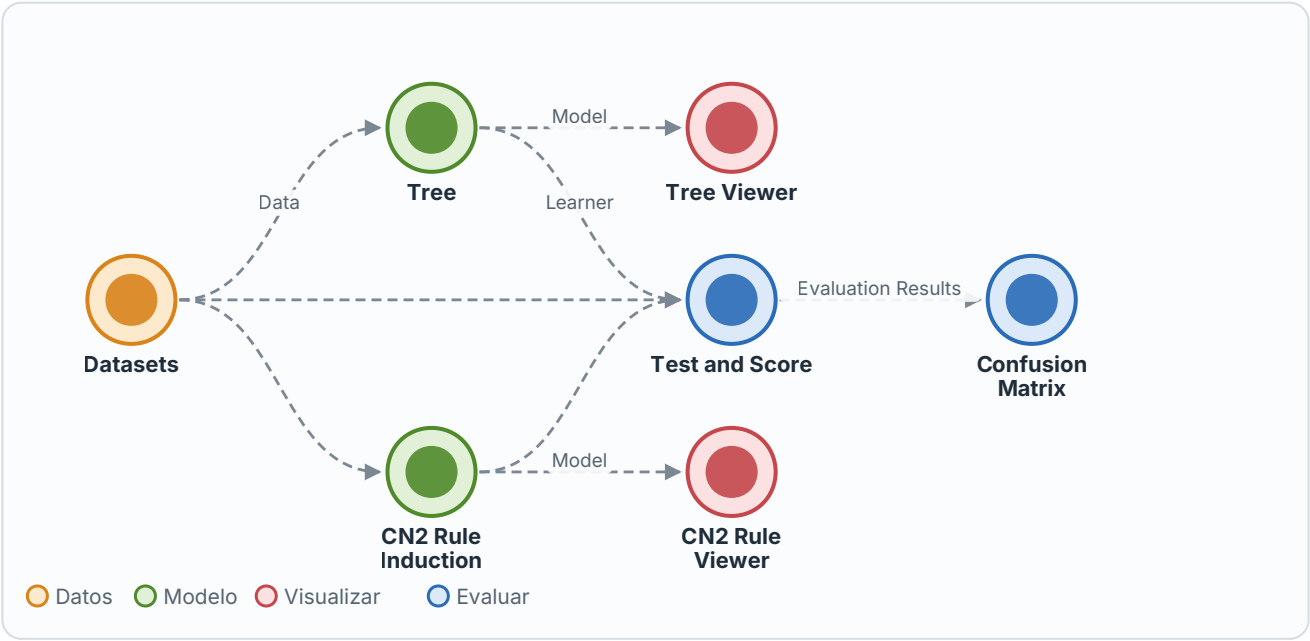
Columna	Tipo	Significado	Valores
`age`	categórica	Grupo de edad: `young` (joven), `pre-presbyopic` (antes de la vista cansada) o `presbyopic` (con vista cansada).	young (8), pre-presbyopic (8), presbyopic (8)
`prescription`	categórica	Graduación: `myope` (miopía) o `hypermetrope` (hipermetropía).	myope (12), hypermetrope (12)
`astigmatic`	categórica	Si hay astigmatismo (`yes` / `no`).	no (12), yes (12)
`tear_rate`	categórica	Producción de lágrima: `reduced` (reducida) o `normal`.	reduced (12), normal (12)
`lenses` `objetivo`	categórica	**Clase**: lente recomendada, `hard` (dura), `soft` (blanda) o `none` (ninguna).	none (15), soft (5), hard (4)

5 Particularidades técnicas al modelar

- **No es una muestra, es la tabla completa**: cada combinación aparece una vez. No hay ruido ni casos repetidos, así que un árbol sin poda reproduce los 24 casos sin error.
- **Por eso la validación cruzada engaña poco y enseña mucho**: al quitar un caso, el modelo tiene que adivinar una combinación que no ha visto nunca. En una prueba con validación cruzada de 4 bolsas, el árbol acierta un 67 % y Naive Bayes un 79 %, frente al 62,5 % de decir siempre «ninguna».

- **Clases desequilibradas en miniatura**: con 4 casos de lente dura, un solo error cambia mucho la exactitud de esa clase. Mira la matriz de confusión, no solo el acierto global.
- Las reglas (widget *CN2 Rule Induction*) son aquí más naturales que el árbol, y es el contexto en que se propuso el dataset.

6 Flujo de trabajo en Orange



1. **Datasets** → «Lenses» (o **File** con el CSV).
2. **Tree** → **Tree Viewer**: la primera pregunta es el lagrimeo.
3. **CN2 Rule Induction** → **CN2 Rule Viewer**: compara las reglas con el árbol; ¿cuál se explica mejor?
4. **Test and Score** con *Leave one out*: acierto de cada modelo cuando tiene que adivinar una combinación que no ha visto.
5. **Confusion Matrix**: qué clases se confunden (sobre todo las lentes duras).

7 Otras consideraciones

- **Ejercicio de lápiz y papel**: con solo 24 filas, se puede pedir a los alumnos que encuentren las reglas a mano antes de usar Orange.
- **Comparar con el original**: el artículo de Cendrowska da las reglas que obtiene PRISM; contrastarlas con las de CN2 es un buen ejercicio de lectura.
- Para un conjunto completo y sin ruido pero mucho mayor, ver *Car Evaluation* (1.728 combinaciones).

En la carpeta `lenses` ← `lenses.tab` (datasets.biolab.si)

1.05
Clasificación: introductorios y de juguete

Naughty or nice

`01_clasificacion_introductorios/naughty_nice/`

Treinta niños ficticios, sus tareas de casa y sus travesuras, y el veredicto de Papá Noel: bueno o malo. Un conjunto inventado para enseñar regresión logística y nomogramas.

Clasificación binaria · ◦ Juguete · ✎ Sintético

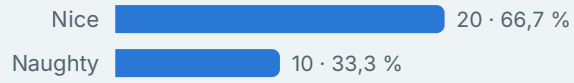
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
30	**8**	`Santa's Score`	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`naughty_nice`	30 × 8	CSV 1 KB · XLSX

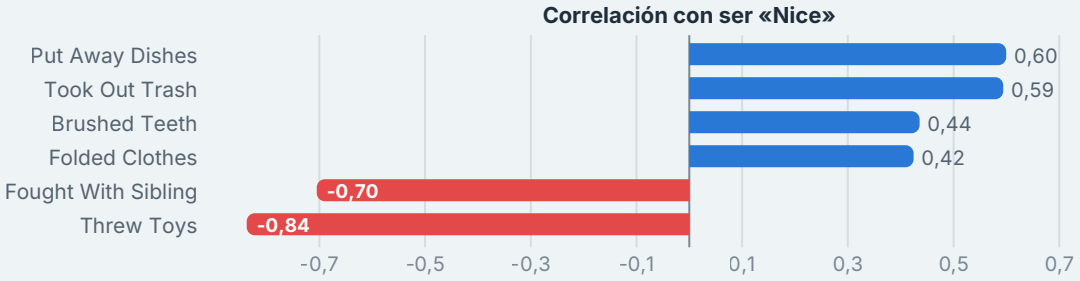
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/01_clasificacion_introductorios/naughty_nice/` seguido del nombre del fichero CSV.

Radiografía

Santa's Score en naughty_nice



Qué conductas acompañan a ser bueno



1 Descripción general y estudios habituales

Son **30 niños inventados**, cada uno con su nombre y seis recuentos de lo que ha hecho en la semana: cuántas veces ha recogido los platos, sacado la basura, doblado la ropa o se ha lavado los dientes, y cuántas veces se ha peleado con sus hermanos o ha tirado los juguetes. Papá Noel ha decidido si cada niño ha sido bueno (`Nice`, 20) o malo (`Naughty`, 10).

Los estudios habituales son:

- **Regresión logística**: qué conductas suman y cuáles restan para ser «bueno».
- **Interpretar un modelo con el nomograma**: cuánto cambia la probabilidad con cada tarea hecha o cada travesura.

- **Comparar modelos** sobre un problema casi separable.

2 Contexto y fuente original

Lo creó en 2024 el laboratorio de bioinformática de la Universidad de Liubliana (los autores de Orange) como dataset educativo para la regresión logística, con la excusa navideña. Es sintético: los niños, sus nombres y los recuentos son inventados. Viene con Orange y se carga con el widget *Datasets*.

- Naughty or Nice, en datasets.biolab.si (widget Datasets de Orange)

3 Variable objetivo

La clase es `Santa's Score`: `Nice` (20 niños) o `Naughty` (10).

Las diferencias son claras: los niños «buenos» recogen los platos 2,3 veces de media, frente a 1,1 los «malos», y tiran los juguetes 0,6 veces frente a 2,4. Con estas variables el problema es casi separable: en una prueba con validación cruzada, todos los modelos aciertan al menos 29 de los 30 niños.

4 Diccionario de columnas

Columnas de `naughty_nice` (valores observados en el fichero)

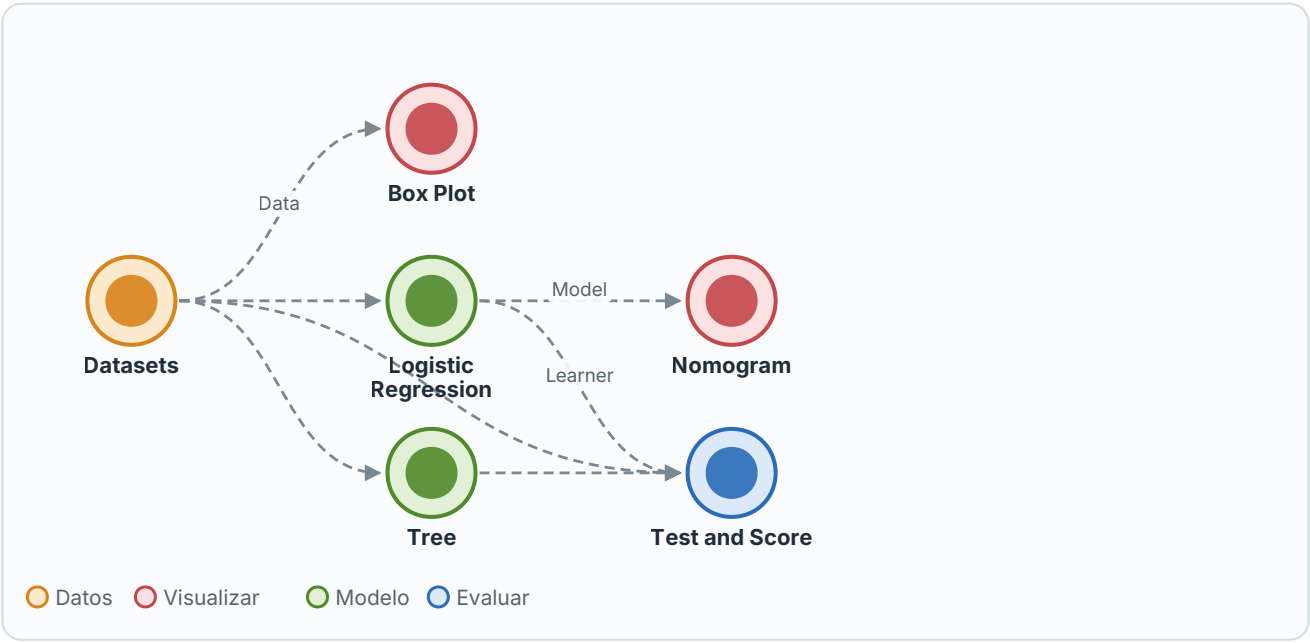
Columna	Tipo	Significado	Valores
`Santa's Score` objetivo	categórica	**Clase**: el veredicto de Papá Noel, `Nice` (bueno) o `Naughty` (malo).	Nice (20), Naughty (10)
`Name`	texto	Nombre del niño (inventado). Es un identificador: en Orange va como *meta*.	Yasmine (1), Liam (1), Fiona (1), Ben (1), Sophie (1), Laura (1) …
`Put Away Dishes`	numérica	Veces que recogió los platos (0 a 3).	0 – 3
`Took Out Trash`	numérica	Veces que sacó la basura (0 a 3).	0 – 3
`Folded Clothes`	numérica	Veces que dobló la ropa (0 a 3).	0 – 3
`Fought With Sibling`	numérica	Veces que se peleó con sus hermanos (0 a 3).	0 – 3
`Threw Toys`	numérica	Veces que tiró los juguetes (0 a 3).	0 – 3
`Brushed Teeth`	numérica	Veces que se lavó los dientes (0 a 3).	0 – 3

5 Particularidades técnicas al modelar

- **Casi separable**: con datos tan limpios, la regresión logística sin regularización puede dar coeficientes enormes. Deja la regularización por defecto de Orange (*Ridge*, C = 1) para que el nomograma sea legible.
- **Variables en la misma escala** (de 0 a 3): los coeficientes se pueden comparar directamente sin normalizar, lo que hace el ejemplo muy cómodo para explicar.
- **Clase desequilibrada 2:1**: acertar siempre «Nice» ya da un 67 %. Compara cualquier modelo con esa referencia.
- **Pocos casos**: 30 niños. Los resultados de la validación cruzada varían bastante según cómo caigan las bolsas.

- El apóstrofo del nombre de la clase es tipográfico (`’`), no el recto (`'`). Si se escribe a mano en una fórmula, hay que copiarlo tal cual.

6 Flujo de trabajo en Orange



1. **Datasets** → «Naughty or Nice».
2. **Box Plot** de cada variable agrupada por la clase: las tareas de casa separan, las travesuras también.
3. **Logistic Regression** → **Nomogram**: los puntos que suma cada tarea y los que resta cada travesura.
4. **Test and Score** con regresión logística y árbol: los dos aciertan casi todo; compara el AUC.

7 Otras consideraciones

- **Juego en clase**: cada alumno inventa un niño (seis números) y el nomograma predice si Papá Noel le traerá regalos.
- **Quitar variables**: con solo dos variables (una tarea y una travesura) el *Scatter Plot* muestra la frontera de la regresión logística a simple vista.
- Para un ejemplo real con la misma técnica, ver *Titanic* o *Stroke*.

En la carpeta `naughty_nice` ← `naughty-nice.tab` (datasets.biolab.si)

1.06
Clasificación: introductorios y de juguete

Gnomes (gnomos)

`01_clasificacion_introductorios/gnomes/`

Veintiún gnomos de jardín descritos por su aspecto (gorro, lámpara, pala, zapatos…): de 15 se sabe el oficio y de 6 hay que adivinarlo. Una actividad de primaria para descubrir reglas y árboles de decisión.

Clasificación multiclase · ? Valores faltantes · ∘ Juguete · ✎ Sintético · ◇ Solo categóricos

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
21	**10**	`profession`	**2,9 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`gnomes`	21 × 10	CSV 1 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/01_clasificacion_introductorios/gnomes/` seguido del nombre del fichero CSV.

Radiografía

profession en gnomes



1 Descripción general y estudios habituales

Son **21 gnomos**, cada uno con su nombre y ocho rasgos visibles: hacia qué lado cae el gorro, si lleva lámpara o pala, el color de los zapatos y del cinturón, si el cinturón tiene hebilla, si tiene la boca abierta y si los pantalones tienen el borde negro. De **15** se conoce el oficio (minero, jardinero, constructor o sastre); de los **6** restantes, no.

Los estudios habituales son:

- **Descubrir reglas a mano** para saber el oficio por el aspecto y compararlas con las que encuentra el ordenador.
- **Construir un árbol de decisión** y usarlo para clasificar a los 6 gnomos sin oficio.
- **Hablar de qué es un modelo** con alumnos muy jóvenes, sin fórmulas.

2 Contexto y fuente original

Es la actividad *¿Qué hacen los gnomos?* del proyecto educativo del laboratorio de bioinformática de la Universidad de Liubliana (los autores de Orange) para enseñar inteligencia artificial en primaria y secundaria, que ahora se publica en la web *Gairdin*. Los alumnos trabajan primero con tarjetas de los gnomos y después con un flujo de Orange ya preparado, que carga este dataset desde *Datasets*.

Hay versiones traducidas con los mismos datos: en esloveno (`palcki`), alemán (`zwerge`) y francés (`nains`). Aquí solo se incluye la inglesa.

- «Prediction Models» (actividades de los gnomos, los cuadriláteros y el árbol de los animales), notas del laboratorio de bioinformática de Liubliana
- «Gairdin: Gnomes with the Youngest Students», blog de Orange (A. Farič, 2026)

3 Variable objetivo

La clase es `profession` : `miner` (minero, 3), `gardener` (jardinero, 4), `builder` (constructor, 4) y `tailor` (sastre, 4). Los otros 6 gnomos tienen el oficio vacío: son los que hay que predecir.

Dos preguntas bastan para clasificar a los 15 conocidos: **¿lleva pala?** Si la lleva, es minero cuando además lleva lámpara y jardinero cuando no. Si no lleva pala, es sastre cuando el cinturón tiene hebilla y constructor cuando no. Con ese árbol, los 6 sin oficio serían: Basil constructor, Otto y Monty mineros, Elroy y Finnian jardineros y Alfie sastre.

4 Diccionario de columnas

Columnas de `gnomes` (valores observados en el fichero)

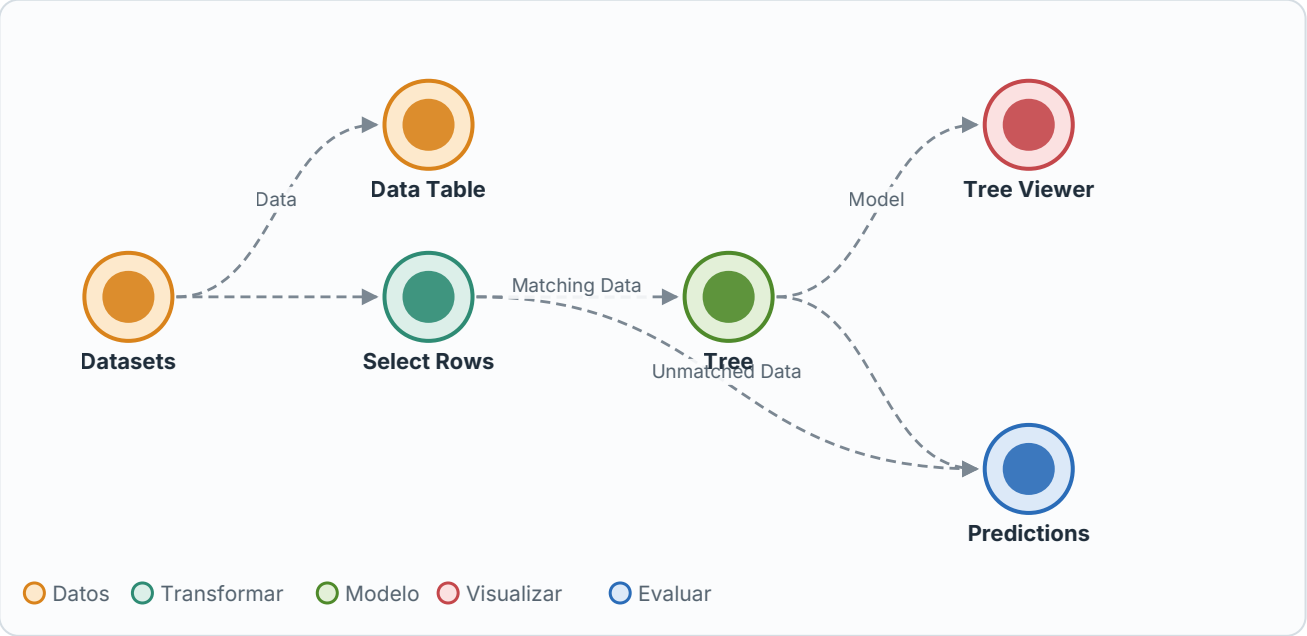
Columna	Tipo	Significado	Valores
`name`	texto	Nombre del gnomo. Es un identificador: en Orange va como *meta*.	Albie (1), Nedrick (1), Fritz (1), Ollie (1), Percy (1), Wilbur (1) …
`hat`	categórica	Hacia qué lado cae la punta del gorro (`left` / `right`).	left (12), right (9)
`lamp`	categórica	Si lleva lámpara (`yes` / `no`).	no (16), yes (5)
`shovel`	categórica	Si lleva pala (`yes` / `no`).	yes (11), no (10)
`shoes`	categórica	Color de los zapatos (`black` / `white`).	white (11), black (10)
`belt buckle`	categórica	Si el cinturón tiene hebilla (`yes` / `no`).	no (14), yes (7)
`open mouth`	categórica	Si tiene la boca abierta (`yes` / `no`).	yes (11), no (10)
`black pant cuffs`	categórica	Si el borde de los pantalones es negro (`yes` / `no`).	no (11), yes (10)
`belt`	categórica	Color del cinturón (`black` / `white`).	black (12), white (9)
`profession` `objetivo`	categórica	**Clase**: oficio del gnomo. Vacío en los 6 que hay que adivinar.	gardener (4), builder (4), tailor (4), miner (3)

5 Particularidades técnicas al modelar

- **Los 6 gnomos sin oficio no son datos que falten por error**: son el conjunto que hay que predecir. Orange los deja fuera al entrenar (no tienen clase) y los clasifica en *Predictions*. Para separarlos explícitamente, usa *Select Rows* con la condición `profession` *is defined*.
- **Hay rasgos que distraen**: el gorro, la boca o el color de los zapatos no ayudan a saber el oficio. Es una buena ocasión para hablar de variables irrelevantes.

- **Muy pocos casos**: con 15 gnomos, la validación cruzada no tiene sentido como medida de calidad. El interés está en entender el árbol y comprobarlo con los gnomos nuevos.
- El árbol de Orange coincide con el razonamiento que suelen hacer los niños («¿tiene pala?»), lo que lo hace ideal para presentar la idea de modelo.

6 Flujo de trabajo en Orange



1. **Datasets** → «Gnomes» → **Data Table**: los 21 gnomos; ordena por `profession` y busca reglas.
2. **Select Rows** con `profession` *is defined*: la salida *Matching Data* son los 15 con oficio y *Unmatched Data*, los 6 sin él.
3. **Tree** con los 15 → **Tree Viewer**: dos preguntas, pala y luego lámpara o hebilla.
4. **Predictions** con el árbol y los 6 gnomos sin oficio: ¿coincide con lo que habías deducido a mano?

7 Otras consideraciones

- **Actividad desenchufada primero**: con las tarjetas impresas de los gnomos, los alumnos ordenan y deducen las reglas antes de abrir Orange. El material está en la web del proyecto.
- **Cambiar un dato**: modifica un rasgo de un gnomo (por ejemplo, quítale la pala a un minero) y observa cómo cambia el árbol. Muestra lo sensible que es un modelo con tan pocos datos.
- Otras actividades del mismo proyecto con datos de Orange: el árbol de los animales (dataset *Zoo*).

En la carpeta	`gnomes` ← `gnomes.xlsx` (datasets.biolab.si)
Traducción, no se copia	`palcki.xlsx` (datasets.biolab.si)
Traducción, no se copia	`zwerge.xlsx` (datasets.biolab.si)
Traducción, no se copia	`nains.xlsx` (datasets.biolab.si)

1.07
Clasificación: introductorios y de juguete

Zoo

`01_clasificacion_introductorios/zoo/`

Cien animales descritos por 16 rasgos (pelo, plumas, huevos, leche, aletas, patas…) y su grupo: mamífero, ave, pez, reptil, anfibio, insecto u otro invertebrado. El clásico para árboles de decisión con varias clases.

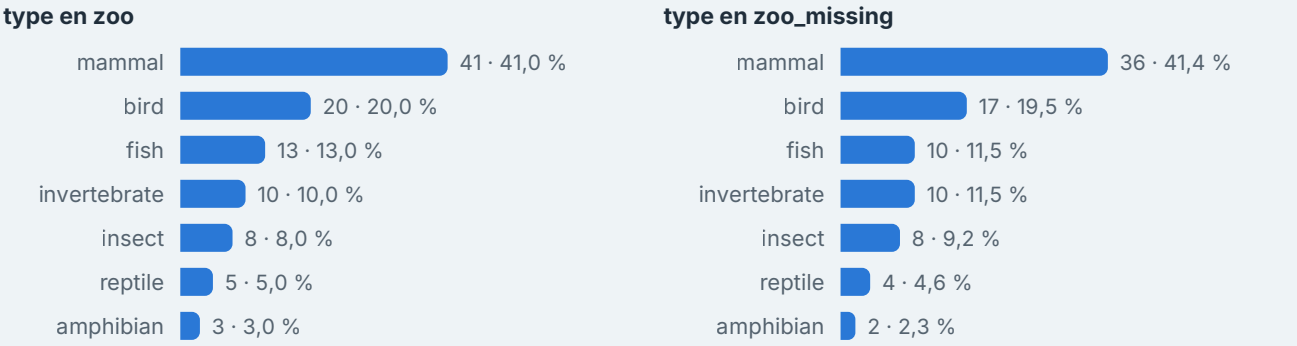
Clasificación multiclase · ⚖ Desbalanceado · ? Valores faltantes · ◇ Solo categóricos

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
100	**18**	`type`	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`zoo`	100 × 18	CSV 7 KB · XLSX
`zoo_missing`	100 × 18	CSV 7 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/01_clasificacion_introductorios/zoo/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Son **100 animales**, del oso hormiguero a la avispa, cada uno descrito por 15 rasgos de sí o no (si tiene pelo, plumas o aletas, si pone huevos, si da leche, si vuela, si es acuático, depredador o venenoso…) y por el número de patas. La clase es el grupo zoológico, con siete valores.

Hay dos versiones:

- `zoo`: los 100 animales, todos clasificados.
- `zoo_missing`: una variante para clase, con algunos nombres cambiados y **13 animales sin grupo** que hay que predecir.

Los estudios habituales son:

- **Clasificación multiclase con un árbol de decisión**, fácil de comprobar con conocimientos de biología.
- **Buscar las reglas** que distinguen cada grupo (plumas → ave, leche → mamífero…).
- **Agrupar animales** sin usar la clase y ver si salen los grupos zoológicos.

2 Contexto y fuente original

Lo creó **Richard Forsyth** y está en el repositorio UCI desde 1990. La versión original tiene 101 animales: incluye dos veces la rana y una «chica» (*girl*) como ejemplo de mamífero. La versión de Orange tiene 100, con «human» en lugar de *girl* y sin la rana repetida.

`zoo_missing` es una variante preparada por los autores de Orange para actividades en clase: los mismos rasgos, pero 39 animales con otro nombre (por ejemplo, *largemouth bass* en lugar de *bass*), las patas como categoría (`no`, 2, 4…) y 13 animales sin grupo. También hay versiones traducidas al alemán, francés, esloveno y finés, que aquí no se incluyen.

- Zoo en el repositorio UCI (R. Forsyth, 1990)
- «Classification Trees», notas del laboratorio de bioinformática de Liubliana (actividad con Zoo)

3 Variable objetivo

La clase es `type`, con siete grupos muy desiguales: `mammal` (41), `bird` (20), `fish` (13), `invertebrate` (10), `insect` (8), `reptile` (5) y `amphibian` (3).

Algunos grupos se reconocen por un solo rasgo (todos los animales con plumas son aves; todos los que dan leche, mamíferos), y otros necesitan varias preguntas: reptiles y anfibios son los más difíciles. En `zoo_missing` los 13 animales sin grupo son, entre otros, el delfín, el elefante, el murciélago, la salamandra y la serpiente marina.

4 Diccionario de columnas

Columnas de `zoo` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`hair`	categórica	Si tiene pelo (`yes` / `no`).	no (57), yes (43)
`feathers`	categórica	Si tiene plumas.	no (80), yes (20)
`eggs`	categórica	Si pone huevos.	yes (58), no (42)
`milk`	categórica	Si da leche (amamanta).	no (59), yes (41)
`airborne`	categórica	Si vuela.	no (76), yes (24)
`aquatic`	categórica	Si es acuático.	no (65), yes (35)
`predator`	categórica	Si es depredador.	yes (55), no (45)
`toothed`	categórica	Si tiene dientes.	yes (60), no (40)
`backbone`	categórica	Si tiene columna vertebral.	yes (82), no (18)
`breathes`	categórica	Si respira aire.	yes (79), no (21)
`venomous`	categórica	Si es venenoso.	no (93), yes (7)
`fins`	categórica	Si tiene aletas.	no (83), yes (17)
`legs`	categórica	Número de patas: 0, 2, 4, 5, 6 u 8 (categoría, no número).	4 (37), 2 (27), 0 (23), 6 (10), 8 (2), 5 (1)

Columna	Tipo	Significado	Valores
`tail`	categórica	Si tiene cola.	yes (75), no (25)
`domestic`	categórica	Si es doméstico.	no (87), yes (13)
`catsize`	categórica	Si es al menos del tamaño de un gato.	no (56), yes (44)
`type` objetivo	categórica	**Clase**: grupo zoológico (`mammal` , `bird` , `fish` , `reptile` , `amphibian` , `insect` , `invertebrate`).	mammal (41), bird (20), fish (13), invertebrate (10), insect (8), reptile (5) …
`name`	texto	Nombre del animal en inglés. En Orange va como *meta*.	aardvark (1), antelope (1), bass (1), bear (1), boar (1), buffalo (1) …

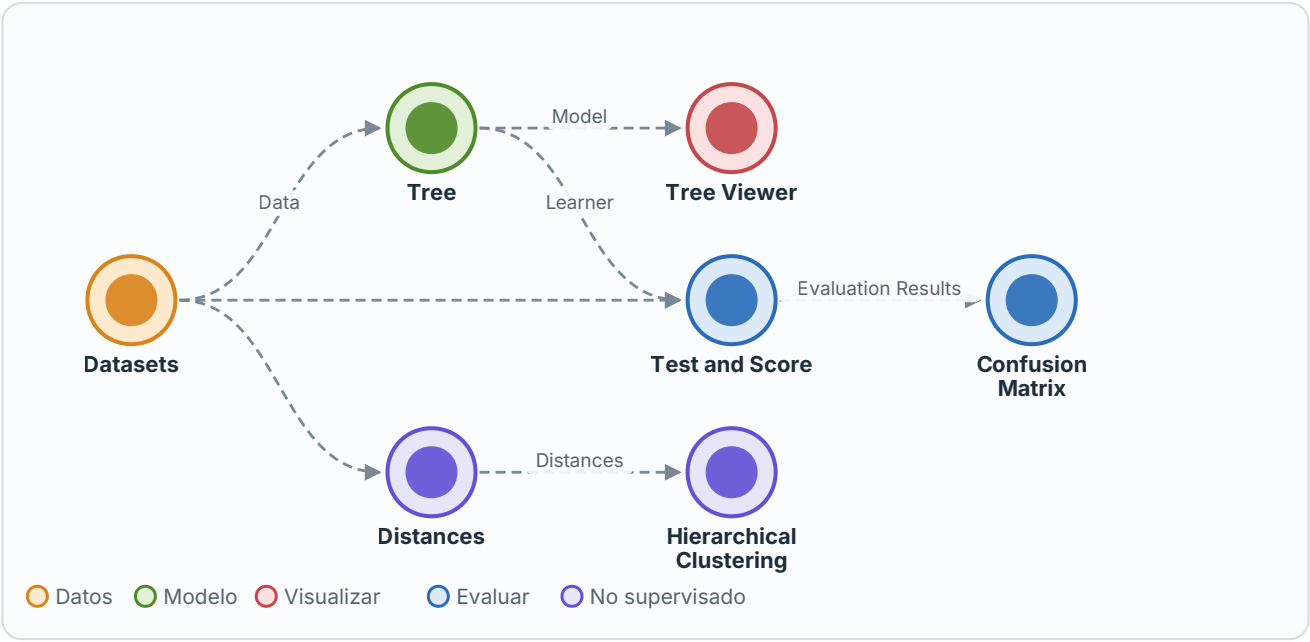
Columnas de `zoo_missing` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`hair`	categórica	Si tiene pelo (`yes` / `no`).	no (57), yes (43)
`feathers`	categórica	Si tiene plumas.	no (80), yes (20)
`eggs`	categórica	Si pone huevos.	yes (58), no (42)
`milk`	categórica	Si da leche (amamanta).	no (59), yes (41)
`airborne`	categórica	Si vuela.	no (76), yes (24)
`aquatic`	categórica	Si es acuático.	no (65), yes (35)
`predator`	categórica	Si es depredador.	yes (55), no (45)
`toothed`	categórica	Si tiene dientes.	yes (60), no (40)
`backbone`	categórica	Si tiene columna vertebral.	yes (82), no (18)
`breathes`	categórica	Si respira aire.	yes (79), no (21)
`venomous`	categórica	Si es venenoso.	no (93), yes (7)
`fins`	categórica	Si tiene aletas.	no (83), yes (17)
`legs`	categórica	Número de patas como categoría: `no` , 2, 4, 5, 6 u 8.	4 (37), 2 (27), no (23), 6 (10), 8 (2), 5 (1)
`tail`	categórica	Si tiene cola.	yes (75), no (25)
`domestic`	categórica	Si es doméstico.	no (87), yes (13)
`catsize`	categórica	Si es al menos del tamaño de un gato.	no (56), yes (44)
`type` objetivo	categórica	**Clase**: grupo zoológico. Vacío en 13 animales, los que hay que predecir.	mammal (36), bird (17), fish (10), invertebrate (10), insect (8), reptile (4) …
`name`	texto	Nombre del animal (39 distintos de los de `zoo` : sinónimos o especies cercanas).	aardvark (1), antelope (1), largemouth bass (1), bear (1), boar (1), bubalina (1) …

5 Particularidades técnicas al modelar

- **Clases muy desiguales**: 41 mamíferos frente a 3 anfibios. Con validación cruzada de 10 bolsas, alguna bolsa queda sin anfibios; usa validación estratificada y mira la matriz de confusión por clase.
- **Muchos animales idénticos**: 42 de los 100 tienen exactamente los mismos rasgos que otro (por ejemplo, varios peces). Nunca con grupo distinto, así que no hay contradicciones, pero sí inflan un poco el acierto en validación cruzada.
- **Rasgos casi definitorios**: `feathers` y `milk` separan aves y mamíferos sin error. Aun así, el árbol de Orange empieza por `legs`, porque con sus seis valores separa varios grupos a la vez. Compáralo con el que haría un biólogo; el reto está en reptiles, anfibios e invertebrados.
- En una prueba con validación cruzada estratificada de 3 bolsas (por los 3 anfibios), el árbol acierta un 94 % y un bosque aleatorio un 97 %.
- `zoo_missing` **no es** `zoo` **con huecos**: cambia nombres y el tipo de `legs`. Úsalo para la actividad de predecir los 13 animales, no para comparar resultados con `zoo`.

6 Flujo de trabajo en Orange



1. **Datasets** → «Zoo» (o **File** con `zoo`).
2. **Tree** → **Tree Viewer**: el árbol de Orange empieza por el número de patas (una rama por valor) y luego pregunta por pelo, aletas o dientes; sigue las ramas hasta los reptiles.
3. **Test and Score** con validación estratificada → **Confusion Matrix**: qué grupos se confunden.
4. **Distances** (por ejemplo, Jaccard o Hamming) → **Hierarchical Clustering** con el nombre como etiqueta: ¿se agrupan los animales como los clasifica la biología?
5. Con `zoo_missing`: entrena el árbol con los animales que tienen grupo y usa **Predictions** con los 13 que no.

7 Otras consideraciones

- **El árbol de los animales en primaria**: los alumnos añaden animales uno a uno y el árbol se va adaptando. La actividad está en las notas del laboratorio de Liubliana.
- **Animales raros**: el ornitorrinco (pone huevos y da leche) y el murciélago o el delfín (mamíferos que vuelan o nadan) son buenos casos para comentar con el árbol.
- **Reglas**: *CN2 Rule Induction* da reglas por clase que se leen como una clave de identificación.

En la carpeta	`zoo` ← `zoo.tab` (datasets.biolab.si)
En la carpeta	`zoo_missing` ← `zoo-missing.tab` (datasets.biolab.si)
Traducción, no se copia	`tiere.tab` (datasets.biolab.si)
Traducción, no se copia	`animaux.tab` (datasets.biolab.si)
Traducción, no se copia	`zivali.tab` (datasets.biolab.si)
Traducción, no se copia	`zivali-z-neznanimi.tab` (datasets.biolab.si)
Traducción, no se copia	`zivali-v-finscini.tab` (datasets.biolab.si)
Traducción, no se copia	`zoo-finnish.tab` (datasets.biolab.si)

1.08
Clasificación: introductorios y de juguete

Titanic (supervivientes)

`01_clasificacion_introductorios/titanic/`

Las 2.201 personas que viajaban en el Titanic, descritas por clase, edad y sexo, y si sobrevivieron al hundimiento de 1912.

Clasificación binaria ◇ Solo categóricos

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
2.201	**4**	`survived`	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`titanic`	2.201 × 4	CSV 45 KB · XLSX
`titanic_numerico`	2.201 × 4	CSV 18 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/01_clasificacion_introductorios/titanic/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Cada fila es una persona que iba a bordo del RMS Titanic en su viaje inaugural, en abril de 1912: pasajeros de primera, segunda y tercera clase y también la tripulación. De cada una se conocen solo cuatro datos, todos categóricos: la clase (o si era tripulante), si era adulto o niño, el sexo y si sobrevivió.

Es el dataset más usado para dar los primeros pasos en clasificación porque la pregunta se entiende sin explicaciones y los patrones se ven a simple vista. Los estudios habituales son:

- **Predecir la supervivencia** (clasificación binaria) con árboles de decisión, Naive Bayes o regresión logística.
- **Explicar el resultado**: comprobar hasta qué punto se cumplió el «mujeres y niños primero» y cómo pesó la clase.
- **Explorar relaciones entre variables categóricas** con diagramas de mosaico y de tamiz.
- **Buscar reglas de asociación** del tipo {sexo = mujer, clase = primera} ⇒ sobrevive.

2 Contexto y fuente original

Los datos los recopiló Robert J. MacG. Dawson a partir del informe de la investigación oficial británica sobre el naufragio (*Report on the Loss of the «Titanic» (S.S.)*, British Board of Trade, reeditado en 1990) y los publicó en 1995 en el *Journal of Statistics Education*. Dawson partía de una tabla que circulaba en clases de estadística como un «episodio inusual» sin identificar; comprobó que describía el Titanic, pero solo con los pasajeros y con cifras que no cuadraban con ninguna fuente, y publicó una versión completa, con la tripulación, una fila por persona.

Las propias fuentes primarias no coinciden en el número exacto de personas a bordo, rescatadas o fallecidas, así que las cifras deben tomarse como aproximadas. Este es el mismo conjunto que trae R como `datasets::Titanic` (en forma de tabla de contingencia) y el que usó Simonoff (1997) para enseñar regresión logística.

No es el Titanic de Kaggle. Aquel solo incluye 891 pasajeros (sin tripulación) y añade nombre, tarifa, camarote, puerto de embarque o edad numérica; este tiene a todas las personas a bordo pero solo cuatro variables.

- Dawson, R. J. MacG. (1995). The «Unusual Episode» Data Revisited. Journal of Statistics Education, 3(3).
- DOI del artículo: 10.1080/10691898.1995.11910499
- Simonoff, J. S. (1997). The «Unusual Episode» and a Second Statistics Course. Journal of Statistics Education, 5(1).
- Documentación de datasets::Titanic en R

3 Variable objetivo

La variable objetivo es `survived`: si la persona sobrevivió (`yes`) o no (`no`). Sobrevivió casi una de cada tres personas, así que un clasificador que dijera siempre «no» ya acertaría el 67,7 % de las veces: esa es la referencia mínima que cualquier modelo debe superar.

Las tasas de supervivencia por grupo cuentan la historia del naufragio: sobrevivieron el 73,2 % de las mujeres y el 21,2 % de los hombres; el 52,3 % de los niños y el 31,3 % de los adultos; el 62,5 % de primera clase frente al 25,2 % de tercera y el 24,0 % de la tripulación.

4 Diccionario de columnas

Columnas de `titanic` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`status`	categórica	Clase del billete o pertenencia a la tripulación: `first`, `second`, `third` (pasajeros de 1.ª, 2.ª y 3.ª clase) y `crew` (tripulación). Para los pasajeros es una variable ordinal; la tripulación queda fuera de ese orden.	crew (885), third (706), first (325), second (285)
`age`	categórica	Grupo de edad: `adult` o `child`. La fuente no da la edad exacta, solo esta categoría.	adult (2.092), child (109)
`sex`	categórica	Sexo registrado: `male` o `female`.	male (1.731), female (470)
`survived` `objetivo`	categórica	Si la persona sobrevivió: `yes` o `no`. Es la variable objetivo.	no (1.490), yes (711)

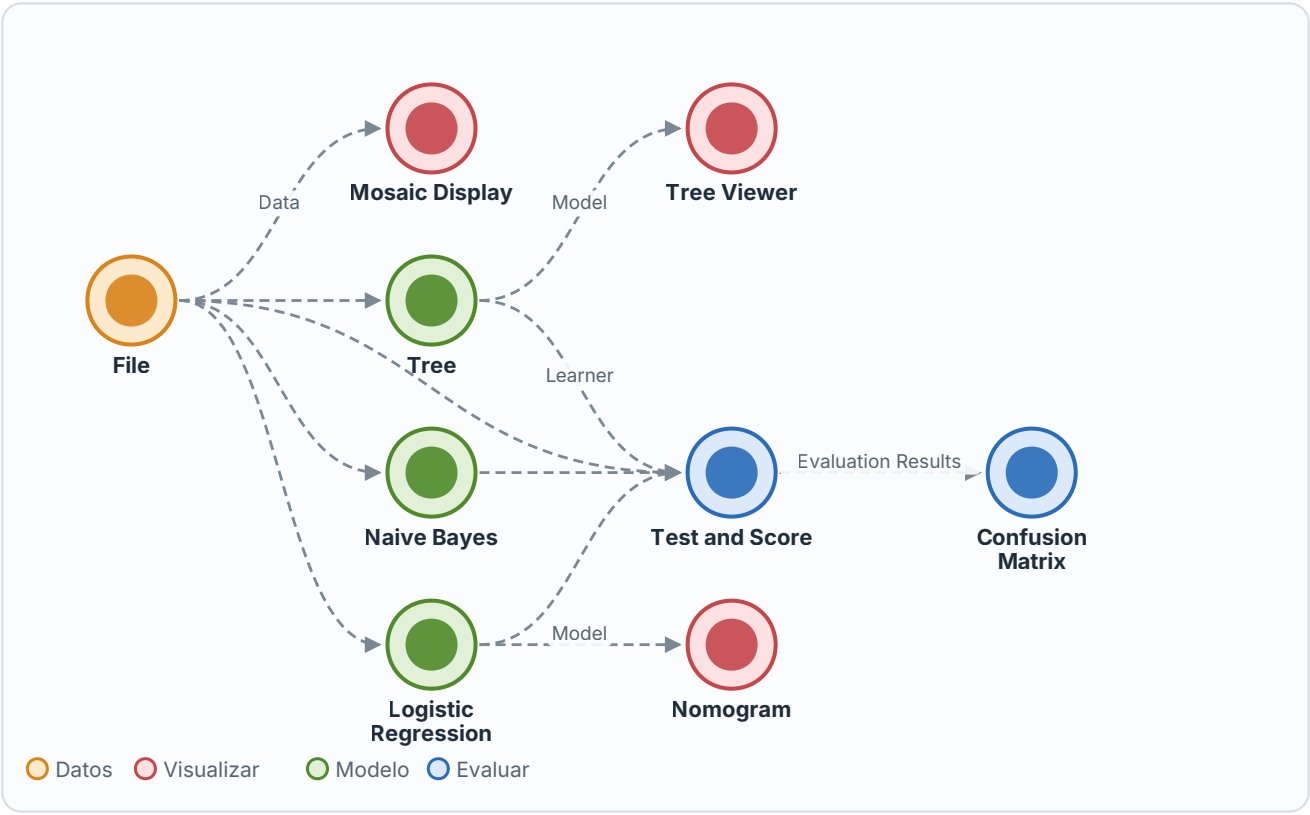
Columnas de `titanic_numerico` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Clase`	categórica	Igual que `status`, codificada como número: 0 = tripulación, 1 = primera, 2 = segunda, 3 = tercera.	0 (885), 3 (706), 1 (325), 2 (285)
`Edad`	categórica	Igual que `age`: 1 = adulto, 0 = niño.	1 (2.092), 0 (109)
`Sexo`	categórica	Igual que `sex`: 1 = hombre, 0 = mujer.	1 (1.731), 0 (470)
`Sobrevivió` `objetivo`	categórica	Igual que `survived`: 1 = sí, 0 = no.	0 (1.490), 1 (711)

5 Particularidades técnicas al modelar

- **Solo hay 14 combinaciones distintas** de clase, edad y sexo (en la tripulación no hay niños). Las 2.201 filas son repeticiones de esas combinaciones, así que un modelo no puede distinguir a dos personas del mismo grupo. Por eso el techo de acierto es del **79,1 %**: el que se obtiene prediciendo, para cada combinación, el resultado más frecuente. Un modelo que en validación cruzada supere claramente esa cifra tiene un error en el montaje.
- **Todas las variables son categóricas.** Árboles, Naive Bayes y reglas las usan tal cual. Regresión logística, kNN o SVM necesitan números: Orange las convierte por dentro con codificación *one-hot* (una columna 0/1 por valor), así que no hace falta preparar nada, pero conviene saberlo al interpretar los coeficientes.
- **Desbalance moderado** (32 % frente a 68 %). La exactitud sola engaña: mira también el AUC, la precisión y la sensibilidad para la clase `yes`, y la matriz de confusión.
- **Al abrir el CSV en Orange**, `survived` aparece como una variable más. En el widget *File*, cambia su rol a **target** antes de modelar. En `titanic_numerico`, Orange toma `Clase` como numérica (0–3): cámbiala a categórica, o el modelo tratará la tripulación como «clase cero» de una escala.
- No hay valores faltantes.

6 Flujo de trabajo en Orange



1. **File**: abre `titanic.csv` (o pega su URL de GitHub) y marca `survived` como *target*.
2. **Mosaic Display**: cruza `sex` y `status` con la supervivencia antes de modelar; las diferencias se ven de inmediato.
3. **Tree** + **Tree Viewer**: entrena un árbol pequeño (profundidad máxima 3 o 4) y léelo de arriba abajo: la primera división es por sexo.
4. **Naive Bayes** y **Logistic Regression**: dos modelos sencillos para comparar con el árbol.
5. **Test and Score**: validación cruzada estratificada de 10 particiones. Compara AUC y exactitud con la referencia del 67,7 % y el techo del 79,1 %.
6. **Confusion Matrix**: revisa cuántos supervivientes reales se clasifican como fallecidos.
7. **Nomogram**: muestra cuánto suma cada valor de cada variable a la probabilidad de sobrevivir en la regresión logística.

7 Otras consideraciones

- **Un buen dataset para hablar de causalidad.** La clase no «causa» la supervivencia: actúa a través de la ubicación de los camarotes, el acceso a las cubiertas de botes o el idioma. Es un ejemplo claro de correlación con explicación detrás.
- **Reglas de asociación.** Con el add-on *Associate*, los widgets *Frequent Itemsets* y *Association Rules* sobre este dataset dan reglas fáciles de leer, como {sex = female, status = first} ⇒ survived = yes.
- `titanic_numerico` es la versión del repositorio del curso (de `titanic.arff`): mismos datos con códigos 0/1 y nombres en español. Sirve para ver qué cambia cuando una categoría se representa con números.
- Para practicar ingeniería de atributos (extraer el título del nombre, agrupar edades, tarifas…) hace falta el Titanic de Kaggle, que tiene esas columnas.

En la carpeta	`titanic` ← `titanic.tab` (datasets.biolab.si)
En la carpeta	`titanic_numerico` ← `titanic.arff` (curso_ciencia_datos (GitHub))

1.09
Clasificación: introductorios y de juguete

Car Evaluation

`01_clasificacion_introductorios/car/`

Las 1.728 combinaciones de precio, mantenimiento, puertas, plazas, maletero y seguridad de un coche, valoradas por un modelo de decisión jerárquico: un problema sin ruido para comparar clasificadores.

Clasificación multiclase · ⚖ Desbalanceado · ✎ Sintético · ◇ Solo categóricos

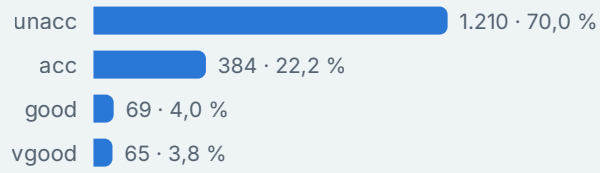
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
1.728	**7**	`car`	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`car`	1.728 × 7	CSV 52 KB · XLSX

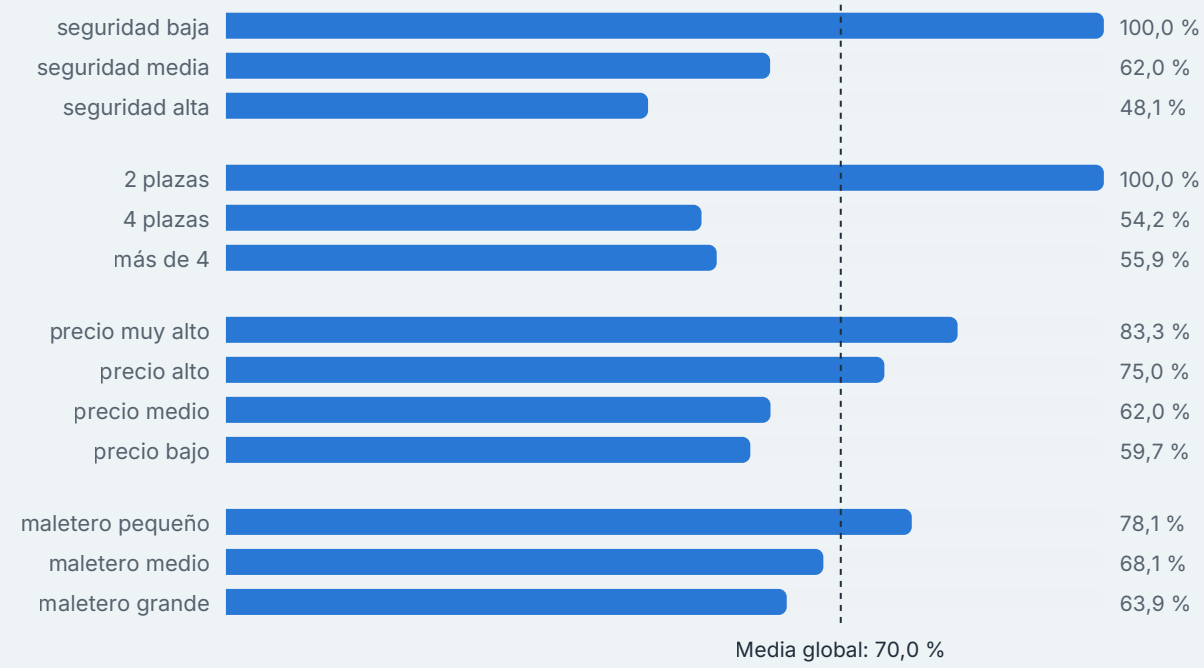
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/01_clasificacion_introductorios/car/` seguido del nombre del fichero CSV.

Radiografía

car en car



Porcentaje de coches inaceptables



1 Descripción general y estudios habituales

Cada fila es un coche hipotético descrito por seis características con pocos valores: precio de compra, coste de mantenimiento, número de puertas, plazas, tamaño del maletero y seguridad. La clase es la valoración del coche: inaceptable, aceptable, bueno o muy bueno.

Son **1.728 filas**, todas las combinaciones posibles (4 × 4 × 4 × 3 × 3 × 3), valoradas con un modelo de reglas hecho por expertos. Los estudios habituales son:

- **Clasificación multiclase** con atributos categóricos ordenados.
- **Comparar modelos** en un problema sin ruido: árbol, Naive Bayes, regresión logística, bosque aleatorio.
- **Clases desequilibradas**: el 70 % de los coches son inaceptables.
- **Recuperar la estructura de un modelo experto** a partir de sus decisiones.

2 Contexto y fuente original

Los datos salen de un modelo de decisión jerárquico construido con **DEX**, un sistema de apoyo a la decisión de **Marko Bohanec y Vladislav Rajkovič** (1988). El modelo combina las seis características en conceptos intermedios: el precio (compra y mantenimiento), el confort (puertas, plazas y maletero) y las características técnicas (confort y seguridad). En el dataset solo quedan las seis características y la valoración final.

Blaž Zupan y colaboradores lo usaron en 1999 para mostrar que un algoritmo puede redescubrir esa jerarquía a partir de los datos. Está en el repositorio UCI desde 1997.

- Car Evaluation en el repositorio UCI
- Zupan, B., Bohanec, M., Demšar, J. y Bratko, I. (1999). Learning by discovering concept hierarchies. Artificial Intelligence, 109, 211–242.

3 Variable objetivo

La clase es `car` : `unacc` (inaceptable, 1.210), `acc` (aceptable, 384), `good` (bueno, 69) y `vgood` (muy bueno, 65).

Dos condiciones descartan por sí solas: **un coche de 2 plazas o con seguridad baja siempre es inaceptable** (en total, 960 coches). Los coches muy buenos solo aparecen con seguridad alta y al menos 4 plazas.

4 Diccionario de columnas

Columnas de `car` (valores observados en el fichero)

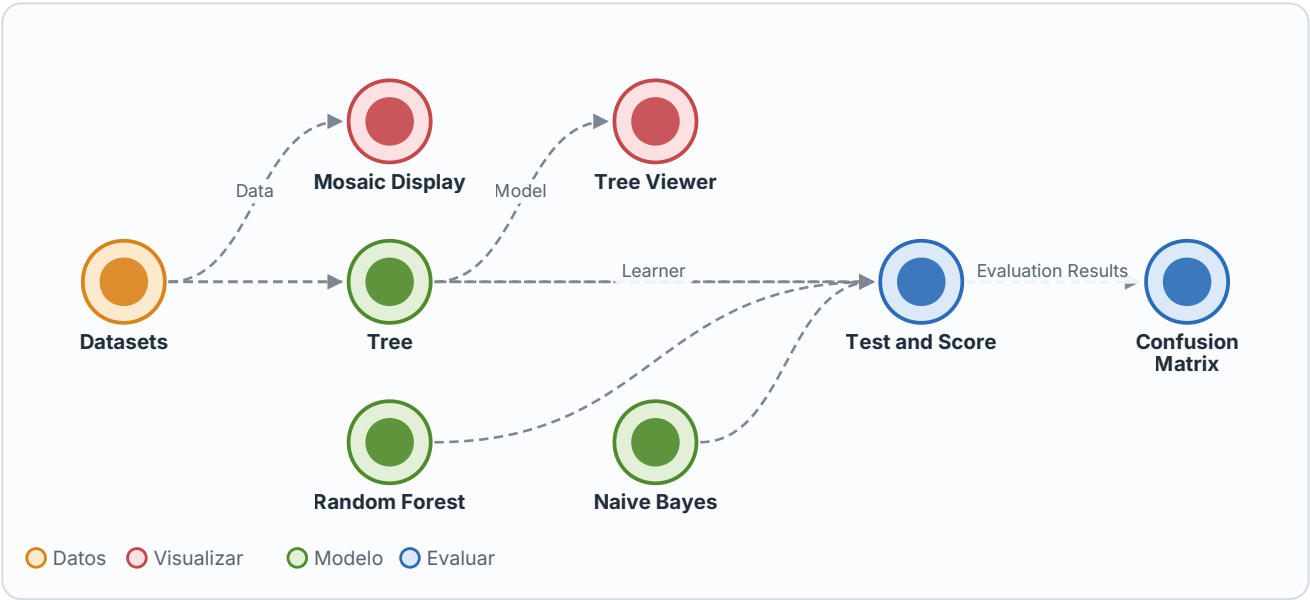
Columna	Tipo	Significado	Valores
`buying`	categórica	Precio de compra: `vhigh` , `high` , `med` o `low` .	vhigh (432), high (432), med (432), low (432)
`maint`	categórica	Coste de mantenimiento: `vhigh` , `high` , `med` o `low` .	vhigh (432), high (432), med (432), low (432)
`doors`	categórica	Número de puertas: `2` , `3` , `4` o `5more` (5 o más).	2 (432), 3 (432), 4 (432), 5more (432)
`persons`	categórica	Plazas: `2` , `4` o `more` (más de 4).	2 (576), 4 (576), more (576)

Columna	Tipo	Significado	Valores
`lug_boot`	categórica	Tamaño del maletero: `small`, `med` o `big`.	small (576), med (576), big (576)
`safety`	categórica	Seguridad estimada: `low`, `med` o `high`.	low (576), med (576), high (576)
`car` `objetivo`	categórica	**Clase**: valoración del coche, `unacc` (inaceptable), `acc` (aceptable), `good` (bueno) o `vgood` (muy bueno).	unacc (1.210), acc (384), good (69), vgood (65)

5 Particularidades técnicas al modelar

- **No es una muestra, es la tabla completa**: cada combinación aparece una vez y la clase sale de reglas fijas, sin ruido. Un modelo puede llegar casi al 100 %; si no llega, es porque no sabe representar las reglas, no por los datos.
- **Desequilibrio fuerte**: el 70 % es `unacc` y `good` y `vgood` no llegan al 4 % cada una. Mira la exactitud por clase y la matriz de confusión: un modelo con un 90 % de acierto puede fallar casi todos los coches muy buenos.
- **Atributos ordinales leídos como categorías**: Orange los trata como categorías sin orden, así que Naive Bayes y la regresión logística no aprovechan que «bajo < medio < alto». Los árboles y los bosques lo compensan con más divisiones.
- **Valores que parecen números**: `doors` y `persons` llevan valores como `5more` y `more`, así que son categóricas.
- En una prueba con validación cruzada de 10 bolsas: bosque aleatorio 96,6 %, árbol 94,6 %, regresión logística 91,6 %, Naive Bayes 86,7 % y kNN 81,7 %.

6 Flujo de trabajo en Orange



1. **Datasets** → «Car Evaluation» (o **File** con el CSV).
2. **Mosaic Display** con `safety` y `persons`: las dos casillas que son siempre `unacc`.
3. **Tree** → **Tree Viewer**: las primeras preguntas son la seguridad y las plazas.
4. **Test and Score** con árbol, bosque aleatorio y Naive Bayes, validación cruzada estratificada.
5. **Confusion Matrix**: elige Naive Bayes y mira cómo trata `good` y `vgood`.

7 Otras consideraciones

- **Redescubrir la jerarquía**: crea con *Feature Constructor* los conceptos intermedios (por ejemplo, un «precio» a partir de compra y mantenimiento) y comprueba si el árbol se simplifica.
- **Codificar el orden**: convierte las categorías en números (bajo = 1, medio = 2…) con *Edit Domain* o *Feature Constructor* y repite la regresión logística: el acierto sube.
- **Desequilibrio**: con *Data Sampler* o ponderando, prueba a mejorar la detección de `good` y `vgood` sin perder demasiado acierto global.

En la carpeta `car` ← `car.tab` (datasets.biolab.si)

1.10
Clasificación: introductorios y de juguete

MONK's problems

`01_clasificacion_introductorios/monks/`

Tres problemas artificiales con robots descritos por seis rasgos, cada uno definido por una regla conocida: el banco de pruebas de 1991 para ver qué tipo de concepto sabe aprender cada algoritmo.

Clasificación binaria · ✎ Sintético · ◇ Solo categóricos

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
556	**8**	`y`	**0,0 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`monks_1`	556 × 8	CSV 13 KB · XLSX
`monks_2`	601 × 8	CSV 14 KB · XLSX
`monks_3`	554 × 8	CSV 13 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/01_clasificacion_introductorios/monks/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Cada fila es un «robot» descrito por seis atributos con pocos valores, codificados como números: la forma de la cabeza (`a`), la del cuerpo (`b`), si sonríe (`c`), qué sostiene (`d`), el color de la chaqueta (`e`) y si lleva corbata (`f`). La clase `y` dice si el robot cumple un concepto oculto. Hay tres problemas, cada uno con su concepto:

- **MONK-1**: la cabeza tiene la misma forma que el cuerpo, o la chaqueta es roja (`a = b` o `e = 1`).
- **MONK-2**: exactamente dos de los seis atributos tienen su primer valor.

- **MONK-3**: chaqueta verde y sostiene una espada, o bien chaqueta no azul y cuerpo no octogonal; con un 5 % de errores añadidos a propósito en el entrenamiento.

Los estudios habituales son:

- **Comparar algoritmos** en conceptos de dificultad conocida: un árbol aprende bien MONK-1 y MONK-3, pero no MONK-2.
- **Ver el efecto del ruido** (MONK-3) y del sobreajuste.
- **Entender qué puede representar cada modelo**: igualdades entre atributos, recuentos, disyunciones.

2 Contexto y fuente original

Los problemas se crearon en la **2.ª Escuela Europea de Verano de Aprendizaje Automático**, celebrada en julio de 1991 en el priorato de Corsendonk (Bélgica), para comparar los algoritmos de los participantes sobre los mismos datos. El informe técnico de **Sebastian Thrun** y otros 24 autores (Universidad Carnegie Mellon, 1991) recoge los resultados de más de veinte métodos. Están en el repositorio UCI desde 1992.

Cada problema tiene un conjunto de entrenamiento (124, 169 y 122 robots) y uno de prueba con **los 432 robots posibles**. En los ficheros de Orange están **los dos juntos**: primero las filas de entrenamiento y después las 432 de prueba. La columna `instance` (`data_1` … `data_432`) da el número de cada robot dentro de los 432.

- Thrun, S. B. et al. (1991). The MONK's Problems: A performance comparison of different learning algorithms. Informe técnico CMU-CS-91-197, Carnegie Mellon University.
- MONK's Problems en el repositorio UCI

3 Variable objetivo

La clase es `y`: 1 si el robot cumple el concepto y 0 si no. En los ficheros combinados: MONK-1 tiene 278 y 278, MONK-2 206 unos y 395 ceros, y MONK-3 288 unos y 266 ceros.

Comprobadas sobre los datos, las reglas describen sin error todas las filas de MONK-1 y MONK-2, y todas las de MONK-3 salvo 6, que son los errores añadidos al entrenamiento.

4 Diccionario de columnas

Columnas de `monks_1` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
y `objetivo`	categórica	**Clase**: 1 si el robot cumple el concepto del problema, 0 si no.	1 (278), 0 (278)
a	categórica	Forma de la cabeza: 1 redonda, 2 cuadrada, 3 octogonal.	1 (189), 2 (186), 3 (181)
b	categórica	Forma del cuerpo: 1 redonda, 2 cuadrada, 3 octogonal.	3 (191), 2 (186), 1 (179)
c	categórica	Si sonríe: 1 sí, 2 no.	1 (281), 2 (275)
d	categórica	Qué sostiene: 1 espada, 2 globo, 3 bandera.	3 (187), 1 (186), 2 (183)
e	categórica	Color de la chaqueta: 1 rojo, 2 amarillo, 3 verde, 4 azul.	4 (142), 2 (139), 3 (138), 1 (137)

Columna	Tipo	Significado	Valores
f	categórica	Si lleva corbata: 1 sí, 2 no.	2 (284), 1 (272)
instance	texto	Número del robot dentro de los 432 posibles (`data_1` … `data_432`). En Orange va como *ignorada*.	data_5 (2), data_6 (2), data_19 (2), data_22 (2), data_27 (2), data_28 (2) …

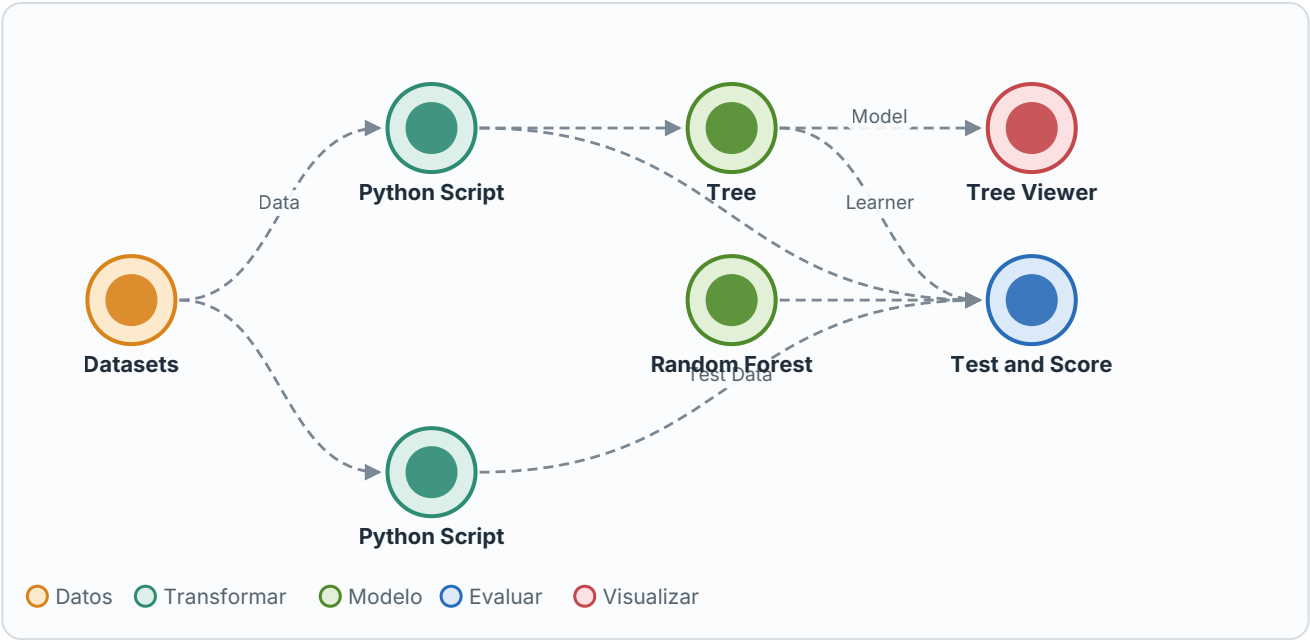
`monks_2` tiene las mismas columnas con el mismo significado que `monks_1` .

`monks_3` tiene las mismas columnas con el mismo significado que `monks_1` .

5 Particularidades técnicas al modelar

- **Entrenamiento y prueba están juntos**: los 124 (o 169, o 122) primeros robots son el entrenamiento, y los 432 siguientes la prueba, que contiene a su vez todos los robots del entrenamiento. Si se hace validación cruzada sobre el fichero completo, cada robot de entrenamiento está repetido y el acierto sale inflado. Para reproducir el experimento original, separa las primeras filas (por ejemplo, con *Python Script*, como en el flujo de abajo).
- **Los números son categorías**: `a` = 1 no es «menos» que `a` = 2. Orange ya los trata como categóricos; no los conviertas en numéricos.
- **MONK-1 necesita comparar dos atributos** (`a = b`): un árbol lo consigue con muchas ramas; la regresión logística y Naive Bayes no pueden expresarlo y se quedan en torno al 71 % en los 432 robots de prueba.
- **MONK-2 es difícil para casi todos**: «exactamente dos atributos con su primer valor» no se expresa bien con preguntas de una en una. En el entrenamiento original, un árbol se queda en el 69 %.
- **MONK-3 tiene ruido**: 6 de los 122 robots de entrenamiento tienen la clase cambiada. Un árbol se los aprende y se queda en el 94 % en la prueba, mientras que Naive Bayes, más sencillo, llega al 97 %.

6 Flujo de trabajo en Orange



1. **Datasets** → «MONK's 1» (o **File** con `monks_1`).
2. Dos **Python Script**: uno con `out_data = in_data[:124]` (entrenamiento) y otro con `out_data = in_data[124:]` (prueba). En MONK-2 el corte está en 169 y en MONK-3 en 122.

3. **Test and Score** en modo *Test on test data*, con el entrenamiento en *Data* y la prueba en *Test Data*: árbol, bosque aleatorio y regresión logística.
4. **Tree** → **Tree Viewer** sobre el entrenamiento: ¿se ve la regla `a = b` en el árbol?
5. Repite con MONK-2 y MONK-3 y compara qué modelo gana en cada uno.

7 Otras consideraciones

- **Crear la variable que falta**: con *Feature Constructor*, añade `a == b` en MONK-1 o el número de atributos con valor 1 en MONK-2. Con esa columna, cualquier modelo acierta casi todo. Es la mejor demostración de que la ingeniería de atributos puede valer más que el algoritmo.
- **Poda y ruido**: en MONK-3, compara un árbol sin poda con otro con un mínimo de 5 casos por hoja.
- El informe original compara más de veinte algoritmos de 1991 (AQ, ID3, redes neuronales…): un buen texto para situar históricamente el aprendizaje automático.

En la carpeta	`monks_1` ← `monks-1.tab` (datasets.biolab.si)
En la carpeta	`monks_2` ← `monks-2.tab` (datasets.biolab.si)
En la carpeta	`monks_3` ← `monks-3.tab` (datasets.biolab.si)

1.11
Clasificación: introductorios y de juguete

Mushroom (setas)

`01_clasificacion_introductorios/mushrooms/`

8.124 setas de 23 especies descritas por 22 rasgos del sombrero, las láminas, el pie y el olor, y si son comestibles o venenosas. El olor por sí solo acierta el 98,5 %.

Clasificación binaria · ? Valores faltantes · ◇ Solo categóricos

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
8.124	**23**	`class`	**1,3 %**	**Iniciación**	**Ninguno**

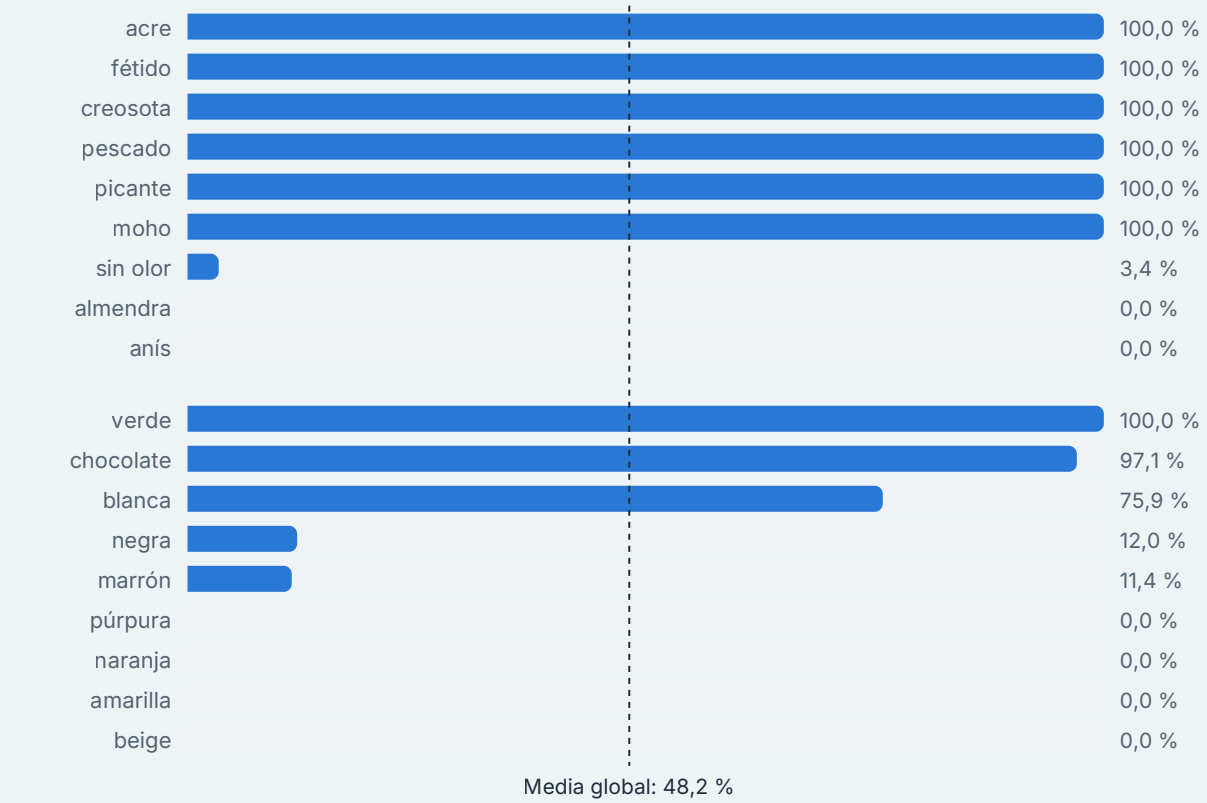
Fichero	Filas × col.	Descargar
`mushrooms`	8.124 × 23	CSV 372 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/01_clasificacion_introductorios/mushrooms/` seguido del nombre del fichero CSV.

Radiografía

class en mushrooms





1 Descripción general y estudios habituales

Cada fila es una seta descrita por 22 rasgos que se pueden observar en el campo: forma, superficie y color del sombrero, si se amorata al tocarla, el olor, cómo son las láminas, el pie, el anillo y el velo, el color de la esporada, cómo crece (sola o en grupo) y dónde. La clase dice si es **comestible** o **venenosa**.

Son **8.124 setas**, casi mitad y mitad. Los estudios habituales son:

- **Clasificación binaria** con atributos categóricos.
- **Encontrar reglas sencillas** que separen las comestibles de las venenosas (¡solo como ejercicio!).
- **Comparar el poder de cada atributo**: unos pocos rasgos lo deciden casi todo.

2 Contexto y fuente original

Los datos los preparó **Jeffrey Schlimmer** en 1987 a partir de la guía de campo *The Audubon Society Field Guide to North American Mushrooms* (G. H. Lincoff, 1981). Describen **23 especies** de setas con láminas de las familias *Agaricus* y *Lepiota*. No son 8.124 setas recogidas una a una: cada especie aparece muchas veces con combinaciones plausibles de sus rasgos, así que hay mucha repetición de patrones.

La guía clasifica cada especie como comestible, venenosa, de comestibilidad desconocida o no recomendada; en el dataset, las dos últimas se juntaron con las venenosas. Está en el repositorio UCI desde 1987. La copia del curso viene en XLSX con los valores codificados por letras, como en el original.

- Mushroom en el repositorio UCI (J. Schlimmer, 1987)

3 Variable objetivo

La clase es `class` : `e` (*edible*, comestible, 4.208) o `p` (*poisonous*, venenosa o dudosa, 3.916).

El olor lo dice casi todo: las setas que huelen a almendra (`a`) o a anís (`l`) son todas comestibles, y todas las que tienen algún otro olor (a pescado, fétido, picante, a creosota, a moho, acre) son venenosas. Solo las setas sin olor (`n`) mezclan las dos clases: 3.408 comestibles y 120 venenosas. Con esa sola regla se acierta un 98,5 %.

4 Diccionario de columnas

Columnas de `mushrooms` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`class` `objetivo`	categórica	**Clase**: `e` comestible, `p` venenosa (o de comestibilidad desconocida).	e (4.208), p (3.916)
`cap-shape`	categórica	Forma del sombrero: `b` campana, `c` cónica, `x` convexa, `f` plana, `k` con mamelón, `s` hundida.	x (3.656), f (3.152), k (828), b (452), s (32), c (4)
`cap-surface`	categórica	Superficie del sombrero: `f` fibrosa, `g` con surcos, `y` escamosa, `s` lisa.	y (3.244), s (2.556), f (2.320), g (4)
`cap-color`	categórica	Color del sombrero: `n` marrón, `b` beige, `c` canela, `g` gris, `r` verde, `p` rosa, `u` púrpura, `e` rojo, `w` blanco, `y` amarillo.	n (2.284), g (1.840), e (1.500), y (1.072), w (1.040), b (168) …
`bruises`	categórica	Si se amorata al tocarla: `t` sí, `f` no.	f (4.748), t (3.376)
`odor`	categórica	Olor: `a` almendra, `l` anís, `c` creosota, `y` pescado, `f` fétido, `m` moho, `n` ninguno, `p` acre, `s` picante.	n (3.528), f (2.160), s (576), y (576), a (400), l (400) …
`gill-attachment`	categórica	Unión de las láminas al pie: `a` adherentes, `f` libres (en los datos solo hay estos dos).	f (7.914), a (210)
`gill-spacing`	categórica	Separación de las láminas: `c` juntas, `w` apretadas.	c (6.812), w (1.312)
`gill-size`	categórica	Anchura de las láminas: `b` anchas, `n` estrechas.	b (5.612), n (2.512)
`gill-color`	categórica	Color de las láminas: `k` negro, `n` marrón, `b` beige, `h` chocolate, `g` gris, `r` verde, `o` naranja, `p` rosa, `u` púrpura, `e` rojo, `w` blanco, `y` amarillo.	b (1.728), p (1.492), w (1.202), n (1.048), g (752), h (732) …
`stalk-shape`	categórica	Forma del pie: `e` ensanchado en la base, `t` estrechado.	t (4.608), e (3.516)
`stalk-root`	categórica	Base del pie: `b` bulbosa, `c` en maza, `e` igual, `r` con raíces. **Vacío en 2.480 setas** (en el original, `?`).	b (3.776), e (1.120), c (556), r (192)

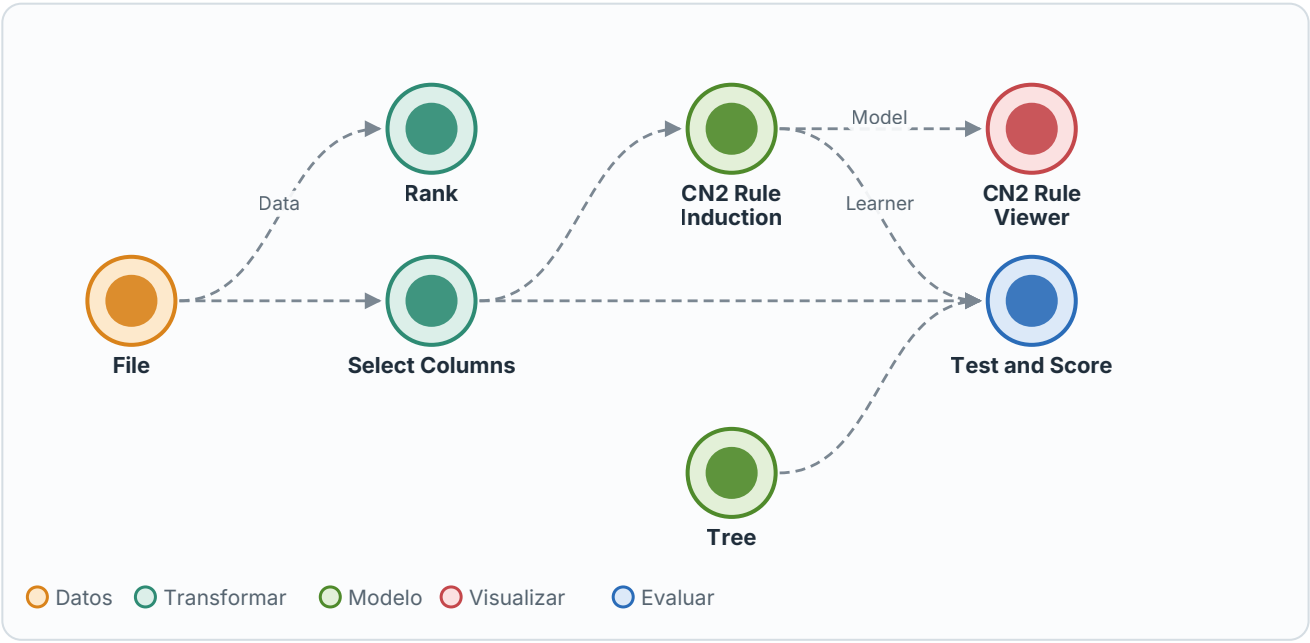
Columna	Tipo	Significado	Valores
`stalk-surface-above-ring`	categórica	Superficie del pie sobre el anillo: `f` fibrosa, `y` escamosa, `k` sedosa, `s` lisa.	s (5.176), k (2.372), f (552), y (24)
`stalk-surface-below-ring`	categórica	Superficie del pie bajo el anillo (mismos códigos).	s (4.936), k (2.304), f (600), y (284)
`stalk-color-above-ring`	categórica	Color del pie sobre el anillo: `n` marrón, `b` beige, `c` canela, `g` gris, `o` naranja, `p` rosa, `e` rojo, `w` blanco, `y` amarillo.	w (4.464), p (1.872), g (576), n (448), b (432), o (192) …
`stalk-color-below-ring`	categórica	Color del pie bajo el anillo (mismos códigos).	w (4.384), p (1.872), g (576), n (512), b (432), o (192) …
`veil-type`	categórica	Tipo de velo: siempre `p` (parcial). **No aporta nada**: tiene un único valor.	p (8.124)
`veil-color`	categórica	Color del velo: `n` marrón, `o` naranja, `w` blanco, `y` amarillo.	w (7.924), n (96), o (96), y (8)
`ring-number`	categórica	Número de anillos: `n` ninguno, `o` uno, `t` dos.	o (7.488), t (600), n (36)
`ring-type`	categórica	Tipo de anillo: `e` evanescente, `f` acampanado, `l` grande, `n` ninguno, `p` colgante.	p (3.968), e (2.776), l (1.296), f (48), n (36)
`spore-print-color`	categórica	Color de la esporada: `k` negra, `n` marrón, `b` beige, `h` chocolate, `r` verde, `o` naranja, `u` púrpura, `w` blanca, `y` amarilla.	w (2.388), n (1.968), k (1.872), h (1.632), r (72), u (48) …
`population`	categórica	Cómo crece: `a` abundante, `c` en racimos, `n` numerosa, `s` dispersa, `v` varias, `y` solitaria.	v (4.040), y (1.712), s (1.248), n (400), a (384), c (340)
`habitat`	categórica	Dónde crece: `g` hierba, `l` hojarasca, `m` prados, `p` caminos, `u` urbano, `w` terrenos baldíos, `d` bosque.	d (3.148), g (2.148), p (1.144), l (832), u (368), m (292) …

5 Particularidades técnicas al modelar

- **Demasiado fácil**: con todos los atributos, la regresión logística, kNN y un bosque aleatorio aciertan el 100 % en validación cruzada, y un árbol el 98,5 %. Es útil para enseñar a leer reglas, no para comparar algoritmos.
- **Patrones repetidos**: las filas son combinaciones de rasgos de 23 especies, no setas independientes. La validación cruzada mezcla la misma especie en entrenamiento y prueba y da un acierto optimista para setas de otras especies.
- `veil-type` **tiene un solo valor**: quítala (o Orange la ignorará en algunos modelos). `stalk-root` tiene 2.480 valores ausentes, un 30 %; los árboles los manejan, pero Naive Bayes y la regresión logística necesitan que se imputen o que se trate «desconocido» como un valor más.
- **Valores por letras**: hay que tener a mano el diccionario para interpretar los modelos (`n` es «marrón» en los colores pero «ninguno» en el olor).

- **Cuidado con la lectura práctica**: este modelo no sirve para decidir si una seta real se puede comer. Las clases vienen de una guía de 1981 y de solo 23 especies norteamericanas.

6 Flujo de trabajo en Orange



1. **File** con `mushrooms` y `class` como *target*.
2. **Rank**: `odor` es, con diferencia, el atributo más informativo; le siguen el color de la esporada y el de las láminas.
3. **Select Columns**: quita `veil-type`.
4. **CN2 Rule Induction** → **CN2 Rule Viewer**: unas pocas reglas cubren casi todas las setas.
5. **Test and Score** con reglas y árbol: los dos rondan el 100 %.

7 Otras consideraciones

- **Un modelo sin olor**: quita `odor` y repite. ¿Qué rasgos lo sustituyen y cuánto baja el acierto? Es más interesante que el problema completo.
- **El coste de los errores no es simétrico**: clasificar una venenosa como comestible es mucho peor que lo contrario. Mira en la matriz de confusión cuántas venenosas se escapan y cómo cambia al mover el umbral de decisión.
- **Reglas explicables**: *CN2 Rule Induction* da reglas del tipo «si el olor es fétido, venenosa», muy útiles para hablar de modelos interpretables.

En la carpeta `mushrooms` ← `mushrooms.xlsx` (curso_ciencia_datos (GitHub))

1.12
Clasificación: introductorios y de juguete

Soybean (enfermedades de la soja)

`01_clasificacion_introductorios/soybean/`

683 plantas de soja con 35 síntomas y condiciones del cultivo, y su diagnóstico entre 19 enfermedades y daños: el clásico de sistemas expertos agrícolas, con muchas clases y valores ausentes que delatan el diagnóstico.

Clasificación multiclase · ⚖ Desbalanceado · ? Valores faltantes · ◇ Solo categóricos

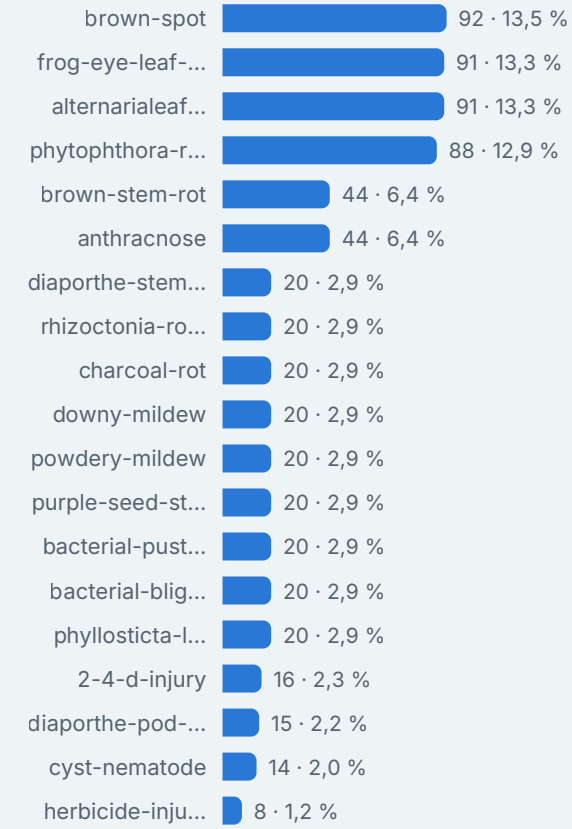
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
683	**36**	`class`	**9,5 %**	**Intermedio**	**Ninguno**

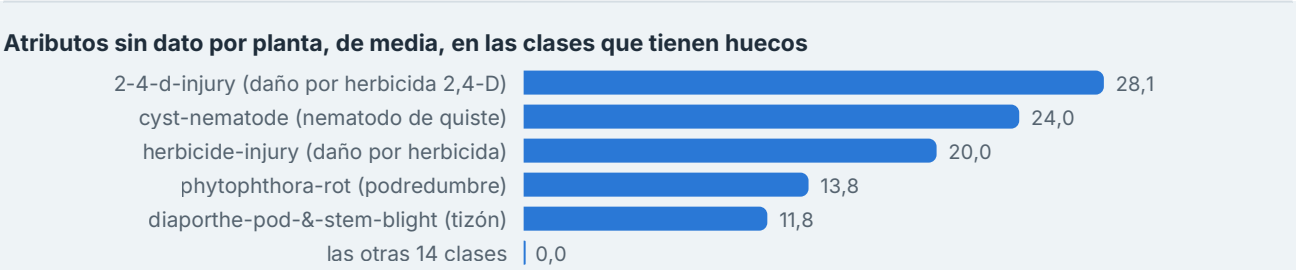
Fichero	Filas × col.	Descargar
`soybean`	683 × 36	CSV 171 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/01_clasificacion_introductorios/soybean/` seguido del nombre del fichero CSV.

Radiografía

class en soybean





1 Descripción general y estudios habituales

Cada fila es una planta de soja enferma descrita por **35 atributos categóricos**: cuándo se observó, las condiciones del campo (lluvia, temperatura, granizo, historial del cultivo, tratamiento de la semilla, germinación), y los síntomas de hojas, tallo, vainas, semillas y raíces. La clase es el diagnóstico, con **19 valores**: hongos, bacterias, nematodos, daños por herbicida…

Los estudios habituales son:

- **Clasificación con muchas clases** y pocos casos en algunas (8 en la más rara).
- **Tratamiento de valores ausentes** cuando faltar un dato no es casual.
- **Comparar reglas aprendidas con reglas de experto**, que es para lo que se creó el dataset.

2 Contexto y fuente original

Es la *Large Soybean Database* de **Ryszard Michalski y Richard Chilausky** (Universidad de Illinois, 1980). La usaron para comparar dos formas de construir un sistema experto de diagnóstico: preguntar las reglas a un fitopatólogo o aprenderlas de ejemplos con el algoritmo AQ. Las reglas aprendidas acertaron más que las del experto.

En el repositorio UCI está separada en entrenamiento (307 casos) y prueba (376). La versión del curso, la que distribuye Weka (`soybean.arff`), junta las dos en 683 casos. El original venía codificado con números; aquí los valores son palabras (`lt-norm`, `absent`…).

- Soybean (Large) en el repositorio UCI. Referencia original: Michalski, R. S. y Chilausky, R. L. (1980). Learning by being told and learning from examples… International Journal of Policy Analysis and Information Systems, 4(2).

3 Variable objetivo

La clase es `class`, con 19 diagnósticos muy desiguales: cuatro con unos 90 casos (mancha marrón, ojo de rana, mancha de alternaria y podredumbre por *Phytophthora*), dos con 44, nueve con 20 y cuatro con menos de 20 (el daño por herbicida solo tiene 8).

Acertar la clase más frecuente da un 13,5 %. En una prueba con validación cruzada estratificada de 8 bolsas, la regresión logística y el bosque aleatorio aciertan un 93 %, kNN un 91 %, Naive Bayes un 89 % y el árbol un 83 %.

4 Diccionario de columnas

Columnas de `soybean` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`date`	categórica	Mes de la observación (de abril a octubre).	september (149), august (131), july (118), june (93), october (90), may (75) …

Columna	Tipo	Significado	Valores
`plant-stand`	categórica	Estado de la plantación: `normal` o `lt-normal` (por debajo de lo normal).	normal (354), lt-normal (293)
`precip`	categórica	Precipitación: `lt-norm`, `norm` o `gt-norm` (por debajo, normal o por encima de lo normal).	gt-norm (459), norm (112), lt-norm (74)
`temp`	categórica	Temperatura: `lt-norm`, `norm` o `gt-norm`.	norm (374), gt-norm (199), lt-norm (80)
`hail`	categórica	Si hubo granizo.	yes (435), no (127)
`crop-hist`	categórica	Historial del cultivo: soja el año pasado, los dos últimos, varios años o un cultivo distinto.	same-lst-two-yrs (219), same-lst-sev-yrs (218), same-lst-yr (165), diff-lst-year (65)
`area-damaged`	categórica	Zona dañada: dispersa, partes bajas, partes altas o todo el campo.	low-areas (227), whole-field (187), upper-areas (145), scattered (123)
`severity`	categórica	Gravedad: `minor`, `pot-severe` (potencialmente grave) o `severe`.	pot-severe (322), minor (195), severe (45)
`seed-tmt`	categórica	Tratamiento de la semilla: ninguno, fungicida u otro.	none (305), fungicide (222), other (35)
`germination`	categórica	Germinación: `90-100`, `80-89` o `lt-80` (%).	80-89 (213), lt-80 (193), 90-100 (165)
`plant-growth`	categórica	Crecimiento de la planta: normal o anormal.	norm (441), abnorm (226)
`leaves`	categórica	Hojas: normales o anormales.	abnorm (606), norm (77)
`leafspots-halo`	categórica	Manchas en las hojas: ausentes, con halo amarillo o sin él.	no-yellow-halos (342), absent (221), yellow-halos (36)
`leafspots-marg`	categórica	Borde de las manchas (`w-s-marg`: con borde empapado de agua). `dna`: no se aplica.	w-s-marg (357), dna (221), no-w-s-marg (21)
`leafspot-size`	categórica	Tamaño de las manchas: menores o mayores de 1/8 de pulgada. `dna`: no se aplica.	gt-1/8 (327), dna (221), lt-1/8 (51)
`leaf-shread`	categórica	Si las hojas están deshilachadas.	absent (487), present (96)
`leaf-malf`	categórica	Si las hojas están deformadas.	absent (554), present (45)
`leaf-mild`	categórica	Moho en las hojas: ausente, en el haz o en el envés.	absent (535), upper-surf (20), lower-surf (20)
`stem`	categórica	Tallo: normal o anormal.	abnorm (371), norm (296)

Columna	Tipo	Significado	Valores
`lodging`	categórica	Si la planta está tumbada (encamado).	yes (520), no (42)
`stem-cankers`	categórica	Chancros en el tallo: ausentes, bajo el suelo, sobre el suelo o por encima del segundo nudo.	absent (379), above-sec-nde (191), below-soil (39), above-soil (36)
`canker-lesion`	categórica	Color de la lesión del chancro: canela, marrón o marrón oscuro-negro. `dna` : no se aplica.	dna (320), dk-brown-blk (177), brown (83), tan (65)
`fruiting-bodies`	categórica	Si hay cuerpos fructíferos de hongo.	absent (473), present (104)
`external-decay`	categórica	Pudrición externa: ausente, firme y seca, o acuosa.	absent (497), firm-and-dry (135), watery (13)
`mycelium`	categórica	Si hay micelio.	absent (639), present (6)
`int-discolor`	categórica	Coloración interna del tallo: ninguna, marrón o negra.	none (581), brown (44), black (20)
`sclerotia`	categórica	Si hay esclerocios.	absent (625), present (20)
`fruit-pods`	categórica	Vainas: normales, enfermas, pocas. `dna` : no se aplica.	norm (407), diseased (130), dna (48), few-present (14)
`fruit-spots`	categórica	Manchas en las vainas: ausentes, de color, marrones con puntos negros. `dna` : no se aplica.	absent (345), dna (100), colored (75), brown-w/blk-specks (57)
`seed`	categórica	Semilla: normal o anormal.	norm (476), abnorm (115)
`mold-growth`	categórica	Si hay moho en la semilla.	absent (524), present (67)
`seed-discolor`	categórica	Si la semilla está decolorada.	absent (513), present (64)
`seed-size`	categórica	Tamaño de la semilla: normal o menor.	norm (532), lt-norm (59)
`shriveling`	categórica	Si la semilla está arrugada.	absent (539), present (38)
`roots`	categórica	Raíces: normales, podridas o con agallas y quistes.	norm (551), rotted (86), galls-cysts (15)
`class` `objetivo`	categórica	**Clase**: diagnóstico, uno de 19 (por ejemplo, `brown-spot` , `phytophthora-rot` , `herbicide-injury`).	brown-spot (92), frog-eye-leaf-spot (91), alternarialeaf-spot (91), phytophthora-rot (88), brown-stem-rot (44), anthracnose (44) …

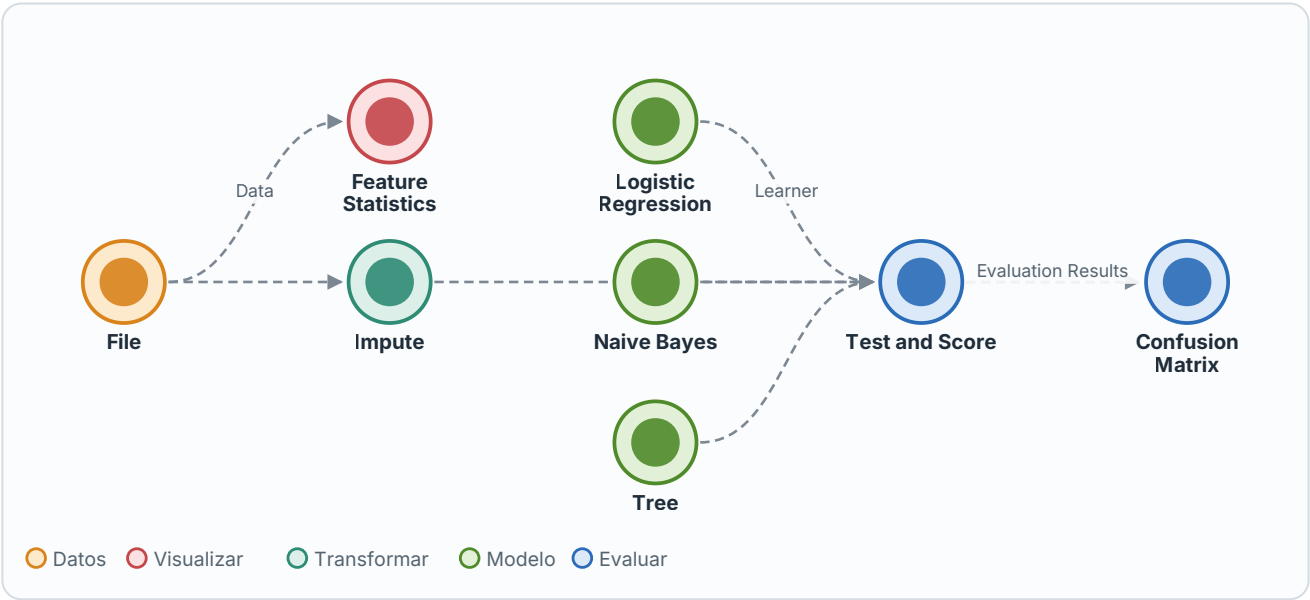
5 Particularidades técnicas al modelar

- **Los huecos no son casuales**: solo 121 plantas tienen algún dato ausente, y todas son de cinco clases (las 16 del daño por 2,4-D, las 14 del nematodo, las 8 del herbicida, las 15 del tizón y 68 de las 88 de *Phytophthora*). En el daño por 2,4-D faltan de media 28 de los 35 atributos. **El patrón de huecos delata la clase**: si se

imputan con la moda, se pierde esa información; si se tratan como un valor más («desconocido»), el modelo la aprovecha, pero entonces aprende cómo se recogieron los datos, no los síntomas.

- `dna` **no es un hueco**: significa «no se aplica» (por ejemplo, el tamaño de la mancha cuando no hay manchas) y es un valor legítimo.
- **Clases muy desiguales**: con 8 casos de daño por herbicida, la validación cruzada de 10 bolsas deja bolsas sin esa clase. Usa validación estratificada y mira el acierto por clase.
- **Entrenamiento y prueba juntos**: en UCI hay 307 casos de entrenamiento y 376 de prueba; el fichero del curso los junta y no marca la separación. Para comparar con resultados publicados, usa los dos ficheros de UCI por separado.
- Todas las variables son categóricas, varias ordinales (`lt-norm` < `norm` < `gt-norm`), que Orange trata sin orden.

6 Flujo de trabajo en Orange



1. **File** con `soybean` ; `class` como *target*.
2. **Feature Statistics**: los atributos con más huecos (`hail` , `severity` , `seed-tmt` , `lodging` : 121 cada uno).
3. **Impute**: prueba dos versiones, con la moda y con «tratar como valor distinto». Compara.
4. **Test and Score** con validación estratificada: regresión logística, Naive Bayes y árbol.
5. **Confusion Matrix**: qué enfermedades se confunden entre sí (las manchas foliares suelen hacerlo).

7 Otras consideraciones

- **Experimento del artículo**: con los ficheros de entrenamiento y prueba de UCI y *Test and Score* en modo *Test on test data*, se puede comparar con los resultados publicados.
- **Reglas de diagnóstico**: *CN2 Rule Induction* produce reglas por enfermedad que se pueden comparar con las de un manual de fitopatología.
- **Agrupar síntomas**: un *Distance Map* o un clustering jerárquico sobre los casos muestra qué enfermedades se parecen en sus síntomas.

En la carpeta `soybean` ← `soybean.arff` (curso_ciencia_datos (GitHub))

1.13
Clasificación: introductorios y de juguete

Congressional Voting Records 1984

`01_clasificacion_introductorios/voting/`

Cómo votaron los 435 miembros de la Cámara de Representantes de Estados Unidos en 16 votaciones clave de 1984, y a qué partido pertenecían: un problema binario muy limpio en el que una sola votación casi lo decide todo.

Clasificación binaria · ? Valores faltantes · ◇ Solo categóricos

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
435	**17**	`party`	**5,3 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`voting`	435 × 17	CSV 18 KB · XLSX

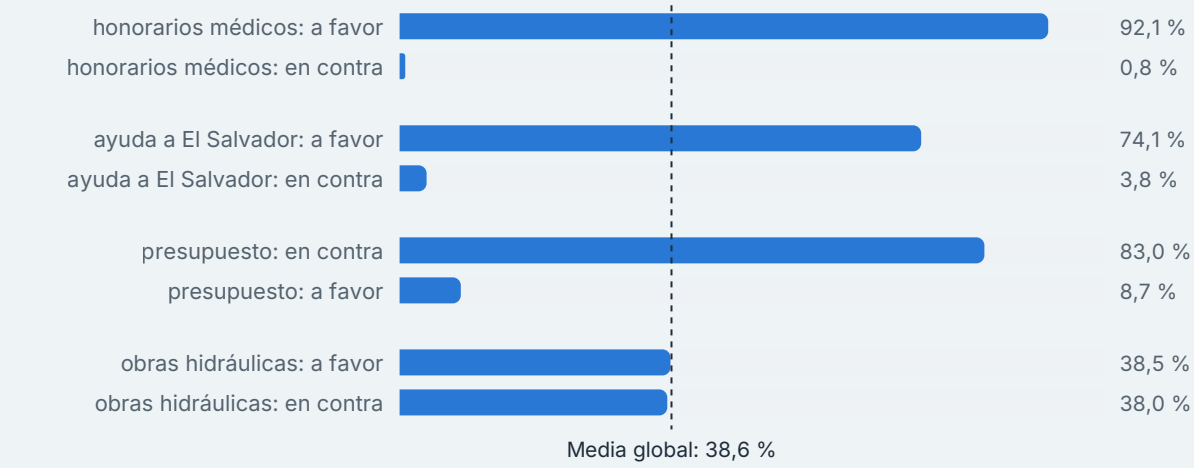
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/01_clasificacion_introductorios/voting/` seguido del nombre del fichero CSV.

Radiografía

party en voting



Porcentaje de republicanos según el voto



1 Descripción general y estudios habituales

Cada fila es un congresista y cada columna, una de las **16 votaciones** que el *Congressional Quarterly Almanac* consideró clave en 1984: congelar los honorarios médicos, ayuda a la Contra nicaragüense o a El Salvador, el

misil MX, la oración en las escuelas, sanciones a Sudáfrica... El valor es `y` (a favor), `n` (en contra) o vacío. La clase es el partido: **267 demócratas y 168 republicanos**.

Los estudios habituales son:

- **Clasificación binaria** con atributos de tres valores.
- **Ver qué votaciones separan a los partidos** y cuáles no.
- **Explicar Naive Bayes y la regresión logística** con el nomograma: es el ejemplo de los tutoriales de Orange.
- **Agrupar a los congresistas** por su forma de votar y buscar a los que se apartan de su partido.

2 Contexto y fuente original

Los datos los recopiló **Jeffrey Schlimmer** para su tesis doctoral (Universidad de California en Irvine, 1987) a partir del *Congressional Quarterly Almanac* de 1984 (98.º Congreso, 2.ª sesión), y están en el repositorio UCI desde 1987.

El almanaque distingue nueve formas de votar. Schlimmer las redujo a tres: **a favor** (votó, se emparejó o anunció su voto a favor), **en contra** (lo mismo en contra) y **desconocido** (votó «presente», se abstuvo por conflicto de intereses o no votó ni anunció su posición).

- Congressional Voting Records en el repositorio UCI (J. Schlimmer, 1987)
- Tutorial de clasificación de Orange (ejemplo con voting)

3 Variable objetivo

La clase es `party` : `democrat` (267) o `republican` (168).

Una sola votación casi basta: en la de congelar los honorarios médicos (`physician-fee-freeze`), 245 de los 267 demócratas votaron en contra y 163 de los 168 republicanos a favor. Prediciendo el partido solo con esa votación se acierta un 95,6 %. Otras votaciones (presupuesto, El Salvador, educación) separan bastante menos.

4 Diccionario de columnas

Columnas de `voting` (valores observados en el fichero)

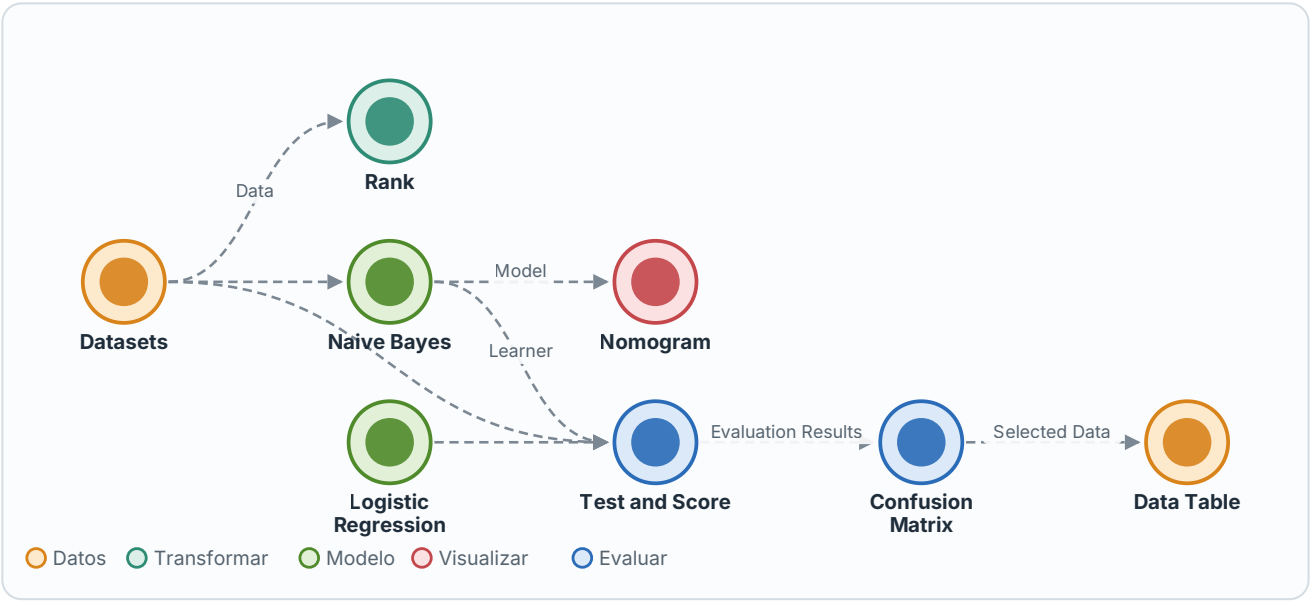
Columna	Tipo	Significado	Valores
`party` `objetivo`	categórica	**Clase**: partido del congresista, `democrat` o `republican` .	democrat (267), republican (168)
`handicapped-infants`	categórica	Protección de recién nacidos con discapacidad. Valores `y` (a favor), `n` (en contra) o vacío (desconocido), igual en todas las votaciones.	n (236), y (187)
`water-project-cost-sharing`	categórica	Reparto de costes de obras hidráulicas. Es la que menos separa a los partidos: un 38 % de republicanos tanto entre los votos a favor como entre los votos en contra.	y (195), n (192)
`adoption-of-the-budget-resolution`	categórica	Aprobación de la resolución presupuestaria.	y (253), n (171)

Columna	Tipo	Significado	Valores
`physician-fee-freeze`	categórica	Congelación de los honorarios médicos. **La que mejor separa a los partidos.**	n (247), y (177)
`el-salvador-aid`	categórica	Ayuda a El Salvador.	y (212), n (208)
`religious-groups-in-schools`	categórica	Grupos religiosos en las escuelas.	y (272), n (152)
`anti-satellite-test-ban`	categórica	Prohibición de pruebas de armas antisatélite.	y (239), n (182)
`aid-to-nicaraguan-contras`	categórica	Ayuda a la Contra nicaragüense.	y (242), n (178)
`mx-missile`	categórica	Misil MX.	y (207), n (206)
`immigration`	categórica	Reforma de la inmigración.	y (216), n (212)
`synfuels-corporation-cutback`	categórica	Recorte a la empresa pública de combustibles sintéticos.	n (264), y (150)
`education-spending`	categórica	Gasto en educación.	n (233), y (171)
`superfund-right-to-sue`	categórica	Derecho a demandar en el fondo de limpieza de residuos tóxicos (*Superfund*).	y (209), n (201)
`crime`	categórica	Ley contra el crimen.	y (248), n (170)
`duty-free-exports`	categórica	Exportaciones libres de aranceles.	n (233), y (174)
`export-administration-act-south-africa`	categórica	Ley de exportaciones a Sudáfrica (sanciones al apartheid). Es la que tiene más huecos: 104.	y (269), n (62)

5 Particularidades técnicas al modelar

- **El vacío no es un dato perdido**: significa que el congresista no votó ni a favor ni en contra (votó «presente», se abstuvo o no anunció su posición). Puede tener significado político. Tratarlo como un tercer valor suele funcionar mejor que imputarlo.
- **Huecos desiguales**: el 5,3 % de las celdas están vacías, pero en la votación de Sudáfrica faltan 104 de 435.
- **Muy fácil con todas las variables**: en una prueba con validación cruzada de 10 bolsas, la regresión logística acierta un 96,3 %, el bosque aleatorio un 95,6 % y el árbol un 95,2 %. El árbol empieza casi siempre por `physician-fee-freeze`.
- **Ojo con interpretarlo hoy**: son votaciones de 1984. Los partidos y sus posiciones han cambiado mucho; el dataset sirve para aprender técnicas, no para sacar conclusiones políticas actuales.
- Los congresistas que el modelo clasifica mal, los que votan más como el otro partido, son los más interesantes de mirar.

6 Flujo de trabajo en Orange



1. **Datasets** → «Voting» (o **File** con el CSV).
2. **Rank**: `physician-fee-freeze` encabeza la lista con mucha diferencia.
3. **Naive Bayes** → **Nomogram**: cuánto empuja cada voto hacia uno u otro partido.
4. **Test and Score** con Naive Bayes y regresión logística.
5. **Confusion Matrix**: selecciona los errores → **Data Table**: ¿cómo votaron esos congresistas?

7 Otras consideraciones

- **Agrupar sin la clase**: *Distances* (por ejemplo, Hamming) y *Hierarchical Clustering* o *MDS* coloreado por partido: se ven dos bloques y unos pocos congresistas en tierra de nadie.
- **Reglas**: *CN2 Rule Induction* da reglas cortas y legibles («si votó a favor de congelar los honorarios… republicano»).
- **Quitar la votación decisiva**: repite sin `physician-fee-freeze` y mira qué votaciones la sustituyen.

En la carpeta `voting` ← `voting.tab` (datasets.biolab.si)

1.14
Clasificación: introductorios y de juguete

Bicycle rides (gravel vs mountain)

`01_clasificacion_introductorios/bicycle/`

Las 98 salidas en bicicleta de un investigador durante 2023, sacadas de Strava, con la distancia, el tiempo, la velocidad, el desnivel y las fotos: ¿fue con la de gravel o con la de montaña?

Clasificación binaria · Juguete

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
98	**6**	`Gear`	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`bicycle_gravel_vs_mountain`	98 × 6	CSV 5 KB · XLSX
`bicycle_time_distance`	98 × 3	CSV 2 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/01_clasificacion_introductorios/bicycle/` seguido del nombre del fichero CSV.

Radiografía

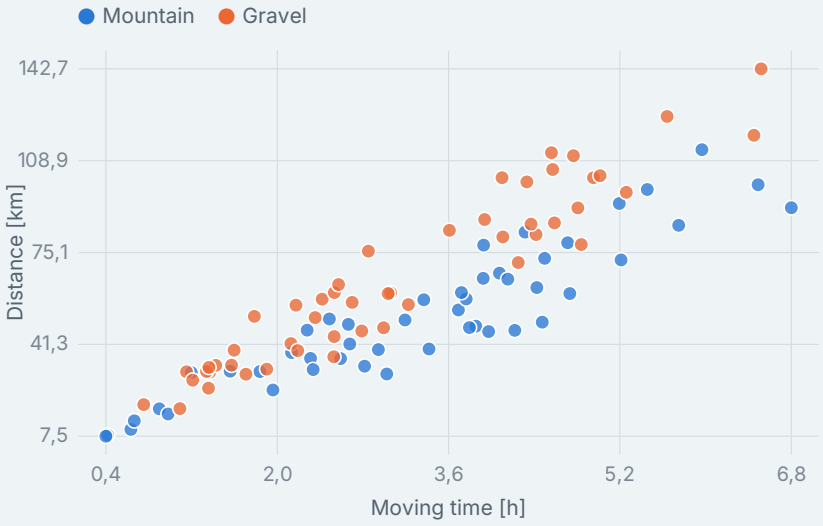
Gear en bicycle_gravel_vs_mountain



Gear en bicycle_time_distance



Distancia frente a tiempo en movimiento: la pendiente es la velocidad



1 Descripción general y estudios habituales

Cada fila es una salida en bicicleta registrada en Strava a lo largo de 2023. La clase dice qué bicicleta se usó: **gravel** (50 salidas) o **de montaña** (48). Hay dos versiones con las mismas 98 salidas en el mismo orden:

- `bicycle_gravel_vs_mountain`: cinco variables (distancia, tiempo en movimiento, velocidad media, desnivel acumulado y número de fotos).
- `bicycle_time_distance`: solo el tiempo y la distancia, para ver la frontera en un gráfico de dos ejes.

Los estudios habituales son:

- **Clasificación binaria con variables numéricas**, fácil de visualizar en un *Scatter Plot*.
- **Comparar fronteras de decisión**: árbol (cortes rectos), regresión logística (una recta), kNN (una frontera irregular).
- **Ver el efecto de una variable derivada**: la velocidad media es la distancia dividida por el tiempo.

2 Contexto y fuente original

Los datos los donó **Janez Demšar**, profesor de la Universidad de Liubliana y uno de los creadores de Orange: son sus propias salidas de 2023, exportadas de Strava. Se publicaron en 2024 como dataset educativo y se cargan con el widget *Datasets* de Orange. Son datos reales, aunque de una sola persona.

- Gravel vs Mountain Bike Rides: Data from Strava, en datasets.biolab.si (widget Datasets de Orange)
- Gravel vs Mountain Bike Rides: Distance and Time, en datasets.biolab.si

3 Variable objetivo

La clase es `Gear`: `Gravel` (50) o `Mountain` (48), casi equilibrada.

La velocidad media es lo que más separa: 21,0 km/h de media con la de gravel y 15,8 con la de montaña. Con una sola regla («gravel si va a más de 17 km/h») se acierta un 77 %. Con la de montaña hay más desnivel por kilómetro (18,6 m/km de media frente a 11,9) y se hacen más fotos (6,7 por salida frente a 3,2).

4 Diccionario de columnas

Columnas de `bicycle_gravel_vs_mountain` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Gear` objetivo	categórica	**Clase**: bicicleta usada, `Gravel` o `Mountain`.	Gravel (50), Mountain (48)
`Distance [km]`	numérica	Distancia recorrida en kilómetros (de 7,5 a 142,7).	7,452 – 142,747
`Moving time [h]`	numérica	Tiempo en movimiento en horas (sin contar las paradas).	0,412 – 6,819
`Avg speed`	numérica	Velocidad media en km/h. Es exactamente `Distance [km]` / `Moving time [h]`.	9,99 – 28,674
`Elevation [m]`	numérica	Desnivel positivo acumulado en metros.	33 – 2.284
`Photos`	numérica	Número de fotos subidas a la actividad en Strava.	0 – 20

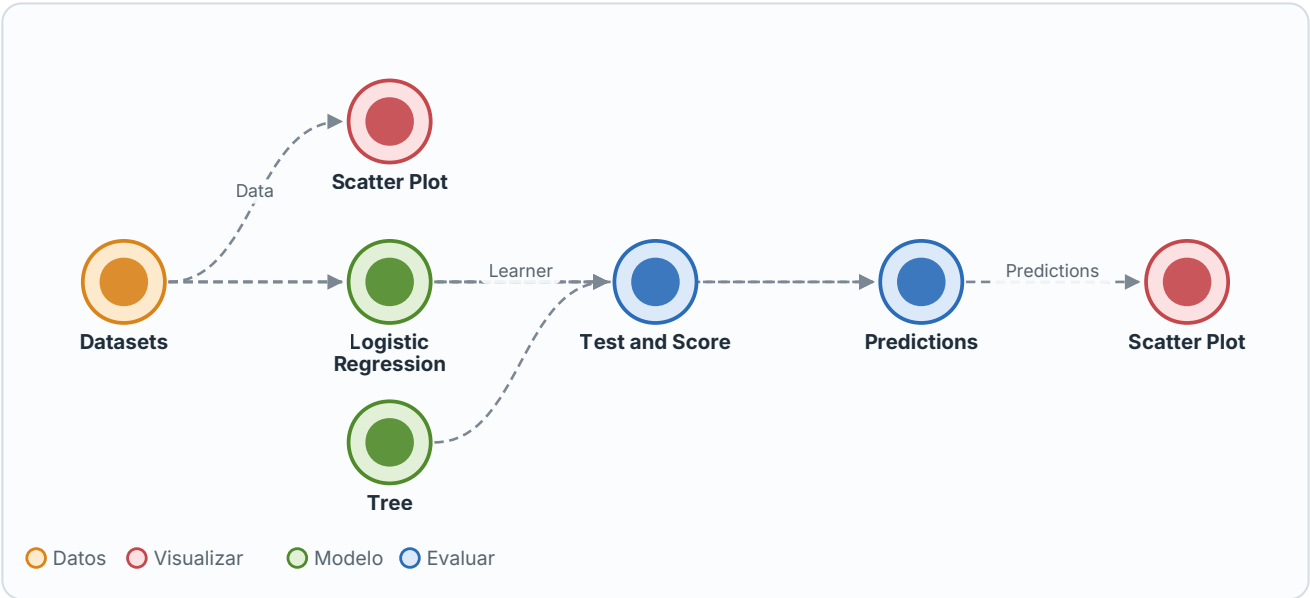
Columnas de `bicycle_time_distance` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Gear` `objetivo`	categórica	**Clase**: bicicleta usada.	Gravel (50), Mountain (48)
`Moving time [h]`	numérica	Tiempo en movimiento en horas.	0,412 – 6,819
`Distance [km]`	numérica	Distancia en kilómetros.	7,452 – 142,747

5 Particularidades técnicas al modelar

- **Una variable es función de otras dos**: `Avg speed` = distancia / tiempo. Un árbol la aprovecha directamente; en la versión de dos variables, el modelo tiene que «descubrir» la velocidad como la pendiente de una recta que pasa por el origen, y la regresión logística, que traza una recta cualquiera, lo hace bastante bien.
- **Las clases se solapan**: hay salidas lentas con la de gravel y rápidas con la de montaña. En una prueba con validación cruzada de 10 bolsas, la regresión logística acierta un 77 % con todas las variables y un 76 % solo con tiempo y distancia; el árbol, un 75 % y un 65 %.
- **Escalas muy distintas** (kilómetros, horas, metros, fotos): para kNN y la regresión logística con regularización, normaliza antes con *Preprocess*.
- **Una sola persona y un año**: el modelo aprende las costumbres de un ciclista concreto (dónde sale con cada bici, cuánto fotografía), no algo general sobre las bicicletas.
- `Photos` es curiosa pero no tiene nada que ver con la bicicleta en sí: es una buena ocasión para hablar de variables que predicen por casualidad o por costumbre.

6 Flujo de trabajo en Orange



1. **Datasets** → «Gravel vs Mountain Bike Rides: Distance and Time» (o **File** con `bicycle_time_distance`).
2. **Scatter Plot** con tiempo en el eje X, distancia en el Y y color por `Gear`: las salidas de gravel quedan por encima, con más pendiente.
3. **Test and Score** con regresión logística y árbol.
4. **Predictions** → **Scatter Plot** coloreado por la predicción: dónde está la frontera de cada modelo.
5. Repite con `bicycle_gravel_vs_mountain` y las cinco variables, y mira en *Rank* cuál pesa más.

7 Otras consideraciones

- **Construir la velocidad**: con *Feature Constructor*, crea `Distance [km] / Moving time [h]` en la versión de dos variables y compara el árbol antes y después.
- **Tus propias salidas**: Strava y otras aplicaciones permiten exportar las actividades. Con los datos de un alumno (andar, correr, bici) se puede repetir el ejercicio.
- **Visualizar fronteras**: el add-on *Educational* de Orange tiene el widget *Polynomial Classification*, que dibuja la frontera de decisión de cada modelo con dos variables.

En la carpeta	`bicycle_gravel_vs_mountain` ← `bicycle-gravel-vs-mountain.xlsx` (datasets.biolab.si)
En la carpeta	`bicycle_time_distance` ← `bicycle-time-distance.xlsx` (datasets.biolab.si)

2 Clasificación: salud y medicina

14 datasets en el capítulo; en esta edición, 14 con ficha.

2.01
Clasificación: salud y medicina

Pima Indians Diabetes

`02_clasificacion_salud/pima_diabetes/`

768 mujeres de origen pima de Arizona, con ocho medidas clínicas y si desarrollaron diabetes: el clásico de clasificación médica, con ceros que en realidad son datos que faltan.

Clasificación binaria · ? Valores faltantes

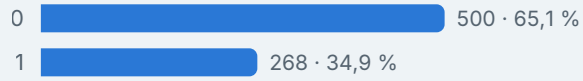
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
768	**9**	`Outcome`	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`pima_diabetes`	768 × 9	CSV 23 KB · XLSX
`pima_diabetes_missing`	768 × 9	CSV 22 KB · XLSX

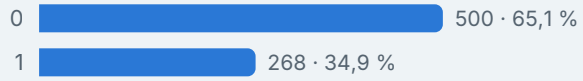
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/02_clasificacion_salud/pima_diabetes/` seguido del nombre del fichero CSV.

Radiografía

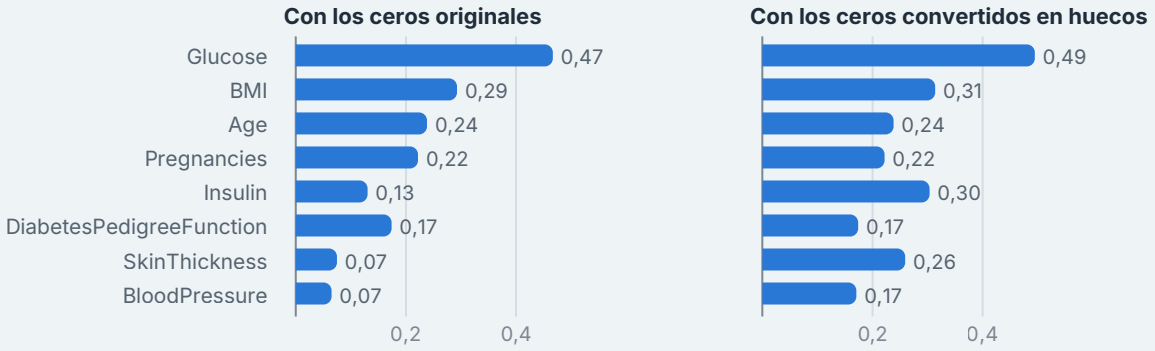
Outcome en pima_diabetes



Outcome en pima_diabetes_missing



Correlación de cada variable con tener diabetes



1 Descripción general y estudios habituales

Cada fila es una mujer de al menos 21 años, de origen pima, con ocho medidas tomadas en una revisión: número de embarazos, glucosa en sangre tras una prueba de tolerancia, tensión arterial, pliegue cutáneo del

tríceps, insulina, índice de masa corporal, un índice de antecedentes familiares de diabetes y la edad. La clase dice si la mujer fue diagnosticada de diabetes (268) o no (500).

Hay dos versiones con las mismas 768 filas:

- `pima_diabetes` : la original, donde los datos que faltan aparecen como **0**.
- `pima_diabetes_missing` : la misma tabla con esos ceros imposibles convertidos en valores ausentes.

Los estudios habituales son:

- **Clasificación binaria** con variables numéricas y clase algo desequilibrada.
- **Detectar y tratar valores ausentes disfrazados** (ceros donde no puede haberlos).
- **Explicar un modelo médico** con regresión logística y nomograma.

2 Contexto y fuente original

Los datos son del Instituto Nacional de Diabetes y Enfermedades Digestivas y Renales de Estados Unidos (NIDDK), que estudió durante décadas a la comunidad pima del río Gila, cerca de Phoenix (Arizona), con una de las tasas de diabetes tipo 2 más altas del mundo. Los publicaron Jack Smith y colaboradores en 1988, en un trabajo que predecía la aparición de diabetes en los cinco años siguientes, y estuvieron muchos años en el repositorio UCI; hoy la copia más usada es la de Kaggle.

En el repositorio del curso está en CSV y ARFF, y Orange incluye la misma tabla en su widget *Datasets*. Aquí se usa la CSV del curso y su variante con huecos.

- Smith, J. W. et al. (1988). Using the ADAP learning algorithm to forecast the onset of diabetes mellitus. Proceedings of the Annual Symposium on Computer Application in Medical Care, 261–265.
- Pima Indians Diabetes Database, Kaggle (copia del repositorio UCI)

3 Variable objetivo

La clase es `Outcome` : 1 si la mujer tiene diabetes (268, el 35 %) y 0 si no (500). Acertar siempre «no» da un 65 %.

La glucosa es la variable que más separa: 141 mg/dl de media en las diabéticas frente a 110 en las demás. Le siguen el índice de masa corporal (35 frente a 30), la edad (37 frente a 31 años) y el número de embarazos. En una prueba con validación cruzada de 10 bolsas, la regresión logística y el bosque aleatorio aciertan en torno al 76–77 % y el árbol un 70 %.

4 Diccionario de columnas

Columnas de `pima_diabetes` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Pregnancies`	numérica	Número de embarazos (aquí el 0 sí es un valor real: 111 mujeres).	0 – 17
`Glucose`	numérica	Glucosa en plasma a las 2 horas de una prueba de tolerancia oral (mg/dl). 5 ceros, imposibles.	0 – 199
`BloodPressure`	numérica	Tensión arterial diastólica (mm Hg). 35 ceros, imposibles.	0 – 122

Columna	Tipo	Significado	Valores
`SkinThickness`	numérica	Pliegue cutáneo del tríceps (mm). 227 ceros: casi un 30 % sin medir.	0 – 99
`Insulin`	numérica	Insulina en suero a las 2 horas (µU/ml). 374 ceros: casi la mitad sin medir.	0 – 846
`BMI`	numérica	Índice de masa corporal (kg/m²). 11 ceros, imposibles.	0 – 67,1
`DiabetesPedigreeFunction`	numérica	Índice de antecedentes familiares de diabetes, calculado a partir de los familiares diagnosticados.	0,078 – 2,42
`Age`	numérica	Edad en años (de 21 a 81).	21 – 81
`Outcome` `objetivo`	categórica	**Clase**: 1 diabetes, 0 no.	0 (500), 1 (268)

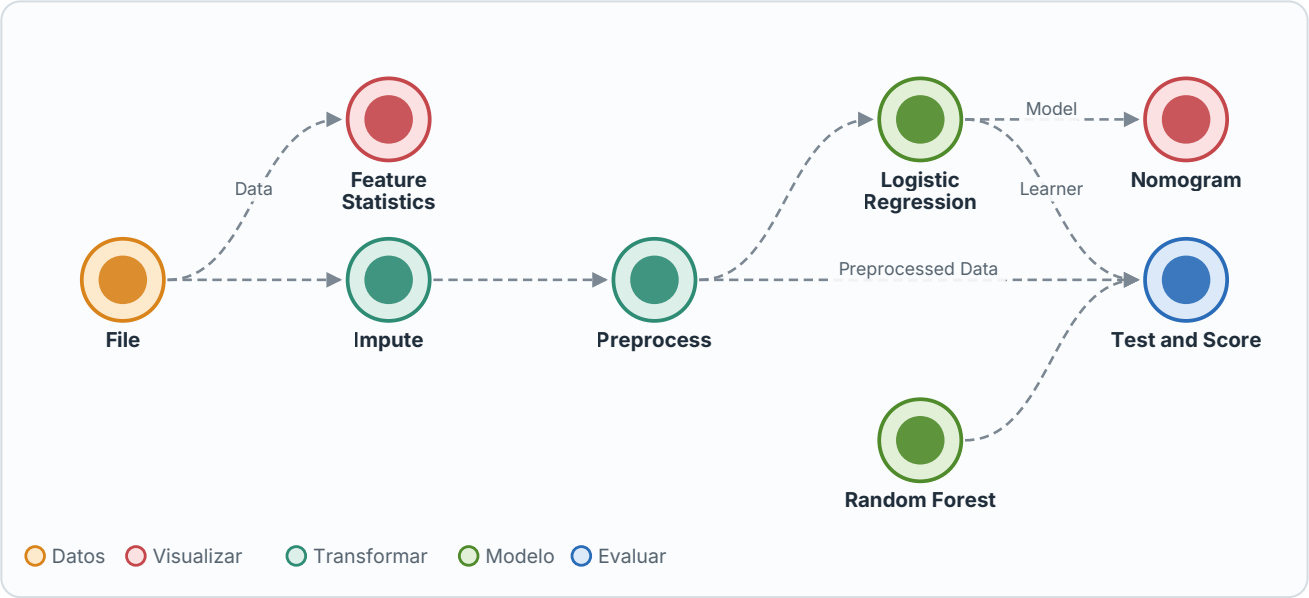
Columnas de `pima_diabetes_missing` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Pregnancies`	numérica	Número de embarazos.	0 – 17
`Glucose`	numérica	Glucosa (mg/dl), con 5 huecos.	44 – 199
`BloodPressure`	numérica	Tensión diastólica (mm Hg), con 35 huecos.	24 – 122
`SkinThickness`	numérica	Pliegue del tríceps (mm), con 227 huecos.	7 – 99
`Insulin`	numérica	Insulina (µU/ml), con 374 huecos.	14 – 846
`BMI`	numérica	Índice de masa corporal, con 11 huecos.	18,2 – 67,1
`DiabetesPedigreeFunction`	numérica	Índice de antecedentes familiares.	0,078 – 2,42
`Age`	numérica	Edad en años.	21 – 81
`Outcome` `objetivo`	categórica	**Clase**: 1 diabetes, 0 no.	0 (500), 1 (268)

5 Particularidades técnicas al modelar

- **Ceros que son huecos**: nadie tiene tensión arterial, glucosa o índice de masa corporal 0. En el fichero original, un 0 en esas cinco columnas significa «no se midió». Si se dejan como están, la media de la insulina baja a la mitad y los modelos aprenden que «insulina 0» es un valor. La versión `pima_diabetes_missing` ya los ha convertido en ausentes; en el original hay que hacerlo con *Edit Domain*, *Formula* o *Select Rows*.
- **Muchos huecos en dos variables**: la insulina falta en casi la mitad de las mujeres y el pliegue cutáneo en un 30 %. Imputar con la media puede distorsionar; prueba también a quitar esas columnas.
- **Desequilibrio moderado** (35 % de diabéticas): mira la sensibilidad y el AUC, no solo el acierto.
- **Escalas muy distintas** (la insulina llega a 846; el índice familiar no pasa de 2,4): normaliza para kNN, SVM y la regresión logística.
- Es una población muy concreta (mujeres pima adultas de los años ochenta): el modelo no se generaliza a otras.

6 Flujo de trabajo en Orange



1. **File** con `pima_diabetes_missing` (o con el original, para buscar los ceros) y `Outcome` como *target*.
2. **Feature Statistics**: en el original, los mínimos 0 de glucosa, tensión e índice de masa corporal delatan los huecos; en la otra versión se ven como ausentes.
3. **Impute** (media o modelo) → **Preprocess** (normalizar).
4. **Test and Score** con regresión logística y bosque aleatorio; compara el AUC.
5. **Logistic Regression** → **Nomogram**: cuánto pesa la glucosa frente a las demás variables.

7 Otras consideraciones

- **Comparar las dos versiones**: entrena el mismo modelo con los ceros originales y con los huecos imputados. La diferencia de acierto es pequeña, pero los coeficientes de la regresión logística cambian mucho.
- **Umbral de decisión**: en un cribado interesa detectar a casi todas las diabéticas. Con *Calibration Plot* o moviendo el umbral, mira cuántos falsos positivos cuesta llegar a una sensibilidad del 90 %.
- **Equidad**: el dataset solo tiene mujeres de una comunidad indígena; es un buen punto de partida para hablar de quién está representado en los datos médicos.

En la carpeta	`pima_diabetes` ← `diabetes.csv` (curso_ciencia_datos (GitHub))
En la carpeta	`pima_diabetes_missing` ← `diabetes_missing.csv` (curso_ciencia_datos (GitHub))
Duplicado, no se copia	`diabetes.arff` (curso_ciencia_datos (GitHub))
Duplicado, no se copia	`pima-diabetes.xlsx` (datasets.biolab.si)

2.02
Clasificación: salud y medicina

Heart Disease (Cleveland)

`02_clasificacion_salud/heart_disease/`

303 pacientes de la Clínica Cleveland con 13 datos clínicos y de pruebas de esfuerzo, y si tenían estrechamiento de las arterias coronarias: el dataset médico más usado para clasificación binaria con variables mixtas.

Clasificación binaria · ? Valores faltantes · ◈ Mixto num. + cat.

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
303	**14**	`diameter narrowing`	**0,1 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`heart_disease`	303 × 14	CSV 24 KB · XLSX

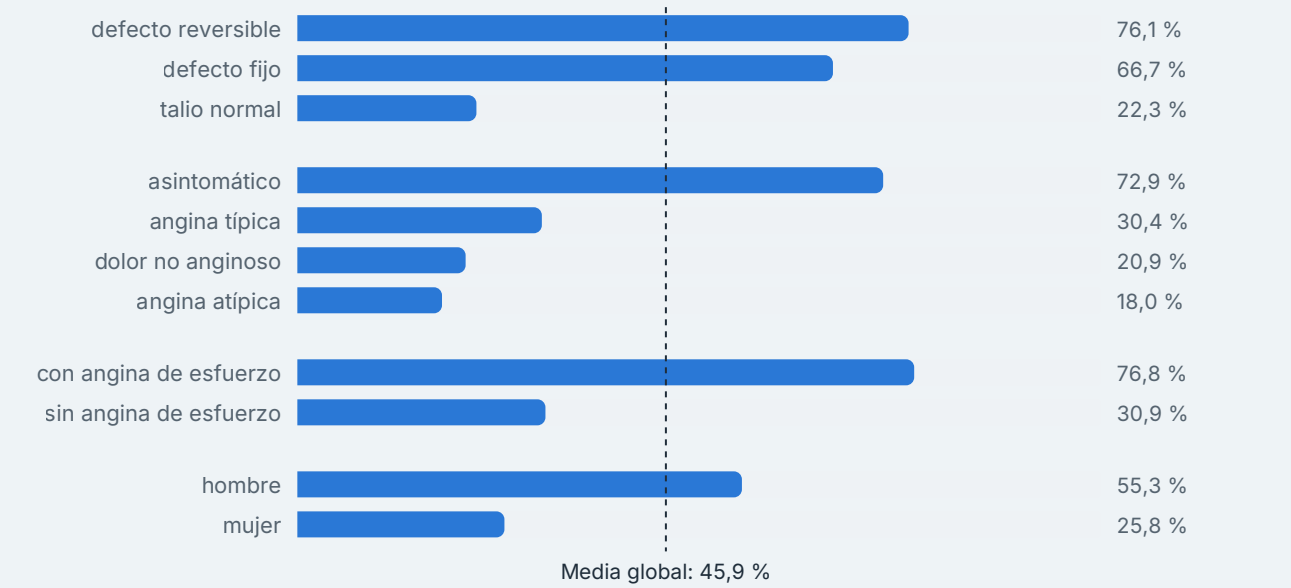
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/02_clasificacion_salud/heart_disease/` seguido del nombre del fichero CSV.

Radiografía

diameter narrowing en heart_disease



Porcentaje de pacientes con estrechamiento coronario



1 Descripción general y estudios habituales

Cada fila es un paciente estudiado por sospecha de enfermedad coronaria. Las 13 variables combinan datos generales (edad, sexo), síntomas (tipo de dolor torácico, angina con el ejercicio), analíticas (colesterol, glucosa en ayunas) y resultados de pruebas (electrocardiograma en reposo, frecuencia cardiaca máxima en la prueba de esfuerzo, descenso del segmento ST, vasos coloreados en la fluoroscopia y resultado de la gammagrafía con talio). La clase dice si una angiografía encontró un estrechamiento de más del 50 % en alguna arteria coronaria (139 pacientes) o no (164).

Los estudios habituales son:

- **Clasificación binaria** con variables numéricas y categóricas mezcladas.
- **Interpretar el modelo**: qué pruebas aportan más al diagnóstico.
- **Comparar modelos** en un problema de tamaño moderado y casi equilibrado.

2 Contexto y fuente original

Los datos los recogió **Robert Detrano** en la Clínica Cleveland (Ohio) y forman parte de una colección de cuatro hospitales (Cleveland, Hungría, Suiza y Long Beach) publicada en 1989 para validar un algoritmo de probabilidad de enfermedad coronaria. La base original tenía 76 variables; todos los trabajos usan este subconjunto de 14. Está en el repositorio UCI desde 1988.

La clase original iba de 0 (sin estrechamiento) a 4. Casi todos los estudios, y la versión de Orange, la reducen a ausencia (0) o presencia (1 a 4).

- Detrano, R. et al. (1989). International application of a new probability algorithm for the diagnosis of coronary artery disease. American Journal of Cardiology, 64(5), 304–310.
- Heart Disease en el repositorio UCI

3 Variable objetivo

La clase es `diameter narrowing`: 1 si hay estrechamiento de más del 50 % en alguna coronaria (139 pacientes, el 46 %) y 0 si no (164).

Las variables que más separan son los resultados de las pruebas: con un defecto reversible en la gammagrafía con talio, el 76 % de los pacientes tiene la enfermedad, frente al 22 % con resultado normal; con dolor torácico asintomático, el 73 %. En una prueba con validación cruzada de 10 bolsas, la regresión logística acierta un 85 %, Naive Bayes un 83 % y el árbol un 77 %.

4 Diccionario de columnas

Columnas de `heart_disease` (valores observados en el fichero)

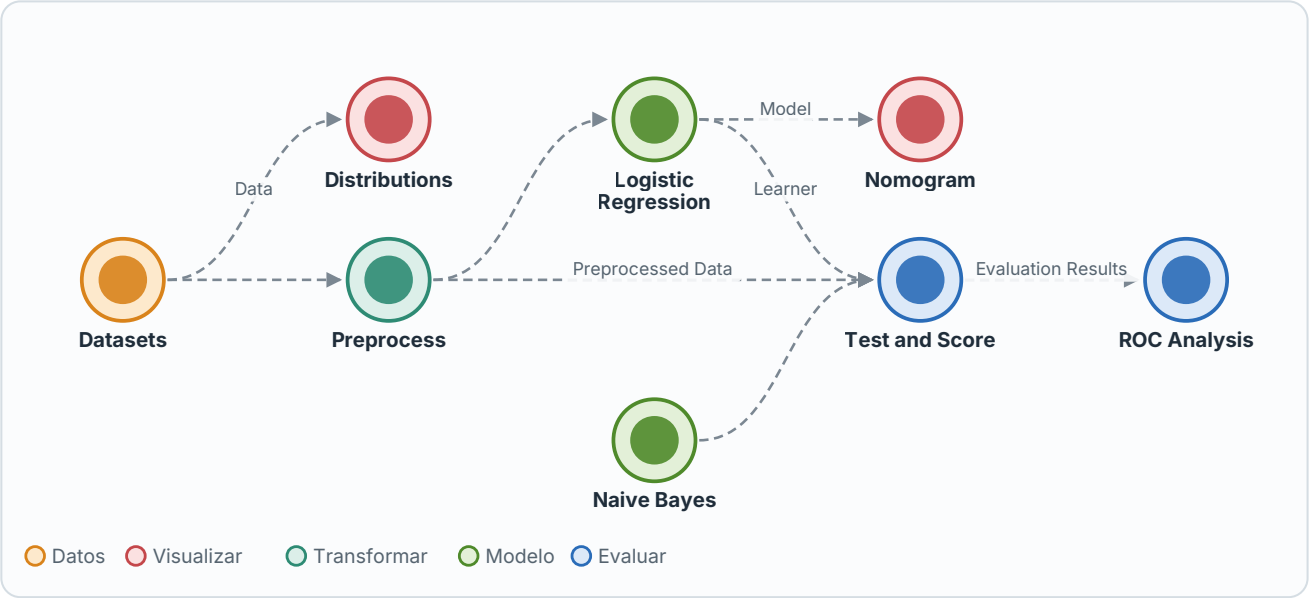
Columna	Tipo	Significado	Valores
`age`	numérica	Edad en años (de 29 a 77).	29 – 77
`gender`	categórica	Sexo (`male` / `female`).	male (206), female (97)
`chest pain`	categórica	Tipo de dolor torácico: `typical ang` (angina típica), `atypical ang` (atípica), `non-anginal` (no anginoso) o `asymptomatic` (sin dolor).	asymptomatic (144), non-anginal (86), atypical ang (50), typical ang (23)

Columna	Tipo	Significado	Valores
`rest SBP`	numérica	Tensión arterial sistólica en reposo (mm Hg).	94 – 200
`cholesterol`	numérica	Colesterol sérico (mg/dl).	126 – 564
`fasting blood sugar > 120`	categórica	Glucosa en ayunas mayor de 120 mg/dl (1 sí, 0 no).	0 (258), 1 (45)
`rest ECG`	categórica	Electrocardiograma en reposo: `normal`, `ST-T abnormal` o `left vent hypertrophy` (hipertrofia ventricular izquierda).	normal (151), left vent hypertrophy (148), ST-T abnormal (4)
`max HR`	numérica	Frecuencia cardiaca máxima alcanzada en la prueba de esfuerzo.	71 – 202
`exerc ind ang`	categórica	Angina provocada por el ejercicio (1 sí, 0 no).	0 (204), 1 (99)
`ST by exercise`	numérica	Descenso del segmento ST con el ejercicio respecto al reposo (mm).	0 – 6,2
`slope peak exc ST`	categórica	Pendiente del segmento ST en el pico del esfuerzo: `upsloping`, `flat` o `downsloping`.	upsloping (142), flat (140), downsloping (21)
`major vessels colored`	numérica	Número de vasos principales (0 a 3) coloreados en la fluoroscopia. 4 huecos.	0 – 3
`thal`	categórica	Gammagrafía con talio: `normal`, `fixed defect` (defecto fijo) o `reversable defect` (reversible). 2 huecos.	normal (166), reversable defect (117), fixed defect (18)
`diameter narrowing` `objetivo`	categórica	**Clase**: estrechamiento de más del 50 % en alguna coronaria (1) o no (0).	0 (164), 1 (139)

5 Particularidades técnicas al modelar

- **Variables mixtas**: seis numéricas, tres binarias guardadas como 0/1 y cuatro categóricas. Orange lee las binarias como numéricas; para Naive Bayes o para interpretar mejor, conviene pasarlas a categóricas con *Edit Domain*.
- **Pocos huecos**: 6 pacientes con algún dato ausente (en `major vessels colored` y `thal`). Se pueden imputar o quitar sin perder mucho.
- **Variables de pruebas costosas**: la angiografía es la prueba de referencia y la gammagrafía o la fluoroscopia son pruebas invasivas o caras. Un modelo que solo use datos sencillos (edad, sexo, dolor, colesterol) es menos preciso pero más útil en una primera consulta. Es un buen ejercicio comparar los dos.
- **Escalas distintas** (el colesterol llega a 564; el descenso del ST no pasa de 6,2): normaliza para kNN y SVM. Sin normalizar, kNN se queda en un 64 %.
- Casi equilibrado (46 % de enfermos), así que el acierto es una medida razonable, aunque en diagnóstico importa más la sensibilidad.

6 Flujo de trabajo en Orange



1. **Datasets** → «Heart Disease» (o **File** con el CSV).
2. **Distributions** de `thal` y `chest pain` agrupadas por la clase.
3. **Preprocess**: imputar los 6 huecos y normalizar.
4. **Test and Score** con regresión logística y Naive Bayes → **ROC Analysis**.
5. **Logistic Regression** → **Nomogram**: el peso de cada prueba en el diagnóstico.

7 Otras consideraciones

- **Modelo de consulta frente a modelo hospitalario**: con *Select Columns*, quita `thal`, `major vessels colored` y las variables de la prueba de esfuerzo y compara el AUC con el modelo completo.
- **Los otros hospitales**: el repositorio UCI tiene los datos de Hungría, Suiza y Long Beach con las mismas columnas (y muchos más huecos). Entrenar en Cleveland y probar en otro hospital muestra cuánto cuesta generalizar.
- **Explicabilidad**: *Explain Model* (add-on *Explain*) da la importancia de cada variable y es un buen complemento del nomograma.

En la carpeta `heart_disease` ← `heart_disease.tab` (datasets.biolab.si)

2.03
Clasificación: salud y medicina

Breast Cancer (Ljubljana)

`02_clasificacion_salud/breast_cancer/`

286 pacientes operadas de cáncer de mama en Liubliana, con nueve datos del tumor, y si el cáncer reapareció: un dataset difícil, en el que casi ningún modelo supera de forma clara a decir siempre «no».

Clasificación binaria · ? Valores faltantes · ◇ Solo categóricos

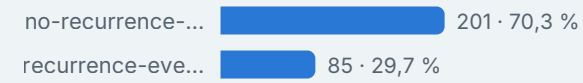
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
286	**10**	`recurrence`	**0,3 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`breast_cancer`	286 × 10	CSV 19 KB · XLSX

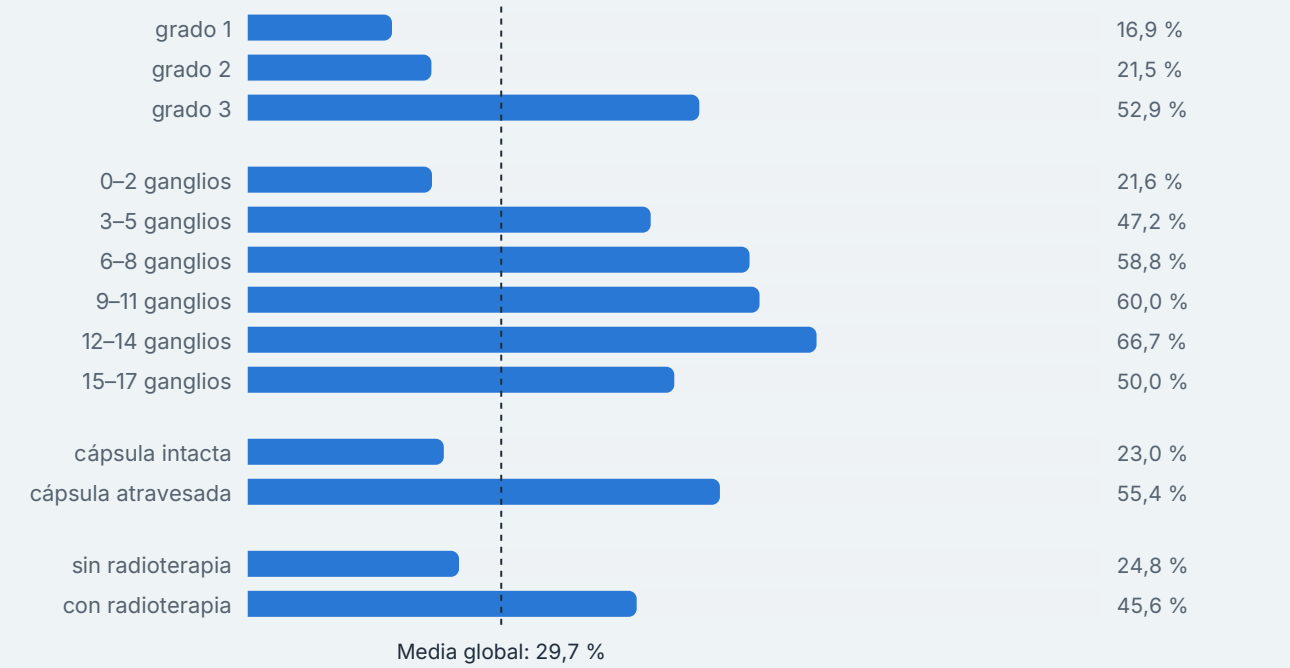
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/02_clasificacion_salud/breast_cancer/` seguido del nombre del fichero CSV.

Radiografía

recurrence en breast_cancer



Porcentaje de recaídas



1 Descripción general y estudios habituales

Cada fila es una paciente con cáncer de mama, descrita por nueve variables categóricas: edad y estado menopáusico, tamaño del tumor, número de ganglios axilares afectados, si el tumor atravesaba la cápsula del ganglio, grado de malignidad, mama y cuadrante afectados y si recibió radioterapia. La clase dice si el cáncer **reapareció** (85) o no (201) en el seguimiento.

Los estudios habituales son:

- **Clasificación binaria con atributos categóricos**, varios ordinales agrupados en rangos.
- **Ver los límites del aprendizaje automático**: con estas variables, la recaída es difícil de predecir.
- **Comparar con trabajos clásicos**: la documentación de UCI recoge aciertos de entre el 66 % y el 78 % para los sistemas de los años ochenta.

2 Contexto y fuente original

Es uno de los tres datasets que el **Instituto de Oncología del Centro Médico Universitario de Liubliana** (M. Zwitter y M. Soklič) cedió a finales de los años ochenta, junto con *Lymphography* y *Primary Tumor*. Los tres aparecen en muchos trabajos clásicos de aprendizaje automático, empezando por el sistema AQ15 de Michalski y colaboradores (1986). Está en el repositorio UCI desde 1988.

No hay que confundirlo con los dos datasets de cáncer de mama de Wisconsin de este capítulo, que diagnostican si un tumor es maligno a partir de imágenes de células: aquí todas las pacientes tienen cáncer y se trata de prever la recaída.

- Breast Cancer en el repositorio UCI (Instituto de Oncología de Liubliana)

3 Variable objetivo

La clase es `recurrence`: `recurrence-events` (85, el 30 %) o `no-recurrence-events` (201). Decir siempre «no reaparece» acierta un 70 %.

El grado de malignidad es lo que más se relaciona con la recaída: reaparece en el 17 % de los tumores de grado 1, en el 22 % de los de grado 2 y en el 53 % de los de grado 3. También importa el número de ganglios afectados. Pero en una prueba con validación cruzada de 10 bolsas, los modelos se quedan entre el 69 % (árbol) y el 76 % (bosque aleatorio): apenas por encima de no usar ningún modelo.

4 Diccionario de columnas

Columnas de `breast_cancer` (valores observados en el fichero)

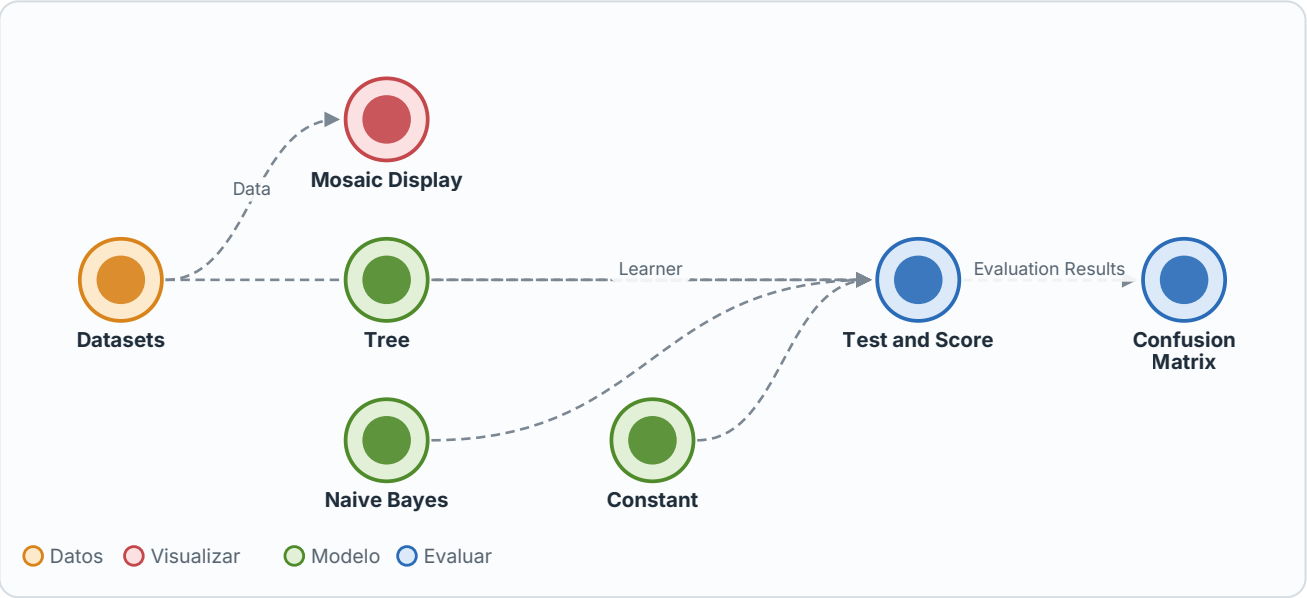
Columna	Tipo	Significado	Valores
`recurrence` objetivo	categórica	**Clase**: `recurrence-events` (el cáncer reapareció) o `no-recurrence-events`.	no-recurrence-events (201), recurrence-events (85)
`age`	categórica	Edad en rangos de diez años (`20-29` … `70-79`).	50-59 (96), 40-49 (90), 60-69 (57), 30-39 (36), 70-79 (6), 20-29 (1)
`menopause`	categórica	Estado menopáusico: `premeno`, `lt40` (menopausia antes de los 40) o `ge40` (a partir de los 40).	premeno (150), ge40 (129), lt40 (7)

Columna	Tipo	Significado	Valores
`tumor-size`	categórica	Tamaño del tumor en mm, en rangos de 5 (`0-4` … `50-54`).	30-34 (60), 25-29 (54), 20-24 (50), 15-19 (30), 10-14 (28), 40-44 (22) …
`inv-nodes`	categórica	Número de ganglios axilares afectados, en rangos de 3 (`0-2` … `15-17`). 1 hueco.	0-2 (213), 3-5 (36), 6-8 (17), 9-11 (10), 15-17 (6), 12-14 (3)
`node-caps`	categórica	Si el tumor atraviesa la cápsula del ganglio (`yes` / `no`). 8 huecos.	no (222), yes (56)
`deg-malig`	categórica	Grado de malignidad histológica: 1, 2 o 3.	2 (130), 3 (85), 1 (71)
`breast`	categórica	Mama afectada (`left` / `right`).	left (152), right (134)
`breast-quad`	categórica	Cuadrante afectado: `left_up`, `left_low`, `right_up`, `right_low` o `central`. 1 hueco.	left_low (110), left_up (97), right_up (33), right_low (24), central (21)
`irradiat`	categórica	Si recibió radioterapia (`yes` / `no`).	no (218), yes (68)

5 Particularidades técnicas al modelar

- **Los rangos son categorías sin orden**: Orange ordena `tumor-size` y `inv-nodes` alfabéticamente (`5-9` queda después de `45-49`). Para un árbol da igual, pero en gráficos y en modelos lineales conviene reordenarlos o convertirlos en números (el punto medio de cada rango) con *Feature Constructor*.
- **Muy difícil**: la información que hay en estas nueve variables es escasa. Cualquier mejora de un modelo sobre el 70 % de base debe comprobarse con cuidado (varias repeticiones de la validación cruzada) antes de creérsela.
- **Casos repetidos y contradictorios**: 14 pacientes tienen exactamente los mismos datos que otra, y en 6 grupos de pacientes idénticas unas recayeron y otras no. Ningún modelo puede acertar esos casos.
- **Desequilibrio**: con un 30 % de recaídas, mira la sensibilidad. Un modelo que diga casi siempre «no» tiene buen acierto y no sirve para nada.
- Pocos huecos: 10 celdas, sobre todo en `node-caps`.

6 Flujo de trabajo en Orange



1. **Datasets** → «Breast Cancer» (o **File** con el CSV).
2. **Mosaic Display** con `deg-malig` y `inv-nodes`: dónde se concentran las recaídas.
3. **Test and Score** con árbol, Naive Bayes y **Constant** (el modelo que siempre dice la clase mayoritaria): la diferencia es pequeña.
4. **Confusion Matrix**: cuántas recaídas detecta cada modelo.

7 Otras consideraciones

- **Lección de humildad**: es un buen dataset para enseñar que no todos los problemas se resuelven con datos y que hay que comparar siempre con un modelo trivial.
- **Ordenar los rangos**: convierte `tumor-size` e `inv-nodes` en números y repite con regresión logística. ¿Mejora?
- **Los otros datasets de Liubliana**: *Lymphography* y *Primary Tumor*, de la misma época y el mismo instituto.

En la carpeta `breast_cancer` ← `breast-cancer.tab` (datasets.biolab.si)

2.04
Clasificación: salud y medicina

Breast Cancer Wisconsin (original)

`02_clasificacion_salud/breast_cancer_wisconsin/`

683 biopsias de mama por punción con nueve características de las células puntuadas de 1 a 10, y si el tumor era benigno o maligno. La versión de Orange tiene los valores «difuminados» para que se vean mejor en los gráficos.

Clasificación binaria

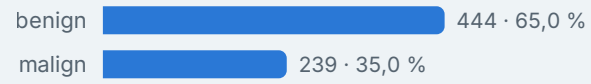
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
683	**10**	`type`	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`breast_cancer_wisconsin`	683 × 10	CSV 35 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/02_clasificacion_salud/breast_cancer_wisconsin/` seguido del nombre del fichero CSV.

Radiografía

type en breast_cancer_wisconsin



Qué características acompañan a los tumores malignos



1 Descripción general y estudios habituales

Cada fila es una muestra de tejido de mama obtenida por punción con aguja fina. Un patólogo puntuó de 1 a 10 nueve características de las células: grosor del grupo celular, uniformidad del tamaño y de la forma, adhesión marginal, tamaño de las células epiteliales, núcleos desnudos, cromatina, nucléolos normales y mitosis. La clase dice si el tumor era **benigno** (444) o **maligno** (239).

Los estudios habituales son:

- **Clasificación binaria** con variables numéricas: es un problema fácil, con aciertos del 96–97 %.
- **Comparar modelos** y ver que casi todos llegan al mismo techo.
- **Visualizar la separación** entre clases en un *Scatter Plot*.

2 Contexto y fuente original

Los datos los reunió el médico **William H. Wolberg** en los hospitales de la Universidad de Wisconsin (Madison) entre 1989 y 1991, y los usó con Olvi Mangasarian para presentar un método de separación por planos (1990). Es el *Breast Cancer Wisconsin (Original)* del repositorio UCI, con 699 muestras; la versión de Orange quita las 16 que tenían ausente el valor de núcleos desnudos y se queda en 683.

Los valores no son los originales. En el original, cada característica es un número entero de 1 a 10. En la versión de Orange se ha restado a cada valor un número aleatorio entre 0 y 1 (al redondear hacia arriba se recupera el entero original en el 99,8 % de las celdas). Es un truco para que los puntos no se amontonen en los gráficos de dispersión: en el original, 234 muestras repiten exactamente los mismos valores que otra.

No hay que confundirlo con el *Breast Cancer Wisconsin (Diagnostic)* (WDBC, en este mismo capítulo), que tiene 30 medidas calculadas sobre imágenes de los núcleos.

- Wolberg, W. H. y Mangasarian, O. L. (1990). Multisurface method of pattern separation for medical diagnosis applied to breast cytology. Proceedings of the National Academy of Sciences, 87(23), 9193–9196.
- Breast Cancer Wisconsin (Original) en el repositorio UCI

3 Variable objetivo

La clase es `type`: `benign` (444, el 65 %) o `malign` (239).

Casi todas las variables separan bien las clases: en los tumores malignos las células son más grandes, menos uniformes y con más núcleos desnudos. En una prueba con validación cruzada de 10 bolsas, kNN, el bosque aleatorio, Naive Bayes y la regresión logística aciertan entre el 96,8 % y el 97,4 %; el árbol, un 93,4 %.

4 Diccionario de columnas

Columnas de `breast_cancer_wisconsin` (valores observados en el fichero)

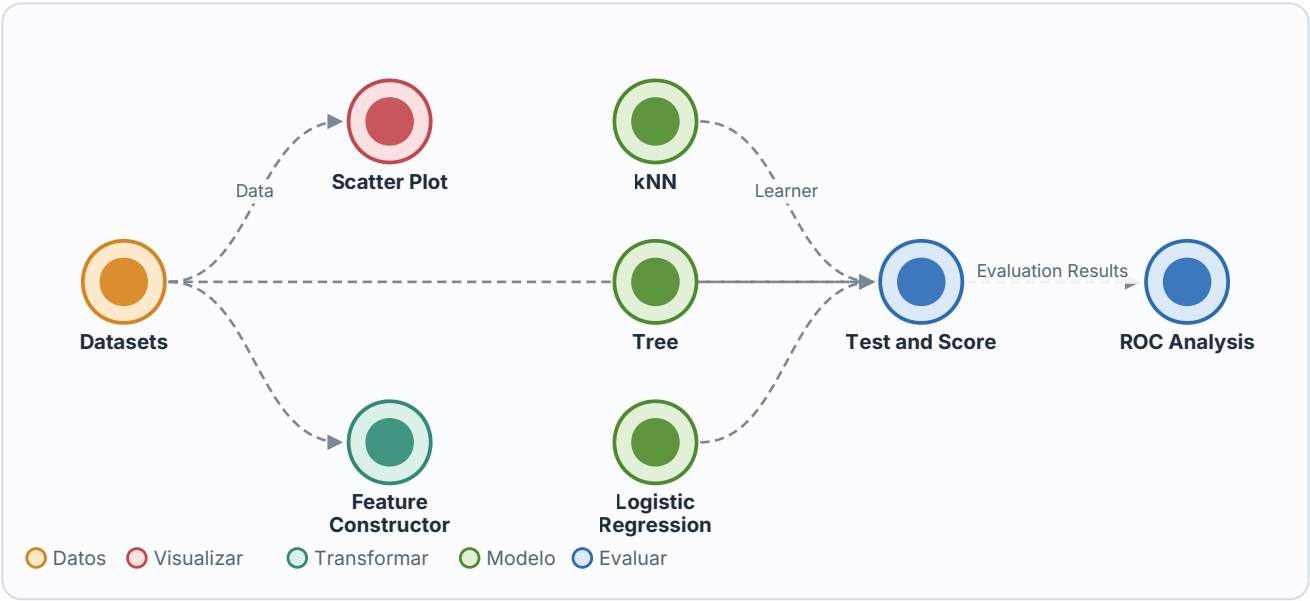
Columna	Tipo	Significado	Valores
`Clump thickness`	numérica	Grosor del grupo de células (1 a 10 en el original; aquí, con un desplazamiento aleatorio de hasta −1).	0 – 10
`Unif_Cell_Size`	numérica	Uniformidad del tamaño de las células.	0 – 9,99
`Unif_Cell_Shape`	numérica	Uniformidad de la forma de las células.	0 – 10
`Marginal_Adhesion`	numérica	Adhesión marginal (cuánto se pegan las células entre sí).	0 – 9,98
`Single_Cell_Size`	numérica	Tamaño de las células epiteliales individuales.	0,02 – 9,96
`Bare_Nuclei`	numérica	Núcleos desnudos (núcleos sin citoplasma alrededor).	0 – 9,99
`Bland_Chromatine`	numérica	Aspecto de la cromatina («suave» en las células normales).	0,01 – 9,97

Columna	Tipo	Significado	Valores
`Normal_Nucleoli`	numérica	Nucléolos normales.	0 – 10
`Mitoses`	numérica	Mitosis (células en división).	0 – 9,92
`type` objetivo	categórica	**Clase**: `benign` (benigno) o `malign` (maligno).	benign (444), malign (239)

5 Particularidades técnicas al modelar

- **Valores difuminados**: en esta versión las variables parecen continuas (4,05; 0,79…), pero en realidad son puntuaciones enteras de 1 a 10 con ruido añadido. Para recuperar el original, redondea hacia arriba con *Feature Constructor* (`ceil(...)`). Los resultados de los modelos apenas cambian, pero los árboles dan umbrales «raros» como 2,14 en lugar de 3.
- **Muchos casos repetidos en el original**: 234 de las 683 muestras son idénticas a otra. El ruido lo disimula en esta versión, pero conviene saberlo al interpretar la validación cruzada.
- **Variables muy correlacionadas**: uniformidad del tamaño y de la forma van casi juntas. No afecta al acierto, pero sí a la interpretación de los coeficientes de la regresión logística.
- **Fácil**: el techo está en torno al 97 %. Sirve para aprender, no para distinguir buenos y malos modelos.

6 Flujo de trabajo en Orange



1. **Datasets** → «Breast Cancer Wisconsin» (o **File** con el CSV).
2. **Scatter Plot** con *Find Informative Projections*: dos variables bastan para separar casi todo.
3. **Test and Score** con kNN, árbol y regresión logística → **ROC Analysis**.
4. (Opcional) **Feature Constructor** con `ceil()` para volver a los valores enteros y repetir.

7 Otras consideraciones

- **Comparar con WDBC**: las dos versiones de Wisconsin tienen techos parecidos (≈ 97 %). WDBC mide los núcleos con un programa; esta, a ojo del patólogo. Es un buen tema de discusión.
- **Selección de atributos**: con *Rank*, quédate con las tres mejores variables y comprueba cuánto acierto se pierde (casi nada).

- **Coste de los errores**: un maligno clasificado como benigno es mucho peor que lo contrario. Mira cuántos hay en la matriz de confusión y mueve el umbral para reducirlos.

En la carpeta `breast_cancer_wisconsin` ← `breast-cancer-wisconsin.tab` (datasets.biolab.si)

2.05
Clasificación: salud y medicina

Breast Cancer Wisconsin Diagnostic (WDBC)

`02_clasificacion_salud/breast_cancer_wdbc/`

569 tumores de mama descritos por 30 medidas de los núcleos celulares en imágenes de punción, para distinguir benignos de malignos.

Clasificación binaria

> **En el curso:** Tema 7 (explicabilidad): propuesto en las diapositivas como dataset de cáncer de mama para explicar modelos.

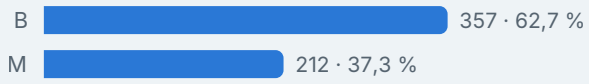
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
569	**32**	`diagnosis`	**0,0 %**	**Intermedio**	**Explain**

Fichero	Filas × col.	Descargar
`breast_cancer_wdbc`	569 × 32	CSV 125 KB · XLSX

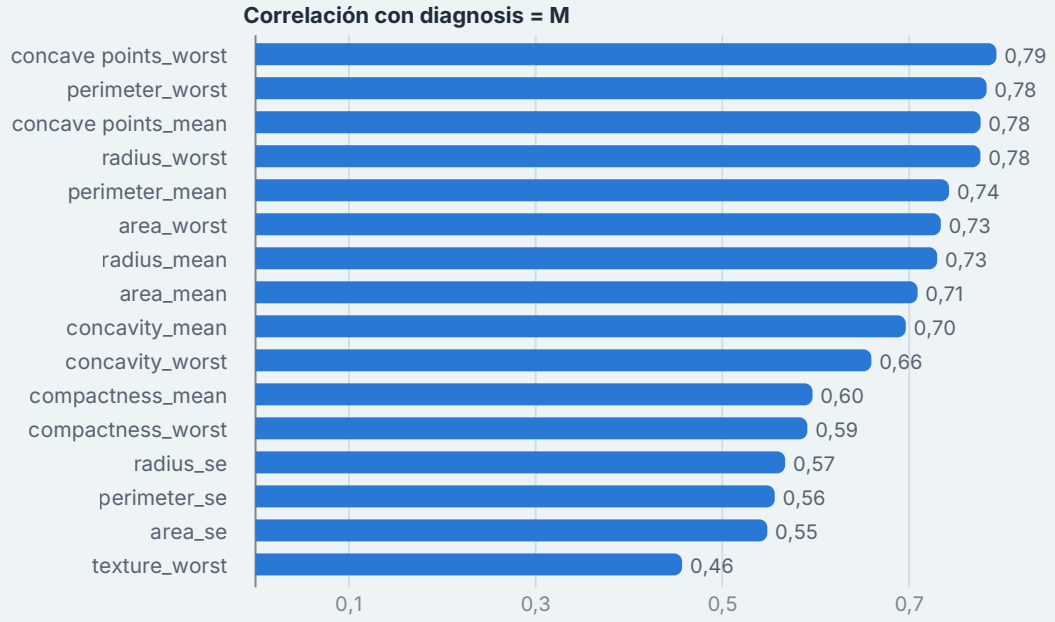
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/02_clasificacion_salud/breast_cancer_wdbc/` seguido del nombre del fichero CSV.

Radiografía

diagnosis en breast_cancer_wdbc



Las 16 medidas más relacionadas con la malignidad



1 Descripción general y estudios habituales

Cada fila es una masa mamaria a la que se hizo una punción con aguja fina (PAAF). La muestra se digitalizó al microscopio y un programa trazó el contorno de los núcleos celulares; de esos contornos salen **10 medidas** (radio, textura, perímetro, área, suavidad, compacidad, concavidad, puntos cóncavos, simetría y dimensión fractal). Para cada medida hay tres columnas: la **media** de todos los núcleos de la imagen, su **error estándar** y el **peor valor** (la media de los tres núcleos más extremos). En total, 30 atributos numéricos más el identificador y el diagnóstico.

Es el dataset médico más usado para clasificación binaria con muchos atributos numéricos. Los estudios habituales son:

- **Diagnosticar** (clasificación binaria) maligno frente a benigno; los buenos modelos pasan del 95 % de acierto.
- **Seleccionar atributos**: con 30 columnas muy redundantes, encontrar las pocas que bastan.
- **Reducir dimensión** con PCA y ver que dos componentes separan casi del todo las clases.
- **Explicar** las predicciones de un modelo: qué medidas hacen que un tumor parezca maligno.

2 Contexto y fuente original

Los datos los crearon William H. Wolberg (médico, Universidad de Wisconsin), W. Nick Street y Olvi L. Mangasarian (informática) a principios de los años noventa, y están en el repositorio UCI desde 1995 como *Breast Cancer Wisconsin (Diagnostic)*, abreviado **WDBC**. Las medidas se calcularon con el programa Xcyt a partir de las imágenes digitalizadas de cada punción; el método se describe en Street, Wolberg y Mangasarian (1993).

Este fichero es la copia de Kaggle que estaba en el repositorio del curso (`kaggle-breast-cancer.csv`), con los mismos 569 casos y las mismas columnas que la versión de UCI.

No hay que confundirlo con otros dos datasets de cáncer de mama de este libro: *Breast Cancer Wisconsin (original)* (683 casos y 9 atributos puntuados de 1 a 10 por un patólogo) y *Breast Cancer* de Ljubljana (286 casos, recidiva tras la operación).

- Breast Cancer Wisconsin (Diagnostic) en el repositorio UCI (Wolberg, Mangasarian, Street y Street, 1995)
- Street, W. N., Wolberg, W. H. y Mangasarian, O. L. (1993). Nuclear feature extraction for breast tumor diagnosis. Proc. SPIE 1905, 861–870.

3 Variable objetivo

La variable objetivo es `diagnosis`: `B` (benigno, 357 casos, 62,7 %) o `M` (maligno, 212 casos, 37,3 %). Decir siempre «benigno» acierta el 62,7 %, que es la referencia mínima.

En diagnóstico importa más no dejar escapar un maligno (falso negativo) que dar una falsa alarma: además de la exactitud, mira la **sensibilidad** (*recall*) de la clase `M`.

Las medidas más relacionadas con la malignidad son las de tamaño y forma irregular: el peor valor de puntos cóncavos (correlación 0,79 con el diagnóstico), el perímetro y el radio peores (0,78) y la media de puntos cóncavos (0,78). La textura del error estándar o la dimensión fractal media apenas aportan.

4 Diccionario de columnas

Columnas de `breast_cancer_wdbc` (valores observados en el fichero)

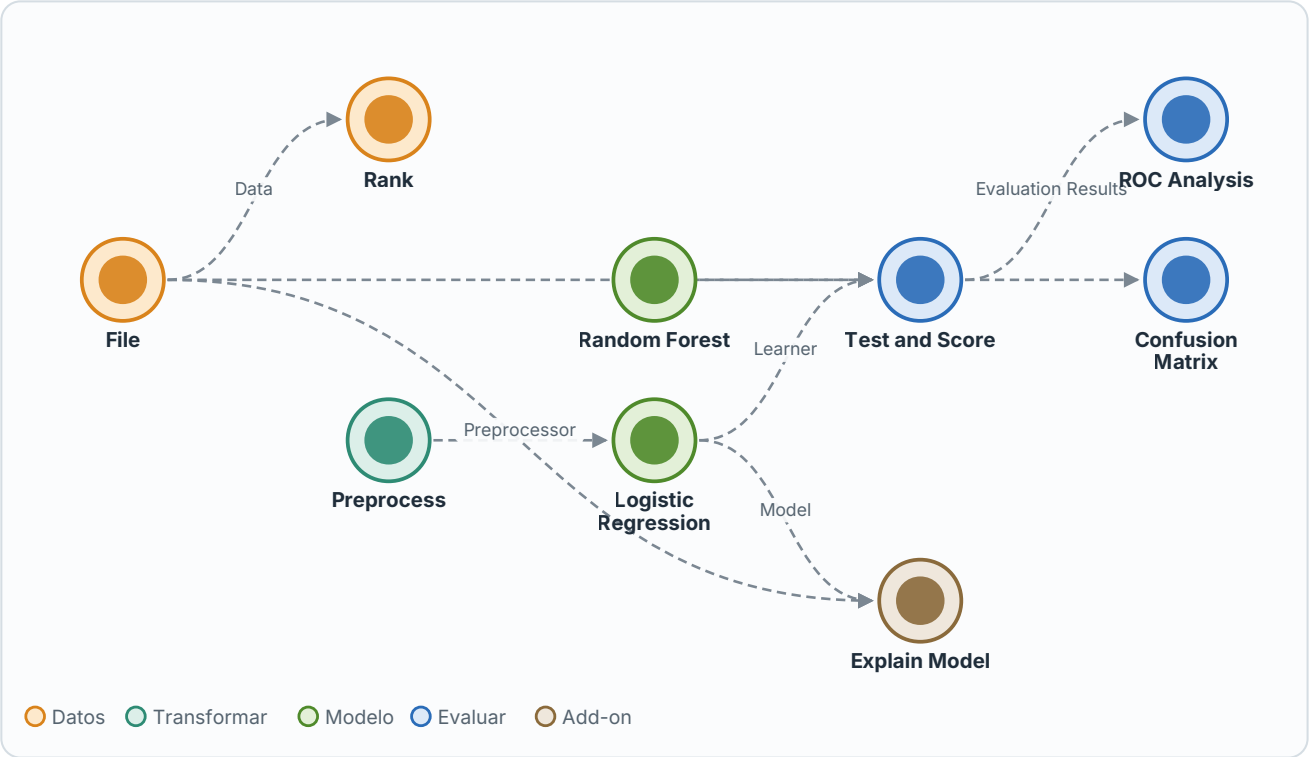
Columna	Tipo	Significado	Valores
`id`	numérica	Número de identificación de la muestra. No es un atributo: márcalo como *meta*.	8.670 – 911.320.502
`diagnosis` objetivo	categórica	Diagnóstico: `M` = maligno, `B` = benigno. Es la variable objetivo.	B (357), M (212)
`radius_mean`	numérica	Radio medio de los núcleos: distancia media del centro al contorno (en píxeles de la imagen).	6,981 – 28,11
`texture_mean`	numérica	Textura: desviación típica de los niveles de gris dentro del núcleo.	9,71 – 39,28
`perimeter_mean`	numérica	Perímetro medio del núcleo.	43,79 – 188,5
`area_mean`	numérica	Área media del núcleo.	143,5 – 2.501
`smoothness_mean`	numérica	Suavidad: variación local de la longitud de los radios.	0,053 – 0,163
`compactness_mean`	numérica	Compacidad: perímetro² / área − 1.	0,019 – 0,345
`concavity_mean`	numérica	Concavidad: profundidad de las partes cóncavas del contorno.	0 – 0,427
`concave points_mean`	numérica	Puntos cóncavos: número de partes cóncavas del contorno.	0 – 0,201
`symmetry_mean`	numérica	Simetría del núcleo.	0,106 – 0,304
`fractal_dimension_mean`	numérica	Dimensión fractal del contorno («aproximación de la línea de costa» − 1).	0,05 – 0,097
`radius_se`	numérica	Error estándar del radio entre los núcleos de la imagen. Igual para las demás columnas `_se`.	0,112 – 2,873
`texture_se`	numérica	Error estándar de la textura.	0,36 – 4,885
`perimeter_se`	numérica	Error estándar del perímetro.	0,757 – 21,98
`area_se`	numérica	Error estándar del área.	6,802 – 542,2
`smoothness_se`	numérica	Error estándar de la suavidad.	0,002 – 0,031
`compactness_se`	numérica	Error estándar de la compacidad.	0,002 – 0,135
`concavity_se`	numérica	Error estándar de la concavidad.	0 – 0,396
`concave points_se`	numérica	Error estándar de los puntos cóncavos.	0 – 0,053
`symmetry_se`	numérica	Error estándar de la simetría.	0,008 – 0,079
`fractal_dimension_se`	numérica	Error estándar de la dimensión fractal.	0,001 – 0,03
`radius_worst`	numérica	Peor radio: media de los tres núcleos con el valor más alto. Igual para las demás columnas `_worst`.	7,93 – 36,04

Columna	Tipo	Significado	Valores
`texture_worst`	numérica	Peor textura.	12,02 – 49,54
`perimeter_worst`	numérica	Peor perímetro.	50,41 – 251,2
`area_worst`	numérica	Peor área.	185,2 – 4.254
`smoothness_worst`	numérica	Peor suavidad.	0,071 – 0,223
`compactness_worst`	numérica	Peor compacidad.	0,027 – 1,058
`concavity_worst`	numérica	Peor concavidad.	0 – 1,252
`concave points_worst`	numérica	Peor número de puntos cóncavos.	0 – 0,291
`symmetry_worst`	numérica	Peor simetría.	0,157 – 0,664
`fractal_dimension_worst`	numérica	Peor dimensión fractal.	0,055 – 0,207

5 Particularidades técnicas al modelar

- **Redundancia extrema**: radio, perímetro y área miden casi lo mismo (correlación de 0,987 a 0,998 entre sus medias), y cada medida aparece tres veces (media, error estándar, peor valor). Un modelo lineal con las 30 columnas tiene coeficientes inestables y difíciles de interpretar: selecciona atributos (*Rank*) o usa regularización.
- **Escalas muy distintas**: el área llega a 2.501 y la suavidad no pasa de 0,16. kNN, SVM, regresión logística y redes necesitan normalizar (*Preprocess* → *Normalize features*).
- **Al abrir el CSV en Orange**, `id` aparece como un atributo numérico más y `diagnosis` no viene como *target*. En *File* pon `id` como *meta* y `diagnosis` como *target*; si no, el modelo usará el número de muestra para predecir.
- **Coste asimétrico**: un falso negativo (maligno clasificado como benigno) es mucho más grave. Ajusta el umbral de decisión mirando la curva ROC o el widget *Calibration Plot*, en vez de quedarte con el 0,5 por defecto.
- No hay valores faltantes ni filas repetidas.

6 Flujo de trabajo en Orange



1. **File**: abre `breast_cancer_wdbc.csv`; `id` como *meta* y `diagnosis` como *target*.
2. **Rank**: ordena los 30 atributos por ganancia de información o ReliefF; las medidas de concavidad y tamaño encabezan la lista.
3. **Preprocess** (*Normalize features*) conectado a **Logistic Regression**; **Random Forest** no lo necesita.
4. **Test and Score**: validación cruzada estratificada de 10 particiones; mira AUC y la sensibilidad de la clase `M`.
5. **ROC Analysis** y **Confusion Matrix**: elige el umbral que reduce los falsos negativos.
6. **Explain Model** (add-on *Explain*): qué medidas pesan más en el modelo y en qué dirección.

7 Otras consideraciones

- **Para explicabilidad**, este dataset funciona mejor que Iris porque las 30 medidas compiten entre sí: se ve cómo la importancia se reparte entre atributos redundantes y cómo cambia al quitar algunos.
- **Prueba a quedarte con pocas columnas**: con tres medidas «peores» (puntos cóncavos, perímetro y textura) los modelos pierden muy poco frente a las 30.
- **PCA** (widget *PCA* → *Scatter Plot*): con dos componentes las dos clases quedan casi separadas, una buena demostración visual de reducción de dimensión.
- Las muestras son de una sola institución y de hace más de treinta años: un modelo entrenado aquí sirve para aprender, no es un modelo clínico.

En la carpeta `breast_cancer_wdbc` ← `kaggle-breast-cancer.csv` (curso_ciencia_datos (GitHub))

2.06
Clasificación: salud y medicina

Prostate Cancer (Kaggle)

`02_clasificacion_salud/prostate_cancer/`

100 casos etiquetados como cáncer de próstata maligno o benigno con 8 medidas de células, de origen no documentado: en realidad, una copia alterada de datos de cáncer de mama.

Clasificación binaria

> **En el curso:** Tema 7 (explicabilidad): propuesto en las diapositivas como dataset de cáncer de próstata para explicar modelos.

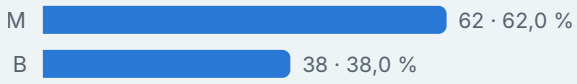
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
100	**10**	`diagnosis_result`	**0,0 %**	**Iniciación**	**Explain**

Fichero	Filas × col.	Descargar
`prostate_cancer`	100 × 10	CSV 4 KB · XLSX

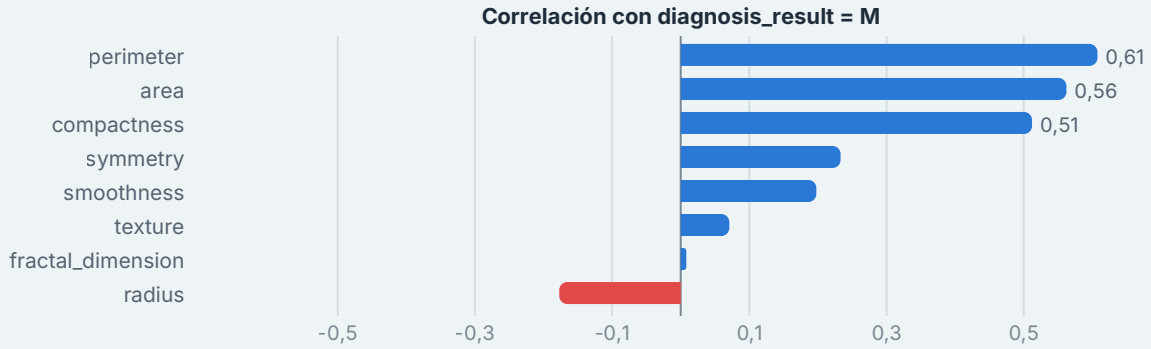
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/02_clasificacion_salud/prostate_cancer/` seguido del nombre del fichero CSV.

Radiografía

diagnosis_result en prostate_cancer



Relación de cada medida con el diagnóstico maligno



1 Descripción general y estudios habituales

Cada fila es un caso con un diagnóstico (`M`, maligno, o `B`, benigno) y ocho medidas que, por sus nombres, describen la forma y textura de células: radio, textura, perímetro, área, suavidad, compacidad, simetría y dimensión fractal.

Es pequeño y fácil de manejar, y por eso se usa en tutoriales de introducción a la clasificación binaria y a la explicación de modelos. Los estudios habituales son:

- **Clasificar** maligno frente a benigno con kNN, regresión logística o árboles.
- **Explicar** qué medidas pesan en la predicción (importancia de atributos, nomograma, SHAP).
- **Comprobar la calidad de un dataset**: es un buen ejemplo de por qué hay que mirar los datos antes de fiarse de su nombre (ver la sección 2).

2 Contexto y fuente original

El dataset está en Kaggle como *Prostate Cancer* (fichero `Prostate_Cancer.csv`), subido por el usuario **sajid saifi**, con una descripción de una línea («dataset of 100 patients to implement the machine learning algorithm»). **No indica de dónde salen los datos.**

Al compararlo con *Breast Cancer Wisconsin (Diagnostic)* (ficha 2.05) se ve su origen: **son las 100 primeras filas de ese dataset de cáncer de mama, modificadas**. En las 100 filas coinciden exactamente la compacidad, la simetría y la dimensión fractal medias; el perímetro coincide redondeado en 99; la suavidad, en 95; y el diagnóstico, en 97. En cambio, el radio y la textura se han sustituido por números enteros (de 9 a 25 y de 11 a 27) que no guardan relación con el resto. Es una comprobación propia hecha para este libro; no está documentada en la página de Kaggle.

Conclusión: sirve para practicar la técnica, pero **no son datos de próstata** y no se puede sacar de él ninguna conclusión médica.

- Prostate Cancer en Kaggle (sajid saifi)
- Breast Cancer Wisconsin (Diagnostic) en UCI, del que proceden las filas

3 Variable objetivo

La variable objetivo es `diagnosis_result`: `M` (maligno, 62 casos) o `B` (benigno, 38). Decir siempre «maligno» acierta el 62 %.

Las medidas más relacionadas con el diagnóstico son el perímetro (correlación 0,61 con «maligno»), el área (0,56) y la compacidad (0,51). El radio tiene una correlación ligeramente **negativa** (−0,18), algo imposible si midiera el mismo contorno que el perímetro y el área: es la huella de que esa columna se ha alterado.

4 Diccionario de columnas

Columnas de `prostate_cancer` (valores observados en el fichero)

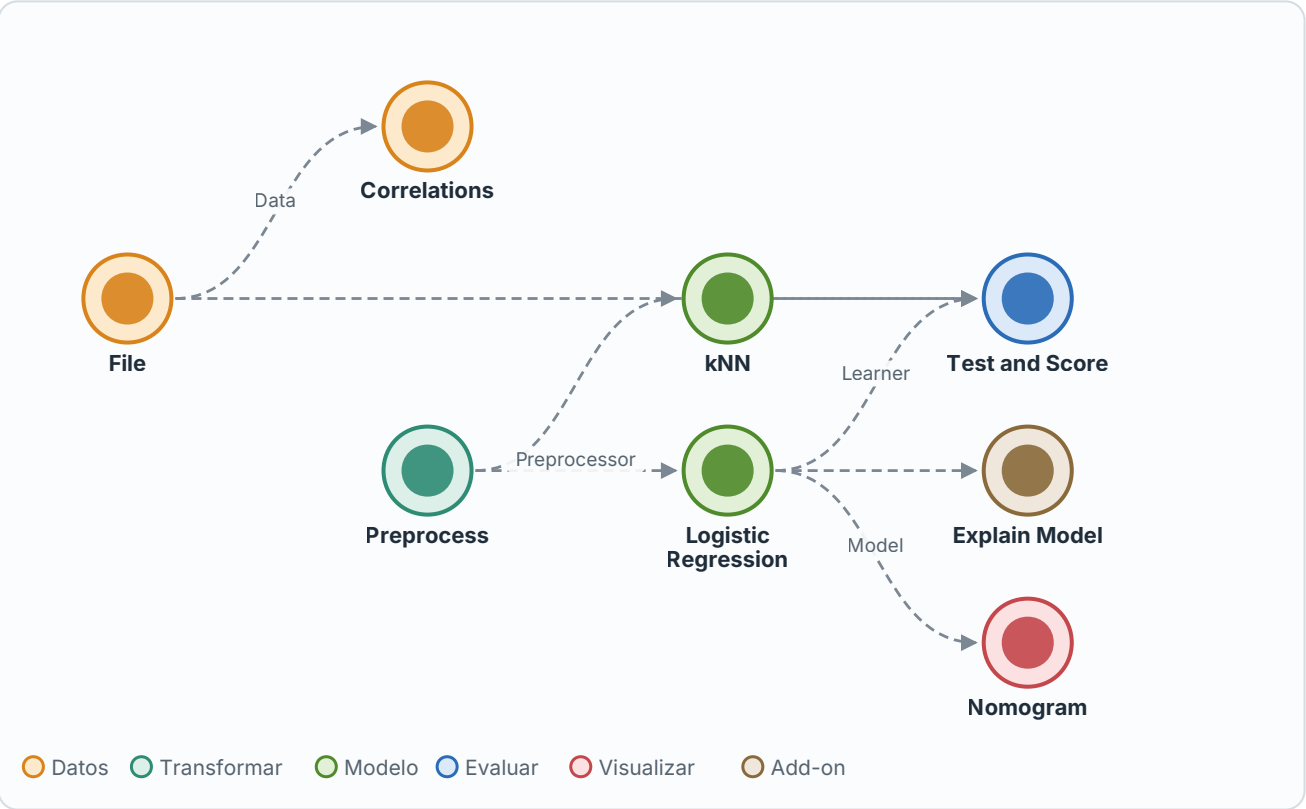
Columna	Tipo	Significado	Valores
`id`	numérica	Número de caso, de 1 a 100. No es un atributo: márcalo como *meta*.	1 – 100
`diagnosis_result` objetivo	categórica	Diagnóstico: `M` = maligno, `B` = benigno. Es la variable objetivo.	M (62), B (38)
`radius`	numérica	Radio. En este fichero son enteros de 9 a 25 sin relación con el perímetro ni el área: columna alterada.	9 – 25
`texture`	numérica	Textura. Enteros de 11 a 27, también alterada respecto al dataset de origen.	11 – 27

Columna	Tipo	Significado	Valores
`perimeter`	numérica	Perímetro medio del núcleo celular (coincide, redondeado, con `perimeter_mean` del dataset de mama).	52 – 172
`area`	numérica	Área media del núcleo celular.	202 – 1.878
`smoothness`	numérica	Suavidad: variación local de la longitud de los radios.	0,07 – 0,143
`compactness`	numérica	Compacidad: perímetro² / área − 1.	0,038 – 0,345
`symmetry`	numérica	Simetría del núcleo.	0,135 – 0,304
`fractal_dimension`	numérica	Dimensión fractal del contorno.	0,053 – 0,097

5 Particularidades técnicas al modelar

- **Muy pocos casos** (100): una partición de prueba del 20 % son 20 casos, y cada error vale 5 puntos. Usa validación cruzada (10 particiones) o *leave-one-out*.
- **Al abrir el CSV en Orange**, `id` aparece como atributo numérico y `diagnosis_result` no es *target*. En *File*: `id` como *meta* y `diagnosis_result` como *target*. Si `id` entra en el modelo, puede «aprender» que los primeros casos son malignos.
- **Columnas alteradas**: `radius` y `texture` no aportan información real. Un buen ejercicio es detectarlo uno mismo con *Correlations* (el radio debería estar casi perfectamente correlacionado con el perímetro y el área, como en el dataset de mama) antes de leer esta ficha.
- **Escalas distintas**: el área llega a 1.878 y la dimensión fractal no pasa de 0,1. Normaliza para kNN, SVM o regresión logística.
- No hay valores faltantes.

6 Flujo de trabajo en Orange



1. **File**: `id` como *meta* y `diagnosis_result` como *target*.
2. **Correlations**: comprueba que `radius` no se correlaciona con `perimeter` ni con `area`. Es la pista de que el dataset está manipulado.
3. **Preprocess** (*Normalize features*) conectado a **Logistic Regression** y **kNN**.
4. **Test and Score** con validación cruzada de 10 particiones.
5. **Nomogram** y **Explain Model** (add-on *Explain*): qué medidas empujan hacia «maligno». Conecta también los datos a *Explain Model*.
6. Repite el flujo **sin** `radius` **ni** `texture` (en *File*, rol *skip*) y compara: el resultado apenas cambia.

7 Otras consideraciones

- **Para explicabilidad, compáralo con la ficha 2.05**: el mismo flujo sobre el dataset de mama completo (569 casos y 30 medidas) da explicaciones más estables y con más sentido.
- **Una lección sobre fuentes**: un dataset con un nombre médico y miles de descargas puede no ser lo que dice. Antes de usar datos de Kaggle conviene buscar su origen y comprobar que las columnas se comportan como deberían.
- Es la copia que estaba en el repositorio del curso (`kaggle-Prostate_Cancer.csv`).

En la carpeta `prostate_cancer` ← `kaggle-Prostate_Cancer.csv` (curso_ciencia_datos (GitHub))

2.07
Clasificación: salud y medicina

Cervical Cancer Risk Factors (cáncer de útero)

`02_clasificacion_salud/cancer_utero/`

858 pacientes de un hospital de Caracas con datos demográficos, hábitos e historial médico, y el resultado de cuatro pruebas de cribado del cáncer de cuello de útero: cuatro variables objetivo, muy desequilibradas y con muchos huecos.

Clasificación binaria · ? Valores faltantes · ◈ Mixto num. + cat. · ⊕ Multiobjetivo

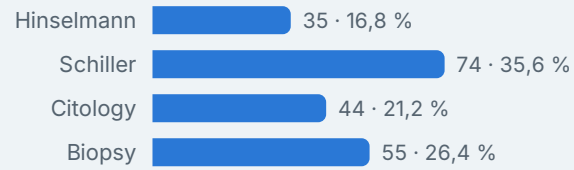
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
858	**36**	`Biopsy (y otras tres)`	**11,7 %**	**Avanzado**	**Ninguno**

Fichero	Filas × col.	Descargar
`cancer_utero`	858 × 36	CSV 86 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/02_clasificacion_salud/cancer_utero/` seguido del nombre del fichero CSV.

Radiografía

Resultados positivos en cada prueba



1 Descripción general y estudios habituales

Cada fila es una paciente atendida en el Hospital Universitario de Caracas (Venezuela). Hay 32 variables sobre su edad, historia reproductiva y sexual, tabaco, anticonceptivos hormonales, DIU, infecciones de transmisión sexual y diagnósticos previos. Y hay **cuatro variables objetivo**, el resultado de cuatro pruebas de cribado: colposcopia con ácido acético (Hinselmann), prueba de Schiller (yodo), citología y biopsia.

Los estudios habituales son:

- **Predecir el resultado de la biopsia**, la prueba de referencia, a partir de los factores de riesgo.
- **Clasificación muy desequilibrada**: solo un 6 % de biopsias positivas.
- **Tratamiento de valores ausentes** cuando las pacientes no quisieron responder.
- **Varias variables objetivo**: cómo se relacionan las cuatro pruebas entre sí.

2 Contexto y fuente original

Los datos los publicaron **Kelwin Fernandes, Jaime S. Cardoso y Jessica Fernandes** (Universidad de Oporto) en 2017, en un trabajo sobre cribado del cáncer de cuello de útero con observación parcial: muchas pacientes no responden a ciertas preguntas por motivos de privacidad. Está en el repositorio UCI como *Cervical Cancer (Risk Factors)*.

En el repositorio del curso se llama `cancer_utero` (en CSV y ARFF). Aunque el nombre dice «útero», se trata del **cuello del útero** (cérvix), no del cuerpo del útero.

- Fernandes, K., Cardoso, J. S. y Fernandes, J. (2017). Transfer learning with partial observability applied to cervical cancer screening. Iberian Conference on Pattern Recognition and Image Analysis (IbPRIA), 243–250.
- Cervical Cancer (Risk Factors) en el repositorio UCI

3 Variable objetivo

Hay **cuatro variables objetivo**, todas binarias (1 = resultado positivo) y muy desequilibradas:

- `Hinselmann`: 35 positivas (4 %).
- `Schiller`: 74 (9 %).
- `Citology`: 44 (5 %).
- `Biopsy`: 55 (6 %). Es la prueba de referencia y la que se suele predecir.

Las pruebas se parecen entre sí: la de Schiller coincide con la biopsia en la mayoría de casos (48 de los 55 positivos de biopsia tienen también Schiller positivo). Pero si se predice la biopsia **solo con los factores de riesgo**, ningún modelo supera claramente el 93,6 % de decir siempre «negativo».

4 Diccionario de columnas

Columnas de `cancer_utero` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
Age	numérica	Edad (años).	13 – 84
`Number of sexual partners`	numérica	Número de parejas sexuales. 26 huecos.	1 – 28
`First sexual intercourse`	numérica	Edad de la primera relación sexual. 7 huecos.	10 – 32
`Num of pregnancies`	numérica	Número de embarazos. 56 huecos.	0 – 11
`Smokes`	categórica	Fuma (1/0). 13 huecos.	0.0 (722), 1.0 (123)
`Smokes (years)`	numérica	Años fumando.	0 – 37
`Smokes (packs/year)`	numérica	Paquetes-año.	0 – 37
`Hormonal Contraceptives`	categórica	Usa anticonceptivos hormonales (1/0). 108 huecos.	1.0 (481), 0.0 (269)
`Hormonal Contraceptives (years)`	numérica	Años usándolos.	0 – 30

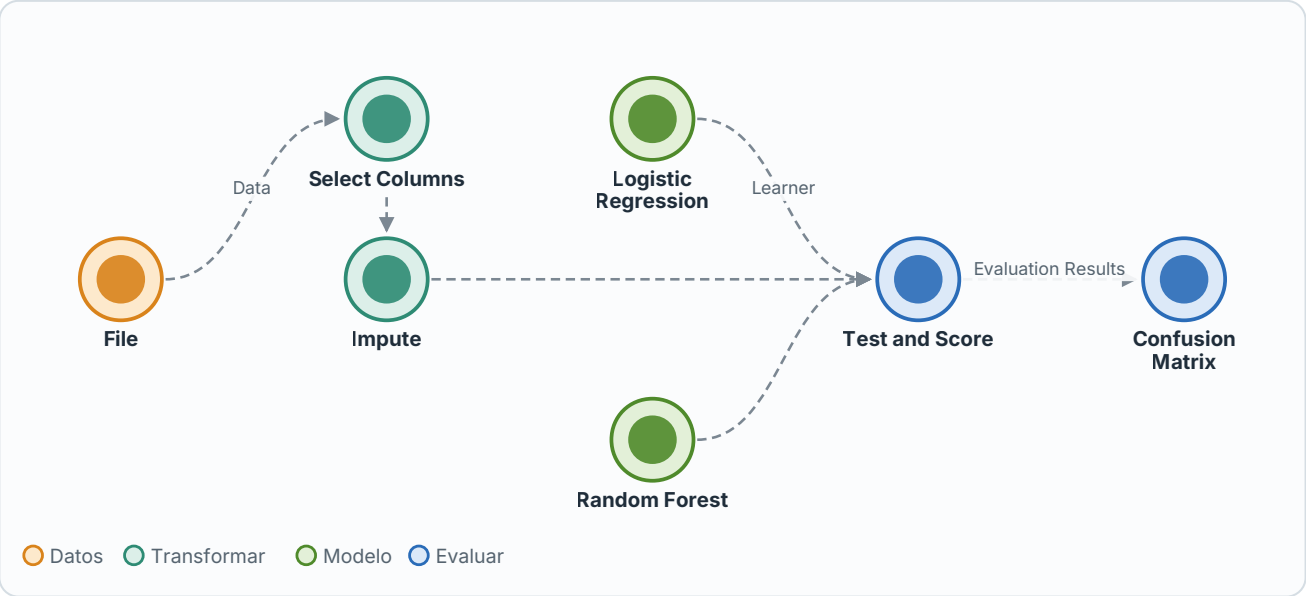
Columna	Tipo	Significado	Valores
`IUD`	categórica	Lleva o llevó DIU (1/0). 117 huecos.	0.0 (658), 1.0 (83)
`IUD (years)`	numérica	Años con DIU.	0 – 19
`STDs`	categórica	Ha tenido alguna infección de transmisión sexual (1/0). 105 huecos, los mismos en todas las columnas `STDs`.	0.0 (674), 1.0 (79)
`STDs (number)`	numérica	Número de infecciones de transmisión sexual.	0 – 4
`STDs:condylomatosis`	categórica	Ha tenido condilomatosis (1/0). Igual para las demás columnas `STDs:` (sífilis, herpes, VIH, VPH…).	0.0 (709), 1.0 (44)
`STDs: Number of diagnosis`	numérica	Número de diagnósticos de infecciones de transmisión sexual.	0 – 3
`STDs: Time since first diagnosis`	numérica	Años desde el primer diagnóstico. Vacío en 787 pacientes (las que no han tenido ninguno).	1 – 22
`STDs: Time since last diagnosis`	numérica	Años desde el último diagnóstico. Igual que la anterior.	1 – 22
`Dx:Cancer`	categórica	Diagnóstico previo de cáncer (1/0).	0 (840), 1 (18)
`Dx:CIN`	categórica	Diagnóstico previo de neoplasia intraepitelial cervical (1/0).	0 (849), 1 (9)
`Dx:HPV`	categórica	Diagnóstico previo de virus del papiloma humano (1/0).	0 (840), 1 (18)
`Dx`	categórica	Algún diagnóstico previo (1/0).	0 (834), 1 (24)
`Hinselmann` `objetivo`	categórica	**Objetivo**: colposcopia con ácido acético positiva (1/0).	0 (823), 1 (35)
`Schiller` `objetivo`	categórica	**Objetivo**: prueba de Schiller (yodo) positiva (1/0).	0 (784), 1 (74)
`Citology` `objetivo`	categórica	**Objetivo**: citología positiva (1/0).	0 (814), 1 (44)
`Biopsy` `objetivo`	categórica	**Objetivo**: biopsia positiva (1/0). Es la prueba de referencia.	0 (803), 1 (55)
…		y 11 columnas más del mismo tipo que la anterior.	

5 Particularidades técnicas al modelar

- **Cuatro objetivos a la vez**: Orange marca las cuatro como *target* y muchos modelos no aceptan varias clases. Antes de modelar, deja una como *target* (normalmente `Biopsy`) y pasa las otras tres a *meta* o quítalas con *Select Columns*. **Si se dejan como atributos, son fuga de información**: Schiller casi predice la biopsia, pero no es un factor de riesgo, es otra prueba.

- **Huecos por no responder**: 105 pacientes tienen vacíos todos los datos de infecciones de transmisión sexual, y unas 110 los de anticonceptivos y DIU. No faltan al azar: son pacientes que prefirieron no contestar. Imputar con la media borra esa información; se puede añadir una columna «no respondió».
- **Huecos que son ceros**: las dos columnas de tiempo desde el diagnóstico están vacías en las 787 pacientes que nunca han tenido una infección. No son datos que falten, sino que no se aplican.
- **Columnas sin información**: `STDs:cervical condylomatosis` y `STDs:AIDS` valen siempre 0. Quítalas.
- **Desequilibrio extremo**: con un 6 % de biopsias positivas, el acierto no sirve. Usa sensibilidad, precisión, F1 o AUC, y prueba a reponderar o submuestrear.
- **Datos sensibles**: historia sexual y reproductiva de pacientes reales. Úsalos con respeto y sin intentar identificar a nadie.

6 Flujo de trabajo en Orange



1. **File** con `cancer_utero`: deja `Biopsy` como *target* y pasa `Hinselmann`, `Schiller` y `Citology` a *meta*.
2. **Select Columns**: quita las dos columnas constantes.
3. **Impute**: compara la media con «tratar como valor distinto» para las preguntas sin respuesta.
4. **Test and Score** con regresión logística (con *Balance class distribution*) y bosque aleatorio; ordena por sensibilidad o F1, no por acierto.
5. **Confusion Matrix**: cuántas biopsias positivas detecta cada modelo.

7 Otras consideraciones

- **Las pruebas entre sí**: usando Hinselmann, Schiller y citología como atributos para predecir la biopsia, el acierto sube mucho. Es un buen ejercicio para explicar qué es una fuga de información y cuándo no lo es (si las tres pruebas se hacen antes que la biopsia, usarlas es legítimo).
- **Una sola clase compuesta**: algunos trabajos definen «positiva» si cualquiera de las cuatro pruebas lo es (102 pacientes). Con *Feature Constructor* se puede crear esa clase.
- Para un cribado médico, lo importante es no dejar escapar positivos: compara modelos fijando una sensibilidad mínima.

En la carpeta	`cancer_utero` ← `cancer_utero.csv` (curso_ciencia_datos (GitHub))
Duplicado, no se copia	`cancer_utero.arff` (curso_ciencia_datos (GitHub))

2.08
Clasificación: salud y medicina

Stroke Prediction (ictus)

`02_clasificacion_salud/stroke/`

5.110 pacientes con datos demográficos y de salud básicos, para predecir quién ha sufrido un ictus: solo el 4,9 % lo tuvo.

Clasificación binaria · ⚖ Desbalanceado · ? Valores faltantes · ◈ Mixto num. + cat.

> **En el curso:** Actividad 2.1b (Tema 2, desbalanceo: submuestreo y umbral con Calibration Plot) y Tema 3 (ensembles: Random Forest, Gradient Boosting, AdaBoost y stacking).

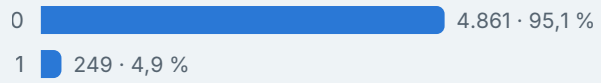
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
5.110	**12**	`stroke`	**0,3 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`stroke`	5.110 × 12	CSV 316 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/02_clasificacion_salud/stroke/` seguido del nombre del fichero CSV.

Radiografía

stroke en stroke



Porcentaje de pacientes con ictus por grupo



1 Descripción general y estudios habituales

Cada fila es un paciente, con su sexo, edad, si tiene hipertensión o una cardiopatía, si se ha casado alguna vez, su tipo de trabajo y de residencia, su nivel medio de glucosa, su índice de masa corporal (IMC) y si fuma. La variable objetivo indica si ha sufrido un ictus (accidente cerebrovascular).

Es el dataset de referencia para practicar **clasificación desbalanceada** con datos reales y mezclados (numéricos y categóricos, con algún faltante). Los estudios habituales son:

- **Detectar a los pacientes con ictus** (clasificación binaria) y comprobar que la exactitud engaña con clases tan desiguales.
- **Corregir el desbalanceo**: submuestreo, sobremuestreo, ponderación de clases o cambio del umbral de decisión.
- **Comparar ensembles** (Random Forest, Gradient Boosting, AdaBoost) con modelos sencillos usando métricas adecuadas (MCC, F1, sensibilidad, AUC).
- **Analizar factores de riesgo**: edad, hipertensión, cardiopatía y glucosa.

2 Contexto y fuente original

El dataset lo publicó en Kaggle el usuario **fedesoriano** con el nombre *Stroke Prediction Dataset*. La página indica que la fuente es **confidencial** («Confidential Source») y que los datos solo deben usarse con fines educativos: no se sabe de qué hospital o estudio proceden, ni cuándo se recogieron. Se ha usado muchísimo en cursos y en Kaggle, pero no hay una publicación científica que lo describa, así que sus conclusiones médicas deben tomarse con cautela.

Este fichero es la copia del repositorio del curso (`healthcare-dataset-stroke-data.csv`); Kaggle exige registrarse para descargarlo.

- Stroke Prediction Dataset en Kaggle (fedesoriano)

3 Variable objetivo

La variable objetivo es `stroke` : `1` si el paciente ha sufrido un ictus (249 pacientes, 4,9 %) y `0` si no (4.861, 95,1 %). Un modelo que diga siempre «no» acierta el 95,1 % y no sirve para nada: por eso aquí la exactitud (CA) no es una métrica útil. Mira la sensibilidad (*recall*) y la precisión de la clase `1` , el F1, el MCC y el AUC.

El riesgo crece claramente con la edad: el 0,2 % de los menores de 18 años, el 0,5 % entre 18 y 44, el 5,2 % entre 45 y 64 y el 15,5 % a partir de 65. También es mayor con hipertensión (13,3 % frente a 4,0 %) o cardiopatía (17,0 % frente a 4,2 %).

4 Diccionario de columnas

Columnas de `stroke` (valores observados en el fichero)

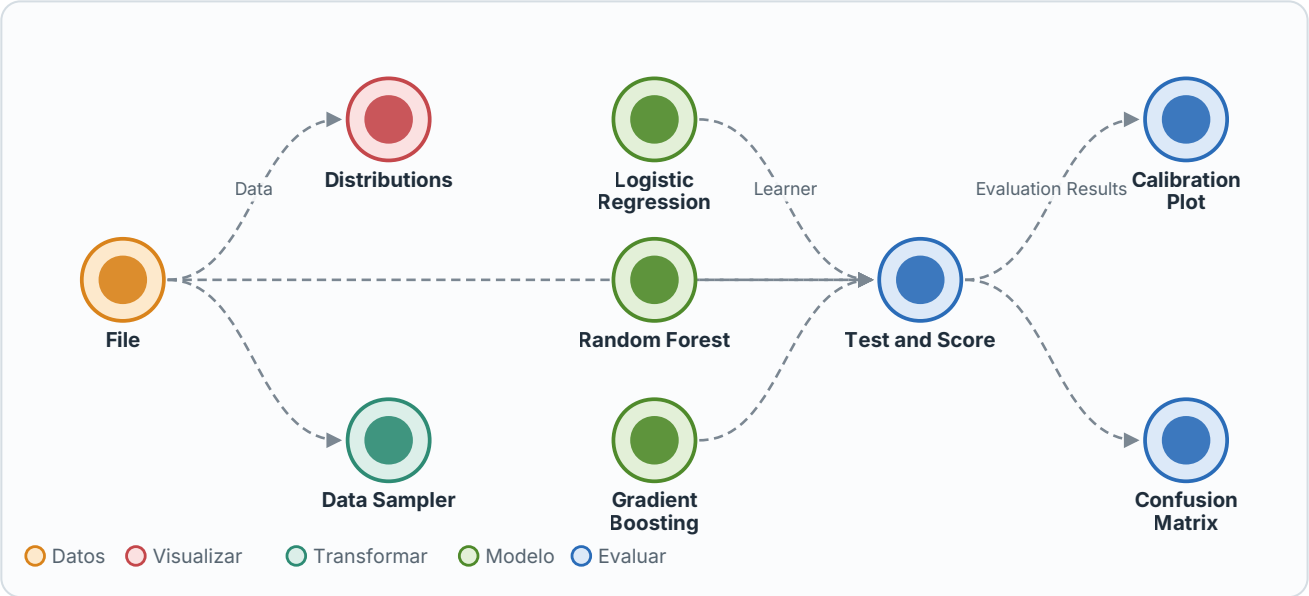
Columna	Tipo	Significado	Valores
`id`	numérica	Identificador del paciente. No es un atributo: márcalo como *meta*.	67 – 72.940
`gender`	categórica	Sexo: `Male` , `Female` u `Other` (un único caso).	Female (2.994), Male (2.115), Other (1)
`age`	numérica	Edad en años. En los menores de 2 años aparece con decimales (por ejemplo, 0,64).	0,08 – 82

Columna	Tipo	Significado	Valores
`hypertension`	categórica	1 si el paciente tiene hipertensión, 0 si no.	0 (4.612), 1 (498)
`heart_disease`	categórica	1 si tiene alguna enfermedad cardíaca, 0 si no.	0 (4.834), 1 (276)
`ever_married`	categórica	Si se ha casado alguna vez: `Yes` o `No`.	Yes (3.353), No (1.757)
`work_type`	categórica	Tipo de trabajo: `Private` (empresa privada), `Self-employed` (autónomo), `Govt_job` (sector público), `children` (menor de edad) o `Never_worked` (nunca ha trabajado).	Private (2.925), Self-employed (819), children (687), Govt_job (657), Never_worked (22)
`Residence_type`	categórica	Zona de residencia: `Urban` o `Rural`.	Urban (2.596), Rural (2.514)
`avg_glucose_level`	numérica	Nivel medio de glucosa en sangre. La fuente no indica la unidad; por el rango (55–272), probablemente mg/dL.	55,12 – 271,74
`bmi`	numérica	Índice de masa corporal (kg/m²). Falta en 201 pacientes.	10,3 – 97,6
`smoking_status`	categórica	Tabaquismo: `never smoked`, `formerly smoked` (exfumador), `smokes` o `Unknown` (la información no estaba disponible).	never smoked (1.892), Unknown (1.544), formerly smoked (885), smokes (789)
`stroke` `objetivo`	categórica	1 si ha sufrido un ictus, 0 si no. Es la variable objetivo.	0 (4.861), 1 (249)

5 Particularidades técnicas al modelar

- **Desbalanceo fuerte** (1 positivo por cada 19,5 negativos). Usa validación cruzada **estratificada** y compara con MCC, F1 o AUC. Para corregirlo en Orange: submuestrear la clase mayoritaria (*Data Sampler* o *Select Rows* + *Concatenate*), activar la ponderación de clases (*Balance class distribution*) en los modelos que la tienen, o mover el umbral de decisión con *Calibration Plot*.
- **Al abrir el CSV en Orange**: pon `id` como *meta* (si no, el modelo lo usa como atributo) y `stroke` como *target*. Orange lee `stroke`, `hypertension` y `heart_disease` como categóricas por tener solo los valores 0 y 1, lo que está bien.
- **Faltantes informativos**: `bmi` falta en el 16,1 % de los pacientes con ictus y solo en el 3,3 % de los demás. Si se imputa sin más, se borra esa señal; si un modelo aprende que «IMC desconocido» predice ictus, aprende algo del proceso de recogida, no de la medicina. Prueba a añadir una columna indicadora del faltante y compara.
- `smoking_status = Unknown` (30 % de los pacientes) es en la práctica otro faltante, y abunda en niños.
- **Variables que son la edad disfrazada**: `ever_married = Yes` (edad media 54) frente a `No` (22) y `work_type = children` reflejan sobre todo la edad. Un modelo puede apoyarse en ellas sin que tengan sentido causal.
- Hay un solo paciente con `gender = Other`: con validación cruzada, ese valor aparece en unos pliegues y no en otros.

6 Flujo de trabajo en Orange



1. **File**: abre `stroke.csv` (o pega la URL «raw» del fichero de GitHub en el campo *URL*); `id` como *meta*, `stroke` como *target*.
2. **Distributions** con `stroke`: comprueba el 95 / 5 antes de nada.
3. **Logistic Regression**, **Random Forest** (marca *Replicable training* para que todos obtengan lo mismo) y **Gradient Boosting** → **Test and Score** con validación cruzada estratificada; ordena por MCC y no por CA.
4. **Confusion Matrix**: cuenta cuántos de los 249 ictus detecta cada modelo.
5. **Calibration Plot**: mueve el umbral de decisión para ganar sensibilidad a costa de precisión.
6. **Data Sampler** (submuestreo de la clase `0` hasta igualar los 249 positivos) y repite la evaluación para comparar.

7 Otras consideraciones

- **Cuidado al submuestrear antes de validar**: si se equilibran las clases y después se hace validación cruzada, la prueba también queda equilibrada y las métricas salen optimistas. Lo correcto es equilibrar solo los datos de entrenamiento y evaluar con la proporción real (por ejemplo, con *Data Sampler* para separar una prueba aparte).
- **El mismo flujo sirve para IBM Attrition**: cambiar de dataset es cambiar solo el widget de entrada, y comparar ambos muestra cómo afecta el grado de desbalanceo (5 % frente a 16 %).
- **Para explicabilidad**, el add-on *Explain* muestra que la edad domina las predicciones con mucha diferencia.
- El origen confidencial impide saber si la muestra representa a alguna población concreta: sirve para aprender técnica, no para estimar riesgos reales de ictus.

En la carpeta `stroke` ← `healthcare-dataset-stroke-data.csv` (curso_ciencia_datos (GitHub))

2.09
Clasificación: salud y medicina

Dermatology

`02_clasificacion_salud/dermatology/`

366 pacientes con seis enfermedades de la piel que se parecen mucho (psoriasis, dermatitis seborreica, liquen plano…), descritos por 12 rasgos clínicos y 22 de la biopsia: clasificación multiclase con atributos ordinales.

Clasificación multiclase · ⚖ Desbalanceado · ? Valores faltantes · ◈ Mixto num. + cat.

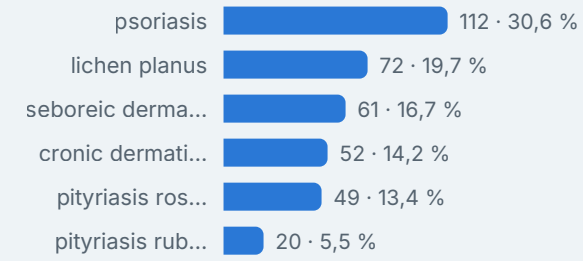
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
366	**35**	`type`	**0,1 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`dermatology`	366 × 35	CSV 32 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/02_clasificacion_salud/dermatology/` seguido del nombre del fichero CSV.

Radiografía

type en dermatology



1 Descripción general y estudios habituales

Las enfermedades eritemato-descamativas comparten los síntomas principales (enrojecimiento y descamación) y también muchos rasgos de la biopsia, así que distinguirlas es un problema real en dermatología. Cada fila es un paciente descrito por **12 rasgos clínicos** (observados en la consulta) y **22 histopatológicos** (observados al microscopio en la biopsia), puntuados de 0 (ausente) a 3 (máximo), más la edad y si hay antecedentes familiares.

La clase es la enfermedad diagnosticada, con seis valores. Los estudios habituales son:

- **Clasificación multiclase** con atributos ordinales.
- **Comparar qué aportan los rasgos clínicos y los de la biopsia**: ¿se puede diagnosticar sin biopsia?
- **Seleccionar atributos** y explicar el modelo.

2 Contexto y fuente original

Los datos son de **Nilsel İlter** (Facultad de Medicina de la Universidad Gazi, Ankara) y **H. Altay Güvenir** (Universidad Bilkent), que los usaron en 1998 para presentar un clasificador basado en intervalos de rasgos

(VFI5). El médico puntuó los 12 rasgos clínicos en la consulta; los 22 histopatológicos se valoraron después en la biopsia. Está en el repositorio UCI desde 1998.

- Güvenir, H. A., Demiröz, G. e İlter, N. (1998). Learning differential diagnosis of erythemato-squamous diseases using voting feature intervals. Artificial Intelligence in Medicine, 13(3), 147–165.
- Dermatology en el repositorio UCI

3 Variable objetivo

La clase es `type`: psoriasis (112), liquen plano (72), dermatitis seborreica (61), dermatitis crónica (52), pitiriasis rosada (49) y pitiriasis rubra pilaris (20).

Con los 34 rasgos el problema es bastante fácil: en una prueba con validación cruzada de 10 bolsas, la regresión logística, Naive Bayes y el bosque aleatorio aciertan un 97,5 % y el árbol un 95 %. La pitiriasis rubra pilaris se reconoce casi por la edad: sus pacientes tienen entre 7 y 22 años, frente a una media de 35–40 en las demás.

4 Diccionario de columnas

Columnas de `dermatology` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`erythema`	numérica	Eritema (enrojecimiento), de 0 a 3. **Rasgo clínico**.	0 – 3
`scaling`	numérica	Descamación, 0–3. Clínico.	0 – 3
`definite borders`	numérica	Bordes definidos, 0–3. Clínico.	0 – 3
`itching`	numérica	Picor, 0–3. Clínico.	0 – 3
`koebner phenomenon`	numérica	Fenómeno de Koebner (lesiones en zonas de roce o herida), 0–3. Clínico.	0 – 3
`polygonal papules`	numérica	Pápulas poligonales, 0–3. Clínico.	0 – 3
`follicular papules`	numérica	Pápulas foliculares, 0–3. Clínico.	0 – 3
`oral mucosal involvement`	numérica	Afectación de la mucosa oral, 0–3. Clínico.	0 – 3
`knee and elbow involvement`	numérica	Afectación de rodillas y codos, 0–3. Clínico.	0 – 3
`scalp involvement`	numérica	Afectación del cuero cabelludo, 0–3. Clínico.	0 – 3
`family history`	categórica	Antecedentes familiares (1 sí, 0 no). Clínico.	0 (320), 1 (46)
`melanin incontinence`	numérica	Incontinencia de melanina, 0–3. **Rasgo de la biopsia**.	0 – 3
`eosinophils in the infiltrate`	numérica	Eosinófilos en el infiltrado, 0–3. Biopsia.	0 – 2

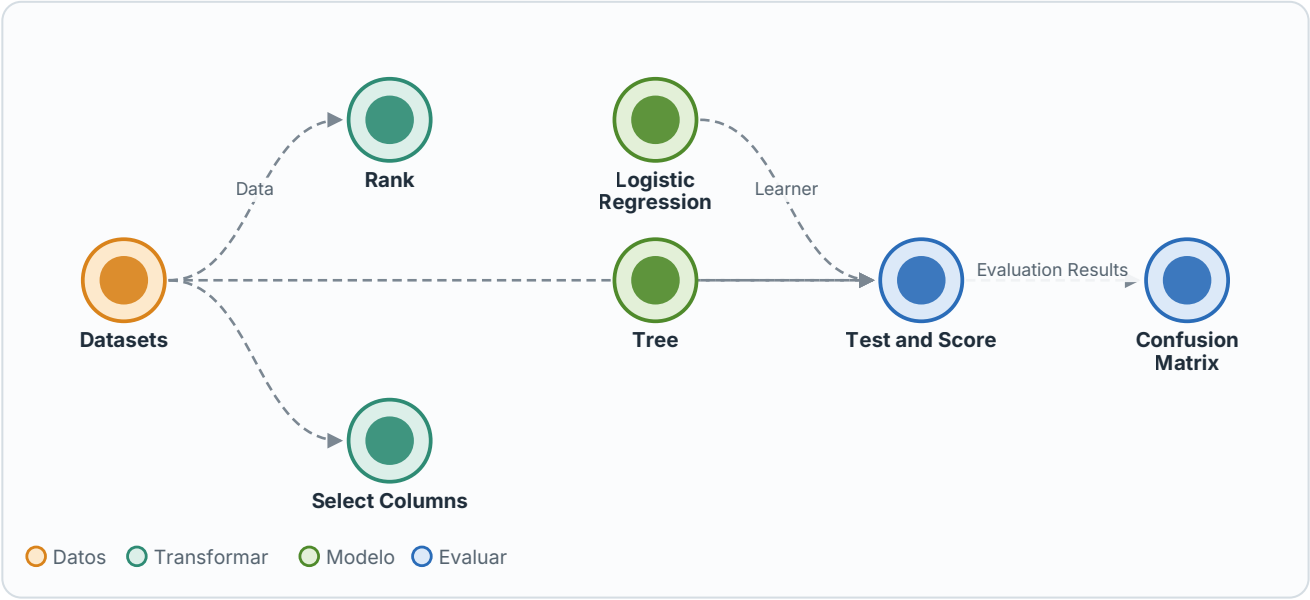
Columna	Tipo	Significado	Valores
PNL infiltrate	numérica	Infiltrado de leucocitos polimorfonucleares, 0–3. Biopsia.	0 – 3
fibrosis of the papillary dermis	numérica	Fibrosis de la dermis papilar, 0–3. Biopsia.	0 – 3
exocytosis	numérica	Exocitosis, 0–3. Biopsia.	0 – 3
acanthosis	numérica	Acantosis (engrosamiento de la epidermis), 0–3. Biopsia.	0 – 3
hyperkeratosis	numérica	Hiperqueratosis, 0–3. Biopsia.	0 – 3
parakeratosis	numérica	Paraqueratosis, 0–3. Biopsia.	0 – 3
clubbing of the rete ridges	numérica	Crestas epidérmicas en maza, 0–3. Biopsia.	0 – 3
elongation of the rete ridges	numérica	Alargamiento de las crestas epidérmicas, 0–3. Biopsia.	0 – 3
thinning of the suprapapillary epidermis	numérica	Adelgazamiento de la epidermis suprapapilar, 0–3. Biopsia.	0 – 3
spongiform pustule	numérica	Pústula espongiforme, 0–3. Biopsia.	0 – 3
munro microabcess	numérica	Microabsceso de Munro, 0–3. Biopsia.	0 – 3
focal hypergranulosis	numérica	Hipergranulosis focal, 0–3. Biopsia.	0 – 3
disappearance of the granular layer	numérica	Desaparición de la capa granulosa, 0–3. Biopsia.	0 – 3
vacuolisation and damage of basal layer	numérica	Vacuolización y daño de la capa basal, 0–3. Biopsia.	0 – 3
spongiosis	numérica	Espongiosis, 0–3. Biopsia.	0 – 3
saw-tooth appearance of retes	numérica	Crestas en dientes de sierra, 0–3. Biopsia.	0 – 3
follicular horn plug	numérica	Tapón córneo folicular, 0–3. Biopsia.	0 – 3
perifollicular parakeratosis	numérica	Paraqueratosis perifolicular, 0–3. Biopsia.	0 – 3
inflammatory monoluclear inflitrate	numérica	Infiltrado inflamatorio mononuclear, 0–3. Biopsia. (El nombre tiene erratas en el original.)	0 – 3
band-like infiltrate	numérica	Infiltrado en banda, 0–3. Biopsia.	0 – 3
age	numérica	Edad en años. 8 huecos y un 0 que parece un error.	0 – 75

Columna	Tipo	Significado	Valores
type `objetivo`	categórica	**Clase**: enfermedad (`psoriasis` , `seboreic dermatitis` , `lichen planus` , `pityriasis rosea` , `cronic dermatitis` , `pityriasis rubra pilaris`).	psoriasis (112), lichen planus (72), seboreic dermatitis (61), cronic dermatitis (52), pityriasis rosea (49), pityriasis rubra pilaris (20)

5 Particularidades técnicas al modelar

- **Atributos ordinales como números**: los rasgos van de 0 a 3 y Orange los lee como numéricos, lo que respeta el orden. Está bien así para la mayoría de modelos.
- **La edad casi delata una clase**: la pitiriasis rubra pilaris aparece solo en niños y jóvenes en estos datos. Si se quiere evaluar el diagnóstico por la piel, prueba también sin la edad.
- **Dos fuentes de información con coste distinto**: los rasgos clínicos se ven en la consulta; los histopatológicos exigen una biopsia. Comparar un modelo solo clínico con el completo responde a una pregunta médica real.
- **Pocos huecos**: solo 8 edades. Hay una edad 0 en un paciente de psoriasis que probablemente es un error.
- **Clases algo desequilibradas** (de 112 a 20 casos): usa validación estratificada y mira el acierto por clase.

6 Flujo de trabajo en Orange



1. **Datasets** → «Dermatology» (o **File** con el CSV).
2. **Rank**: los rasgos más informativos son casi todos de la biopsia.
3. **Test and Score** con regresión logística y árbol, validación estratificada → **Confusion Matrix**: qué enfermedades se confunden.
4. **Select Columns**: quédate con los 12 rasgos clínicos y la edad, y repite. ¿Cuánto acierto se pierde sin biopsia?

7 Otras consideraciones

- **Árbol para el médico**: un árbol de profundidad 3 o 4 da reglas que un dermatólogo puede contrastar con lo que sabe.

- **Visualizar**: *t-SNE* o *MDS* coloreados por la enfermedad muestran qué grupos se solapan (dermatitis seborreica y pitiriasis rosada suelen hacerlo).
- **Rasgos clínicos frente a biopsia**: un buen ejercicio de selección de atributos con coste.

En la carpeta `dermatology` ← `dermatology.tab` (datasets.biolab.si)

2.10
Clasificación: salud y medicina

Lymphography

`02_clasificacion_salud/lymphography/`

148 linfografías del Instituto de Oncología de Liubliana, descritas por 18 rasgos de los ganglios linfáticos, para distinguir metástasis, linfoma maligno, fibrosis y ganglios normales: pocas filas y dos clases casi vacías.

Clasificación multiclase · ⚖ Desbalanceado · ◈ Mixto num. + cat.

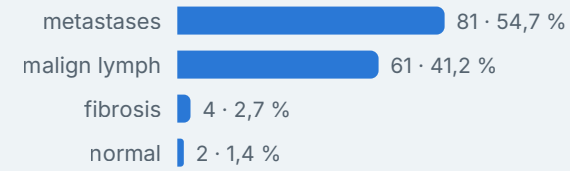
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
148	**19**	y	**0,0 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`lymphography`	148 × 19	CSV 15 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/02_clasificacion_salud/lymphography/` seguido del nombre del fichero CSV.

Radiografía

y en lymphography



1 Descripción general y estudios habituales

La linfografía es una prueba de imagen de los vasos y ganglios linfáticos con contraste. Cada fila es una exploración descrita por 18 rasgos que valora el radiólogo: el aspecto de los vasos linfáticos, si hay bloqueos o vías alternativas, el tamaño y la forma de los ganglios, los defectos de relleno, los cambios en su estructura y el número de ganglios afectados. La clase es el diagnóstico: metástasis (81), linfoma maligno (61), fibrosis (4) o normal (2).

Los estudios habituales son:

- **Distinguir metástasis de linfoma**, que es lo que se hace casi siempre, porque las otras dos clases tienen 6 casos.
- **Clasificación con muy pocos datos** y atributos categóricos.
- **Comparar con médicos**: según la documentación de UCI, los expertos acertaban un 85 % (estimado) y Naive Bayes un 83 %.

2 Contexto y fuente original

Es uno de los tres datasets del **Instituto de Oncología del Centro Médico Universitario de Liubliana** (M. Zwitter y M. Soklič), junto con *Breast Cancer* y *Primary Tumor*, que cedieron a Igor Kononenko y Bojan Cestnik

para los primeros sistemas de aprendizaje de reglas y árboles en medicina (Assistant-86). Está en el repositorio UCI desde 1988.

- Lymphography en el repositorio UCI (Instituto de Oncología de Liubliana)

3 Variable objetivo

La clase es `y`: `metastases` (81), `malign lymph` (61), `fibrosis` (4) y `normal` (2).

Con dos clases casi vacías, el problema es en la práctica binario: metástasis frente a linfoma. En una prueba con validación cruzada estratificada de 10 bolsas, el bosque aleatorio acierta un 86 %, la regresión logística y kNN un 84 % y el árbol un 76 %, frente al 55 % de decir siempre «metástasis».

4 Diccionario de columnas

Columnas de `lymphography` (valores observados en el fichero)

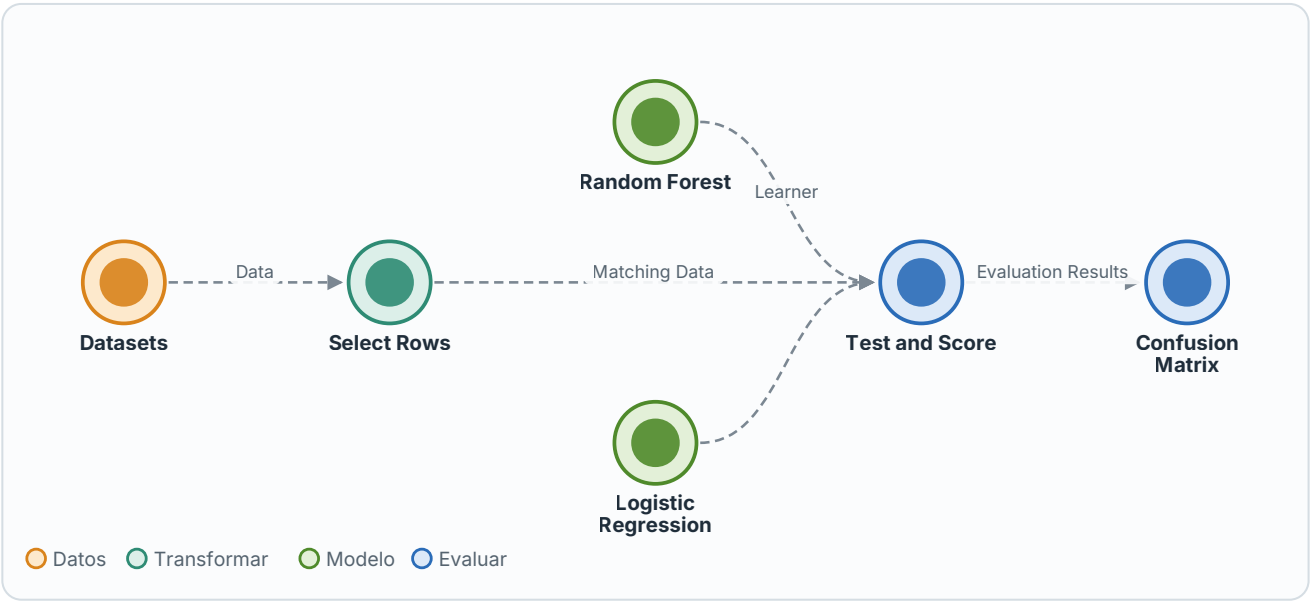
Columna	Tipo	Significado	Valores
y `objetivo`	categórica	**Clase**: `metastases`, `malign lymph` (linfoma maligno), `fibrosis` o `normal`.	metastases (81), malign lymph (61), fibrosis (4), normal (2)
`lymphatics`	categórica	Aspecto de los vasos linfáticos: `normal`, `arched` (arqueados), `deformed` (deformados) o `displaced` (desplazados).	arched (67), deformed (46), displaced (33), normal (2)
`bl_affere`	categórica	Bloqueo de los vasos aferentes (`yes` / `no`).	yes (82), no (66)
`bl_lymph_c`	categórica	Bloqueo linfático en la zona clavicular.	no (122), yes (26)
`bl_lymph_s`	categórica	Bloqueo linfático en la zona subclavia.	no (141), yes (7)
`by_pass`	categórica	Si hay vías linfáticas alternativas (derivación).	no (112), yes (36)
`extravasates`	categórica	Si hay extravasación del contraste.	yes (75), no (73)
`regen`	categórica	Si hay regeneración de vasos.	no (138), yes (10)
`early_uptake`	categórica	Captación temprana del contraste en los ganglios.	yes (104), no (44)
`lym_dimin`	numérica	Disminución de los ganglios (1 a 3).	1 – 3
`lym_enlar`	numérica	Aumento de tamaño de los ganglios (1 a 4).	1 – 4
`changes_lym`	categórica	Forma de los ganglios: `bean` (judía), `oval` o `round` (redonda).	oval (77), round (65), bean (6)
`defect`	categórica	Defecto de relleno: `no`, `lacunar`, `lac marginal` o `lac central`.	lac central (50), lacunar (49), lac marginal (46), no (3)
`changes_node`	categórica	Cambios en el ganglio: mismos valores que `defect`.	lac marginal (75), lacunar (42), lac central (25), no (6)
`changes_stru`	categórica	Cambios en la estructura del ganglio: `no`, `grainy`, `drop-like`, `coarse`, `diluted`, `reticular`, `stripped` o `faint`.	faint (45), coarse (31), diluted (28), drop-like (19), grainy (14), stripped (7) …

Columna	Tipo	Significado	Valores
`spec_forms`	categórica	Formas especiales: `no`, `chalices` (cálices) o `vesicles` (vesículas).	vesicles (77), chalices (43), no (28)
`dislocation`	categórica	Si hay desplazamiento de los ganglios.	yes (98), no (50)
`exclusion`	categórica	Si hay exclusión de ganglios (no se rellenan).	yes (117), no (31)
`no_nodes`	numérica	Número de ganglios afectados, en grupos del 1 al 8.	1 – 8

5 Particularidades técnicas al modelar

- **Dos clases casi vacías**: con 2 casos normales y 4 de fibrosis, ningún modelo puede aprenderlas y la validación cruzada de 10 bolsas deja bolsas sin ellas. Lo habitual es quitarlas con *Select Rows* y trabajar con metástasis frente a linfoma.
- **Pocos casos y muchos atributos categóricos**: 148 filas y 18 variables. Los árboles sobreajustan con facilidad; pódalos o limita la profundidad.
- **Números que son categorías**: `lym_dimin`, `lym_enlar` y `no_nodes` vienen codificados con números, pero son grupos ordinales. Orange los lee como categorías.
- Los datos se recogieron en los años ochenta, con la linfografía como prueba habitual; hoy se usan otras técnicas de imagen. Sirve para practicar, no como referencia clínica.
- No hay valores ausentes.

6 Flujo de trabajo en Orange



1. **Datasets** → «Lymphography» (o **File** con el CSV).
2. **Select Rows**: `y` es `metastases` o `malign lymph` (142 casos).
3. **Test and Score** con bosque aleatorio y regresión logística, validación estratificada.
4. **Confusion Matrix**: ¿se confunden más las metástasis o los linfomas?

7 Otras consideraciones

- **Con las cuatro clases**: repite sin filtrar y mira qué pasa con fibrosis y normal en la matriz de confusión. Es una buena forma de enseñar qué hace un modelo con clases que casi no ha visto.
- **Reglas**: *CN2 Rule Induction* da reglas cortas que se pueden comparar con criterios radiológicos.
- **Los otros datasets de Liubliana**: *Breast Cancer* y *Primary Tumor*, del mismo instituto y época.

En la carpeta `lymphography` ← `lymphography.tab` (datasets.biolab.si)

2.11

Clasificación: salud y medicina

Primary Tumor

`02_clasificacion_salud/primary_tumor/`

339 pacientes con metástasis del Instituto de Oncología de Liubliana: a partir de dónde se ha extendido el cáncer, hay que adivinar en qué órgano empezó, entre 21 posibilidades. Uno de los problemas más difíciles del capítulo.

Clasificación multiclase | ⚖ Desbalanceado | ? Valores faltantes | ◇ Solo categóricos

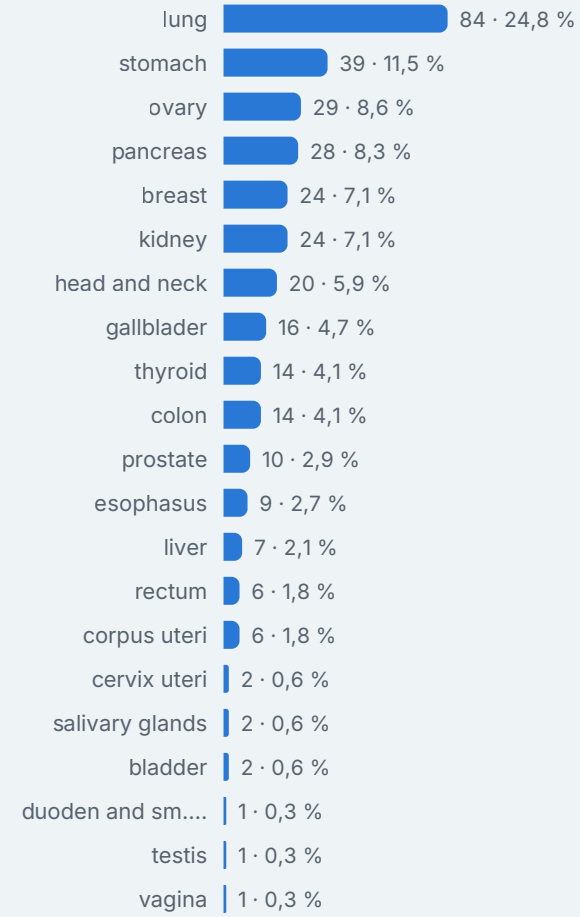
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
339	**18**	`primary`	**3,7 %**	**Avanzado**	**Ninguno**

Fichero	Filas × col.	Descargar
`primary_tumor`	339 × 18	CSV 24 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/02_clasificacion_salud/primary_tumor/` seguido del nombre del fichero CSV.

Radiografía

primary en primary_tumor



1 Descripción general y estudios habituales

Cada fila es un paciente con un cáncer que ya se ha extendido. Las 17 variables dicen la edad, el sexo, el tipo histológico del tumor, su grado de diferenciación y, sobre todo, **en qué órganos se han encontrado metástasis** (huesos, médula ósea, pulmón, pleura, peritoneo, hígado, cerebro, piel, cuello, ganglios supraclaviculares, axilares, mediastínicos y abdominales). La clase es el **órgano donde empezó el tumor** (tumor primario).

Los estudios habituales son:

- **Clasificación con muchas clases** (21) y muy desiguales.
- **Ver los límites de un problema difícil**: ni los modelos ni los especialistas superan el 50 % de acierto.
- **Comparar con los médicos**: según la documentación de UCI, los expertos acertaban un 42 % y los primeros sistemas de aprendizaje, entre el 44 % y el 48 %.

2 Contexto y fuente original

Es el tercero de los datasets del **Instituto de Oncología del Centro Médico Universitario de Liubliana** (M. Zwitter y M. Soklič), junto con *Breast Cancer* y *Lymphography*. Se usó con el sistema Assistant-86 (Cestnik, Kononenko y Bratko, 1987) y está en el repositorio UCI desde 1988. El problema tiene sentido clínico: a veces el cáncer se descubre por una metástasis y el tratamiento depende de saber dónde empezó.

- Primary Tumor en el repositorio UCI (Instituto de Oncología de Liubliana)

3 Variable objetivo

La clase es `primary`, con 21 órganos de origen. Están muy desequilibrados: pulmón (84), estómago (39), ovario (29), páncreas (28), mama y riñón (24 cada uno), cabeza y cuello (20)… y seis órganos con 1 o 2 casos (cuello de útero, glándulas salivales, vejiga, duodeno, testículo y vagina).

Acertar siempre «pulmón» da un 25 %. En una prueba con validación cruzada estratificada de 10 bolsas, la regresión logística acierta un 49 %, el bosque aleatorio un 44 % y el árbol un 41 %.

4 Diccionario de columnas

Columnas de `primary_tumor` (valores observados en el fichero)

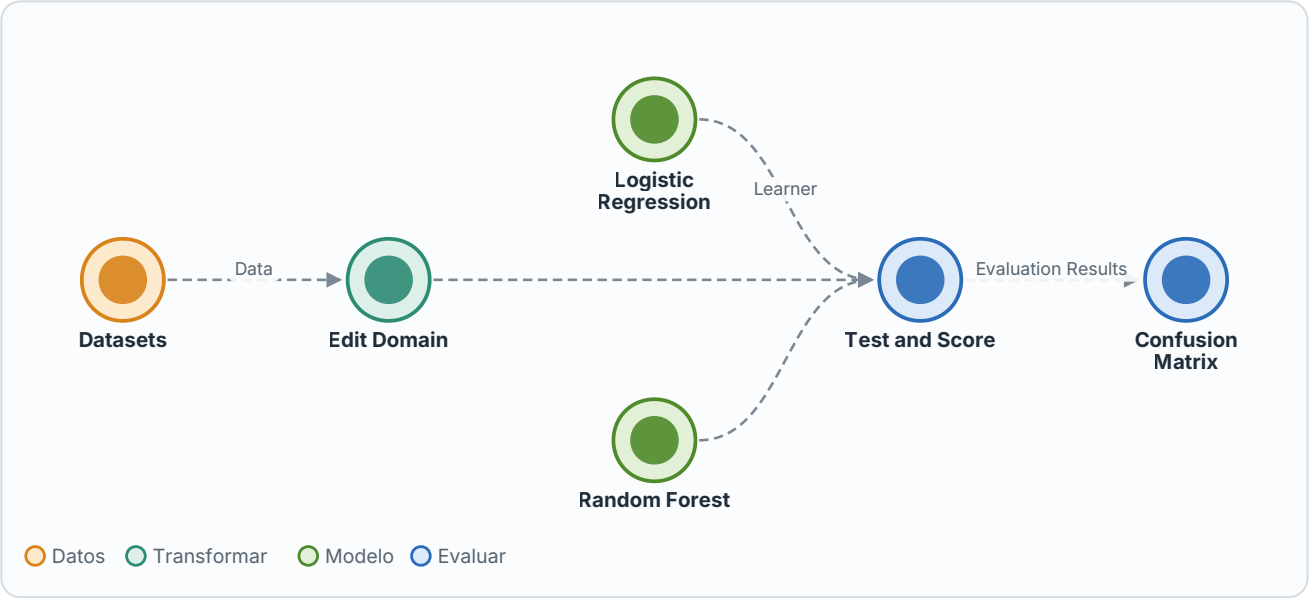
Columna	Tipo	Significado	Valores
`primary` objetivo	categórica	**Clase**: órgano donde se originó el tumor (`lung`, `stomach`, `ovary` … 21 valores).	lung (84), stomach (39), ovary (29), pancreas (28), breast (24), kidney (24) …
`age`	categórica	Edad: `<30`, `30-59` o `>=60`.	30-59 (209), >=60 (107), <30 (23)
`sex`	categórica	Sexo (`male` / `female`). 1 hueco.	female (177), male (161)
`histologic_type`	categórica	Tipo histológico: `epidermoid` (epidermoide), `adeno` (adenocarcinoma) o `anaplastic`. 67 huecos.	adeno (220), epidermoid (44), anaplastic (8)
`degree_of_diffe`	categórica	Grado de diferenciación del tumor: `well` (bien), `fairly` (moderado) o `poorly` (poco diferenciado). 155 huecos.	poorly (100), well (57), fairly (27)

Columna	Tipo	Significado	Valores
bone	categórica	Metástasis en hueso (`yes` / `no`). Igual para las columnas siguientes.	no (245), yes (94)
bone_marrow	categórica	Metástasis en médula ósea.	no (332), yes (7)
lung	categórica	Metástasis en pulmón.	no (264), yes (75)
pleura	categórica	Metástasis en la pleura.	no (264), yes (75)
peritoneum	categórica	Metástasis en el peritoneo.	no (244), yes (95)
liver	categórica	Metástasis en el hígado.	no (230), yes (109)
brain	categórica	Metástasis en el cerebro.	no (318), yes (21)
skin	categórica	Metástasis en la piel. 1 hueco.	no (318), yes (20)
neck	categórica	Metástasis en el cuello.	no (295), yes (44)
supraclavicular	categórica	Metástasis en los ganglios supraclaviculares.	no (278), yes (61)
axillar	categórica	Metástasis en los ganglios axilares. 1 hueco.	no (305), yes (33)
mediastinum	categórica	Metástasis en el mediastino.	no (247), yes (92)
abdominal	categórica	Metástasis en los ganglios abdominales.	no (224), yes (115)

5 Particularidades técnicas al modelar

- **Muy difícil**: con metástasis en pocos órganos y descritas solo como sí o no, mucha información clínica se pierde. Un 49 % de acierto es un buen resultado aquí.
- **Clases casi vacías**: 6 de los 21 órganos tienen 1 o 2 casos. Con validación cruzada de 10 bolsas, la mayoría de las bolsas no los ven nunca. Se pueden agrupar en «otros» con *Edit Domain*.
- **Muchos casos idénticos y contradictorios**: 57 pacientes repiten exactamente los datos de otro, y en 22 grupos de pacientes idénticos el tumor empezó en sitios distintos. Ningún modelo puede acertar esos casos.
- **Huecos importantes**: el grado de diferenciación falta en 155 pacientes (casi la mitad) y el tipo histológico en 67.
- **Mejor mirar más allá del primer puesto**: en clínica es útil una lista corta de órganos probables. Las probabilidades que da *Predictions* permiten medir si el órgano real está entre los 3 primeros.

6 Flujo de trabajo en Orange



1. **Datasets** → «Primary Tumor» (o **File** con el CSV).
2. **Edit Domain**: junta en «other» los órganos con menos de 5 casos.
3. **Test and Score** con regresión logística y bosque aleatorio, validación estratificada.
4. **Confusion Matrix**: qué órganos se confunden entre sí (por ejemplo, estómago, páncreas y vesícula).

7 Otras consideraciones

- **Comparar con los médicos**: el 42 % de los expertos que recoge la documentación de UCI es una referencia interesante para discutir qué significa que un modelo «iguale a un experto».
- **Pregunta más sencilla**: crea una clase binaria (por ejemplo, pulmón o no) y compara la dificultad.
- **Los otros datasets de Liubliana**: *Breast Cancer* y *Lymphography*.

En la carpeta `primary_tumor` ← `primary-tumor.tab` (datasets.biolab.si)

2.12
Clasificación: salud y medicina

BUPA Liver Disorders

`02_clasificacion_salud/bupa/`

345 hombres con cinco análisis de sangre relacionados con el hígado y lo que beben al día. Durante años se usó como diagnóstico de enfermedad hepática, pero la columna «selector» no es un diagnóstico: es una partición de los datos.

Clasificación binaria

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
345	**7**	`selector`	**0,0 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`bupa`	345 × 7	CSV 7 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/02_clasificacion_salud/bupa/` seguido del nombre del fichero CSV.

Radiografía

selector en bupa



drinks: bebidas al día (la variable con sentido)



1 Descripción general y estudios habituales

Cada fila es un hombre adulto con cinco análisis de sangre que se consideran sensibles a los trastornos hepáticos por consumo de alcohol (volumen corpuscular medio, fosfatasa alcalina y tres enzimas hepáticas) y el número de bebidas alcohólicas que toma al día. La séptima columna, `selector`, vale 1 o 2.

Los estudios habituales son:

- **Clasificación binaria con** `selector`, como se ha hecho en cientos de artículos (con aciertos del 65–75 %).
- **Regresión o clasificación del consumo de alcohol** (`drinks`) a partir de los análisis, que es para lo que se recogieron los datos.
- **Una lección sobre leer la documentación**: qué significa de verdad cada columna.

2 Contexto y fuente original

Los datos son de **BUPA Medical Research Ltd** (Reino Unido) y los donó Richard S. Forsyth al repositorio UCI en 1990, con el nombre *Liver Disorders*. Durante 25 años se usaron como si `selector` fuera la presencia o ausencia de enfermedad hepática.

En 2016, **James McDermott y Richard Forsyth** publicaron *Diagnosing a disorder in a classification benchmark*: `selector` es una variable que los investigadores originales añadieron para **dividir los datos en entrenamiento y prueba**, no un diagnóstico. La variable que se pretendía predecir era `drinks`, el consumo de alcohol, y lo recomendable es usarla como objetivo (o convertirla en clase con un umbral, por ejemplo 3 bebidas o más). La documentación de UCI se corrigió entonces.

- McDermott, J. y Forsyth, R. S. (2016). Diagnosing a disorder in a classification benchmark. Pattern Recognition Letters, 73, 41–43.
- Liver Disorders en el repositorio UCI

3 Variable objetivo

En Orange, la clase marcada es `selector` (1: 145 hombres, 2: 200). **No es un diagnóstico**: es la partición entre entrenamiento y prueba que hicieron los autores originales. Que un modelo la «prediga» con un 70 % de acierto dice más de cómo se hizo la partición que del hígado.

La variable con sentido es `drinks`: número de medias pintas (unos 284 ml) de bebidas alcohólicas al día, de 0 a 20, con mediana de 3. Si se convierte en clase («3 o más bebidas al día»), una regresión logística con los cinco análisis acierta un 61 %, frente al 51 % de decir siempre la clase mayoritaria: los análisis informan, pero poco.

4 Diccionario de columnas

Columnas de `bupa` (valores observados en el fichero)

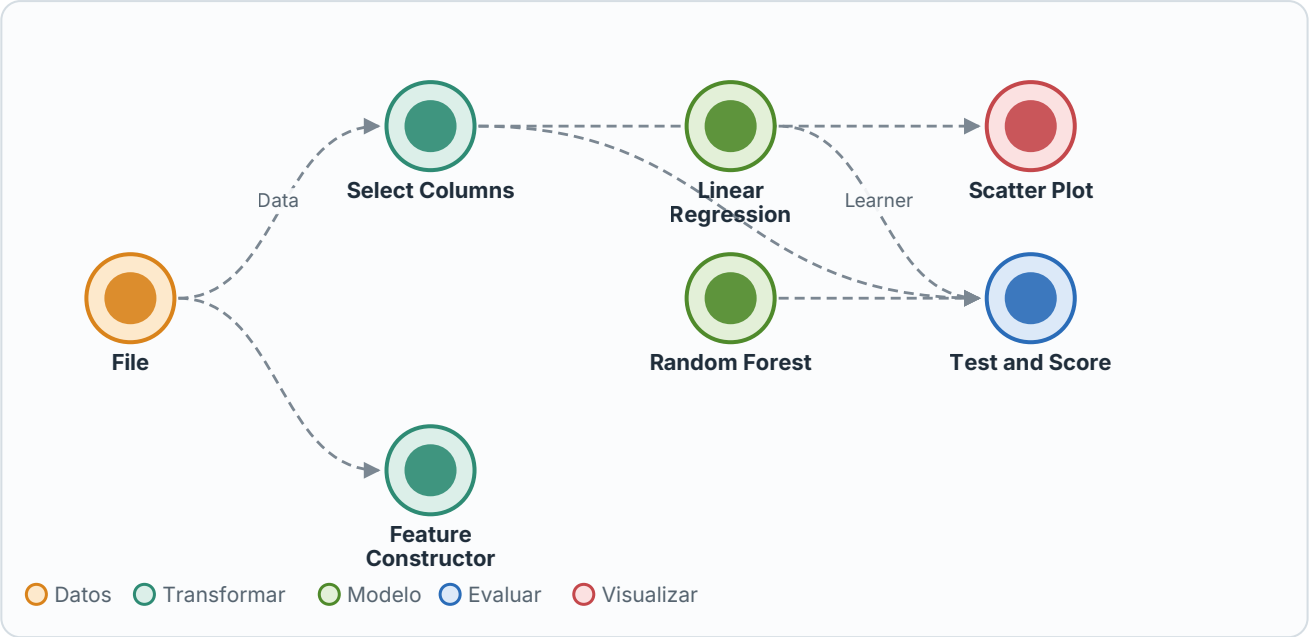
Columna	Tipo	Significado	Valores
`mcv`	numérica	Volumen corpuscular medio de los glóbulos rojos (fl). Sube con el consumo crónico de alcohol.	65 – 103
`alkphos`	numérica	Fosfatasa alcalina (U/l).	23 – 138
`sgpt`	numérica	Alanina aminotransferasa (ALT, U/l), enzima hepática.	4 – 155
`sgot`	numérica	Aspartato aminotransferasa (AST, U/l), enzima hepática.	5 – 82
`gammagt`	numérica	Gamma-glutamil transpeptidasa (GGT, U/l). Es el marcador más clásico del consumo de alcohol.	5 – 297
`drinks`	numérica	Medias pintas de bebidas alcohólicas al día (de 0 a 20). **Es la variable que se quería predecir.**	0 – 20
`selector` `objetivo`	categórica	Partición de los datos (1 o 2) hecha por los investigadores originales. **No es un diagnóstico**, aunque Orange la marca como clase.	2 (200), 1 (145)

5 Particularidades técnicas al modelar

- **El error histórico**: tratar `selector` como clase es un ejemplo famoso de cómo un error en la documentación se propaga durante décadas. Antes de modelar, cambia el objetivo a `drinks` en el widget *File*.
- `drinks` **no es continua del todo**: toma valores como 0,5, 1, 2… con muchos empates (108 hombres con 0,5). Para regresión funciona; para clasificación, elige un umbral con sentido (3 bebidas, 6…).

- **Asimetría**: las enzimas (sobre todo la GGT) tienen colas largas hacia valores altos. Un logaritmo con *Feature Constructor* ayuda a los modelos lineales.
- **Pocos datos y señal débil**: 345 hombres y una relación modesta entre análisis y consumo. No esperes modelos muy precisos.
- 4 filas repetidas exactamente. No hay valores ausentes.

6 Flujo de trabajo en Orange



1. **File** con `bupa`: cambia el rol de `drinks` a *target* y el de `selector` a *meta* (o quítala).
2. **Scatter Plot** de `gammagt` frente a `drinks`: se ve la relación, y lo dispersa que es.
3. **Test and Score** con regresión lineal y bosque aleatorio: compara el error con el de predecir siempre la media.
4. Para clasificación: **Feature Constructor** con una clase «3 o más bebidas» y repite con regresión logística.

7 Otras consideraciones

- **Discutir el error**: pide a los alumnos que «resuelvan» el problema con `selector` y después lee con ellos el artículo de 2016. Es una lección muy eficaz sobre entender los datos antes de modelarlos.
- **Transformar las enzimas**: compara la regresión con y sin logaritmo de la GGT y las transaminasas.
- Datasets con un problema parecido de interpretación en este libro: *Prostate Cancer* (que en realidad son datos de cáncer de mama alterados).

En la carpeta `bupa` ← `bupa.tab` (datasets.biolab.si)

2.13
Clasificación: salud y medicina

Mice Protein Expression (ratones con síndrome de Down)

`02_clasificacion_salud/ratones_sindrome_down/`

1.080 mediciones de 77 proteínas del cerebro de 72 ratones, sanos o con un modelo de síndrome de Down, tratados o no con memantina y estimulados o no a aprender: ocho clases, 15 mediciones por ratón y una trampa de evaluación.

Clasificación multiclase | Clustering | ? Valores faltantes | ◈ Mixto num. + cat.

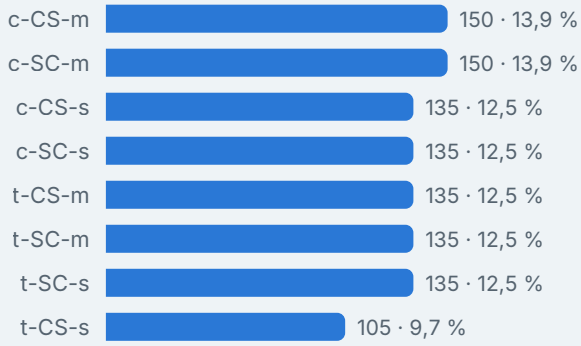
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
1.080	**82**	`class`	**1,6 %**	**Avanzado**	**Ninguno**

Fichero	Filas × col.	Descargar
`ratones_sindrome_down`	1.080 × 82	CSV 1,0 MB · XLSX

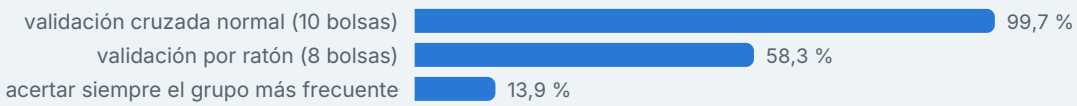
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/02_clasificacion_salud/ratones_sindrome_down/` seguido del nombre del fichero CSV.

Radiografía

class en ratones_sindrome_down



Acierto de un bosque aleatorio con las 77 proteínas según cómo se valide (%)



1 Descripción general y estudios habituales

Cada fila es una medición de los niveles de **77 proteínas** en la fracción nuclear de la corteza cerebral de un ratón. Hay 72 ratones y **15 mediciones de cada uno** (réplicas técnicas), en total 1.080 filas. Los ratones se diferencian en tres factores:

- **Genotipo**: control (sanos) o Ts65Dn (trisómicos, un modelo del síndrome de Down).

- **Comportamiento**: estimulados a aprender (*context-shock*, C/S) o no (*shock-context*, S/C), en una prueba de miedo condicionado.
- **Tratamiento**: memantina (un fármaco que mejora el aprendizaje en estos ratones) o suero salino.

La clase combina los tres factores en **ocho grupos**. Los estudios habituales son:

- **Clasificación multiclase con muchas variables numéricas** (77 proteínas).
- **Encontrar qué proteínas distinguen a los grupos**, que es lo que buscaba el estudio original.
- **Agrupar sin la clase** y ver si salen los genotipos o los tratamientos.

2 Contexto y fuente original

Los datos son de **Clara Higuera, Katheleen Gardiner y Krzysztof Cios**, que en 2015 los usaron para buscar proteínas que explicaran por qué la memantina recupera el aprendizaje en los ratones trisómicos. Usaron mapas autoorganizados y no se centraron en la clasificación. Está en el repositorio UCI como *Mice Protein Expression*.

En el repositorio del curso aparece como `ratones_sindrome_down` en CSV, XLS y ARFF con el mismo contenido.

- Higuera, C., Gardiner, K. J. y Cios, K. J. (2015). Self-organizing feature maps identify proteins critical to learning in a mouse model of Down syndrome. PLoS ONE, 10(6), e0129126.
- Mice Protein Expression en el repositorio UCI

3 Variable objetivo

La clase es `class`, con ocho grupos que combinan genotipo (`c` control, `t` trisómico), comportamiento (`CS` o `SC`) y tratamiento (`m` memantina, `s` salino): por ejemplo, `t-CS-m` son ratones trisómicos estimulados y tratados con memantina. Los grupos tienen entre 105 y 150 filas (de 7 a 10 ratones).

El resultado depende por completo de cómo se valide. Con validación cruzada normal, un bosque aleatorio acierta el 99,7 %. Pero si se hace que todas las mediciones de un mismo ratón vayan juntas a entrenamiento o a prueba, el acierto cae al **58 %**: el modelo había aprendido a reconocer a cada ratón, no a su grupo.

4 Diccionario de columnas

Columnas de `ratones_sindrome_down` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`MouseID`	texto	Identificador de la medición: número de ratón y número de réplica (`309_1` … `309_15`). En Orange va como *meta*.	309_1 (1), 309_2 (1), 309_3 (1), 309_4 (1), 309_5 (1), 309_6 (1) …
`DYRK1A_N`	numérica	Nivel de la proteína DYRK1A en la fracción nuclear. Las 77 columnas que terminan en `_N` son niveles de proteínas (algunas fosforiladas, con el prefijo `p`).	0,145 – 2,516
`Genotype`	categórica	Genotipo: `Control` o `Ts65Dn` (trisómico). **Forma parte de la clase.**	Control (570), Ts65Dn (510)

Columna	Tipo	Significado	Valores
`Treatment`	categórica	Tratamiento: `Memantine` o `Saline`. **Forma parte de la clase.**	Memantine (570), Saline (510)
`Behavior`	categórica	Comportamiento: `C/S` (estimulado a aprender) o `S/C` (no estimulado). **Forma parte de la clase.**	S/C (555), C/S (525)
`class` objetivo	categórica	**Clase**: combinación de genotipo, comportamiento y tratamiento (`c-CS-m` , `t-SC-s` …).	c-CS-m (150), c-SC-m (150), c-CS-s (135), c-SC-s (135), t-CS-m (135), t-SC-m (135) …
…		y 76 columnas más del mismo tipo que la anterior.	

5 Particularidades técnicas al modelar

- **Tres columnas son la clase desmontada**: `Genotype` , `Treatment` y `Behavior` determinan `class` sin error (con solo esas tres, cualquier modelo acierta el 100 %). Orange las carga como atributos: **pásalas a *meta*** o quítalas antes de modelar.
- **15 filas por ratón**: las réplicas de un mismo ratón se parecen mucho. La validación cruzada normal las reparte entre entrenamiento y prueba y el modelo las reconoce. Para una evaluación honesta, valida dejando fuera ratones enteros (en Orange se puede con *Python Script*, o promediando las 15 réplicas de cada ratón con *Group By* y trabajando con 72 filas).
- **Huecos concentrados en pocas proteínas**: BCL2 (285 huecos), H3MeK4 (270), BAD (213), EGR1 (210) y H3AcK18 (180). Algunos ratones no tienen ninguna medición de esas proteínas. Imputar con la media o quitar esas columnas.
- **Muchas variables correlacionadas**: proteínas de la misma vía de señalización suben y bajan juntas. Útil para practicar PCA y selección de atributos.
- Las 77 proteínas están en escalas parecidas pero no iguales: normaliza para kNN y SVM.

6 Flujo de trabajo en Orange



1. **File** con `ratones_sindrome_down`: `class` como *target*; `MouseID`, `Genotype`, `Treatment` y `Behavior` como *meta*.
2. **Impute** (media) o quita las cinco proteínas con más huecos.
3. **Group By** por ratón (a partir de `MouseID` sin el número de réplica, creado con *Feature Constructor*) con la media de cada proteína: 72 filas, una por ratón.
4. **Test and Score** con bosque aleatorio sobre las 72 filas: el acierto realista.
5. **PCA** → **Scatter Plot** coloreado por `Genotype` y por `Treatment`: ¿qué factor separa más?

7 Otras consideraciones

- **El experimento de la trampa**: compara el acierto con las 1.080 filas y con las 72 medias por ratón. Es uno de los mejores ejemplos para enseñar que las filas no siempre son independientes.
- **Problemas binarios**: predecir solo el genotipo (sano o trisómico) o solo el tratamiento es más interpretable que las ocho clases.
- **Proteínas importantes**: *Rank* o la importancia de un bosque aleatorio dan una lista que se puede comparar con las proteínas que destaca el artículo original.

En la carpeta	`ratones_sindrome_down` ← `ratones_sindrome_down.csv` (curso_ciencia_datos (GitHub))
Duplicado, no se copia	`ratones_sindrome_down.xls` (curso_ciencia_datos (GitHub))
Duplicado, no se copia	`ratones_sindrome_down.arff` (curso_ciencia_datos (GitHub))

2.14
Clasificación: salud y medicina

Health survey (encuesta de hábitos)

`02_clasificacion_salud/health_survey/`

Una pequeña encuesta de hábitos (café, dulces, agua, tabaco, deporte, transporte) y salud percibida de 41 personas con apodo: un conjunto de juguete para explorar datos reales de clase, con una columna «Selected» que sobra.

Exploración y visualización | Clustering | Regresión | ◦ Juguete | ◈ Mixto num. + cat. | ✎ Sintético

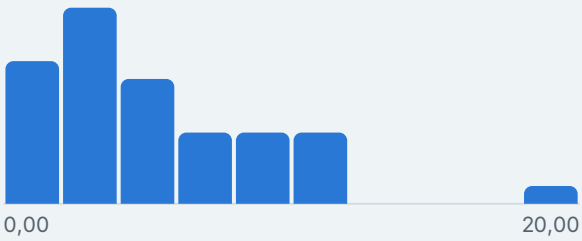
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
41	**9**	`general health (propuesto)`	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`health_survey`	41 × 9	CSV 2 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/02_clasificacion_salud/health_survey/` seguido del nombre del fichero CSV.

Radiografía

Horas de deporte a la semana (sin el valor de 100)



1 Descripción general y estudios habituales

Son **41 respuestas** a una encuesta breve: cuántos cafés, dulces y litros de agua toma la persona al día, si fuma, cuántas horas de deporte hace a la semana, cómo va al trabajo y cómo valora su salud general (de 1 a 5). Cada persona aparece con un apodo.

Los estudios habituales son:

- **Explorar y visualizar** datos sencillos de una encuesta: distribuciones, valores extraños y relaciones.
- **Detectar errores de captura**: hay respuestas imposibles y erratas.
- **Un primer modelo**: predecir la salud percibida (como clase o como número) a partir de los hábitos.

2 Contexto y fuente original

El fichero está en el repositorio del curso (`health_survey.tab`), sin documentación sobre su origen. Por el formato y el contenido parece una encuesta hecha en clase o en un taller de Orange, con apodos para que sea anónima, y guardada desde Orange después de seleccionar filas en algún widget: de ahí la columna `Selected`, que vale `No` en todas las filas.

Los datos son reales (respuestas de personas) pero no representan a ninguna población: sirven para practicar.

- health_survey.tab en el repositorio del curso (gualbe/datasets/curso_ciencia_datos)

3 Variable objetivo

En el fichero, la clase marcada es `Selected`, pero **no es una variable útil**: vale `No` en las 41 filas. Es un resto de una selección hecha en Orange.

Lo natural es usar como objetivo `general health`, la salud percibida de 1 a 5 (mediana 4; las 3 respuestas con −1 habrá que tratarlas como ausentes), como número (regresión) o como categoría (clasificación). Con 41 personas, cualquier modelo será poco fiable: el interés está en explorar.

4 Diccionario de columnas

Columnas de `health_survey` (valores observados en el fichero)

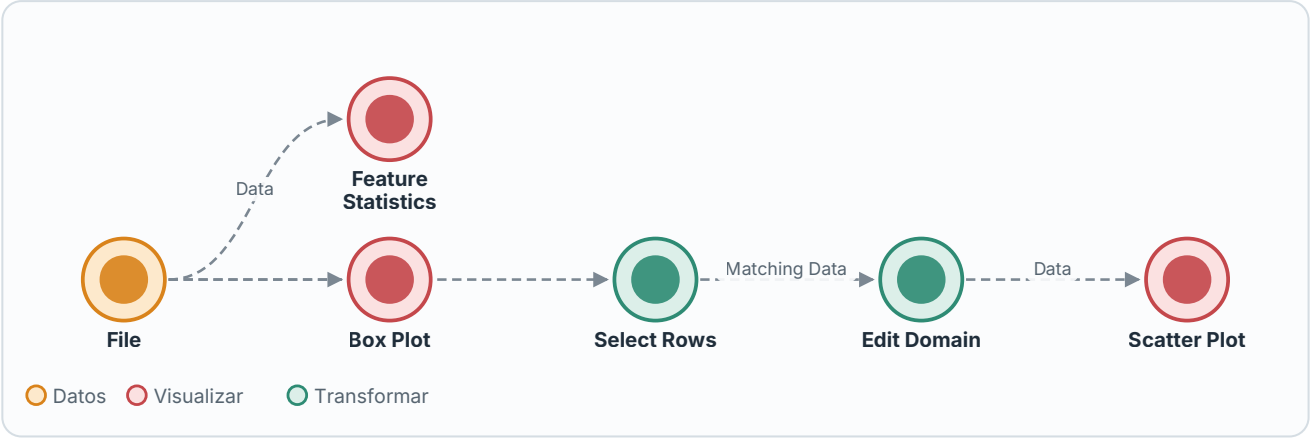
Columna	Tipo	Significado	Valores
`coffees per day`	numérica	Cafés al día (de 0 a 10).	0 – 10
`sweets per day`	numérica	Dulces al día (de 0 a 5).	0 – 5
`water per day (l)`	numérica	Litros de agua al día (de 1 a 10; 10 litros es poco creíble).	1 – 10
`smoker`	categórica	Si fuma (`Yes` / `No`). Solo 2 fumadores.	No (39), Yes (2)
`sport per week [h]`	numérica	Horas de deporte a la semana. **Hay un 100**, imposible (una semana tiene 168 horas).	0 – 100
`transport to work`	categórica	Cómo va al trabajo: `car`, `bike/skates`, `walking` o `pubic transport` (con errata: *public*).	pubic transport (15), car (13), bike/skates (9), walking (4)
`general health`	numérica	Salud general percibida, en principio de 1 (mala) a 5 (muy buena). **Hay 3 respuestas con −1**, fuera de la escala (quizá «no contesta»).	-1 – 5
`Selected` `objetivo`	categórica	Resto de una selección en Orange: vale `No` en todas las filas. **Quítala.**	No (41)
`nickname`	texto	Apodo de la persona. Es un identificador: en Orange va como *meta*.	a (1), diskus (1), mićo (1), foobar (1), martin (1), anon (1) …

5 Particularidades técnicas al modelar

- **Una clase inútil**: `Selected` tiene un solo valor. Cualquier widget de modelado dará error o un modelo trivial. Cambia el objetivo a `general health` (o a otra variable) en *File*.

- **Valores imposibles o dudosos**: 100 horas de deporte a la semana, 10 litros de agua al día, 10 cafés y una salud general de −1 en una escala de 1 a 5. Son el ejercicio principal del dataset: detectarlos con *Box Plot* o *Feature Statistics* y decidir qué hacer.
- **Erratas en categorías**: `pubic transport` en lugar de *public transport*. Con *Edit Domain* se puede corregir.
- **Muy pocos datos**: 41 filas y solo 2 fumadores. No tiene sentido estudiar el efecto del tabaco.
- **Escala de 1 a 5**: `general health` es ordinal. Como número, la regresión funciona; como categoría, hay que juntar niveles con pocos casos.

6 Flujo de trabajo en Orange



1. **File** con `health_survey`: quita `Selected` y marca `general health` como *target*.
2. **Feature Statistics** y **Box Plot**: busca los máximos imposibles (deporte, agua, cafés).
3. **Select Rows**: quita o marca las respuestas imposibles (por ejemplo, deporte > 30 horas).
4. **Edit Domain**: corrige `pubic transport`.
5. **Scatter Plot**: ¿se relacionan el deporte o el agua con la salud percibida?

7 Otras consideraciones

- **Hacer la encuesta en clase**: con un formulario sencillo, los alumnos recogen sus propios datos y repiten el análisis. Es la mejor forma de ver de dónde salen los errores de captura.
- **Datos personales**: aunque sean apodos, son hábitos de personas reales. Es un buen ejemplo para hablar de anonimización.
- Para un ejemplo inventado con la misma escala de datos, ver *Naughty or nice* (capítulo 1).

En la carpeta `health_survey` ← `health_survey.tab` (curso_ciencia_datos (GitHub))

3 Clasificación: negocio, sociedad y equidad

8 datasets en el capítulo; en esta edición, 8 con ficha.

3.01
Clasificación: negocio, sociedad y equidad

Adult (Census Income)

`03_clasificacion_negocio_sociedad/adult/`

48.842 personas del censo de Estados Unidos de 1994 y si ganaban más de 50.000 dólares al año: el dataset clásico de clasificación con datos reales y, hoy, el banco de pruebas más usado para hablar de sesgo y equidad.

Clasificación binaria · ⚑ Sesgo y equidad · ? Valores faltantes · ▤ Grande · ◈ Mixto num. + cat.

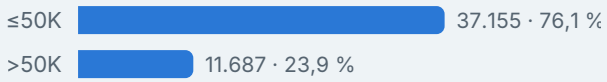
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
48.842	**15**	`income`	**0,9 %**	**Intermedio**	**Fairness**

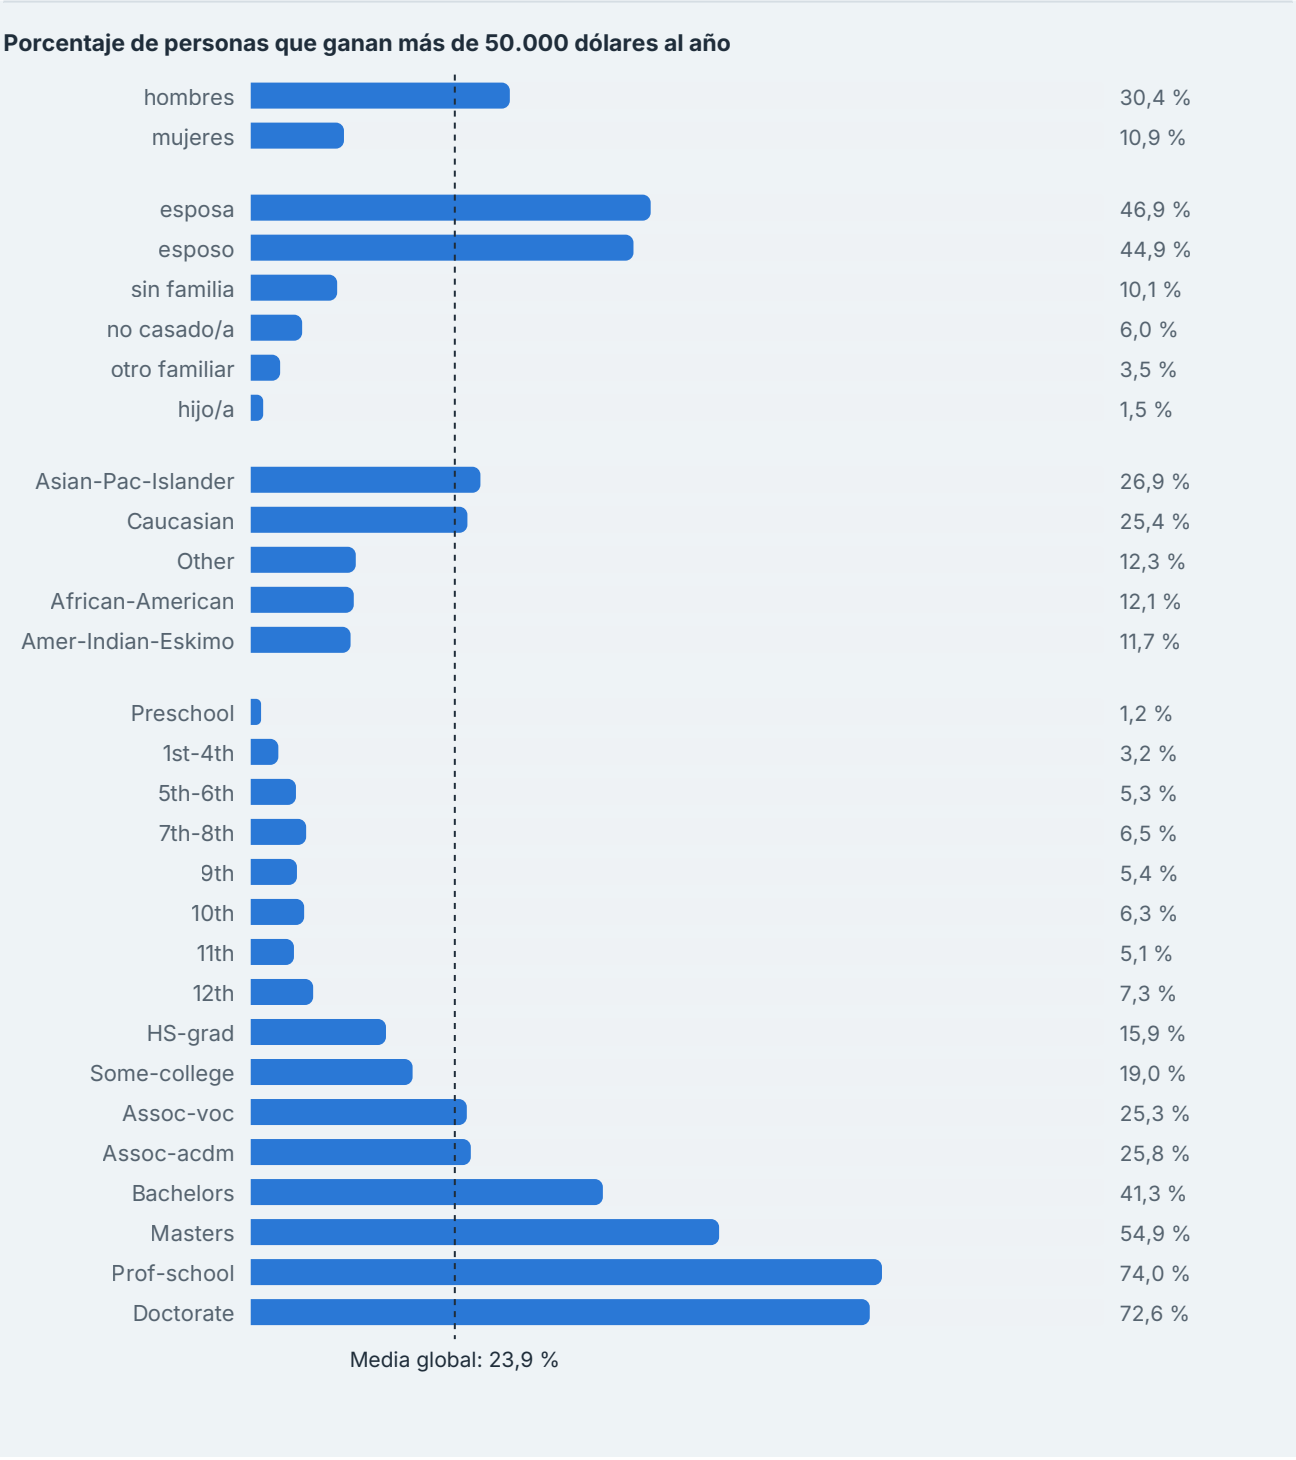
Fichero	Filas × col.	Descargar
`adult`	48.842 × 15	CSV 5,5 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/03_clasificacion_negocio_sociedad/adult/` seguido del nombre del fichero CSV.

Radiografía

income en adult





1 Descripción general y estudios habituales

Cada fila es una persona adulta con datos del censo: edad, tipo de empleador, estudios, estado civil, ocupación, relación dentro del hogar, raza, sexo, ganancias y pérdidas de capital, horas trabajadas por semana y país de origen. La clase dice si sus ingresos anuales superaban los **50.000 dólares** (11.687 personas, el 24 %) o no (37.155).

Los estudios habituales son:

- **Clasificación binaria** con muchas filas y variables mixtas.
- **Equidad algorítmica**: ¿trata el modelo igual a hombres y mujeres, o a personas de distinta raza? Es el ejemplo de referencia del add-on *Fairness* de Orange.
- **Interpretar qué factores se asocian a los ingresos altos.**

2 Contexto y fuente original

Los datos los extrajo **Barry Becker** del censo de Estados Unidos de 1994, filtrando adultos con ingresos y horas de trabajo positivos, y **Ronny Kohavi** los publicó en 1996 en un trabajo sobre un clasificador que combina árboles y Naive Bayes. Están en el repositorio UCI como *Adult* (o *Census Income*), separados en entrenamiento (32.561) y prueba (16.281); la versión de Orange los junta en 48.842 filas.

La versión de Orange cambia algunos nombres respecto al original: las razas *White* y *Black* aparecen como `Caucasian` y `African-American`, y los ingresos como `≤50K` y `>50K`. Su ficha indica que, para estudiar la equidad, suele tomarse el sexo como atributo protegido (con «hombre» como grupo privilegiado), y también la raza y la edad.

- Adult en el repositorio UCI. Referencia original: Kohavi, R. (1996). Scaling up the accuracy of Naive-Bayes classifiers: a decision-tree hybrid. Proceedings of KDD-96, 202–207.
- Add-on Fairness de Orange (documentación)

3 Variable objetivo

La clase es `income`: `>50K` (24 %) o `≤50K` (76 %). Decir siempre «no» acierta un 76 %.

Las diferencias entre grupos son grandes: superan los 50.000 dólares el 30 % de los hombres y el 11 % de las mujeres; el 45 % de los casados (`Married-civ-spouse`) y el 5 % de los solteros; en torno al 73 % de quienes tienen escuela profesional o doctorado y el 16 % de los graduados de secundaria. En una prueba con una muestra de 10.000 personas y validación cruzada de 5 bolsas, el bosque aleatorio acierta un 84 % (AUC 0,89) y Naive Bayes un 82 % (AUC 0,90).

4 Diccionario de columnas

Columnas de `adult` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`age`	numérica	Edad en años (de 17 a 90).	17 – 90
`workclass`	categórica	Tipo de empleador: privado, autónomo, administración federal, estatal o local, sin sueldo… 2.799 huecos.	Private (33.906), Self-emp-not-inc (3.862), Local-gov (3.136), State-gov (1.981), Self-emp-inc (1.695), Federal-gov (1.432) …
`final-weight`	numérica	Peso muestral del censo: cuántas personas de la población representa la fila. **No es una característica de la persona.**	12.285 – 1.490.400
`education`	categórica	Nivel de estudios (`HS-grad`, `Bachelors`, `Masters`…).	HS-grad (15.784), Some-college (10.878), Bachelors (8.025), Masters (2.657), Assoc-voc (2.061), 11th (1.812) …
`education-num`	numérica	Nivel de estudios como número de 1 a 16. Es exactamente la misma información que `education`.	1 – 16

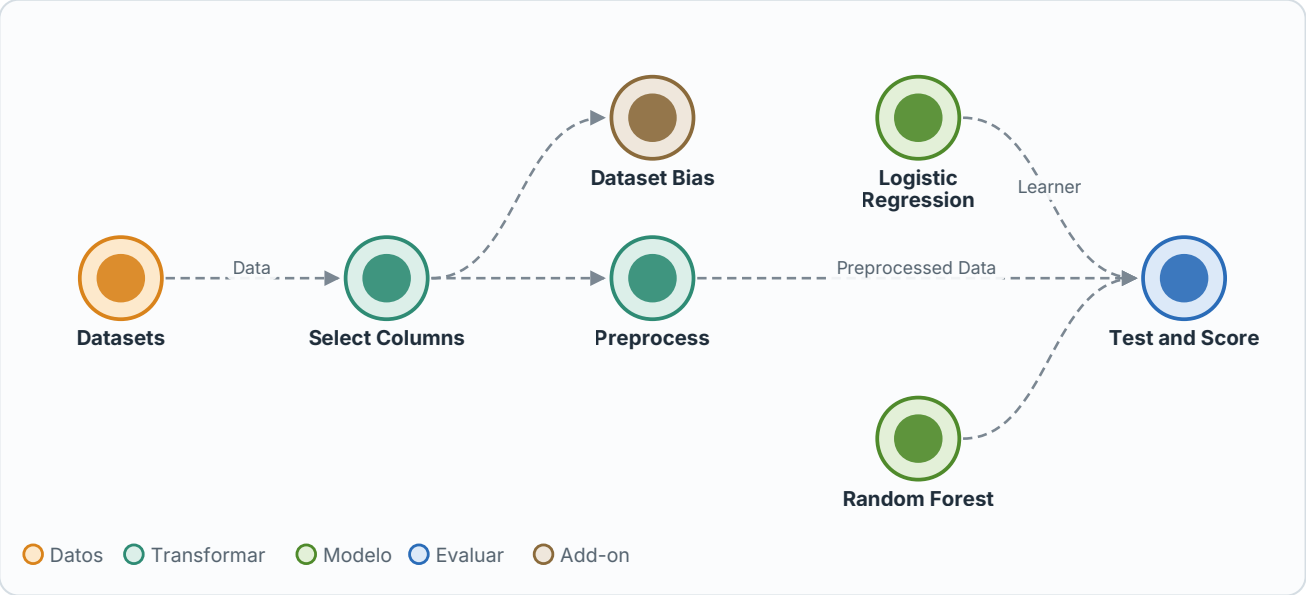
Columna	Tipo	Significado	Valores
`marital-status`	categórica	Estado civil (`Married-civ-spouse`, `Never-married`, `Divorced`…).	Married-civ-spouse (22.379), Never-married (16.117), Divorced (6.633), Separated (1.530), Widowed (1.518), Married-spouse-absent (628) …
`occupation`	categórica	Ocupación (`Exec-managerial`, `Craft-repair`, `Prof-specialty`…). 2.809 huecos.	Prof-specialty (6.172), Craft-repair (6.112), Exec-managerial (6.086), Adm-clerical (5.611), Sales (5.504), Other-service (4.923) …
`relationship`	categórica	Relación con la persona de referencia del hogar (`Husband`, `Wife`, `Own-child`…).	Husband (19.716), Not-in-family (12.583), Own-child (7.581), Unmarried (5.125), Wife (2.331), Other-relative (1.506)
`race`	categórica	Raza, con los nombres de la versión de Orange (`Caucasian`, `African-American`, `Asian-Pac-Islander`…).	Caucasian (41.762), African-American (4.685), Asian-Pac-Islander (1.519), Amer-Indian-Eskimo (470), Other (406)
`sex`	categórica	Sexo (`Male` / `Female`). Atributo protegido habitual en estudios de equidad.	Male (32.650), Female (16.192)
`capital-gain`	numérica	Ganancias de capital del año (dólares). Casi siempre 0; el valor 99.999 es un tope.	0 – 99.999
`capital-loss`	numérica	Pérdidas de capital del año (dólares). Casi siempre 0.	0 – 4.356
`hours-per-week`	numérica	Horas de trabajo por semana (de 1 a 99).	1 – 99
`native-country`	categórica	País de origen. 857 huecos; el 90 % es `United-States`.	United-States (43.832), Mexico (951), Philippines (295), Germany (206), Puerto-Rico (184), Canada (182) …
`income` `objetivo`	categórica	**Clase**: ingresos anuales `>50K` o `≤50K` (dólares de 1994).	≤50K (37.155), >50K (11.687)

5 Particularidades técnicas al modelar

- **Variables redundantes**: `education` y `education-num` son la misma información; `relationship` (*Husband*/*Wife*) lleva implícito el sexo. Quitar `sex` no basta para que un modelo deje de usarlo.
- `final-weight` **no es un atributo**: es el peso de muestreo del censo. Como predictor no tiene sentido; para estimaciones de población se usaría como ponderación.
- **Ganancias de capital muy sesgadas**: el 92 % vale 0 y hay un tope en 99.999. Discretizarla o usar una variable «tiene ganancias» suele funcionar mejor.
- **Huecos que no son al azar**: `workclass` y `occupation` faltan casi a la vez (personas sin empleo declarado).
- **Desequilibrio moderado** (24 % de ingresos altos): mira el AUC y la sensibilidad, no solo el acierto.

- **Escalas muy distintas**: normaliza antes de la regresión logística, kNN o SVM; sin normalizar, la regresión logística rinde peor que Naive Bayes.
- **Datos de 1994**: 50.000 dólares de entonces equivalen a bastante más hoy. Sirve para aprender, no para describir la sociedad actual.

6 Flujo de trabajo en Orange



1. **Datasets** → «Adult» (o **File** con el CSV).
2. **Select Columns**: quita `final-weight` y `education-num` (duplica a `education`).
3. **Preprocess**: imputar y normalizar.
4. **Test and Score** con regresión logística y bosque aleatorio; compara el AUC.
5. Con el add-on *Fairness*: **Dataset Bias** para medir la diferencia de ingresos altos entre hombres y mujeres en los datos, y después compara la equidad de un modelo normal y uno con corrección (*Reweighing*, *Adversarial Debiasing*).

7 Otras consideraciones

- **¿Quitar el sexo arregla el sesgo?** Entrena sin `sex` y mira si las predicciones siguen siendo distintas para hombres y mujeres: `relationship` y `marital-status` transportan esa información.
- **Muestras más pequeñas**: con 48.842 filas, algunos widgets van lentos. *Data Sampler* con un 20 % basta para explorar.
- **Comparar con COMPAS y German Credit**: los tres datasets de equidad del capítulo plantean problemas distintos (ingresos, reincidencia, crédito).

En la carpeta `adult` ← `adult.tab` (datasets.biolab.si)

3.02
Clasificación: negocio, sociedad y equidad

Bank Marketing (bank-additional)

`03_clasificacion_negocio_sociedad/bank_marketing/`

4.119 llamadas de una campaña de telemarketing de un banco portugués y si el cliente contrató un depósito a plazo: clasificación desequilibrada con una variable, la duración de la llamada, que no se debe usar para predecir.

Clasificación binaria · ⚖ Desbalanceado · ? Valores faltantes · ◈ Mixto num. + cat.

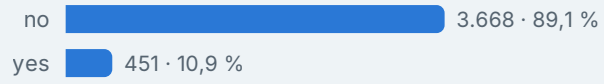
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
4.119	**21**	`y`	**4,6 %**	**Intermedio**	**Ninguno**

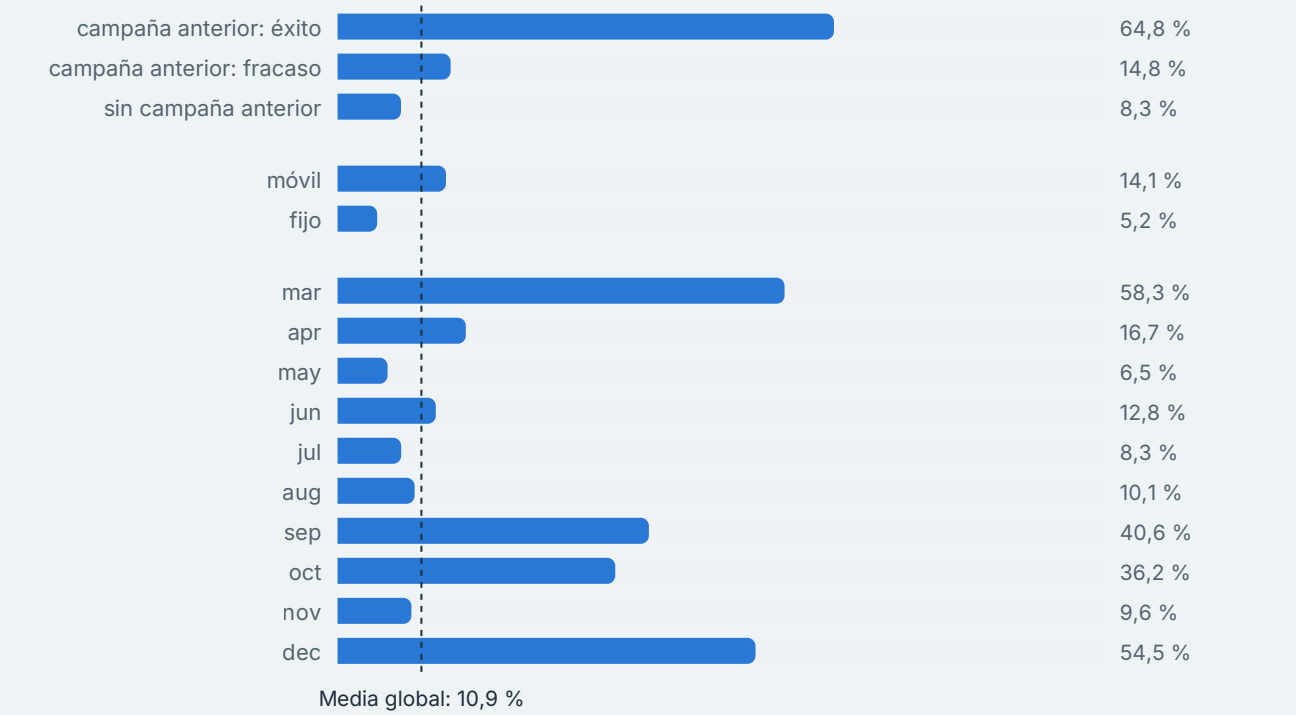
Fichero	Filas × col.	Descargar
`bank_additional`	4.119 × 21	CSV 477 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/03_clasificacion_negocio_sociedad/bank_marketing/` seguido del nombre del fichero CSV.

Radiografía

y en bank_additional





1 Descripción general y estudios habituales

Cada fila es un cliente al que el banco llamó para ofrecerle un depósito a plazo. Hay datos del cliente (edad, profesión, estado civil, estudios, impagos, hipoteca, préstamos), de la llamada (tipo de teléfono, mes, día de la semana, duración), de campañas anteriores (número de contactos, días desde el último, resultado) y **cinco indicadores económicos** del momento (tasa de variación del empleo, IPC, confianza del consumidor, euríbor a tres meses y número de empleados). La clase dice si el cliente contrató el depósito: 451 sí (11 %) y 3.668 no.

Los estudios habituales son:

- **Clasificación binaria desequilibrada** con variables mixtas.
- **Detectar fugas de información**: la duración de la llamada solo se conoce cuando la llamada ha terminado.
- **Priorizar a quién llamar**: ordenar a los clientes por probabilidad y ver cuántos éxitos se consiguen con las primeras llamadas (curva de ganancia).

2 Contexto y fuente original

Los datos son de un banco portugués que hizo campañas de telemarketing entre mayo de 2008 y noviembre de 2010. Los publicaron **Sérgio Moro, Paulo Cortez y Paulo Rita** en 2014, en un trabajo que añadía indicadores socioeconómicos a los datos del cliente y de la llamada. El dataset completo (*bank-additional-full*) tiene 41.188 llamadas; este, *bank-additional*, es una **muestra aleatoria del 10 %** que se distribuye para probar algoritmos lentos. Está en el repositorio UCI como *Bank Marketing*.

- Moro, S., Cortez, P. y Rita, P. (2014). A data-driven approach to predict the success of bank telemarketing. Decision Support Systems, 62, 22–31.
- Bank Marketing en el repositorio UCI

3 Variable objetivo

La clase es `y` : `yes` si el cliente contrató el depósito (451, el 11 %) y `no` (3.668). Decir siempre «no» ya acierta un 89 %, así que el acierto sirve de poco: hay que mirar el AUC o la sensibilidad.

Lo que más ayuda es el resultado de campañas anteriores (contrató el 65 % de los que ya habían aceptado antes, frente al 8 % de los que no habían sido contactados) y el contexto económico (el euríbor medio era de 2,1 % en las llamadas con éxito y de 3,8 % en las demás). En una prueba con validación cruzada de 10 bolsas y **sin la duración**, la regresión logística y el bosque aleatorio llegan a un AUC de 0,75–0,76; con la duración, a 0,93.

4 Diccionario de columnas

Columnas de `bank_additional` (valores observados en el fichero)

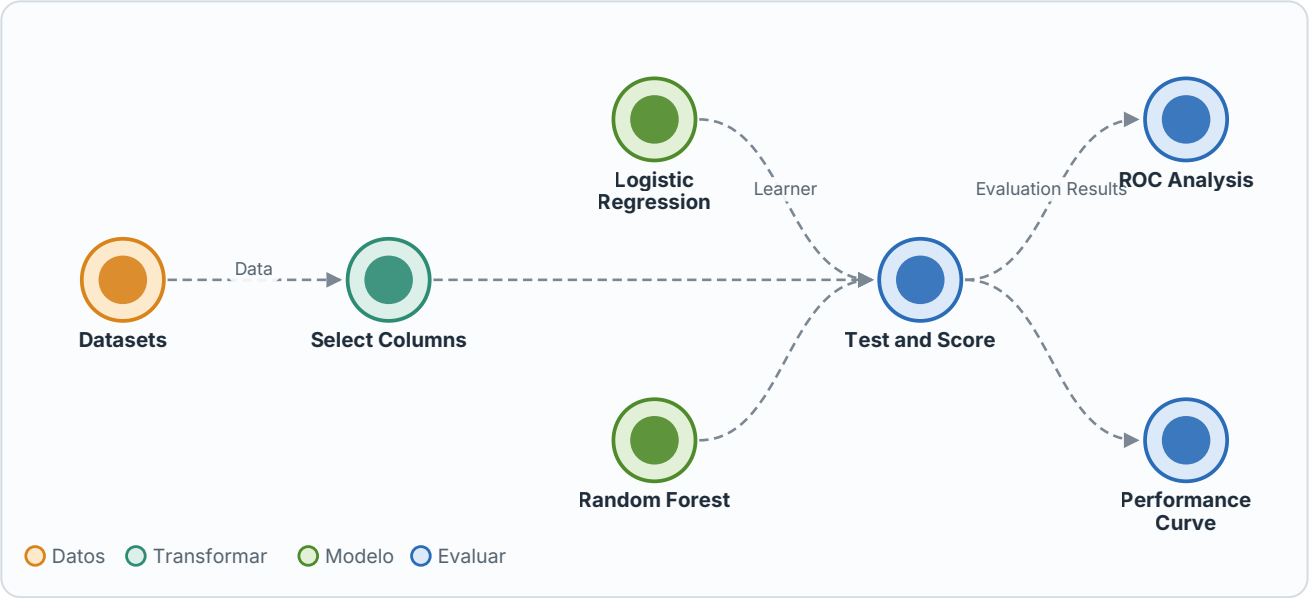
Columna	Tipo	Significado	Valores
`age`	numérica	Edad del cliente.	18 – 88
`job`	categórica	Profesión (`admin.` , `blue-collar` , `technician` , `services` …, `unknown`).	admin. (1.012), blue-collar (884), technician (691), services (393), management (324), retired (166) …
`marital`	categórica	Estado civil (`married` , `single` , `divorced` , `unknown`).	married (2.509), single (1.153), divorced (446), unknown (11)
`education`	categórica	Estudios (`basic.4y` , `high.school` , `university.degree` …, `unknown`).	university.degree (1.264), high.school (921), basic.9y (574), professional.course (535), basic.4y (429), basic.6y (228) …
`default`	categórica	Si tiene créditos impagados (`yes` , `no` , `unknown`).	no (3.315), unknown (803), yes (1)
`housing`	categórica	Si tiene hipoteca.	yes (2.175), no (1.839), unknown (105)
`loan`	categórica	Si tiene un préstamo personal.	no (3.349), yes (665), unknown (105)
`contact`	categórica	Tipo de teléfono de contacto: `cellular` (móvil) o `telephone` (fijo).	cellular (2.652), telephone (1.467)
`month`	categórica	Mes de la última llamada.	may (1.378), jul (711), aug (636), jun (530), nov (446), apr (215) …
`day_of_week`	categórica	Día de la semana de la última llamada.	thu (860), mon (855), tue (841), wed (795), fri (768)
`duration`	numérica	Duración de la última llamada en segundos. **Solo se conoce al terminar la llamada: es fuga de información.**	0 – 3.643
`campaign`	numérica	Número de contactos con el cliente en esta campaña (incluida la última llamada).	1 – 35
`pdays`	numérica	Días desde el último contacto en una campaña anterior. **Vacío = nunca contactado** (en el original, 999).	0 – 21

Columna	Tipo	Significado	Valores
`previous`	numérica	Número de contactos en campañas anteriores.	0 – 6
`poutcome`	categórica	Resultado de la campaña anterior: `success`, `failure` o `nonexistent`.	nonexistent (3.523), failure (454), success (142)
`emp.var.rate`	numérica	Tasa de variación del empleo (trimestral).	-3,4 – 1,4
`cons.price.idx`	numérica	Índice de precios al consumo (mensual).	92,201 – 94,767
`cons.conf.idx`	numérica	Índice de confianza del consumidor (mensual).	-50,8 – -26,9
`euribor3m`	numérica	Euríbor a tres meses (diario).	0,635 – 5,045
`nr.employed`	numérica	Número de empleados, en miles (trimestral).	4.963,6 – 5.228,1
y `objetivo`	categórica	**Clase**: si contrató el depósito a plazo (`yes` / `no`).	no (3.668), yes (451)

5 Particularidades técnicas al modelar

- **La duración es fuga de información**: una llamada larga casi siempre acaba en contratación (561 segundos de media con éxito frente a 219 sin él), pero la duración no se sabe antes de llamar. La propia documentación del dataset recomienda quitarla si se quiere un modelo realista. Con ella, el AUC pasa de 0,76 a 0,93.
- `pdays` **vacío no es un dato perdido**: significa que el cliente no había sido contactado nunca (3.959 de 4.119). Si se imputa con la media, se inventa un contacto que no existió.
- `unknown` **como valor**: varias variables categóricas usan `unknown` en lugar de vacío. Orange lo trata como una categoría más, lo que está bien.
- **Indicadores económicos repetidos**: los cinco toman pocos valores (uno por mes o trimestre) y son casi un sustituto de la fecha. Ayudan mucho, pero un modelo entrenado con 2008–2010 no sabe qué hacer con otro contexto.
- **Desequilibrio** (11 % de éxitos): usa AUC, curva de ganancia o *lift*, y prueba a reponderar las clases.

6 Flujo de trabajo en Orange



1. **Datasets** → «Bank Marketing» (o **File** con el CSV).
2. **Select Columns**: quita `duration`.
3. **Test and Score** con regresión logística y bosque aleatorio; ordena por AUC.
4. **ROC Analysis** y **Performance Curve** (*Lift* o *Cumulative gains*): con el 20 % de llamadas mejor puntuadas, ¿qué porcentaje de contrataciones se consigue?
5. Repite con `duration` para ver cuánto «mejora» el modelo con una variable que no se puede usar.

7 Otras consideraciones

- **El dataset completo**: el repositorio UCI tiene las 41.188 llamadas (*bank-additional-full*). Con más datos, los resultados son más estables.
- **Coste de las llamadas**: si cada llamada cuesta y cada contratación aporta un beneficio, el umbral óptimo no es 0,5. Es un buen ejercicio de decisión con *Performance Curve*.
- **Modelo «antes de la campaña»**: quita también `campaign` (número de llamadas de esta campaña) para quedarte solo con lo que se sabe antes de la primera llamada.

En la carpeta `bank_additional` ← `bank-additional.tab` (datasets.biolab.si)

3.03
Clasificación: negocio, sociedad y equidad

German Credit

`03_clasificacion_negocio_sociedad/german_credit/`

1.000 solicitantes de crédito de un banco alemán, clasificados como buen o mal riesgo: clasificación con costes asimétricos (dar crédito a un mal pagador cuesta cinco veces más) y uno de los datasets de referencia sobre equidad.

Clasificación binaria · ⚑ Sesgo y equidad · ◈ Mixto num. + cat.

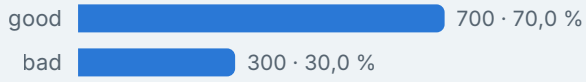
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
1.000	**21**	`Credit`	**0,0 %**	**Intermedio**	**Ninguno**

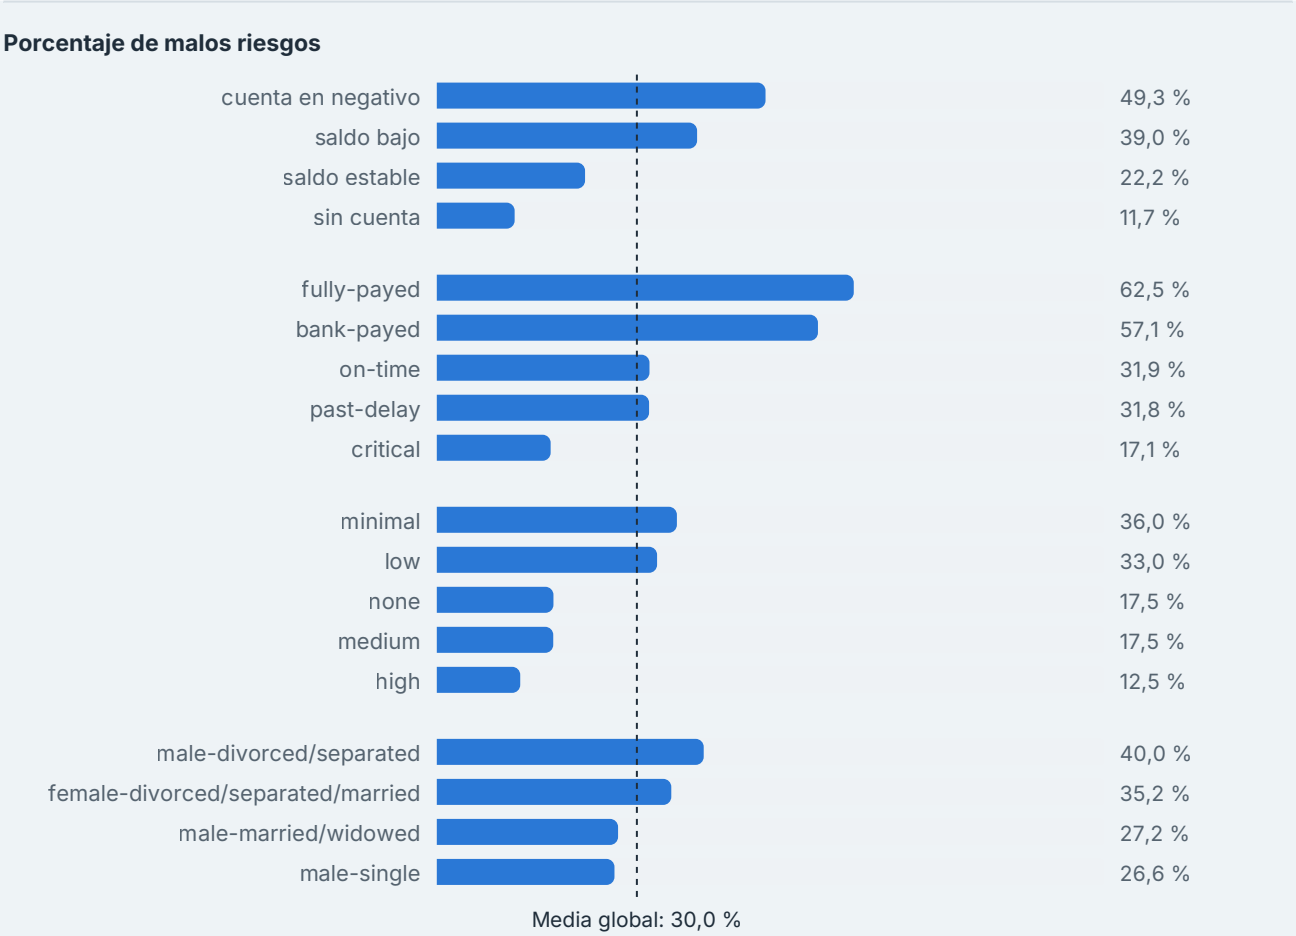
Fichero	Filas × col.	Descargar
`german_credit`	1.000 × 21	CSV 169 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/03_clasificacion_negocio_sociedad/german_credit/` seguido del nombre del fichero CSV.

Radiografía

Credit en german_credit





1 Descripción general y estudios habituales

Cada fila es una persona que pidió un préstamo, con 20 variables: estado de la cuenta corriente, duración y cantidad del crédito, historial de créditos, finalidad, ahorros, antigüedad en el empleo, porcentaje de la renta que se va en cuotas, estado civil y sexo, avalistas, propiedades, edad, vivienda, empleo, teléfono y si es trabajador extranjero. La clase dice si el banco la consideró **buen riesgo** (700) o **mal riesgo** (300).

Los estudios habituales son:

- **Clasificación con costes**: equivocarse con un mal pagador es mucho peor que con un buen cliente.
- **Equidad**: ¿perjudica el modelo a las mujeres, a los jóvenes o a los extranjeros?
- **Modelos de puntuación de crédito** interpretables (regresión logística, *scorecards*).

2 Contexto y fuente original

Lo donó **Hans Hofmann** (Universidad de Hamburgo) en 1994 dentro del proyecto europeo Statlog, que comparó algoritmos de clasificación en muchos datasets. Está en el repositorio UCI como *Statlog (German Credit Data)*. La documentación original incluye una **matriz de costes**: clasificar como bueno a un mal pagador cuesta 5, y clasificar como malo a un buen cliente cuesta 1.

En el original, las variables categóricas venían codificadas (`A11` , `A12` ...). La versión de Orange las traduce a palabras (`negative` , `low` , `stable` ...), lo que facilita mucho la lectura. Según su ficha, en estudios de equidad suele tomarse el sexo como atributo protegido, y también la edad (25 años o menos frente a más de 25).

- Hofmann, H. (1994). Statlog (German Credit Data). UCI Machine Learning Repository.

3 Variable objetivo

La clase es `Credit` : `good` (700, buen riesgo) o `bad` (300, mal riesgo). Decir siempre «bueno» acierta un 70 %.

El estado de la cuenta corriente es lo que más separa: entre quienes no tienen cuenta, solo un 12 % son malos riesgos; entre quienes tienen saldo negativo, un 49 %. También pesan el historial, la duración del préstamo y los ahorros. En una prueba con validación cruzada de 10 bolsas, el bosque aleatorio acierta un 76 % y Naive Bayes y la regresión logística un 75 % (AUC 0,78–0,79): poco por encima del 70 % de base.

4 Diccionario de columnas

Columnas de `german_credit` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Credit` objetivo	categórica	**Clase**: `good` (buen riesgo) o `bad` (mal riesgo).	good (700), bad (300)
`Status of existing checking account`	categórica	Estado de la cuenta corriente: `negative` (< 0 marcos), `low` (0–200), `stable` (≥ 200 o nómina domiciliada) o `none` (sin cuenta).	none (394), negative (274), low (269), stable (63)
`Duration in month`	numérica	Duración del préstamo en meses (de 4 a 72).	4 – 72
`Credit history`	categórica	Historial: `critical` (cuenta crítica o créditos en otros bancos), `past-delay` (retrasos en el pasado), `on-time` (créditos actuales pagados a tiempo hasta ahora), `bank-payed` (todos los créditos de este banco pagados), `fully-payed` (sin créditos o todos pagados).	on-time (530), critical (293), past-delay (88), bank-payed (49), fully-payed (40)
`Purpose`	categórica	Finalidad: coche nuevo o usado, muebles, radio/televisión, electrodomésticos, reparaciones, educación, negocio…	radio/television (280), car-new (234), furniture/equipement (181), car-used (103), business (97), education (50) …
`Credit amount`	numérica	Cantidad del crédito (marcos alemanes).	250 – 18.424
`Savings account/bonds`	categórica	Ahorros: `minimal` (< 100 marcos), `low` (100–500), `medium` (500–1.000), `high` (≥ 1.000) o `none` (desconocidos o sin ahorros).	minimal (603), none (183), low (103), medium (63), high (48)
`Present employment since`	categórica	Antigüedad en el empleo: `unemployed`, `less-than-1`, `good-to-4` (1–4 años), `4-to-7`, `7-plus`.	good-to-4 (339), 7-plus (253), 4-to-7 (174), less-than-1 (172), unemployed (62)
`Installment rate in percentage of disposable income`	numérica	Cuota como porcentaje de la renta disponible (1 a 4: de menos de 20 % a más de 35 %).	1 – 4

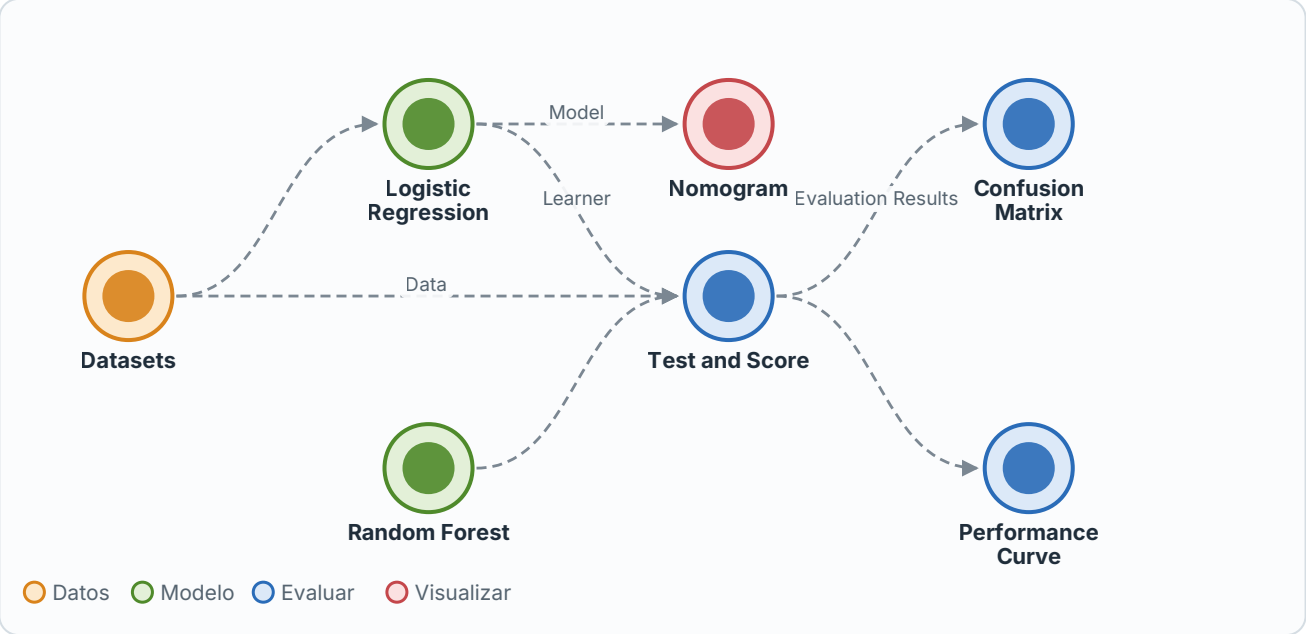
Columna	Tipo	Significado	Valores
`Personal status and sex`	categórica	Sexo y estado civil combinados. **No hay ninguna categoría de mujer soltera** en los datos.	male-single (548), female-divorced/separated/married (310), male-married/widowed (92), male-divorced/separated (50)
`Other debtors / guarantors`	categórica	Otros deudores o avalistas: `none`, `co-applicant`, `guarantor`.	none (907), guarantor (52), co-applicant (41)
`Present residence since`	numérica	Años en la vivienda actual (1 a 4).	1 – 4
`Property`	categórica	Propiedades: inmuebles, seguro de vida, coche u otra, o ninguna conocida.	car/other (332), real-estate (282), savings-agreement/life-insurance (232), unknown/none (154)
`Age in years`	numérica	Edad (de 19 a 75).	19 – 75
`Other installment plans`	categórica	Otros pagos a plazos: `bank`, `stores` o `none`.	none (814), bank (139), stores (47)
`Housing`	categórica	Vivienda: `own` (propia), `rent` (alquiler) o `for-free` (gratis).	own (713), rent (179), for-free (108)
`Number of existing credits at this bank`	numérica	Créditos que ya tiene en este banco (1 a 4).	1 – 4
`Job`	categórica	Empleo: no cualificado (residente o no), cualificado o alta cualificación.	skilled-employee (630), unskilled-resident (200), high-qualification (148), unskilled/non-resident (22)
`Number of people being liable to provide maintenance for`	categórica	Personas a su cargo (1 o 2).	1 (845), 2 (155)
`Telephone`	categórica	Si tiene teléfono registrado a su nombre.	no-telephone (596), registered-telephone (404)
`Foreign worker`	categórica	Si es trabajador extranjero (`foreign-worker` / `local-worker`). El 96 % lo es.	foreign-worker (963), local-worker (37)

5 Particularidades técnicas al modelar

- **Costes asimétricos**: según la documentación, un mal pagador clasificado como bueno cuesta 5 veces más que lo contrario. Un modelo con buen acierto puede ser caro. Evalúa con el coste total (o mueve el umbral de decisión) en lugar de con el acierto.

- **Sexo y estado civil mezclados**: `Personal status and sex` junta las dos cosas, y la categoría «mujer soltera» del código original no aparece ni una vez. Para estudiar la equidad por sexo, hay que separar el sexo con *Feature Constructor*.
- **Atributos sensibles**: sexo, edad y ser extranjero están entre las variables. Usarlos para decidir un crédito está prohibido o limitado en muchos países, y quitarlos no garantiza un modelo justo si otras variables los reflejan.
- **Poca mejora sobre la base**: con un 70 % de buenos clientes, los modelos apenas pasan del 75 %. Compara siempre con el modelo trivial.
- **Un historial «crítico» parece bueno**: solo el 17 % de los clientes con historial `critical` son malos riesgos, frente al 57–63 % de los que no tienen créditos o los tienen todos pagados. Probablemente refleja a quién concedió el banco créditos en el pasado (sesgo de selección), no que los morosos paguen mejor. Conviene comentarlo antes de interpretar un árbol.
- **«Trabajador extranjero» casi constante** (963 de 1.000): los 37 trabajadores locales son malos riesgos solo en un 11 %, pero son tan pocos que la diferencia es poco fiable.
- No hay valores ausentes.

6 Flujo de trabajo en Orange



1. **Datasets** → «German Credit» (o **File** con el CSV).
2. **Test and Score** con regresión logística y bosque aleatorio.
3. **Confusion Matrix**: calcula el coste con la matriz 5:1 (malos aceptados × 5 + buenos rechazados × 1).
4. **Performance Curve**: busca el umbral que minimiza ese coste; suele estar muy por debajo de 0,5 para la clase «bueno».
5. **Logistic Regression** → **Nomogram**: una tarjeta de puntuación de crédito.

7 Otras consideraciones

- **Equidad por edad**: crea una variable «25 años o menos» y compara la tasa de aprobación del modelo en cada grupo. El add-on *Fairness* de Orange tiene widgets para medirlo y corregirlo.
- **Versión numérica**: el repositorio UCI tiene también `german.data-numeric`, con las categorías ya codificadas como números.

- **Comparar con Adult y COMPAS**: los tres datasets de equidad del capítulo, con atributos protegidos distintos.

En la carpeta `german_credit` ← `german-credit-data.tab` (datasets.biolab.si)

3.04
Clasificación: negocio, sociedad y equidad

COMPAS (reincidencia a dos años)

`03_clasificacion_negocio_sociedad/compas/`

7.214 personas detenidas en Broward (Florida) en 2013–2014, su puntuación de riesgo COMPAS y si volvieron a delinquir en dos años: el dataset con el que ProPublica mostró que el algoritmo se equivoca de forma distinta según la raza.

Clasificación binaria · ⚑ Sesgo y equidad · ? Valores faltantes · ◈ Mixto num. + cat. · ◷ Temporal

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
7.214	**52**	`two_year_recid`	**17,1 %**	**Avanzado**	**Ninguno**

Fichero	Filas × col.	Descargar
`compas_scores_two_years`	7.214 × 52	CSV 2,5 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/03_clasificacion_negocio_sociedad/compas/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

COMPAS es un programa comercial que usan juzgados de Estados Unidos para estimar el riesgo de que un acusado vuelva a delinquir. Puntúa del 1 al 10 (*decile score*) y agrupa en riesgo bajo, medio o alto. Este dataset reúne a 7.214 personas evaluadas en el condado de Broward (Florida) en 2013 y 2014, con su edad, sexo, raza, antecedentes (delitos juveniles y condenas previas), el delito por el que se las evaluó, las puntuaciones de COMPAS y lo que pasó después: si volvieron a ser detenidas en los dos años siguientes.

Los estudios habituales son:

- **Equidad algorítmica**: comparar los errores de COMPAS (o de un modelo propio) entre grupos.
- **Clasificación binaria**: predecir la reincidencia con los datos disponibles en el momento de la evaluación.
- **Fugas de información**: muchas columnas describen hechos posteriores y delatan la clase.

2 Contexto y fuente original

En 2016, el medio de investigación **ProPublica** (Julia Angwin, Jeff Larson, Surya Mattu y Lauren Kirchner) consiguió las puntuaciones mediante una petición de información pública, las cruzó con los registros judiciales del condado y publicó el artículo *Machine Bias*. Su conclusión: con una tasa de acierto parecida para ambos grupos, COMPAS marcaba como de riesgo medio o alto a casi el doble de personas negras que no reincidieron que de blancas que no reincidieron, y al revés con quienes sí reincidieron. La empresa respondió que el programa estaba bien calibrado (a igual puntuación, igual reincidencia), y el debate llevó a demostrar que **no se pueden cumplir a la vez** todas las definiciones de equidad cuando los grupos tienen tasas base distintas.

ProPublica publicó los datos y el análisis en GitHub. La versión de Orange, para el add-on *Fairness*, marca `race` como atributo protegido (con `Caucasian` como grupo privilegiado) y «no reincide» como resultado favorable.

- Angwin, J., Larson, J., Mattu, S. y Kirchner, L. (2016). Machine Bias. ProPublica.
- Larson, J. et al. (2016). How We Analyzed the COMPAS Recidivism Algorithm. ProPublica.
- Datos y análisis de ProPublica en GitHub
- Add-on Fairness de Orange (documentación)

3 Variable objetivo

La clase es `two_year_recid`: `yes` si la persona fue detenida de nuevo en los dos años siguientes (3.251, el 45 %) y `no` (3.963). La reincidencia es del 51 % entre los afroamericanos y del 39 % entre los blancos.

La puntuación de COMPAS predice regular: reincide el 31 % de los clasificados como riesgo bajo y el 71 % de los de riesgo alto, y la puntuación sola da un AUC de 0,70. En una prueba con validación cruzada de 10 bolsas, una regresión logística con edad, sexo, raza, antecedentes y grado del delito acierta un 68 % (AUC 0,72): casi lo mismo que COMPAS.

La diferencia está en el tipo de error (gráfico de la radiografía). Entre quienes **no** reincidieron, COMPAS puso riesgo medio o alto al 45 % de los afroamericanos y al 24 % de los blancos (falsos positivos). Entre quienes **sí** reincidieron, puso riesgo bajo al 28 % de los afroamericanos y al 48 % de los blancos (falsos negativos).

4 Diccionario de columnas

Columnas de `compas_scores_two_years` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`two_year_recid` objetivo	categórica	**Clase**: si fue detenido de nuevo en los dos años siguientes a la evaluación.	no (3.963), yes (3.251)
`id`	numérica	Identificador de la persona.	1 – 11.001
`compas_screening_date`	fecha/hora	Fecha de la evaluación COMPAS (2013–2014).	2013-02-20 (32), 2013-03-20 (32), 2013-02-07 (31), 2013-04-20 (30), 2013-01-03 (29), 2013-09-06 (28) …
dob	fecha/hora	Fecha de nacimiento.	1994-07-15 (5), 1989-04-27 (5), 1987-02-04 (5), 1990-05-02 (5), 1990-02-22 (5), 1989-08-31 (5) …

Columna	Tipo	Significado	Valores
`c_jail_in`	fecha/hora	Entrada en prisión por el delito evaluado (c_ = *current charge*).	2013-08-13 06:03:42 (1), 2013-01-26 03:45:27 (1), 2013-04-13 04:58:34 (1), 2013-11-30 04:50:18 (1), 2014-02-18 05:08:24 (1), 2013-08-29 08:55:23 (1) …
`r_offense_date`	fecha/hora	Fecha del nuevo delito (*r_* = reincidencia). **Posterior a la evaluación: fuga.**	2014-12-08 (12), 2015-01-28 (11), 2014-09-15 (10), 2014-10-17 (10), 2015-02-10 (10), 2015-03-11 (10) …
`vr_offense_date`	fecha/hora	Fecha del nuevo delito violento (*vr_*). **Fuga.**	2015-08-15 (6), 2013-11-14 (4), 2015-02-05 (4), 2015-09-04 (4), 2014-02-18 (4), 2015-04-27 (4) …
`name`	texto	Nombre y apellido de la persona. **Datos personales reales: no se muestran.** Junto con `first` y `last`.	(no se muestran)
`c_case_number`	texto	Número de caso judicial (también `r_case_number`, `vr_case_number`). No se muestran.	(no se muestran)
`c_charge_desc`	texto	Descripción del delito evaluado.	Battery (1.156), arrest case no charge (1.137), Possession of Cocaine (474), Grand Theft in the 3rd Degree (425), Driving While License Revoked (200), Driving Under The Influence (135) …
`sex`	categórica	Sexo.	Male (5.819), Female (1.395)
`age`	numérica	Edad en la evaluación (de 18 a 96).	18 – 96
`age_cat`	categórica	Grupo de edad: menos de 25, de 25 a 45, más de 45.	25 - 45 (4.109), Greater than 45 (1.576), Less than 25 (1.529)
`race`	categórica	Raza según el registro policial. **Atributo protegido** en el add-on Fairness.	African-American (3.696), Caucasian (2.454), Hispanic (637), Other (377), Asian (32), Native American (18)
`juv_fel_count`	numérica	Delitos graves (*felonies*) cometidos de menor.	0 – 20
`decile_score (1)`	numérica	Puntuación COMPAS de riesgo de reincidencia (1–10). `decile_score (2)` es la misma columna repetida.	1 – 10

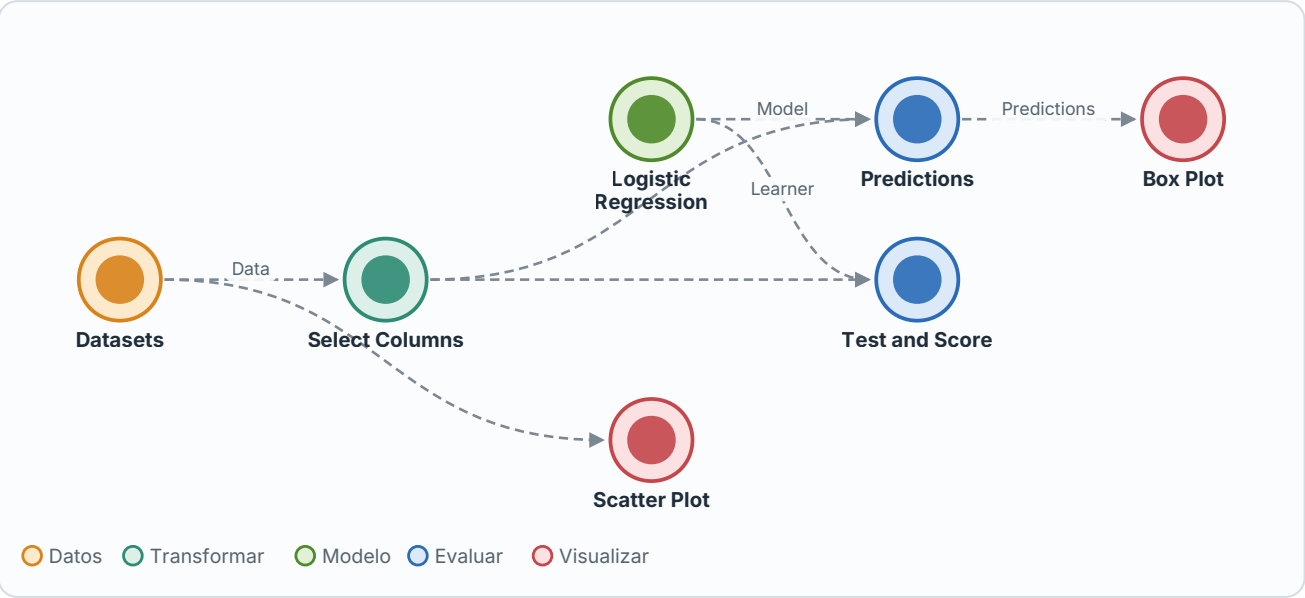
Columna	Tipo	Significado	Valores
`juv_misd_count`	numérica	Delitos menores (*misdemeanors*) cometidos de menor.	0 – 13
`juv_other_count`	numérica	Otros antecedentes juveniles.	0 – 17
`priors_count (1)`	numérica	Número de condenas previas (0–38). `priors_count (2)` es la misma columna repetida.	0 – 38
`days_b_screening_arrest`	numérica	Días entre la detención y la evaluación. ProPublica descarta los casos con más de 30 días.	-414 – 1.057
`c_charge_degree`	categórica	Grado del delito evaluado: `F` (grave, *felony*) o `M` (menor, *misdemeanor*).	F (4.666), M (2.548)
`is_recid`	categórica	Si reincidió (en cualquier plazo). **Casi idéntica a la clase: fuga.**	0 (3.743), 1 (3.471)
`r_charge_degree`	categórica	Grado del nuevo delito. **Fuga.**	(M1) (1.201), (M2) (1.107), (F3) (892), (F2) (168), (F1) (51), (MO3) (39) …
`is_violent_recid`	categórica	Si reincidió con un delito violento. **Fuga.**	0 (6.395), 1 (819)
`vr_charge_desc`	categórica	Descripción del nuevo delito violento. **Fuga** (y es atributo en la versión de Orange).	Battery (329), Battery on Law Enforc Officer (38), Felony Battery (Dom Strang) (38), Aggravated Assault W/ Dead Weap (37), Aggrav Battery w/ Deadly Weapon (34), Aggravated Battery / Pregnant (31) …
`score_text`	categórica	Puntuación COMPAS agrupada: `Low` (1–4), `Medium` (5–7), `High` (8–10).	Low (3.897), Medium (1.914), High (1.403)
`v_decile_score`	numérica	Puntuación COMPAS de riesgo de violencia (1–10).	1 – 10
`v_score_text`	categórica	Riesgo de violencia agrupado.	Low (4.761), Medium (1.739), High (714)
`start`	numérica	Inicio del periodo de seguimiento (días), para análisis de supervivencia. **Fuga.**	0 – 937

Columna	Tipo	Significado	Valores
end	numérica	Fin del periodo de seguimiento (días). **Fuga.**	0 – 1.186
event	categórica	Si hubo reincidencia en el periodo de seguimiento. **Fuga.**	0 (4.452), 1 (2.762)
…		y 21 columnas más del mismo tipo que la anterior.	

5 Particularidades técnicas al modelar

- **Fugas de información por todas partes**: todo lo que empieza por `r_` o `vr_`, `is_recid`, `is_violent_recid`, `start`, `end` y `event` describe lo que pasó **después** de la evaluación. `is_recid` casi es la clase (todos los `is_recid = 0` son `no`; de los 3.471 con `is_recid = 1`, 3.251 son `yes`): con ella, el acierto sube al 97 %. Antes de modelar, quédate con datos del momento de la evaluación: edad, sexo, raza, antecedentes y delito actual.
- **Las puntuaciones de COMPAS son atributos**: si se dejan, el modelo aprende de COMPAS. Para comparar «mi modelo frente a COMPAS», quítalas.
- **Columnas duplicadas**: `decile_score (1)` y `(2)`, y `priors_count (1)` y `(2)`, son idénticas (el original las repetía y Orange las renombró).
- **Datos personales reales**: hay nombres, apellidos y números de caso de personas reales. Son metas y no deben mostrarse ni usarse; en este libro no se enseñan sus valores.
- **Raza muy desigual**: 3.696 afroamericanos, 2.454 blancos, 637 hispanos, 377 «otros», 32 asiáticos y 18 nativos americanos. Los análisis de equidad suelen comparar solo los dos primeros grupos.
- **La clase no es «delinquir» sino «ser detenido»**: si la policía patrulla más unos barrios que otros, la etiqueta ya trae el sesgo.

6 Flujo de trabajo en Orange



1. **Datasets** → «COMPAS» (o **File** con el CSV; marca como `meta` los nombres y números de caso).
2. **Select Columns**: deja `sex`, `age`, `race`, `juv_*`, `priors_count (1)` y `c_charge_degree`; quita fugas, puntuaciones COMPAS y duplicados.

3. **Test and Score** con regresión logística: compara el acierto y el AUC con los de `decile_score` sola.
4. **Predictions** → **Box Plot** (o **Distributions**) agrupando por `race`: compara falsos positivos y negativos.
5. Con el add-on **Fairness**, usa *Dataset Bias* y *Reweighing* o *Equal Odds Postprocessing* para medir y corregir.

7 Otras consideraciones

- **Las definiciones de equidad chocan**: calibración (misma reincidencia a igual puntuación), igualdad de falsos positivos y de falsos negativos no pueden cumplirse a la vez con tasas base distintas. Es el resultado de Kleinberg, Mullainathan y Raghavan, y de Chouldechova (2016–2017).
- **Quitar la raza no basta**: los antecedentes y la edad están correlacionados con ella. Prueba a quitar `race` y compara los errores por grupo.
- **Reincidencia violenta**: el repositorio de ProPublica tiene también `compas-scores-two-years-violent.csv`, con la puntuación de violencia como objetivo.
- **Filtro de ProPublica**: su análisis se queda con los casos con `days_b_screening_arrest` entre −30 y 30, con `is_recid` distinto de −1 y sin delitos de tráfico (`c_charge_degree` distinto de `O`). Esta versión ya no tiene `O`, pero no aplica el filtro de días: 735 casos quedan fuera de ese margen.

En la carpeta `compas_scores_two_years` ← `compas-scores-two-years.tab` (datasets.biolab.si)

3.05
Clasificación: negocio, sociedad y equidad

Telco Customer Churn

`03_clasificacion_negocio_sociedad/telecom_churn/`

7.043 clientes de una compañía de telecomunicaciones ficticia y si se dieron de baja en el último mes: el ejemplo clásico de predicción de abandono (*churn*), con servicios contratados, tipo de contrato y facturación.

Clasificación binaria · ? Valores faltantes · ◈ Mixto num. + cat.

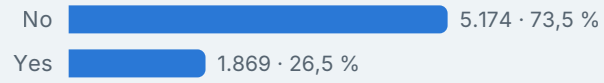
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
7.043	**21**	`Churn`	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`telecom_churn`	7.043 × 21	CSV 970 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/03_clasificacion_negocio_sociedad/telecom_churn/` seguido del nombre del fichero CSV.

Radiografía

Churn en telecom_churn



Porcentaje de clientes que se dieron de baja



1 Descripción general y estudios habituales

Cada fila es un cliente con sus datos demográficos (sexo, si es mayor de 65 años, si tiene pareja o personas a su cargo), los servicios que tiene contratados (teléfono, varias líneas, internet por DSL o fibra, seguridad, copias de seguridad, protección del dispositivo, soporte técnico, televisión y películas en *streaming*), su cuenta (meses de antigüedad, tipo de contrato, factura electrónica, forma de pago, cuota mensual y total facturado) y si **se dio de baja** en el último mes.

Los estudios habituales son:

- **Clasificación binaria** para predecir qué clientes se irán.
- **Interpretación**: qué factores se asocian al abandono (contrato, antigüedad, fibra, forma de pago).
- **Decisiones de retención**: a quién ofrecer un descuento, con curvas de ganancia y costes.

2 Contexto y fuente original

Es un dataset de ejemplo creado por **IBM** para sus herramientas de analítica, con una empresa de telecomunicaciones ficticia. Se hizo popular al publicarse en **Kaggle**, donde es uno de los datasets más usados para enseñar *churn*. No son datos reales de ninguna compañía.

- Telco Customer Churn en Kaggle (muestra de IBM)

3 Variable objetivo

La clase es `Churn`: `Yes` si el cliente se dio de baja (1.869, el 27 %) o `No` (5.174). Decir siempre «no» acierta un 73 %.

El tipo de contrato es lo que más separa: se va el 43 % de los clientes mes a mes, el 11 % de los de contrato anual y el 3 % de los de dos años. También se van más los que tienen fibra (42 %), los que pagan con cheque electrónico (45 %), los que no tienen soporte técnico ni seguridad en línea (42 %) y los clientes recientes: la antigüedad mediana es de 10 meses entre los que se van y de 38 entre los que se quedan. En una prueba con validación cruzada de 10 bolsas, la regresión logística acierta un 80,5 % (AUC 0,84).

4 Diccionario de columnas

Columnas de `telecom_churn` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`customerID`	texto	Identificador del cliente (meta).	7590-VHVEG (1), 5575-GNVDE (1), 3668-QPYBK (1), 7795-CFOCW (1), 9237-HQITU (1), 9305-CDSKC (1) …
`gender`	categórica	Sexo.	Male (3.555), Female (3.488)
`SeniorCitizen`	categórica	Si es mayor de 65 años (`1`) o no (`0`).	0 (5.901), 1 (1.142)
`Partner`	categórica	Si tiene pareja.	No (3.641), Yes (3.402)
`Dependents`	categórica	Si tiene personas a su cargo.	No (4.933), Yes (2.110)
`tenure`	numérica	Meses que lleva como cliente (de 0 a 72).	0 – 72
`PhoneService`	categórica	Si tiene línea de teléfono.	Yes (6.361), No (682)

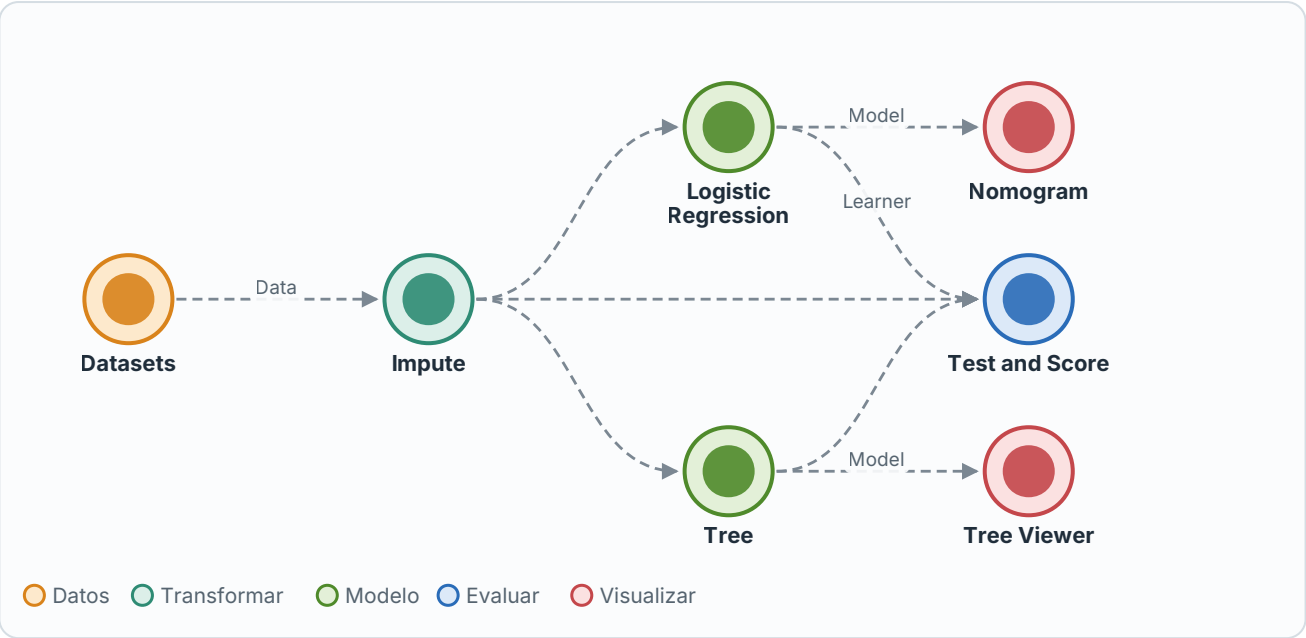
Columna	Tipo	Significado	Valores
`MultipleLines`	categórica	Si tiene varias líneas (`No phone service` si no tiene teléfono).	No (3.390), Yes (2.971), No phone service (682)
`InternetService`	categórica	Tipo de internet: `DSL`, `Fiber optic` (fibra) o `No`.	Fiber optic (3.096), DSL (2.421), No (1.526)
`OnlineSecurity`	categórica	Si tiene el servicio de seguridad en línea (`No internet service` si no tiene internet).	No (3.498), Yes (2.019), No internet service (1.526)
`OnlineBackup`	categórica	Si tiene copias de seguridad en línea.	No (3.088), Yes (2.429), No internet service (1.526)
`DeviceProtection`	categórica	Si tiene seguro del dispositivo.	No (3.095), Yes (2.422), No internet service (1.526)
`TechSupport`	categórica	Si tiene soporte técnico.	No (3.473), Yes (2.044), No internet service (1.526)
`StreamingTV`	categórica	Si tiene televisión en *streaming*.	No (2.810), Yes (2.707), No internet service (1.526)
`StreamingMovies`	categórica	Si tiene películas en *streaming*.	No (2.785), Yes (2.732), No internet service (1.526)
`Contract`	categórica	Tipo de contrato: `Month-to-month` (mes a mes), `One year` o `Two year`.	Month-to-month (3.875), Two year (1.695), One year (1.473)
`PaperlessBilling`	categórica	Si recibe la factura en formato electrónico.	Yes (4.171), No (2.872)
`PaymentMethod`	categórica	Forma de pago: cheque electrónico, cheque por correo, transferencia o tarjeta (estas dos, automáticas).	Electronic check (2.365), Mailed check (1.612), Bank transfer (automatic) (1.544), Credit card (automatic) (1.522)
`MonthlyCharges`	numérica	Cuota mensual en dólares (de 18,25 a 118,75).	18,25 – 118,75
`TotalCharges`	numérica	Total facturado en dólares. Vacío en 11 clientes con antigüedad 0.	18,8 – 8.684,8
`Churn` `objetivo`	categórica	**Clase**: si se dio de baja en el último mes.	No (5.174), Yes (1.869)

5 Particularidades técnicas al modelar

- `TotalCharges` **es casi** `tenure × MonthlyCharges` (difiere en un 2 % de mediana). Aporta poco que no esté ya en las otras dos y las tres juntas están muy correlacionadas, lo que afecta a la interpretación de la regresión.
- **11 valores vacíos** en `TotalCharges`, todos de clientes con antigüedad 0 (aún no se les ha facturado). Lo lógico es rellenarlos con 0, no con la media.
- **«No internet service» repetido**: seis variables tienen ese valor para los mismos 1.526 clientes. Es redundante con `InternetService = No`, y algunos análisis lo funden con `No`.

- **Datos sintéticos**: las relaciones son verosímiles pero inventadas. Sirve para aprender, no para sacar conclusiones sobre el mercado real.
- **Desequilibrio moderado** (27 % de bajas): mira también la sensibilidad o el AUC.

6 Flujo de trabajo en Orange



1. **Datasets** → «Telecom Customer Churn» (o **File** con el CSV).
2. **Impute**: para `TotalCharges`, valor fijo 0.
3. **Test and Score** con regresión logística y árbol.
4. **Nomogram**: qué variables empujan hacia la baja. **Tree Viewer** (profundidad 3–4): el contrato mes a mes y la fibra suelen aparecer arriba.
5. **Distributions** o **Mosaic Display** con `Contract` y `Churn` para enseñar la relación más clara.

7 Otras consideraciones

- **Rangos de antigüedad**: con *Discretize* o *Feature Constructor*, agrupa `tenure` en tramos de 12 meses y mira cómo cae el abandono con los años.
- **Campaña de retención**: si ofrecer un descuento cuesta poco y perder un cliente mucho, interesa un umbral bajo. Usa *Performance Curve* para elegirlo.
- **Otros datasets de abandono**: IBM HR Attrition (empleados) en este mismo capítulo usa la misma idea con otro tipo de «cliente».

En la carpeta `telecom_churn` ← `telecom-customer-churn.xlsx` (datasets.biolab.si)

3.06
Clasificación: negocio, sociedad y equidad

IBM HR Employee Attrition

`03_clasificacion_negocio_sociedad/ibm_hr_attrition/`

1.470 empleados ficticios de una empresa, creados por IBM, para predecir quién deja la empresa: lo hace el 16 %.

Clasificación binaria · ⚖ Desbalanceado · ◈ Mixto num. + cat. · ✎ Sintético

En el curso: Actividad 2.1a (Tema 2, desbalanceo: reponderación y validación estratificada) y Tema 3 (ensembles), con «Attrition - Train» desde el widget Datasets.

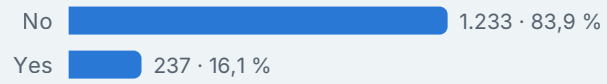
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
1.470	**33**	`Attrition`	**0,0 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`hrm_employee_attrition`	1.470 × 33	CSV 217 KB · XLSX
`attrition_train`	1.470 × 19	CSV 155 KB · XLSX
`attrition_predict`	3 × 19	CSV 1 KB · XLSX

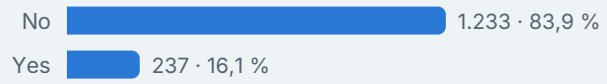
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/03_clasificacion_negocio_sociedad/ibm_hr_attrition/` seguido del nombre del fichero CSV.

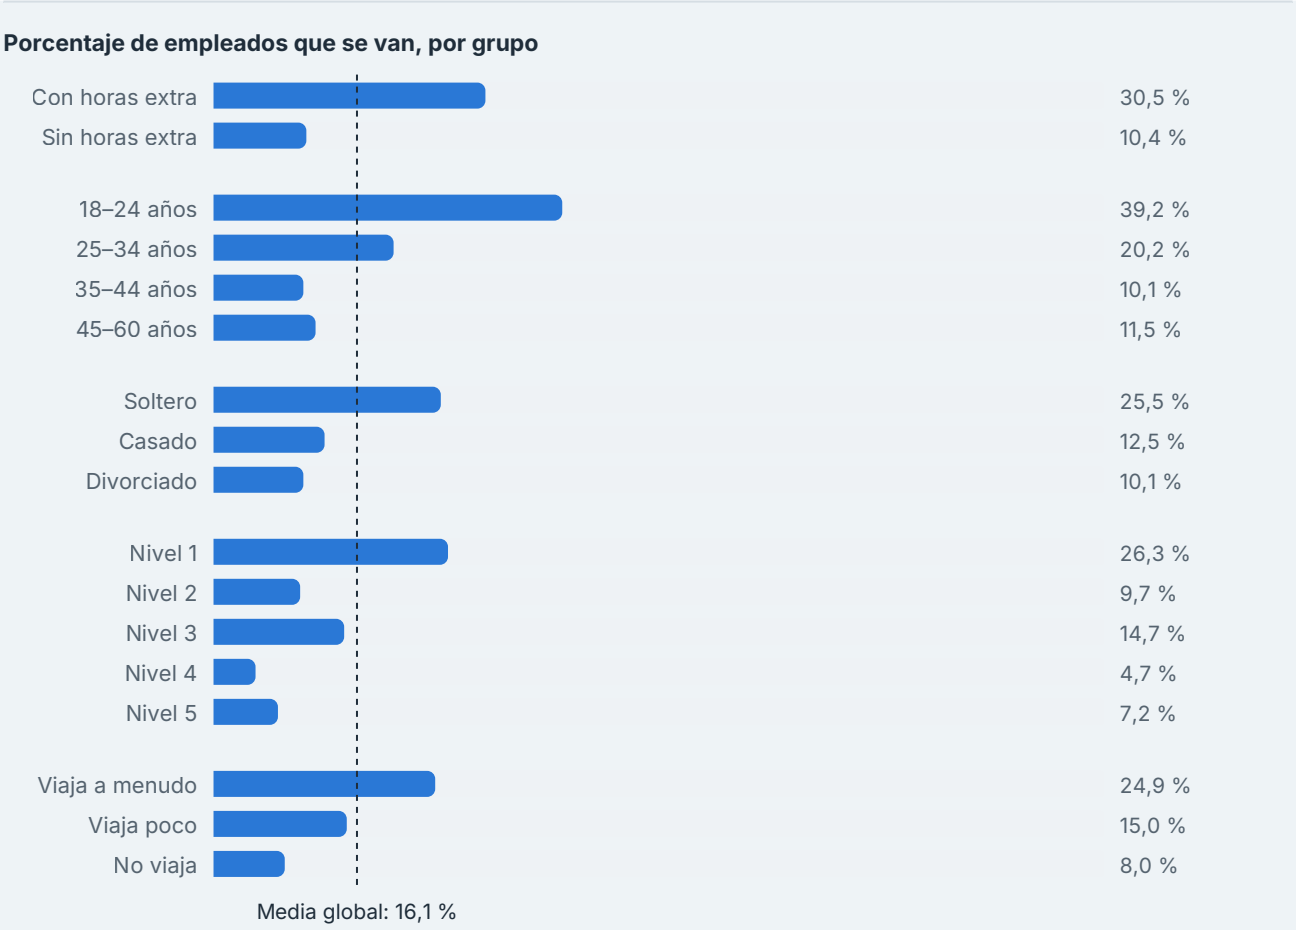
Radiografía

Attrition en hrm_employee_attrition



Attrition en attrition_train





1 Descripción general y estudios habituales

Cada fila es un empleado, con datos personales (edad, sexo, estado civil, distancia de casa al trabajo), de su puesto (departamento, rol, nivel, horas extra, viajes), de su retribución (sueldo mensual, subida salarial, opciones sobre acciones), de su trayectoria (años en la empresa, en el puesto, desde el último ascenso) y de encuestas de satisfacción. La variable objetivo dice si el empleado se ha ido de la empresa (*attrition*, rotación o fuga de talento).

Es un dataset de recursos humanos muy usado para clasificación desbalanceada y para explicar modelos ante un público no técnico. Los estudios habituales son:

- **Predecir quién se irá** (clasificación binaria) con un desbalanceo moderado (16 % frente a 84 %).
- **Explicar los motivos**: horas extra, nivel del puesto, edad, estado civil o satisfacción.
- **Comparar técnicas contra el desbalanceo**: ponderación de clases, submuestreo, sobremuestreo o SMOTE.
- **Predecir casos nuevos**: el fichero `attrition_predict` trae tres empleados con nombre para aplicar un modelo ya entrenado.

2 Contexto y fuente original

Los datos son **ficticios**: los crearon científicos de datos de IBM para demostrar su herramienta Watson Analytics, y se difundieron sobre todo a través de Kaggle (*IBM HR Analytics Employee Attrition & Performance*). Son datos simulados con relaciones plausibles, no los de una empresa real, así que sirven para practicar técnica pero no para sacar conclusiones sobre recursos humanos.

Hay tres ficheros en la carpeta:

- `hrm_employee_attrition`: la versión completa, con 33 columnas.
- `attrition_train`: los mismos 1.470 empleados con 18 columnas seleccionadas y la clase. Es el *Attrition - Train* del widget *Datasets* de Orange que se usa en el curso.
- `attrition_predict`: tres empleados inventados (John, Rachel y Veronica), con las columnas de `attrition_train` y sin la clase, para practicar con el widget *Predictions*.
- IBM HR Analytics Employee Attrition & Performance en Kaggle

3 Variable objetivo

La variable objetivo es `Attrition`: `Yes` si el empleado se ha ido (237, el 16,1 %) y `No` si sigue (1.233, el 83,9 %). Decir siempre «No» acierta el 83,9 %, así que la exactitud engaña: usa sensibilidad y F1 de la clase `Yes`, MCC y AUC.

Los grupos con más rotación son quienes hacen horas extra (30,5 % frente a 10,4 %), los menores de 25 años (39,2 %), los solteros (25,5 %), el nivel de puesto más bajo (26,3 %) y quienes viajan con frecuencia (24,9 %).

4 Diccionario de columnas

Columnas de `attrition_train` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
Age	numérica	Edad, en años.	18 – 60
BusinessTravel	categórica	Frecuencia de viajes de trabajo: `Non-Travel`, `Travel_Rarely` o `Travel_Frequently`.	Travel_Rarely (1.043), Travel_Frequently (277), Non-Travel (150)
Department	categórica	Departamento: `Research & Development`, `Sales` o `Human Resources`.	Research & Development (961), Sales (446), Human Resources (63)
DistanceFromHome	numérica	Distancia de casa al trabajo (unidad no documentada; valores de 1 a 29).	1 – 29
Education	categórica	Nivel de estudios: 1 = inferior a universitario, 2 = universitario sin título, 3 = grado, 4 = máster, 5 = doctorado.	3.0 (572), 4.0 (398), 2.0 (282), 1.0 (170), 5.0 (48)
Gender	categórica	Sexo: `Male` o `Female`.	Male (882), Female (588)
JobLevel	numérica	Nivel del puesto en la jerarquía, de 1 (más bajo) a 5.	1 – 5
JobRole	categórica	Puesto: comercial, investigador, técnico de laboratorio, director, etc. (9 valores).	Sales Executive (326), Research Scientist (292), Laboratory Technician (259), Manufacturing Director (145), Healthcare Representative (131), Manager (102) …

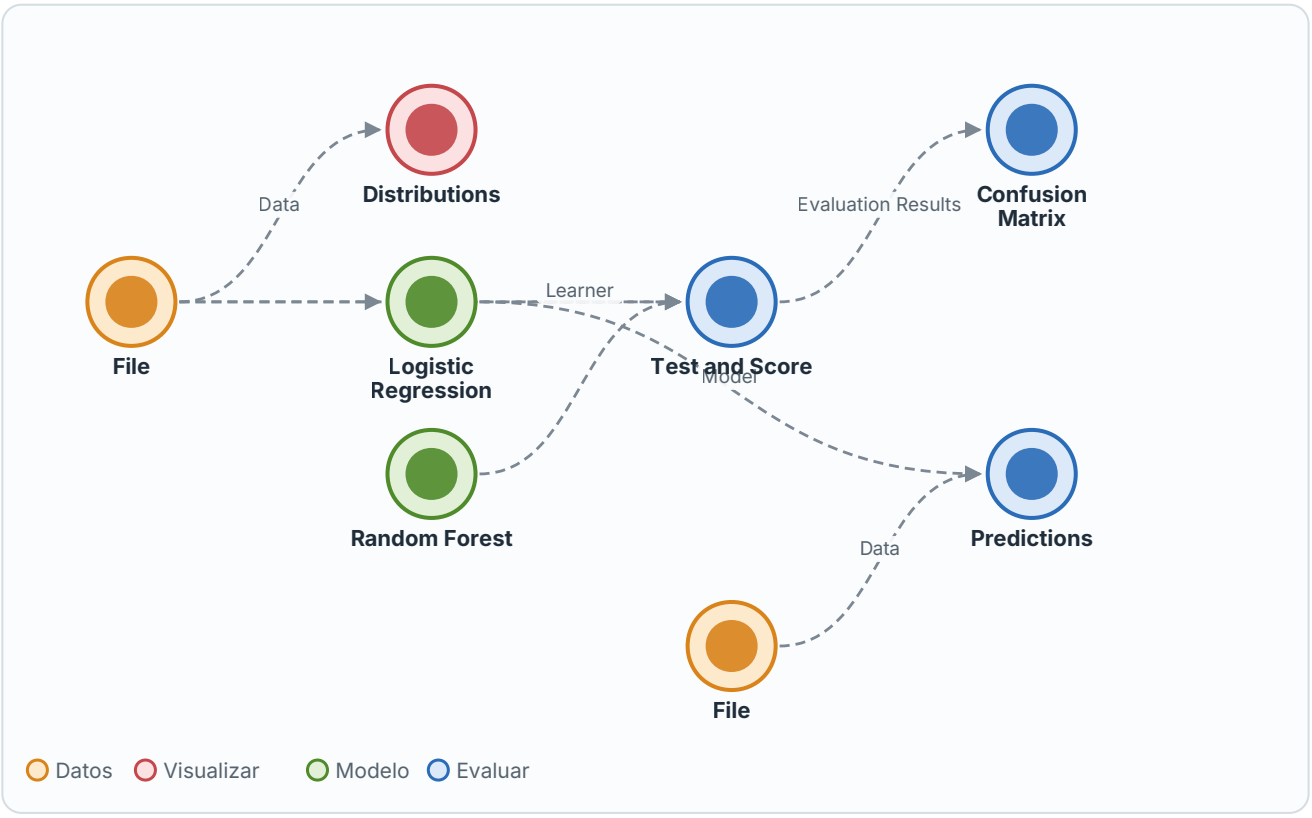
Columna	Tipo	Significado	Valores
`JobSatisfaction`	numérica	Satisfacción con el trabajo: 1 = baja, 2 = media, 3 = alta, 4 = muy alta.	1 – 4
`MaritalStatus`	categórica	Estado civil: `Single`, `Married` o `Divorced`.	Married (673), Single (470), Divorced (327)
`MonthlyIncome`	numérica	Sueldo mensual (moneda no documentada; de 1.009 a 19.999).	1.009 – 19.999
`OverTime`	categórica	Si hace horas extra: `Yes` o `No`.	No (1.054), Yes (416)
`PercentSalaryHike`	numérica	Subida salarial del último año, en %.	11 – 25
`PerformanceRating`	numérica	Evaluación del desempeño: 3 = excelente, 4 = sobresaliente (en los datos solo aparecen estos dos valores).	3 – 4
`StockOptionLevel`	categórica	Nivel de opciones sobre acciones de la empresa, de 0 (ninguna) a 3.	0.0 (631), 1.0 (596), 2.0 (158), 3.0 (85)
`TotalWorkingYears`	numérica	Años de experiencia laboral total.	0 – 40
`YearsAtCompany`	numérica	Años en esta empresa.	0 – 40
`YearsSinceLastPromotion`	numérica	Años desde el último ascenso.	0 – 15
`Attrition` `objetivo`	categórica	Si el empleado se ha ido: `Yes` o `No`. Es la variable objetivo.	No (1.233), Yes (237)

5 Particularidades técnicas al modelar

- **Desbalanceo moderado** (1 de cada 6). Valida con **estratificación** y compara modelos por MCC, F1 o AUC. Muchos modelos de Orange (regresión logística, árboles, Random Forest, SVM) tienen la opción *Balance class distribution*, que pondera las clases sin quitar filas.
- **Códigos ordinales como números**: `Education`, `JobLevel`, `JobSatisfaction`, `PerformanceRating` y `StockOptionLevel` son categorías ordenadas codificadas con números. Al abrir el CSV, Orange las toma como numéricas. Para árboles o regresión logística suele valer así; si quieres tratarlas como categorías, cámbialas en *File*.
- **Al abrir el CSV en Orange**, marca `Attrition` como *target*. Desde el widget *Datasets* («Attrition - Train») ya viene configurado.
- `PerformanceRating` solo toma los valores 3 y 4 en los datos de entrenamiento, pero Veronica, en `attrition_predict`, tiene un 5: el modelo recibe un valor que nunca ha visto. Es un buen ejemplo de por qué hay que revisar los datos nuevos.

- **Columnas que no aportan** en la versión completa: `Over18` y `StandardHours` tienen el mismo valor en todas las filas, y `DailyRate`, `HourlyRate` y `MonthlyRate` parecen números aleatorios sin relación con el sueldo. *Rank* lo confirma.
- No hay valores faltantes.

6 Flujo de trabajo en Orange



1. **File** con `attrition_train` (o **Datasets** → «Attrition - Train»): `Attrition` como *target*.
2. **Distributions** con `Attrition` y, después, con `OverTime` coloreado por la clase: la diferencia salta a la vista.
3. **Logistic Regression** y **Random Forest**, primero sin y después con *Balance class distribution*.
4. **Test and Score** con validación cruzada **estratificada** de 10 particiones; ordena por MCC.
5. **Confusion Matrix**: cuántos de los 237 que se van detecta cada modelo y a cuántos que se quedan señala por error.
6. **Predictions**: conecta el modelo de regresión logística y un segundo **File** con `attrition_predict` para ver la probabilidad de que John, Rachel y Veronica se vayan.

7 Otras consideraciones

- **Para explicabilidad** funciona muy bien: las explicaciones («las horas extra y el nivel 1 suben la probabilidad de irse») se entienden sin saber de aprendizaje automático. Prueba *Nomogram* con la regresión logística o el add-on *Explain*.
- **Ética**: un modelo de «riesgo de fuga» puede acabar usándose contra los empleados. Variables como el sexo, la edad o el estado civil son sensibles; conviene discutir si deben entrar en el modelo.
- **Mismo flujo que Stroke**: cambiando solo el widget de entrada se comparan dos grados de desbalanceo (16 % aquí, 5 % en Stroke).
- Al ser datos simulados, algunas relaciones son más limpias que en la realidad; los resultados no se pueden extrapolar a empresas reales.

En la carpeta	`hrm_employee_attrition` ← `hrm-employee-attrition.xlsx` (datasets.biolab.si)
En la carpeta	`attrition_train` ← `attrition-train.tab` (datasets.biolab.si)
En la carpeta	`attrition_predict` ← `attrition-predict.tab` (datasets.biolab.si)

3.07
Clasificación: negocio, sociedad y equidad

Kickstarter

`03_clasificacion_negocio_sociedad/kickstarter/`

1.163 campañas de Kickstarter de principios de 2016, descritas solo por rasgos de su página (imágenes, vídeos, niveles de recompensa, longitud de textos): ¿se puede predecir si una campaña conseguirá financiarse?

Clasificación binaria · Mixto num. + cat. · Texto

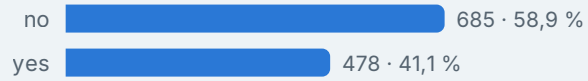
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
1.163	**21**	Funded	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`kickstarter`	1.163 × 21	CSV 219 KB · XLSX

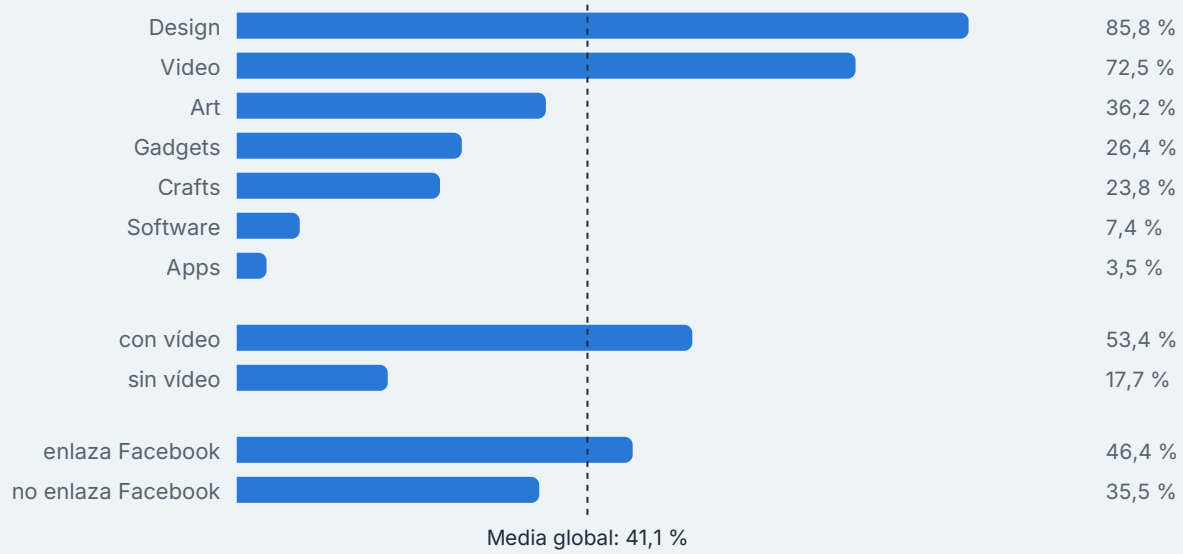
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/03_clasificacion_negocio_sociedad/kickstarter/` seguido del nombre del fichero CSV.

Radiografía

Funded en kickstarter



Porcentaje de proyectos financiados



1 Descripción general y estudios habituales

Cada fila es un proyecto de **Kickstarter**, la plataforma de micromecenazgo, recogido al empezar su campaña. Las variables describen la página del proyecto y a su creador: tipo de proyecto (arte, manualidades, diseño, vídeo, aplicaciones, software, *gadgets*), si el creador enlaza Facebook, cuántos proyectos ha apoyado y creado

antes, la longitud de su descripción y del título, el objetivo de financiación, la duración, el número de niveles de recompensa y sus importes mínimo y máximo, la longitud de la descripción del proyecto y el número de imágenes y vídeos. La clase dice si el proyecto **consiguió financiarse**.

Los estudios habituales son:

- **Clasificación binaria** con atributos muy sencillos.
- **Interpretación**: qué rasgos de una página se asocian al éxito.
- **Detectar fugas** escondidas en las metas (el título).

2 Contexto y fuente original

Lo preparó el equipo de **Orange** (Biolab, Universidad de Liubliana) con una pequeña muestra de proyectos cuyas campañas empezaron a principios de 2016. Según su ficha, aunque los atributos solo describen lo básico de la página, como el número de vídeos e imágenes, sorprende que basten para predecir bastante bien el éxito. No se indica cómo se eligieron los proyectos ni en qué moneda está el objetivo.

- Kickstarter projects en el repositorio de datasets de Orange

3 Variable objetivo

La clase es `Funded`: `yes` si el proyecto consiguió su objetivo (478, el 41 %) o `no` (685). Decir siempre «no» acierta un 59 %.

El tipo de proyecto lo explica casi todo: se financió el 86 % de los proyectos de diseño y el 73 % de los de vídeo, frente al 7 % de los de software y el 3 % de las aplicaciones. También ayudan las imágenes (mediana de 8 en los financiados y 0 en los demás), tener vídeo (53 % frente a 18 %), enlazar Facebook y haber apoyado otros proyectos. En una prueba con validación cruzada de 10 bolsas, el bosque aleatorio acierta un 86 % (AUC 0,93).

4 Diccionario de columnas

Columnas de `kickstarter` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
URL	texto	Dirección de la página del proyecto (meta).	URL (1.163 distintas), p. ej. www.kickstarter.com/projects/mischaa/pixelstart-choose-your-own-pixels
`Title`	texto	Título del proyecto (meta). **Contiene «(Canceled)» en 88 proyectos: fuga.**	Pixelstart: Choose Your Own Pixels (Canceled) (1), Smart shop Icons (Canceled) (1), Minimal Haus Prints: Digital Prints for DIY Wall ART (1), NeoN: Altering the Alternative (Canceled) (1), Nintendo NES 8bit retro canvas (Canceled) (1), Day and Night Cards (Canceled) (1) …
`Year`	texto	Año: siempre 2016 (meta, constante).	2016 (1.163)
`Month`	categórica	Mes de inicio de la campaña (meta): febrero a mayo, casi todos en marzo.	Mar (823), Apr (185), Feb (151), May (4)

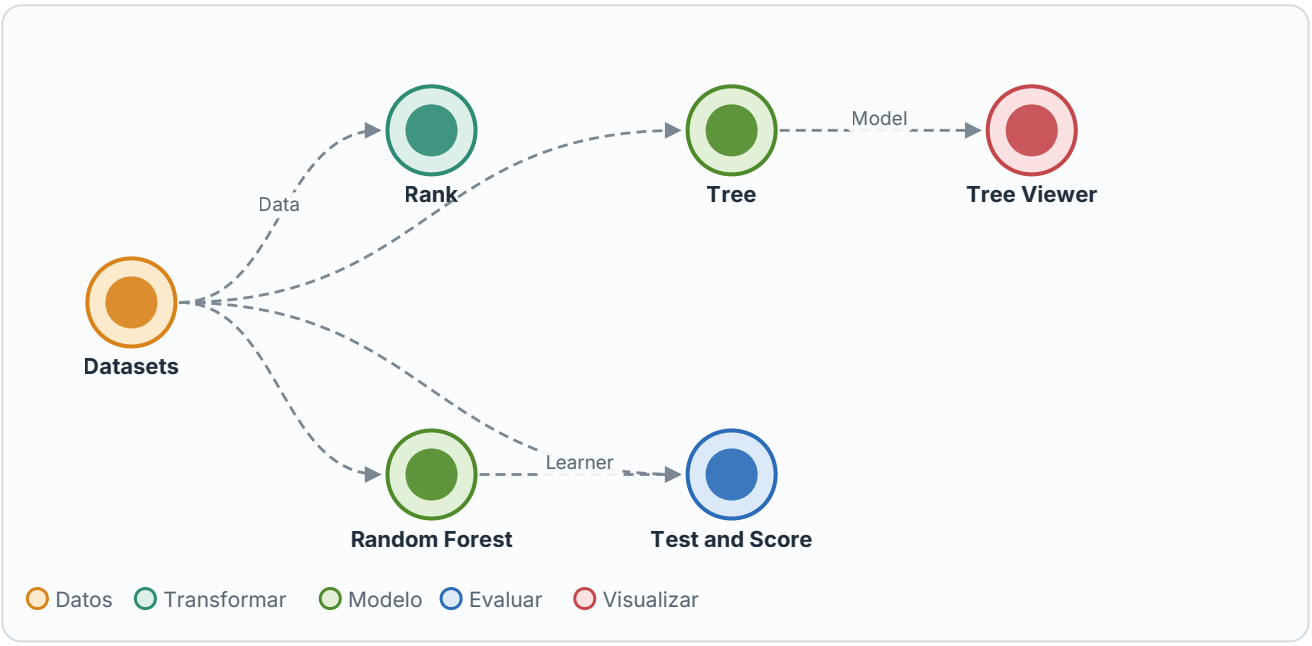
Columna	Tipo	Significado	Valores
`Subcategory`	texto	Subcategoría de Kickstarter (*Product Design*, *Web*, *Documentary*…). Ignorada en Orange.	Apps (172), Crafts (172), Product Design (157), Web (102), Documentary (69), Shorts (65) …
`Type`	categórica	Tipo de proyecto: `Art`, `Crafts`, `Design`, `Video`, `Apps`, `Software` o `Gadgets`.	Video (244), Design (197), Crafts (172), Apps (172), Software (149), Art (138) …
`Has FB`	categórica	Si el creador enlaza su cuenta de Facebook.	1 (599), 0 (564)
`Backed Projects`	numérica	Proyectos que el creador ha apoyado antes.	0 – 348
`Previous Projects`	numérica	Proyectos que el creador ha creado antes.	0 – 29
`Creator Desc Len`	numérica	Longitud (caracteres) de la descripción del creador.	0 – 757
`Title Len`	numérica	Longitud del título.	1 – 82
`Goal`	numérica	Objetivo de financiación (de 10 a 10 millones; con decimales, probablemente convertido de otra moneda).	10 – 10.000.000
`Duration`	numérica	Duración de la campaña en días.	4 – 62
`Pledge Levels`	numérica	Número de niveles de recompensa.	1 – 89
`Min Pledge Tiers`	numérica	Importe del nivel de recompensa más barato.	0,7 – 10.000
`Max Pledge Tiers`	numérica	Importe del nivel de recompensa más caro.	0,76 – 25.000
`Proj Desc Len`	numérica	Longitud de la descripción del proyecto.	59 – 28.293
`Images`	numérica	Número de imágenes en la página.	0 – 95
`Videos`	numérica	Número de vídeos en la página.	0 – 13

Columna	Tipo	Significado	Valores
Has Video	numérica	Si la página tiene al menos un vídeo.	0 – 1
Funded `objetivo`	categórica	**Clase**: si el proyecto consiguió financiarse.	no (685), yes (478)

5 Particularidades técnicas al modelar

- **El título delata la clase**: Kickstarter añade «(Canceled)» al título cuando el creador cancela la campaña, y 87 de esos 88 proyectos no se financiaron. Es una meta y Orange no la usa, pero si se convierte el título en texto (add-on *Text*) o se crea una variable a partir de él, aparece una fuga.
- **El tipo es casi una regla**: con solo `Type`, un árbol ya acierta mucho. Si se quiere estudiar el efecto de la página, conviene comparar dentro de cada tipo.
- **Objetivo con decimales**: `Goal` tiene importes como 2.829,59, lo que sugiere una conversión de moneda que no está documentada. Su distribución es muy asimétrica (mediana de 7.000, máximo de 10 millones): usa una escala logarítmica.
- **Metas poco útiles**: `Year` es constante y `Month` casi (823 de 1.163 en marzo). La ficha original habla de enero a abril, pero los datos van de febrero a mayo.
- **Correlación no es causa**: más imágenes no hacen que un proyecto se financie; los proyectos más cuidados tienen más imágenes y también más éxito.
- No hay valores ausentes.

6 Flujo de trabajo en Orange



1. **Datasets** → «Kickstarter» (o **File** con el CSV).
2. **Rank**: qué atributos separan más (el tipo, las imágenes y los vídeos suelen ir arriba).
3. **Test and Score** con bosque aleatorio, árbol y regresión logística.
4. **Tree Viewer** con profundidad 3: el primer corte suele ser el tipo de proyecto.
5. Extra: con **Feature Constructor**, crea `cancelado = "(Canceled)" in Title` y comprueba cómo «mejora» el modelo.

7 Otras consideraciones

- **Análisis de texto**: con el add-on *Text*, los títulos se pueden convertir en palabras; quita antes «(Canceled)».
- **Datos completos**: hay datasets públicos mucho más grandes de Kickstarter (cientos de miles de proyectos), pero con otras variables.
- **Por tipo**: con *Select Rows*, entrena un modelo solo con proyectos de diseño o de vídeo y mira qué atributos importan dentro de cada tipo.

En la carpeta `kickstarter` ← `kickstarter.tab` (datasets.biolab.si)

3.08
Clasificación: negocio, sociedad y equidad

NBA players

`03_clasificacion_negocio_sociedad/nba/`

248 jugadores de la NBA a mitad de la temporada 2022/23, con medidas físicas y estadísticas por partido: ¿se puede adivinar la posición de un jugador por cómo juega? Clasificación multiclase y agrupamiento.

Clasificación multiclase · Clustering · ? Valores faltantes · ◈ Mixto num. + cat.

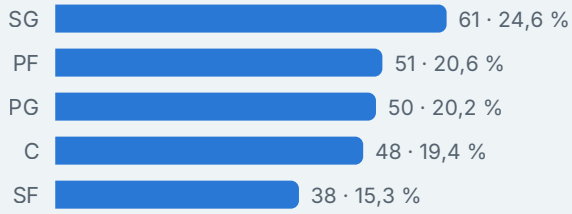
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
248	**17**	`Pos`	**0,2 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`nba`	248 × 17	CSV 19 KB · XLSX

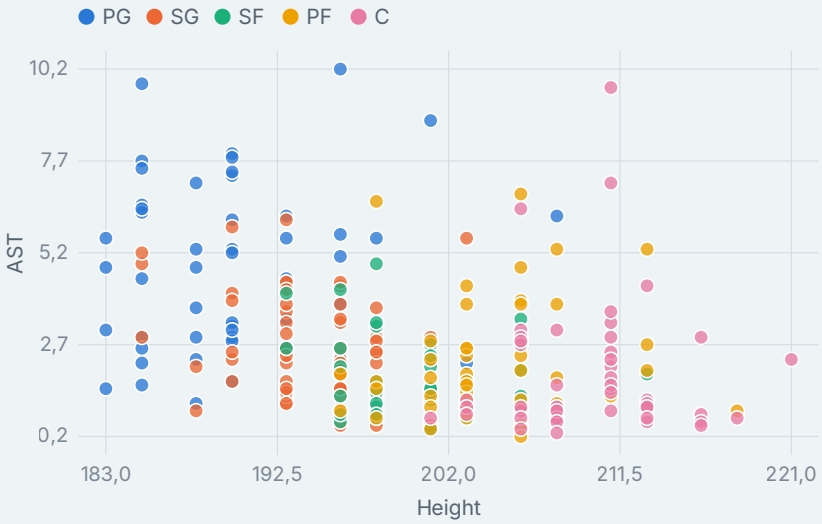
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/03_clasificacion_negocio_sociedad/nba/` seguido del nombre del fichero CSV.

Radiografía

Pos en nba



Altura (cm) y asistencias por partido, por posición



1 Descripción general y estudios habituales

Cada fila es un jugador de la NBA con su equipo, edad, altura, peso, mano dominante y sus estadísticas: porcentaje de acierto en triples, tiros de dos y tiros libres, y rebotes, asistencias, robos, tapones, pérdidas, faltas y puntos. La clase es su **posición**: base, escolta, alero, ala-pívot o pívot.

Los estudios habituales son:

- **Clasificación multiclase** con atributos numéricos.
- **Agrupamiento**: ¿se forman grupos de jugadores parecidos sin mirar la posición? ¿Coinciden con las posiciones?
- **Visualización**: proyecciones (PCA, t-SNE) y diagramas de dispersión de altura frente a asistencias o rebotes.

2 Contexto y fuente original

Lo preparó el equipo de **Orange** (Biolab) en enero de 2023, con datos de **Basketball Reference**, a mitad de la temporada 2022/23. La ficha de Orange enlaza la tabla de totales de la temporada, pero los valores son **promedios por partido** (Luka Dončić, primero de la tabla, promediaba 33,8 puntos). No se indica cómo se eligieron los 248 jugadores (la liga tiene más de 500).

- Basketball Reference, temporada 2022/23 de la NBA

3 Variable objetivo

La clase es `Pos`, la posición del jugador:

- `PG` (*point guard*, base): 50.
- `SG` (*shooting guard*, escolta): 61.
- `SF` (*small forward*, alero): 38.
- `PF` (*power forward*, ala-pívot): 51.
- `C` (*center*, pívot): 48.

Las posiciones van de pequeña a grande: los pívots miden 210 cm de media y los bases 190, y los bases dan 4,8 asistencias por partido frente a menos de 2,6 en las demás posiciones. Los extremos (base y pívot) son fáciles de reconocer; las posiciones intermedias se confunden. En una prueba con validación cruzada de 10 bolsas, el bosque aleatorio acierta un 62,5 % y Naive Bayes un 58 %, frente al 25 % de decir siempre «escolta».

4 Diccionario de columnas

Columnas de `nba` (valores observados en el fichero)

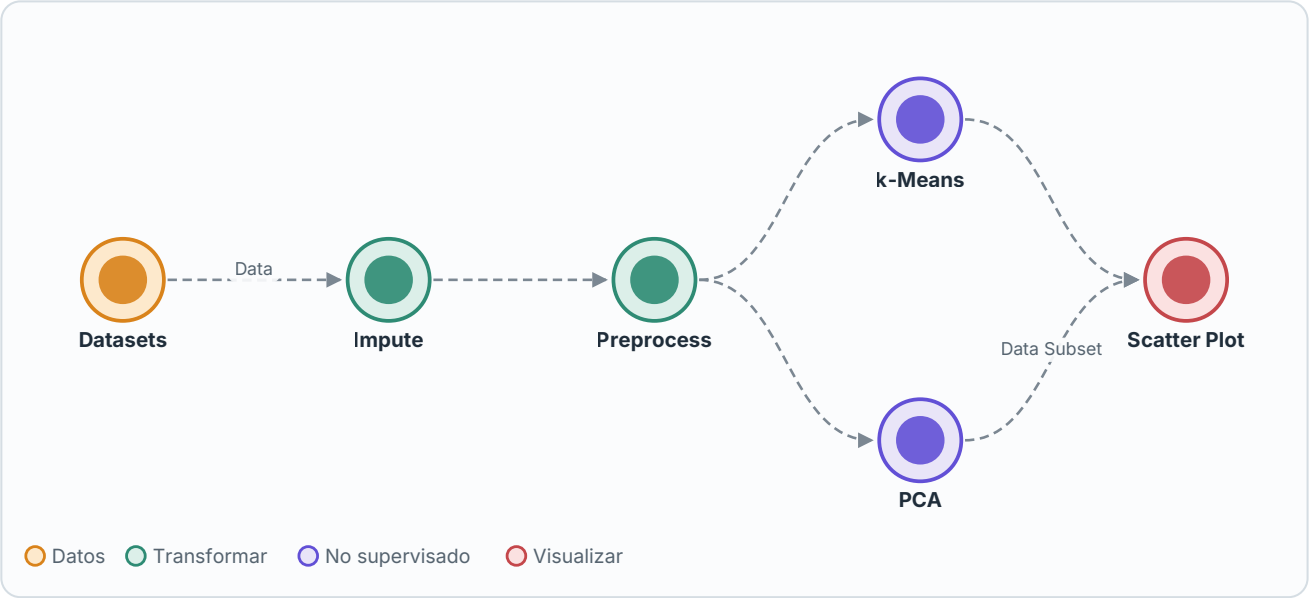
Columna	Tipo	Significado	Valores
Pos `objetivo`	categórica	**Clase**: posición (`PG` base, `SG` escolta, `SF` alero, `PF` ala-pívot, `C` pívot).	SG (61), PF (51), PG (50), C (48), SF (38)
`Tm`	categórica	Equipo, con la abreviatura de Basketball Reference (meta).	OKC (10), CHI (10), DET (10), IND (10), HOU (10), SAC (10) …
`Player`	texto	Nombre del jugador (meta).	Luka Dončić (1), Joel Embiid (1), Giannis Antetokounmpo (1), Shai Gilgeous-Alexander (1), Jayson Tatum (1), Kevin Durant (1) …

Columna	Tipo	Significado	Valores
Age	numérica	Edad (de 19 a 38).	19 – 38
Height	numérica	Altura en centímetros.	183 – 221
Weight	numérica	Peso en kilos.	74 – 131
Hand	categórica	Mano dominante: `R` (derecha, 228) o `L` (izquierda, 20).	R (228), L (20)
3P%	numérica	Porcentaje de acierto en triples. Vacío en 9 pívots que no han lanzado ninguno.	0 – 0,75
2P%	numérica	Porcentaje de acierto en tiros de dos.	0,365 – 0,779
FT%	numérica	Porcentaje de acierto en tiros libres.	0,325 – 1
TRB	numérica	Rebotes totales por partido.	0,7 – 12,5
AST	numérica	Asistencias por partido.	0,2 – 10,2
STL	numérica	Robos por partido.	0,1 – 2,2
BLK	numérica	Tapones por partido.	0 – 2,6
TOV	numérica	Pérdidas de balón por partido.	0,3 – 4
PF	numérica	Faltas personales por partido. **No confundir con la posición `PF`.**	0,4 – 4
PTS	numérica	Puntos por partido (de 3,2 a 33,8).	3,2 – 33,8

5 Particularidades técnicas al modelar

- **Escalas distintas**: altura en centímetros, porcentajes entre 0 y 1 y estadísticas por partido. Para kNN, agrupamiento o PCA, hay que normalizar.
- **Ausentes con sentido**: los 9 vacíos en `3P%` son pívots que no han tirado triples. No es que falte el dato: el porcentaje no existe. Imputarlos con la media los hace parecer tiradores normales; un 0 o una variable «no lanza triples» es más fiel.
- **Las posiciones se solapan**: muchos jugadores juegan en dos posiciones y Basketball Reference les asigna una. Un acierto del 60 % no es un mal resultado.
- **Porcentajes con pocos tiros**: un jugador con dos triples lanzados y uno metido tiene un 50 %. Los porcentajes no llevan el número de intentos.
- `PF` **significa dos cosas**: la columna de faltas personales y la posición ala-pívot.
- **Muestra pequeña**: 248 jugadores y 38 aleros. Los resultados varían bastante entre particiones.

6 Flujo de trabajo en Orange



1. **Datasets** → «NBA Players» (o **File** con el CSV).
2. **Impute** para los 9 `3P%` vacíos (por ejemplo, con 0) y **Preprocess** → *Normalize*.
3. **k-Means** con k = 5 y **Scatter Plot** de altura frente a asistencias, coloreando por grupo y con la forma por posición: ¿coinciden los grupos con las posiciones?
4. **PCA**: las dos primeras componentes separan a los jugadores grandes de los pequeños.
5. Para clasificar: **Test and Score** con bosque aleatorio y kNN, y **Confusion Matrix** para ver qué posiciones se confunden.

7 Otras consideraciones

- **Matriz de confusión**: los errores se concentran entre posiciones vecinas (base con escolta, ala-pívot con pívot). Es una buena forma de enseñar que no todos los errores son iguales.
- **Tres posiciones**: agrupar en exteriores (`PG` , `SG`), aleros (`SF`) e interiores (`PF` , `C`) con *Create Class* o *Feature Constructor* sube mucho el acierto.
- **Distancias y jugadores parecidos**: con *Distances* y *Neighbors*, busca los jugadores más parecidos a uno dado.

En la carpeta `nba` ← `nba.tab` (datasets.biolab.si)

4 Clasificación: ciencias naturales y físicas

6 datasets en el capítulo; en esta edición, 6 con ficha.

4.01
Clasificación: ciencias naturales y físicas

Glass Identification

`04_clasificacion_ciencias_naturales/glass/`

214 fragmentos de vidrio con su índice de refracción y su composición química, para saber de qué tipo de objeto proceden: un problema forense con seis clases muy desequilibradas y un identificador que delata la clase.

Clasificación multiclase ⚖ Desbalanceado

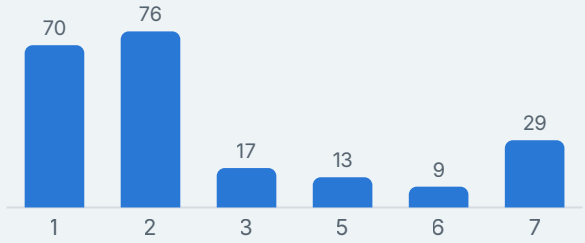
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
214	**11**	y	**0,0 %**	**Intermedio**	**Ninguno**

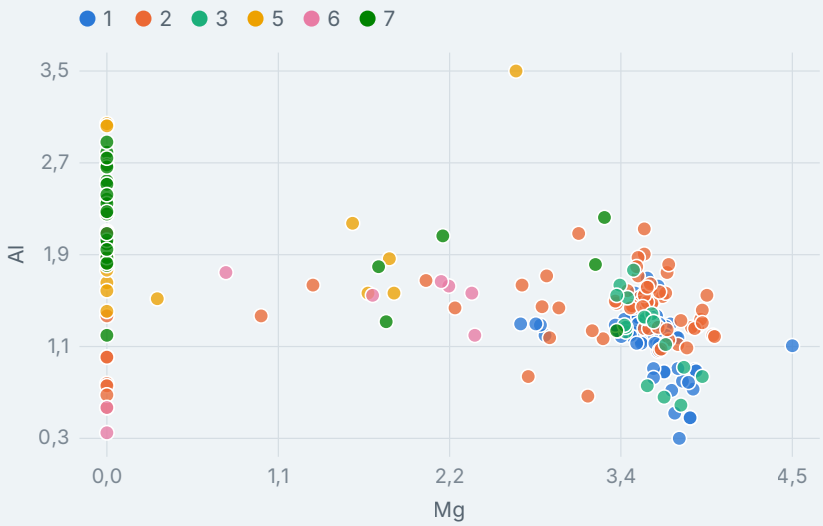
Fichero	Filas × col.	Descargar
`glass`	214 × 11	CSV 11 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/04_clasificacion_ciencias_naturales/glass/` seguido del nombre del fichero CSV.

Radiografía

y en glass





1 Descripción general y estudios habituales

Cada fila es un fragmento de vidrio analizado en un laboratorio forense. Se midió su **índice de refracción** y el porcentaje en peso de ocho elementos (como óxidos): sodio, magnesio, aluminio, silicio, potasio, calcio, bario y hierro. La clase dice de dónde viene el vidrio: ventana de edificio (fabricada por flotado o no), ventana de vehículo, envase, vajilla o faro.

Los estudios habituales son:

- **Clasificación multiclase** con clases pequeñas y desequilibradas.
- **Clasificación binaria** «vidrio flotado o no», que era la pregunta original.
- **Exploración**: qué elementos distinguen cada tipo de vidrio (el bario, por ejemplo, casi solo aparece en los faros).

2 Contexto y fuente original

Los datos son de **B. German**, del servicio de ciencia forense del Ministerio del Interior británico (Aldermaston), y los donó **Vina Spiehler** en 1987. El estudio nació de la investigación criminal: un fragmento de vidrio hallado en la escena de un crimen puede servir de prueba si se identifica bien su origen. En la comparación original, el vecino más cercano funcionó tan bien como un sistema de reglas comercial.

- German, B. (1987). Glass Identification. UCI Machine Learning Repository.

3 Variable objetivo

La clase es `y`, un código del 1 al 7:

- `1`: ventana de edificio, vidrio flotado (70).
- `2`: ventana de edificio, no flotado (76).
- `3`: ventana de vehículo, flotado (17).
- `4`: ventana de vehículo, no flotado. **No hay ninguno.**
- `5`: envases (13).
- `6`: vajilla (9).
- `7`: faros (29).

Las tres clases no relacionadas con ventanas se separan bien (los faros tienen bario y poco magnesio). Lo difícil es distinguir las ventanas entre sí, sobre todo las de vehículo, que son pocas. En una prueba con validación cruzada estratificada de 9 bolsas, sin el identificador, el bosque aleatorio acierta un 79 % y el árbol un 67 %, frente al 36 % de decir siempre `2`.

4 Diccionario de columnas

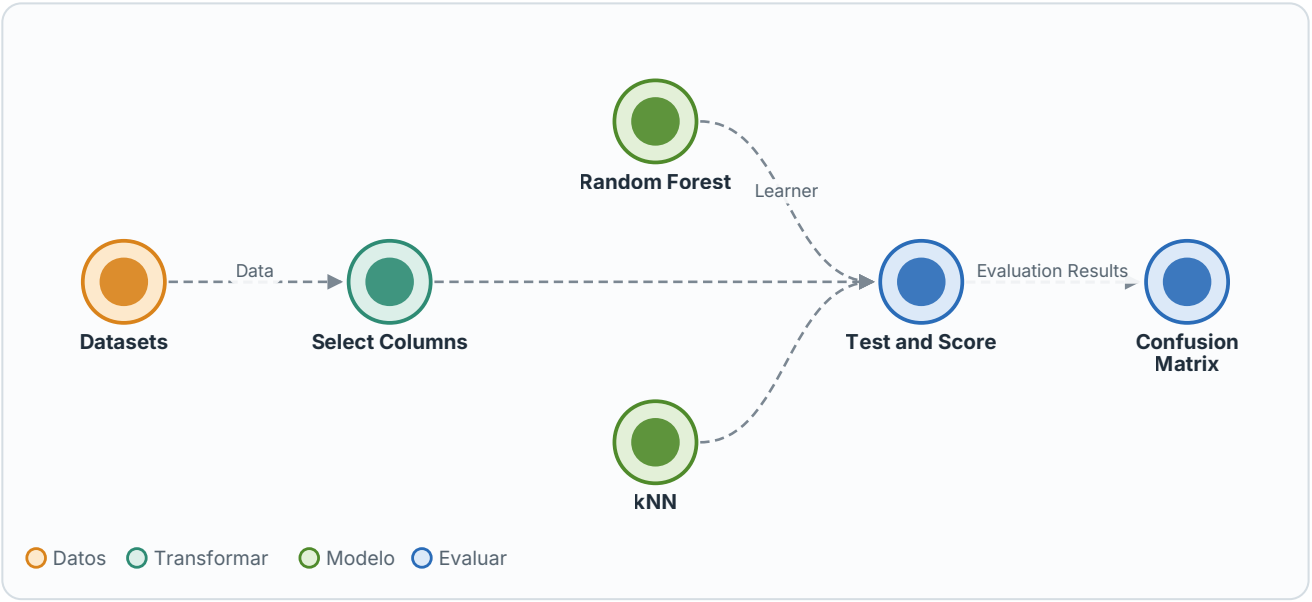
Columnas de `glass` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Id`	numérica	Número de fragmento (1 a 214). **Ignorado en Orange: está ordenado por clase y la delata.**	1 – 214
`RI`	numérica	Índice de refracción (de 1,511 a 1,534).	1,511 – 1,534
`Na`	numérica	Sodio (% en peso, como óxido).	10,73 – 17,38
`Mg`	numérica	Magnesio. Vale 0 en 42 fragmentos.	0 – 4,49
`Al`	numérica	Aluminio.	0,29 – 3,5
`Si`	numérica	Silicio (alrededor del 72 %).	69,81 – 75,41
`K`	numérica	Potasio. Vale 0 en 30 fragmentos.	0 – 6,21
`Ca`	numérica	Calcio.	5,43 – 16,19
`Ba`	numérica	Bario. Vale 0 en 176 fragmentos; sobre todo aparece en los faros.	0 – 3,15
`Fe`	numérica	Hierro. Vale 0 en 144 fragmentos.	0 – 0,51
y `objetivo`	categórica	**Clase**: tipo de vidrio (códigos 1, 2, 3, 5, 6 y 7; el 4 no aparece).	2 (76), 1 (70), 7 (29), 3 (17), 5 (13), 6 (9)

5 Particularidades técnicas al modelar

- **El identificador delata la clase**: los fragmentos están numerados por tipo (1–70 son del tipo 1, 71–146 del tipo 2, etc.). Orange lo marca como ignorado, pero si se lee el CSV con **File** pasa a ser un atributo, y con él el acierto sube al 97–99 %. Hay que quitarlo o marcarlo como `skip`.
- **La clase es numérica en el fichero**: al abrir el CSV, Orange puede tratar `y` como número. Cámbiala a categórica en el widget **File**; si no, el problema se convierte en regresión.
- **Clases pequeñas**: con 9 fragmentos de vajilla, una validación cruzada de 10 bolsas deja alguna bolsa sin esa clase. Usa validación estratificada o menos bolsas.
- **Composición que suma 100 %**: los ocho elementos suman entre 99 % y 100,1 %, así que no son independientes (si uno sube, otro baja).
- **Muchos ceros**: bario, hierro, potasio y magnesio valen 0 en muchos fragmentos. Son medidas reales («por debajo del límite»), no huecos.
- Hay un fragmento repetido (mismos valores, distinto `Id`).

6 Flujo de trabajo en Orange



1. **Datasets** → «Glass» (o **File** con el CSV: `y` como categórica y `Id` como `skip`).
2. **Select Columns**: comprueba que `Id` no está entre los atributos.
3. **Test and Score** con bosque aleatorio y kNN, validación estratificada.
4. **Confusion Matrix**: los errores se concentran entre los tipos 1, 2 y 3 (ventanas).
5. **Scatter Plot** de `Mg` frente a `Al` o `Ba`, coloreado por `y`, para ver qué separa cada tipo.

7 Otras consideraciones

- **Versión binaria**: con *Create Class* o *Feature Constructor*, agrupa en «flotado» (1 y 3) frente a «no flotado» (2), la pregunta del estudio original.
- **Normalizar para kNN**: las escalas van de 0,01 (hierro) a 72 (silicio).
- **Comparar con Wine**: otro dataset químico pequeño, pero mucho más fácil; ver por qué ayuda a hablar de la dificultad de un problema.

En la carpeta `glass` ← `glass.tab` (datasets.biolab.si)

4.02
Clasificación: ciencias naturales y físicas

Ionosphere

`04_clasificacion_ciencias_naturales/ionosphere/`

351 señales de radar devueltas por la ionosfera, descritas por 34 números, para decir si muestran estructura («buenas») o la atraviesan («malas»): clasificación binaria con atributos numéricos abstractos.

Clasificación binaria

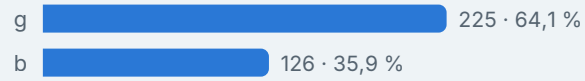
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
351	**35**	`y`	**0,0 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`ionosphere`	351 × 35	CSV 75 KB · XLSX

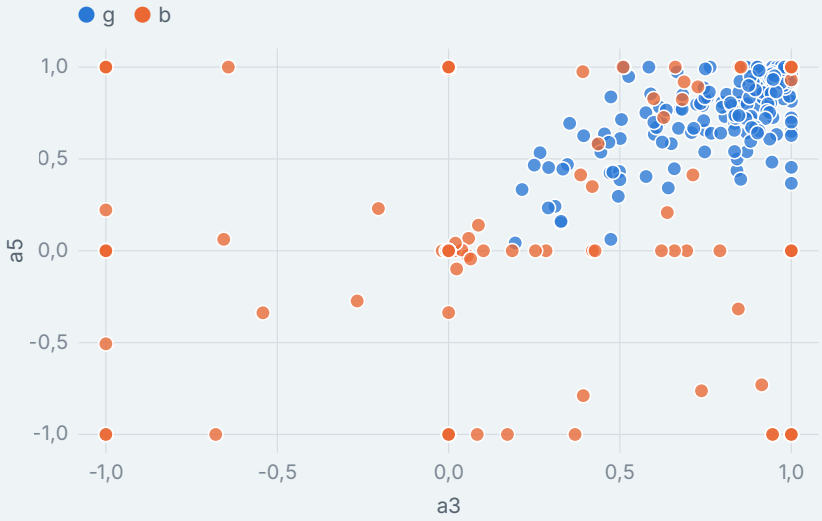
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/04_clasificacion_ciencias_naturales/ionosphere/` seguido del nombre del fichero CSV.

Radiografía

y en ionosphere



Primer pulso (a3) y segundo pulso (a5), parte real, por clase



1 Descripción general y estudios habituales

Un radar de Goose Bay (Labrador, Canadá), con 16 antenas de alta frecuencia y unos 6,4 kW de potencia, apuntaba a los electrones libres de la ionosfera. Cada señal recibida se procesó con una función de autocorrelación sobre 17 pulsos; cada pulso da un número complejo, es decir, **dos atributos** (parte real e imaginaria), y en total hay 34. Una señal es **buena** si muestra algún tipo de estructura en la ionosfera y **mala** si la atraviesa.

Los estudios habituales son:

- **Clasificación binaria** con muchas variables numéricas sin nombre interpretable.
- **Comparar algoritmos**: es un clásico de las redes neuronales y las máquinas de vectores de soporte.
- **Selección de atributos y reducción de dimensión** (PCA).

2 Contexto y fuente original

Lo donó **Vince Sigillito**, del Grupo de Física Espacial del Laboratorio de Física Aplicada de la Universidad Johns Hopkins, en 1989. En el estudio original entrenaron perceptrones y redes con retropropagación con las 200 primeras señales, equilibradas, y probaron con las 151 restantes, de las que solo unas 24 eran malas. La retropropagación superó el 96 % de acierto.

- Sigillito, V. G., Wing, S. P., Hutton, L. V. y Baker, K. B. (1989). Classification of radar returns from the ionosphere using neural networks. Johns Hopkins APL Technical Digest, 10, 262–266.

3 Variable objetivo

La clase es `y` : `g` (*good*, buena: 225, el 64 %) o `b` (*bad*, mala: 126). Decir siempre «buena» acierta un 64 %.

En una prueba con validación cruzada de 10 bolsas, el bosque aleatorio acierta un 93 %, el árbol un 89 % y Naive Bayes un 88 %; la regresión logística y kNN se quedan en el 85 %. Según la información mutua, los atributos que más separan son los de los primeros pulsos (`a3` , `a5` , `a6` , `a8`).

4 Diccionario de columnas

Columnas de `ionosphere` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
a1	numérica	Indicador binario (0/1). **Ignorado en Orange.** Las 38 señales con `a1 = 0` son todas malas.	0 – 1
a2	numérica	Siempre 0. **Ignorado en Orange** (constante).	0 – 0
a3	numérica	Pulso 1, parte real (de −1 a 1).	-1 – 1
a4	numérica	Pulso 1, parte imaginaria.	-1 – 1
a5	numérica	Pulso 2, parte real. Los atributos siguen en parejas real–imaginaria hasta `a34` (pulso 16).	-1 – 1
y `objetivo`	categórica	**Clase**: `g` (buena) o `b` (mala).	g (225), b (126)
…		y 29 columnas más del mismo tipo que la anterior.	

5 Particularidades técnicas al modelar

- **Atributos sin nombre**: son partes reales e imaginarias de una autocorrelación, sin unidades interpretables. Es un buen dataset para algoritmos, no para explicar resultados.
- **Las dos primeras columnas son raras**: `a2` es constante y `a1` solo vale 0 o 1. Orange las ignora, pero si se lee el CSV con **File** entran como atributos. `a1 = 0` aparece solo en señales malas: es una pista fuerte, quizá un indicador de calidad de la medida.

- **Valores acotados** entre −1 y 1, con muchos valores exactamente en −1, 0 o 1 (el 28 % de las celdas): saturación.
- **Desequilibrio moderado** (36 % malas) y, en el reparto original, la prueba tenía muy pocas señales malas: el acierto en malas era mucho menor que en buenas. Mira la matriz de confusión.

6 Flujo de trabajo en Orange



1. **Datasets** → «Ionosphere» (o **File** con el CSV, marcando `a1` y `a2` como `skip`).
2. **Rank**: qué atributos separan más.
3. **PCA** → **Scatter Plot** de las dos primeras componentes, coloreando por clase.
4. **Test and Score** con bosque aleatorio y SVM (núcleo RBF).
5. **Confusion Matrix**: compara el acierto en señales buenas y malas.

7 Otras consideraciones

- **Reparto original**: entrena con las 200 primeras filas y prueba con el resto (*Data Sampler* con tamaño fijo y sin barajar, o *Select Rows* por número de fila) para comparar con el artículo.
- **Pocos atributos bastan**: prueba con los 10 mejores de *Rank*; el acierto apenas baja.

En la carpeta `ionosphere` ← `ionosphere.tab` (datasets.biolab.si)

4.03

Clasificación: ciencias naturales y físicas

Vehicle Silhouettes

`04_clasificacion_ciencias_naturales/vehicle/`

846 siluetas de cuatro maquetas de vehículos vistas desde distintos ángulos, descritas por 18 medidas de forma: el autobús y la furgoneta son fáciles, pero distinguir un Saab de un Opel es casi tirar una moneda.

Clasificación multiclase

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
846	**19**	`vehicle`	**0,0 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`vehicle`	846 × 19	CSV 55 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/04_clasificacion_ciencias_naturales/vehicle/` seguido del nombre del fichero CSV.

Radiografía

vehicle en vehicle



Acierto por clase con bosque aleatorio (validación cruzada, %)



1 Descripción general y estudios habituales

Se fotografiaron cuatro maquetas de vehículos (un autobús de dos pisos, una furgoneta Chevrolet, un Saab 9000 y un Opel Manta 400) desde muchos ángulos de giro y una elevación limitada. De cada silueta se extrajeron 18 medidas de forma: compacidad, circularidad, rectangularidad, relaciones de aspecto, varianza, asimetría y curtosis respecto a los ejes mayor y menor, radio de giro y huecos. La clase es el **vehículo**.

Los estudios habituales son:

- **Clasificación multiclase** con atributos numéricos muy correlacionados.
- **Análisis de la matriz de confusión**: dos clases fáciles y dos casi indistinguibles.
- **Reducción de dimensión**: muchos atributos miden casi lo mismo.

2 Contexto y fuente original

Los datos se recogieron en el **Turing Institute** de Glasgow en 1986–87 (J. P. Siebert), con financiación de Barr and Stroud. El objetivo era reconocer objetos 3D a partir de su silueta 2D con un conjunto de extractores de forma (el sistema HIPS, extensión BINATTS). Las maquetas, pintadas de negro mate, se fotografiaron sobre una caja de luz a 128 × 128 píxeles, desde tres elevaciones y girándolas en 360°. Se eligieron esperando que el autobús, la furgoneta y un turismo fueran fáciles de distinguir, pero los dos turismos no. Formó parte del proyecto europeo **Statlog**, y su documentación pide citar al Turing Institute si se publica algo con él.

- Statlog (Vehicle Silhouettes). UCI Machine Learning Repository (Turing Institute, Glasgow).

3 Variable objetivo

La clase es `vehicle`: `bus` (218), `saab` (217), `opel` (212) y `van` (199), casi equilibradas.

En una prueba con validación cruzada de 10 bolsas, el bosque aleatorio acierta un 76 %, el árbol un 73 % y la regresión logística un 72 %; Naive Bayes se queda en el 58 %. El problema está en los turismos: el autobús y la furgoneta se aciertan en el 98–99 % de los casos, pero el Saab y el Opel solo en un 53–54 %, porque sus siluetas son muy parecidas.

4 Diccionario de columnas

Columnas de `vehicle` (valores observados en el fichero)

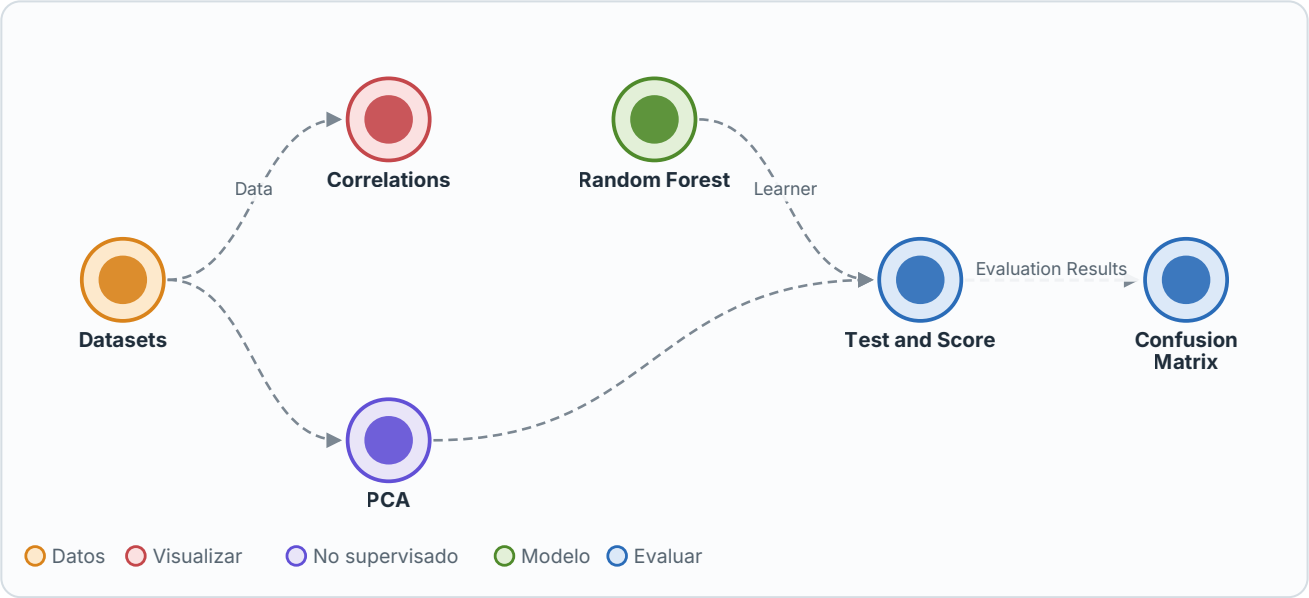
Columna	Tipo	Significado	Valores
`compactness`	numérica	Compacidad: (perímetro medio)² / área.	73 – 119
`circularity`	numérica	Circularidad: (radio medio)² / área.	33 – 59
`distance circularity`	numérica	Circularidad por distancias: área / (distancia media al borde)².	40 – 112
`radius ratio`	numérica	(Radio máximo − radio mínimo) / radio medio.	104 – 333
`pr.axis aspect ratio`	numérica	Relación de aspecto: eje principal menor / eje principal mayor.	47 – 138
`max.length aspect ratio`	numérica	Longitud perpendicular a la máxima / longitud máxima.	2 – 55
`scatter ratio`	numérica	Relación de dispersión: inercia en el eje menor / inercia en el mayor.	112 – 265
`elongatedness`	numérica	Alargamiento: área / (anchura tras encoger la silueta)².	26 – 61
`pr.axis rectangularity`	numérica	Área / (largo × ancho según los ejes principales).	17 – 29
`max.length rectangularity`	numérica	Área / (longitud máxima × longitud perpendicular).	118 – 188
`scaled variance along major axis`	numérica	Momento de segundo orden respecto al eje menor / área.	130 – 320

Columna	Tipo	Significado	Valores
`scaled variance along minor axis`	numérica	Momento de segundo orden respecto al eje mayor / área.	184 – 1.018
`scaled radius of gyration`	numérica	Radio de giro escalado: suma de las dos varianzas / área.	109 – 268
`skewness about major axis`	numérica	Asimetría respecto al eje mayor.	59 – 135
`skewness about minor axis`	numérica	Asimetría respecto al eje menor.	0 – 22
`kurtosis about minor axis`	numérica	Curtosis respecto al eje menor.	0 – 41
`kurtosis about major axis`	numérica	Curtosis respecto al eje mayor.	176 – 206
`hollows ratio`	numérica	Área de los huecos / área del polígono que envuelve la silueta.	181 – 211
`vehicle` `objetivo`	categórica	**Clase**: `bus`, `van`, `saab` u `opel`.	bus (218), saab (217), opel (212), van (199)

5 Particularidades técnicas al modelar

- **Atributos casi idénticos**: `scatter ratio` y `scaled variance along minor axis` tienen una correlación de 0,996, y varias parejas más pasan de 0,96. Esto confunde a Naive Bayes (que supone independencia y cuenta la misma información varias veces) y hace inestables los coeficientes de la regresión logística.
- **Escalas muy distintas**: de valores en torno a 10 a valores en torno a 400. Normaliza para kNN o SVM.
- **Dos clases muy parecidas**: Saab y Opel son turismos de tamaño similar. Ningún modelo pasa de un acierto moderado entre ellos con estas medidas.
- **Vistas del mismo objeto**: todas las siluetas son de solo cuatro maquetas giradas. La validación cruzada mezcla ángulos parecidos entre entrenamiento y prueba.
- No hay valores ausentes.

6 Flujo de trabajo en Orange



1. **Datasets** → «Vehicle» (o **File** con el CSV).
2. **Correlations**: busca las parejas de atributos casi idénticas.
3. **PCA** (normalizando): con 5 componentes se explica el 91 % de la varianza.
4. **Test and Score** con bosque aleatorio, con los datos originales y con las componentes de PCA.
5. **Confusion Matrix**: los errores se concentran entre `saab` y `opel`.

7 Otras consideraciones

- **Tres clases**: une `saab` y `opel` en «turismo» con *Create Class* o *Feature Constructor*; el bosque aleatorio acierta un 96 %. Es un buen ejemplo de que la dificultad depende de cómo se define la clase.
- **Comparar con Naive Bayes**: quitar atributos redundantes (*Select Columns* o *Rank*) mejora Naive Bayes y apenas cambia el bosque aleatorio.

En la carpeta `vehicle` ← `vehicle.tab` (datasets.biolab.si)

4.04
Clasificación: ciencias naturales y físicas

Wine (cultivares italianos)

`04_clasificacion_ciencias_naturales/wine/`

178 vinos de una misma región de Italia, de tres variedades de uva, con 13 medidas químicas: un dataset pequeño y casi perfectamente separable, ideal para ver por qué hay que normalizar antes de usar kNN.

Clasificación multiclase · Clustering

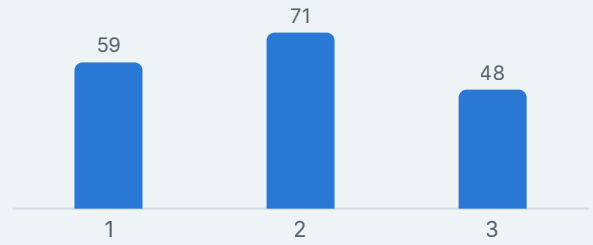
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
178	**14**	`Wine`	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`wine`	178 × 14	CSV 11 KB · XLSX

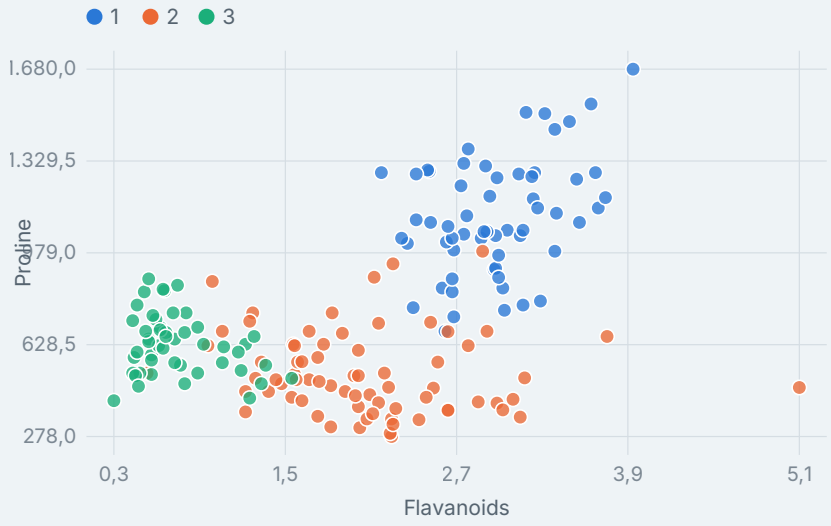
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/04_clasificacion_ciencias_naturales/wine/` seguido del nombre del fichero CSV.

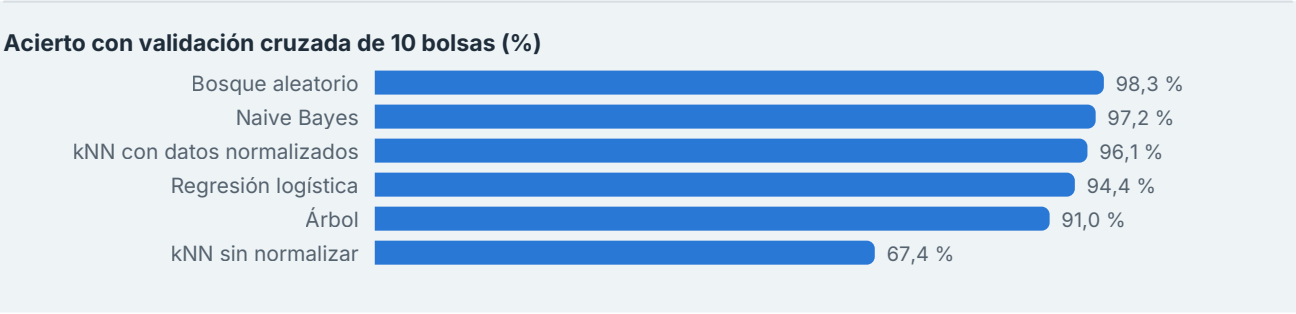
Radiografía

Wine en wine



Flavonoides y prolina por variedad





1 Descripción general y estudios habituales

Cada fila es un vino elaborado en la misma región de Italia a partir de una de **tres variedades de uva** (cultivares). Se midieron 13 componentes químicos: alcohol, ácido málico, cenizas y su alcalinidad, magnesio, fenoles totales, flavonoides y fenoles no flavonoides, proantocianidinas, intensidad y tono del color, la relación OD280/OD315 (una medida de proteínas) y prolina.

Los estudios habituales son:

- **Clasificación multiclase** con atributos numéricos.
- **Agrupamiento**: ¿encuentra k-medias las tres variedades sin mirar la clase?
- **Normalización y reducción de dimensión**: las escalas van de 0,1 a más de 1.000.

2 Contexto y fuente original

Los datos proceden de **M. Forina** y su grupo de la Universidad de Génova (programa PARVUS para análisis de datos químicos). Según su donante, el original tenía unos 30 componentes; la versión que se difunde, donada al repositorio UCI en 1991, se quedó con 13. No es el mismo dataset que **Wine Quality** (capítulo 5), que puntúa vinos portugueses.

- Wine. UCI Machine Learning Repository (Forina et al., PARVUS; donado por S. Aeberhard en 1991).

3 Variable objetivo

La clase es `Wine`, la variedad de uva, codificada como `1` (59 vinos), `2` (71) y `3` (48). No se dice qué variedades son.

Las clases se separan casi del todo: la variedad 1 tiene mucha prolina (1.116 de media frente a 520–630), la 3 muy pocos flavonoides (0,78 frente a 2–3) y la 2 poco color. En una prueba con validación cruzada de 10 bolsas, el bosque aleatorio acierta un 98 % y Naive Bayes un 97 %. kNN sin normalizar se queda en el **67 %**; con los datos normalizados, sube al **96 %**.

4 Diccionario de columnas

Columnas de `wine` (valores observados en el fichero)

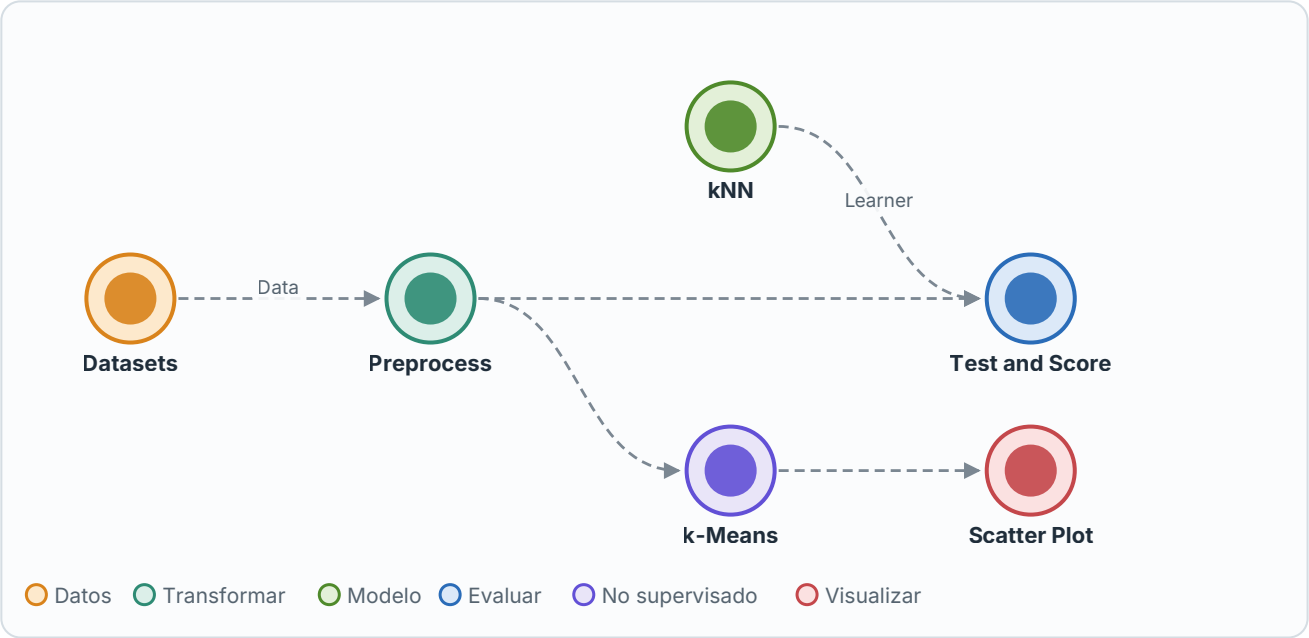
Columna	Tipo	Significado	Valores
`Wine` objetivo	categórica	**Clase**: variedad de uva (`1` , `2` o `3`).	2 (71), 1 (59), 3 (48)
`Alcohol`	numérica	Grado alcohólico (de 11 a 14,8).	11,03 – 14,83
`Malic Acid`	numérica	Ácido málico.	0,74 – 5,8

Columna	Tipo	Significado	Valores
`Ash`	numérica	Cenizas.	1,36 – 3,23
`Alcalinity of ash`	numérica	Alcalinidad de las cenizas.	10,6 – 30
`Magnesium`	numérica	Magnesio (de 70 a 162).	70 – 162
`Total phenols`	numérica	Fenoles totales.	0,98 – 3,88
`Flavanoids`	numérica	Flavonoides (de 0,34 a 5,08). Muy bajos en la variedad 3.	0,34 – 5,08
`Nonflavanoid phenols`	numérica	Fenoles no flavonoides.	0,13 – 0,66
`Proanthocyanins`	numérica	Proantocianidinas.	0,41 – 3,58
`Color intensity`	numérica	Intensidad del color (de 1,3 a 13).	1,28 – 13
`Hue`	numérica	Tono del color.	0,48 – 1,71
`OD280/OD315 of diluted wines`	numérica	Relación de absorbancias a 280 y 315 nm del vino diluido (indica el contenido de proteínas).	1,27 – 4
`Proline`	numérica	Prolina, un aminoácido (de 278 a 1.680). Muy alta en la variedad 1.	278 – 1.680

5 Particularidades técnicas al modelar

- **Escalas muy distintas**: la prolina va de 278 a 1.680 y los fenoles no flavonoides de 0,13 a 0,66. Cualquier método basado en distancias (kNN, k-medias, SVM) queda dominado por la prolina si no se normaliza. En Orange, el learner kNN no normaliza por sí solo: añade **Preprocess** → *Normalize*.
- **La clase es numérica en el fichero**: al abrir el CSV con **File**, cambia `Wine` a categórica; si no, Orange la tratará como un número.
- **Muy fácil**: casi cualquier modelo pasa del 90 %. Sirve para enseñar, no para comparar algoritmos con fineza.
- No hay valores ausentes.

6 Flujo de trabajo en Orange



1. **Datasets** → «Wine» (o **File** con el CSV, con `Wine` categórica).
2. **Test and Score** con kNN conectando los datos **sin** normalizar: anota el acierto.
3. Intercala **Preprocess** → *Normalize* y repite: el acierto sube unos 30 puntos.
4. **k-Means** con k = 3 sobre los datos normalizados y **Scatter Plot** coloreando por grupo y con la forma por variedad: los grupos coinciden con las variedades en 172 de 178 vinos.
5. Compara con **Silhouette Plot** o con **Hierarchical Clustering**.

7 Otras consideraciones

- **PCA**: con dos componentes ya se ven las tres variedades separadas. Es un buen ejemplo para introducir PCA.
- **Versión del GitHub del curso**: `wine.arff` es el mismo dataset (se cita como duplicado).
- **No confundir con Wine Quality**: aquel es de regresión o clasificación ordinal sobre vinos verdes portugueses.

En la carpeta	`wine` ← `wine.tab` (datasets.biolab.si)
Duplicado, no se copia	`wine.arff` (curso_ciencia_datos (GitHub))

4.05
Clasificación: ciencias naturales y físicas

E. coli promoter gene sequences

`04_clasificacion_ciencias_naturales/promoters/`

106 fragmentos de ADN de E. coli de 57 nucleótidos, la mitad promotores de genes y la otra mitad no: clasificación binaria con atributos categóricos (a, c, g, t) donde la posición de cada letra importa.

Clasificación binaria · ◇ Solo categóricos · ¶ Texto

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
106	**58**	`y`	**0,0 %**	**Avanzado**	**Ninguno**

Fichero	Filas × col.	Descargar
`promoters`	106 × 58	CSV 13 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/04_clasificacion_ciencias_naturales/promoters/` seguido del nombre del fichero CSV.

Radiografía

y en promoters



Posiciones más conservadas en los promotores (% con la letra más frecuente)



1 Descripción general y estudios habituales

Un **promotor** es la zona del ADN, justo antes de un gen, donde se une la ARN polimerasa para empezar a leerlo. Cada fila es una secuencia de 57 nucleótidos de la bacteria *E. coli*, desde la posición −50 hasta la +7 respecto al inicio del gen, y cada columna es la letra en una posición (`a`, `c`, `g` o `t`). La mitad de las secuencias son promotores y la otra mitad no.

Los estudios habituales son:

- **Clasificación binaria** con atributos categóricos y muy pocos casos.
- **Interpretación biológica**: qué posiciones y letras identifican un promotor (las «cajas» −35 y −10).
- **Combinar conocimiento y datos**: el dataset se creó para probar un sistema que refina una teoría previa con ejemplos.

2 Contexto y fuente original

Los promotores proceden de **C. Harley y R. Reynolds** (1987), y los no promotores y la «teoría del dominio» (reglas escritas por biólogos para reconocer promotores) de **M. Noordewier**, a partir de una secuencia del laboratorio de Tom Record (Universidad de Wisconsin). Lo donaron **Noordewier y J. Shavlik** en 1990 para evaluar **KBANN**, una red neuronal que parte de esas reglas y las corrige con ejemplos. Con validación «dejando uno fuera», KBANN cometió 4 errores de 106; una red normal, 8; el vecino más cercano (k = 3), 13; y el árbol ID3, 19.

- Towell, G., Shavlik, J. y Noordewier, M. (1990). Refinement of approximate domain theories by knowledge-based artificial neural networks. AAAI-90.

3 Variable objetivo

La clase es `y` : `pp` (promotor, 53) o `mm` (no promotor, 53). Está perfectamente equilibrada: decir siempre lo mismo acierta un 50 %.

Los promotores tienen dos zonas reconocibles. En la **caja −35**, el 79–81 % de los promotores tienen `t` , `t` , `g` en las posiciones −36, −35 y −34, frente al 21 % de los no promotores. En la **caja −10** hay muchas `a` y `t` . En una prueba con validación cruzada de 10 bolsas, la regresión logística acierta un 93 %, Naive Bayes un 92 %, el bosque aleatorio un 88 % y el árbol un 80 %.

4 Diccionario de columnas

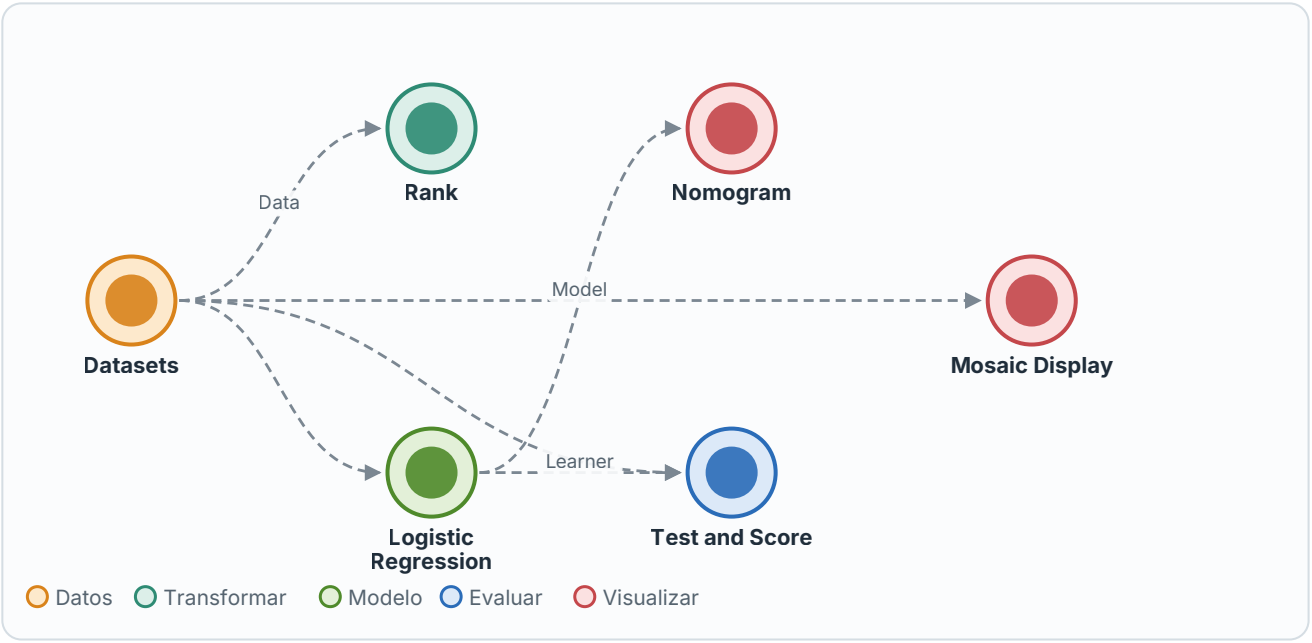
Columnas de `promoters` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
p-50	categórica	Nucleótido en la posición −50: `a` , `c` , `g` o `t` .	t (38), c (27), a (26), g (15)
p-49	categórica	Posición −49. Así sucesivamente hasta `p-01` (posición −1) y luego de `p+01` a `p+07` .	a (34), t (26), g (24), c (22)
y `objetivo`	categórica	**Clase**: `pp` (promotor) o `mm` (no promotor).	pp (53), mm (53)
…		y 55 columnas más del mismo tipo que la anterior.	

5 Particularidades técnicas al modelar

- **Nombres de columna corregidos**: en el fichero de Orange faltaba `p-11` y había un `p+00` , posición que no existe (se pasa de −1 a +1). Comparando con las reglas del dataset original, las columnas de `p-10` a `p+00` de Orange estaban desplazadas una posición. En este CSV se han renombrado: lo que Orange llama `p-10` es aquí `p-11` , y así hasta `p+00` , que es `p-01` . Los datos no cambian.
- **Atributos categóricos sin orden**: cada letra es una categoría. Para regresión logística o kNN, Orange las convierte en variables indicadoras (4 por posición, 228 en total) con más columnas que filas.
- **Muy pocos casos** (106) para 57 atributos: los resultados varían mucho entre particiones. Usa validación «dejando uno fuera» para comparar con el artículo.
- **Falta el nombre de cada secuencia**: el original incluía un identificador (`S10` , `AMPC` …) que Orange no conserva.
- **La posición importa, el orden no**: los modelos tratan cada posición por separado; una caja desplazada una posición ya no se reconoce.

6 Flujo de trabajo en Orange



1. **Datasets** → «Promoters» (o **File** con el CSV).
2. **Rank**: las posiciones −36, −35 y −34 deberían salir arriba.
3. **Test and Score** con *Leave one out*, regresión logística, Naive Bayes y árbol.
4. **Nomogram** de la regresión logística: qué letras en qué posiciones empujan hacia «promotor».
5. **Mosaic Display** con `p-35` y la clase.

7 Otras consideraciones

- **Reglas del original**: el repositorio UCI incluye la teoría del dominio (`promoters.theory`) con las reglas de las cajas −35 y −10. Es un buen ejercicio comprobar con *Select Rows* cuántas secuencias cumplen cada regla; según su documentación, ninguna secuencia las cumple todas de forma exacta.
- **Análisis de secuencias**: el add-on *Bioinformatics* de Orange tiene herramientas más específicas para genes.
- **Otro dataset de ADN**: *splice junction* (UCI) usa el mismo formato con 60 posiciones y tres clases.

En la carpeta `promoters` ← `promoters.tab` (datasets.biolab.si)

4.06
Clasificación: ciencias naturales y físicas

Poker Hand

`04_clasificacion_ciencias_naturales/poker_hand/`

Algo más de un millón de manos de póquer de cinco cartas y su jugada (pareja, color, escalera…): las reglas son sencillas y conocidas, pero con los atributos tal cual los modelos apenas superan el azar. Un ejemplo de por qué la representación de los datos importa.

Clasificación multiclase · ⚖ Desbalanceado · ▤ Grande · ◈ Mixto num. + cat. · ✎ Sintético

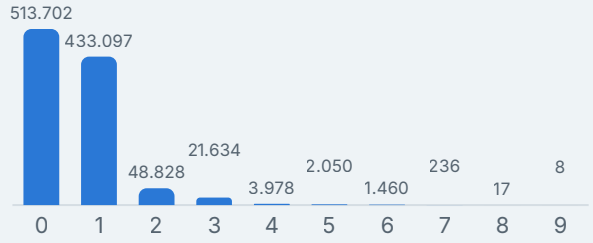
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
1.025.010	**12**	`Poker Hand`	**0,0 %**	**Avanzado**	**Ninguno**

Fichero	Filas × col.	Descargar
`poker_hand`	1.025.010 × 12	CSV 29,3 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/04_clasificacion_ciencias_naturales/poker_hand/` seguido del nombre del fichero CSV.

Radiografía

Poker Hand en poker_hand



Acierto en 200.000 manos de prueba (entrenando con 25.010), %



1 Descripción general y estudios habituales

Cada fila es una mano de cinco cartas de una baraja francesa de 52. Cada carta tiene dos atributos: el **palo** (`S1` … `S5` , de 1 a 4) y el **valor** (`C1` … `C5` , de 1 = as a 13 = rey). La clase es la **jugada**, de 0 (nada) a 9 (escalera real). Los datos son sintéticos: las manos se generaron al azar y la jugada se calculó con las reglas.

Los estudios habituales son:

- **Clasificación multiclase muy desequilibrada**: la mitad de las manos no tienen nada y hay 8 escaleras reales.

- **Ingeniería de atributos**: con variables como «cuántas cartas se repiten» o «cuántos palos distintos hay», el problema se resuelve casi por completo.
- **Datos grandes**: más de un millón de filas para probar la velocidad de los algoritmos.

2 Contexto y fuente original

Lo crearon **Robert Cattral y Franz Oppacher** (Universidad de Carleton, Canadá) para probar algoritmos que aprenden reglas; lo donaron al repositorio UCI en 2007. El original tiene dos ficheros: entrenamiento (25.010 manos) y prueba (1.000.000). Orange los ha juntado en uno, con una columna meta `train/test` que dice de cuál viene cada mano.

- Cattral, R. y Oppacher, F. (2007). Poker Hand. UCI Machine Learning Repository.

3 Variable objetivo

La clase es `Poker Hand`, la jugada:

- `0` nada (513.702) · `1` pareja (433.097) · `2` doble pareja (48.828) · `3` trío (21.634).
- `4` escalera (3.978) · `5` color (2.050) · `6` *full* (1.460) · `7` póquer (236).
- `8` escalera de color (17) · `9` escalera real (8).

Entrenando con las 25.010 manos de entrenamiento y probando con 200.000 de prueba, el árbol acierta un 44 %, Naive Bayes y la regresión logística un 50 % (justo lo que se acierta diciendo siempre «nada») y el bosque aleatorio un 57 %. Con cuatro atributos construidos (veces que se repite el valor más frecuente y el segundo, número de palos distintos y distancia entre la carta más alta y la más baja), el árbol acierta un 97 % y el bosque aleatorio un **99,96 %**.

4 Diccionario de columnas

Columnas de `poker_hand` (valores observados en el fichero)

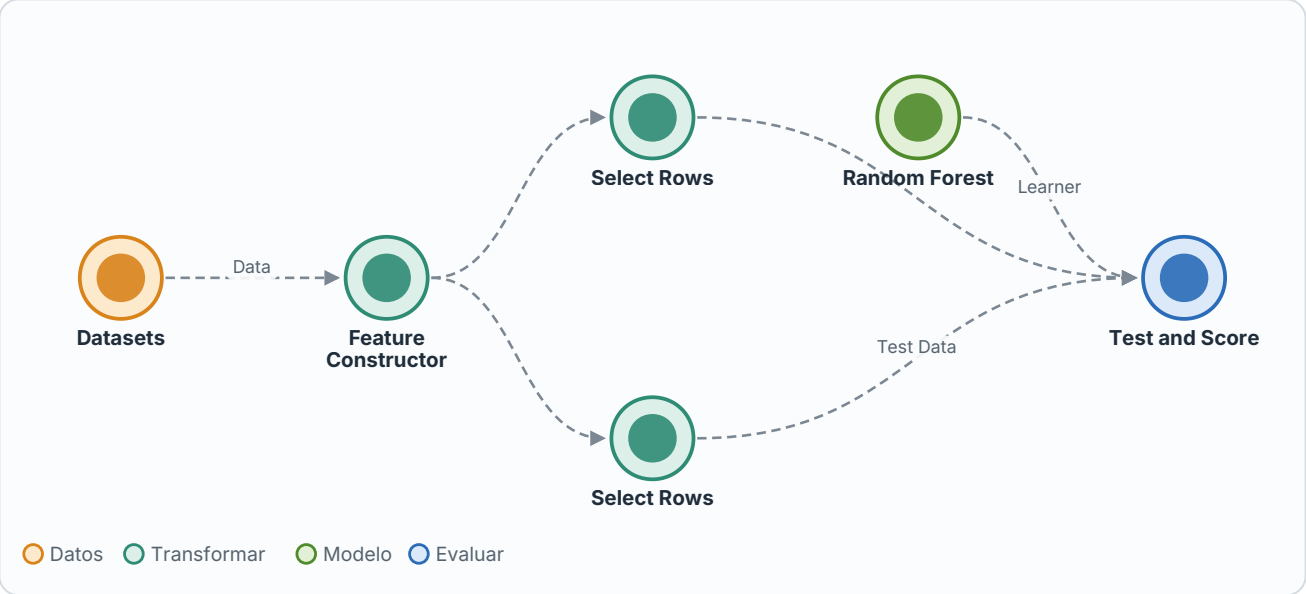
Columna	Tipo	Significado	Valores
`train/test`	categórica	Fichero original de la mano: `train` (25.010) o `test` (1.000.000). Meta.	test (1.000.000), train (25.010)
S1	categórica	Palo de la carta 1: 1 = corazones, 2 = picas, 3 = diamantes, 4 = tréboles.	3 (257.150), 1 (256.087), 4 (256.077), 2 (255.696)
C1	numérica	Valor de la carta 1: 1 = as, 2–10, 11 = jota, 12 = reina, 13 = rey.	1 – 13
S2	categórica	Palo de la carta 2.	1 (256.671), 4 (256.535), 3 (255.943), 2 (255.861)
C2	numérica	Valor de la carta 2.	1 – 13
S3	categórica	Palo de la carta 3.	3 (256.901), 4 (256.531), 1 (256.331), 2 (255.247)
C3	numérica	Valor de la carta 3. **En el fichero de Orange se llamaba** `C4` (ver particularidades).	1 – 13

Columna	Tipo	Significado	Valores
S4	categórica	Palo de la carta 4.	3 (256.914), 2 (256.530), 4 (255.816), 1 (255.750)
C4	numérica	Valor de la carta 4.	1 – 13
S5	categórica	Palo de la carta 5.	1 (257.063), 4 (256.483), 3 (255.986), 2 (255.478)
C5	numérica	Valor de la carta 5.	1 – 13
`Poker Hand` `objetivo`	categórica	**Clase**: jugada, de 0 (nada) a 9 (escalera real).	0 (513.702), 1 (433.097), 2 (48.828), 3 (21.634), 4 (3.978), 5 (2.050) …

5 Particularidades técnicas al modelar

- **Nombre de columna corregido**: en el fichero de Orange, el valor de la tercera carta se llama `C4`, igual que el de la cuarta. Al leerlo, Orange los renombra `C4 (1)` y `C4 (2)`. En este CSV se llaman `C3` y `C4`, en su orden (comprobado con el fichero original de UCI).
- **El orden de las cartas no importa**, pero los modelos no lo saben: «as de picas en la carta 1» y «as de picas en la carta 3» son cosas distintas para ellos. Las jugadas dependen de relaciones entre cartas (repeticiones, palos iguales, valores consecutivos) que ningún atributo recoge por separado.
- **Clases muy raras**: la escalera real aparece 8 veces y la escalera de color 17. El acierto global oculta que esas clases casi nunca se aciertan. En el fichero de entrenamiento, las clases raras están sobrerrepresentadas respecto a su probabilidad real.
- **Fichero grande**: 1.025.010 filas (29 MB en CSV). Orange lo carga, pero algunos widgets (kNN, *Scatter Plot*, *Test and Score* con validación cruzada) se vuelven lentos. Usa *Data Sampler* o *Select Rows* con `train/test`.
- **Manos repetidas**: 2.239 manos aparecen más de una vez (las mismas cartas en el mismo orden), y 109 están en entrenamiento y en prueba.
- **Palos y valores como números**: en el CSV son números. Los palos deberían ser categóricos; cámbialos en **File**.

6 Flujo de trabajo en Orange



1. **Datasets** → «Poker Hand» (o **File** con el CSV, con los palos categóricos).
2. Primero sin **Feature Constructor**: **Select Rows** con `train/test` = `train` para entrenar, y otro con `test` seguido de un **Data Sampler** para quedarte con una muestra.
3. **Test and Score** con *Test on test data*: árbol, Naive Bayes y bosque aleatorio. Mira la matriz de confusión.
4. Intercala **Feature Constructor** antes de separar: crea atributos que describan la mano entera, como el número de palos distintos o cuántas cartas comparten el valor más repetido.
5. Repite la evaluación con los atributos nuevos: el salto de acierto es enorme.

7 Otras consideraciones

- **Lección**: el mismo algoritmo pasa del 57 % al 99,96 % solo cambiando cómo se describen los datos. Es el mejor ejemplo del libro de que la ingeniería de atributos puede importar más que el modelo.
- **Ases altos**: la escalera 10-J-Q-K-A tiene una distancia de 12 entre la carta más alta (13) y la más baja (1). Un atributo de «distancia» debe tratar el as como 14 en ese caso.
- **Probabilidades reales**: en la prueba, la frecuencia de cada jugada se acerca a la probabilidad teórica (50,1 % nada, 42,2 % pareja…); se puede comparar con la tabla de probabilidades del póquer.

En la carpeta `poker_hand` ← `poker-hand.tab` (datasets.biolab.si)

5 Regresión

14 datasets en el capítulo; en esta edición, 14 con ficha.

5.01
Regresión

Boston Housing

`05_regresion/housing/`

506 zonas del área de Boston en 1970 y el valor mediano de sus viviendas: el dataset clásico de regresión, hoy retirado de varias bibliotecas por una variable construida a partir del porcentaje de población negra.

Regresión ⚑ Sesgo y equidad

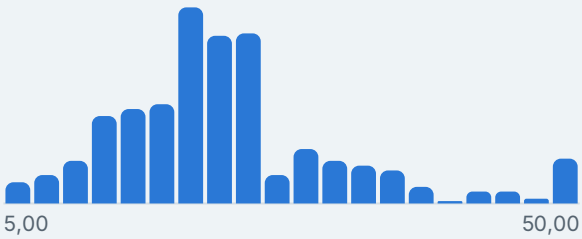
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
506	**14**	`MEDV`	**0,0 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`housing`	506 × 14	CSV 35 KB · XLSX

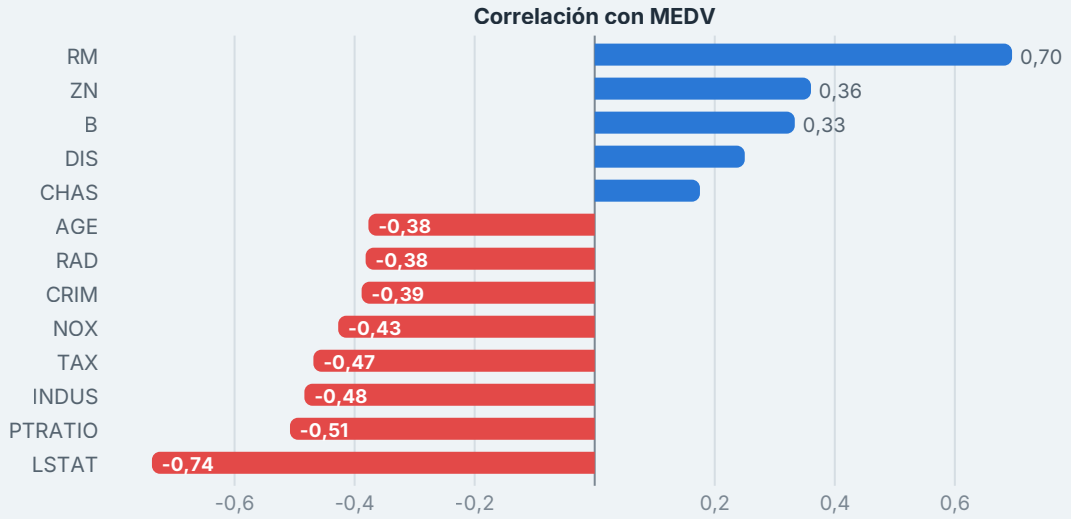
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/05_regresion/housing/` seguido del nombre del fichero CSV.

Radiografía

MEDV en housing



Correlación de cada variable con el valor de la vivienda



1 Descripción general y estudios habituales

Cada fila es una zona censal del área metropolitana de Boston con 13 variables: criminalidad, suelo residencial e industrial, si linda con el río Charles, contaminación por óxidos de nitrógeno, número medio de habitaciones, antigüedad de las viviendas, distancia a los centros de empleo, acceso a autopistas, impuestos, alumnos por profesor, una variable racial (`B`) y el porcentaje de población de nivel socioeconómico bajo. El objetivo es el **valor mediano de las viviendas ocupadas por sus propietarios**.

Los estudios habituales son:

- **Regresión** con atributos numéricos.
- **Interpretación de coeficientes** de la regresión lineal y comparación con modelos no lineales.
- **Ética de los datos**: qué variables no deberían usarse y por qué.

2 Contexto y fuente original

Lo publicaron **David Harrison y Daniel Rubinfeld** en 1978, en un estudio sobre cuánto estaban dispuestos a pagar los ciudadanos por respirar aire limpio (el «precio hedónico» de la contaminación). Los datos son del censo de Estados Unidos de 1970. Se distribuyó en StatLib y en el repositorio UCI, y fue durante décadas el ejemplo estándar de regresión.

En 2020–2022 varias bibliotecas lo retiraron (scikit-learn desde la versión 1.2), porque la variable `B` se construyó suponiendo que el efecto de la población negra sobre el precio era una parábola, y porque los datos tienen otros problemas conocidos. La versión de Orange se mantiene.

- Harrison, D. y Rubinfeld, D. L. (1978). Hedonic housing prices and the demand for clean air. Journal of Environmental Economics and Management, 5, 81–102.
- Boston house-price data en StatLib

3 Variable objetivo

El objetivo es `MEDV` , el valor mediano de las viviendas en miles de dólares de 1970 (de 5 a 50, media 22,5).

Las dos variables más relacionadas son el número de habitaciones (`RM` , correlación 0,70) y el porcentaje de población de nivel bajo (`LSTAT` , −0,74). En una prueba con validación cruzada de 10 bolsas, la regresión lineal

explica un 72 % de la varianza (R^2 = 0,72; error típico de 4.900 dólares) y el bosque aleatorio un 83 % (RMSE de 3.800 dólares).

4 Diccionario de columnas

Columnas de `housing` (valores observados en el fichero)

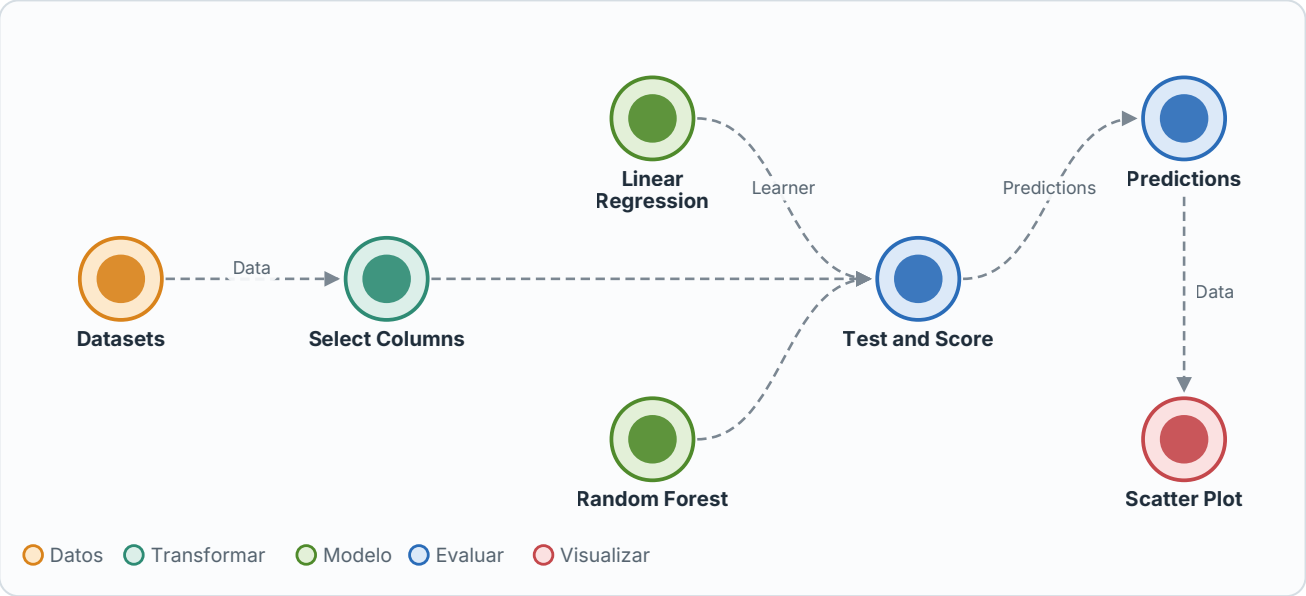
Columna	Tipo	Significado	Valores
`CRIM`	numérica	Tasa de criminalidad per cápita de la zona.	0,006 – 88,976
`ZN`	numérica	Porcentaje de suelo residencial con parcelas de más de 25.000 pies².	0 – 100
`INDUS`	numérica	Porcentaje de suelo para negocios no comerciales (industria).	0,46 – 27,74
`CHAS`	numérica	Si la zona linda con el río Charles (1) o no (0).	0 – 1
`NOX`	numérica	Concentración de óxidos de nitrógeno (partes por 10 millones).	0,385 – 0,871
`RM`	numérica	Número medio de habitaciones por vivienda.	3,561 – 8,78
`AGE`	numérica	Porcentaje de viviendas ocupadas por sus propietarios construidas antes de 1940.	2,9 – 100
`DIS`	numérica	Distancia ponderada a cinco centros de empleo de Boston.	1,13 – 12,127
`RAD`	numérica	Índice de accesibilidad a autopistas radiales (1–24).	1 – 24
`TAX`	numérica	Impuesto sobre la propiedad por cada 10.000 dólares.	187 – 711
`PTRATIO`	numérica	Alumnos por profesor.	12,6 – 22
`B`	numérica	1000 × (Bk − 0,63)², donde Bk es la proporción de población negra. **Variable problemática** (ver particularidades).	0,32 – 396,9
`LSTAT`	numérica	Porcentaje de población de nivel socioeconómico bajo.	1,73 – 37,97
`MEDV` `objetivo`	numérica	**Objetivo**: valor mediano de las viviendas en propiedad, en miles de dólares.	5 – 50

5 Particularidades técnicas al modelar

- **La variable** `B`: transforma la proporción de población negra con una parábola centrada en el 63 %, porque los autores suponían que el precio bajaba con la segregación en ambos sentidos. Es una variable racial que no debería usarse para fijar precios, y su forma no permite recuperar la proporción original de manera única. Lo habitual hoy es quitarla o usar el dataset para hablar de ética.
- **Valor máximo censurado**: 16 zonas tienen `MEDV` = 50 exactamente. Es un tope del censo, no un valor real. Los modelos aprenden ese tope; se pueden quitar esas filas o tratarlas aparte.
- **Relaciones no lineales**: `LSTAT` y `RM` tienen relaciones curvas con el precio. Una regresión lineal mejora con términos como `LSTAT²` o `log(LSTAT)` (*Feature Constructor*).

- **Variables muy correlacionadas**: `RAD` y `TAX` (0,91), `NOX`, `INDUS` y `DIS`. Los coeficientes de la regresión lineal son inestables; prueba *Ridge* o *Lasso*.
- `CHAS` **es binaria** aunque esté como número.
- No hay valores ausentes en esta versión.

6 Flujo de trabajo en Orange



1. **Datasets** → «Housing» (o **File** con el CSV).
2. **Select Columns**: quita `B` (y comenta por qué).
3. **Test and Score** con regresión lineal (prueba también *Ridge* y *Lasso*) y bosque aleatorio; compara RMSE y R^2.
4. **Linear Regression** → **Data Table** de coeficientes, normalizando antes para poder compararlos.
5. **Scatter Plot** del valor real frente al predicho: el tope de 50 aparece como una línea horizontal.

7 Otras consideraciones

- **Alternativas modernas**: Ames Housing (más rico y sin variables raciales) y California Housing, en este mismo capítulo.
- **Precio hedónico**: el objetivo original era medir el efecto de `NOX` sobre el precio, no predecir. Es un buen ejemplo de la diferencia entre explicar y predecir.

En la carpeta	`housing` ← `housing.tab` (datasets.biolab.si)
Duplicado, no se copia	`regresion_housing.arff` (curso_ciencia_datos (GitHub))

5.02
Regresión

California Housing

`05_regresion/california_housing/`

20.640 barrios de California del censo de 1990 con su renta, edad de las viviendas, ocupación y coordenadas: regresión del valor mediano de la vivienda con datos geográficos y topes artificiales en tres variables.

Regresión · Espacial · Grande

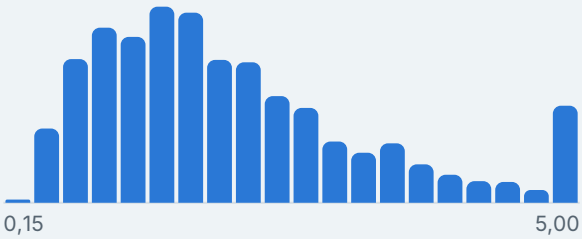
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
20.640	**9**	`MedHouseVal`	**0,0 %**	**Intermedio**	**Geo**

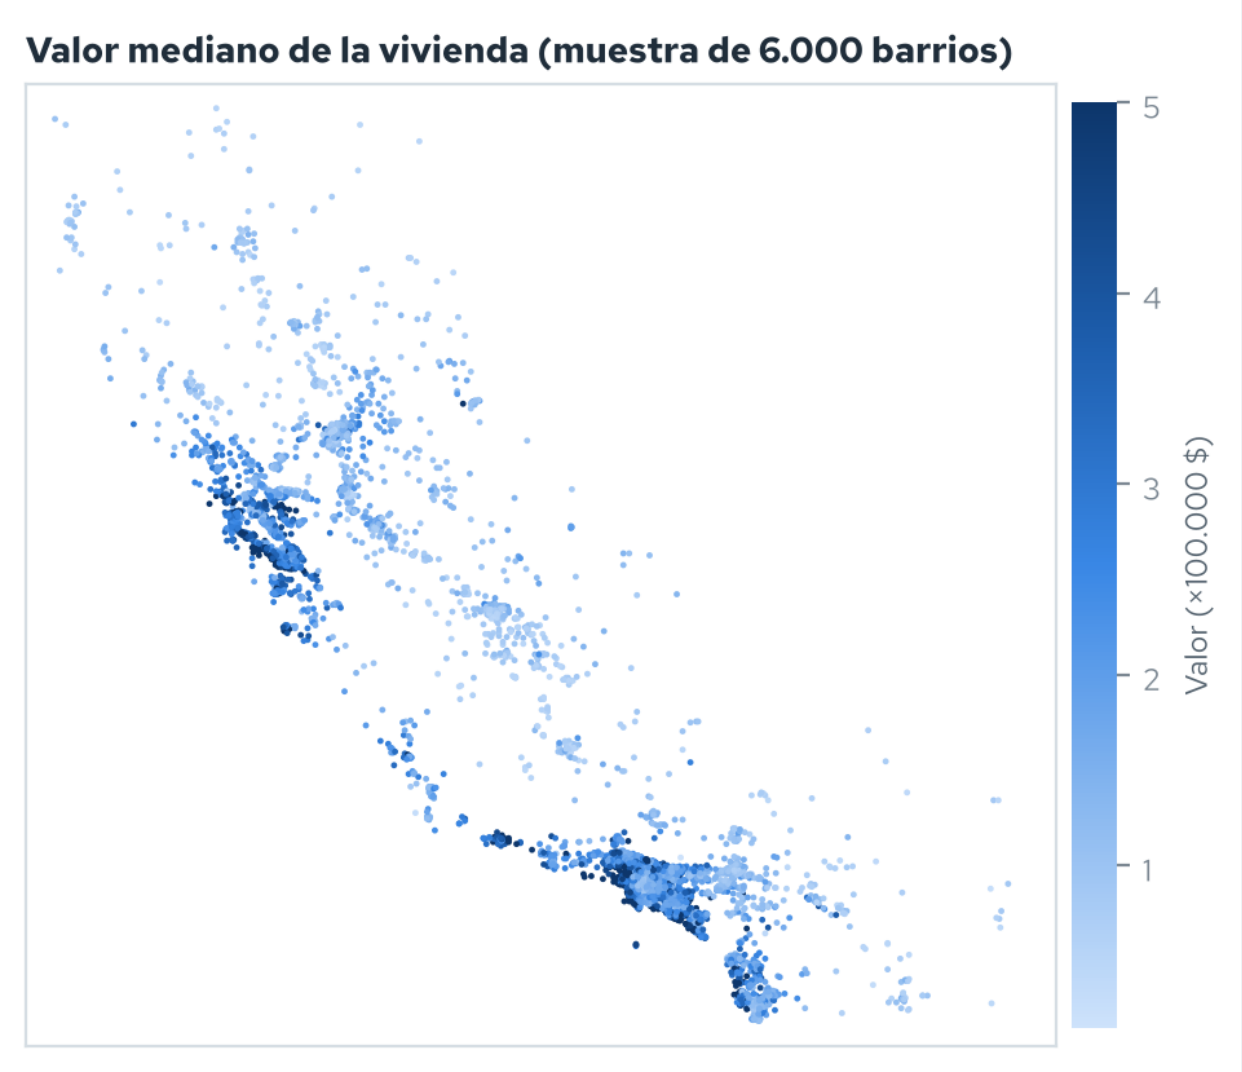
Fichero	Filas × col.	Descargar
`california_housing`	20.640 × 9	CSV 1,8 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/05_regresion/california_housing/` seguido del nombre del fichero CSV.

Radiografía

MedHouseVal en california_housing





1 Descripción general y estudios habituales

Cada fila es un **grupo de manzanas** (*block group*, la unidad más pequeña del censo de Estados Unidos, con unas 600–3.000 personas) de California en 1990. Las variables son la renta mediana, la antigüedad mediana de las viviendas, el número medio de habitaciones y dormitorios por vivienda, la población, la ocupación media (personas por vivienda), la latitud y la longitud. El objetivo es el **valor mediano de la vivienda**.

Los estudios habituales son:

- **Regresión** con muchos casos y pocas variables.
- **Datos geográficos**: la ubicación (costa, Bahía de San Francisco, Los Ángeles) explica buena parte del precio.
- **Limpieza**: topes, valores extremos y variables derivadas.

2 Contexto y fuente original

Lo publicaron **R. Kelley Pace y Ronald Barry** en 1997 en un artículo sobre autorregresión espacial, y se difundió a través de StatLib. Es el dataset de regresión de ejemplo de scikit-learn desde que se retiró Boston

Housing. La versión de Orange, como la de scikit-learn, usa medias por vivienda (habitaciones, dormitorios, ocupantes) y el valor en cientos de miles de dólares.

- Pace, R. K. y Barry, R. (1997). Sparse spatial autoregressions. Statistics & Probability Letters, 33(3), 291–297.
- California Housing en la documentación de scikit-learn

3 Variable objetivo

El objetivo es `MedHouseVal`, el valor mediano de la vivienda en cientos de miles de dólares (de 0,15 a 5, media 2,07). **Está topado en 5**: 992 barrios tienen exactamente 5,00001, que significa «500.000 dólares o más».

La renta mediana es lo que más se relaciona con el precio (correlación 0,69), seguida de la ubicación. En una prueba con validación cruzada de 5 bolsas, la regresión lineal y el árbol explican un 60 % de la varianza, kNN con datos normalizados un 69 % y el bosque aleatorio un **81 %** (RMSE de 50.000 dólares): los modelos que combinan latitud y longitud captan el efecto de la costa.

4 Diccionario de columnas

Columnas de `california_housing` (valores observados en el fichero)

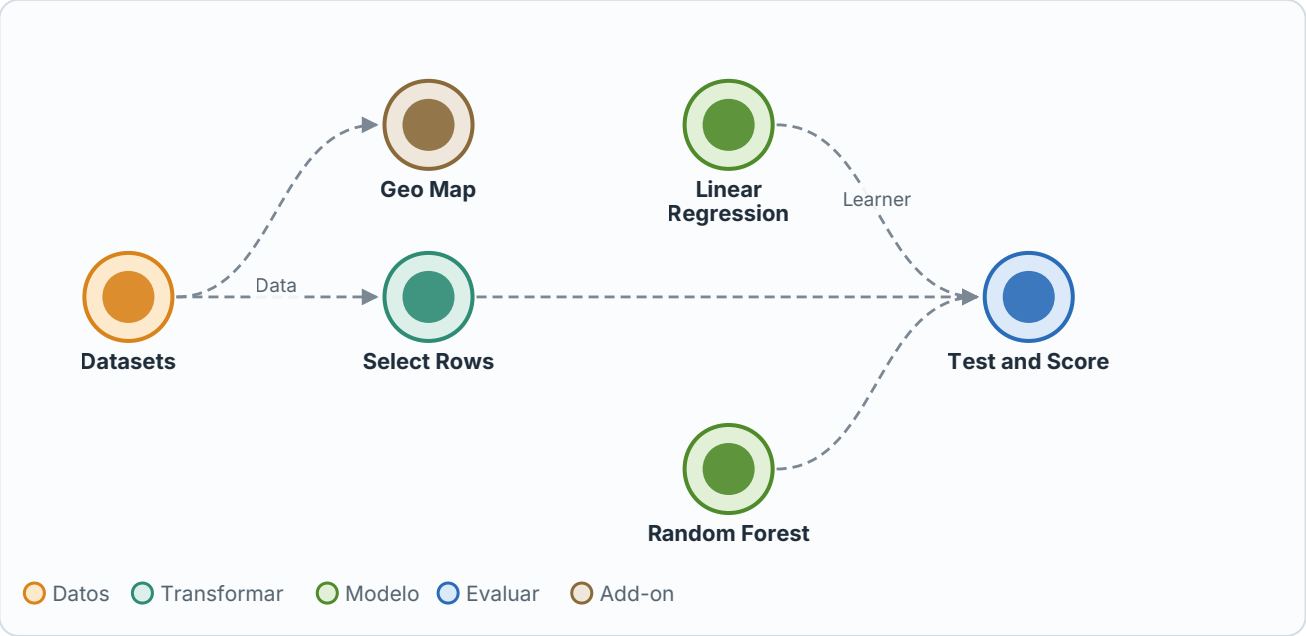
Columna	Tipo	Significado	Valores
`MedInc`	numérica	Renta mediana de los hogares, en decenas de miles de dólares (de 0,5 a 15; **topada en 15,0001**).	0,5 – 15
`HouseAge`	numérica	Antigüedad mediana de las viviendas en años (de 1 a 52; **topada en 52**).	1 – 52
`AveRooms`	numérica	Habitaciones por vivienda (media).	0,846 – 141,909
`AveBedrms`	numérica	Dormitorios por vivienda (media).	0,333 – 34,067
`Population`	numérica	Personas que viven en el grupo de manzanas.	3 – 35.682
`AveOccup`	numérica	Personas por vivienda (media). Tiene valores extremos de hasta 1.243.	0,692 – 1.243,333
`Latitude`	numérica	Latitud del centro del grupo de manzanas.	32,54 – 41,95
`Longitude`	numérica	Longitud del centro del grupo de manzanas.	-124,35 – -114,31
`MedHouseVal` `objetivo`	numérica	**Objetivo**: valor mediano de la vivienda, en cientos de miles de dólares (**topado en 5,00001**).	0,15 – 5

5 Particularidades técnicas al modelar

- **Tres variables topadas**: el valor (992 barrios en 5,00001), la antigüedad (1.273 en 52) y la renta (51 en 15,0001). En un histograma se ven como picos al final. Los modelos predicen mal cerca del tope; se pueden quitar esas filas o tratarlas como un caso aparte.

- **Medias con valores absurdos**: en barrios con pocas viviendas y mucha población (residencias, cárceles, zonas turísticas), `AveOccup` llega a 1.243 personas por vivienda y `AveRooms` a 142 habitaciones. Afectan mucho a la regresión lineal; conviene recortarlos o usar logaritmos.
- **La ubicación no es lineal**: el precio sube cerca de la costa y en las grandes ciudades, algo que una regresión lineal con latitud y longitud no capta. Los árboles y kNN sí.
- **Fichero grande para algunos widgets**: 20.640 filas. kNN y la validación cruzada con bosque aleatorio tardan algo; *Scatter Plot* va bien.
- No hay valores ausentes.

6 Flujo de trabajo en Orange



1. **Datasets** → «California Housing» (o **File** con el CSV).
2. **Distributions** de `MedHouseVal` y `HouseAge`: busca los picos del tope.
3. **Select Rows** con `MedHouseVal` < 5 (opcional) para quitar los barrios topados.
4. **Test and Score** con regresión lineal y bosque aleatorio (validación de 5 bolsas para que no tarde).
5. **Geo Map** (add-on *Geo*) o **Scatter Plot** de longitud frente a latitud coloreado por valor.

7 Otras consideraciones

- **Variables nuevas**: dormitorios por habitación (`AveBedrms / AveRooms`) o distancia a la costa o a Los Ángeles y San Francisco mejoran la regresión lineal.
- **Transformar el objetivo**: el logaritmo del valor reduce la asimetría.
- **La versión de Aurélien Géron** (libro *Hands-On Machine Learning*) usa totales en lugar de medias y añade la proximidad al océano como categoría; no es exactamente este fichero.

En la carpeta `california_housing` ← `california_housing.xlsx` (datasets.biolab.si)

5.03
Regresión

Ames Iowa Housing

`05_regresion/ames_housing/`

2.930 viviendas vendidas en Ames (Iowa) entre 2006 y 2010, descritas por 79 variables: la alternativa moderna a Boston Housing, con muchos huecos que no son datos perdidos sino «no tiene».

Regresión · ? Valores faltantes · ◈ Mixto num. + cat.

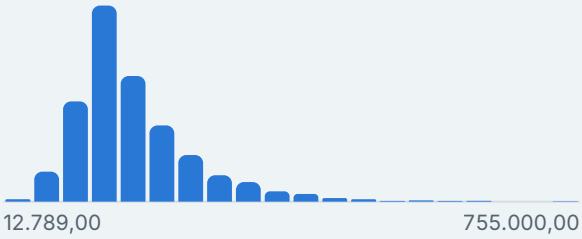
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
2.930	**81**	`SalePrice`	**5,9 %**	**Avanzado**	**Ninguno**

Fichero	Filas × col.	Descargar
`ames_housing`	2.930 × 81	CSV 897 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/05_regresion/ames_housing/` seguido del nombre del fichero CSV.

Radiografía

SalePrice en ames_housing



Las 12 variables numéricas más relacionadas con el precio



1 Descripción general y estudios habituales

Cada fila es una vivienda vendida en Ames, una ciudad universitaria de Iowa, con 79 variables que describen casi todo: barrio, parcela, tipo y estilo de casa, calidad y estado generales, año de construcción y de reforma, tejado, fachada, sótano, calefacción, superficies de cada planta, baños, cocina, chimeneas, garaje, porches, piscina, valla, extras y condiciones de la venta. El objetivo es el **precio de venta**.

Los estudios habituales son:

- **Regresión** con muchas variables mixtas (numéricas, ordinales y nominales).
- **Preparación de datos**: huecos con significado, variables ordinales escritas como texto, valores extremos.
- **Selección de variables y regularización** (Lasso, Ridge).

2 Contexto y fuente original

Lo reunió **Dean De Cock** (Truman State University) con los registros de la oficina de tasación de Ames, y lo publicó en 2011 en el *Journal of Statistics Education* como alternativa a Boston Housing para enseñar regresión. Una parte (1.460 casas) se hizo famosa como concurso de Kaggle (*House Prices*). Orange toma la versión completa publicada en Kaggle por Marco Palermo.

- De Cock, D. (2011). Ames, Iowa: Alternative to the Boston Housing Data as an End of Semester Regression Project. Journal of Statistics Education, 19(3).
- Ames Iowa Housing Data en Kaggle (fuente de Orange)

3 Variable objetivo

El objetivo es `SalePrice`, el precio de venta en dólares (de 12.789 a 755.000; mediana de 160.000). Su distribución es asimétrica: conviene modelar su logaritmo.

Las variables más relacionadas son la calidad general (`Overall Qual`, correlación 0,80), la superficie habitable (`Gr Liv Area`, 0,71) y el garaje (plazas y superficie, 0,64–0,65). En una prueba con validación cruzada de 5 bolsas, sin la columna `Order`, la regresión lineal explica un 86 % de la varianza (RMSE de 30.000 dólares) y el bosque aleatorio un 89 % (RMSE de 26.700 dólares).

4 Diccionario de columnas

Columnas de `ames_housing` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`SalePrice` objetivo	numérica	**Objetivo**: precio de venta en dólares.	12.789 – 755.000
`Order`	numérica	Número de fila del fichero original. **No es una característica: quítalo.**	1 – 2.930
`MS SubClass`	numérica	Tipo de vivienda codificado con números (20 = una planta de 1946 o posterior, 60 = dos plantas…). **Es categórica aunque sea un número.**	20 – 190
`MS Zoning`	categórica	Zonificación: `RL` residencial de baja densidad, `RM` media, `FV` residencial flotante, `C (all)` comercial…	RL (2.273), RM (462), FV (139), RH (27), C (all) (25), I (all) (2) …
`Lot Frontage`	numérica	Longitud de calle en contacto con la parcela, en pies. 490 vacíos.	21 – 313

Columna	Tipo	Significado	Valores
`Lot Area`	numérica	Superficie de la parcela en pies².	1.300 – 215.245
`Alley`	categórica	Acceso por callejón: `Grvl` grava, `Pave` asfalto. **Vacío = sin callejón** (2.732).	Grvl (120), Pave (78)
`Neighborhood`	categórica	Barrio de Ames (28 barrios).	NAmes (443), CollgCr (267), OldTown (239), Edwards (194), Somerst (182), NridgHt (166) …
`Bldg Type`	categórica	Tipo de edificio: unifamiliar, adosado, dúplex…	1Fam (2.425), TwnhsE (233), Duplex (109), Twnhs (101), 2fmCon (62)
`House Style`	categórica	Estilo: una planta, dos plantas, planta y media…	1Story (1.481), 2Story (873), 1.5Fin (314), SLvl (128), SFoyer (83), 2.5Unf (24) …
`Overall Qual`	numérica	Calidad general de materiales y acabados (1 = muy mala, 10 = excelente).	1 – 10
`Overall Cond`	numérica	Estado general (1–9).	1 – 9
`Year Built`	numérica	Año de construcción (1872–2010).	1.872 – 2.010
`Year Remod/Add`	numérica	Año de la última reforma (igual al de construcción si no hubo).	1.950 – 2.010
`Mas Vnr Type`	categórica	Tipo de revestimiento de mampostería. **Vacío = ninguno** (1.775).	BrkFace (880), Stone (249), BrkCmn (25), CBlock (1)
`Exter Qual`	categórica	Calidad del exterior: `Ex` excelente, `Gd` buena, `TA` normal, `Fa` regular, `Po` mala. **Ordinal escrita como texto.**	TA (1.799), Gd (989), Ex (107), Fa (35)
`Bsmt Qual`	categórica	Altura del sótano, en la misma escala. **Vacío = sin sótano** (80).	TA (1.283), Gd (1.219), Ex (258), Fa (88), Po (2)
`Total Bsmt SF`	numérica	Superficie total del sótano en pies².	0 – 6.110
`Central Air`	categórica	Si tiene aire acondicionado central.	Y (2.734), N (196)
`Gr Liv Area`	numérica	Superficie habitable sobre rasante en pies². Hay 5 viviendas de más de 4.000 pies² (ver particularidades).	334 – 5.642
`Full Bath`	numérica	Baños completos sobre rasante.	0 – 4

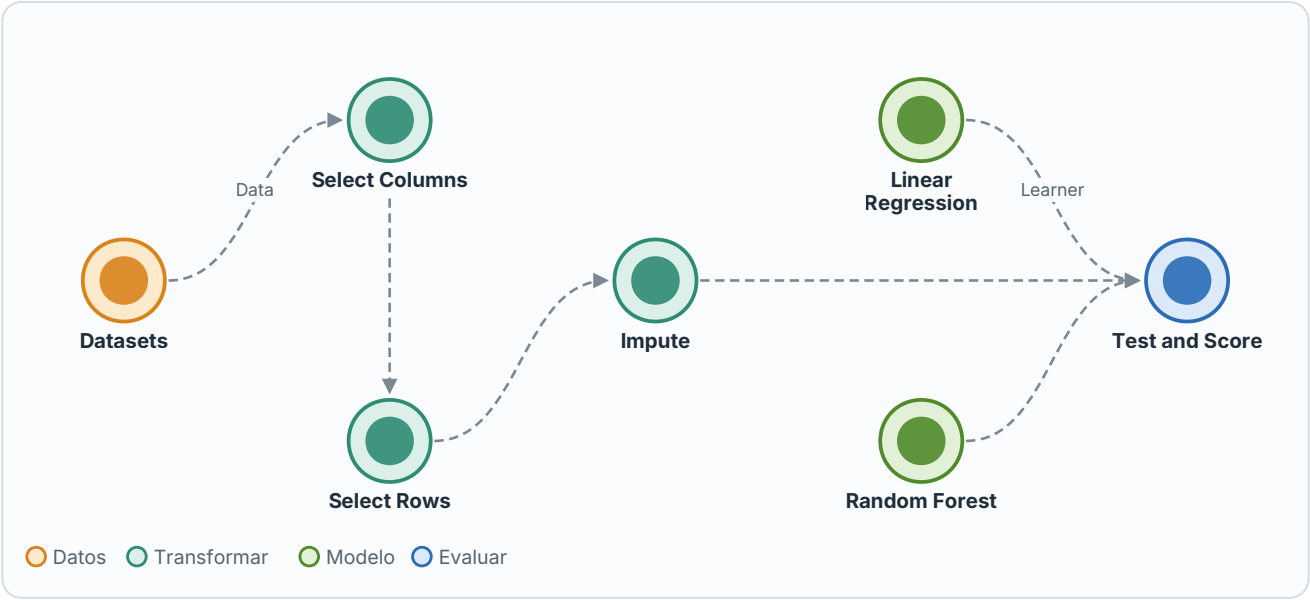
Columna	Tipo	Significado	Valores
`Kitchen Qual`	categórica	Calidad de la cocina (escala `Ex` – `Po`).	TA (1.494), Gd (1.160), Ex (205), Fa (70), Po (1)
`Fireplace Qu`	categórica	Calidad de la chimenea. **Vacío = sin chimenea** (1.422).	Gd (744), TA (600), Fa (75), Po (46), Ex (43)
`Garage Yr Blt`	numérica	Año de construcción del garaje. Vacío si no hay garaje; un valor imposible, 2207.	1.895 – 2.207
`Garage Cars`	numérica	Plazas del garaje.	0 – 5
`Pool QC`	categórica	Calidad de la piscina. **Vacío = sin piscina** (2.917 de 2.930).	Ex (4), Gd (4), TA (3), Fa (2)
`Fence`	categórica	Calidad de la valla. **Vacío = sin valla.**	MnPrv (330), GdPrv (118), GdWo (112), MnWw (12)
`Misc Feature`	categórica	Otros extras (cobertizo, segundo garaje, ascensor, pista de tenis). **Vacío = ninguno.**	Shed (95), Gar2 (5), Othr (4), Elev (1), TenC (1)
`Mo Sold`	numérica	Mes de la venta.	1 – 12
`Yr Sold`	numérica	Año de la venta (2006–2010).	2.006 – 2.010
`Sale Condition`	categórica	Condición de la venta: `Normal`, `Partial` (casa nueva vendida sin terminar), `Abnorml` (ejecución, venta forzosa), `Family` …	Normal (2.413), Partial (245), Abnorml (190), Family (46), Alloca (24), AdjLand (12)
…		y 50 columnas más: zonificación, forma y pendiente de la parcela, materiales y estado del exterior, sótano (calidad, exposición, superficies), calefacción, electricidad, baños, cocinas, chimeneas, garaje, porches, piscina y otros extras.	

5 Particularidades técnicas al modelar

- **Huecos que significan «no tiene»**: en `Pool QC`, `Misc Feature`, `Alley`, `Fence`, `Fireplace Qu`, las variables de garaje y de sótano, un vacío significa que la casa no tiene piscina, callejón, chimenea, garaje o sótano. Si se imputa con la moda o la media se inventan piscinas. Lo correcto es sustituir el vacío por una categoría «ninguno» (o por 0 en las superficies).
- `Order` **es un número de fila**, y en Orange entra como atributo. Quítalo con *Select Columns*.
- **Escalas ordinales como texto**: las calidades (`Ex`, `Gd`, `TA`, `Fa`, `Po`) tienen orden, pero Orange las trata como nominales y las ordena alfabéticamente. Para la regresión lineal es mejor convertirlas a números (5 a 1) con *Feature Constructor*.
- `MS SubClass` **es un código**: 20, 60, 120… son categorías, no cantidades.
- **Valores extremos recomendados para quitar**: De Cock aconseja eliminar las casas de más de 4.000 pies² habitables. Son 5: tres ventas parciales muy baratas para su tamaño y dos casas muy grandes y caras. Distorsionan mucho la regresión lineal.

- **Errores de tecleo**: un garaje construido en «2207» (la casa es de 2006).
- **Variables casi constantes**: `Utilities`, `Street`, `Condition 2`, `Roof Matl` o `Heating` tienen un valor en más del 98 % de las casas.

6 Flujo de trabajo en Orange



1. **Datasets** → «Ames Iowa Housing» (o **File** con el CSV; `MS SubClass` como categórica).
2. **Select Columns**: quita `Order`. **Select Rows**: `Gr Liv Area` < 4000.
3. **Impute**: para las variables con «vacío = no tiene», usa un valor fijo; para el resto, la media o la moda.
4. **Test and Score** con regresión lineal (*Lasso*, con datos normalizados) y bosque aleatorio, validación de 5 bolsas.
5. Con **Feature Constructor**, crea `log(SalePrice)` y repite: los errores se reparten mejor entre casas baratas y caras.

7 Otras consideraciones

- **Documentación original**: De Cock publicó una descripción detallada de las 80 variables y sus códigos, útil para traducir las abreviaturas.
- **Concurso de Kaggle**: el de *House Prices* usa 1.460 de estas casas para entrenar y evalúa con el RMSE del logaritmo del precio.
- **Variables nuevas**: superficie total (sótano + plantas), edad de la casa en la venta, años desde la reforma o número total de baños mejoran los modelos.

En la carpeta `ames_housing` ← `ames-iowa-housing.xlsx` (datasets.biolab.si)

5.04
Regresión

Auto MPG

`05_regresion/auto_mpg/`

398 coches de 1970 a 1982 con su consumo en millas por galón, cilindrada, potencia, peso y origen: un dataset pequeño y limpio para regresión, con una tendencia histórica muy visible (la crisis del petróleo).

Regresión · ? Valores faltantes · ◈ Mixto num. + cat.

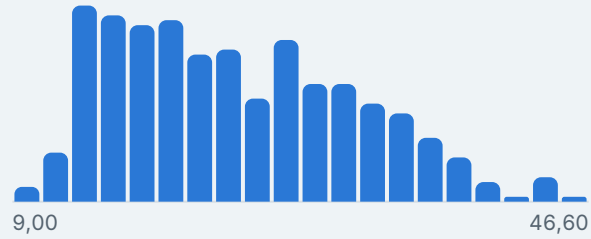
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
398	**9**	`mpg`	**0,2 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`auto_mpg`	398 × 9	CSV 18 KB · XLSX

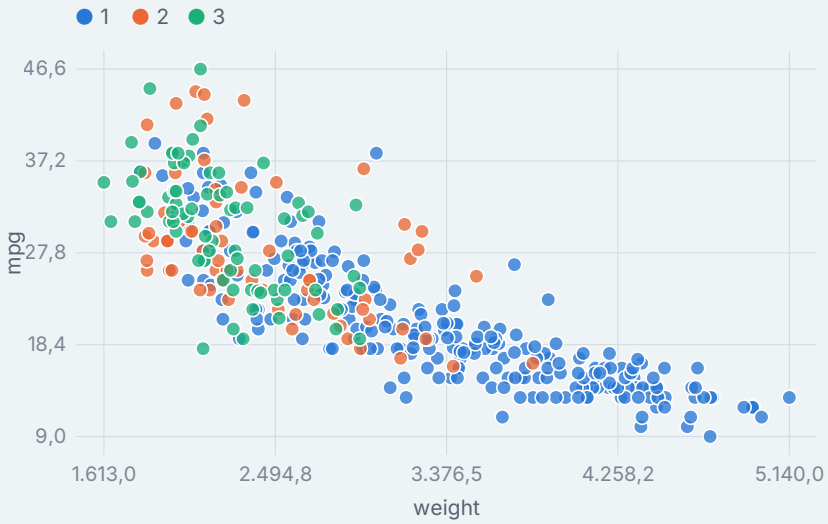
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/05_regresion/auto_mpg/` seguido del nombre del fichero CSV.

Radiografía

mpg en auto_mpg



Peso (libras) y consumo (mpg) por origen: 1 EE. UU., 2 Europa, 3 Japón



1 Descripción general y estudios habituales

Cada fila es un modelo de coche con su número de cilindros, cilindrada, potencia, peso, aceleración, año del modelo (de 1970 a 1982), origen (Estados Unidos, Europa o Japón) y nombre. El objetivo es el **consumo en ciudad**, medido como millas recorridas por galón de combustible (más millas = menos consumo).

Los estudios habituales son:

- **Regresión** con pocas variables, fácil de interpretar.
- **Relaciones no lineales**: el consumo no baja en línea recta con el peso.
- **Exploración histórica**: cómo cambian los coches tras las crisis del petróleo de 1973 y 1979.

2 Contexto y fuente original

Procede de la biblioteca **StatLib** de la Universidad Carnegie Mellon y se usó en la exposición de datos de la American Statistical Association de 1983. **Ross Quinlan** lo usó en 1993 para combinar aprendizaje basado en casos y en modelos, y quitó 8 coches sin consumo. La versión de Orange es la del repositorio UCI.

- Quinlan, R. (1993). Auto MPG. UCI Machine Learning Repository.

3 Variable objetivo

El objetivo es `mpg`, millas por galón (de 9 a 46,6; media 23,5). Para pasarlo a litros cada 100 km: 235,2 / mpg.

El peso es lo que más pesa (correlación −0,83), junto con la cilindrada, la potencia y los cilindros, que están muy relacionados entre sí. El año también cuenta: los coches de 1970 hacían 17,7 mpg de media y los de 1982, 31,7. Los japoneses (30,5) y europeos (27,9) gastan menos que los estadounidenses (20,1). En una prueba con validación cruzada de 10 bolsas, la regresión lineal explica un 81 % de la varianza (RMSE de 3,4 mpg) y el bosque aleatorio un 88 % (2,8 mpg).

4 Diccionario de columnas

Columnas de `auto_mpg` (valores observados en el fichero)

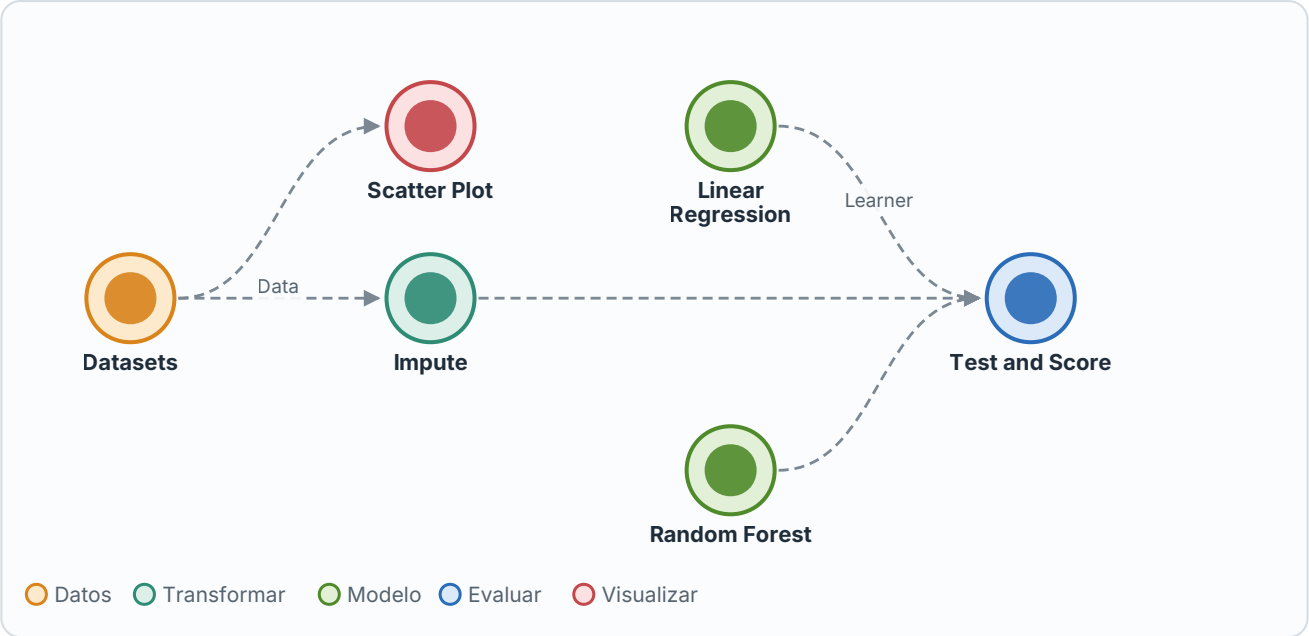
Columna	Tipo	Significado	Valores
`mpg` `objetivo`	numérica	**Objetivo**: millas por galón (EE. UU.) en ciudad.	9 – 46,6
`cylinders`	categórica	Número de cilindros (3, 4, 5, 6 u 8).	4 (204), 8 (103), 6 (84), 3 (4), 5 (3)
`displacement`	numérica	Cilindrada en pulgadas cúbicas.	68 – 455
`horsepower`	numérica	Potencia en caballos. **6 vacíos.**	46 – 230
`weight`	numérica	Peso en libras.	1.613 – 5.140
`acceleration`	numérica	Segundos para pasar de 0 a 60 millas por hora.	8 – 24,8
`model year`	categórica	Año del modelo, con dos cifras (70 = 1970 … 82 = 1982).	73 (40), 78 (36), 76 (34), 82 (31), 75 (30), 80 (29) …
`origin`	categórica	Origen: 1 = Estados Unidos, 2 = Europa, 3 = Japón. **Es categórica aunque sea un número.**	1 (249), 3 (79), 2 (70)

Columna	Tipo	Significado	Valores
`car name`	texto	Marca y modelo (meta). Hay erratas en las marcas: `chevy` / `chevroelt`, `vw` / `vokswagen`, `toyouta`, `maxda`…	ford pinto (6), toyota corolla (5), ford maverick (5), amc matador (5), chevrolet chevette (4), amc gremlin (4) …

5 Particularidades técnicas al modelar

- `origin` **es una categoría**: con los códigos 1–3 como número, la regresión lineal supondría que Europa está «entre» Estados Unidos y Japón. Cámbiala a categórica en **File**.
- **Variables casi redundantes**: cilindros, cilindrada, potencia y peso tienen correlaciones de 0,84 a 0,95 entre sí. Los coeficientes de la regresión lineal pueden salir con signos raros.
- **Relación curva**: el consumo baja con el peso, pero cada vez menos. Transformar el objetivo (litros/100 km o 1/mpg) hace la relación casi lineal.
- **6 potencias vacías**, de coches conocidos (Ford Pinto, Ford Maverick, Renault 18i…). Se pueden imputar o buscar.
- **Nombres con erratas**: si se extrae la marca del nombre, hay que unificar variantes.
- **El año es una tendencia**: si se predicen coches posteriores a 1982, el modelo extrapola.

6 Flujo de trabajo en Orange



1. **Datasets** → «Auto MPG» (o **File** con el CSV, con `origin` categórica).
2. **Scatter Plot** de `weight` frente a `mpg`, coloreado por `origin`.
3. **Impute** para las 6 potencias vacías.
4. **Test and Score** con regresión lineal y bosque aleatorio.
5. **Feature Constructor**: crea `l100km = 235.2 / mpg` y repite con ese objetivo.

7 Otras consideraciones

- **Clasificación**: discretizando `mpg` en tramos (alto, medio, bajo) se convierte en un problema de clasificación.
- **Comparar con Imports-85**: otro dataset de coches de los ochenta, con precio como objetivo.

En la carpeta	`auto_mpg` ← `auto-mpg.tab` (datasets.biolab.si)

5.05
Regresión

Automobile (imports-85)

`05_regresion/imports_85/`

205 modelos de coches importados a Estados Unidos en 1985, con medidas, motor, consumo, riesgo de seguro y precio: regresión del precio con pocas filas, muchas variables mixtas y una columna objetivo con un espacio en el nombre.

Regresión · ? Valores faltantes · ◈ Mixto num. + cat.

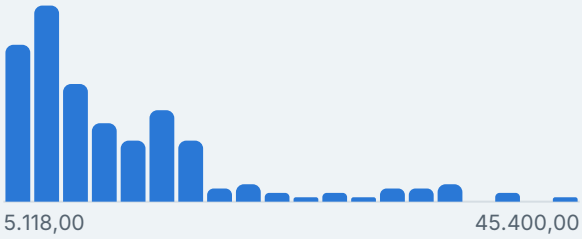
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
205	**26**	`price`	**1,1 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`imports_85`	205 × 26	CSV 25 KB · XLSX

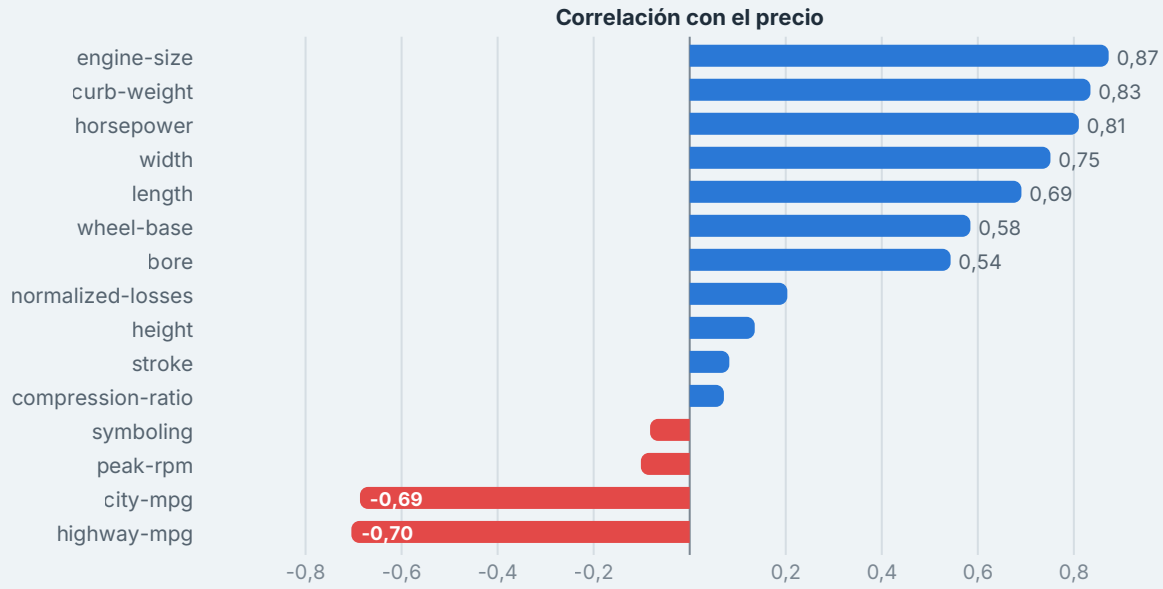
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/05_regresion/imports_85/` seguido del nombre del fichero CSV.

Radiografía

price en imports_85



Correlación de las variables numéricas con el precio



1 Descripción general y estudios habituales

Cada fila es un modelo de coche importado a Estados Unidos en 1985, con tres tipos de información: sus características (marca, combustible, carrocería, tracción, dimensiones, peso, motor, potencia, consumo), su **clasificación de riesgo para el seguro** (`symboling`) y sus **pérdidas normalizadas** (lo que pagan de media las aseguradoras por ese coche). El objetivo en Orange es el **precio**, aunque se puede cambiar.

Los estudios habituales son:

- **Regresión** del precio con variables numéricas y categóricas.
- **Clasificación del riesgo** (`symboling` , de −3 a +3) o regresión de las pérdidas normalizadas.
- **Tratamiento de valores ausentes** en varias columnas.

2 Contexto y fuente original

Lo reunió **Jeffrey C. Schlimmer** en 1987 a partir de tres fuentes de 1985: las especificaciones del anuario de automóviles Ward's, los manuales de seguros de vehículos y el informe de pérdidas del Insurance Institute for Highway Safety. En el repositorio UCI se llama *Automobile*.

El `symboling` funciona así: cada coche recibe un nivel de riesgo según su precio y, si resulta más (o menos) arriesgado de lo que su precio indica, se sube (o baja) en la escala. +3 indica un coche arriesgado; −3, uno probablemente muy seguro.

- Schlimmer, J. (1987). Automobile. UCI Machine Learning Repository.

3 Variable objetivo

El objetivo es `price` (con un espacio al final del nombre), en dólares de 1985: de 5.118 a 45.400, media de 13.200. **4 coches no tienen precio** (un Audi, dos Isuzu y un Porsche) y Orange los descarta al entrenar.

El tamaño del motor es lo que más se relaciona con el precio (correlación 0,87), junto con el peso, la anchura y la potencia. La marca también importa: de 6.000 dólares de media en Chevrolet a 34.600 en Jaguar. En una prueba con validación cruzada de 10 bolsas, la regresión lineal explica un 90 % de la varianza (RMSE de 2.540 dólares) y el bosque aleatorio un 92 % (2.220 dólares).

4 Diccionario de columnas

Columnas de `imports_85` (valores observados en el fichero)

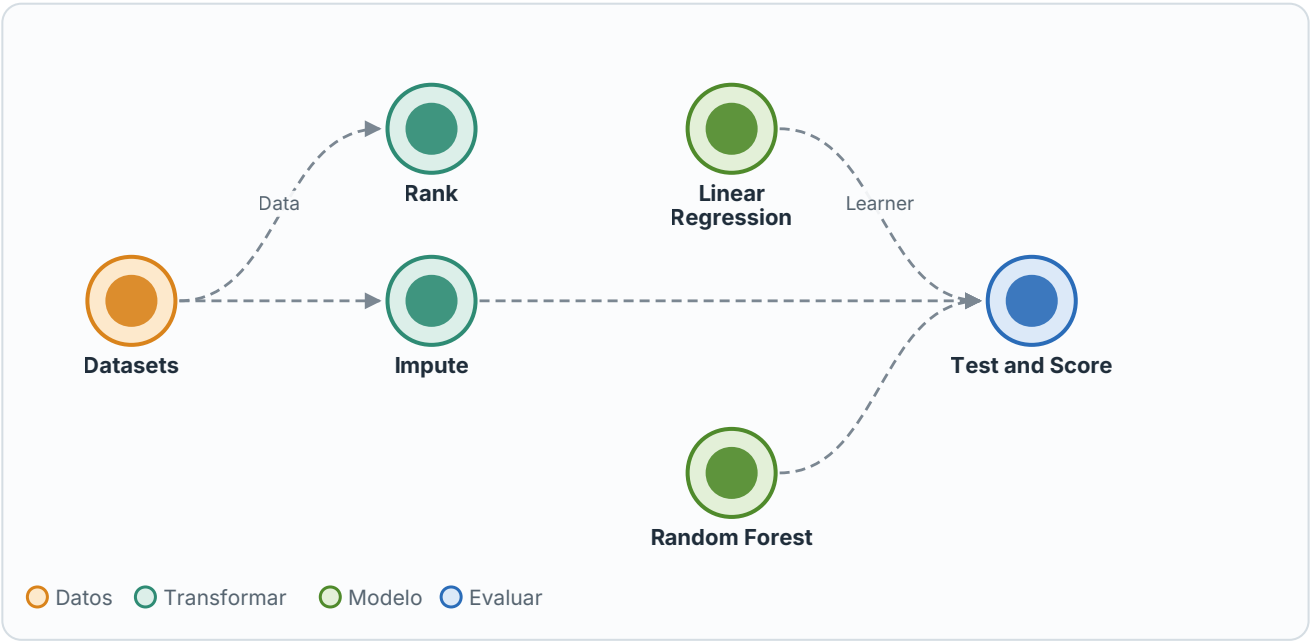
Columna	Tipo	Significado	Valores
`symboling`	categórica	Riesgo para el seguro, de −3 (seguro) a +3 (arriesgado). En los datos, de −2 a 3.	0 (67), 1 (54), 2 (32), 3 (27), -1 (22), -2 (3)
`normalized-losses`	numérica	Pérdidas medias por vehículo asegurado y año, normalizadas por tamaño de coche (65–256). **41 vacíos.**	65 – 256
`make`	categórica	Marca (22): `toyota` , `nissan` , `mazda` , `mercedes-benz` , `jaguar` … (Alfa Romeo aparece como `alfa-romero`).	toyota (32), nissan (18), mazda (17), mitsubishi (13), honda (13), subaru (12) …
`fuel-type`	categórica	Combustible: `gas` (gasolina) o `diesel` .	gas (185), diesel (20)
`aspiration`	categórica	Aspiración: `std` (atmosférico) o `turbo` .	std (168), turbo (37)

Columna	Tipo	Significado	Valores
`num-of-doors`	categórica	Número de puertas: `two` o `four` (escrito en inglés). 2 vacíos.	four (114), two (89)
`body-style`	categórica	Carrocería: `sedan`, `hatchback`, `wagon`, `hardtop`, `convertible`.	sedan (96), hatchback (70), wagon (25), hardtop (8), convertible (6)
`drive-wheels`	categórica	Tracción: `fwd` delantera, `rwd` trasera, `4wd` total.	fwd (120), rwd (76), 4wd (9)
`engine-location`	categórica	Motor delantero (`front`) o trasero (`rear`, 3 coches).	front (202), rear (3)
`wheel-base`	numérica	Distancia entre ejes (pulgadas).	86,6 – 120,9
`length`	numérica	Longitud (pulgadas).	141,1 – 208,1
`width`	numérica	Anchura (pulgadas).	60,3 – 72,3
`height`	numérica	Altura (pulgadas).	47,8 – 59,8
`curb-weight`	numérica	Peso en vacío (libras).	1.488 – 4.066
`engine-type`	categórica	Tipo de motor: `ohc`, `dohc`, `ohcv`, `rotor` (rotativo)…	ohc (148), ohcf (15), ohcv (13), dohc (12), l (12), rotor (4) …
`num-of-cylinders`	categórica	Número de cilindros, escrito en inglés (`four`, `six`…). **Ordinal como texto.**	four (159), six (24), five (11), eight (5), two (4), twelve (1) …
`engine-size`	numérica	Tamaño del motor (pulgadas cúbicas).	61 – 326
`fuel-system`	categórica	Sistema de alimentación: `mpfi` (inyección multipunto), `2bbl` (carburador de dos cuerpos)…	mpfi (94), 2bbl (66), idi (20), 1bbl (11), spdi (9), 4bbl (3) …
`bore`	numérica	Diámetro del cilindro. 4 vacíos.	2,54 – 3,94
`stroke`	numérica	Carrera del pistón. 4 vacíos.	2,07 – 4,17
`compression-ratio`	numérica	Relación de compresión (los diésel, en torno a 21–23).	7 – 23
`horsepower`	numérica	Potencia en caballos. 2 vacíos.	48 – 288
`peak-rpm`	numérica	Revoluciones de potencia máxima. 2 vacíos.	4.150 – 6.600
`city-mpg`	numérica	Consumo en ciudad (millas por galón).	13 – 49
`highway-mpg`	numérica	Consumo en carretera (millas por galón).	16 – 54
`price` `objetivo`	numérica	**Objetivo**: precio en dólares. **El nombre lleva un espacio al final.** 4 vacíos.	5.118 – 45.400

5 Particularidades técnicas al modelar

- **El nombre del objetivo tiene un espacio al final** (`price `). Si se escribe una fórmula o se busca la columna por nombre, hay que incluirlo. Viene así del fichero de Orange y se ha conservado.
- **Números escritos con palabras**: `num-of-doors` y `num-of-cylinders` usan `two`, `four`, `six`… Como categorías pierden el orden; con *Feature Constructor* se pueden pasar a números.
- **Valores ausentes en varias columnas**: sobre todo `normalized-losses` (41 de 205). Quitar esas filas deja el dataset en 164 coches.
- **Muy pocas filas por marca**: hay marcas con 1 a 3 coches (Mercury, Renault, Alfa Romeo, Jaguar, Chevrolet). La marca como variable con 22 valores puede sobreajustar.
- **Variables muy correlacionadas**: longitud, anchura, peso y tamaño del motor; consumo en ciudad y en carretera (0,97).
- **Precio asimétrico**: pocos coches muy caros (Jaguar, Mercedes, Porsche). El logaritmo del precio funciona mejor en una regresión lineal.

6 Flujo de trabajo en Orange



1. **Datasets** → «Imports 85» (o **File** con el CSV).
2. **Rank** (con el objetivo numérico usa *RReliefF* o correlación): qué variables explican el precio.
3. **Impute** para los vacíos de los atributos (Orange descarta solo las filas sin precio).
4. **Test and Score** con regresión lineal y bosque aleatorio.
5. Cambia el objetivo a `symboling` en **Select Columns** (como categórica) para un problema de clasificación.

7 Otras consideraciones

- **Varias tareas en un dataset**: precio (regresión), `symboling` (clasificación ordinal) y `normalized-losses` (regresión con huecos). Es útil para practicar cambiando el objetivo.
- **Comparar con Auto MPG**: otro dataset de coches de la misma época.

En la carpeta `imports_85` ← `imports-85.tab` (datasets.biolab.si)

5.06
Regresión

Abalone

`05_regresion/abalone/`

4.177 orejas de mar de Tasmania con su sexo, medidas y pesos, para estimar su edad sin tener que contar los anillos de la concha al microscopio: regresión (o clasificación) con un objetivo entero y medidas muy correlacionadas.

Regresión · Clasificación multiclase · ◈ Mixto num. + cat.

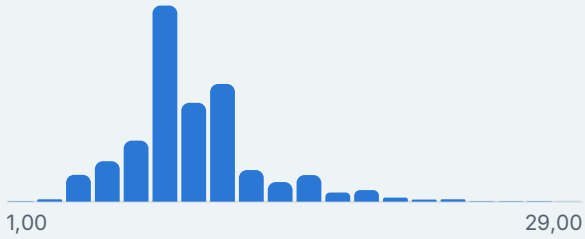
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
4.177	**9**	`Rings`	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`abalone`	4.177 × 9	CSV 192 KB · XLSX

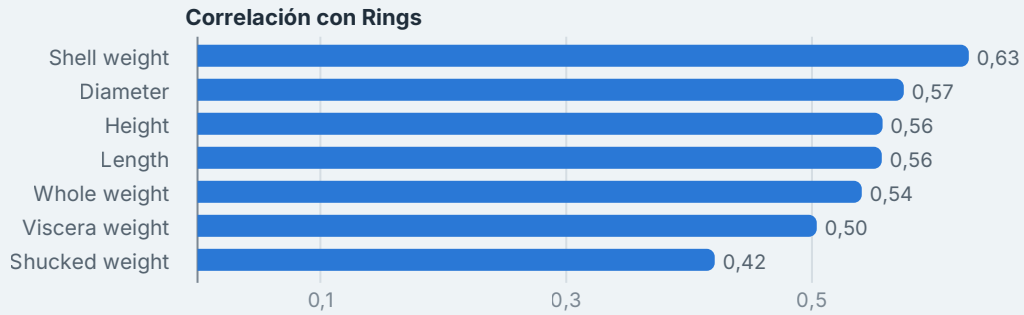
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/05_regresion/abalone/` seguido del nombre del fichero CSV.

Radiografía

Rings en abalone



Correlación de cada medida con el número de anillos



1 Descripción general y estudios habituales

La **oreja de mar** (abulón) es un molusco marino muy apreciado. Su edad se calcula cortando la concha, tiñéndola y contando los anillos al microscopio, una tarea lenta. Cada fila es un ejemplar con su sexo (macho, hembra o inmaduro), tres medidas (longitud, diámetro, altura) y cuatro pesos (entero, de la carne, de las vísceras y de la concha). El objetivo es el **número de anillos**, que más 1,5 da la edad en años.

Los estudios habituales son:

- **Regresión** del número de anillos.
- **Clasificación**: agrupando los anillos en tramos (joven, adulto, viejo) o como problema de 28 clases.
- **Comparación de algoritmos**: es uno de los datasets más usados en los artículos de aprendizaje automático.

2 Contexto y fuente original

Los datos son de un estudio de **Warwick Nash y colaboradores** (1994) del Laboratorio de Investigación Marina de Taroona, en Tasmania (Australia). Los donó **Sam Waugh** al repositorio UCI en 1995. En el original, las medidas continuas se dividieron entre 200 para que quedaran en una escala parecida; por eso las longitudes van de 0,075 a 0,815 y no están en milímetros.

- Nash, W., Sellers, T., Talbot, S., Cawthorn, A. y Ford, W. (1994). Abalone. UCI Machine Learning Repository.

3 Variable objetivo

El objetivo es `Rings`, el número de anillos: de 1 a 29, con media 9,9. La mayoría tiene entre 7 y 11, y por encima de 20 hay muy pocos ejemplares.

El peso de la concha es la medida más relacionada (correlación 0,63); el resto están entre 0,42 y 0,57. Los inmaduros tienen menos anillos (7,9 de media) que machos y hembras (10,7 y 11,1). En una prueba con validación cruzada de 10 bolsas, la regresión lineal y el bosque aleatorio explican solo un 53–54 % de la varianza (RMSE de 2,2 anillos): el tamaño no basta para saber la edad, porque depende también del alimento y del agua.

4 Diccionario de columnas

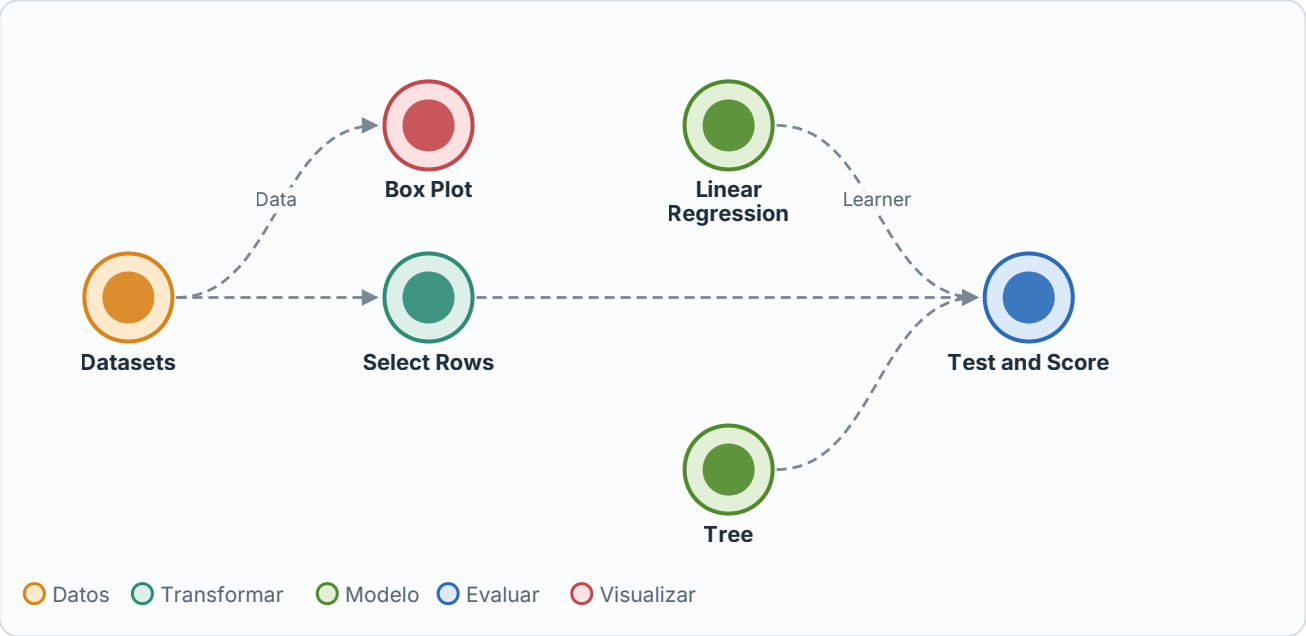
Columnas de `abalone` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
Sex	categórica	Sexo: `M` macho, `F` hembra, `I` inmaduro (*infant*).	M (1.528), I (1.342), F (1.307)
`Length`	numérica	Longitud máxima de la concha (mm / 200).	0,075 – 0,815
`Diameter`	numérica	Diámetro, perpendicular a la longitud (mm / 200).	0,055 – 0,65
`Height`	numérica	Altura con la carne dentro (mm / 200). **Dos ejemplares con 0** y uno con 1,13, imposibles.	0 – 1,13
`Whole weight`	numérica	Peso del ejemplar entero (gramos / 200).	0,002 – 2,825
`Shucked weight`	numérica	Peso de la carne (gramos / 200).	0,001 – 1,488
`Viscera weight`	numérica	Peso de las vísceras tras desangrar (gramos / 200).	0,001 – 0,76
`Shell weight`	numérica	Peso de la concha seca (gramos / 200).	0,002 – 1,005
`Rings` `objetivo`	numérica	**Objetivo**: número de anillos (edad = anillos + 1,5 años).	1 – 29

5 Particularidades técnicas al modelar

- **Valores imposibles**: dos ejemplares inmaduros con altura 0 y uno con altura 1,13 (el siguiente es 0,515). En 155 ejemplares, la carne, las vísceras y la concha pesan más que el ejemplar entero, lo que indica errores de medida (o pérdida de agua). Conviene quitarlos o revisarlos.
- **Medidas casi redundantes**: longitud y diámetro tienen una correlación de 0,99, y los pesos están muy relacionados entre sí. Los coeficientes de la regresión lineal no se pueden interpretar uno a uno.
- **Objetivo entero y asimétrico**: se puede tratar como regresión o como clasificación. Como clasificación de 28 clases, varias tienen 1 o 2 ejemplares; por eso se suele agrupar en tres tramos (por ejemplo, 1–8, 9–10 y 11 o más).
- **El árbol de regresión de Orange sobreajusta** con sus opciones por defecto (R^2 de 0,11 en la prueba): limita la profundidad o el tamaño mínimo de las hojas.
- **Escala dividida entre 200**: para interpretar en milímetros o gramos, multiplica por 200.

6 Flujo de trabajo en Orange



1. **Datasets** → «Abalone» (o **File** con el CSV).
2. **Box Plot** de `Rings` por `Sex`: los inmaduros son claramente más jóvenes.
3. **Select Rows**: quita las alturas imposibles.
4. **Test and Score** con regresión lineal y árbol; prueba el árbol con profundidad máxima 5 y hojas de al menos 20 ejemplares.
5. Para clasificar, crea tramos de edad con **Discretize** o **Feature Constructor** y cambia el objetivo.

7 Otras consideraciones

- **Un problema difícil a propósito**: los resultados modestos son lo esperable; la documentación original advierte que hace falta información del entorno (clima, alimento) para predecir mejor.
- **Transformar el objetivo**: el logaritmo de los anillos reduce el peso de los ejemplares muy viejos.

En la carpeta `abalone` ← `abalone.tab` (datasets.biolab.si)

5.07
Regresión

Body Fat (Brozek)

`05_regresion/body_fat/`

252 hombres con su porcentaje de grasa corporal medido por pesada bajo el agua y 13 medidas del cuerpo con cinta métrica: ¿se puede estimar la grasa sin piscina? Regresión con varios errores de tecleo conocidos.

Regresión

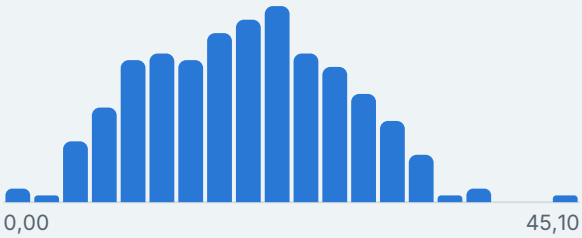
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
252	**16**	`body fat brozek`	**0,0 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`body_fat_brozek`	252 × 16	CSV 19 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/05_regresion/body_fat/` seguido del nombre del fichero CSV.

Radiografía

body fat brozek en body_fat_brozek



Correlación de cada medida con el % de grasa



1 Descripción general y estudios habituales

Medir la grasa corporal con precisión exige pesar a la persona bajo el agua para calcular su densidad. Cada fila es un hombre adulto con su porcentaje de grasa (calculado a partir de la densidad con la ecuación de Brozek), su edad, peso, altura, índice de masa corporal y diez perímetros: cuello, pecho, abdomen, cadera, muslo, rodilla, tobillo, bíceps, antebrazo y muñeca. El objetivo es el **porcentaje de grasa**.

Los estudios habituales son:

- **Regresión lineal múltiple** y selección de variables: ¿bastan dos o tres medidas?
- **Detección de errores** en los datos.
- **Multicolinealidad**: casi todas las medidas crecen a la vez.

2 Contexto y fuente original

Los datos los cedió **A. Garth Fisher** (Centro de Investigación del Rendimiento Humano, Universidad Brigham Young), con permiso para usarlos libremente con fines no comerciales. **Roger W. Johnson** los publicó en 1996 en el *Journal of Statistics Education* como ejemplo para clase, y se distribuyen en StatLib. La ficha de Orange enlaza una versión de Kaggle; su fichero usa la grasa calculada con la fórmula de Brozek, mientras que el original incluye también la densidad y la fórmula de Siri.

- Johnson, R. W. (1996). Fitting Percentage of Body Fat to Simple Body Measurements. Journal of Statistics Education, 4(1).
- Body fat en StatLib (descripción y datos originales)

3 Variable objetivo

El objetivo es `body fat brozek`, el porcentaje de grasa (de 0 a 45,1; media 18,9). **Hay un 0**, imposible en una persona viva.

El perímetro del abdomen es lo que más se relaciona con la grasa (correlación 0,81), seguido del índice de masa corporal (0,73) y del pecho (0,70). En una prueba con validación cruzada de 10 bolsas, la regresión lineal explica un 66 % de la varianza (RMSE de 4,5 puntos de grasa) y el bosque aleatorio un 68 % (4,4 puntos): con las medidas de cinta se consigue una estimación razonable, pero no precisa.

4 Diccionario de columnas

Columnas de `body_fat_brozek` (valores observados en el fichero)

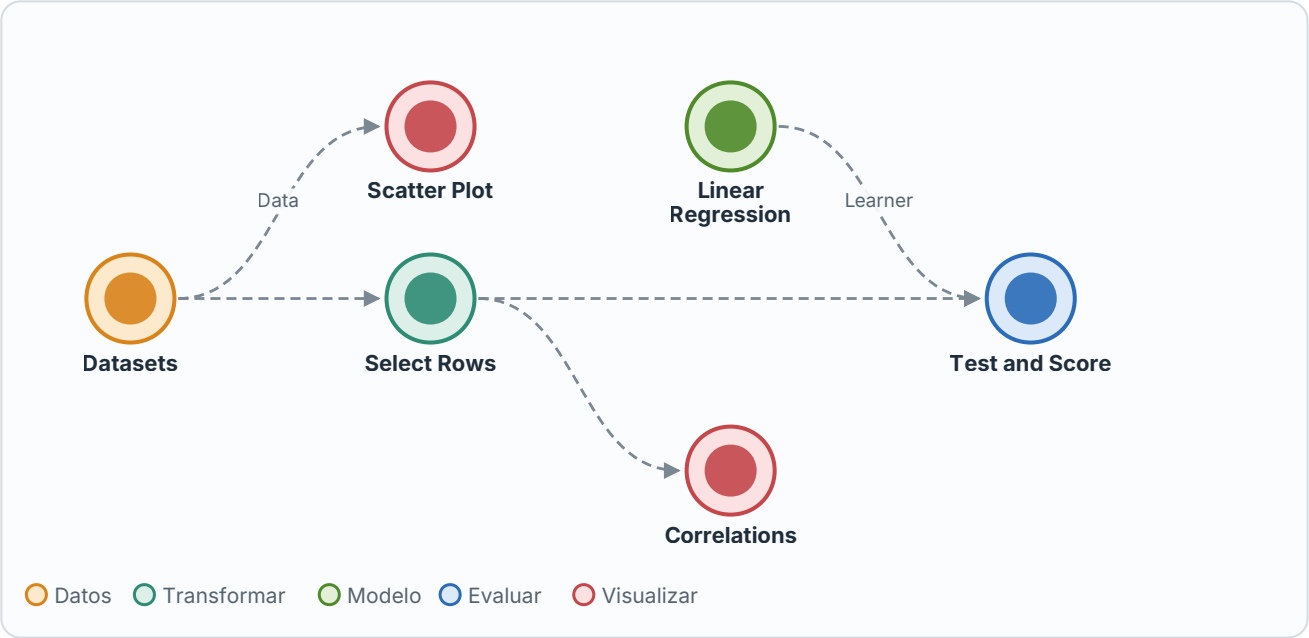
Columna	Tipo	Significado	Valores
`id`	texto	Número del hombre (1–252, meta). Útil para localizar los casos erróneos.	1 (1), 2 (1), 3 (1), 4 (1), 5 (1), 6 (1) …
`body fat brozek` objetivo	numérica	**Objetivo**: porcentaje de grasa por la ecuación de Brozek (457 / densidad − 414,2).	0 – 45,1
`age`	numérica	Edad en años (22–81).	22 – 81
`weight`	numérica	Peso en **libras**.	118,5 – 363,15
`height`	numérica	Altura en **pulgadas**. El caso 42 tiene 29,5 (ver particularidades).	29,5 – 77,75

Columna	Tipo	Significado	Valores
`adiposity`	numérica	Índice de masa corporal (kg/m²), calculado con el peso y la altura.	18,1 – 48,9
`neck`	numérica	Perímetro del cuello (cm).	31,1 – 51,2
`chest`	numérica	Perímetro del pecho (cm).	79,3 – 136,2
`abdomen`	numérica	Perímetro del abdomen (cm).	69,4 – 148,1
`hip`	numérica	Perímetro de la cadera (cm).	85 – 147,7
`tight`	numérica	Perímetro del muslo (cm). **El nombre tiene una errata: debería ser `thigh`.**	47,2 – 87,3
`knee`	numérica	Perímetro de la rodilla (cm).	33 – 49,1
`ankle`	numérica	Perímetro del tobillo (cm).	19,1 – 33,9
`biceps`	numérica	Perímetro del bíceps extendido (cm).	24,8 – 45
`forearm`	numérica	Perímetro del antebrazo (cm).	21 – 34,9
`wrist`	numérica	Perímetro de la muñeca (cm).	15,8 – 21,4

5 Particularidades técnicas al modelar

- **Errores conocidos**: el hombre 182 tiene un 0 % de grasa (imposible). El 42 mide 29,5 pulgadas (75 cm), pero su índice de masa corporal (29,9) solo cuadra con una altura de unas 69,5 pulgadas: es una errata. El 39 pesa 363 libras (165 kg), un valor real pero muy extremo. Conviene revisarlos antes de modelar.
- **Unidades mezcladas**: peso en libras y altura en pulgadas, pero perímetros en centímetros.
- **Todas las medidas crecen a la vez**: peso, pecho, abdomen, cadera y muslo tienen correlaciones de 0,73 a 0,94 entre sí. Los coeficientes de la regresión lineal cambian de signo según qué variables se incluyan. Prueba *Lasso* o selección paso a paso.
- **Solo hombres**: el modelo no sirve para mujeres.
- **Nombre con errata**: `tight` (apretado) por `thigh` (muslo). Se ha conservado tal cual.
- No hay valores ausentes.

6 Flujo de trabajo en Orange



1. **Datasets** → «Body Fat Prediction» (o **File** con el CSV).
2. **Scatter Plot** de `abdomen` frente a la grasa; colorea por `height` para encontrar al caso 42.
3. **Select Rows**: quita el 0 % de grasa y la altura imposible.
4. **Correlations**: comprueba cuánto se parecen las medidas entre sí.
5. **Test and Score** con regresión lineal usando solo `abdomen`, luego `abdomen` + `weight`, luego todas: ¿cuánto se gana con cada variable?

7 Otras consideraciones

- **Fórmulas sencillas**: con abdomen y peso ya se explica casi todo; el artículo de Johnson propone modelos con 2–4 medidas.
- **Brozek frente a Siri**: las dos ecuaciones dan valores muy parecidos; en el original están las dos y la densidad.

En la carpeta `body_fat_brozek` ← `body-fat-brozek.xlsx` (datasets.biolab.si)

5.08
Regresión

Advertising (ISLR)

`05_regresion/advertising/`

200 mercados con su inversión en publicidad en televisión, radio y prensa y las ventas de un producto: el ejemplo de regresión lineal del libro ISLR, perfecto para hablar de coeficientes, variables inútiles e interacciones.

Regresión

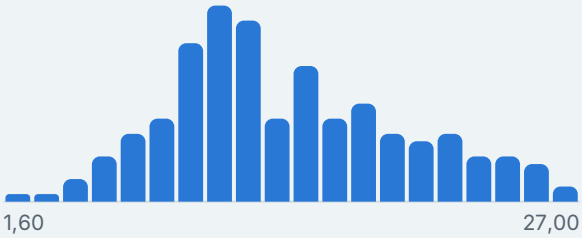
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
200	**4**	`sales`	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`advertising`	200 × 4	CSV 4 KB · XLSX

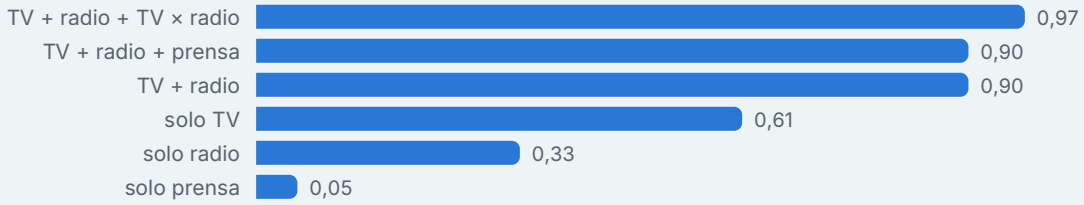
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/05_regresion/advertising/` seguido del nombre del fichero CSV.

Radiografía

sales en advertising



R^2 en los datos de entrenamiento según las variables usadas



1 Descripción general y estudios habituales

Cada fila es un mercado (una zona geográfica) con el presupuesto gastado en publicidad en **televisión**, **radio** y **prensa**, en miles de dólares, y las **ventas** del producto en miles de unidades. Solo hay tres variables, lo que permite ver y entender todo el modelo.

Los estudios habituales son:

- **Regresión lineal simple y múltiple**: cuánto aumentan las ventas por cada 1.000 dólares en cada medio.
- **Significación de las variables**: la prensa parece útil sola, pero no lo es junto a las otras dos.
- **Interacción**: la televisión y la radio se refuerzan entre sí.

2 Contexto y fuente original

Es el dataset del capítulo 3 (regresión lineal) del libro ***An Introduction to Statistical Learning*** (ISLR), de **Gareth James, Daniela Witten, Trevor Hastie y Robert Tibshirani** (2013), que se puede descargar gratis en su web. Los datos son ilustrativos: el libro no dice de qué producto ni de qué mercados se trata.

- James, G., Witten, D., Hastie, T. y Tibshirani, R. (2013). An Introduction to Statistical Learning. Springer (web del libro con los datos).

3 Variable objetivo

El objetivo es `sales`, las ventas en miles de unidades (de 1,6 a 27).

La regresión lineal con los tres medios explica un 90 % de la varianza: cada 1.000 dólares en televisión añaden unas 46 unidades, y en radio unas 189; el coeficiente de la prensa es prácticamente 0. Si se añade el término de interacción televisión × radio, el ajuste sube al 97 %. En una prueba con validación cruzada de 10 bolsas, la regresión lineal sin interacción explica un 89 % y el bosque aleatorio, que capta la interacción solo, un 98 %.

4 Diccionario de columnas

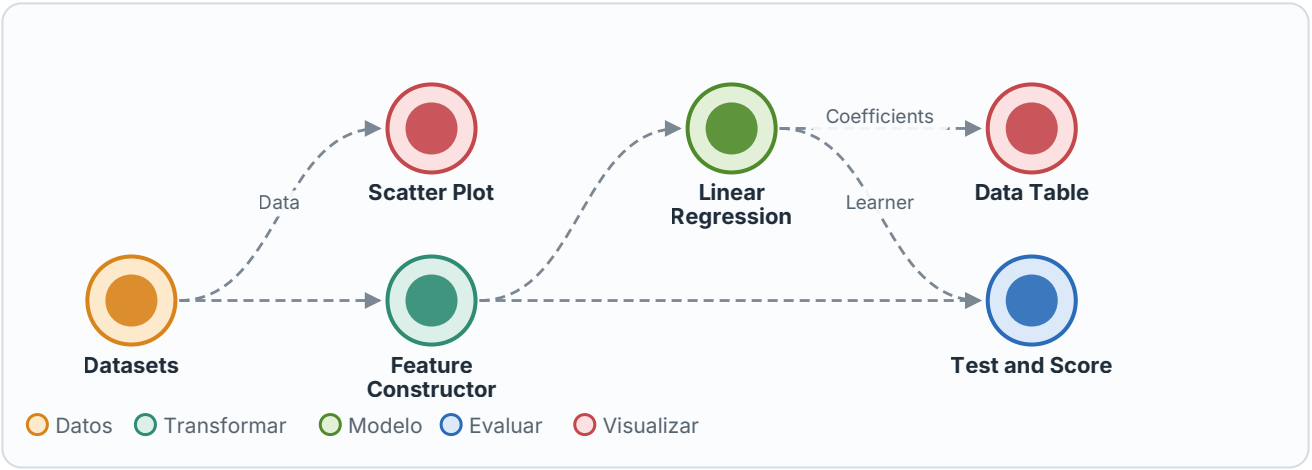
Columnas de `advertising` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
TV	numérica	Inversión en publicidad en televisión (miles de dólares).	0,7 – 296,4
`radio`	numérica	Inversión en radio (miles de dólares).	0 – 49,6
`newspaper`	numérica	Inversión en prensa (miles de dólares).	0,3 – 114
`sales` `objetivo`	numérica	**Objetivo**: ventas del producto (miles de unidades).	1,6 – 27

5 Particularidades técnicas al modelar

- **La prensa engaña**: sola tiene una relación positiva con las ventas (correlación 0,23), pero en el modelo con los tres medios su coeficiente es casi cero. La explicación: los mercados que gastan más en radio también gastan más en prensa (correlación 0,35), y la prensa se lleva el mérito de la radio cuando va sola.
- **Interacción entre medios**: el efecto de la radio es mayor cuando también se invierte en televisión. Un modelo lineal sin interacción deja un patrón curvo en los residuos.
- **Efecto decreciente de la televisión**: las ventas crecen cada vez menos con más inversión en televisión; la raíz o el logaritmo de `TV` ajustan mejor.
- **Muy pocas variables y datos limpios**: no hay valores ausentes ni extremos. Es un dataset para entender, no para competir.

6 Flujo de trabajo en Orange



1. **Datasets** → «Advertising» (o **File** con el CSV).
2. **Scatter Plot** de cada medio frente a `sales`: la televisión muestra la relación más clara.
3. **Linear Regression** → **Data Table** (salida *Coefficients*): compara el coeficiente de la prensa sola y con los otros dos medios.
4. **Feature Constructor**: añade `TV * radio` y vuelve a ajustar.
5. **Test and Score**: compara el modelo con y sin interacción.

7 Otras consideraciones

- **Presupuesto óptimo**: con el modelo con interacción se puede plantear cómo repartir un presupuesto fijo entre televisión y radio.
- **Libro gratuito**: ISLR (y su versión en Python, ISLP) explica este ejemplo paso a paso en el capítulo 3.

En la carpeta `advertising` ← `advertising.xlsx` (datasets.biolab.si)

5.09
Regresión

Diabetes (progresión, Efron et al.)

`05_regresion/diabetes_sklearn/`

442 pacientes de diabetes con diez medidas iniciales, ya estandarizadas, y la progresión de la enfermedad un año después: el dataset del método LARS, con dos nombres de columna mal traducidos en la versión de Orange.

Regresión

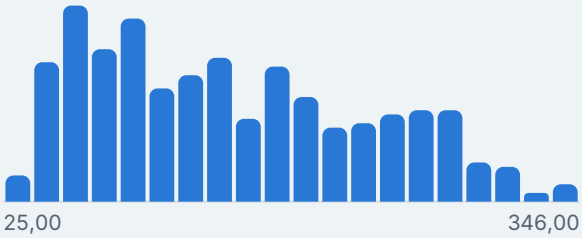
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
442	**11**	`progression`	**0,0 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`diabetes_sklearn`	442 × 11	CSV 93 KB · XLSX

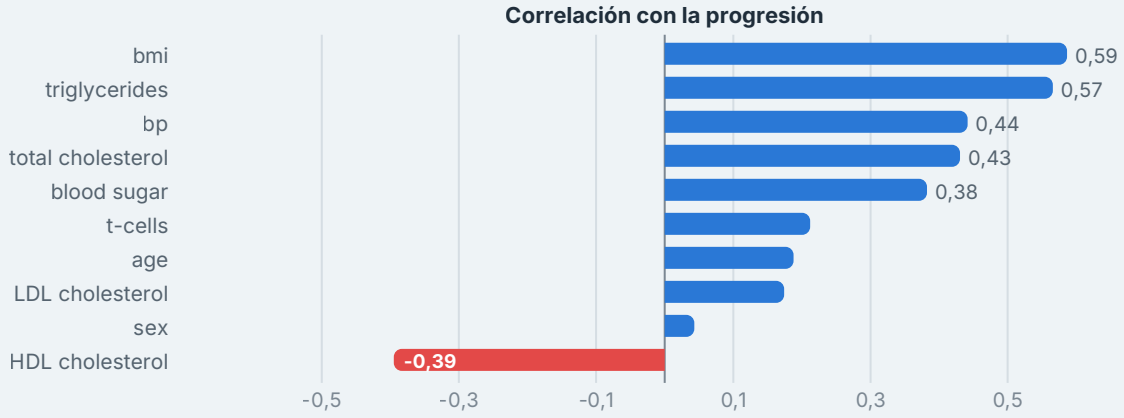
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/05_regresion/diabetes_sklearn/` seguido del nombre del fichero CSV.

Radiografía

progression en diabetes_sklearn



Correlación de cada medida con la progresión



1 Descripción general y estudios habituales

Cada fila es un paciente de diabetes con diez medidas tomadas al inicio: edad, sexo, índice de masa corporal, presión arterial media y seis análisis de sangre. El objetivo es una **medida cuantitativa de la progresión de**

la enfermedad un año después. Las diez variables están **estandarizadas**: centradas en 0 y escaladas para que la suma de sus cuadrados sea 1.

Los estudios habituales son:

- **Regresión lineal con regularización** (Lasso, LARS, Ridge) y selección de variables.
- **Comparación de modelos** en un problema con mucho ruido.

No debe confundirse con el dataset **Pima** (capítulo 2), que es de clasificación.

2 Contexto y fuente original

Lo publicaron **Bradley Efron, Trevor Hastie, Iain Johnstone y Robert Tibshirani** en 2004, en el artículo que presentó el algoritmo LARS (*Least Angle Regression*). No se dice de dónde proceden los pacientes ni cómo se mide la progresión. Se popularizó como dataset de ejemplo de scikit-learn, de donde procede esta versión (con las variables ya escaladas).

- Efron, B., Hastie, T., Johnstone, I. y Tibshirani, R. (2004). Least Angle Regression. Annals of Statistics, 32(2), 407–499.
- Diabetes data (página de Dennis Boos, NC State, con los nombres originales)

3 Variable objetivo

El objetivo es `progression`, la progresión de la enfermedad al cabo de un año (de 25 a 346, media 152). No tiene unidades conocidas.

El índice de masa corporal (correlación 0,59) y los triglicéridos (0,57) son lo que más se relaciona con la progresión; el colesterol HDL va en sentido contrario (−0,39). En una prueba con validación cruzada de 10 bolsas, la regresión lineal explica un 50 % de la varianza (RMSE de 55) y supera al bosque aleatorio (43 %) y a kNN (40 %); el árbol de regresión, con sus opciones por defecto, lo hace peor que predecir la media. Es un problema con mucho ruido.

4 Diccionario de columnas

Columnas de `diabetes_sklearn` (valores observados en el fichero)

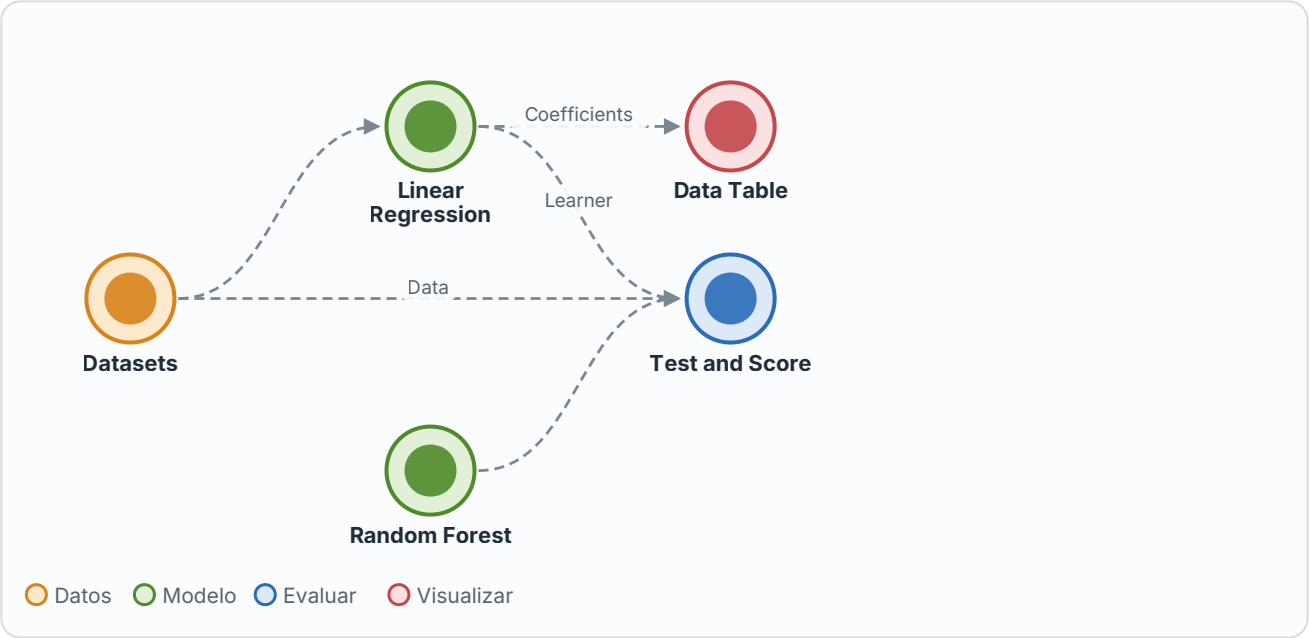
Columna	Tipo	Significado	Valores
`age`	numérica	Edad (estandarizada).	-0,107 – 0,111
`sex`	numérica	Sexo (estandarizado: solo dos valores, −0,045 y 0,051; no se dice cuál es cuál).	-0,045 – 0,051
`bmi`	numérica	Índice de masa corporal.	-0,09 – 0,171
`bp`	numérica	Presión arterial media.	-0,112 – 0,132
`t-cells`	numérica	**Nombre erróneo**: es `tc`, el colesterol total en suero (en el original, `S1`).	-0,127 – 0,154
`LDL cholesterol`	numérica	Colesterol LDL (`ldl`, `S2`).	-0,116 – 0,199

Columna	Tipo	Significado	Valores
`HDL cholesterol`	numérica	Colesterol HDL (`hdl` , `S3`).	-0,102 – 0,181
`total cholesterol`	numérica	**Nombre engañoso**: es `tch` , el cociente colesterol total / HDL (`S4`).	-0,076 – 0,185
`triglycerides`	numérica	Logaritmo de los triglicéridos en suero (`ltg` , `S5`).	-0,126 – 0,134
`blood sugar`	numérica	Glucosa en sangre (`glu` , `S6`).	-0,138 – 0,136
`progression` `objetivo`	numérica	**Objetivo**: progresión de la enfermedad un año después (25–346).	25 – 346

5 Particularidades técnicas al modelar

- **Dos nombres mal puestos en Orange**: la quinta variable se llama `t-cells` (linfocitos T), pero es el colesterol total en suero (`tc`); y la que se llama `total cholesterol` es en realidad el cociente colesterol total / HDL (`tch`). Los nombres del CSV se han conservado como en Orange; el diccionario dice qué es cada una.
- **Variables ya escaladas**: no tienen sus unidades originales y la suma de sus cuadrados es 1. No hace falta normalizar, pero no se pueden interpretar en mg/dl ni en años. Los datos sin escalar están en la página de LARS de Hastie y en la de Dennis Boos.
- **El sexo es binario** aunque aparezca como número.
- **Colesteroles muy correlacionados**: colesterol total y LDL (0,90). Es el escenario para el que se pensó LARS y Lasso.
- **Mucho ruido**: los modelos complejos no mejoran a la regresión lineal. Buen ejemplo de que «más complejo» no significa «mejor».
- No hay valores ausentes.

6 Flujo de trabajo en Orange



1. **Datasets** → «Diabetes» (o **File** con el CSV).
2. **Linear Regression** con *Lasso*: sube poco a poco la fuerza de la regularización y mira en **Data Table** qué coeficientes se van haciendo 0 (el orden en que desaparecen es la idea de LARS).
3. **Test and Score** con regresión lineal, *Lasso*, bosque aleatorio y árbol.
4. **Scatter Plot** de `bmi` frente a `progression`.

7 Otras consideraciones

- **Versión de 64 variables**: el artículo de LARS usa también un «modelo cuadrático» con los cuadrados y productos de las variables, útil para practicar con muchas variables correlacionadas.
- **Comparar con Pima**: otro dataset de diabetes, de clasificación, que no tiene relación con este.

En la carpeta `diabetes_sklearn` ← `diabetes.xlsx` (datasets.biolab.si)

5.10
Regresión

Forest Fires (Montesinho)

`05_regresion/forestfires/`

517 incendios forestales del parque natural de Montesinho (Portugal) con datos meteorológicos e índices de riesgo: predecir la superficie quemada es tan difícil que ningún modelo supera a decir siempre la media.

Regresión · Espacial · Mixto num. + cat. · Temporal

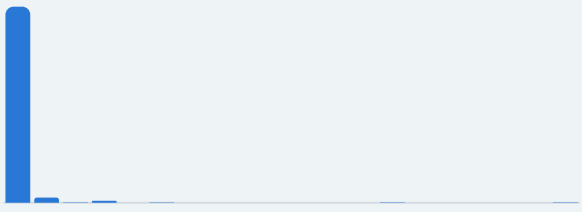
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
517	**15**	`area`	**0,0 %**	**Avanzado**	**Ninguno**

Fichero	Filas × col.	Descargar
`forestfires`	517 × 15	CSV 32 KB · XLSX

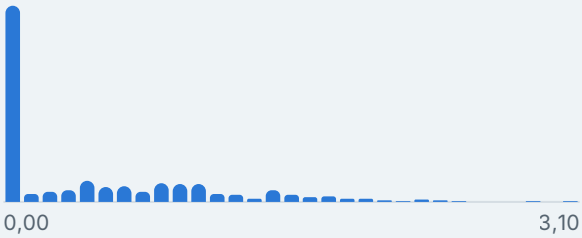
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/05_regresion/forestfires/` seguido del nombre del fichero CSV.

Radiografía

area en forestfires



Superficie quemada en escala logarítmica: $\log_{10}$(área



1 Descripción general y estudios habituales

Cada fila es un incendio registrado en el parque natural de **Montesinho**, en el noreste de Portugal, entre 2000 y 2003. Se conocen su posición en una cuadrícula de 9 × 9 sobre el mapa del parque, el mes y el día de la semana, cuatro componentes del índice canadiense de riesgo de incendio (FWI) y el tiempo en ese momento: temperatura, humedad relativa, viento y lluvia. El objetivo es la **superficie quemada** en hectáreas.

Los estudios habituales son:

- **Regresión con un objetivo muy asimétrico**: casi la mitad de los incendios queman menos de una hectárea.
- **Transformación del objetivo** (logaritmo) y elección de métricas.
- **Clasificación**: ¿hubo superficie quemada medible o no?

2 Contexto y fuente original

Lo publicaron **Paulo Cortez y Aníbal Morais** (Universidad del Miño) en 2007. Combinaron los registros de incendios de los responsables del parque con los datos de una estación meteorológica. En su estudio, el mejor modelo fue una máquina de vectores de soporte con solo las cuatro variables meteorológicas, que acertaba mejor los incendios pequeños (los más frecuentes). Orange añade dos metas: el logaritmo de la superficie y si es distinta de cero.

- Cortez, P. y Morais, A. (2007). A Data Mining Approach to Predict Forest Fires using Meteorological Data. EPIA 2007, 512–523. Datos en el repositorio UCI.

3 Variable objetivo

El objetivo es `area`, la superficie quemada en hectáreas: de 0 a 1.090,84, con media 12,8 pero **mediana 0,52**. 247 incendios (el 48 %) tienen 0, que significa menos de 1/100 de hectárea. Hay 11 por encima de 100 ha y dos enormes (747 y 1.091 ha).

En una prueba con validación cruzada de 10 bolsas, **ningún modelo mejora a predecir la media**: la regresión lineal tiene un R^2 de −0,02 y el bosque aleatorio de −0,15. Con el logaritmo de la superficie como objetivo pasa lo mismo. Los incendios grandes dependen de cosas que no están en los datos (cuándo se detectaron, cuánto tardó la extinción).

4 Diccionario de columnas

Columnas de `forestfires` (valores observados en el fichero)

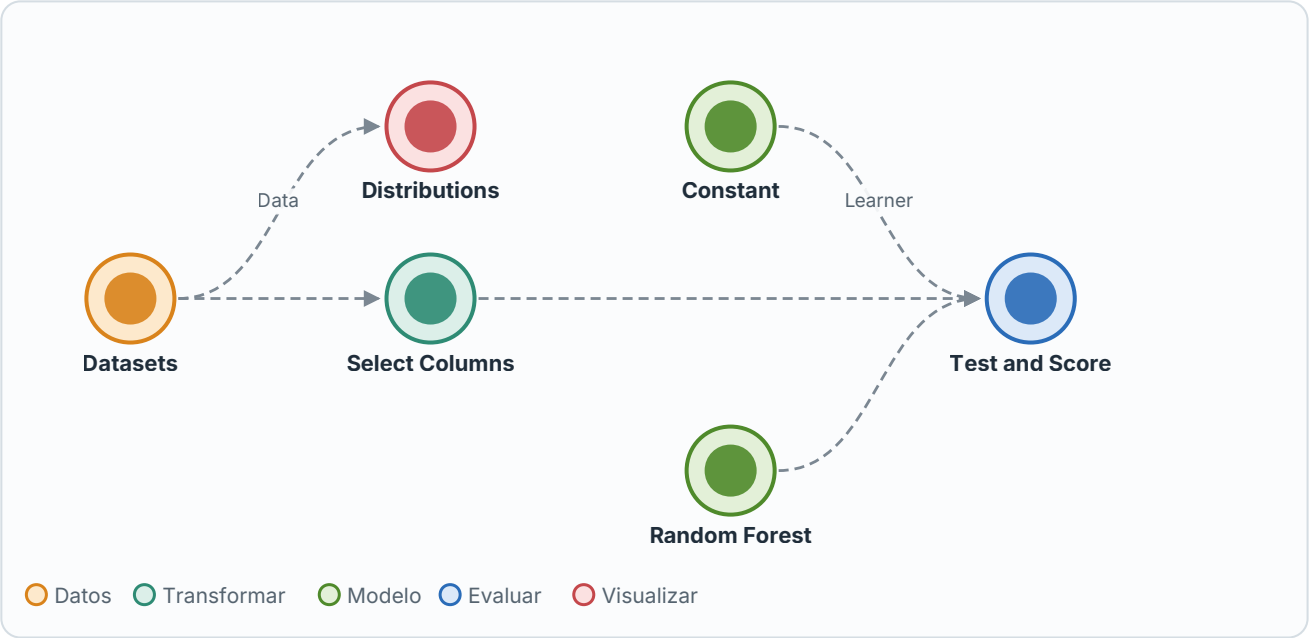
Columna	Tipo	Significado	Valores
X	numérica	Columna de la cuadrícula del mapa del parque (1–9).	1 – 9
Y	numérica	Fila de la cuadrícula (2–9).	2 – 9
month	categórica	Mes del incendio (`jan` … `dec`). Agosto y septiembre suman 356 de 517.	aug (184), sep (172), mar (54), jul (32), feb (20), jun (17) …
day	categórica	Día de la semana (`mon` … `sun`).	sun (95), fri (85), sat (84), mon (74), tue (64), thu (61) …
FFMC	numérica	Índice de humedad del combustible fino (*Fine Fuel Moisture Code*), 18,7–96,2.	18,7 – 96,2
DMC	numérica	Índice de humedad del mantillo (*Duff Moisture Code*).	1,1 – 291,3
DC	numérica	Índice de sequía (*Drought Code*).	7,9 – 860,6
ISI	numérica	Índice de propagación inicial (*Initial Spread Index*).	0 – 56,1

Columna	Tipo	Significado	Valores
`temp`	numérica	Temperatura (°C).	2,2 – 33,3
`RH`	numérica	Humedad relativa (%).	15 – 100
`wind`	numérica	Velocidad del viento (km/h).	0,4 – 9,4
`rain`	numérica	Lluvia exterior (mm/m²). Solo 8 incendios con lluvia distinta de 0.	0 – 6,4
`area` `objetivo`	numérica	**Objetivo**: superficie quemada (ha).	0 – 1.090,84
`log(area+1)`	numérica	Meta añadida por Orange: **logaritmo decimal** de área + 1 (no natural, a diferencia del artículo).	0 – 3,038
`nonzero(area)`	categórica	Meta añadida por Orange: si la superficie es mayor que 0.	True (270), False (247)

5 Particularidades técnicas al modelar

- **Objetivo extremadamente asimétrico**: la mitad son ceros y los dos mayores incendios suman el 28 % de toda la superficie quemada. El RMSE queda dominado por esos dos; el error absoluto medio (MAE) o el error sobre el logaritmo son más útiles.
- **El logaritmo de Orange es decimal**: `log(area+1)` llega a 3,04, que es $\log_{10}(1.091{,}84)$. El artículo original usa el logaritmo natural. Para comparar resultados hay que usar la misma escala.
- **Las metas son el objetivo transformado**: si se pasan a atributos, son fuga de información.
- **Meses y días muy desiguales**: enero, mayo y noviembre tienen 1 o 2 incendios. El mes puede sobreajustar.
- **Índices relacionados entre sí**: FFMC, DMC, DC e ISI se calculan con la temperatura, la humedad, el viento y la lluvia de los días anteriores.
- **Coordenadas como números**: `X` e `Y` son posiciones en una cuadrícula, no medidas; sus valores no tienen un efecto lineal.

6 Flujo de trabajo en Orange



1. **Datasets** → «Forest Fires» (o **File** con el CSV).
2. **Distributions** de `area`: casi todo es 0 o muy pequeño.
3. **Select Columns**: usa `log(area+1)` como objetivo y quita `area` y `nonzero(area)`.
4. **Test and Score** con **Constant** (predice la media), regresión lineal y bosque aleatorio: compara MAE y R^2.
5. Como clasificación: usa `nonzero(area)` como objetivo y mira si se puede predecir que haya superficie quemada.

7 Otras consideraciones

- **Lección**: no todos los problemas se pueden resolver con los datos disponibles; el modelo trivial es la referencia con la que hay que comparar siempre.
- **Solo meteorología**: el artículo obtuvo sus mejores resultados con temperatura, humedad, viento y lluvia; prueba a quedarte con esas cuatro.
- **Mapa**: un **Scatter Plot** de `X` frente a `Y` con el tamaño por superficie muestra las zonas más afectadas.

En la carpeta	`forestfires` ← `forestfires.tab` (datasets.biolab.si)
Duplicado, no se copia	`forestfires.csv` (curso_ciencia_datos (GitHub))

5.11
Regresión

Wine Quality (vinho verde)

`05_regresion/wine_quality/`

6.497 vinos verdes portugueses (1.599 tintos y 4.898 blancos) con 11 análisis de laboratorio y la nota que les pusieron catadores expertos.

Regresión · Clasificación multiclase · ⚖ Desbalanceado

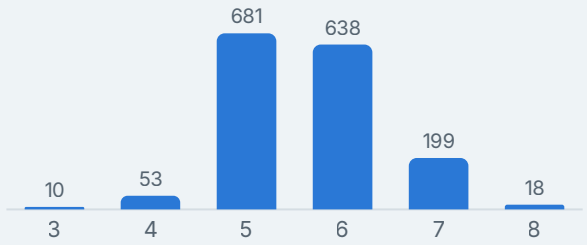
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
1.599	**12**	`quality`	**0,0 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`wine_quality_red`	1.599 × 12	CSV 84 KB · XLSX
`wine_quality_white`	4.898 × 12	CSV 264 KB · XLSX

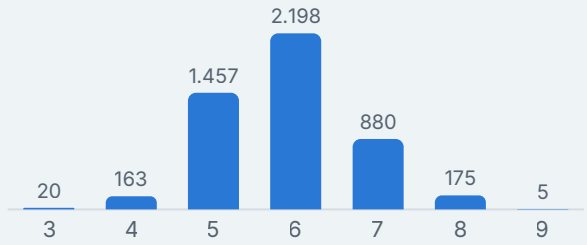
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/05_regresion/wine_quality/` seguido del nombre del fichero CSV.

Radiografía

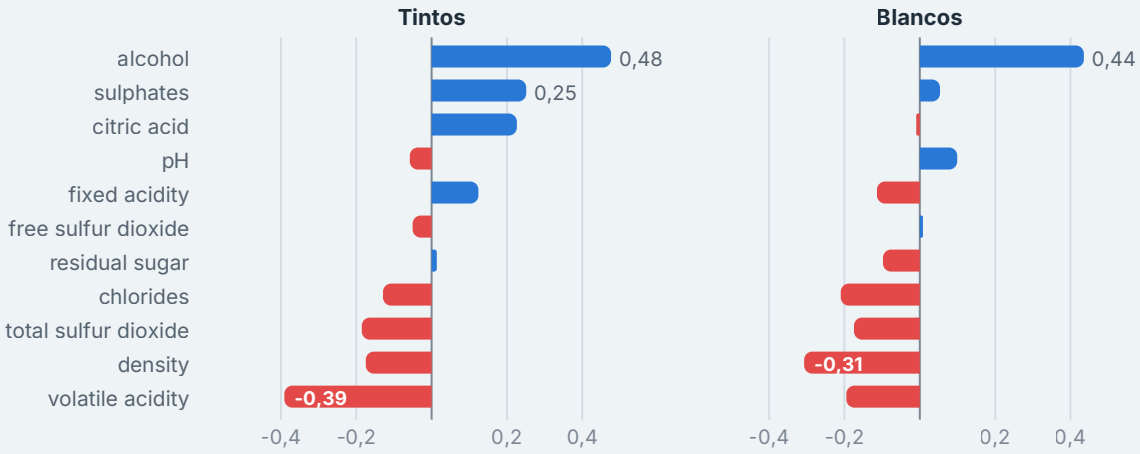
quality en wine_quality_red



quality en wine_quality_white



Correlación de cada análisis con la nota



1 Descripción general y estudios habituales

Cada fila es una muestra de *vinho verde*, la denominación de origen del noroeste de Portugal (región del Miño). De cada vino se conocen once medidas fisicoquímicas habituales en la certificación (acidez, azúcar,

sulfuroso, densidad, pH, alcohol…) y una nota sensorial de 0 a 10 que le pusieron catadores expertos. Tintos y blancos vienen en dos ficheros separados porque su química es muy distinta.

Es el dataset de referencia para pasar de la clasificación a la **regresión** con datos reales y todos numéricos. Los estudios habituales son:

- **Predecir la nota** (regresión) a partir de los análisis de laboratorio, como en el artículo original.
- **Clasificar** la nota como clase ordenada (3 a 9) o, más a menudo, en dos grupos: «bueno» (nota de 7 o más) frente al resto.
- **Seleccionar atributos**: averiguar qué análisis importan de verdad para la calidad.
- **Detectar atípicos**: los vinos excelentes o muy malos son pocos y se comportan como rarezas.
- **Comparar tintos y blancos**: los mismos análisis pesan de forma distinta en cada tipo.

2 Contexto y fuente original

Los datos son de Paulo Cortez y colaboradores (Universidad del Miño y Comisión de Viticultura de la Región de los Vinos Verdes, CVRVV) y se publicaron con el artículo *Modeling wine preferences by data mining from physicochemical properties* (*Decision Support Systems*, 2009). Se recogieron entre mayo de 2004 y febrero de 2007 con muestras de denominación de origen protegida analizadas en la entidad oficial de certificación (CVRVV).

Cada vino lo cataron a ciegas al menos tres evaluadores en una escala de 0 (muy malo) a 10 (excelente), y la nota final es la **mediana** de sus evaluaciones. Por privacidad y logística solo se publicaron los análisis y la nota: no hay variedad de uva, marca ni precio. Los datos están en el repositorio UCI con licencia CC BY 4.0, que permite reutilizarlos citando a los autores.

En el artículo, el mejor modelo fue una máquina de vectores soporte (SVM), con un error absoluto medio de 0,46 en tintos y 0,45 en blancos, y acertando la nota exacta (con tolerancia de 0,5) en el 62,4 % y el 64,6 % de los vinos.

- Cortez, P., Cerdeira, A., Almeida, F., Matos, T. y Reis, J. (2009). Modeling wine preferences by data mining from physicochemical properties. Decision Support Systems, 47(4), 547–553.
- Wine Quality en el repositorio UCI (DOI 10.24432/C56S3T)

3 Variable objetivo

La variable objetivo es `quality`, la nota sensorial: un número entero de 0 a 10, aunque en la práctica solo aparecen valores de 3 a 8 en tintos y de 3 a 9 en blancos. Casi todos los vinos sacan un 5 o un 6 (el 82 % de los tintos y el 75 % de los blancos), así que los extremos están muy poco representados: solo hay 10 tintos con un 3 y 5 blancos con un 9.

Como referencia, predecir siempre la nota media da un error absoluto medio de 0,68 en tintos y 0,67 en blancos; el mejor modelo del artículo lo baja a 0,46 y 0,45. Si se trata como clasificación, decir siempre la nota más frecuente acierta el 42,6 % de los tintos (nota 5) y el 44,9 % de los blancos (nota 6).

4 Diccionario de columnas

Columnas de `wine_quality_red` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`fixed acidity`	numérica	Acidez fija, en g de ácido tartárico por dm³: ácidos que no se evaporan.	4,6 – 15,9

Columna	Tipo	Significado	Valores
`volatile acidity`	numérica	Acidez volátil, en g de ácido acético por dm³. En exceso da sabor a vinagre.	0,12 – 1,58
`citric acid`	numérica	Ácido cítrico, en g/dm³. Aporta frescor.	0 – 1
`residual sugar`	numérica	Azúcar residual que queda tras la fermentación, en g/dm³.	0,9 – 15,5
`chlorides`	numérica	Cloruros (sal), en g de cloruro sódico por dm³.	0,012 – 0,611
`free sulfur dioxide`	numérica	Dióxido de azufre libre, en mg/dm³: la parte del sulfuroso que protege el vino frente a microbios y oxidación.	1 – 72
`total sulfur dioxide`	numérica	Dióxido de azufre total (libre más combinado), en mg/dm³.	6 – 289
`density`	numérica	Densidad, en g/cm³. Depende sobre todo del alcohol y del azúcar.	0,99 – 1,004
pH	numérica	pH: cuanto más bajo, más ácido.	2,74 – 4,01
`sulphates`	numérica	Sulfatos, en g de sulfato potásico por dm³. Aditivo que aporta sulfuroso.	0,33 – 2
`alcohol`	numérica	Grado alcohólico, en % de volumen.	8,4 – 14,9
`quality` `objetivo`	numérica	Nota sensorial (mediana de al menos tres catadores), de 0 a 10. Es la variable objetivo.	3 – 8

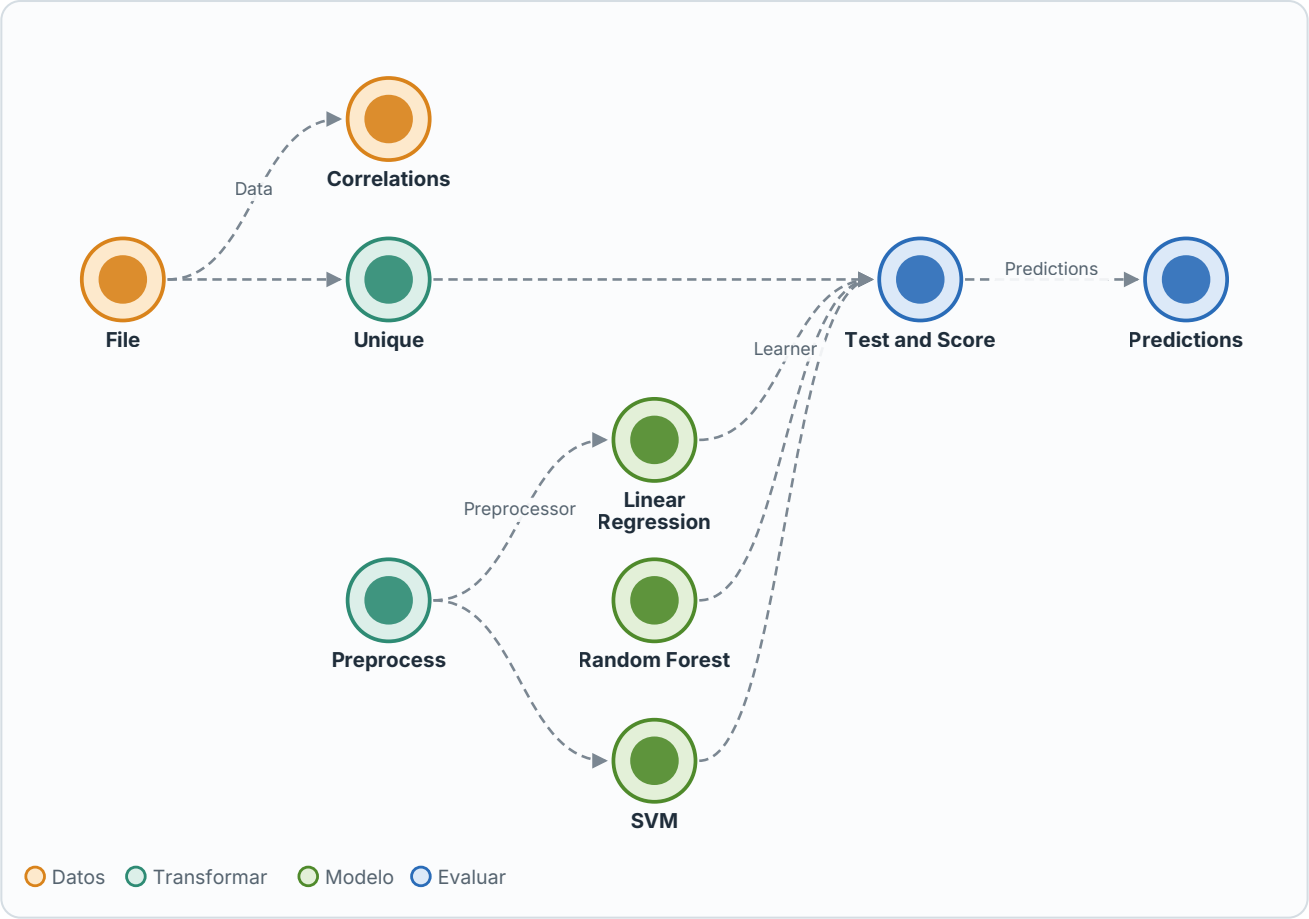
`wine_quality_white` tiene las mismas columnas con el mismo significado que `wine_quality_red`.

5 Particularidades técnicas al modelar

- **En Orange, `quality` se abre como numérica**, así que los modelos hacen regresión. Para clasificar, cámbiala a categórica en el widget *File* o crea una variable binaria con *Feature Constructor* (por ejemplo `quality >= 7`). Al abrir el CSV, recuerda además marcar `quality` como *target*.
- **Clases muy desequilibradas en los extremos.** Con 5 blancos de nota 9, la validación cruzada estratificada de 10 particiones no puede repartirlos en todas: Orange avisará. Agrupar notas (por ejemplo ≤4, 5, 6, ≥7) suele dar modelos más útiles.
- **Filas repetidas**: 240 tintos y 937 blancos son copias exactas de otra fila (probablemente catas repetidas del mismo vino). En validación cruzada, una copia puede caer en entrenamiento y otra en prueba e inflar el resultado. Para comprobarlo, quítalas con el widget *Unique* y compara.
- **Escalas muy distintas** (la densidad varía en milésimas; el sulfuroso total, en cientos) **y distribuciones asimétricas** (cloruros, azúcar residual y sulfatos tienen colas largas). Los modelos basados en distancias o pesos (kNN, SVM, regresión lineal, redes) necesitan normalizar con *Preprocess*; los árboles y Random Forest no.
- **Atributos muy correlacionados entre sí**: en blancos, la densidad sube con el azúcar ($r = 0{,}84$) y baja con el alcohol ($r = -0{,}78$). Los coeficientes de una regresión lineal se vuelven inestables; para interpretar, quédate con uno de ellos o usa regularización (Lasso o Ridge en *Linear Regression*).
- El alcohol es el atributo más relacionado con la nota en ambos tipos ($r = 0{,}48$ en tintos, 0,44 en blancos). En tintos le sigue la acidez volátil ($r = -0{,}39$); en blancos, la densidad ($r = -0{,}31$).

- No hay valores faltantes.

6 Flujo de trabajo en Orange



1. **File**: abre `wine_quality_red.csv` (o el de blancos) y marca `quality` como *target*.
2. **Correlations**: ordena las parejas de atributos por correlación; descubrirás la relación alcohol–nota y las parejas redundantes (densidad, azúcar, alcohol).
3. **Unique**: elimina las filas repetidas antes de evaluar.
4. **Preprocess** con *Normalize features*, conectado a los modelos que lo necesitan (regresión lineal y SVM).
5. **Linear Regression**, **Random Forest** y **SVM**: tres modelos de complejidad creciente.
6. **Test and Score**: validación cruzada de 10 particiones; compara MAE, RMSE y R^2 con la referencia de predecir la media (MAE ≈ 0,68 en tintos).
7. **Predictions**: revisa en qué vinos falla más el mejor modelo; casi siempre son los de nota extrema.

7 Otras consideraciones

- **Unir tintos y blancos.** Con el widget *Concatenate* y la opción de añadir el identificador de origen se obtiene una columna con el tipo de vino, útil como atributo o como objetivo (¿se puede adivinar el color del vino por su química?).
- **Es el mismo fichero que muchas versiones de Kaggle** («Red Wine Quality»). El repositorio del curso tenía el tinto como `calidad_vino_tinto_regresion` (CSV y ARFF) y `regresion_calidad_vino_tinto.arff`: son idénticos a `wine_quality_red`, por eso no se duplican.
- **Para el tema de explicabilidad**, el add-on *Explain* (widget *Explain Model*) muestra con valores SHAP cuánto empuja cada análisis la nota hacia arriba o hacia abajo.

- **La nota es subjetiva y ordinal**: un 6 no es «el doble de bueno» que un 3. Tratarla como número (regresión) o como clase (clasificación) es una decisión de modelado que conviene discutir.
- No confundir con **Wine** (capítulo 4): son 178 vinos italianos de tres cultivares y el objetivo es identificar el cultivar.

En la carpeta	`wine_quality_red` ← `winequality-red.tab` (datasets.biolab.si)
En la carpeta	`wine_quality_white` ← `winequality-white.tab` (datasets.biolab.si)
Duplicado, no se copia	`calidad_vino_tinto_regresion.csv` (curso_ciencia_datos (GitHub))
Duplicado, no se copia	`calidad_vino_tinto_regresion.arff` (curso_ciencia_datos (GitHub))
Duplicado, no se copia	`regresion_calidad_vino_tinto.arff` (curso_ciencia_datos (GitHub))
Duplicado, no se copia	`calidad_vino_tinto_regresion(descripcion).txt` (curso_ciencia_datos (GitHub))

5.12
Regresión

Energy Efficiency (ENB2012)

`05_regresion/energy_efficiency/`

768 edificios simulados con ocho características de forma y acristalamiento y dos objetivos, la carga de calefacción y la de refrigeración: regresión con dos salidas en un problema casi determinista.

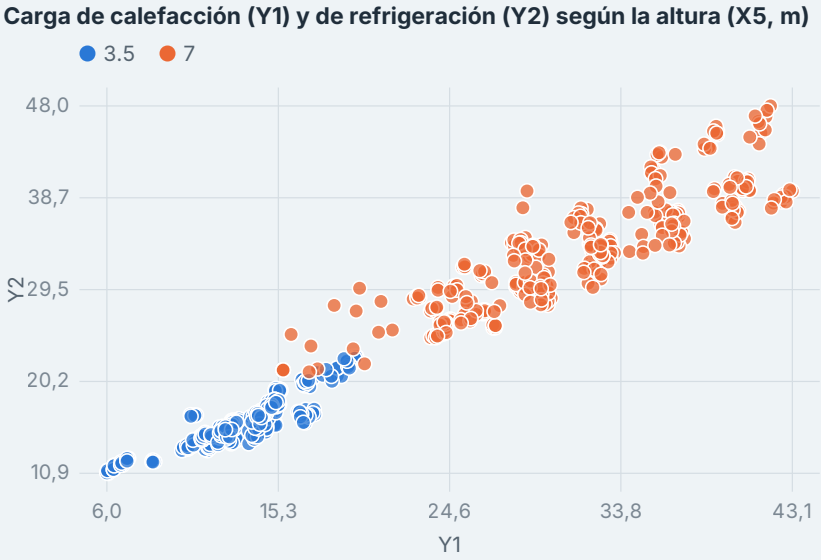
Regresión · Multiobjetivo

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
768	**10**	`Y1`	**0,0 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`energy_efficiency`	768 × 10	CSV 33 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/05_regresion/energy_efficiency/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Cada fila es un edificio **simulado por ordenador**: 12 formas distintas, cada una con 4 orientaciones y 16 combinaciones de superficie y distribución de las ventanas. De cada edificio se conocen ocho características (compacidad, superficies de fachada y cubierta, altura, orientación y acristalamiento) y dos resultados: la **carga de calefacción** y la **carga de refrigeración** que necesita.

Los estudios habituales son:

- **Regresión con dos objetivos** (*multitarget*): predecir las dos cargas a la vez.
- **Importancia de las variables**: qué características del diseño ahorran más energía.

- **Modelos lineales frente a árboles** cuando las variables toman pocos valores.

2 Contexto y fuente original

Lo publicaron **Athanasios Tsanas y Angeliki Xifara** (Universidad de Oxford) en 2012. Los edificios se simularon con el programa Ecotect, todos con el mismo volumen y los mismos materiales, en un clima griego. El fichero de Orange procede de la carpeta del curso (`regresion_consumo_energetico.csv`), con los nombres `X1` – `X8` , `Y1` e `Y2` del original.

- Tsanas, A. y Xifara, A. (2012). Accurate quantitative estimation of energy performance of residential buildings using statistical machine learning tools. Energy and Buildings, 49, 560–567.
- Energy Efficiency en el repositorio UCI

3 Variable objetivo

Hay **dos objetivos**: `Y1` , la carga de calefacción (de 6 a 43, en kWh/m²), y `Y2` , la de refrigeración (de 10,9 a 48). Están muy relacionadas (correlación 0,98).

La altura del edificio lo decide casi todo: los de 3,5 m necesitan 13,3 de calefacción de media y los de 7 m, 31,3. La superficie de ventanas también cuenta; la orientación, nada. En una prueba con validación cruzada de 10 bolsas, prediciendo cada objetivo por separado, el bosque aleatorio explica el 99,8 % de la varianza de la calefacción y el 97 % de la refrigeración; la regresión lineal, el 92 % y el 89 %.

4 Diccionario de columnas

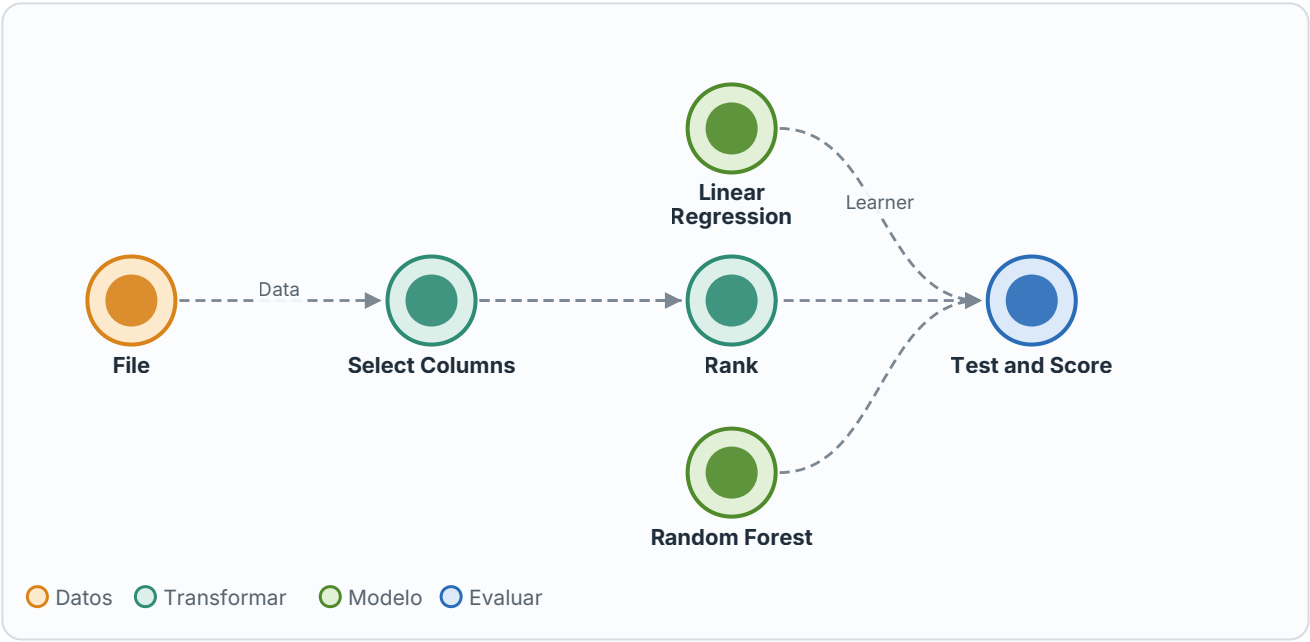
Columnas de `energy_efficiency` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
X1	numérica	Compacidad relativa (0,62–0,98): cuanto más compacto, menos superficie expuesta.	0,62 – 0,98
X2	numérica	Superficie total de la envolvente (m²). **Es exactamente X3 + 2 × X4.**	514,5 – 808,5
X3	numérica	Superficie de fachada (m²).	245 – 416,5
X4	numérica	Superficie de cubierta (m²).	110,25 – 220,5
X5	numérica	Altura total: 3,5 o 7 m (una o dos plantas).	3,5 – 7
X6	numérica	Orientación: 2 = norte, 3 = este, 4 = sur, 5 = oeste. **Es categórica.**	2 – 5
X7	numérica	Superficie acristalada, como fracción de la planta: 0, 10 %, 25 % o 40 %.	0 – 0,4
X8	numérica	Distribución del acristalamiento: 0 = sin ventanas, 1 = uniforme, 2–5 = concentrado en el lado norte, este, sur u oeste. **Es categórica.**	0 – 5
Y1 `objetivo`	numérica	**Objetivo 1**: carga de calefacción (kWh/m²).	6,01 – 43,1
Y2 `objetivo`	numérica	**Objetivo 2**: carga de refrigeración (kWh/m²).	10,9 – 48,03

5 Particularidades técnicas al modelar

- **Dos objetivos a la vez**: si se marcan los dos como objetivo en **File**, la mayoría de learners de Orange no funcionan, porque esperan uno solo. Lo más sencillo es trabajar cada objetivo por separado con *Select Columns*, dejando el otro como meta (y no como atributo: sería una fuga, porque están correlacionados al 0,98).
- **Datos simulados y sin ruido**: el mismo diseño da siempre la misma carga. Por eso los árboles llegan casi al 100 %. No hay que esperar estos resultados con edificios reales.
- **Variables redundantes**: `X2` es exactamente `X3 + 2·X4`, y `X1` y `X2` tienen una correlación de −0,99 (las 12 formas fijan las dos). La regresión lineal da coeficientes inestables o no puede calcularlos todos.
- **Variables con pocos valores**: todas tienen entre 2 y 12 valores distintos. `X6` y `X8` son códigos, no cantidades.
- **La orientación no influye** en la carga media (22,3 en las cuatro), aunque sí combinada con dónde están las ventanas.
- No hay valores ausentes.

6 Flujo de trabajo en Orange



1. **File** con el CSV (`X6` y `X8` como categóricas).
2. **Select Columns**: deja un solo objetivo (por ejemplo, `Y1`) y pasa el otro a meta.
3. **Rank**: la altura (`X5`) y las superficies salen arriba; la orientación (`X6`), abajo.
4. **Test and Score** con regresión lineal y bosque aleatorio.
5. Repite con `Y2` como objetivo y compara qué variables importan en cada caso.

7 Otras consideraciones

- **Clasificación**: el artículo también discretiza las cargas en niveles de eficiencia.
- **Diseño de edificios**: con el modelo se puede explorar qué combinación de forma y ventanas minimiza las dos cargas.

En la carpeta	`energy_efficiency` ← `regresion_consumo_energetico.csv` (curso_ciencia_datos (GitHub))

Duplicado, no se copia	`ENB2012_data_procesados.csv` (curso_ciencia_datos (GitHub))
Duplicado, no se copia	`regresion_consumo_energetico.xlsx` (curso_ciencia_datos (GitHub))
Duplicado, no se copia	`regresion_consumo_energetico.arff` (curso_ciencia_datos (GitHub))

5.13
Regresión

Hitters (salarios de béisbol, ISLR)

`05_regresion/hitters/`

322 jugadores de béisbol de las Grandes Ligas con sus estadísticas de 1986 y de toda su carrera, y su salario de 1987: regresión de ISLR con 59 salarios vacíos y un objetivo muy asimétrico.

Regresión · ? Valores faltantes · ◈ Mixto num. + cat.

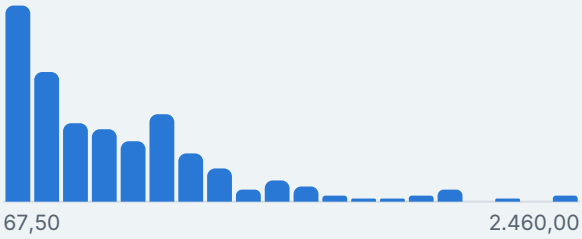
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
322	**21**	`Salary`	**0,9 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`hitters`	322 × 21	CSV 25 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/05_regresion/hitters/` seguido del nombre del fichero CSV.

Radiografía

Salary en hitters



Correlación de cada estadística con el salario



1 Descripción general y estudios habituales

Cada fila es un jugador de las Grandes Ligas de béisbol (MLB) con sus estadísticas de bateo y defensa de la temporada 1986 (turnos al bate, golpes, cuadrangulares, carreras, carreras impulsadas, bases por bolas…), las mismas estadísticas acumuladas en toda su carrera (columnas que empiezan por `C`), sus años en la liga, su liga y división, y su **salario** al empezar la temporada 1987.

Los estudios habituales son:

- **Regresión con selección de variables y regularización** (Lasso, Ridge): es el ejemplo del capítulo 6 de ISLR.
- **Árboles de regresión**: el ejemplo del capítulo 8 de ISLR (años en la liga y golpes).
- **Valores ausentes en el objetivo**.

2 Contexto y fuente original

Los datos proceden de StatLib (Universidad Carnegie Mellon) y se usaron en la exposición de datos de la sección de gráficos de la **American Statistical Association** de 1988. Las estadísticas salieron de la *1987 Baseball Encyclopedia Update*, y los salarios, de *Sports Illustrated*. Se popularizaron con el libro ***An Introduction to Statistical Learning*** (ISLR) y su paquete de R. El fichero de Orange procede de la carpeta del curso (`Hitters.csv`).

- Paquete ISLR2 de R (datos Hitters, con su documentación)
- James, G., Witten, D., Hastie, T. y Tibshirani, R. An Introduction to Statistical Learning (web del libro)

3 Variable objetivo

El objetivo es `Salary`, el salario anual en **miles de dólares** de 1987: de 67,5 a 2.460, con mediana de 425. **59 jugadores no tienen salario** y Orange los descarta al entrenar.

Lo que más se relaciona con el salario son las estadísticas de carrera (carreras impulsadas, carreras y golpes de toda la carrera, correlaciones de 0,55–0,57), más que las de 1986: se paga la trayectoria. En una prueba con validación cruzada de 10 bolsas, la regresión lineal explica un 43 % de la varianza y el bosque aleatorio un 60 % (RMSE de 283.000 dólares).

4 Diccionario de columnas

Columnas de `hitters` (valores observados en el fichero)

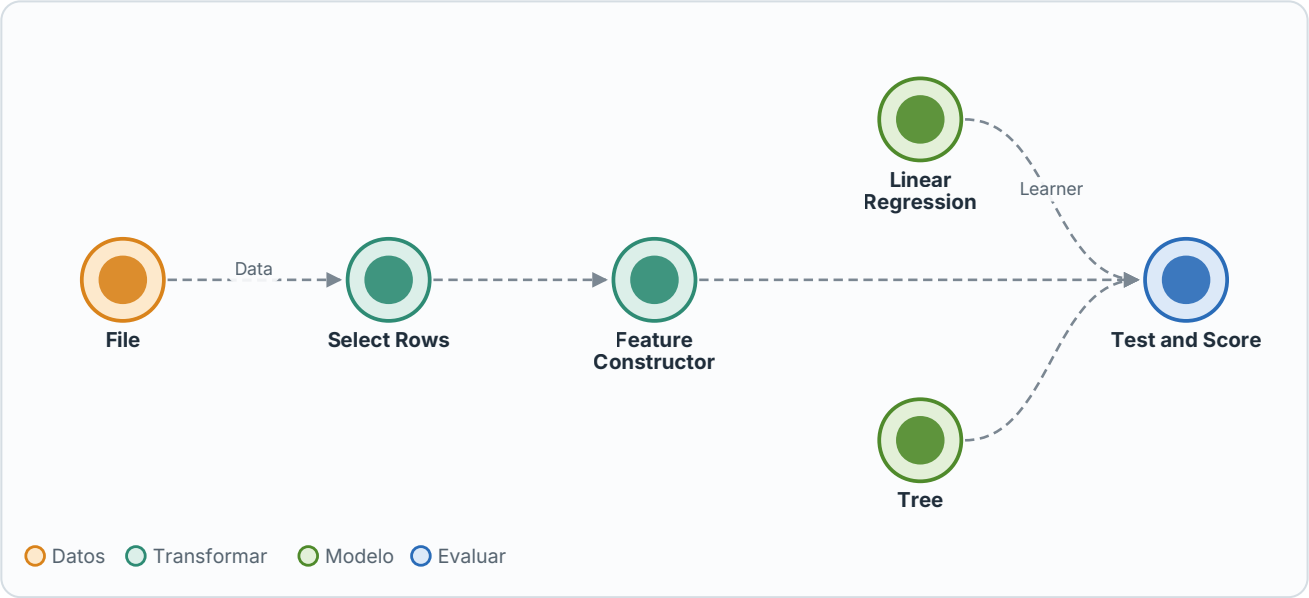
Columna	Tipo	Significado	Valores
`Player`	texto	Nombre del jugador (meta). **Todos empiezan por un guion** (`-Andy Allanson`), que venía del nombre de fila del fichero original.	-Andy Allanson (1), -Alan Ashby (1), -Alvin Davis (1), -Andre Dawson (1), -Andres Galarraga (1), -Alfredo Griffin (1) …
`AtBat`	numérica	Turnos al bate en 1986.	16 – 687
`Hits`	numérica	Golpes (*hits*) en 1986.	1 – 238
`HmRun`	numérica	Cuadrangulares (*home runs*) en 1986.	0 – 40
`Runs`	numérica	Carreras anotadas en 1986.	0 – 130
`RBI`	numérica	Carreras impulsadas en 1986.	0 – 121

Columna	Tipo	Significado	Valores
`Walks`	numérica	Bases por bolas en 1986.	0 – 105
`Years`	numérica	Años en las Grandes Ligas.	1 – 24
`CAtBat`	numérica	Turnos al bate en toda la carrera.	19 – 14.053
`CHits`	numérica	Golpes en toda la carrera.	4 – 4.256
`CHmRun`	numérica	Cuadrangulares en toda la carrera.	0 – 548
`CRuns`	numérica	Carreras en toda la carrera.	1 – 2.165
`CRBI`	numérica	Carreras impulsadas en toda la carrera.	0 – 1.659
`CWalks`	numérica	Bases por bolas en toda la carrera.	0 – 1.566
`League`	categórica	Liga al final de 1986: `A` (Americana) o `N` (Nacional).	A (175), N (147)
`Division`	categórica	División al final de 1986: `E` (Este) o `W` (Oeste).	W (165), E (157)
`PutOuts`	numérica	Eliminaciones (*put outs*) en defensa en 1986.	0 – 1.378
`Assists`	numérica	Asistencias en defensa en 1986.	0 – 492
`Errors`	numérica	Errores en defensa en 1986.	0 – 32
`Salary` `objetivo`	numérica	**Objetivo**: salario en 1987, en miles de dólares. **59 vacíos.**	67,5 – 2.460
`NewLeague`	categórica	Liga al principio de 1987 (`A` o `N`).	A (176), N (146)

5 Particularidades técnicas al modelar

- **Salarios vacíos**: 59 de 322. No tiene sentido imputar el objetivo; lo habitual es quitar esas filas (quedan 263), como hace ISLR.
- **Objetivo asimétrico**: pocos jugadores cobran mucho. Con el logaritmo del salario los modelos lineales funcionan mejor y el árbol de ISLR queda más claro.
- **Estadísticas de carrera dependen de los años**: un jugador veterano acumula más de todo. Las medias por año (`CHits / Years`) separan el talento de la antigüedad.
- **Muchas variables correlacionadas** (turnos al bate, golpes y carreras; las de carrera entre sí): Lasso o Ridge son preferibles a la regresión lineal sin regularizar.
- **Nombres con guion inicial** en `Player`: si se cruza con otras fuentes hay que quitarlo.

6 Flujo de trabajo en Orange



1. **File** con el CSV (`Salary` como objetivo y `Player` como meta).
2. **Select Rows**: `Salary` *is defined*, para quitar los 59 vacíos.
3. **Feature Constructor**: crea `log(Salary)` y úsalo como objetivo.
4. **Test and Score** con regresión lineal (*Lasso*, normalizando) y árbol.
5. **Tree Viewer** con un árbol de profundidad 2–3: `Years` y `Hits` aparecen arriba, como en ISLR.

7 Otras consideraciones

- **Árbol de ISLR**: con `Years` y `Hits` solos, un árbol pequeño separa a los jugadores en tres grupos de salario: pocos años; muchos años y pocos golpes; muchos años y muchos golpes.
- **Clasificación**: dividiendo el salario por la mediana se obtiene un problema binario.

En la carpeta `hitters` ← `Hitters.csv` (curso_ciencia_datos (GitHub))

5.14
Regresión

Multitarget synthetic

`05_regresion/multitarget_synthetic/`

100 filas sintéticas con 3 variables de entrada y 4 objetivos numéricos, uno de ellos puro ruido: un dataset de juguete para probar la regresión con varias salidas en Orange.

Regresión · Multiobjetivo · Sintético

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
100	**7**	`Y1`	**0,0 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`multitarget_synthetic`	100 × 7	CSV 4 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/05_regresion/multitarget_synthetic/` seguido del nombre del fichero CSV.

Radiografía

R^2 de la regresión lineal por objetivo (validación cruzada de 10 bolsas)



1 Descripción general y estudios habituales

Un conjunto de datos inventado con tres variables de entrada (`X1` , `X2` , `X3`) y **cuatro objetivos** (`Y1` a `Y4`), todos numéricos. Al ser sintético, sirve para comprobar si un método descubre relaciones que sabemos que existen (o que no existen).

Los estudios habituales son:

- **Regresión con varios objetivos** (*multitarget*) en Orange.
- **Comparar objetivos**: unos se predicen bien y otro no se puede predecir.
- **Relaciones entre objetivos**: dos de ellos son casi el mismo.

2 Contexto y fuente original

Lo incluye el repositorio de datasets de **Orange** sin descripción ni autor: solo dice que es un conjunto sintético para regresión con varios objetivos. Las relaciones que se describen en esta ficha se han deducido de los propios datos.

- Multitarget Synthetic en el repositorio de datasets de Orange

3 Variable objetivo

Hay **cuatro objetivos**, y cada uno se comporta de forma distinta:

- `Y1` depende casi solo de `X1` (correlación 0,89).
- `Y2` depende de `X1` (a favor) y de `X2` (en contra).
- `Y3` es prácticamente `Y2` escalado (correlación 0,99 entre ambos).
- `Y4` no tiene relación con nada: es ruido, con valores repartidos entre 0 y 1.

En una prueba con validación cruzada de 10 bolsas con regresión lineal, prediciendo cada objetivo por separado, el R^2 es de 0,80 para `Y1`, 0,89 para `Y2` y 0,90 para `Y3`, y de −0,07 para `Y4` (peor que la media).

4 Diccionario de columnas

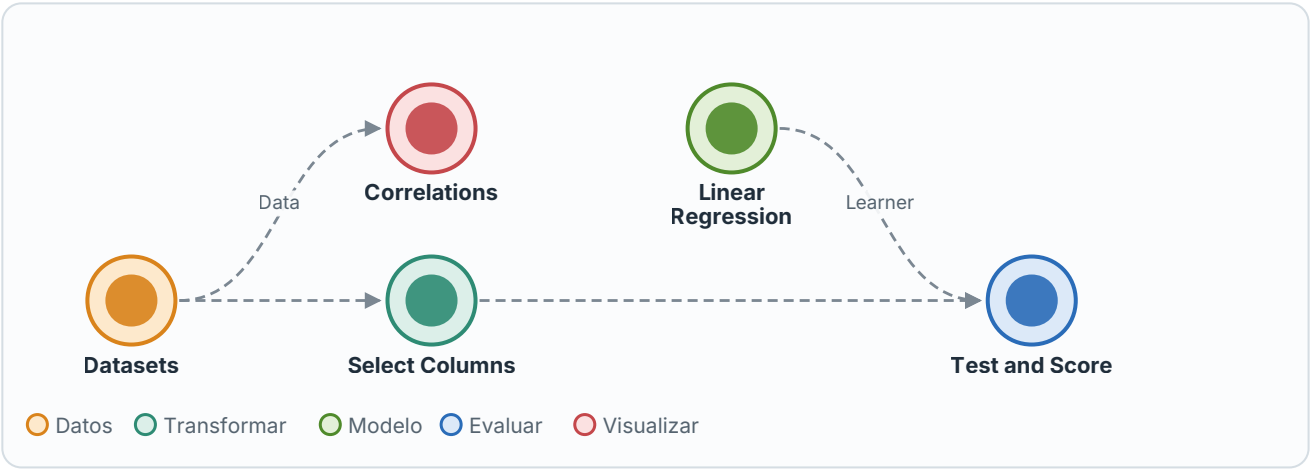
Columnas de `multitarget_synthetic` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
X1	numérica	Variable de entrada 1 (aprox. 0–1).	-0,089 – 1,223
X2	numérica	Variable de entrada 2 (aprox. 0–1).	-0,139 – 1,115
X3	numérica	Variable de entrada 3. Es aproximadamente `X1 + X2` (explica el 84 % de su varianza).	-0,097 – 1,87
Y1 `objetivo`	numérica	**Objetivo 1**: aproximadamente proporcional a `X1`.	-0,164 – 1,044
Y2 `objetivo`	numérica	**Objetivo 2**: crece con `X1` y baja con `X2`.	-2,74 – 1,687
Y3 `objetivo`	numérica	**Objetivo 3**: casi igual a `Y2` multiplicado por 1,8.	-5,642 – 2,54
Y4 `objetivo`	numérica	**Objetivo 4**: sin relación con las entradas (ruido).	0,002 – 0,995

5 Particularidades técnicas al modelar

- **Cuatro objetivos a la vez**: en Orange, la mayoría de learners esperan un solo objetivo. Para trabajar con uno, usa *Select Columns* y deja los demás como metas.
- `X3` **es redundante**: se obtiene casi sumando `X1` y `X2`. Con las tres en una regresión lineal, los coeficientes se reparten de forma inestable.
- `Y4` **no se puede predecir**: es la prueba de que un modelo no siempre encuentra algo. Cualquier R^2 positivo en entrenamiento es sobreajuste.
- **Muy pocas filas** (100): los resultados cambian bastante entre particiones.
- Sin origen documentado: no se sabe con qué fórmulas exactas se generó.

6 Flujo de trabajo en Orange



1. **Datasets** → «Multitarget Synthetic».
2. **Correlations**: mira la relación entre `Y2` e `Y3`, y que `Y4` no se relaciona con nada.
3. **Select Columns**: deja un objetivo y pasa los otros tres a metas.
4. **Test and Score** con regresión lineal; repite con cada objetivo y compara el R^2.

7 Otras consideraciones

- **Para qué sirve**: más que un problema real, es un banco de pruebas para enseñar qué pasa con objetivos predecibles, redundantes e impredecibles.
- **Otro dataset con dos objetivos**: Energy Efficiency, en este mismo capítulo, con datos simulados de edificios.

En la carpeta `multitarget_synthetic` ← `multitarget-synthetic.tab` (datasets.biolab.si)

6 No supervisado: clustering, exploración y datos geográficos

21 datasets en el capítulo; en esta edición, 21 con ficha.

6.01
No supervisado: clustering, exploración y datos geográficos

Grades (notas de estudiantes)

`06_exploracion_clustering_geo/grades/`

Notas inventadas de 16 estudiantes en siete asignaturas (y una versión con 12 estudiantes y dos asignaturas): el dataset de juguete de Orange para explicar distancias y agrupamiento jerárquico.

Clustering | Exploración y visualización | ◦ Juguete | ✎ Sintético

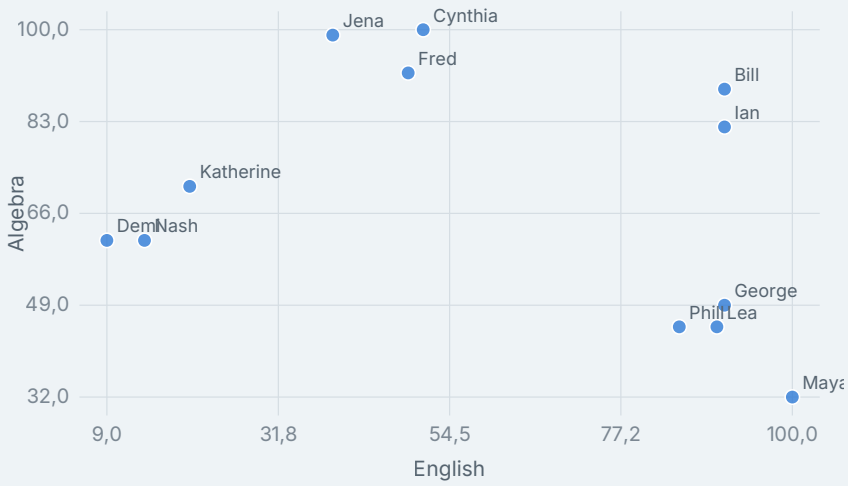
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
16	**8**	–	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`grades`	16 × 8	CSV 1 KB · XLSX
`grades_two`	12 × 3	CSV 1 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/grades/` seguido del nombre del fichero CSV.

Radiografía

Inglés y álgebra (grades_two): cada punto es un estudiante



1 Descripción general y estudios habituales

Dos tablas pequeñas, hechas a mano para enseñar:

- `grades` : 16 estudiantes con su nota (0–100) en siete asignaturas: inglés, francés, historia, álgebra, biología, física y educación física.
- `grades_two` : 12 de esos estudiantes con solo dos asignaturas, inglés y álgebra, para poder dibujar los puntos en un plano y calcular distancias a mano.

No hay variable objetivo: la pregunta es **qué estudiantes se parecen** y qué grupos se forman (los de letras, los de ciencias, los deportistas…).

Los estudios habituales son:

- **Distancia euclídea** y su interpretación en dos dimensiones.
- **Agrupamiento jerárquico** y lectura del dendrograma.
- **k-medias** y comparación con el jerárquico.

2 Contexto y fuente original

Los creó el equipo de **Orange** (Biolab, Universidad de Liubliana) para sus cursos y vídeos de introducción al agrupamiento. Los nombres de los estudiantes y las notas son inventados, pensados para que los grupos se vean claros.

- Course Grades en el repositorio de datasets de Orange
- Grades for English and Math en el repositorio de datasets de Orange

3 Variable objetivo

No tiene variable objetivo. Lo que se busca son grupos de estudiantes. En la tabla de siete asignaturas se distinguen a simple vista tres perfiles: estudiantes buenos en idiomas e historia (Bill, Eve, Lea, Maya), buenos en ciencias (Demi, Fred, Jena, Katherine, Olga) y estudiantes cuya mejor nota es la de educación física (Ana, Henry). George, Ian y Phill sacan buenas notas en casi todo.

4 Diccionario de columnas

Columnas de `grades` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Student`	texto	Nombre del estudiante (meta).	Ana (1), Bill (1), Cynthia (1), Demi (1), Eve (1), Fred (1) …
`English`	numérica	Nota de inglés (0–100).	9 – 100
`French`	numérica	Nota de francés.	4 – 100
`History`	numérica	Nota de historia.	8 – 100
`Algebra`	numérica	Nota de álgebra.	12 – 100
`Biology`	numérica	Nota de biología.	11 – 100
`Physics`	numérica	Nota de física.	11 – 100

Columna	Tipo	Significado	Valores
`Physical`	numérica	Nota de educación física (*physical education*).	8 – 100

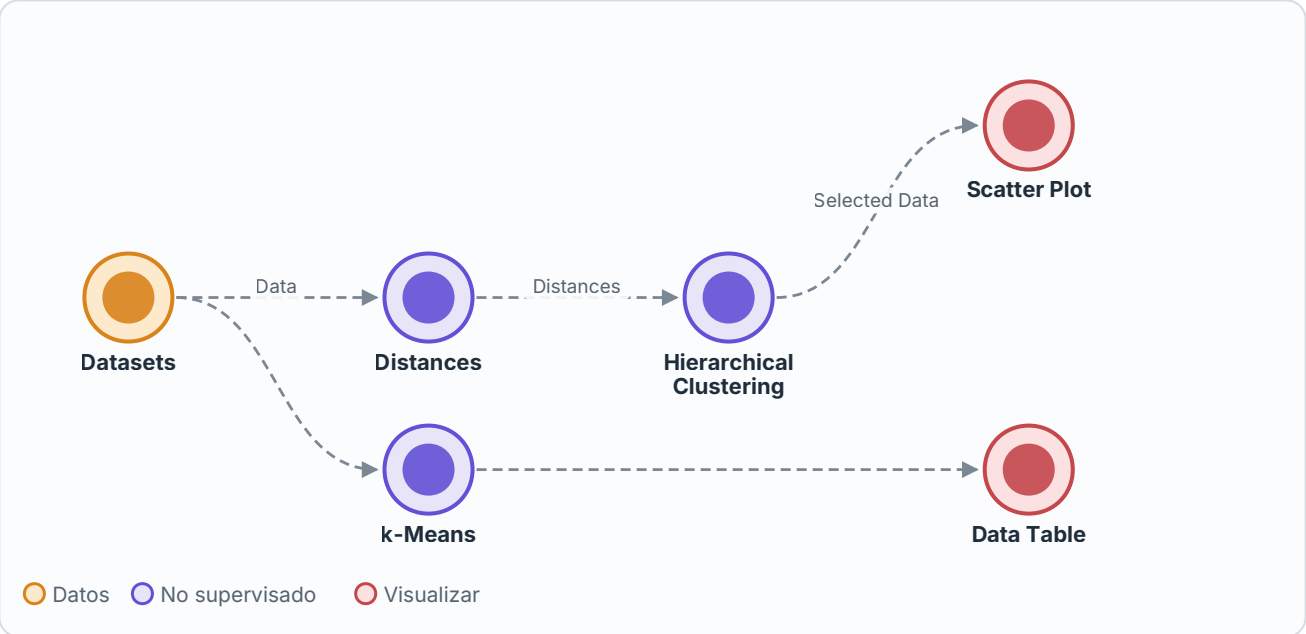
Columnas de `grades_two` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`English`	numérica	Nota de inglés (0–100).	9 – 100
`Algebra`	numérica	Nota de álgebra (0–100).	32 – 100
`Student`	texto	Nombre del estudiante (meta).	Bill (1), Cynthia (1), Demi (1), Fred (1), George (1), Ian (1) …

5 Particularidades técnicas al modelar

- **Muy pocos datos a propósito**: con 12 o 16 filas, todo se puede ver y comprobar a mano. No sirve para sacar conclusiones.
- **Misma escala en todas las variables** (0–100): aquí no hace falta normalizar, lo que permite hablar de la normalización en otro dataset por contraste.
- `Physical` es educación física, no física (que es `Physics`).
- `grades_two` **no tiene a todos**: faltan Ana, Eve, Henry y Olga; las notas de los demás de inglés y álgebra coinciden con las de `grades`.
- No hay valores ausentes.

6 Flujo de trabajo en Orange



1. **Datasets** → «Grades for English and Math» y **Scatter Plot**: ¿qué estudiantes están cerca?
2. **Distances** (euclídea) → **Distance Matrix**: comprueba un par de distancias a mano.
3. **Hierarchical Clustering**: lee el dendrograma; selecciona grupos y míralos en **Scatter Plot**.
4. Repite con «Course Grades» (siete asignaturas): ya no se puede dibujar, pero el dendrograma sí funciona.
5. **k-Means** con k = 3 y compara los grupos con los del jerárquico.

7 Otras consideraciones

- **Enlace de los grupos**: compara en *Hierarchical Clustering* el enlace simple, completo, medio y de Ward; con tan pocos puntos se ve bien cómo cambia el dendrograma.
- **Siguiente paso**: Mathematics and football (aún más pequeño) para una demostración en clase, y Wine o Weather para agrupar con datos reales.

En la carpeta	`grades` ← `grades.xlsx` (datasets.biolab.si)
En la carpeta	`grades_two` ← `grades-two.tab` (datasets.biolab.si)

6.02

No supervisado: clustering, exploración y datos geográficos

Mathematics and football

`06_exploracion_clustering_geo/mathematics_football/`

Once alumnos con una puntuación de matemáticas y otra de fútbol: el dataset más pequeño del libro, pensado para hacer agrupamiento en directo en clase, con los propios alumnos como datos.

Clustering · ◦ Juguete · ✎ Sintético

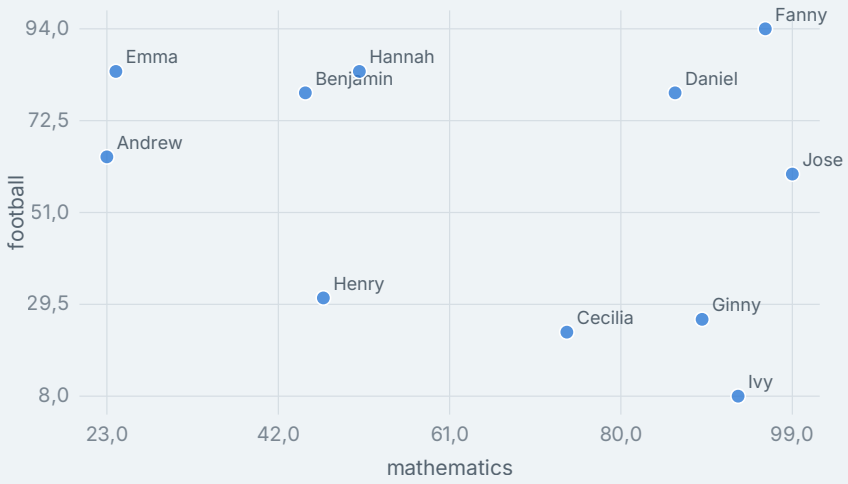
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
11	**3**	—	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`mathematics_football`	11 × 3	CSV 1 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/mathematics_football/` seguido del nombre del fichero CSV.

Radiografía

Matemáticas y fútbol: cada punto es un alumno



1 Descripción general y estudios habituales

Once nombres inventados con dos puntuaciones de 0 a 100: lo bien que se les dan las **matemáticas** y el **fútbol**. Con solo dos variables y once puntos, todo se puede dibujar en la pizarra y agrupar a ojo antes de que lo haga el ordenador.

Los estudios habituales son:

- **Introducción al agrupamiento** con un ejemplo que cabe en una diapositiva.
- **Comparar el agrupamiento humano y el del algoritmo**.

2 Contexto y fuente original

Es material del proyecto **Pumice** del equipo de Orange (Universidad de Liubliana), que prepara actividades de ciencia de datos para escuelas; según su ficha, está pensado para una demostración en directo de agrupamiento en clase. Existe en esloveno, francés y alemán.

- Mathematics and Soccer en el repositorio de datasets de Orange

3 Variable objetivo

No tiene variable objetivo. Al dibujar los once puntos aparecen grupos de alumnos según les vayan mejor las matemáticas, el fútbol, las dos cosas o ninguna. La gracia está en que los alumnos propongan sus grupos y luego los comparen con los del algoritmo.

4 Diccionario de columnas

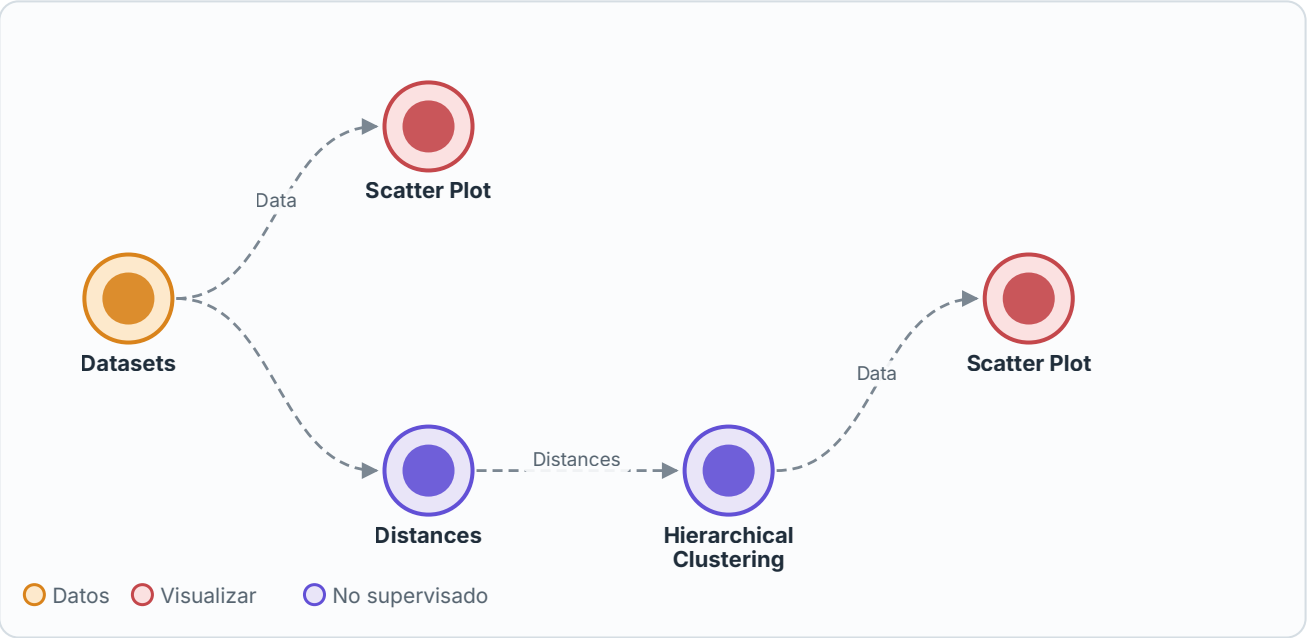
Columnas de `mathematics_football` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`name`	texto	Nombre del alumno (meta).	Andrew (1), Benjamin (1), Cecilia (1), Daniel (1), Emma (1), Fanny (1) …
`mathematics`	numérica	Puntuación en matemáticas (0–100).	23 – 99
`football`	numérica	Puntuación en fútbol (0–100).	8 – 94

5 Particularidades técnicas al modelar

- **Datos de juguete**: once filas, sin ruido ni ausentes. Está hecho para enseñar el concepto, no para analizar.
- **Misma escala** en las dos variables: las distancias se pueden calcular directamente.
- **Versiones traducidas** (esloveno, francés, alemán); en este libro se incluye solo la inglesa.

6 Flujo de trabajo en Orange



1. **Datasets** → «Mathematics and Soccer».
2. **Scatter Plot**: pide a los alumnos que propongan grupos a ojo.
3. **Distances** → **Hierarchical Clustering**: corta el dendrograma en 3 o 4 grupos.
4. **Scatter Plot** coloreado por grupo: ¿coinciden con los grupos propuestos?

7 Otras consideraciones

- **Con los datos de la clase**: sustituye la tabla por las puntuaciones de los propios alumnos (con **Create Table** o una hoja de cálculo).
- **Continuación natural**: Grades (más asignaturas) y luego datasets reales como Weather o Wine.

En la carpeta	`mathematics_football` ← `mathematics-football.xlsx` (datasets.biolab.si)
Traducción, no se copia	`matematika-nogomet.xlsx` (datasets.biolab.si)
Traducción, no se copia	`mathématiques-football.xlsx` (datasets.biolab.si)
Traducción, no se copia	`Mathematik-Fußball.xlsx` (datasets.biolab.si)

6.03

No supervisado: clustering, exploración y datos geográficos

Human Development Index (HDI)

`06_exploracion_clustering_geo/hdi/`

188 países con su Índice de Desarrollo Humano de 2015 y 52 indicadores de salud, educación, empleo y desigualdad del PNUD.

Clustering | Exploración y visualización | ⌖ Espacial | ? Valores faltantes

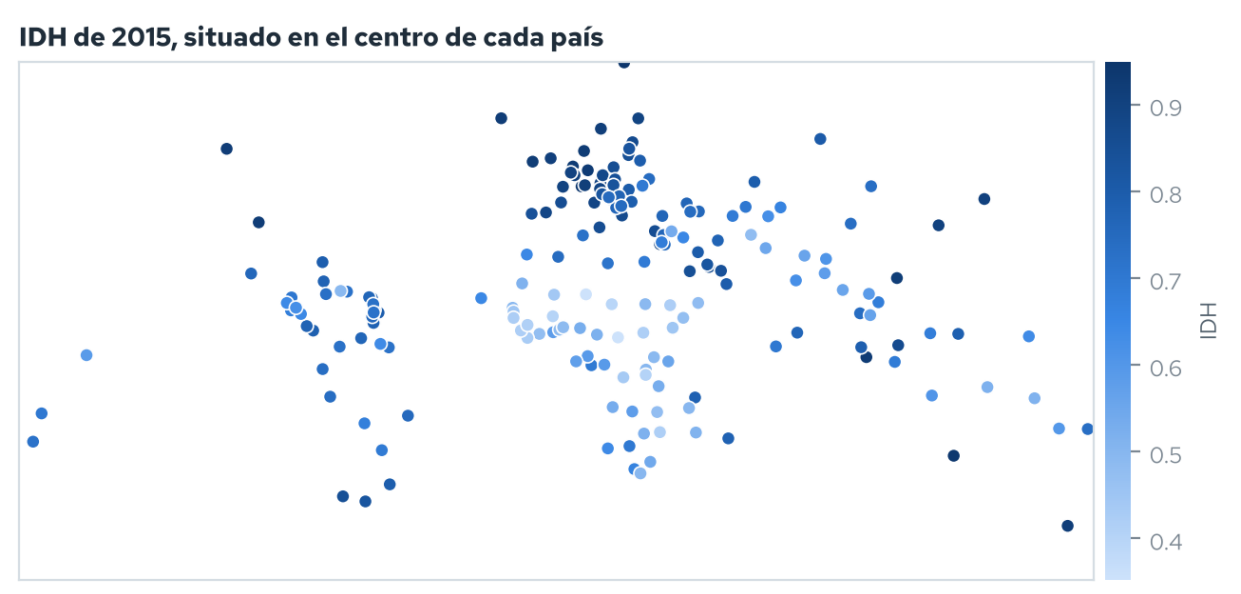
En el curso: Actividad 5.2 (Tema 5, datos espaciales): mapa de países por IDH, propuesta como ejercicio («buscar HDI» en el widget Datasets).

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
188	**54**	`HDI (meta)`	**11,2 %**	**Intermedio**	**Geo**

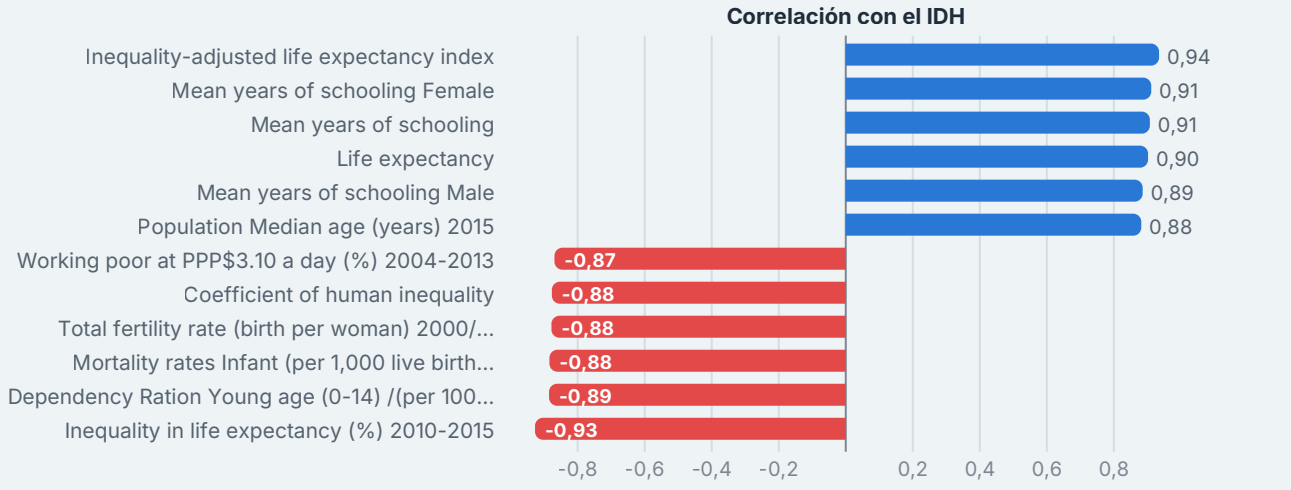
Fichero	Filas × col.	Descargar
`hdi`	188 × 54	CSV 45 KB · XLSX
`hdi_edu`	188 × 53	CSV 50 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/hdi/` seguido del nombre del fichero CSV.

Radiografía



Los 12 indicadores más relacionados con el IDH



1 Descripción general y estudios habituales

Cada fila es un país, con su **Índice de Desarrollo Humano** (IDH, *HDI* en inglés) de 2015 y una selección de indicadores socioeconómicos del Programa de las Naciones Unidas para el Desarrollo (PNUD): esperanza de vida, años de escolarización, renta, mortalidad infantil, fecundidad, empleo, acceso a internet, desigualdad, etc. Casi todas las columnas son porcentajes o tasas, con los nombres originales en inglés.

Es un dataset muy versátil para explorar datos de países. Los estudios habituales son:

- **Agrupar países** (clustering) por su perfil socioeconómico y ver si los grupos coinciden con regiones o con el IDH.
- **Pintar mapas** (coropletas) del IDH o de cualquier indicador.
- **Proyectar** los 52 indicadores en dos dimensiones (PCA, MDS, t-SNE) y ver qué países se parecen.
- **Predecir el IDH** (regresión) a partir de los demás indicadores, con cuidado con las variables que forman parte del propio índice.

2 Contexto y fuente original

El IDH lo publica cada año el PNUD en el *Informe sobre Desarrollo Humano*. Resume tres dimensiones: una **vida larga y saludable** (esperanza de vida al nacer), el **conocimiento** (años medios de escolarización de los adultos y años esperados de escolarización de los niños) y un **nivel de vida digno** (renta nacional bruta per cápita en dólares PPA). Cada dimensión se normaliza entre 0 y 1 y el IDH es su media geométrica.

Los valores corresponden al informe de 2016 (datos de 2015), donde encabeza Noruega (0,949) y cierra la República Centroafricana (0,352). Biolab los tomó de la recopilación de Kaggle *Human Development Data (1990–2015)* del PNUD, quitó los países sin IDH y algunas variables relacionadas con el índice, y preparó dos versiones:

- `hdi`: 188 países, 52 indicadores, el nombre del país y el IDH.
- `hdi_edu`: los mismos países e indicadores **sin la columna HDI**, con la latitud y la longitud del país para dibujarlos en un mapa. Se usa en actividades educativas de la plataforma eslovena *pumice.si*.

- PNUD: Human Development Report 2016 y tablas de datos
- Human Development Data (1990–2015) en Kaggle (PNUD)
- Explicación técnica del IDH (PNUD)

3 Variable objetivo

Este dataset **no trae una variable objetivo definida**: el IDH (`HDI`) viene como columna *meta*, para colorear y etiquetar, y el país (`Country`) como identificador. Se puede usar `HDI` como objetivo de regresión, poniéndolo como *target* en *File*.

El IDH va de 0,352 a 0,949, con media 0,699. España está en 0,884 (puesto 27) y Portugal en 0,843. El PNUD clasifica los países en desarrollo humano muy alto (0,800 o más), alto (0,700–0,799), medio (0,550–0,699) y bajo (menos de 0,550), una discretización útil si se quiere convertir el problema en clasificación.

4 Diccionario de columnas

Columnas de `hdi` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Life expectancy`	numérica	Esperanza de vida al nacer, en años. Es uno de los componentes del IDH.	48,9 – 84,2
`Mean years of schooling`	numérica	Años medios de escolarización de los adultos (25 años o más). Componente del IDH.	1,4 – 13,4
`Gross national income (GNI) per capita`	numérica	Renta nacional bruta per cápita, en dólares PPA de 2011. Componente del IDH.	587 – 129.916
`Gender Development Index value`	numérica	Índice de desarrollo de género: IDH de las mujeres entre IDH de los hombres.	0,609 – 1,032
`Mean years of schooling Female`	numérica		1 – 13,4
`Mean years of schooling Male`	numérica		2 – 13,6
`Estimated gross national income per capita Female`	numérica		481 – 60.787
`Estimated gross national income per capita Male`	numérica		696 – 159.897
`Share of seats in parliament (% held by women)`	numérica		0 – 57,5
`Population with at least some secondary education % (2005-2015) Female`	numérica		1,7 – 100,6
`Population with at least some secondary education % (2005-2015) Male`	numérica		8 – 100

Columna	Tipo	Significado	Valores
Labour force participation rate (% ages 15 and older) Female	numérica		12,2 – 86,4
Population Average annual growth 2000/2005 (%)	numérica		-1,3 – 7,7
Population Average annual growth 2010/2015 (%)	numérica		-3,6 – 8,4
Population Urban 2015 %	numérica		8,4 – 100
Population Median age (years) 2015	numérica		14,8 – 46,5
Dependency Ration Young age (0-14) /(per 100 people ages 15-64)	numérica		16,4 – 107,5
Dependency Ratio Old age (65 and older) /(per 100 people ages 15-64)	numérica		1,3 – 43,3
Total fertility rate (birth per woman) 2000/2005	numérica		1 – 7,7
Total fertility rate (birth per woman) 2000/2007	numérica		1,2 – 7,6
Infants exclusively breastfed (% ages 0-5 months) 2010-2015	numérica		0,3 – 87,3
Infants lacking immunization DTP (% of one-year-olds)	numérica		1 – 51
Infants lacking immunization Measles (% of one-year-olds)	numérica		1 – 78
Child malnutrition Stunting (moderate or severe) 2010-2015	numérica		1,3 – 57,5
Mortality rates Infant (per 1,000 live births) 2015	numérica		1,5 – 96

Columna	Tipo	Significado	Valores
Mortality rates Under-five (per 1,000 live births) 2015	numérica		1,9 – 156,9
Mortality rates Female Adult (per 1,000 live births) 2014	numérica		32 – 612
Mortality rates Male Adult (per 1,000 live births) 2014	numérica		64 – 581
Deaths due to Malria (per 100,000 people)	numérica		0 – 152,6
Deaths due to Tuberculosis (per 100,000 people)	numérica		0 – 120
HIV prevalence, adult (% ages 15-49)	numérica		0,1 – 28,8
Life expectancy at age 59 (years) 2010/2015	numérica		13 – 25,8
Physicians (per 10,000 people) 2001-2014	numérica		0,1 – 77,4
Public health expenditure (% of GDP) 2014	numérica		0,8 – 12,4
Employment to population ratio (% ages 15 and older)	numérica		24,1 – 84,6
Labour force participation rate (% ages 15 and older)	numérica		40 – 86,4
Employment in agriculture (% of total employment) 2010-2014	numérica		0,5 – 75,3
Employment in services (% of total employment) 2010- 2014	numérica		16,2 – 85,7
Total Unemployment (% of labour force) 2015	numérica		0,2 – 53,9
Unemployment Youth (% ages 15-24) 2010-2014	numérica		0,8 – 66,9

Columna	Tipo	Significado	Valores
`Unemployment Youth not in school or employment (% ages 15-24) 2010-2014`	numérica		0,5 – 56,4
`Vulnerable employment (% of total employment) 2005-2014`	numérica		0,2 – 93,7
`Working poor at PPP$3.10 a day (%) 2004-2013`	numérica		0,4 – 93,5
`Old-age pension recipients (% of statutory pension age population) 2004-2013`	numérica		0 – 100
`Internet users (% 2010 -2015)`	numérica		-100 – 6.603,2
`Coefficient of human inequality`	numérica		5,3 – 44,8
`Inequality in life expectancy (%) 2010-2015`	numérica		2,6 – 46,2
`Inequality-adjusted life expectancy index`	numérica		0,263 – 0,959
`Child labour (% ages 5-14) 2009-2015`	numérica		1 – 47
`Inequality in education(%)`	numérica		1,4 – 48,3
`Inequality in income (%)`	numérica		8,9 – 56,4
`Mandatory paid maternity leave (days)`	numérica		0 – 410
`Country`	texto	Nombre del país, en inglés. Rol *meta*.	Norway (1), Australia (1), Switzerland (1), Germany (1), Denmark (1), Singapore (1) …
`HDI`	numérica	Índice de Desarrollo Humano de 2015, de 0 a 1. Rol *meta*; se puede usar como objetivo de regresión.	0,352 – 0,949

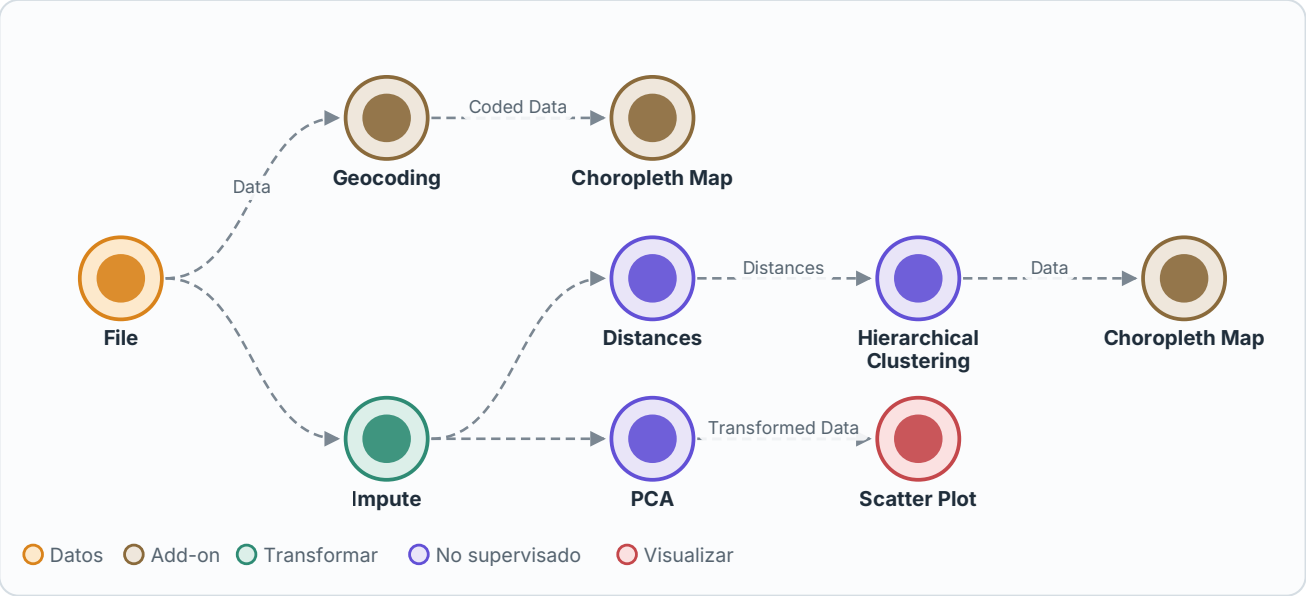
`hdi_edu` tiene las mismas columnas con el mismo significado que `hdi`.

5 Particularidades técnicas al modelar

- **Muchos faltantes**: el 11 % de las celdas está vacío, y algunos indicadores faltan en casi la mitad de los países (muertes por malaria en el 50 %, jóvenes que ni estudian ni trabajan en el 45 %, prevalencia de VIH en el 44 %). Antes de agrupar o modelar, decide si quitas esas columnas o imputas (*Impute*); los métodos de distancias no admiten huecos.

- **El IDH se predice a sí mismo**: la esperanza de vida, los años de escolarización y la renta per cápita son componentes del índice (correlación de 0,90 y 0,91 con él). Un modelo de regresión con ellas acierta casi siempre, pero no descubre nada. Quítalas si lo que se quiere es explicar el IDH con otros factores.
- **Escalas muy distintas** (renta en decenas de miles de dólares, tasas en %): normaliza antes de clustering, PCA o kNN.
- **Para el mapa** hacen falta coordenadas: `hdi_edu` las trae; con `hdi` hay que obtenerlas con el widget *Geocoding* (add-on *Geo*) a partir del nombre del país. Algunos nombres no coinciden con los del geocodificador (por ejemplo, los que llevan paréntesis, como `Bolivia (Plurinational State of)`), y esos países se quedan sin pintar.
- **Los nombres de columna son largos** y algunos llevan erratas del original (`Malria`, `Ration`) o el periodo al que se refieren; en `hdi_edu`, varios usan un guion largo (–) en lugar del corto: no los compares por nombre exacto entre ficheros.
- Las dos versiones no son la misma tabla: `hdi_edu` no tiene la columna `HDI` y sí latitud y longitud.

6 Flujo de trabajo en Orange



1. **File** con `hdi` (o **Datasets** → «HDI»): `Country` y `HDI` vienen como *meta*.
2. **Geocoding** (add-on *Geo*): codifica `Country` como nombre de país para obtener latitud y longitud.
3. **Choropleth Map**: pinta los países con *Values* = `HDI`. Revisa qué países quedan en blanco.
4. **Impute** (media, o quita antes las columnas con más del 40 % de huecos) → **Distances** (euclídea, normalizando) → **Hierarchical Clustering**: corta en 3 o 4 grupos.
5. **Choropleth Map** coloreado por el grupo: ¿coinciden los grupos con regiones del mundo?
6. **PCA** → **Scatter Plot** coloreado por `HDI`: el primer componente ordena los países casi como el IDH.

7 Otras consideraciones

- **Ejercicio de regresión honesto**: quita los tres componentes del IDH (y el índice de género, que se calcula con ellos) y predice el IDH con el resto. Los indicadores de mortalidad infantil y fecundidad siguen explicando mucho.
- **Ejercicio de clasificación**: crea con *Feature Constructor* la categoría del PNUD (muy alto, alto, medio, bajo) a partir de `HDI` y úsala como objetivo.
- **Es una foto de un año**: para ver la evolución en el tiempo hacen falta otras tablas del PNUD (la serie 1990–2015 está en Kaggle).

- **Los datos de países invitan a comparar sin contexto**: conviene recordar que un indicador nacional esconde diferencias internas muy grandes.
- Para mapas con datos actualizados, el widget *Socioeconomic Indices* (add-on *World Happiness*, usado en la Actividad 5.1) descarga indicadores del Banco Mundial.

En la carpeta	`hdi` ← `HDI.tab` (datasets.biolab.si)
En la carpeta	`hdi_edu` ← `hdi-edu.tab` (datasets.biolab.si)
Traducción, no se copia	`hdi-slo.tab` (datasets.biolab.si)

6.04

No supervisado: clustering, exploración y datos geográficos

Clima mensual por continentes

`06_exploracion_clustering_geo/weather_world/`

Temperatura y precipitación medias de cada mes en unas 470 ciudades de Europa, África, Asia y América, en seis tablas: agrupamiento de climas, climogramas y mapas, con unidades que no son iguales en todas las tablas.

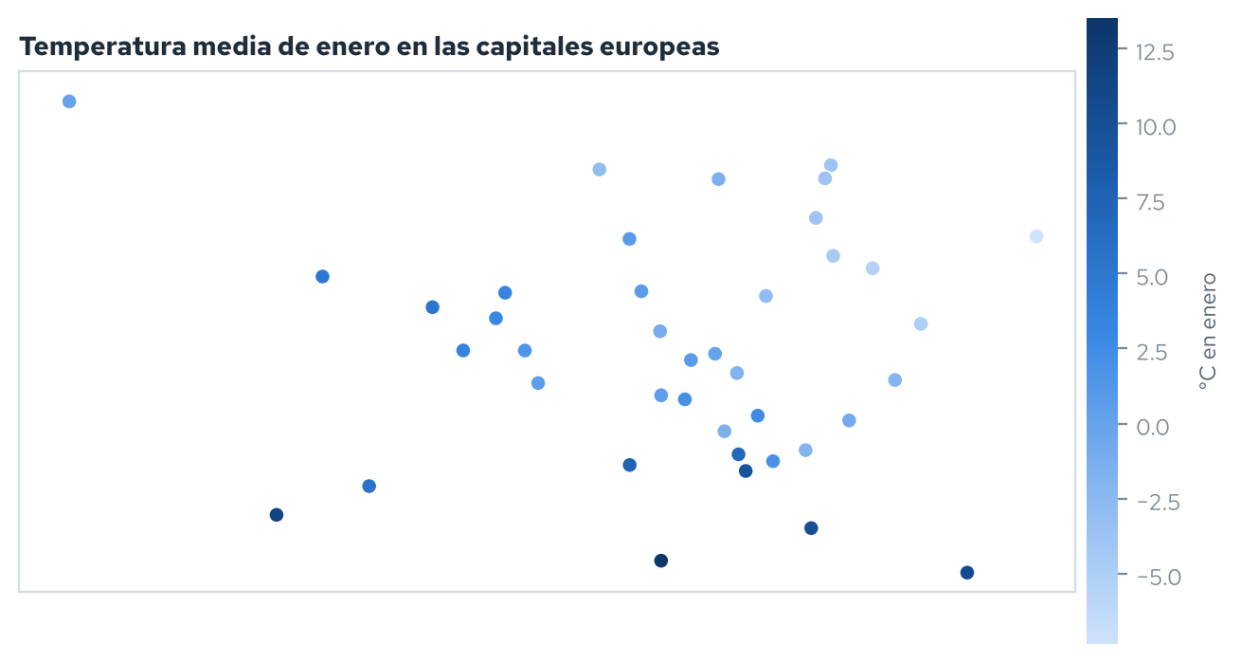
Clustering | Exploración y visualización | Espacial | ? Valores faltantes | Juguete

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
40	**28**	–	**0,1 %**	**Iniciación**	**Geo**

Fichero	Filas × col.	Descargar
`weather_europe_capitals`	40 × 28	CSV 6 KB · XLSX
`weather_africa`	121 × 28	CSV 16 KB · XLSX
`weather_asia`	132 × 28	CSV 18 KB · XLSX
`weather_asia_selected`	36 × 28	CSV 5 KB · XLSX
`weather_north_america`	100 × 28	CSV 23 KB · XLSX
`weather_south_america`	45 × 28	CSV 10 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/weather_world/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Seis tablas con el clima medio de ciudades de distintos continentes. Cada fila es una ciudad con sus coordenadas, su altitud y 24 valores: la **temperatura media** (`T-Jan` … `T-Dec`) y la **precipitación** (`P-Jan` … `P-Dec`) de cada mes.

- `weather_europe_capitals` : 40 capitales europeas.
- `weather_africa` : 121 ciudades africanas.
- `weather_asia` : 132 ciudades asiáticas (traducida del original alemán).
- `weather_asia_selected` : 36 ciudades asiáticas seleccionadas, con precipitación en milímetros.
- `weather_north_america` : 100 ciudades de Norteamérica, Centroamérica y el Caribe.
- `weather_south_america` : 45 ciudades sudamericanas.

Los estudios habituales son:

- **Agrupamiento**: ¿qué ciudades tienen un clima parecido? ¿Coinciden los grupos con las zonas climáticas?
- **Climogramas** (temperatura y lluvia por mes) y **mapas** (add-on *Geo*).
- **Normalización**: las temperaturas y las precipitaciones tienen escalas muy distintas.

2 Contexto y fuente original

Son materiales del proyecto **Pumice** del equipo de Orange (Universidad de Liubliana), que prepara actividades de ciencia de datos para escuelas (en Eslovenia, el estudio del clima con climogramas forma parte de la geografía escolar). Hay versiones en esloveno, alemán y francés; en este libro se incluyen las inglesas, y la de Asia, que solo existía en alemán, se ha traducido (nombres de columnas y de ciudades). Las fichas de Orange no dicen de dónde se tomaron los valores.

- Temperature and Precipitation in European Capitals en el repositorio de datasets de Orange

3 Variable objetivo

No tiene variable objetivo: es un dataset para agrupar y explorar. Con las temperaturas de los 12 meses, el agrupamiento separa bien los climas: mediterráneo, oceánico, continental, tropical, desértico… En Europa, por ejemplo, las capitales del sur (Atenas, Valeta, Nicosia) quedan lejos de las nórdicas (Reikiavik, Helsinki), con las centroeuropeas en medio.

4 Diccionario de columnas

Columnas de `weather_europe_capitals` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`City`	texto	Capital (meta). Algunos nombres van en esloveno o con erratas: `Bruselj` , `Talinn` , `Vilna` , `Bucarest` .	Amsterdam (1), Belgrade (1), Berlin (1), Bucarest (1), Budapest (1), Dublin (1) …
`Latitude`	numérica	Latitud (meta).	35,167 – 64,127
`Longitude`	numérica	Longitud (meta).	-21,902 – 37,617
`Elevation`	numérica	Altitud en metros (meta).	0,5 – 611
`T-Jan`	numérica	Temperatura media de enero (°C). Igual para cada mes hasta `T-Dec` .	-7,35 – 13,5

Columna	Tipo	Significado	Valores
`P-Jan`	numérica	Precipitación de enero (mm). Igual hasta `P-Dec`. Tirana no tiene dato de diciembre.	30 – 184,18
…		y 22 columnas más: el resto de meses con el mismo formato (y las coordenadas y la altitud, como metas).	

Columnas de `weather_africa` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`City`	texto	Ciudad (meta).	Algiers (1), Luanda (1), Porto-Novo (1), Gaborone (1), Ouagadougou (1), Bujumbura (1) …
`P-Jan`	numérica	Precipitación de enero. **No son milímetros** (máximo 28,7): por los valores, es el número medio de días de lluvia del mes.	0 – 25,6
`T-Jan`	numérica	Temperatura media de enero (°C).	6,7 – 27,8
…		y 25 columnas más: el resto de meses con el mismo formato (y las coordenadas y la altitud, como metas).	

Columnas de `weather_asia` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`City`	texto	Ciudad (meta), traducida del alemán (Bagdad → Baghdad…).	Abu Dhabi (1), Aqaba (1), Al Ain (1), Al-Muharraq (1), Aleppo (1), Almaty (1) …
`T-Jan`	numérica	Temperatura media de enero (°C). Llega a −38,3 en Yakutsk.	-38,3 – 28,3
`P-Jan`	numérica	Precipitación de enero. **Como en África, parecen días de lluvia**, no mm (Bombay: 0,2 en enero y 23,1 en julio).	0,1 – 22,6
…		y 25 columnas más: el resto de meses con el mismo formato (y las coordenadas y la altitud, como metas).	

Columnas de `weather_asia_selected` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`City`	texto	Ciudad (meta). Tiflis aparece como `Tbilsi`.	Almaty (1), Ankara (1), Bandar Abbas (1), Bangar (1), Basra (1), Biratnagar (1) …
`T-Jan`	numérica	Temperatura media de enero (°C).	-22,8 – 27,2
`P-Jan`	numérica	Precipitación de enero (mm).	0 – 226,1

Columna	Tipo	Significado	Valores
…		y 25 columnas más: el resto de meses con el mismo formato (y las coordenadas y la altitud, como metas).	

Columnas de `weather_north_america` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`City`	texto	Ciudad (meta).	Saint John's (1), Nassau (1), Bridgetown (1), Havana (1), Roseau (1), Santo Domingo (1) …
`T-Jan`	numérica	Temperatura media de enero (°C, convertida de grados Fahrenheit: por eso tiene dos decimales).	-21,11 – 28,33
`P-Jan`	numérica	Precipitación de enero (mm, convertida de pulgadas).	0 – 195,58
…		y 25 columnas más: el resto de meses con el mismo formato (y las coordenadas y la altitud, como metas).	

Columnas de `weather_south_america` (valores observados en el fichero)

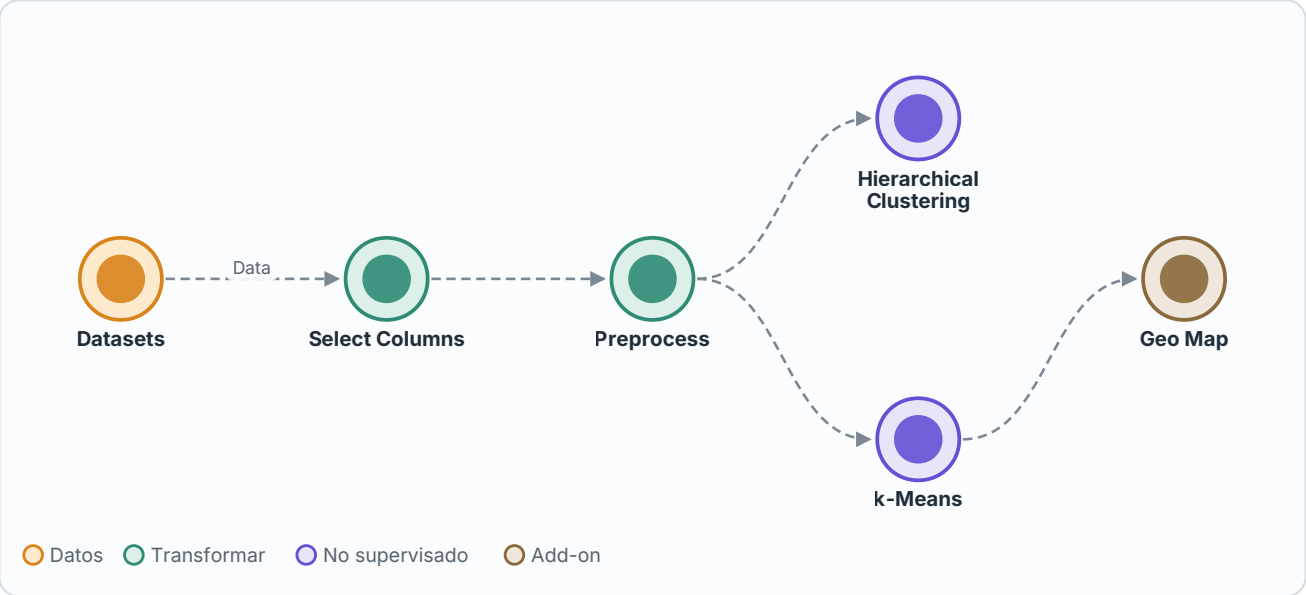
Columna	Tipo	Significado	Valores
`City`	texto	Ciudad (meta).	Buenos Aires (1), Santiago (1), Georgetown (1), Bogota (1), Asuncion (1), Lima (1) …
`T-Jan`	numérica	Temperatura media de enero (°C).	9,4 – 27,8
`P-Jan`	numérica	Precipitación de enero (mm). Buenos Aires, junio y julio, corregidos (ver particularidades).	0 – 287,02
…		y 25 columnas más: el resto de meses con el mismo formato (y las coordenadas y la altitud, como metas).	

5 Particularidades técnicas al modelar

- **La precipitación no siempre está en milímetros**: en Europa, Asia seleccionada y América son mm al mes; en **África y Asia** (la tabla completa) los valores no pasan de 28,7 y siguen el patrón de los días de lluvia (Bombay: 0,2 en enero y 23,1 en julio, cuando allí caen unos 800 mm). No se pueden juntar tablas sin tenerlo en cuenta.
- **Errata corregida en Buenos Aires**: en el fichero de Orange, la precipitación de junio y julio era de 1.355 y 1.290 mm; son 2,1 y 2,0 pulgadas convertidas a milímetros dos veces. En este CSV se han corregido a 53,3 y 50,8 mm.
- **Escalas distintas**: temperaturas de −38 a 39 °C y precipitaciones de 0 a 600 mm. Sin normalizar, las distancias dependen casi solo de la lluvia.

- **Tablas con distintas columnas en distinto orden**: unas empiezan por la temperatura y otras por la precipitación; en `weather_asia_selected` la longitud va antes que la latitud. Para unirlas con **Concatenate**, Orange empareja por nombre, así que funciona.
- **Hemisferio sur**: en Sudamérica y el sur de África, julio es invierno. Agrupar por los valores de cada mes junta climas parecidos con las estaciones invertidas en grupos distintos.

6 Flujo de trabajo en Orange



1. **Datasets** → «Temperature and Precipitation in European Capitals» (o **File** con el CSV).
2. **Select Columns**: empieza solo con las temperaturas.
3. **Distances** → **Hierarchical Clustering** (o **k-Means** con k = 3–5).
4. **Geo Map** (add-on *Geo*) coloreado por grupo: los climas aparecen en el mapa.
5. Añade las precipitaciones normalizadas y compara los grupos.

7 Otras consideraciones

- **Climogramas**: con **Line Plot**, cada ciudad es una línea de 12 meses; seleccionar un grupo muestra su climograma.
- **Comparar con Climate of European cities**: la otra tabla de clima del capítulo trae la clasificación de Köppen, útil para comprobar si los grupos tienen sentido.

En la carpeta	`weather_europe_capitals` ← `weather-capitals.xlsx` (datasets.biolab.si)
En la carpeta	`weather_africa` ← `weather-africa.xlsx` (datasets.biolab.si)
En la carpeta	`weather_asia` ← `wetter-asien.xlsx` (datasets.biolab.si)
En la carpeta	`weather_asia_selected` ← `climate-asia.xlsx` (datasets.biolab.si)
En la carpeta	`weather_north_america` ← `weather-north-america.xlsx` (datasets.biolab.si)
En la carpeta	`weather_south_america` ← `weather-south-america.xlsx` (datasets.biolab.si)
Traducción, no se copia	`vreme-prestolnice.xlsx` (datasets.biolab.si)
Traducción, no se copia	`wetter-hauptstädten.xlsx` (datasets.biolab.si)
Traducción, no se copia	`météo-capitals.xlsx` (datasets.biolab.si)

Traducción, no se copia	`podnebje-afrika.xlsx` (datasets.biolab.si)
Traducción, no se copia	`wetter-afrika.xlsx` (datasets.biolab.si)
Traducción, no se copia	`météo-afrique.xlsx` (datasets.biolab.si)
Traducción, no se copia	`podnebje-azija.xlsx` (datasets.biolab.si)
Traducción, no se copia	`météo-asie.xlsx` (datasets.biolab.si)
Traducción, no se copia	`podnebje-azija-klimogrami.xlsx` (datasets.biolab.si)
Traducción, no se copia	`podnebje-severna-amerika.xlsx` (datasets.biolab.si)
Traducción, no se copia	`wetter-nordamerika.xlsx` (datasets.biolab.si)
Traducción, no se copia	`météo-amérique-du-nord.xlsx` (datasets.biolab.si)
Traducción, no se copia	`podnebje-juzna-amerika.xlsx` (datasets.biolab.si)
Traducción, no se copia	`wetter-sudamerika.xlsx` (datasets.biolab.si)
Traducción, no se copia	`météo-amérique-du-sud.xlsx` (datasets.biolab.si)

6.05
No supervisado: clustering, exploración y datos geográficos

Climate of European cities (Köppen)

`06_exploracion_clustering_geo/climate_europe/`

41 capitales europeas con 11 características de su clima anual y su clasificación de Köppen: agrupamiento comprobable (¿salen los climas?) y clasificación multiclase con muy pocos casos, con algunas etiquetas incoherentes.

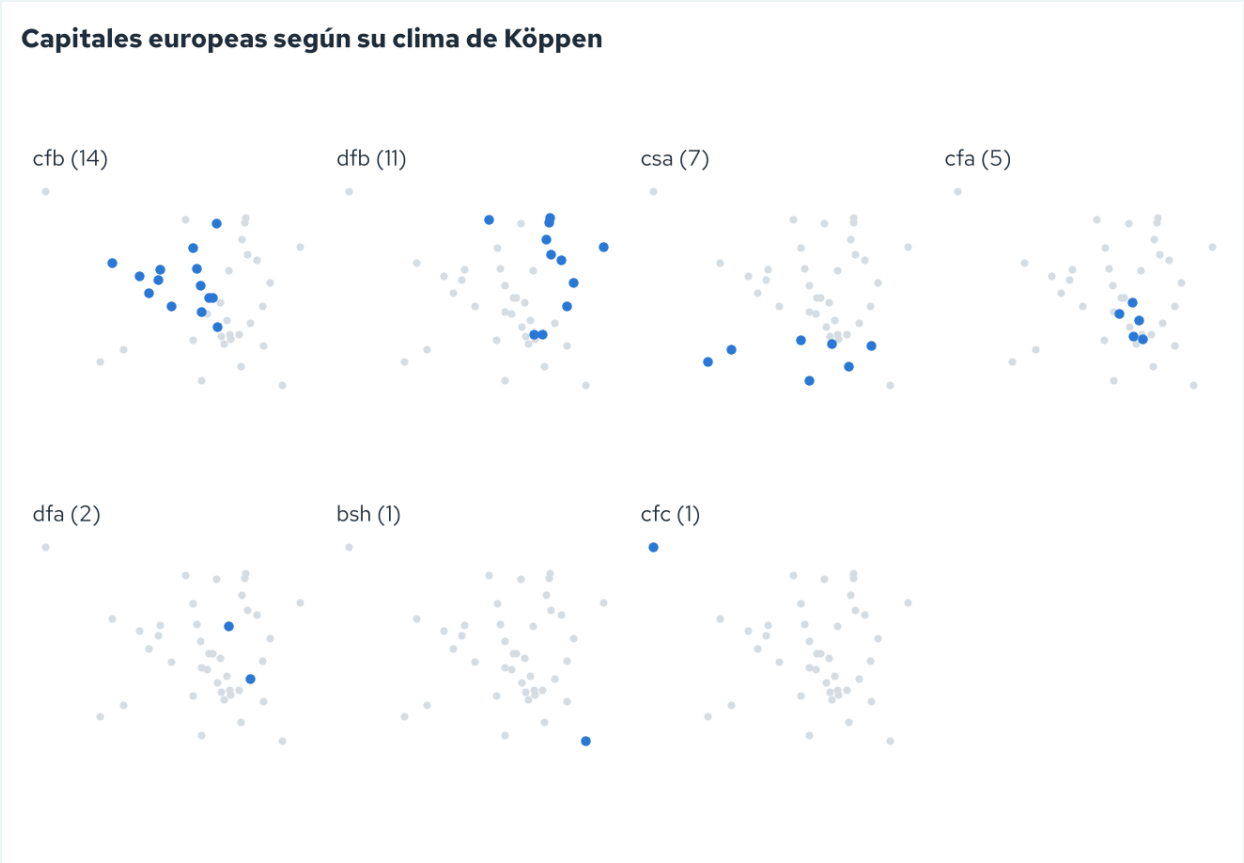
Clustering | Clasificación multiclase | Espacial | ? Valores faltantes | Juguete

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
41	**16**	`Climate (Koppen)`	**3,7 %**	**Iniciación**	**Geo**

Fichero	Filas × col.	Descargar
`climate_europe`	41 × 16	CSV 4 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/climate_europe/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Cada fila es una capital europea (más Estambul) con valores anuales de su clima: temperaturas récord, medias máximas, medias y mínimas, precipitación total, días de lluvia y de nieve, humedad relativa, horas de sol e índice ultravioleta medio. Además trae sus coordenadas y su **clima** según la clasificación de **Köppen**, como código (`cfb` , `csa` ...) y como nombre (oceánico, mediterráneo...).

Los estudios habituales son:

- **Agrupamiento con comprobación**: agrupar por las variables climáticas y ver si los grupos coinciden con Köppen.
- **Clasificación multiclase** del tipo de clima.
- **Mapas** con el add-on *Geo*.

2 Contexto y fuente original

Lo preparó el equipo de **Orange** (Biolab, Universidad de Liubliana), según su ficha en 2015, con datos climáticos de ciudades europeas; no se indica de dónde se tomaron. Existe una versión en esloveno (`podnebje.tab`).

- Climate of European cities en el repositorio de datasets de Orange

3 Variable objetivo

En Orange, las dos columnas de clima son **metas**; se pueden usar como objetivo o solo para comprobar grupos.

- `Climate (Koppen)` , con 7 códigos: `cfb` oceánico (14 ciudades), `dfb` continental húmedo (11), `csa` mediterráneo (7), `cfa` subtropical húmedo (5), `dfa` continental húmedo cálido (2), `bsh` semiárido cálido (1, Nicosia) y `cfc` subpolar oceánico (1, Reikiavik).
- `Climate` , el nombre del clima, con 8 valores.

Las temperaturas y las horas de sol separan bien el sur mediterráneo del resto; distinguir oceánico de continental depende de las temperaturas mínimas y de la nieve.

4 Diccionario de columnas

Columnas de `climate_europe` (valores observados en el fichero)

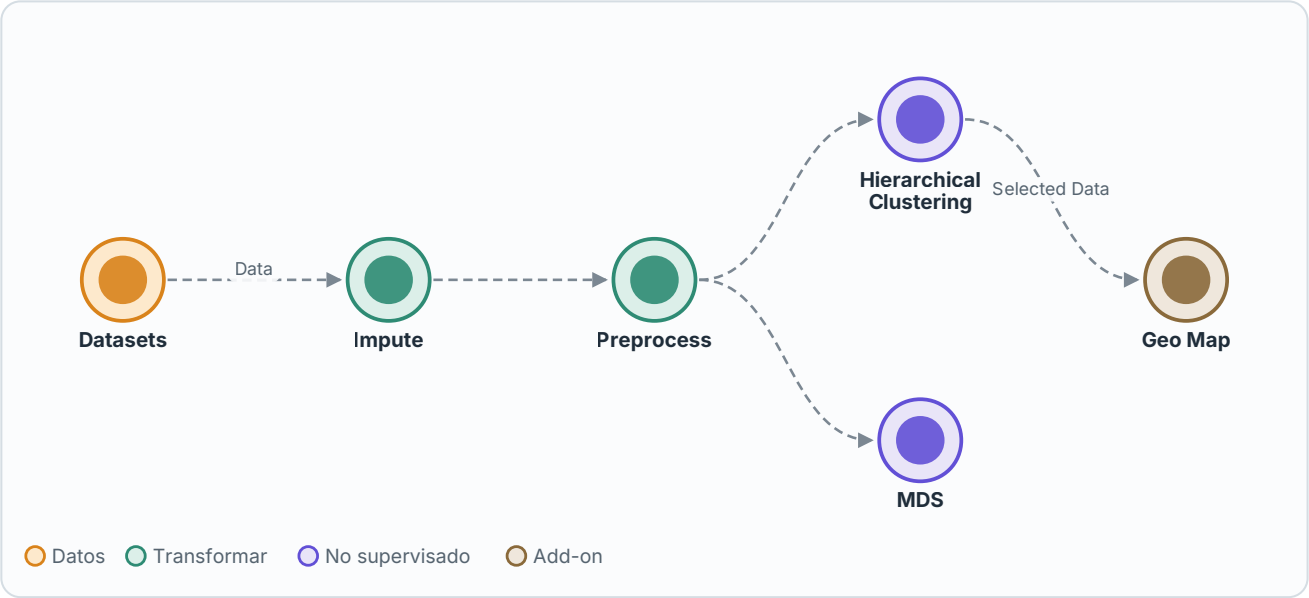
Columna	Tipo	Significado	Valores
`City`	texto	Ciudad (meta).	Amsterdam (1), Athens (1), Belgrade (1), Berlin (1), Bern (1), Bratislava (1) ...
`Climate (Koppen)`	categórica	Código de Köppen (meta): la primera letra es el grupo (`b` seco, `c` templado, `d` continental), la segunda el régimen de lluvias (`f` sin estación seca, `s` verano seco) y la tercera el verano (`a` caluroso, `b` templado, `c` fresco, `h` cálido y seco).	cfb (14), dfb (11), csa (7), cfa (5), dfa (2), bsh (1) ...

Columna	Tipo	Significado	Valores
`Climate`	categórica	Nombre del clima (meta). **Reikiavik aparece en esloveno** (`subpolarno oceansko`).	oceanic (14), humid continental (10), mediterranean (7), humid subtropical (5), hot humid continental (2), hot semi-dry (1) …
`Latitude`	numérica	Latitud (meta).	35,186 – 64,147
`Longitude`	numérica	Longitud (meta).	-21,94 – 37,617
`Record high °C`	numérica	Temperatura máxima récord (°C).	25,7 – 44,8
`Average high °C`	numérica	Media de las máximas (°C).	7,9 – 26,2
`Daily average °C`	numérica	Temperatura media (°C).	5,1 – 19,7
`Average low °C`	numérica	Media de las mínimas (°C).	2,3 – 15,5
`Record low °C`	numérica	Temperatura mínima récord (°C). Moscú, −42,1.	-42,1 – 1,4
`Average precipitation mm`	numérica	Precipitación total del año (mm).	342,2 – 1.659,3
`Number of rainy days`	numérica	Días de lluvia al año. 5 vacíos; Atenas tiene 8,5 (ver particularidades).	8,5 – 189,9
`Number of snowy days`	numérica	Días de nieve al año. 3 vacíos.	0 – 116
`Average relative humidity (%)`	numérica	Humedad relativa media (%). 9 vacíos.	57 – 83
`Average monthly hours of sunshine`	numérica	Horas de sol. **Por los valores (1.326–3.314), es el total del año**, no la media mensual que dice el nombre.	1.326 – 3.314,1
`Average ultraviolet index`	numérica	Índice ultravioleta medio (2–5). 7 vacíos.	2 – 5

5 Particularidades técnicas al modelar

- **Etiquetas incoherentes**: Kiev tiene código `dfb` (continental) pero nombre `oceanic`; Estocolmo, `cfb` con nombre `temperate oceanic` en lugar de `oceanic`; Reikiavik tiene el nombre en esloveno. Para clasificar, mejor usar el código de Köppen.
- **Nombres de columna que no cuadran con los valores**: las horas de sol son totales anuales, no mensuales; y los días de lluvia de Atenas (8,5) parecen una media mensual, cuando el resto son totales anuales (110–190).
- **Clases con 1 o 2 ciudades**: `bsh`, `cfc` y `dfa`. Una validación cruzada estratificada no funciona; para clasificar conviene agrupar en 3–4 climas.
- **Valores ausentes** en días de lluvia, de nieve, humedad e índice UV (24 celdas). Imputar con 41 ciudades es delicado.
- **Variables muy relacionadas**: las cinco temperaturas se mueven juntas. Conviene normalizar y quizá quedarse con dos o tres.

6 Flujo de trabajo en Orange



1. **Datasets** → «Climate of European cities».
2. **Impute** (media) y **Preprocess** → *Normalize*.
3. **Distances** → **Hierarchical Clustering**; etiqueta las hojas con `City` y colorea por `Climate (Koppen)`.
4. **MDS** coloreado por Köppen: los mediterráneos quedan juntos.
5. Selecciona un grupo y míralo en **Geo Map**.

7 Otras consideraciones

- **Clasificación**: con **Select Columns**, pon `Climate (Koppen)` como objetivo y prueba un árbol con validación *leave one out*.
- **Comparar con Weather**: la otra tabla de clima del capítulo tiene valores de cada mes en lugar de anuales.

En la carpeta	`climate_europe` ← `climate-europe.tab` (datasets.biolab.si)
Traducción, no se copia	`podnebje.tab` (datasets.biolab.si)

6.06

No supervisado: clustering, exploración y datos geográficos

Frecuencias de letras por idioma

`06_exploracion_clustering_geo/letter_frequencies/`

Frecuencia de cada letra (a–z) en 167 idiomas calculada con la Wikipedia, y en 35 libros de ocho idiomas: los idiomas parecidos se agrupan solos, y Harry Potter se agrupa con su idioma, no con su argumento.

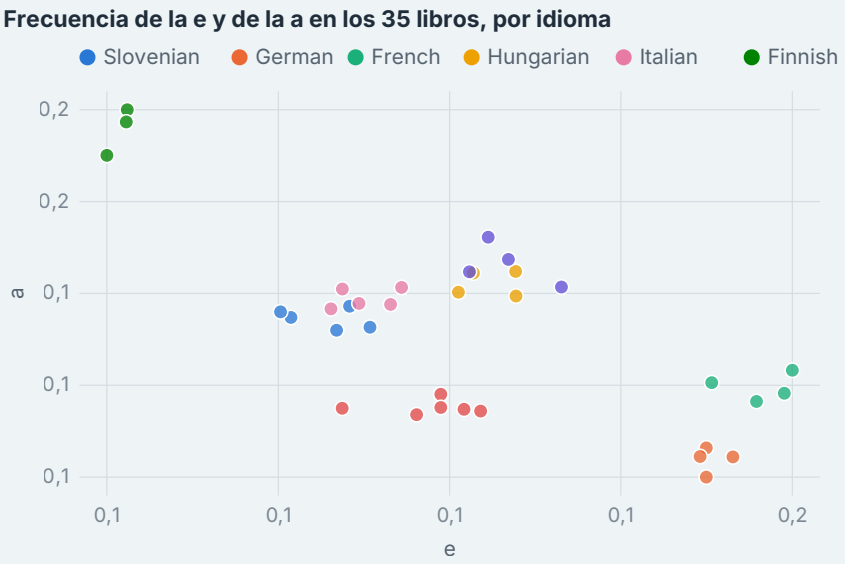
Clustering | Exploración y visualización | ? Valores faltantes | ¶ Texto

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
167	**30**	–	**0,2 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`letter_frequencies`	167 × 30	CSV 54 KB · XLSX
`letter_frequencies_books`	35 × 30	CSV 13 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/letter_frequencies/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Dos tablas con la **frecuencia relativa de las 26 letras** del alfabeto latino básico (sin tildes ni diéresis):

- `letter_frequencies`: 167 idiomas que usan sobre todo el alfabeto latino, calculada con artículos de la Wikipedia de cada idioma. Incluye el nombre del idioma, su código y las regiones donde se habla.
- `letter_frequencies_books`: 35 libros en esloveno, alemán, italiano, húngaro, francés, español, inglés y finés, sobre todo literatura juvenil, más la traducción de **Harry Potter** a los ocho idiomas.

Los estudios habituales son:

- **Agrupamiento jerárquico**: ¿se juntan los idiomas de la misma familia (romances, germánicos, eslavos…)?
- **Proyecciones** (MDS, t-SNE) para ver los idiomas en un plano.
- **El idioma pesa más que el contenido**: en la tabla de libros, las traducciones de Harry Potter se agrupan con los demás libros de su idioma.

2 Contexto y fuente original

Son materiales del proyecto **Pumice** del equipo de Orange (Universidad de Liubliana), para escuelas. Las frecuencias se calcularon quitando los signos diacríticos (á → a, ü → u, č → c), de modo que todos los idiomas comparten las mismas 26 columnas. Hay versiones anteriores en esloveno (`pogostosti-crk.tab`, `books-norm.tab`).

- Letter Frequencies en el repositorio de datasets de Orange
- Letter Frequencies in Books en el repositorio de datasets de Orange

3 Variable objetivo

No tiene variable objetivo. En la tabla de idiomas, con la distancia del coseno, los vecinos más cercanos son idiomas emparentados: el español queda junto al asturiano, el mirandés y el aragonés; el esloveno, junto al bosnio, el serbocroata y el croata; el finés, junto al estonio. Algunos idiomas destacan por una letra: el hausa tiene la mayor frecuencia de `a`, el zelandés de `e`, el inupiaq de `q` y el somalí de `x`. En la tabla de libros, el vecino más cercano de cada uno de los 35 libros es otro libro del mismo idioma, también en las ocho traducciones de Harry Potter.

4 Diccionario de columnas

Columnas de `letter_frequencies` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Language`	texto	Idioma (meta). Hay un nombre mal codificado: `VÃµro` (debería ser *Võro*).	Acehnese (1), Afrikaans (1), Akan (1), Albanian (1), Alemannic (1), Aragonese (1) …
`koda`	texto	Código del idioma en la Wikipedia (meta; *koda* es «código» en esloveno).	ace (1), af (1), ak (1), sq (1), als (1), an (1) …
`Regions`	texto	Países o regiones donde se habla (meta). 12 vacíos.	Italy (8), Germany (7), Philippines (6), Indonesia (6), world (6), South Africa (6) …
`Language and Regions`	texto	Idioma y regiones juntos (meta), útil como etiqueta.	Acehnese (Indonesia) (1), Afrikaans (Namibia, South Africa) (1), Akan (Ghana) (1), Albanian (Albania, Kosovo, North Macedonia) (1), Alemannic (1), Aragonese (Spain) (1) …
`a`	numérica	Frecuencia relativa de la letra `a` (de 0 a 1). Igual para cada letra hasta `z`; cada fila suma 1.	0,054 – 0,269

Columna	Tipo	Significado	Valores
…		y 25 columnas más: una por letra, hasta la z.	

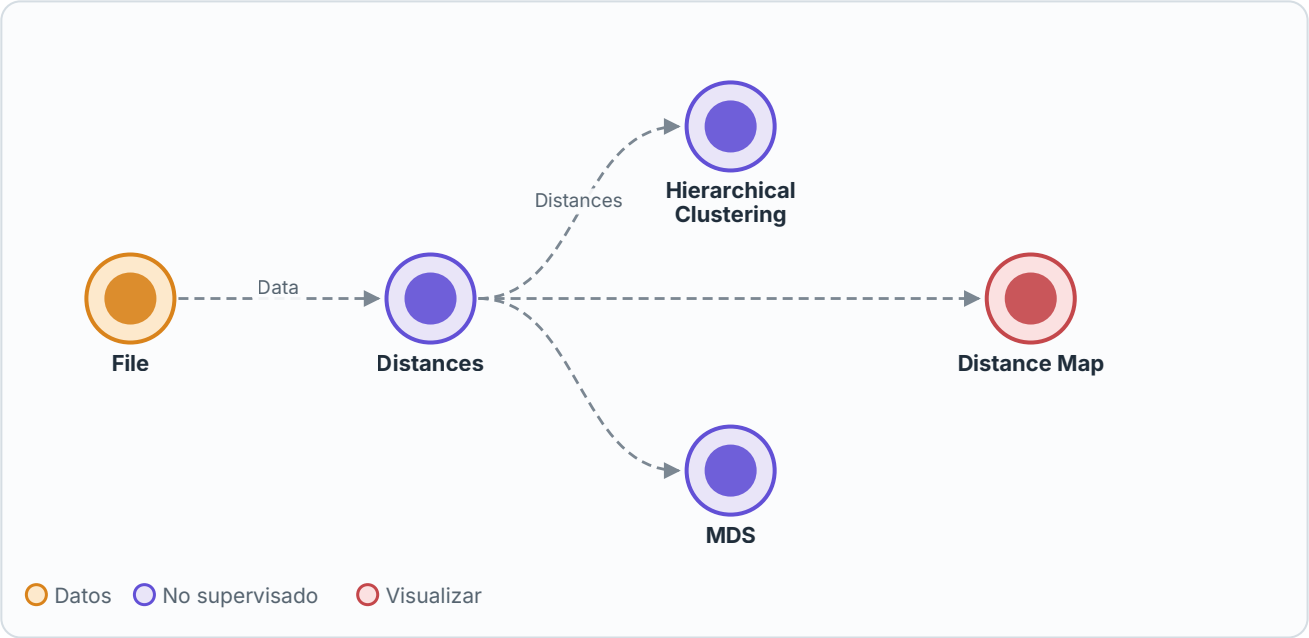
Columnas de `letter_frequencies_books` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Title`	texto	Título en inglés (meta).	Harry Potter (8), Martin Krpan (1), The Tenth Brother (1), The Men of Butale (1), Grimms' Fairy Tales (1), Heidi (1) …
`Original title`	texto	Título original (meta).	Harry Potter (8), Martin Krpan (1), Deseti brat (1), Butalci (1), Kinder- und Hausmärchen. (1), Heidi (1) …
`Author`	texto	Autor (meta).	Joanne K. Rowling (8), Fran Levstik (1), Josip Jurčič (1), Fran Milčiinski (1), Jacob Grimm, Wilhelm Grimm (1), Johanna Spyr (1) …
`Language`	categórica	Idioma del libro (meta).	English (6), Slovenian (5), Italian (5), German (4), Hungarian (4), French (4) …
a	numérica	Frecuencia relativa de la letra `a`. Igual hasta `z`; cada fila suma 1.	0,059 – 0,181
…		y 25 columnas más: una por letra, hasta la z.	

5 Particularidades técnicas al modelar

- **Cada fila suma 1**: son proporciones (datos composicionales). Si una letra sube, otras bajan. La distancia del coseno o la correlación funcionan mejor que la euclídea.
- **Sin diacríticos**: al quitar tildes y diéresis se pierde mucha información que distingue idiomas (ñ, ç, ő, č…); por eso algunos idiomas cercanos se confunden.
- **Letras casi ausentes**: `q`, `x`, `w` o `y` valen casi 0 en muchos idiomas pero son muy altas en otros. Son las que más separan.
- **La Wikipedia no es el idioma hablado**: los artículos tienen muchos nombres propios y términos técnicos, y en las Wikipedias pequeñas pocos artículos.
- **Libros desiguales**: inglés tiene 6 libros, finés 3. Harry Potter aparece 8 veces con el mismo título.
- **Errata de codificación** en `Language` (`VÃµro`).

6 Flujo de trabajo en Orange



1. **Datasets** → «Letter Frequencies» (o **File** con el CSV).
2. **Distances** con la distancia del coseno.
3. **Hierarchical Clustering** con las hojas etiquetadas por `Language`: busca las familias de idiomas.
4. **MDS**: los idiomas en un plano; selecciona un grupo y míralo en **Data Table**.
5. Repite con «Letter Frequencies in Books», coloreando por `Language`: Harry Potter se queda con su idioma.

7 Otras consideraciones

- **Detectar el idioma de un texto**: con el add-on *Text* se pueden calcular las frecuencias de un texto nuevo y buscar el idioma más cercano con *Neighbors*.
- **Clasificación**: en la tabla de libros, `Language` puede ser el objetivo de un kNN con validación *leave one out*.

En la carpeta	`letter_frequencies` ← `letter-frequencies.csv` (datasets.biolab.si)
En la carpeta	`letter_frequencies_books` ← `letter-frequencies-books.csv` (datasets.biolab.si)
Traducción, no se copia	`pogostosti-crk.tab` (datasets.biolab.si)
Traducción, no se copia	`books-norm.tab` (datasets.biolab.si)

6.07
No supervisado: clustering, exploración y datos geográficos

Machine learning conferences

`06_exploracion_clustering_geo/conferences/`

42 congresos y revistas de inteligencia artificial y aprendizaje automático con su número (medio) de autores y de artículos: un dataset mínimo para visualizar y agrupar con solo dos variables.

Exploración y visualización · Clustering · ◦ Juguete · ◈ Mixto num. + cat.

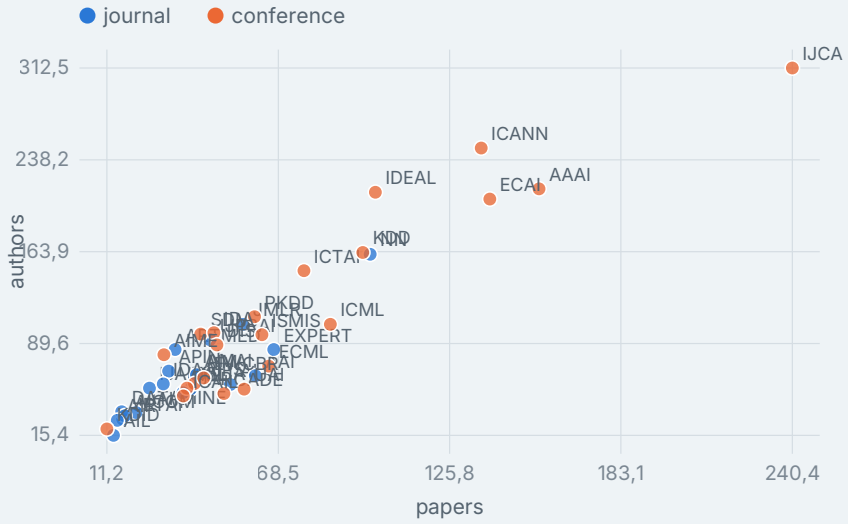
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
42	**5**	–	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`conferences`	42 × 5	CSV 2 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/conferences/` seguido del nombre del fichero CSV.

Radiografía

Artículos y autores de cada congreso o revista



1 Descripción general y estudios habituales

Cada fila es un congreso o una revista científica de inteligencia artificial (IJCAI, AAAI, ICML, ECAI, *Machine Learning*, JAIR…) con dos números: **autores** y **artículos**, y si es un congreso o una revista. Los valores tienen decimales, así que parecen medias (por ejemplo, por edición o por año), aunque la ficha de Orange no lo explica.

Los estudios habituales son:

- **Visualización** de dos variables y sus etiquetas.
- **Agrupamiento** y detección de casos atípicos.

- **Clasificación** sencilla: ¿se distingue un congreso de una revista por su tamaño?

2 Contexto y fuente original

Está en el repositorio de datasets de **Orange** con una descripción mínima («publicaciones de aprendizaje automático con número de autores y de artículos»), sin autor, fecha ni fuente. Incluye revistas y congresos generales de IA (IJCAI, AAAI, ECAI) y específicos de aprendizaje automático y minería de datos (ICML, ECML, KDD, PKDD, JMLR).

- Conferences en el repositorio de datasets de Orange

3 Variable objetivo

No tiene variable objetivo marcada, aunque `type` (22 congresos y 20 revistas) puede hacer de clase. Los congresos son más grandes: 118 autores y 76 artículos de media, frente a 61 y 38 en las revistas. IJCAI es el más grande (312 autores y 240 artículos). La relación autores/artículos está entre 0,9 y 2,7.

4 Diccionario de columnas

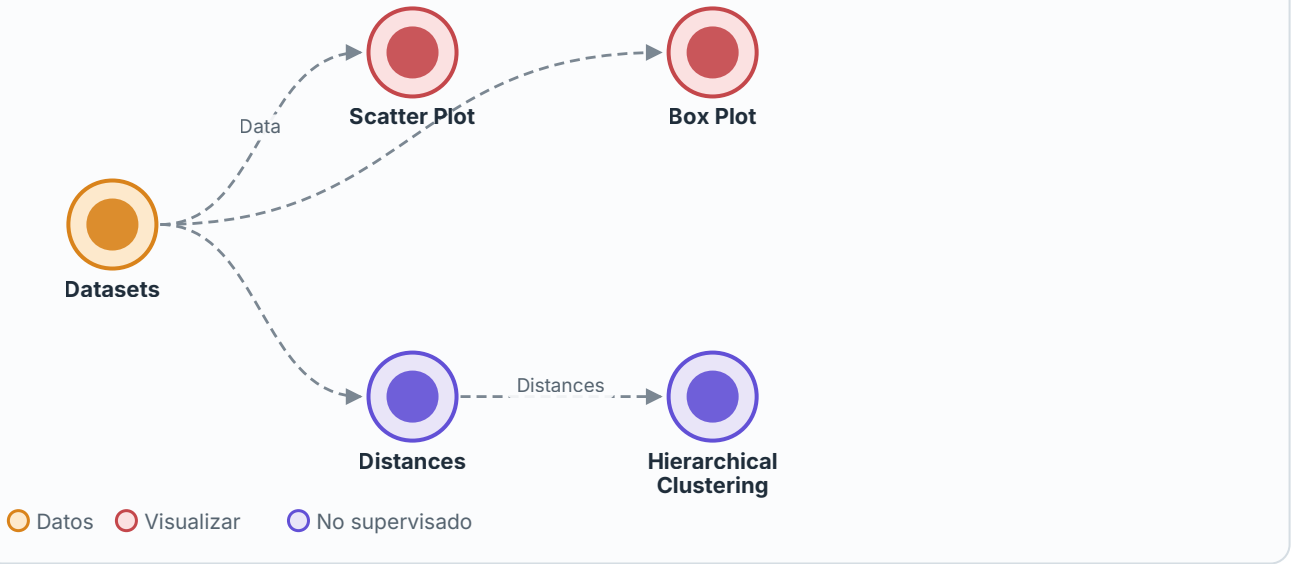
Columnas de `conferences` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`abbrev`	texto	Abreviatura (meta): `IJCAI`, `AAAI`, `ICML`, `JAIR`… La revista *Intelligent Data Analysis* es `IDA-J`.	JETAI (1), AAAI (1), IJCAI (1), AI (1), AIM (1), AIPS (1) …
`name`	texto	Nombre (meta). *Intelligent Data Analysis* aparece dos veces: congreso y revista.	Intelligent Data Analysis (2), Nat. Conf. on AI (1), Intl. Joint Conf on AI (1), Artificial Intelligence (1), AI Magazine (1), AI in Planning Systems (1) …
`authors`	numérica	Número de autores (con decimales: probablemente una media).	15,357 – 312,474
`papers`	numérica	Número de artículos (con decimales: probablemente una media).	11,25 – 240,368
`type`	categórica	`conference` (congreso) o `journal` (revista).	conference (22), journal (20)

5 Particularidades técnicas al modelar

- **Descripción incompleta**: no se sabe si las cifras son medias por año, por edición o de qué periodo. Conviene decirlo al usarlo en clase.
- **Dos variables muy relacionadas**: autores y artículos crecen juntos; en un gráfico, casi forman una línea, y los puntos que se salen de ella son lo interesante.
- **Escala asimétrica**: unos pocos congresos grandes (IJCAI, ICANN, AAAI) dominan; el logaritmo ayuda a ver los pequeños.
- **Nombre repetido**: `name` no es único; usa `abbrev` como etiqueta.
- No hay valores ausentes.

6 Flujo de trabajo en Orange



1. **Datasets** → «Conferences».
2. **Scatter Plot** de `papers` frente a `authors`, coloreado por `type` y etiquetado por `abbrev`.
3. **Box Plot** de `authors` por `type`.
4. **Distances** → **Hierarchical Clustering**: ¿qué congresos y revistas se parecen?

7 Otras consideraciones

- **Variable nueva**: autores por artículo (`authors / papers`) con *Feature Constructor*; separa mejor el tipo de publicación que el tamaño.
- **Ejercicio de crítica de datos**: buen ejemplo para preguntar a los alumnos qué falta en la documentación.

En la carpeta `conferences` ← `conferences.tab` (datasets.biolab.si)

6.08

No supervisado: clustering, exploración y datos geográficos

Food nutrition info

`06_exploracion_clustering_geo/food_nutrition/`

Información nutricional de 61 alimentos frescos (frutas, verduras y pescados y mariscos) según las etiquetas de la FDA: agrupamiento que reencuentra los tres tipos y clasificación pequeña, con unidades mal puestas en los nombres.

Clustering · Clasificación multiclase · ◦ Juguete

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
61	**25**	`food_type`	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`food_nutrition_info`	61 × 25	CSV 6 KB · XLSX

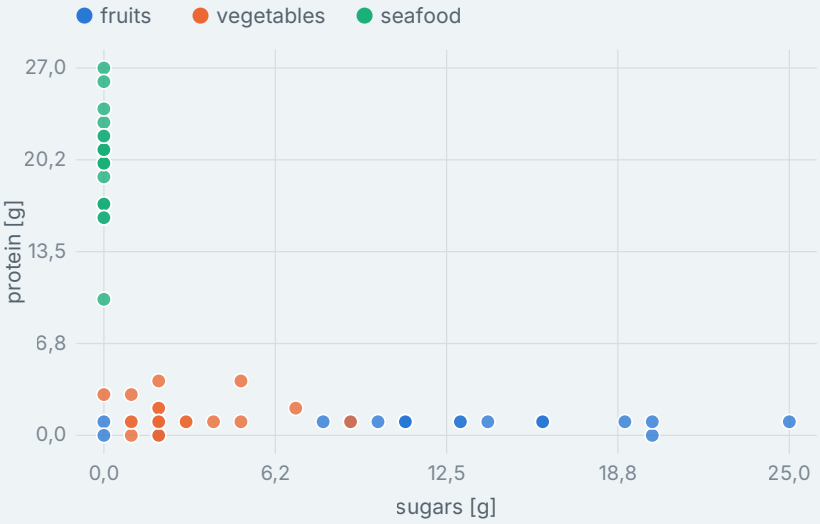
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/food_nutrition/` seguido del nombre del fichero CSV.

Radiografía

food_type en food_nutrition_info



Azúcares y proteínas (g por ración) según el tipo de alimento



1 Descripción general y estudios habituales

Cada fila es un alimento fresco, por ración, con los datos de su etiqueta nutricional: calorías, calorías procedentes de la grasa, grasa total y saturada, colesterol, sodio, potasio, hidratos de carbono, fibra, azúcares, proteínas y el porcentaje de la cantidad diaria recomendada de vitamina A, vitamina C, calcio y hierro. La clase es el **tipo de alimento**: fruta, verdura o pescado y marisco.

Los estudios habituales son:

- **Agrupamiento**: ¿se forman los tres tipos sin decírselo al algoritmo?
- **Clasificación** multiclase con muy pocos casos.
- **Visualización** de perfiles nutricionales (proyecciones, mapas de calor).

2 Contexto y fuente original

Los datos proceden de **data.world**, donde los publicó **Adam Helsinger**, y se basan en las etiquetas nutricionales de la FDA de Estados Unidos para frutas, verduras y pescados crudos. El equipo de **Orange** los adaptó: cuando un nutriente venía en masa y en porcentaje de la cantidad diaria, dejó la masa como atributo y pasó el porcentaje a meta.

- Food Nutrition Information en data.world (Adam Helsinger)

3 Variable objetivo

La clase es `food_type`: `seafood` (21), `fruits` (20) y `vegetables` (20).

Los pescados se separan solos: tienen proteínas (20 g de media frente a 1–1,5 g), colesterol y nada de azúcar ni de vitamina C. Frutas y verduras se parecen más; las frutas tienen más calorías y azúcar (12 g frente a 3 g).

4 Diccionario de columnas

Columnas de `food_nutrition_info` (valores observados en el fichero)

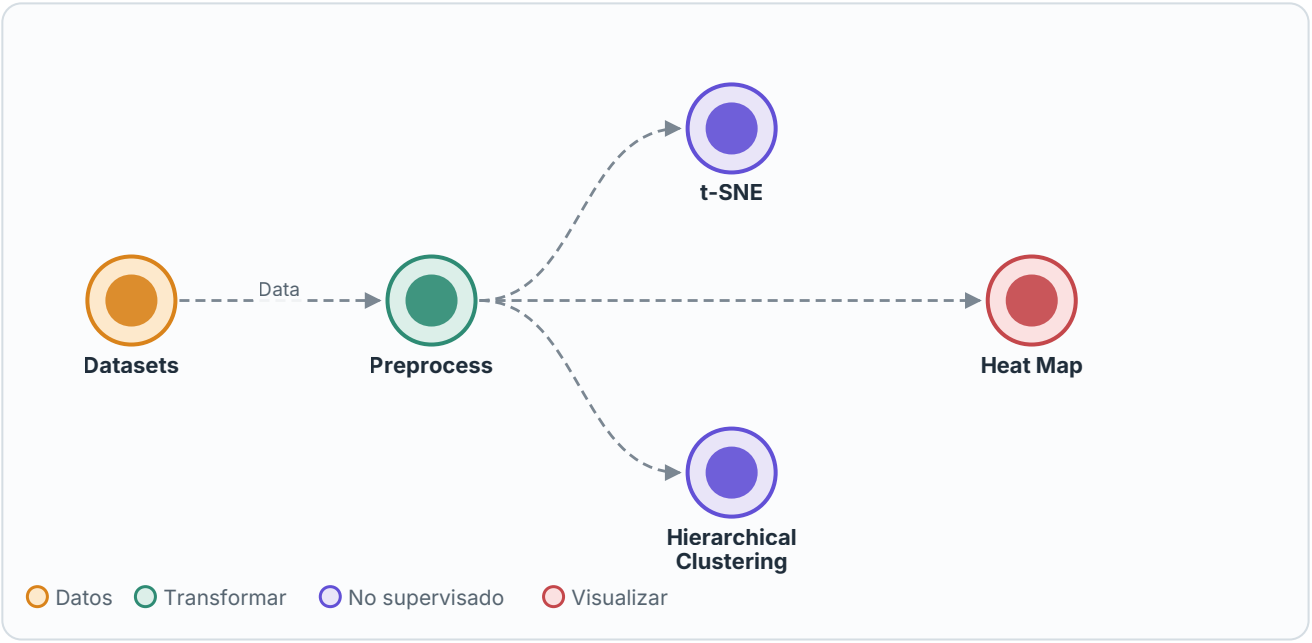
Columna	Tipo	Significado	Valores
`food_type` objetivo	categórica	**Clase**: `fruits`, `vegetables` o `seafood`.	seafood (21), vegetables (20), fruits (20)
`food`	texto	Nombre del alimento (meta).	Asparagus (1), Bell Pepper (1), Broccoli (1), Carrot (1), Cauliflower (1), Celery (1) …
`serving size`	texto	Tamaño de la ración (meta), en texto (`84 g/3 oz`, `1 medium (148 g/5.3 oz)`…).	84 g/3 oz (21), 1 medium (148 g/5.3 oz) (4), 1 medium stalk (148 g/5.3 oz) (1), 1 carrot, 7" long, 1 1/4" diameter (78 g/2.8 oz) (1), 1/6 medium head (99 g/3.5 oz) (1), 5 spears (93 g/3.3 oz) (1) …
`total fat dv`	numérica	Grasa total, % de la cantidad diaria (meta). Igual que las demás columnas `dv` meta.	0 – 15
`calories`	numérica	Calorías por ración.	10 – 200
`calories from fat`	numérica	Calorías que proceden de la grasa.	0 – 90
`total fat [g]`	numérica	Grasa total (g).	0 – 10
`sodium [g]`	numérica	Sodio. **Los valores están en mg**, no en g (hasta 330).	0 – 330

Columna	Tipo	Significado	Valores
`potassium [g]`	numérica	Potasio. **Los valores están en mg**, no en g (70–620; plátano, 450).	70 – 620
`carbohydrate [g]`	numérica	Hidratos de carbono (g).	0 – 34
`dietary fiber [g]`	numérica	Fibra (g).	0 – 6
`sugars [g]`	numérica	Azúcares (g).	0 – 25
`protein [g]`	numérica	Proteínas (g).	0 – 27
`vitamin a dv`	numérica	Vitamina A, % de la cantidad diaria.	0 – 130
`vitamin c dv`	numérica	Vitamina C, % de la cantidad diaria (hasta 240).	0 – 240
`calcium dv`	numérica	Calcio, % de la cantidad diaria.	0 – 10
`iron dv`	numérica	Hierro, % de la cantidad diaria.	0 – 45
`saturated fat [mg]`	numérica	Grasa saturada. **El nombre dice mg** pero los valores (0–10) no cuadran ni con mg ni con g (ver particularidades).	0 – 10
`cholesterol [mg]`	numérica	Colesterol (mg). Solo en pescados y mariscos.	0 – 57
…		y 6 columnas más: los porcentajes de la cantidad diaria del resto de nutrientes (metas).	

5 Particularidades técnicas al modelar

- **Unidades equivocadas en los nombres**: el sodio y el potasio dicen `[g]` pero están en miligramos (un plátano no tiene 450 g de potasio). La grasa saturada dice `[mg]`, pero el bagre (*catfish*) tiene 10 en esa columna y solo 6 g de grasa total, así que algo no cuadra. Hay que revisar las unidades antes de interpretar.
- **Raciones distintas**: los pescados van por 84 g; las frutas y verduras, por pieza o porción habitual. Comparar por ración no es comparar por 100 g.
- **Escalas muy distintas** (de 0 a 620): normaliza antes de agrupar.
- **Muy pocos alimentos** (61) y valores redondeados como en las etiquetas (muchos ceros y valores repetidos).
- **Las metas `dv` duplican información**: si se pasan a atributos, cada nutriente cuenta dos veces.

6 Flujo de trabajo en Orange



1. **Datasets** → «Food Nutrition Information».
2. **Preprocess** → *Normalize*.
3. **t-SNE** (o **MDS**) coloreado por `food_type`: los pescados forman un grupo aparte.
4. **Hierarchical Clustering** con las hojas etiquetadas por `food`.
5. **Heat Map** agrupando por `food_type`: qué nutrientes caracterizan cada tipo.

7 Otras consideraciones

- **Clasificación**: con validación *leave one out*, un árbol acierta el 90 % y el bosque aleatorio el 92 %; los 21 pescados se aciertan siempre y todos los errores son entre frutas y verduras.
- **Ejercicio de unidades**: buen ejemplo para comprobar que los valores tienen sentido antes de modelar.

En la carpeta `food_nutrition_info` ← `food-nutrition-info.tab` (datasets.biolab.si)

6.09
No supervisado: clustering, exploración y datos geográficos

Pittsburgh Bridges

`06_exploracion_clustering_geo/bridges/`

108 puentes de Pittsburgh (1818–1986) con siete especificaciones (río, año, uso, longitud, carriles…) y cinco propiedades de diseño: un dataset pequeño de varias salidas, con huecos, pensado para predecir el diseño.

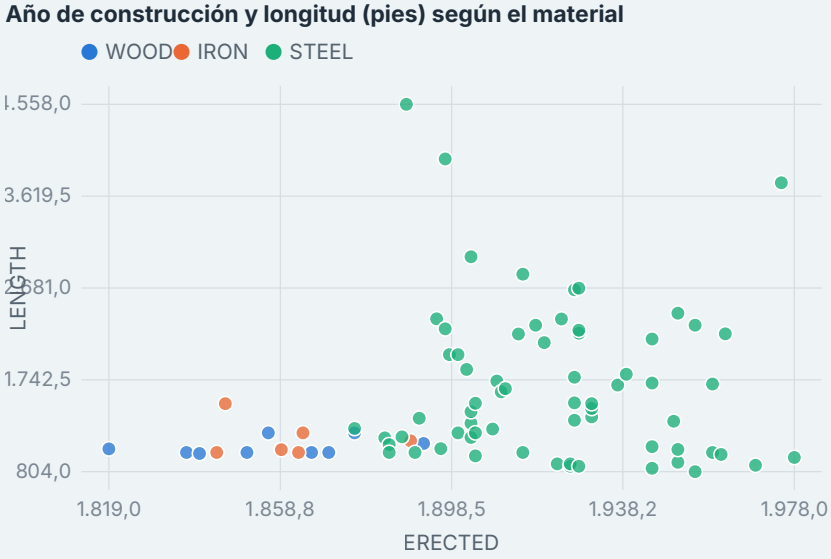
Exploración y visualización · Clasificación multiclase · ? Valores faltantes · Mixto num. + cat. · Multiobjetivo

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
108	**13**	–	**5,5 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`bridges`	108 × 13	CSV 6 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/bridges/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Cada fila es un puente de Pittsburgh (Pensilvania). Hay dos grupos de variables:

- **Especificaciones** (lo que se pide al puente): río que cruza, ubicación, año de construcción, uso (carretera, ferrocarril, acueducto, peatonal), longitud, carriles y si se exige un gálibo vertical.
- **Diseño** (cómo se resolvió): si el tablero va por encima o por dentro de la estructura, material, longitud del vano, longitud relativa y tipo de puente (viga simple, arco, colgante, voladizo…).

En el estudio original, la tarea era predecir las cinco propiedades de diseño a partir de las especificaciones.

Los estudios habituales son:

- **Clasificación con varias salidas** (*multitarget*) o una a una.
- **Exploración histórica**: cómo cambian los materiales y los tipos con los años.
- **Datos con huecos** y variables mixtas en muy pocas filas.

2 Contexto y fuente original

Lo crearon **Yoram Reich y Steven Fenves** (Universidad Carnegie Mellon) a finales de los ochenta para estudiar cómo aprender la experiencia de diseño de los ingenieros. Lo donaron al repositorio UCI en 1990. Hay dos versiones; la de Orange es la primera, con el año y la longitud como números.

- Reich, Y. y Fenves, S. J. (1989). Incremental Learning for Capturing Design Expertise. Informe EDRC 12-34-89, Carnegie Mellon University. Datos en el repositorio UCI (Pittsburgh Bridges).

3 Variable objetivo

En Orange no hay ninguna variable objetivo marcada. En el estudio original, las cinco propiedades de diseño son los objetivos: `T-OR-D`, `MATERIAL`, `SPAN`, `REL-L` y `TYPE`. La más usada es `TYPE` (7 valores: viga simple 44, madera 16, arco 13, colgante 11, voladizo 11, viga continua 10 y uno sin tipo).

El año explica mucho: todos los puentes de madera son anteriores a 1900, el hierro desaparece tras 1900 y el acero domina desde entonces.

4 Diccionario de columnas

Columnas de `bridges` (valores observados en el fichero)

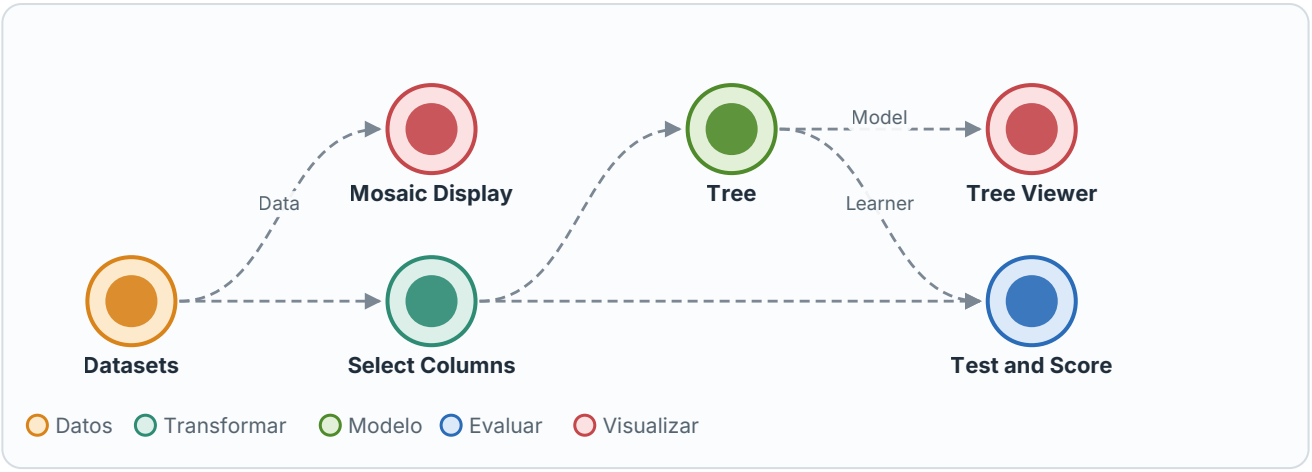
Columna	Tipo	Significado	Valores
`IDENTIF`	texto	Identificador del puente (`E1`, `E2`…). Ignorado en Orange.	E1 (1), E2 (1), E3 (1), E5 (1), E6 (1), E7 (1) …
`RIVER`	categórica	Río: `A` Allegheny, `M` Monongahela, `O` Ohio, `Y` Youghiogheny.	A (49), M (41), O (15), Y (3)
`LOCATION`	numérica	Ubicación codificada a lo largo del río (número). Ignorada en Orange.	1 – 52
`ERECTED`	numérica	Año de construcción (1818–1986).	1.818 – 1.986
`PURPOSE`	categórica	Uso: `HIGHWAY` carretera, `RR` ferrocarril, `AQUEDUCT` acueducto, `WALK` peatonal.	HIGHWAY (71), RR (32), AQUEDUCT (4), WALK (1)
`LENGTH`	numérica	Longitud (pies). **27 vacíos.**	804 – 4.558
`LANES`	numérica	Número de carriles (1, 2, 4 o 6). 16 vacíos.	1 – 6
`CLEAR-G`	categórica	Si se exige un gálibo vertical para la navegación: `G` sí, `N` no.	G (80), N (26)
`T-OR-D`	categórica	*Diseño*: tablero por dentro de la estructura (`THROUGH`) o encima (`DECK`).	THROUGH (87), DECK (15)
`MATERIAL`	categórica	*Diseño*: `WOOD` madera, `IRON` hierro, `STEEL` acero.	STEEL (79), WOOD (16), IRON (11)

Columna	Tipo	Significado	Valores
SPAN	categórica	*Diseño*: longitud del vano: `SHORT`, `MEDIUM`, `LONG`. 16 vacíos.	MEDIUM (53), LONG (30), SHORT (9)
REL-L	categórica	*Diseño*: longitud relativa del vano frente al total: `S` pequeña, `S-F`, `F` completa.	F (58), S (30), S-F (15)
TYPE	categórica	*Diseño*: tipo de puente: `SIMPLE-T` viga simple, `CONT-T` viga continua, `ARCH` arco, `SUSPEN` colgante, `CANTILEV` voladizo, `WOOD` madera, `NIL`.	SIMPLE-T (44), WOOD (16), ARCH (13), SUSPEN (11), CANTILEV (11), CONT-T (10) …

5 Particularidades técnicas al modelar

- **Sin objetivo marcado**: hay que elegirlo en **Select Columns**. Si se predice `TYPE`, las otras propiedades de diseño (sobre todo `MATERIAL`) no deberían usarse como atributos: también son resultado del diseño.
- `TYPE = WOOD` **repite el material**: los 16 puentes de madera tienen tipo `WOOD`, así que `MATERIAL` delata ese valor del tipo.
- **Muchos huecos para tan pocas filas**: 77 celdas vacías, sobre todo en longitud (27), carriles y vano (16).
- **Clases pequeñas**: un puente peatonal, un `NIL`. La validación cruzada es muy inestable.
- **Identificador y ubicación ignorados** en Orange; si se lee el CSV con **File**, márcalos como `skip`.

6 Flujo de trabajo en Orange



1. **Datasets** → «Pittsburgh Bridges».
2. **Scatter Plot** de `ERECTED` frente a `LENGTH` coloreado por `MATERIAL`.
3. **Select Columns**: `TYPE` como objetivo; las especificaciones como atributos; el resto de propiedades de diseño fuera.
4. **Test and Score** con *Leave one out* y un árbol; **Tree Viewer** para leer las reglas.
5. Repite con `MATERIAL` como objetivo: el año de construcción lo explica casi todo.

7 Otras consideraciones

- **Segunda versión**: el repositorio UCI tiene otra versión con el año y la longitud discretizados en categorías.
- **Varias salidas**: es un buen ejemplo para explicar por qué predecir cada salida por separado puede dar diseños incoherentes (un puente de madera colgante, por ejemplo).

En la carpeta `bridges` ← `bridges.tab` (datasets.biolab.si)

6.10

No supervisado: clustering, exploración y datos geográficos

Banking crises

`06_exploracion_clustering_geo/banking_crises/`

Crisis bancarias año a año en 70 países entre 1800 y 2010: una tabla de ceros y unos con una fila por año, ideal para ver oleadas de crisis (1890, 1930, 1990, 2008) y agrupar países o épocas.

Exploración y visualización | Clustering | ? Valores faltantes | ◈ Mixto num. + cat. | ◷ Temporal

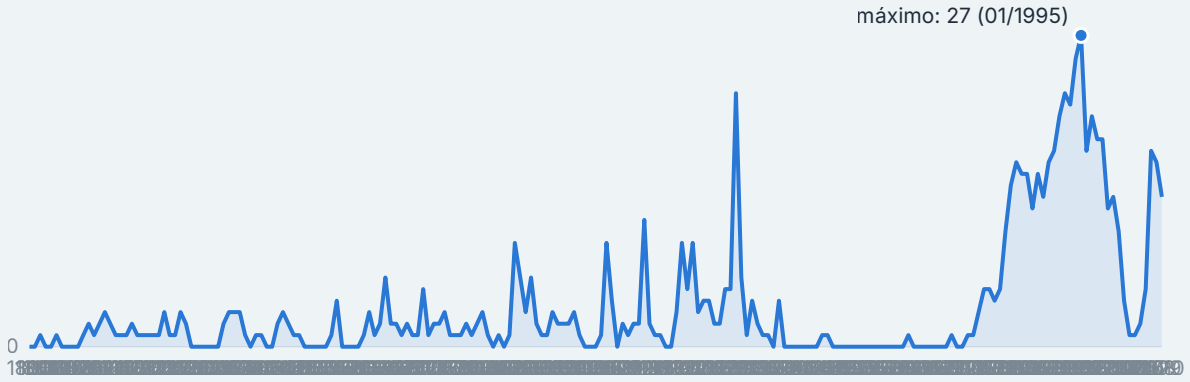
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
211	**73**	–	**0,0 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`banking_crises`	211 × 73	CSV 33 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/banking_crises/` seguido del nombre del fichero CSV.

Radiografía

Número de países en crisis bancaria cada año (1800–2010)



1 Descripción general y estudios habituales

Cada fila es un **año** (de 1800 a 2010) y cada columna un **país** (70), con un 1 si ese país estaba en crisis bancaria ese año y un 0 si no. Dos columnas más resumen la fila: `World`, el número de países en crisis, y `Developed`, el de países desarrollados en crisis.

Los estudios habituales son:

- **Series temporales**: las oleadas de crisis a lo largo de dos siglos.
- **Agrupamiento de países** por la coincidencia de sus crisis (transponiendo la tabla).
- **Agrupamiento de años** o épocas parecidas.

2 Contexto y fuente original

Orange lo presenta como una transformación de un fichero de STATA del **Banco Mundial**, asociado al documento de trabajo *Banking Crises and Exports: Lessons from the Past* (Leonardo Iacovone y Veronika Zavacka, 2009). Ese artículo analiza 23 crisis entre 1980 y 2000; la serie de este fichero es mucho más larga y Orange no detalla de dónde salen las fechas anteriores.

- Iacovone, L. y Zavacka, V. (2009). Banking Crises and Exports: Lessons from the Past. World Bank Policy Research Working Paper 5016.

3 Variable objetivo

No tiene variable objetivo. Lo interesante es la columna `World`: casi no hay crisis entre 1940 y 1970, hay oleadas en la década de 1890 y en la de 1930 (22 países en crisis en 1931) y el máximo llega en los noventa (27 países en 1995). La crisis de 2008 pasa de 5 países en 2007 a 17 en 2008, 13 de ellos desarrollados. Estados Unidos es el país con más años en crisis (31), seguido de España y China (26).

4 Diccionario de columnas

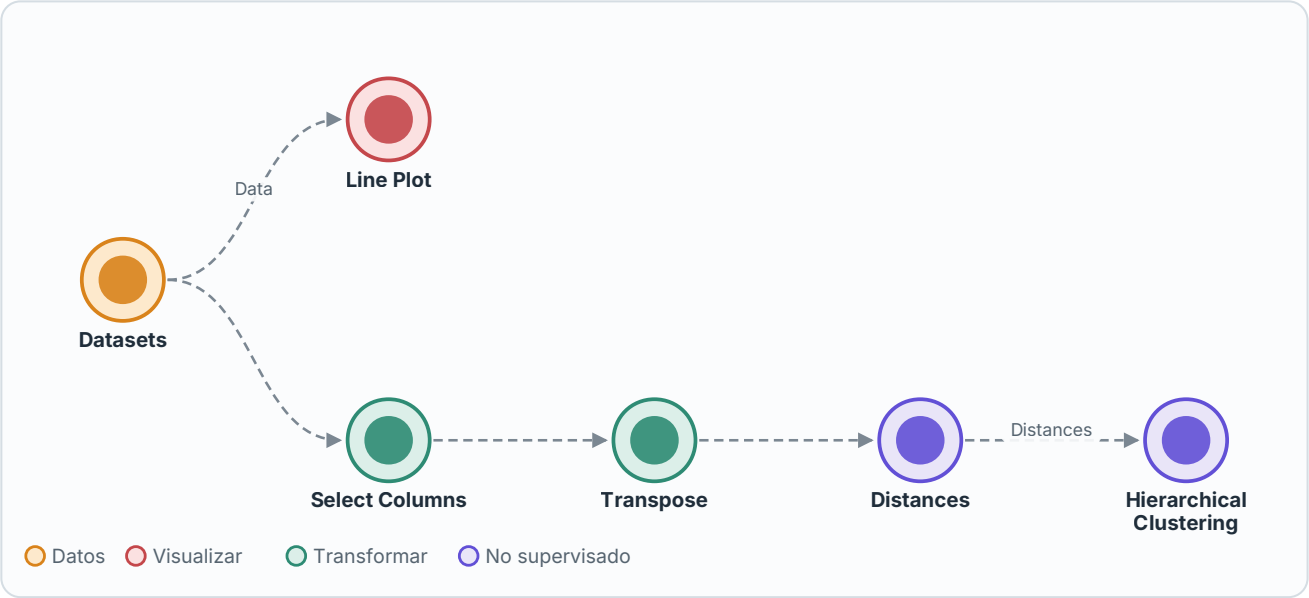
Columnas de `banking_crises` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`year`	fecha/hora	Año, como fecha del 1 de enero (1800-01-01 … 2010-01-01). Orange lo lee como atributo.	1800-01-01 (1), 1801-01-01 (1), 1802-01-01 (1), 1803-01-01 (1), 1804-01-01 (1), 1805-01-01 (1) …
`World`	numérica	Número de países en crisis ese año (suma de las 70 columnas de países, de 0 a 27).	0 – 27
`Developed`	numérica	Número de países desarrollados en crisis (0–15).	0 – 15
`Algeria`	categórica	1 si Argelia estaba en crisis bancaria ese año, 0 si no. Igual para cada país.	0 (208), 1 (3)
…		y 69 columnas más: una por país (de Angola a Zimbabue), con nombres en inglés sin espacios (`CentralAfricanRep`, `CoteDIvoire`…).	

5 Particularidades técnicas al modelar

- **Los países están en columnas**: para agrupar países hay que transponer la tabla (**Transpose**), de modo que cada país sea una fila y cada año una columna.
- `World` **y** `Developed` **son sumas**: si se agrupan años o se hace una regresión, no deben mezclarse con las columnas de países.
- **El año es una fecha** y Orange lo trata como atributo; para una serie temporal hay que usarlo como índice (add-on *Timeseries*) o como meta.
- **Cero no siempre es «sin crisis»**: muchos de estos países no eran independientes en 1800, y la tabla no distingue entre «sin crisis» y «sin dato». Los resultados del siglo XIX son poco fiables para esos países.
- **Un hueco**: Suecia en 1897.

6 Flujo de trabajo en Orange



1. **Datasets** → «Banking Crises».
2. **Scatter Plot** o **Line Plot** de `World` por año: las oleadas de crisis.
3. **Select Columns**: quita `World` y `Developed` y pasa `year` a meta.
4. **Transpose** para que cada país sea una fila.
5. **Distances** (Jaccard, para datos binarios) → **Hierarchical Clustering**: ¿qué países sufren crisis a la vez?

7 Otras consideraciones

- **Relacionar con otros datos**: con el add-on *World Happiness* o los indicadores del Banco Mundial se puede cruzar con el PIB o las exportaciones.
- **Limitar la época**: con *Select Rows*, quedarse con 1945–2010 da grupos de países más fiables.

En la carpeta `banking_crises` ← `banking-crises.tab` (datasets.biolab.si)

6.11
No supervisado: clustering, exploración y datos geográficos

UL Rector Elections 2009

`06_exploracion_clustering_geo/ul_rector_elections/`

Porcentaje de votos de cada uno de los cuatro candidatos a rector de la Universidad de Liubliana en 2009, facultad por facultad: 26 filas para agrupar facultades según a quién votaron.

Exploración y visualización · Clustering · ◦ Juguete

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
26	**7**	—	**0,0 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`ul_rector_elections_2009`	26 × 7	CSV 2 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/ul_rector_elections/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Cada fila es una facultad o academia de la **Universidad de Liubliana** (Eslovenia) con su nombre en inglés, su sigla en esloveno, el número total de votos emitidos y el **porcentaje de votos** que recibió cada uno de los cuatro candidatos a rector en 2009: Janez Hribar, Jože Duhovnik, Rudi Rizman y Stane Pejovnik. Los cuatro tenían perfiles distintos (biotecnología, ingeniería mecánica, sociología, química), lo que hace que las facultades voten de forma muy diferente.

Los estudios habituales son:

- **Agrupamiento** de facultades por su comportamiento de voto.
- **Visualización** de proporciones (cada fila suma 100 %).

2 Contexto y fuente original

Antes del voto electrónico, la votación se organizaba en cada facultad, así que se podían analizar los resultados por centro. El equipo de **Orange** preparó el dataset con los datos de 2009. Ese año fue elegido **Stane Pejovnik** (rector entre 2009 y 2013); las normas preveían una segunda vuelta entre los dos más votados si

nadie superaba el 50 %. En estos datos, con los votos ponderados, Rizman queda primero, así que muy probablemente corresponden a la primera vuelta.

- Elections for Rector of the University of Ljubljana (2009) en el repositorio de datasets de Orange

3 Variable objetivo

No tiene variable objetivo. Sumando todos los votos (1.964), Rudi Rizman obtiene el 33,5 %, Stane Pejovnik el 29,2 %, Janez Hribar el 26,3 % y Jože Duhovnik el 11,0 %. Cada candidato arrasa en su entorno: Hribar en la Facultad de Biotecnología (`BF`), Duhovnik en Ingeniería Mecánica (`FS`), Rizman en Filosofía y Letras (`FF`) y Pejovnik en Química (`FKKT`). Las facultades se agrupan por afinidad de disciplina.

4 Diccionario de columnas

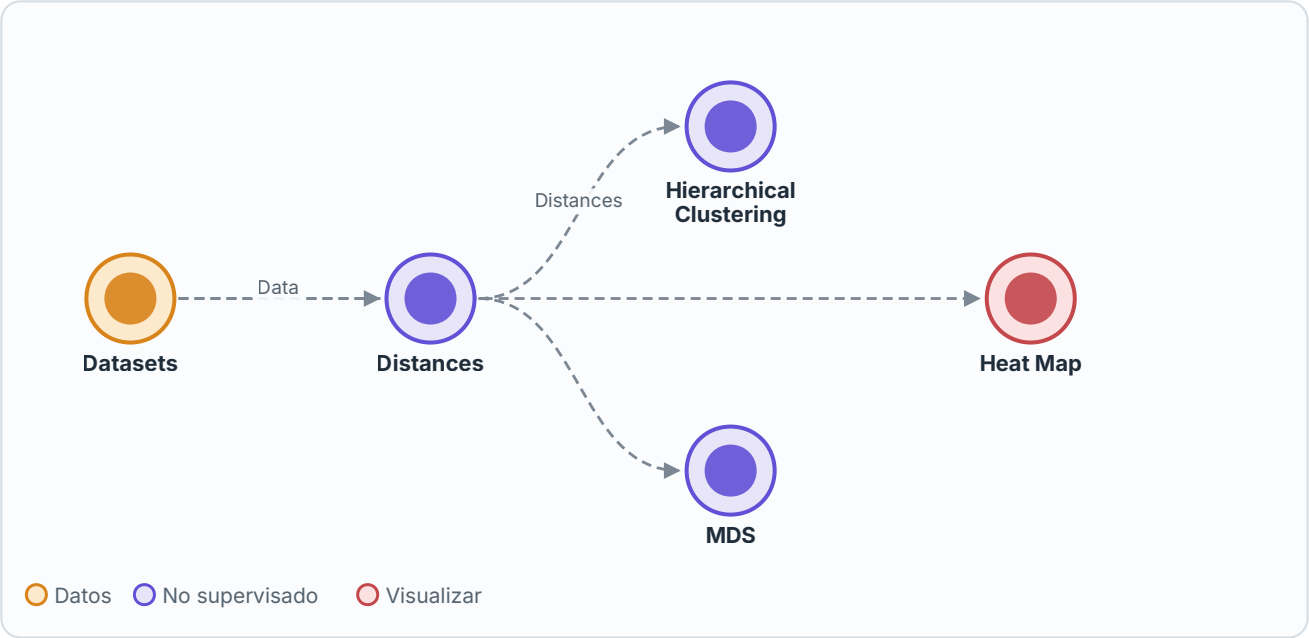
Columnas de `ul_rector_elections_2009` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Faculty`	texto	Nombre de la facultad en inglés (meta).	Academy of Music (1), Academy of Theatre, Radio, Film and Television (1), Academy of Fine Arts and Design (1), Biotechnical Faculty (1), School of Economics and Business (1), Faculty of Arhitecture (1) …
`Short (slo)`	texto	Sigla en esloveno (meta): `FF` Filosofía y Letras, `FS` Ingeniería Mecánica, `BF` Biotecnología…	AG (1), AGRFT (1), ALUO (1), BF (1), EF (1), FA (1) …
`Total`	numérica	Votos emitidos en la facultad (meta), de 19 a 247.	19 – 247
`Janez Hribar`	numérica	Porcentaje de votos para Janez Hribar en esa facultad.	0 – 81,319
`Jože Duhovnik`	numérica	Porcentaje de votos para Jože Duhovnik.	1,205 – 57,265
`Rudi Rizman`	numérica	Porcentaje de votos para Rudi Rizman.	2,778 – 82,186
`Stane Pejovnik`	numérica	Porcentaje de votos para Stane Pejovnik.	4,396 – 83,133

5 Particularidades técnicas al modelar

- **Cada fila suma 100 %**: son proporciones; los cuatro valores no son independientes (con tres se deduce el cuarto).
- **Facultades de tamaño muy distinto**: de 19 a 247 votos. El porcentaje de una facultad pequeña pesa igual que el de una grande al agrupar; para el resultado global hay que ponderar por `Total` .
- **No se sabe la vuelta**: la ficha no aclara si es la primera vuelta; por los totales, no es la votación definitiva.
- **Nombres de personas**: los candidatos son profesores universitarios con un cargo público en juego; los datos son resultados electorales agregados por centro.

6 Flujo de trabajo en Orange



1. **Datasets** → «Elections for Rector of the University of Ljubljana (2009)».
2. **Distances** → **Hierarchical Clustering** con las hojas etiquetadas por la sigla.
3. **Heat Map** ordenado por grupos: se ve qué candidato domina en cada grupo de facultades.
4. **MDS**: las facultades en un plano, con el tamaño del punto según `Total`.

7 Otras consideraciones

- **Ponderar por votos**: con *Feature Constructor* se puede pasar de porcentajes a votos (`Total * porcentaje / 100`) y comparar agrupamientos.
- **Comparar con Slovenian National Assembly**: otro dataset de votaciones, con votos individuales en lugar de porcentajes.

En la carpeta `ul_rector_elections_2009` ← `UL Rector Elections 2009.xlsx` (datasets.biolab.si)

6.12
No supervisado: clustering, exploración y datos geográficos

Slovenian National Assembly (votaciones)

`06_exploracion_clustering_geo/slovenian_national_assembly/`

Cómo votaron 84 diputados del parlamento esloveno 18 leyes en mayo y junio de 2017, con su partido y otros datos: el agrupamiento separa el Gobierno de la oposición sin decirle quién es quién.

Clustering | Exploración y visualización | ? Valores faltantes | ∘ Juguete | ◇ Solo categóricos

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
84	**32**	–	**8,7 %**	**Intermedio**	**Ninguno**

Fichero	Filas × col.	Descargar
`slovenian_national_assembly`	84 × 32	CSV 17 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/slovenian_national_assembly/` seguido del nombre del fichero CSV.

1 Descripción general y estudios habituales

Cada fila es un **diputado** de la Asamblea Nacional de Eslovenia. Las 18 primeras columnas son su voto en 18 leyes de mayo y junio de 2017 (a favor, en contra, presente sin votar o ausente). Las demás son metas: nombre, sexo, nivel de estudios, partido, fecha de nacimiento y edad, asistencia, iniciativas presentadas, intervenciones y palabras por sesión, número de mandatos, votos obtenidos en su elección, circunscripción y un enlace a su foto oficial.

Los estudios habituales son:

- **Agrupamiento de diputados** por su voto y comparación con los partidos.
- **Proyecciones** (PCA, MDS): el primer eje separa Gobierno y oposición.
- **Datos categóricos con valores especiales** (presente sin votar, ausente).

2 Contexto y fuente original

Los datos se descargaron de la API de **Parlameter**, un proyecto de transparencia parlamentaria, para sesiones seleccionadas de mayo y junio de 2017. En ese momento gobernaba una coalición formada por SMC, DeSUS y SD; la oposición incluía a SDS, NSi y Levica, entre otros. El equipo de **Orange** preparó la versión en inglés.

- Slovenian National Assembly en el repositorio de datasets de Orange (datos de la API de Parlameter)

3 Variable objetivo

No tiene variable objetivo; `party` sirve para comprobar los grupos. Codificando los votos (a favor 1, presente 0, en contra −1, ausente 0), la primera componente principal recoge el 56 % de la variación y separa a los partidos del Gobierno (SMC, DeSUS y SD, a un lado) de la oposición (SDS, NSi y los diputados no adscritos, al otro), con Levica y las minorías en medio. Por ejemplo, en la ley de pensiones e invalidez del 30 de mayo, SMC, DeSUS, SD y Levica votaron en contra y SDS y NSi a favor.

4 Diccionario de columnas

Columnas de `slovenian_national_assembly` (valores observados en el fichero)

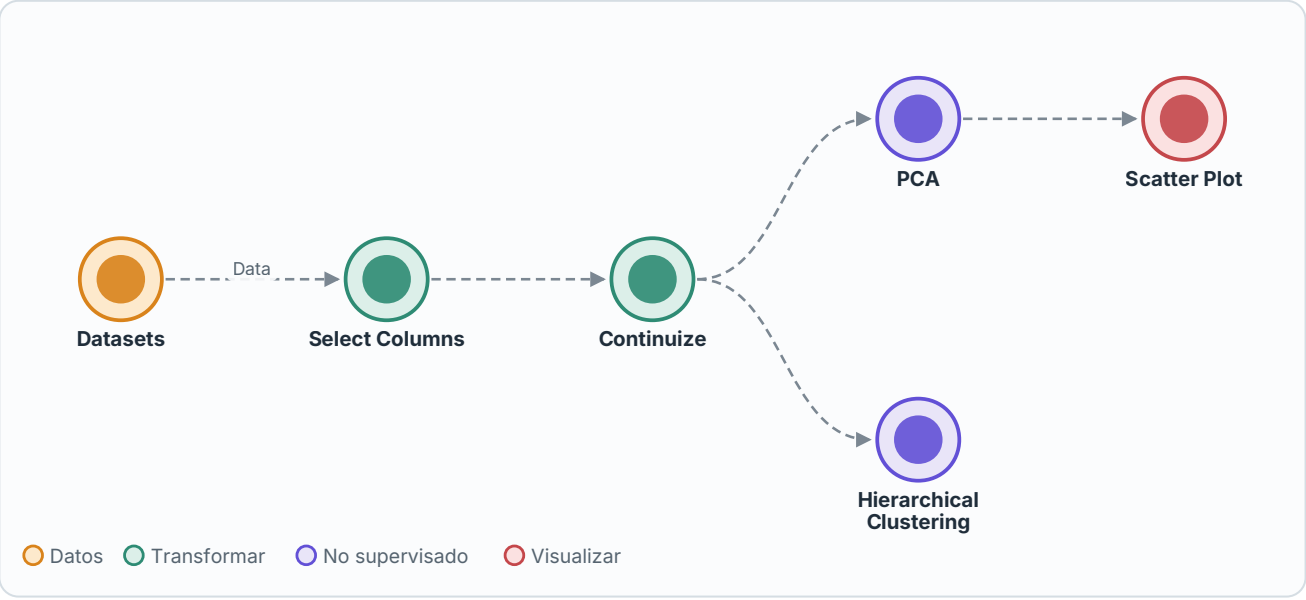
Columna	Tipo	Significado	Valores
`Construction law (22.6.2017)`	categórica	Voto en la ley de construcción del 22 de junio de 2017: `1` a favor, `0` en contra, `quorum` presente sin votar, vacío = ausente. Igual en las 18 leyes.	1 (47), 0 (17), quorum (8)
`Law on equal opportunities for the disabled`	categórica	Voto en la ley de igualdad de oportunidades de las personas con discapacidad. **Todos los presentes votaron a favor**: es constante.	1.0 (70)
`name`	texto	Nombre del diputado (meta).	Aleksander Kavčič (1), Alenka Bratušek (1), Andrej Čuš (1), Andrej Šircelj (1), Andreja Potočnik (1), Anita Koleša (1) …
`gender`	categórica	Sexo (meta): `m` hombre, `ž` mujer (inicial eslovena).	m (54), ž (30)
`education`	categórica	Nivel de estudios (meta), codificado de 4 a 8.	6 (26), 8 (24), 7 (20), 5 (13), 4 (1)
`party`	categórica	Partido o grupo (meta): SMC (31), SDS (19), DeSUS (11), NSI (6), Levica (5), SD (4), PS NP (4, grupo de no adscritos), NeP (2, no adscritos) e IMNS (2, diputados de las minorías italiana y húngara).	SMC (31), SDS (19), DeSUS (11), NSI (6), Levica (5), SD (4) …
`date of birth`	fecha/hora	Fecha de nacimiento (meta).	(no se muestran)
`attendance`	numérica	Asistencia a las votaciones (%).	44,8 – 98,5
`initiatives`	numérica	Iniciativas presentadas.	0 – 356
`speeches/session`	numérica	Intervenciones por sesión.	1 – 54
`words/session`	numérica	Palabras por sesión.	12.138 – 803.984
`age`	numérica	Edad.	27 – 73
`mandates`	numérica	Número de mandatos como diputado (1–7).	1 – 7
`voters`	numérica	Votos obtenidos en su elección.	523 – 6.116
`image`	texto	Enlace a su foto oficial en la web del parlamento (meta).	(no se muestran)

Columna	Tipo	Significado	Valores
`locality`	texto	Circunscripción electoral (meta).	Ljubljana Bežigrad II (3), Ljutomer (2), Cerknica-Logatec (2), Kranj I (2), Ruše (2), Maribor VII (2) …
…		y 16 columnas más de votaciones, con el mismo formato (el nombre incluye la ley y la fecha).	

5 Particularidades técnicas al modelar

- **Tres valores y ausentes**: `1`, `0` y `quorum` (presente pero sin votar, solo cuenta para el quórum); el vacío es ausencia. Orange lee las columnas como categóricas; para distancias o PCA conviene pasarlas a números con *Feature Constructor* o *Continuize*, decidiendo qué valor dar a `quorum` y a los ausentes.
- **Una ley sin información**: `Law on equal opportunities for the disabled` es siempre 1. Quítala.
- **84 de 90 diputados**: la Asamblea tiene 90 escaños; la ficha no explica por qué faltan seis.
- **Mucho absentismo en algunas leyes**: varias tienen entre 11 y 18 ausentes; la asistencia de algunos diputados es del 45 %.
- **Datos personales de cargos públicos**: nombres, fechas de nacimiento y fotos de diputados. Son datos públicos de su actividad, pero en este libro no se muestran las fechas ni los enlaces.

6 Flujo de trabajo en Orange



1. **Datasets** → «Slovenian National Assembly».
2. **Select Columns**: quita la ley constante.
3. **Impute** (ausente → `quorum`, por ejemplo) y **Continuize** (o **Feature Constructor** para codificar 1/0/−1).
4. **PCA** → **Scatter Plot** de las dos primeras componentes, coloreado por `party`.
5. **Distances** → **Hierarchical Clustering**: ¿se corresponden los grupos con los partidos?

7 Otras consideraciones

- **Diputados que votan distinto de su partido**: en el gráfico de PCA, los puntos lejos de su grupo son los interesantes.
- **Comparar con Voting** (capítulo 1): el mismo tipo de análisis con el Congreso de Estados Unidos en 1984.

En la carpeta `slovenian_national_assembly` ← `slovenian-national-assembly-eng.tab` (datasets.biolab.si)

6.13
No supervisado: clustering, exploración y datos geográficos

Slovenian surnames

`06_exploracion_clustering_geo/slovenian_surnames/`

Dónde viven los hogares con los 200 apellidos más comunes de Eslovenia: 103.530 hogares con su posición (alterada para anonimizar) y una tabla por municipio. Los apellidos dibujan regiones: Horvat es el apellido de Prekmurje.

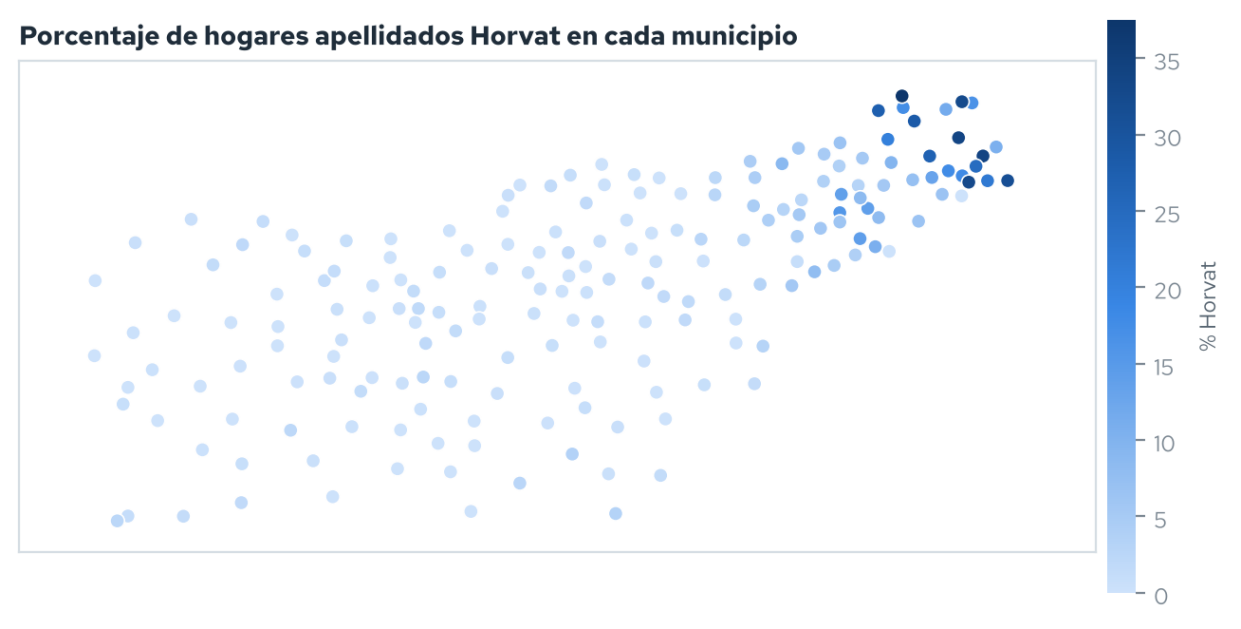
Exploración y visualización | Clustering | Espacial | Grande

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
103.530	**4**	–	**0,0 %**	**Intermedio**	**Geo**

Fichero	Filas × col.	Descargar
`slovenian_surnames`	103.530 × 4	CSV 5,6 MB · XLSX
`slovenian_surnames_by_municipality`	192 × 208	CSV 160 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/slovenian_surnames/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Dos tablas sobre los **200 apellidos más frecuentes** de Eslovenia, con datos de finales de los años noventa:

- `slovenian_surnames`: 103.530 hogares con su apellido, su municipio y unas coordenadas aproximadas. Para anonimizar, la posición de cada hogar se movió al azar hasta 10 km.

- `slovenian_surnames_by_municipality`: 192 municipios con su región, coordenadas, superficie, población y densidad, y el **porcentaje** de hogares de cada uno de los 200 apellidos entre los hogares con esos apellidos (cada fila suma 100).

Los estudios habituales son:

- **Mapas** de la distribución de cada apellido (add-on *Geo*).
- **Agrupamiento de municipios** por sus apellidos: ¿coinciden los grupos con las regiones históricas?
- **Agrupamiento de apellidos** por dónde aparecen (transponiendo la tabla).

2 Contexto y fuente original

Lo preparó el equipo de **Orange** (Universidad de Liubliana); la ficha no dice de qué registro proceden los hogares. Los porcentajes de la tabla por municipio están normalizados respecto a los hogares con alguno de los 200 apellidos, no respecto a toda la población. Hay versiones en esloveno (`priimki-slovenija.tab`, `priimki-v-obcinah.tab`).

- Slovenian Surnames en el repositorio de datasets de Orange
- Slovenian Surnames by Municipality en el repositorio de datasets de Orange

3 Variable objetivo

No tiene variable objetivo. Los apellidos más comunes son Novak (3.367 hogares), Horvat (2.831), Kovačič, Krajnc y Zupančič. Algunos están repartidos por todo el país (Novak) y otros muy concentrados: **Horvat** supone de media el 25 % de los hogares de los municipios de **Prekmurje** y menos del 4 % en el resto de regiones; en Kuzma llega al 37,5 %. Al agrupar los municipios por sus apellidos aparecen regiones parecidas a las históricas.

4 Diccionario de columnas

Columnas de `slovenian_surnames` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`surname`	categórica	Apellido (meta), en mayúsculas.	NOVAK (3.367), HORVAT (2.831), KOVAČIČ (1.672), KRAJNC (1.636), ZUPANČIČ (1.581), POTOČNIK (1.467) …
`municipiality`	categórica	Municipio (meta). **El nombre de la columna tiene una errata** (*municipality*) y los municipios van **sin signos diacríticos** (`Crnomelj`), a diferencia de la otra tabla.	Ljubljana (12.308), Maribor (4.765), Kranj (2.804), Novo Mesto (2.725), Celje (2.009), Koper (1.996) …
`longitude`	numérica	Longitud aproximada del hogar (alterada hasta 10 km).	13,43 – 16,51
`latitude`	numérica	Latitud aproximada del hogar (alterada hasta 10 km).	45,43 – 46,867

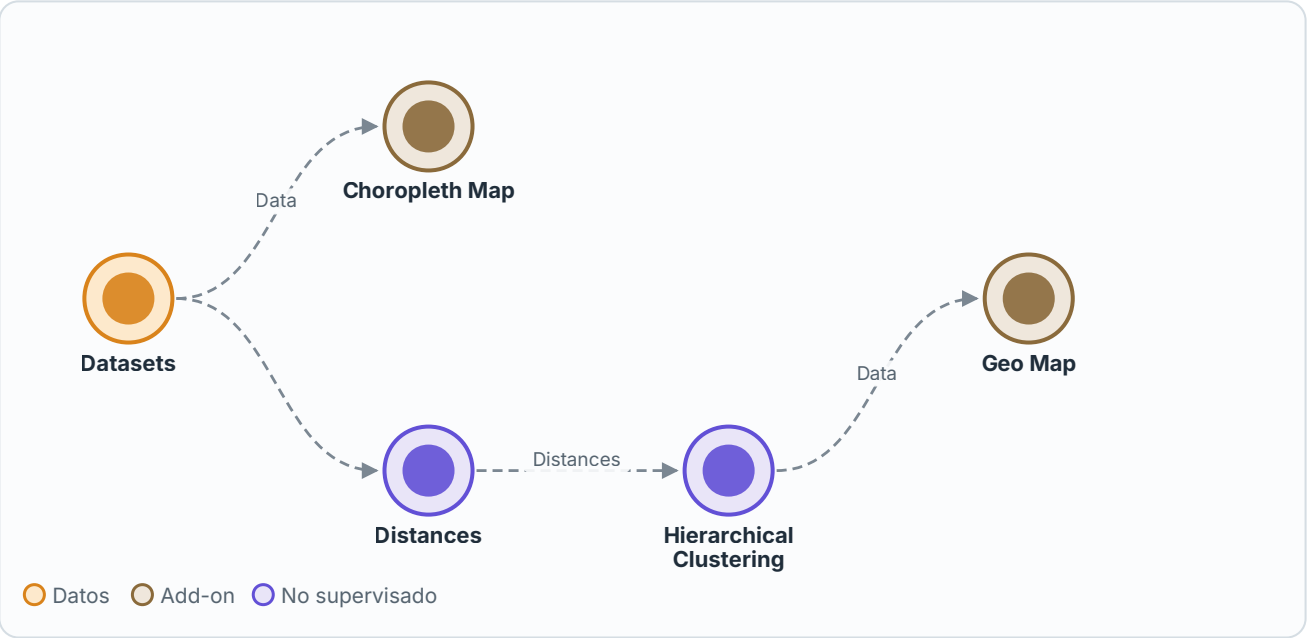
Columnas de `slovenian_surnames_by_municipality` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Municipality`	texto	Municipio (meta), con diacríticos (`Črnomelj`).	Ajdovščina (1), Apače (1), Beltinci (1), Benedikt (1), Bistrica ob Sotli (1), Bled (1) …
`Region`	categórica	Región histórica (meta): Štajerska, Gorenjska, Dolenjska, Primorska, Prekmurje, Notranjska, Koroška y Osrednja (solo Liubliana).	Štajerska (79), Gorenjska (30), Dolenjska (24), Primorska (19), Prekmurje (18), Notranjska (12) …
`latitude`	numérica	Latitud del municipio (meta).	45,498 – 46,838
`longitude`	numérica	Longitud del municipio (meta).	13,538 – 16,422
`Area [km²]`	numérica	Superficie (km², meta).	6,9 – 599,9
`Population`	numérica	Población (meta).	353 – 276.091
`Pop/km²`	numérica	Densidad (meta).	4,9 – 1.004
`Settlements`	numérica	Número de localidades (meta).	1 – 221
`AMBROŽIČ`	numérica	Porcentaje de hogares con el apellido Ambrožič entre los hogares con los 200 apellidos. Igual para cada apellido.	0 – 5,668
…		y 199 columnas más: una por apellido, por orden alfabético (hasta ŽNIDARŠIČ).	

5 Particularidades técnicas al modelar

- **Posiciones falsas a propósito**: cada hogar se movió hasta 10 km para proteger la privacidad. Sirve para mapas a escala de país o región, no para localizar a nadie.
- **Las dos tablas no se pueden unir por el municipio sin limpiar**: una usa nombres sin diacríticos (`Apace` , `Divaca`) y la otra con ellos (`Apače` , `Divača`), y algunos se escriben distinto (`Dobrova-Polhov Gradec` frente a `Dobrova - Polhov Gradec`).
- **Porcentajes relativos a los 200 apellidos**: un 10 % no es el 10 % de la población del municipio. Cada fila suma 100 (datos composicionales): conviene la distancia del coseno o la correlación.
- **Región «Osrednja» con un solo municipio** (Liubliana), mientras que el resto tienen entre 9 y 79.
- **Columnas de apellidos con letras eslovenas** (Č, Š, Ž): algunos programas antiguos las muestran mal.

6 Flujo de trabajo en Orange



1. **Datasets** → «Slovenian Surnames by Municipality».
2. **Geo Map** o **Choropleth Map** (add-on *Geo*) coloreando por un apellido (`HORVAT`, `NOVAK`).
3. **Distances** (coseno) → **Hierarchical Clustering** de los municipios; corta en 5–8 grupos.
4. **Geo Map** coloreado por grupo y comparado con `Region`.
5. Con la tabla de hogares, **Geo Map** con un apellido filtrado en **Select Rows** muestra su mancha en el mapa.

7 Otras consideraciones

- **Apellidos como objetos**: con **Transpose**, cada apellido es una fila y sus porcentajes por municipio las columnas; al agrupar salen familias de apellidos de la misma zona.
- **Estadística regional**: el apellido más frecuente de cada municipio se calcula fácilmente con *Feature Constructor* o *Pivot Table* y da un mapa muy vistoso.

En la carpeta	`slovenian_surnames` ← `slovenian-surnames.tab` (datasets.biolab.si)
En la carpeta	`slovenian_surnames_by_municipality` ← `slovenian surnames by municipality.tab` (datasets.biolab.si)
Traducción, no se copia	`priimki-slovenija.tab` (datasets.biolab.si)
Traducción, no se copia	`priimki-v-obcinah.tab` (datasets.biolab.si)

6.14
No supervisado: clustering, exploración y datos geográficos

Slovenska naselja (localidades de Eslovenia)

`06_exploracion_clustering_geo/slovenska_naselja/`

Las 6.002 localidades de Eslovenia con coordenadas, municipio, región, superficie, población y altitud, sacadas de la Wikipedia: un dataset geográfico para mapas, con los miles mal leídos en el fichero de Orange (corregido aquí).

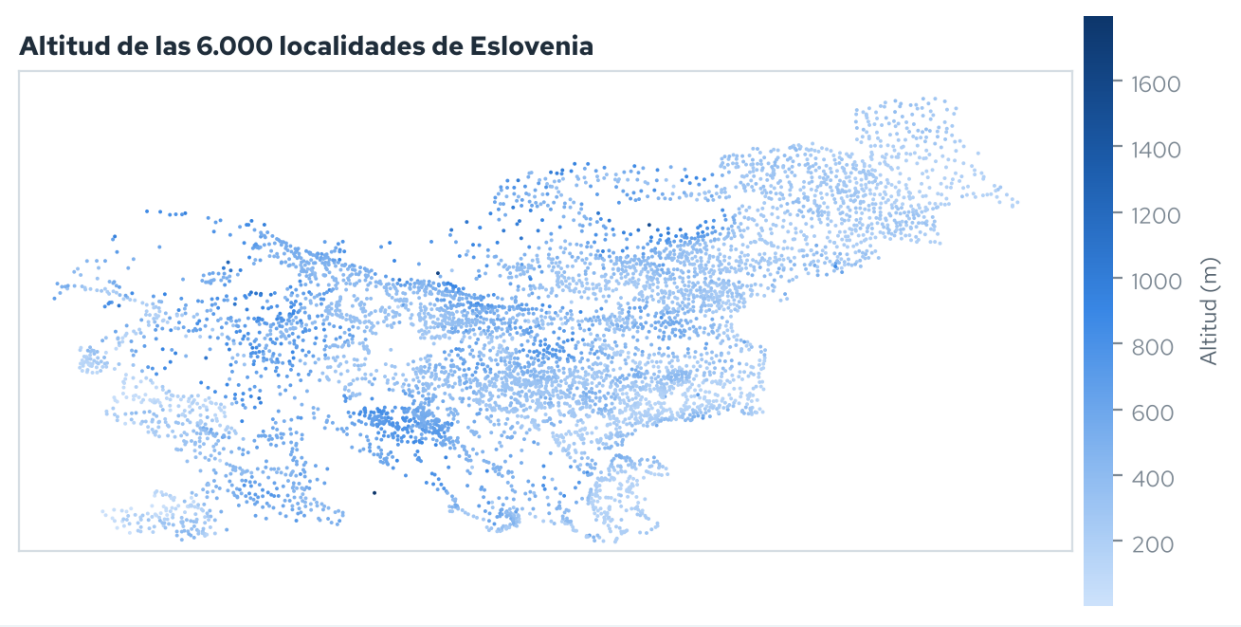
Exploración y visualización · ⌖ Espacial · ? Valores faltantes · ◈ Mixto num. + cat.

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
6.002	**8**	–	**0,1 %**	**Iniciación**	**Geo**

Fichero	Filas × col.	Descargar
`slovenska_naselja`	6.002 × 8	CSV 492 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/slovenska_naselja/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Cada fila es una **localidad** (*naselje*) de Eslovenia: casi todas las del país, desde Liubliana hasta aldeas sin habitantes. Para cada una se da el municipio, la región histórica, la latitud y la longitud, la superficie, el número de habitantes y la altitud. Las columnas tienen nombres en esloveno.

Los estudios habituales son:

- **Mapas** de población, altitud o regiones (add-on *Geo*).
- **Exploración de distribuciones muy asimétricas**: la mayoría de localidades tiene menos de 200 habitantes.
- **Agrupamiento geográfico** (por coordenadas) y comparación con las regiones.

2 Contexto y fuente original

Los datos proceden de la lista de localidades de Eslovenia de la **Wikipedia en esloveno** (*Seznam naselij v Sloveniji*), y el equipo de **Orange** los preparó en 2023. La ficha original está en esloveno.

Corrección en este CSV: en el fichero de Orange, las cifras con separador de miles (el punto, en esloveno) se leyeron como decimales. Maribor aparecía con 96,302 habitantes en lugar de 96.302, y Ambrož pod Krvavcem a 1,078 m de altitud en lugar de 1.078 m. Se han corregido 228 poblaciones y 31 altitudes (las cifras con exactamente tres decimales); la superficie no se ha tocado, porque sus decimales son reales.

- Seznam naselij v Sloveniji (Wikipedia en esloveno)
- Slovenska naselja en el repositorio de datasets de Orange

3 Variable objetivo

No tiene variable objetivo. La mediana es de 105 habitantes y la mayor localidad es Maribor (96.302); **Liubliana no tiene población ni superficie** en el fichero. Las localidades van de 2 a 1.796 m de altitud (mediana 350 m). Las regiones con más localidades son Štajerska (1.895) y Dolenjska (1.835).

4 Diccionario de columnas

Columnas de `slovenska_naselja` (valores observados en el fichero)

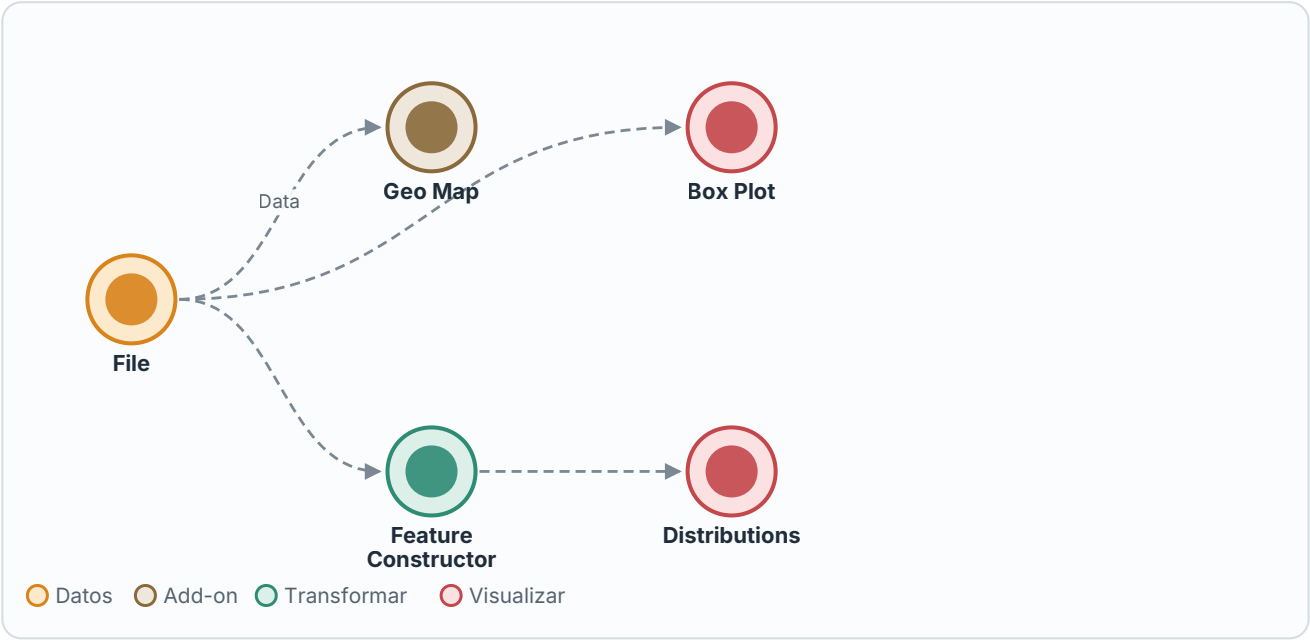
Columna	Tipo	Significado	Valores
`naselje`	texto	Nombre de la localidad (meta). Hay nombres repetidos en municipios distintos (Pristava, Gradišče…) y uno con un resto de enlace de la Wikipedia: `Snežnik#Naselje Snežnik`.	Pristava (8), Gradišče (7), Ravne (7), Potok (7), Dolenja vas (7), Brezje (7) …
`občina`	texto	Municipio (meta).	Krško (158), Ivančna Gorica (137), Trebnje (133), Črnomelj (121), Sevnica (117), Litija (110) …
`pokrajina`	categórica	Región histórica (Štajerska, Dolenjska, Gorenjska, Primorska…). 25 vacíos.	Štajerska (1.895), Dolenjska (1.835), Gorenjska (890), Primorska (653), Notranjska (341), Prekmurje (173) …
`širina`	numérica	Latitud.	45,431 – 46,86
`dolžina`	numérica	Longitud.	13,415 – 16,522
`površina`	numérica	Superficie (km²). 7 vacíos.	0,04 – 148
`prebivalcev`	numérica	Número de habitantes. **Corregido** (separador de miles). 2 vacíos, entre ellos Liubliana.	0 – 96.302

Columna	Tipo	Significado	Valores
`nadm. višina`	numérica	Altitud sobre el nivel del mar (m). **Corregida** (separador de miles). 2 vacíos (Celje entre ellos).	2 – 1.796

5 Particularidades técnicas al modelar

- **Separador de miles mal leído en Orange**: todas las poblaciones de más de 999 habitantes y las altitudes de más de 999 m estaban divididas por mil. Si se usa el fichero original de Orange, Maribor parece una aldea. En este CSV ya está corregido.
- **Huecos importantes**: Liubliana no tiene población ni superficie; Celje no tiene altitud. Cualquier mapa de población sin Liubliana es engañoso.
- **Distribuciones muy asimétricas**: la población va de 0 a 96.302 con mediana 105. Usa escala logarítmica.
- **Nombres repetidos**: `naselje` no es único (5.271 nombres para 6.002 localidades); para identificar una localidad hay que usar el nombre y el municipio.
- **Columnas en esloveno**: *naselje* (localidad), *občina* (municipio), *pokrajina* (región), *širina* (latitud), *dolžina* (longitud), *površina* (superficie), *prebivalcev* (habitantes), *nadm. višina* (altitud).

6 Flujo de trabajo en Orange



1. **File** con el CSV corregido (mejor que el de **Datasets**, que tiene los miles mal leídos).
2. **Geo Map** (add-on *Geo*) con `širina` y `dolžina`, coloreado por `nadm. višina`: se ven los Alpes y la costa.
3. **Box Plot** de la altitud por `pokrajina`.
4. **Feature Constructor**: `log(prebivalcev + 1)` y **Distributions**.

7 Otras consideraciones

- **Unir con otras tablas por municipio**: con Slovenian Surnames o EWBA (vertederos) se puede cruzar información por `občina`, cuidando los nombres.
- **Comprobar con la fuente**: buen ejercicio para enseñar a validar datos contra la fuente original.

En la carpeta `slovenska_naselja` ← `slovenska-naselja.tab` (datasets.biolab.si)

6.15
No supervisado: clustering, exploración y datos geográficos

Celine (países y continentes)

`06_exploracion_clustering_geo/celine/`

229 países con el continente al que pertenecen, en esloveno: una tabla auxiliar de dos columnas para unir con otros datos por país, en la que casi toda Oceanía queda sin continente.

Exploración y visualización · ? Valores faltantes · ◇ Solo categóricos

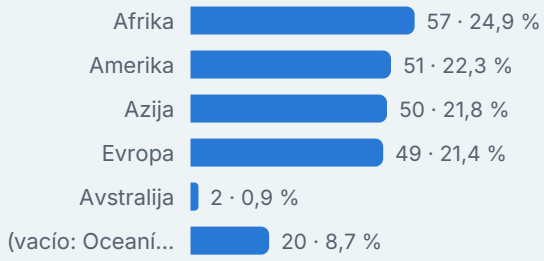
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
229	**2**	–	**4,4 %**	**Iniciación**	**Ninguno**

Fichero	Filas × col.	Descargar
`celine`	229 × 2	CSV 4 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/celine/` seguido del nombre del fichero CSV.

Radiografía

Países por continente (Celina)



1 Descripción general y estudios habituales

Una tabla muy sencilla: el nombre de 229 países y territorios (**Država**) y su continente (**Celina**), los dos en esloveno. No está pensada para analizarse sola, sino para **añadir el continente** a otros datos por país (por ejemplo, indicadores del Banco Mundial o de felicidad) con el widget **Merge Data**.

Los estudios habituales son:

- **Unión de tablas** (*Merge Data*) por el nombre del país.
- **Agrupar o colorear** otros datos por continente.

2 Contexto y fuente original

Es material del proyecto **Pumice** del equipo de Orange (Universidad de Liubliana), para actividades escolares en esloveno. Su ficha dice solo que es una tabla con los nombres de los países y los continentes en que se encuentran.

- Celine en el repositorio de datasets de Orange

3 Variable objetivo

No tiene variable objetivo. Los continentes son `Afrika` (57 países), `Amerika` (51), `Azija` (50), `Evropa` (49) y `Avstralija` (solo 2: Australia y Nueva Zelanda). **Los otros 20 países y territorios de Oceanía** (Fiyi, Papúa Nueva Guinea, Samoa, Tonga…) **no tienen continente**: la columna está vacía. América no se divide en Norte y Sur.

4 Diccionario de columnas

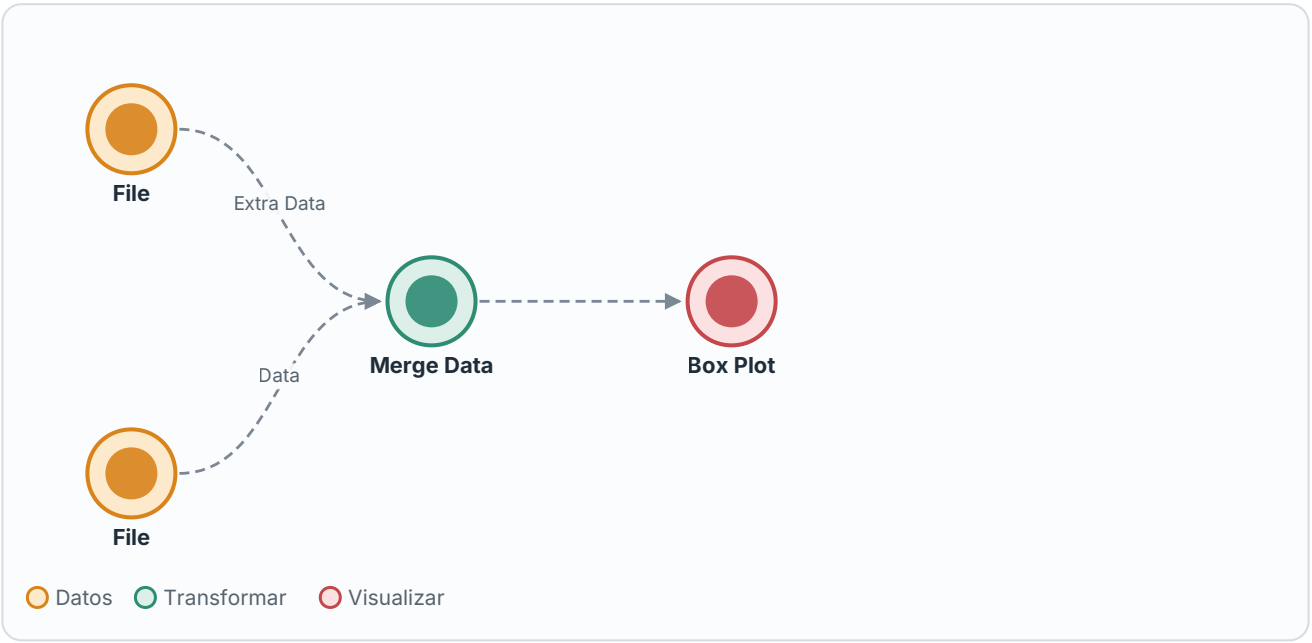
Columnas de `celine` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Država`	texto	Nombre del país o territorio en esloveno (meta): `Afganistan`, `Albanija`, `Alžirija`…	Afganistan (1), Albanija (1), Alžirija (1), Andora (1), Angola (1), Angvila (1) …
`Celina`	categórica	Continente en esloveno: `Afrika`, `Amerika`, `Azija`, `Evropa`, `Avstralija`. **Vacío en 20 países de Oceanía.**	Afrika (57), Amerika (51), Azija (50), Evropa (49), Avstralija (2)

5 Particularidades técnicas al modelar

- **Oceanía, a medias**: Australia y Nueva Zelanda forman el «continente» `Avstralija`, y los demás países de Oceanía tienen el continente vacío. Si se une con otra tabla, esos 20 países quedarán sin continente.
- **Nombres en esloveno**: para unirla con datos en inglés (Banco Mundial, World Happiness…) hay que traducir los nombres o usar una tabla de correspondencias; los nombres de países son el punto débil de cualquier unión.
- **Muy pocos datos**: dos columnas. Es una herramienta, no un dataset para modelar.

6 Flujo de trabajo en Orange



1. **File** con `celine.csv` y otro **File** con datos por país (con los nombres en esloveno).
2. **Merge Data**: une por el nombre del país (`Država`).
3. **Box Plot** o **Distributions** de cualquier indicador por `Celina`.

4. Revisa con **Data Table** los países que se quedan sin continente.

7 Otras consideraciones

- **Completar Oceanía**: con **Feature Constructor** se puede asignar `Avstralija` (u `Oceanija`) a los vacíos.
- **Datasets de Pumice relacionados**: Weather y Letter Frequencies, del mismo proyecto.

En la carpeta `celine` ← `celine.xlsx` (datasets.biolab.si)

6.16
No supervisado: clustering, exploración y datos geográficos

Cyber security breaches (EE. UU.)

`06_exploracion_clustering_geo/cyber_security_breaches/`

1.055 brechas de datos de salud notificadas en Estados Unidos (de 1997 a 2014) con el número de personas afectadas, el tipo de brecha y dónde estaban los datos: exploración de una distribución de colas muy pesadas.

Exploración y visualización · Espacial · ? Valores faltantes · Mixto num. + cat. · Temporal · Texto

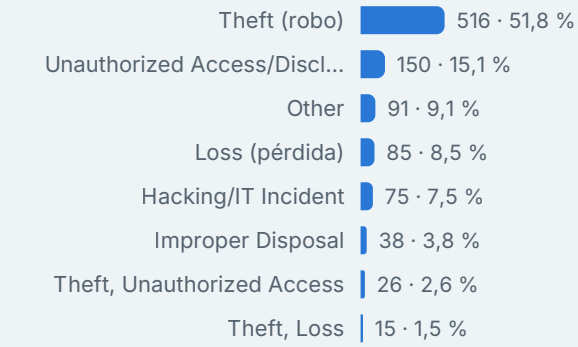
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
1.055	**10**	–	**24,7 %**	**Intermedio**	**Geo**

Fichero	Filas × col.	Descargar
`cyber_security_breaches`	1.055 × 10	CSV 231 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/cyber_security_breaches/` seguido del nombre del fichero CSV.

Radiografía

Brechas por tipo (los ocho más frecuentes)



1 Descripción general y estudios habituales

Cada fila es una **brecha de seguridad** en una entidad sanitaria de Estados Unidos (hospitales, aseguradoras, clínicas, farmacias…) que afectó a 500 personas o más. Se conoce la entidad, el estado, si intervino un proveedor (*business associate*), el número de **personas afectadas**, el tipo de brecha (robo, pérdida, acceso no autorizado, pirateo…), dónde estaba la información (papel, portátil, servidor, correo…), las fechas de inicio y fin de la brecha, la de publicación y, en algunos casos, un resumen en texto.

Los estudios habituales son:

- **Exploración** de una variable con colas pesadas (personas afectadas).
- **Series temporales**: evolución del número de brechas.
- **Tablas de contingencia**: tipo de brecha frente a lugar de los datos.

- **Minería de textos** con los resúmenes (add-on *Text*).

2 Contexto y fuente original

Los registros tienen el formato del portal de brechas de la Oficina de Derechos Civiles del Departamento de Salud de Estados Unidos (HHS), donde las entidades sanitarias deben notificar las brechas que afectan a 500 personas o más. Orange cita como fuente el artículo de **Benjamin Edwards, Steven Hofmeyr y Stephanie Forrest** (2016), que analizó brechas de datos en Estados Unidos y concluyó que su tamaño sigue distribuciones de colas pesadas y que no hay una tendencia clara al alza, pese a lo que sugieren los titulares.

- Edwards, B., Hofmeyr, S. y Forrest, S. (2016). Hype and Heavy Tails: A Closer Look at Data Breaches. Journal of Cybersecurity, 2(1), 3–14.

3 Variable objetivo

No tiene variable objetivo. Las personas afectadas van de 500 a 4,9 millones, con **mediana de 2.300** y media de 30.000: unas pocas brechas enormes (TRICARE, 4,9 millones; Advocate Health, 4,0 millones) pesan más que cientos de pequeñas. El tipo más común es el **robo** (516), sobre todo de portátiles y papeles, muy por delante del pirateo informático (75) en estos años.

4 Diccionario de columnas

Columnas de `cyber_security_breaches` (valores observados en el fichero)

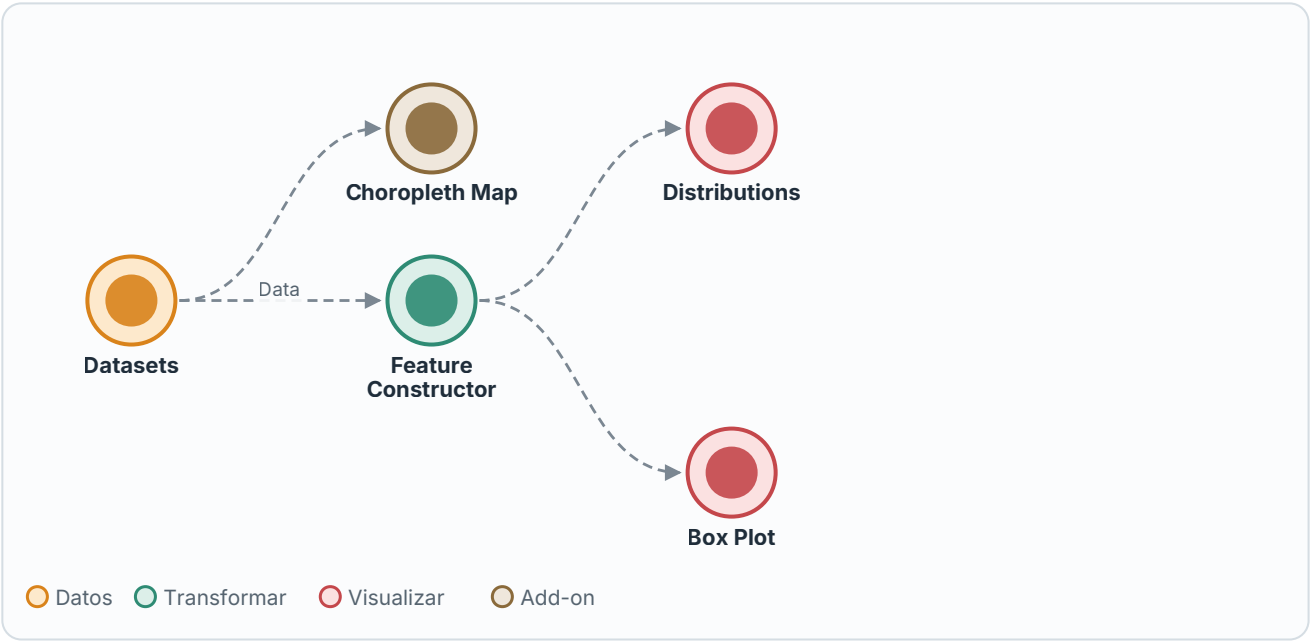
Columna	Tipo	Significado	Valores
`Name_of_Covered_Entity`	texto	Entidad sanitaria afectada (meta).	UnitedHealth Group health plan single affiliated covered … (7), Walgreen Co. (4), Cook County Health & Hospitals System (4), University of California, San Francisco (4), Utah Department of Health (3), Montefiore Medical Center (3) …
`US State`	categórica	Estado (52 valores, con Washington D. C. y Puerto Rico).	CA (113), TX (83), FL (66), NY (58), IL (49), PA (40) …
`Business_Associate_Involved`	texto	Proveedor implicado, si lo hubo (meta). 784 vacíos.	MedAssets (6), StayWell Health Management, LLC (5), Futurity First Insurance Group (4), Clearpoint Design, Inc. (4), HealthPartners Administrators, Inc. (3), ZDI (3) …
`Individuals_Affected`	numérica	Personas cuyos datos se vieron afectados (500 a 4,9 millones).	500 – 4.900.000
`Type_of_Breach`	categórica	Tipo de brecha. **28 valores**, porque las combinaciones aparecen como valores propios (`Theft, Loss`).	Theft (516), Unauthorized Access/ Disclosure (150), Other (91), Loss (85), Hacking/IT Incident (75), Improper Disposal (38) …

Columna	Tipo	Significado	Valores
`Location_of_Breached_Information`	categórica	Dónde estaba la información: `Paper`, `Laptop`, `Desktop Computer`, `Network Server`, `E-mail`… **41 valores** por las combinaciones.	Paper (227), Laptop (217), Other (116), Desktop Computer (113), Network Server (107), Other Portable Electronic Device (60) …
`Date_Posted_or_Updated`	fecha/hora	Fecha de publicación o actualización en el portal. **691 registros tienen la misma fecha** (2014-01-23).	2014-01-23 (691), 2014-03-24 (48), 2014-04-21 (28), 2014-04-23 (25), 2014-02-12 (21), 2014-06-19 (21) …
`Summary`	texto	Resumen del caso en texto (meta). Solo 142 registros lo tienen.	texto libre (mediana de 119 palabras)
`breach_start`	fecha/hora	Fecha de inicio de la brecha (1997–2014).	2012-06-15 (8), 2012-01-11 (7), 2011-06-24 (7), 2011-03-10 (6), 2009-09-27 (6), 2013-09-20 (6) …
`breach_end`	fecha/hora	Fecha de fin de la brecha. 910 vacíos.	2012-10-01 (11), 2012-10-27 (3), 2012-11-15 (3), 2012-09-21 (2), 2012-04-02 (2), 2013-08-15 (2) …

5 Particularidades técnicas al modelar

- **Colas muy pesadas**: la media no representa nada (30.000 frente a una mediana de 2.300). Usa el logaritmo de las personas afectadas para cualquier gráfico o modelo.
- **Categorías combinadas**: `Type_of_Breach` y `Location_of_Breached_Information` tienen valores como `Theft, Loss` o `Laptop, Desktop Computer`. Para contar bien hay que separarlos (con *Feature Constructor* o fuera de Orange).
- **Fechas de publicación poco útiles**: casi dos tercios se publicaron o actualizaron el mismo día; para estudiar la evolución en el tiempo, usa `breach_start`.
- **Umbral de 500 personas**: las brechas más pequeñas no se notifican en este portal; la distribución está cortada.
- **Huecos**: el fin de la brecha falta en 910 de 1.055 casos y el resumen en 913.

6 Flujo de trabajo en Orange



1. **Datasets** → «Cyber Security Breaches».
2. **Feature Constructor**: `log10(Individuals_Affected)`.
3. **Distributions**: compara la variable original con la transformada.
4. **Box Plot** del logaritmo por `Type_of_Breach` (agrupando los tipos menos frecuentes).
5. **Choropleth Map** (add-on *Geo*) con el número de brechas por estado.

7 Otras consideraciones

- **Texto**: los resúmenes se pueden analizar con el add-on *Text* (palabras más frecuentes por tipo de brecha).
- **Relativizar por población**: California y Texas tienen más brechas porque tienen más habitantes y entidades; para comparar estados hay que dividir.

En la carpeta `cyber_security_breaches` ← `cyber-security-breaches.tab` (datasets.biolab.si)

6.17
No supervisado: clustering, exploración y datos geográficos

Philadelphia crime

`06_exploracion_clustering_geo/philadelphia_crime/`

9.666 delitos registrados en Filadelfia entre 2006 y 2016, con fecha y hora, tipo y coordenadas: datos espaciales y temporales para mapas y patrones.

Exploración y visualización · Clustering · Espacial · Mixto num. + cat. · Temporal

En el curso: Actividad 5.3 (Tema 5, datos espacio-temporales): mapa de delitos por tipo con Geo Map desde el widget Datasets.

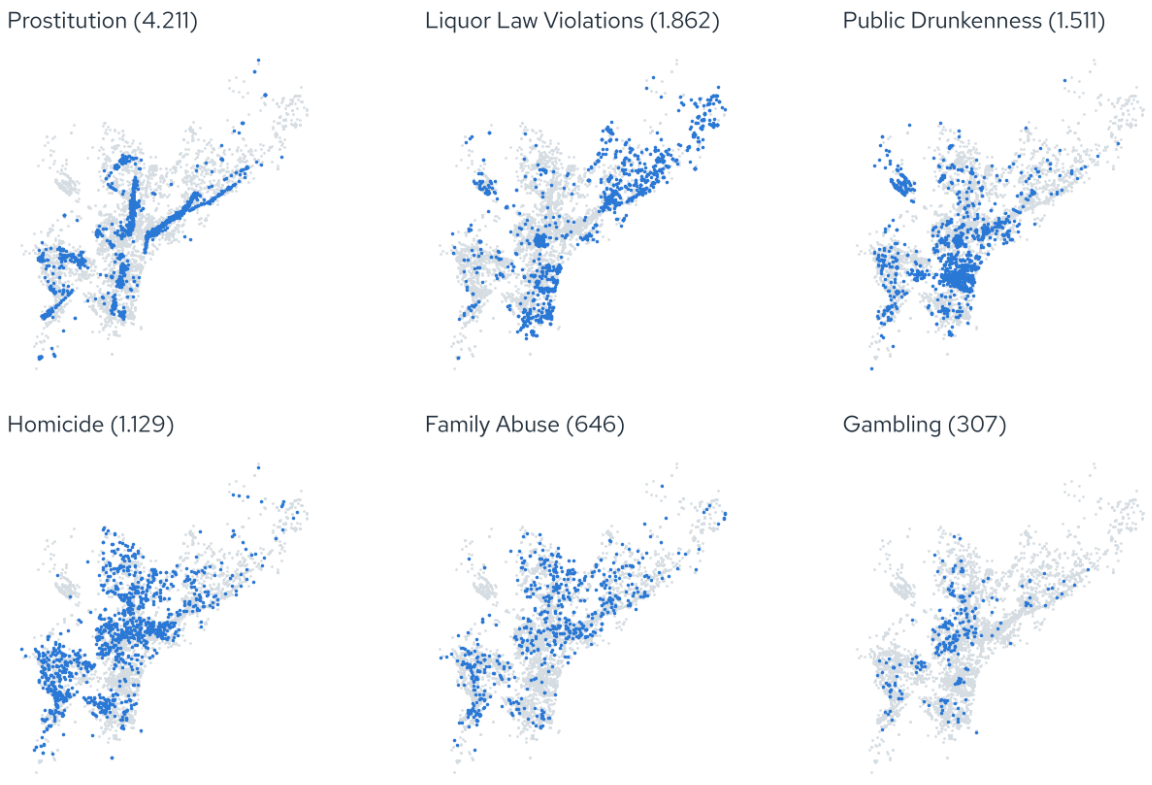
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
9.666	**4**	–	**0,0 %**	**Iniciación**	**Geo**

Fichero	Filas × col.	Descargar
`philadelphia_crime`	9.666 × 4	CSV 575 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/philadelphia_crime/` seguido del nombre del fichero CSV.

Radiografía

Dónde ocurre cada tipo de delito (en gris, todos los demás)



1 Descripción general y estudios habituales

Cada fila es un delito registrado en la ciudad de Filadelfia (Estados Unidos), con su fecha y hora, su tipo y la longitud y latitud del lugar. Hay seis tipos: prostitución, infracciones de la ley de alcohol, embriaguez en la vía pública, homicidio, violencia familiar y juego ilegal.

Es el dataset de referencia en Orange para practicar con **datos espaciales y temporales** sin complicaciones: cuatro columnas, coordenadas listas para el mapa y una fecha que se puede descomponer. Los estudios habituales son:

- **Mapear** los delitos por tipo y descubrir zonas donde se concentra cada uno.
- **Analizar el tiempo**: a qué horas, días de la semana o meses ocurren, y cómo cambian a lo largo de los años.
- **Agrupar espacialmente** (clustering con DBSCAN o k-means sobre las coordenadas) para encontrar focos.
- **Clasificar el tipo** de delito a partir del lugar y la hora, como ejercicio de ingeniería de atributos.

2 Contexto y fuente original

El dataset viene en el widget *Datasets* de Orange con la descripción «datos de actos delictivos menores en Filadelfia» y sin fuente indicada. Orange lo usa en la documentación del widget *Geo Map* y en entradas de su blog, que lo describen como los delitos de la ciudad de 2006 a 2016.

Su origen más probable es el conjunto abierto *Crime Incidents* del Departamento de Policía de Filadelfia, publicado en OpenDataPhilly, que cubre desde 2006 con la fecha, el tipo y las coordenadas de cada incidente. Orange no lo indica, así que es una deducción. En cualquier caso, **no son todos los delitos**: es una selección de seis tipos y, por las cifras (por ejemplo, unos 100 homicidios al año, bastantes menos de los que registró la ciudad en esos años), probablemente una muestra.

Pese a la descripción, no todo son delitos menores: el 11,7 % de las filas son homicidios.

- Documentación del widget Geo Map de Orange, que usa este dataset
- «What is Machine Anthropology?», blog de Orange (2020), con este dataset
- Crime Incidents en OpenDataPhilly (origen probable, no confirmado por Orange)

3 Variable objetivo

No tiene variable objetivo definida: es un dataset para explorar. Si se quiere clasificar, el objetivo natural es `Type`, el tipo de delito: prostitución (4.211 casos, 43,6 %), infracciones de la ley de alcohol (1.862, 19,3 %), embriaguez pública (1.511, 15,6 %), homicidio (1.129, 11,7 %), violencia familiar (646, 6,7 %) y juego ilegal (307, 3,2 %).

La hora es muy reveladora: los registros se concentran entre las 20:00 y las 2:00, con el máximo a las 22:00, y caen al mínimo a primera hora de la mañana.

4 Diccionario de columnas

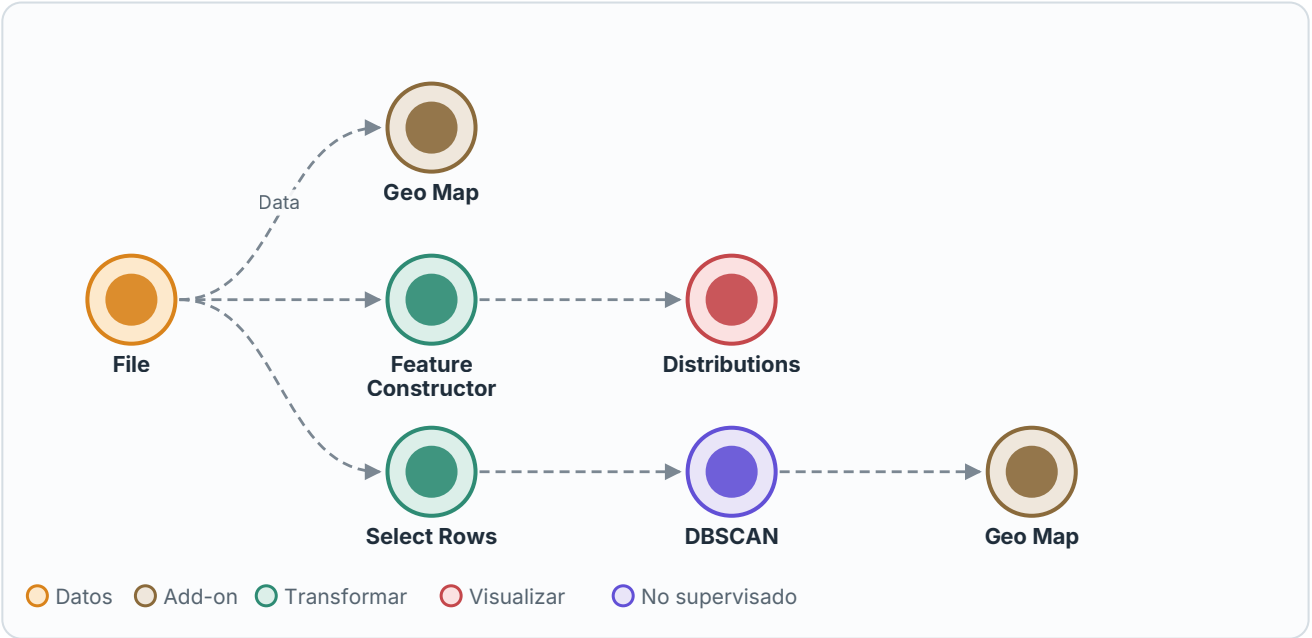
Columnas de `philadelphia_crime` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Datetime`	fecha/hora	Fecha y hora del delito (de 2006-01-01 a 2016-11-07).	2010-05-01 16:36:00 (7), 2013-09-21 20:05:00 (5), 2012-06-14 22:53:00 (5), 2009-02-11 22:17:00 (4), 2009-03-10 23:21:00 (4), 2009-12-26 22:07:00 (4) …
Type	categórica	Tipo de delito: `Prostitution`, `Liquor Law Violations`, `Public Drunkenness`, `Homicide`, `Family Abuse` o `Gambling`.	Prostitution (4.211), Liquor Law Violations (1.862), Public Drunkenness (1.511), Homicide (1.129), Family Abuse (646), Gambling (307)
Lon	numérica	Longitud del lugar, en grados (WGS84).	-75,268 – -74,958
Lat	numérica	Latitud del lugar, en grados (WGS84).	39,876 – 40,133

5 Particularidades técnicas al modelar

- **Orange reconoce la fecha** al abrir el CSV (`Datetime` como variable de tiempo). Para usar la hora o el día de la semana como atributos hay que crearlos con *Feature Constructor* a partir de `Datetime`; Orange guarda las fechas como segundos desde 1970, así que la hora se obtiene con aritmética sobre ese número.
- **Coordenadas repetidas**: la mitad de las filas comparten el punto exacto con otra, porque los incidentes se sitúan en el centro de la manzana o del cruce. En el mapa, muchos puntos quedan unos encima de otros: baja la opacidad o usa un mapa de calor para ver la densidad real.
- **Filas idénticas**: 296 filas repiten fecha, hora, tipo y lugar de otra. Pueden ser varios delitos en el mismo hecho o duplicados de registro; decide si quitarlas antes de contar.
- **2016 está incompleto** (termina el 7 de noviembre): no compares su total con el de los otros años sin ajustar.
- **Clases desequilibradas** si se usa `Type` como objetivo: el juego ilegal es el 3,2 %.
- **Los datos policiales reflejan dónde se patrulla y se registra**, no solo dónde se delinque. Delitos como la prostitución o la embriaguez pública dependen mucho de la presencia policial.

6 Flujo de trabajo en Orange



1. **File** (o **Datasets** → «Philadelphia Crime»).

2. **Geo Map** (add-on *Geo*): latitud y longitud en sus campos, color por `Type` y opacidad baja. Prueba *Show color regions* para ver qué tipo domina en cada zona.
3. **Feature Constructor**: crea la hora y el día de la semana a partir de `Datetime` → **Distributions** por hora, coloreado por `Type`.
4. **Select Rows** (un solo tipo, por ejemplo homicidios) → **DBSCAN** sobre `Lon` y `Lat` → **Geo Map** coloreado por el grupo: aparecen los focos.

7 Otras consideraciones

- **Ejercicio de ingeniería de atributos**: predecir el tipo de delito con el lugar y la hora mejora mucho al añadir la hora del día y el día de la semana; sin ellos, el modelo solo «ve» el mapa.
- **Mapas en PDF**: *Geo Map* permite exportar la imagen en formato vectorial para informes.
- **Ética y sesgo**: un modelo entrenado con datos policiales tiende a reproducir dónde se ha vigilado más. Es un buen ejemplo para discutir la «policía predictiva».
- Para datos actualizados y con todos los tipos de delito, el conjunto completo de OpenDataPhilly tiene millones de filas.

En la carpeta `philadelphia_crime` ← `philadelphia-crime.csv.xz` (datasets.biolab.si)

6.18

No supervisado: clustering, exploración y datos geográficos

EWBA: vertederos ilegales en Eslovenia

`06_exploracion_clustering_geo/ewba_illegal_dumpsites/`

13.165 vertederos ilegales de Eslovenia registrados por voluntarios, con su ubicación, acceso, superficie, volumen y tipos de residuos: un dataset geográfico grande, con muchos huecos y porcentajes que no siempre suman 100.

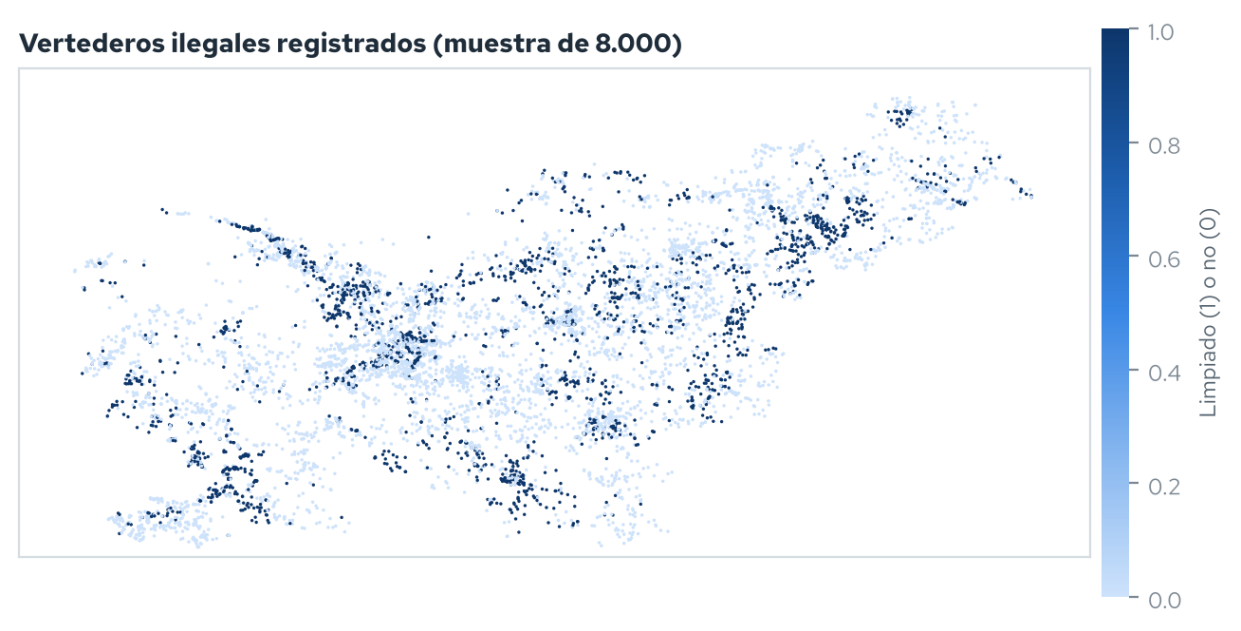
Exploración y visualización · Clustering · Espacial · ? Valores faltantes · Grande · Mixto num. + cat. · Temporal

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
13.165	**29**	–	**22,9 %**	**Intermedio**	**Geo**

Fichero	Filas × col.	Descargar
`ewba_illegal_dumpsites`	13.165 × 29	CSV 2,9 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/ewba_illegal_dumpsites/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Cada fila es un **vertedero ilegal** registrado en Eslovenia: su posición, si ya se ha limpiado, cómo se accede (en coche, todoterreno, a pie…), a qué distancia está de la carretera, el tipo de terreno, la superficie y el volumen

de residuos, el **porcentaje de cada tipo de residuo** (orgánico, de obra, mezclado, voluminoso, neumáticos, vehículos, peligrosos, placas de amianto), si hay bidones con líquidos peligrosos o residuos enterrados, el municipio, una valoración de su importancia y las fechas de registro y de última modificación.

Los estudios habituales son:

- **Mapas** de los vertederos y de su composición (add-on *Geo*).
- **Agrupamiento** de vertederos por tipo de residuos.
- **Clasificación**: qué vertederos se han limpiado.

2 Contexto y fuente original

Los datos proceden del registro de vertederos ilegales de la asociación **Ecologistas sin Fronteras** (*Ekologi brez meja*), que organiza la campaña ciudadana **Očistimo Slovenijo** (Limpiemos Eslovenia). Voluntarios localizaron y describieron los vertederos; el 65 % de los registros se creó un mismo día (28 de marzo de 2010), en la preparación de la gran jornada de limpieza de ese año. El equipo de **Orange** tradujo las columnas al inglés en 2017.

- Register divjih odlagališč (Očistimo Slovenijo / Ekologi brez meja)

3 Variable objetivo

No tiene variable objetivo; `Was cleaned` (si el vertedero se limpió, 29 %) puede hacer de clase. La mayoría son pequeños (mediana de 20 m² de superficie) y accesibles en coche (63 %). Ljubljana es el municipio con más vertederos (1.176), seguido de Koper, Novo mesto y Kočevje.

4 Diccionario de columnas

Columnas de `ewba_illegal_dumpsites` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Geopedia URL`	texto	Enlace a la ficha del vertedero en Geopedia (meta).	URL (13.165 distintas), p. ej. www.geopedia.si/?params=T1199_L6357_F4
`ID`	numérica	Identificador del registro (meta).	4 – 16.946
`Latitude [°]`	numérica	Latitud.	45,427 – 46,856
`Longitude [°]`	numérica	Longitud.	13,433 – 16,521
`Was cleaned`	categórica	Si el vertedero se ha limpiado (1) o no (0).	0 (9.368), 1 (3.797)
`Name`	texto	Nombre o descripción breve (meta, texto libre en esloveno). 7.596 vacíos.	(no se muestran)
`Access type`	categórica	Acceso: `Private car` en coche, `Off-road` todoterreno, `On foot` a pie, `Unsafe access` peligroso, `Inaccessible`.	Private car (8.271), Off-road (2.734), On foot (1.878), Unsafe access (258), Inaccessible (24)

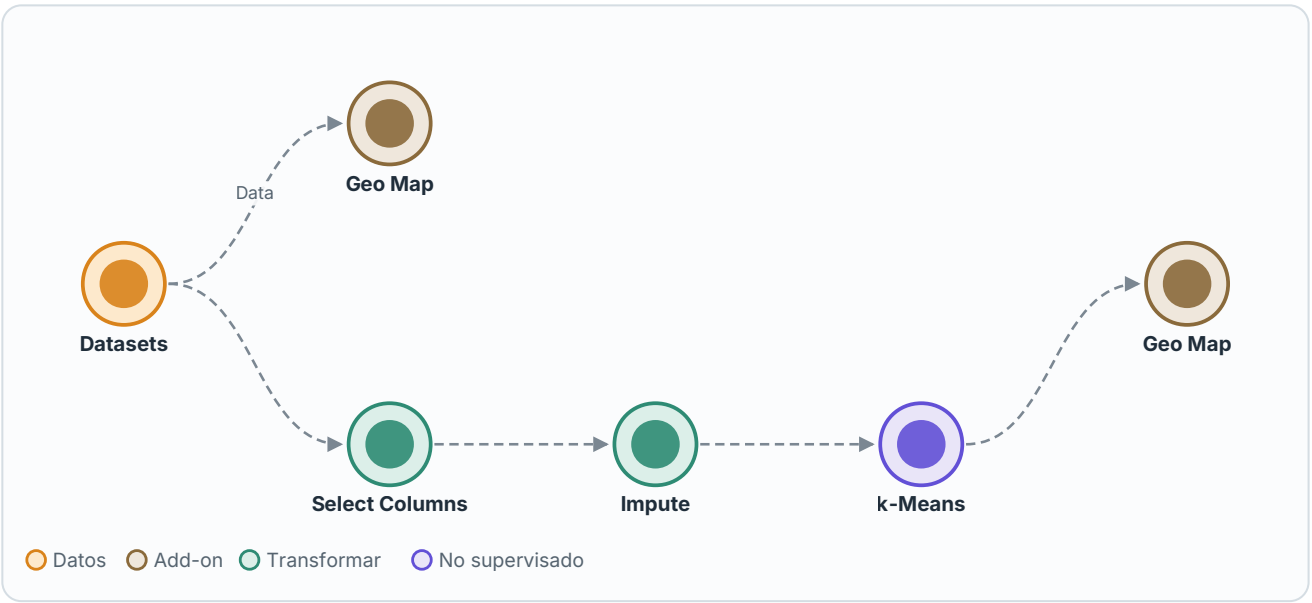
Columna	Tipo	Significado	Valores
`Distance from the road [m]`	numérica	Distancia a la carretera (m).	0 – 3.000
`Location type`	categórica	Terreno: `Plane` llano, `Slope` pendiente, `Basin` hondonada.	Plane (6.986), Slope (4.198), Basin (1.981)
`Waste area [m²]`	numérica	Superficie con residuos (m²), de 0 a 200.000.	0 – 200.000
`Waste volume [m³]`	numérica	Volumen de residuos (m³). **Son categorías** (1, 2, 10, 25, 50, 100, 250, 500, 1.000, 1.500), no medidas.	1 – 1.500
`Organic waste [%]`	numérica	Porcentaje de residuos orgánicos. Igual para obra, mezclados, voluminosos, neumáticos, vehículos, peligrosos y amianto. Muchos vacíos.	0 – 100
`Barrels with hazardous/ unknown liquid`	categórica	Si hay bidones con líquidos peligrosos o desconocidos (0/1).	0 (13.112), 1 (53)
`Description/quantity of hazardous waste`	texto	Descripción de los residuos peligrosos (meta, texto en esloveno: `salonitne plošče`, placas de fibrocemento…).	salonitne plošče (75), salonitke (58), pnevmatike (42), Salonitne plošče (35), Salonitne plošče. (33), gume (26) …
`Waste partially buried?`	categórica	Si hay residuos enterrados (0/1).	0 (12.898), 1 (267)
`Municipality`	texto	Municipio (meta).	Ljubljana (1.176), Koper (384), Novo mesto (353), Kočevje (320), Kranj (237), Trbovlje (233) …
`Land registry property ID`	texto	Parcela catastral (meta).	(no se muestran)
`Importance assessment`	numérica	Valoración de la importancia del vertedero (0–245). 1.342 vacíos.	0 – 245
`IRSOP`	categórica	Unidad regional (9 valores: Ljubljana, Maribor, Celje, Novo Mesto, Koper…).	Ljubljana (4.498), Maribor (1.768), Celje (1.599), Novo Mesto (1.362), Koper (1.240), Kranj (1.121) …
`Duty of Slovenia Forest Service`	categórica	Si es competencia del Servicio Forestal (0/1).	0.0 (9.067), 1.0 (3.890)

Columna	Tipo	Significado	Valores
`Entry creation date`	fecha/hora	Fecha de registro (2010–2017).	2010-03-28 (8.495), 2010-04-18 (1.027), 2010-04-03 (307), 2010-04-04 (248), 2011-02-04 (107), 2010-04-01 (88) …
`Last modification date`	fecha/hora	Fecha de la última modificación.	2011-02-04 (4.274), 2011-09-15 (926), 2010-04-18 (465), 2012-07-12 (265), 2011-04-18 (130), 2011-04-15 (125) …
…		y 7 columnas más de porcentajes por tipo de residuo, con el mismo formato.	

5 Particularidades técnicas al modelar

- **Huecos que pueden significar 0**: en los porcentajes por tipo de residuo, un vacío puede ser «no hay» o «no se anotó» (neumáticos: 12.443 vacíos). Imputar con la media inventa residuos.
- **Porcentajes que no suman 100**: en el 93,5 % de los vertederos con datos suman 100, pero hay sumas de 0 y hasta de 350. Conviene filtrarlos o normalizar.
- **Volumen en categorías**: `Waste volume [m³]` tiene solo 10 valores; mejor tratarlo como ordinal.
- **Superficie muy asimétrica**: de 0 a 200.000 m² con mediana de 20 m². Usa el logaritmo.
- **Fechas concentradas**: el 65 % de los registros es del mismo día, así que la fecha de registro no sirve para ver tendencias.
- **Texto libre en esloveno** en el nombre y en la descripción de los residuos peligrosos. En el libro no se muestran el nombre ni la parcela catastral.

6 Flujo de trabajo en Orange



1. **Datasets** → «Illegal waste dumpsites in Slovenia».
2. **Geo Map** (add-on *Geo*): los vertederos sobre el mapa, coloreados por `Was cleaned`.
3. **Select Columns**: deja los porcentajes por tipo de residuo; **Impute** con valor fijo 0.

4. **k-Means** (k = 4–6): grupos como «obra», «mezclado», «voluminoso», «amianto».
5. **Geo Map** coloreado por grupo: ¿hay zonas con un tipo de vertedero característico?

7 Otras consideraciones

- **Clasificación**: predecir `Was cleaned` con el acceso, la distancia a la carretera y el tamaño ayuda a entender qué vertederos se limpian primero.
- **Unir con Slovenska naselja** por municipio para relacionar vertederos y población.

En la carpeta `ewba_illegal_dumpsites` ← `ewba-slovenia-illegal-dumpsites.tab` (datasets.biolab.si)

6.19

No supervisado: clustering, exploración y datos geográficos

Accidentes de tráfico en Eslovenia 2016

`06_exploracion_clustering_geo/slovenia_traffic_accidents/`

Todos los accidentes de tráfico registrados por la policía eslovena en 2016 (17.931) y las 32.857 personas implicadas, en dos tablas relacionadas y con las columnas en esloveno: exploración, mapas y unión de tablas.

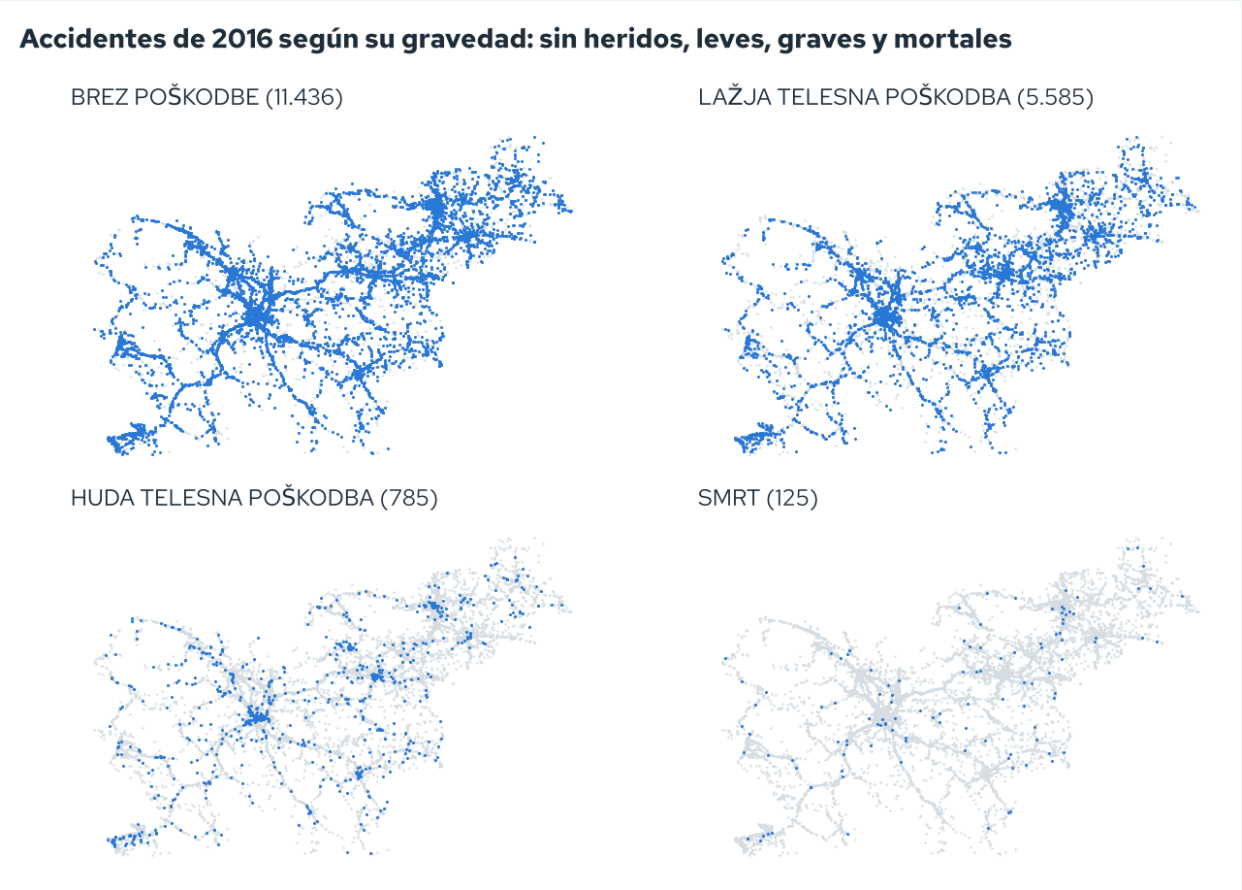
Exploración y visualización · Clustering · Espacial · ? Valores faltantes · Grande · Mixto num. + cat. · Temporal

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
17.931	**21**	–	**0,3 %**	**Intermedio**	**Geo**

Fichero	Filas × col.	Descargar
`slovenia_traffic_accidents_events`	17.931 × 21	CSV 4,5 MB · XLSX
`slovenia_traffic_accidents_persons`	32.857 × 13	CSV 2,8 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/slovenia_traffic_accidents/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Dos tablas del Ministerio del Interior de Eslovenia sobre los accidentes de tráfico de 2016:

- **Accidentes** (`events`): una fila por accidente con su gravedad, la unidad administrativa, la fecha y la hora, si ocurrió en zona urbana, el tipo de vía, la calle o carretera, la causa, el tipo de accidente, el tiempo, el estado del tráfico y de la calzada, y las coordenadas.
- **Personas** (`persons`): una fila por persona implicada, con el número del accidente, si lo causó, su edad, sexo, lugar de residencia, nacionalidad, lesiones, su papel (conductor, pasajero, ciclista, peatón…), si llevaba cinturón, los años de carné y el resultado de las pruebas de alcohol.

Las dos tablas se relacionan por el número del caso (`FIOStevilkaZadeve`). Las columnas y los valores están en esloveno.

Los estudios habituales son:

- **Exploración** de accidentes por hora, día, tipo de vía y tiempo.
- **Mapas** de accidentes y de su gravedad (add-on *Geo*).
- **Unión de tablas** y análisis de los conductores que causan los accidentes (edad, alcohol, experiencia).

2 Contexto y fuente original

Los datos son los que publica la **policía eslovena** en su archivo de estadísticas de seguridad vial, en este caso de 2016. El equipo de **Orange** los preparó para sus cursos, conservando los nombres originales en esloveno. No incluyen nombres ni datos que identifiquen directamente a las personas.

- Estadísticas de seguridad vial de la policía eslovena (Policija, Prometna varnost)

3 Variable objetivo

No tiene variable objetivo; la gravedad (`KlasifikacijaNesrece`) suele usarse como clase. De los 17.931 accidentes, 11.436 fueron sin heridos, 5.585 con heridos leves, 785 con heridos graves y **125 con muertos**. Fuera de las zonas urbanas, los accidentes mortales son proporcionalmente cinco veces más frecuentes (1,4 % frente a 0,3 %). La hora punta es por la tarde (de 14 a 16 h).

4 Diccionario de columnas

Columnas de `slovenia_traffic_accidents_events` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`FIOStevilkaZadeve`	numérica	Número del caso. **Es un identificador**, aunque Orange lo lee como número; une las dos tablas.	831.167 – 858.096
`KlasifikacijaNesrece`	categórica	Gravedad: `BREZ POŠKODBE` sin heridos, `LAŽJA TELESNA POŠKODBA` heridos leves, `HUDA TELESNA POŠKODBA` graves, `SMRT` muerte.	BREZ POŠKODBE (11.436), LAŽJA TELESNA POŠKODBA (5.585), HUDA TELESNA POŠKODBA (785), SMRT (125)
`UpravnaEnotaStoritve`	categórica	Unidad administrativa donde ocurrió (58). 39 vacíos.	LJUBLJANA (3.243), MARIBOR (1.820), KRANJ (811), PTUJ (795), CELJE (709), NOVO MESTO (616) …
`DatumPN`	fecha/hora	Fecha del accidente (2016).	2016-06-24 (92), 2016-03-18 (87), 2016-10-28 (83), 2016-09-09 (83), 2016-06-15 (82), 2016-09-30 (80) …
`UraPN`	numérica	Hora (0–23).	0 – 23
`VNaselju`	categórica	Si ocurrió en zona urbana (1) o no (0).	1 (12.052), 0 (5.879)
`VrstaCeste`	categórica	Tipo de vía: calle de núcleo urbano con o sin callejero, `AVTOCESTA` autopista, `HITRA CESTA` autovía, carretera principal (`GLAVNA`), regional, local o turística.	NASELJE Z ULIČNIM SISTEMOM (8.538), NASELJE BREZ ULIČNEGA SISTEMA (2.678), AVTOCESTA (1.781), REGIONALNA CESTA II. REDA (1.047), REGIONALNA CESTA I. REDA (850), GLAVNA CESTA II. REDA (767) …
`SifraCesteNaselja`	texto	Código de la carretera o del núcleo (meta).	25001 (2.317), 64033 (1.172), 000A1 (1.032), 000A2 (557), 03011 (422), 18035 (320) …

Columna	Tipo	Significado	Valores
TekstCesteNaselja	texto	Nombre de la carretera o del núcleo (meta).	LJUBLJANA (2.317), MARIBOR (1.172), ŠENTILJ-MB-CE-LJ-PO-SRMIN (1.032), KARAVANKE-LJ-NM-OBREŽJE (557), CELJE (422), KRANJ (320) …
SifraOdsekaUlice	numérica	Código del tramo o de la calle.	0 – 99.902
TekstOdsekaUlice	texto	Nombre del tramo o de la calle (meta).	NI ODSEKOV (3.243), LJUBLJANSKA CESTA (262), CELOVŠKA CESTA (232), TRŽAŠKA CESTA (226), ŠMARTINSKA CESTA (166), MARIBORSKA CESTA (136) …
StacionazaDogodka	numérica	Punto kilométrico del accidente (m).	0 – 30.500
Lokacija	categórica	Lugar: `CESTA` en la calzada, `NARAVNO OKOLJE` fuera de ella (entorno natural).	NARAVNO OKOLJE (11.216), CESTA (6.715)
VzrokNesrece	categórica	Causa: `PREMIKI Z VOZILOM` maniobras, `NEPRILAGOJENA HITROST` velocidad inadecuada, `NEPRAVILNA STRAN / SMER VOŽNJE` lado o dirección incorrectos, `NEUPOŠTEVANJE PRAVIL O PREDNOSTI` no respetar la prioridad, `NEUSTREZNA VARNOSTNA RAZDALJA` distancia de seguridad…	PREMIKI Z VOZILOM (4.099), NEPRILAGOJENA HITROST (3.371), NEPRAVILNA STRAN / SMER VOŽNJE (3.091), NEUPOŠTEVANJE PRAVIL O PREDNOSTI (2.612), OSTALO (2.089), NEUSTREZNA VARNOSTNA RAZDALJA (1.933) …
TipNesrece	categórica	Tipo: `BOČNO TRČENJE` colisión lateral, `TRČENJE V STOJEČE / PARKIRANO VOZILO` contra vehículo parado, `OPLAŽENJE` roce, `TRČENJE V OBJEKT` contra un objeto, `NALETNO TRČENJE` alcance, `ČELNO TRČENJE` frontal, `PREVRNITEV VOZILA` vuelco, `POVOŽENJE PEŠCA` atropello…	BOČNO TRČENJE (3.380), TRČENJE V STOJEČE / PARKIRANO VOZILO (2.776), OPLAŽENJE (2.291), TRČENJE V OBJEKT (2.249), NALETNO TRČENJE (2.008), OSTALO (1.684) …
VremenskeOkoliscine	categórica	Tiempo: `JASNO` despejado, `OBLAČNO` nublado, `DEŽEVNO` lluvia, `SNEG` nieve, `MEGLA` niebla, `NEZNANO` desconocido…	JASNO (9.780), OBLAČNO (5.342), DEŽEVNO (1.865), NEZNANO (458), SNEG (287), MEGLA (180) …
StanjePrometa	categórica	Tráfico: `NORMALEN` normal, `REDEK` escaso, `GOST` denso, `ZASTOJI` atascos, `NEZNANO`.	NORMALEN (10.324), REDEK (4.385), GOST (2.142), NEZNANO (1.029), ZASTOJI (51)

Columna	Tipo	Significado	Valores
StanjeVozisca	categórica	Calzada: SUHO seca, MOKRO mojada, SPOLZKO resbaladiza, nevada o helada (con o sin tratar)…	SUHO (12.876), MOKRO (4.067), SPOLZKO (448), OSTALO (253), SNEŽENO - NEPLUŽENO (128), SNEŽENO - PLUŽENO (73) …
VrstaVozisca	categórica	Firme: asfalto u hormigón rugoso (HRAPAV), pulido (ZGLAJEN) o irregular (NERAVEN), MAKADAM tierra…	HRAPAV ASFALT / BETON (11.680), ZGLAJEN ASFALT / BETON (5.728), MAKADAM (308), OSTALO (158), NERAVEN ASFALT / BETON (57)
GeoKoordinata X	numérica	Longitud. 619 vacíos.	13,482 – 16,522
GeoKoordinata Y	numérica	Latitud. 619 vacíos.	45,455 – 46,85

Columnas de slovenia_traffic_accidents_persons (valores observados en el fichero)

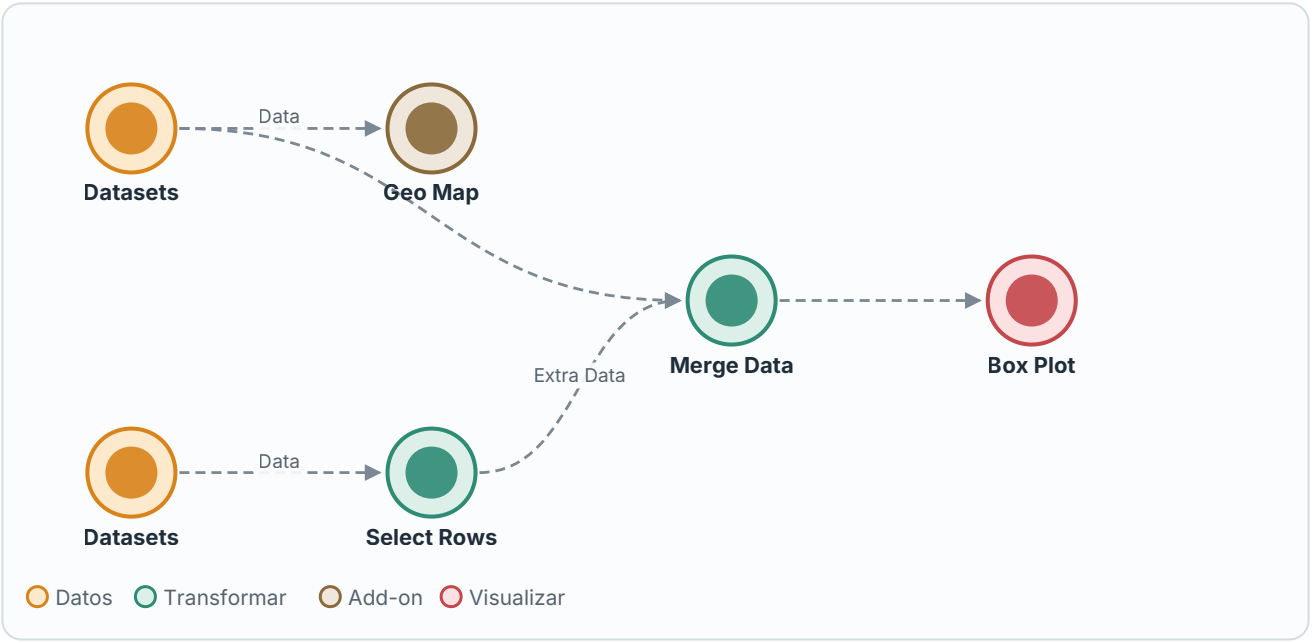
Columna	Tipo	Significado	Valores
FIOStevilkaZadeve	numérica	Número del caso del accidente (para unir con la otra tabla).	831.167 – 858.096
Povzrocitelj	categórica	Si la persona causó el accidente (1) o no (0).	0 (17.247), 1 (15.610)
StarostVLetih	numérica	Edad en años (0–103).	0 – 103
Spol	categórica	Sexo: M hombre, Z mujer (sin la Ž).	M (22.351), Z (10.506)
UEStalnegaPrebivalisca	categórica	Unidad administrativa de residencia. 10.263 vacíos; IZDANO V DRUGI DRŽAVI = residencia en otro país.	LJUBLJANA (3.064), MARIBOR (2.321), IZDANO V DRUGI DRŽAVI (1.130), PTUJ (1.079), NEZNANA OBČ (1.033), CELJE (880) …
Drzavljanstvo	categórica	Nacionalidad (en esloveno): SLOVENIJA , BOSNA IN HERCEGOVINA , HRVAŠKA …	SLOVENIJA (29.042), BOSNA IN HERCEGOVINA (763), HRVAŠKA (462), ITALIJA (287), ROMUNIJA (275), SRBIJA (250) …
PoskodbeUdelezenca	categórica	Lesiones de la persona (mismos valores que la gravedad del accidente, más BREZ POŠKODBE-UZ).	BREZ POŠKODBE (23.870), LAŽJA TELESNA POŠKODBA (7.606), HUDA TELESNA POŠKODBA (850), BREZ POŠKODBE-UZ (296), SMRT (130)

Columna	Tipo	Significado	Valores
VrstaUdelezenca	categórica	Papel: `VOZNIK OSEBNEGA AVTOMOBILA` conductor de turismo, `VOZNIK TOVORNEGA VOZILA` de camión, `POTNIK` pasajero, `KOLESAR` ciclista, `PEŠEC` peatón, `VOZNIK MOTORNEGA KOLESA` motorista…	VOZNIK OSEBNEGA AVTOMOBILA (23.192), VOZNIK TOVORNEGA VOZILA (2.376), POTNIK (1.977), OSTALO (1.522), KOLESAR (1.391), PEŠEC (714) …
UporabaVarnostnegaPasu	categórica	Si llevaba cinturón: `DA` sí, `NE` no, `NEZNANO` desconocido.	DA (26.330), NEZNANO (3.637), NE (2.785)
VozniskiStazVLetih	numérica	Años con carné de conducir (0 si no tiene o no aplica).	0 – 99
VozniskiStazVMesecih	numérica	Meses adicionales con carné (0–11).	0 – 11
VrednostAlkotesta	numérica	Resultado del alcoholímetro (g/kg). 9.562 vacíos (no se hizo la prueba).	0 – 3
VrednostStrokovnegaPregleda	numérica	Resultado del análisis de alcohol en sangre (g/kg). 9.562 vacíos.	0 – 4,47

5 Particularidades técnicas al modelar

- **Todo en esloveno**, columnas y valores: el diccionario de esta ficha traduce los principales.
- **Dos tablas, una relación de uno a muchos**: cada accidente tiene varias personas. Para relacionar la gravedad con los conductores hay que unirlas con **Merge Data** por `FIOStevilkaZadeve`.
- **El número de caso es un identificador**: Orange lo lee como número y lo usaría como atributo. Pásalo a meta.
- **Categorías desequilibradas**: los accidentes mortales son el 0,7 %; para clasificar la gravedad hay que tenerlo en cuenta.
- **Huecos con significado**: el alcohol solo se mide a algunas personas (vacío = no se hizo la prueba, no 0), y la residencia falta para muchos extranjeros.
- **Coordenadas ausentes** en 619 accidentes.
- **Personas jurídicas**: en `VrstaUdelezenca` aparecen algunas empresas y responsables (`PRAVNA OSEBA`, `ODGOVORNA OSEBA`), con edades y sexo poco significativos.

6 Flujo de trabajo en Orange



1. **Datasets** → «Traffic accidents - events» y «Traffic accidents - persons».
2. **Geo Map** de los accidentes coloreados por gravedad.
3. En personas, **Select Rows** con `Povzrocitelj` = 1 (los causantes).
4. **Merge Data**: añade a cada accidente los datos de su causante.
5. **Box Plot** de la edad o del alcohol según la gravedad; **Distributions** de la hora por tipo de vía.

7 Otras consideraciones

- **Series temporales**: con la fecha y la hora se ve el patrón semanal y diario (más accidentes los viernes y por la tarde).
- **Clasificación**: predecir si un accidente tendrá heridos graves o muertos con el tipo de vía, el tiempo y la causa, cuidando el desequilibrio.

En la carpeta `slovenia_traffic_accidents_events` ← `slovenia-traffic-accidents-2016-events.tab` (datasets.biolab.si)

En la carpeta `slovenia_traffic_accidents_persons` ← `slovenia-traffic-accidents-2016-persons.tab` (datasets.biolab.si)

6.20

No supervisado: clustering, exploración y datos geográficos

Renovables por país (Socioeconomic Indices, Banco Mundial)

`06_exploracion_clustering_geo/socioeconomic_renovables/`

Porcentaje de energía renovable en el consumo final de 54 países de Europa y Asia Central, 2010–2018: lo que devuelve el nodo Socioeconomic Indices de Orange, para practicar geocodificación y mapas de países.

Exploración y visualización · Clustering · Espacial · Juguete

> **En el curso:** Actividad 5.1 (Tema 5): Socioeconomic Indices → Geocoding → Choropleth Map, primero con la media 2010–2018 y después año a año.

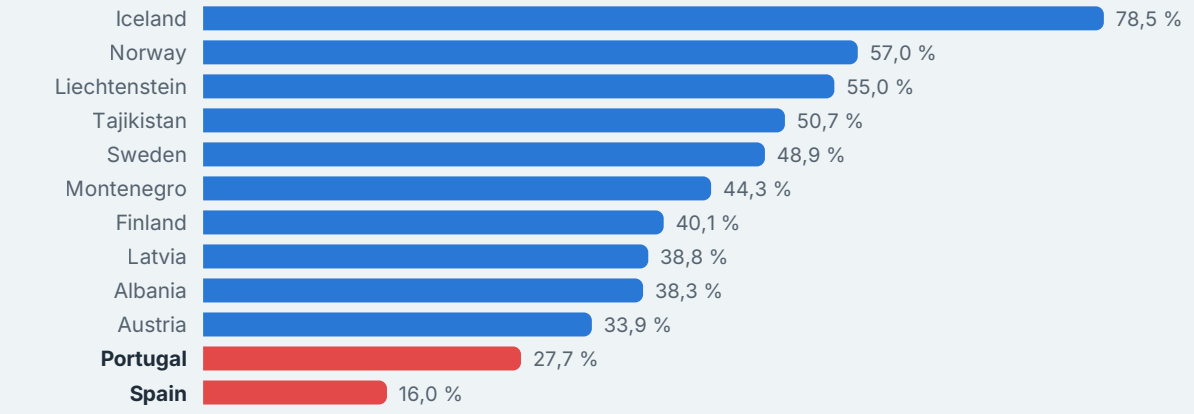
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
54	**3**	– (exploración)	**0,0 %**	**Iniciación**	**World Happiness y Geo**

Fichero	Filas × col.	Descargar
`renovables_eca_2010_2018_media`	54 × 3	CSV 1 KB · XLSX
`renovables_eca_2010_2018_por_anio`	54 × 11	CSV 3 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/socioeconomic_renovables/` seguido del nombre del fichero CSV.

Radiografía

Renovables en el consumo final de energía, media 2010–2018 (%): los 10 primeros, Portugal y España



1 Descripción general y estudios habituales

Es el indicador del Banco Mundial **EG.FEC.RNEW.ZS**, *consumo de energía renovable (% del consumo final total de energía)*, para los países de la región **Europa y Asia Central** entre 2010 y 2018. En clase no se cargó de un fichero: se descargó en directo con el nodo *Socioeconomic Indices* del add-on *World Happiness*.

Aquí van las dos salidas que da el nodo según la opción de agregación por años:

- `renovables_eca_2010_2018_media`: agregación *Mean*, una columna con la media de los nueve años.
- `renovables_eca_2010_2018_por_anio`: agregación *None*, una columna por año.

Los estudios habituales son:

- **Mapa de países** coloreado por el indicador (mapa de coropletas).
- **Evolución en el tiempo**: recorrer los años en el mapa o animarlo.
- **Agrupar países** por su perfil energético, o cruzarlo con otros indicadores del mismo nodo (PIB, emisiones…).

2 Contexto y fuente original

El add-on *World Happiness* (Orange3-WorldHappiness, del laboratorio de bioinformática de Liubliana) da acceso a indicadores de países de varias bases de datos abiertas, sobre todo los *World Development Indicators* (WDI) del Banco Mundial. El nodo descarga los datos de una base de datos propia del add-on, por eso necesita conexión a internet.

Cómo se ha obtenido este fichero. No se puede guardar la salida del nodo sin Orange, así que se ha reproducido su consulta con la API del Banco Mundial: el mismo indicador, los mismos años y los mismos 58 códigos de país que el add-on agrupa como *Europe & Central Asia*, descartando los países sin ningún dato y con los mismos nombres de columna. Los datos son la edición de los WDI del 8 de octubre de 2026, cuya fuente es la Agencia Internacional de la Energía.

Diferencias con lo que se vio en clase. En clase salieron 55 países, entre ellos Kosovo (`XKX`), que hizo fallar la geocodificación por código ISO. En la edición actual de los WDI, Kosovo, Mónaco, San Marino y las Islas del Canal no tienen datos de este indicador, así que aquí hay 54 países y Kosovo no aparece. Los valores también pueden diferir en décimas, porque los WDI se revisan cada año.

- Banco Mundial, World Development Indicators: EG.FEC.RNEW.ZS, Renewable energy consumption (% of total final energy consumption)
- Add-on Orange3-WorldHappiness (nodo Socioeconomic Indices)

3 Variable objetivo

No hay variable objetivo: es un dataset de exploración. La variable de interés es el **porcentaje de renovables**: `EG.FEC.RNEW.ZS` en el fichero de medias y `2010-EG.FEC.RNEW.ZS` … `2018-EG.FEC.RNEW.ZS` en el de años.

La media de 2010–2018 va del 0 % de Gibraltar al 78,5 % de Islandia, con mediana del 15,7 %. Lideran Islandia, Noruega, Liechtenstein, Tayikistán y Suecia; al final quedan los grandes productores de gas y petróleo (Turkmenistán, Uzbekistán, Kazajistán, Azerbaiyán y Rusia). España tiene un 16,0 % de media y Portugal un 27,7 %, con su máximo en 2014 (30,5 %), como se comentó en clase.

4 Diccionario de columnas

Columnas de `renovables_eca_2010_2018_media` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Country code`	texto	Código ISO de 3 letras del país (`ESP` , `PRT` …). En Orange es *meta*.	ALB (1), AND (1), ARM (1), AUT (1), AZE (1), BEL (1) …
`Country name`	texto	Nombre del país en inglés, como lo da el Banco Mundial (`Russian Federation` , `Turkiye` …).	Albania (1), Andorra (1), Armenia (1), Austria (1), Azerbaijan (1), Belgium (1) …
`EG.FEC.RNEW.ZS`	numérica	**Media 2010–2018 del porcentaje de energía renovable** en el consumo final total de energía.	0 – 78,478

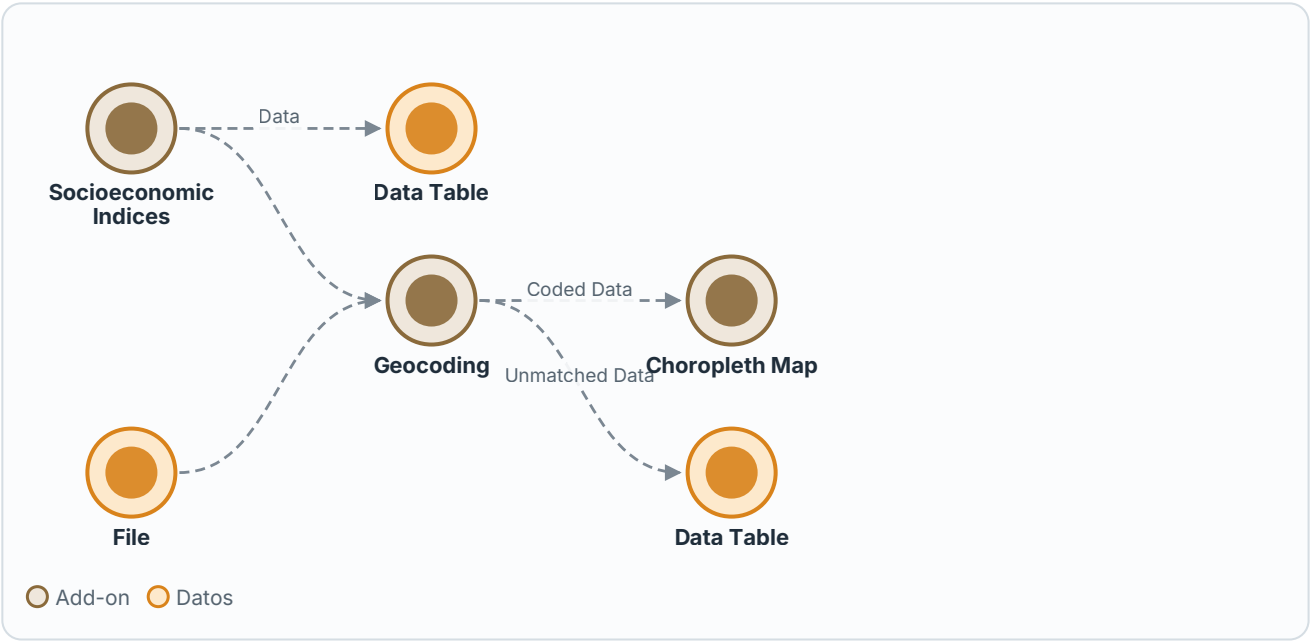
Columnas de `renovables_eca_2010_2018_por_anio` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Country code`	texto	Código ISO de 3 letras del país.	ALB (1), AND (1), ARM (1), AUT (1), AZE (1), BEL (1) …
`Country name`	texto	Nombre del país en inglés.	Albania (1), Andorra (1), Armenia (1), Austria (1), Azerbaijan (1), Belgium (1) …
`2010-EG.FEC.RNEW.ZS`	numérica	Porcentaje de renovables en 2010. Le siguen ocho columnas iguales, de 2011 a 2018, con el formato `año-indicador` que usa el nodo.	0 – 76
…		y 8 columnas más del mismo tipo que la anterior.	

5 Particularidades técnicas al modelar

- **No trae coordenadas**: conectar la tabla directamente a *Choropleth Map* no pinta nada. Hay que pasar antes por **Geocoding** (*Encode region names into coordinates*). En clase este error se provocó a propósito.
- **Geocodifica por nombre, no por código** si algún país da problemas: con el código ISO falló Kosovo (`XKX`), que no es un código ISO oficial. Revisa siempre la salida *Unmatched* del Geocoding.
- **El nodo necesita internet** y a veces lo bloquea el proxy de una red institucional (pasó en la UPO). Estos CSV sirven de alternativa sin conexión.
- En *Choropleth Map*, comprueba que *Values* sea el indicador y no la latitud o la longitud, y que latitud y longitud no estén cruzadas: si no, faltan países.
- **Pocos países y una sola variable**: para clustering hace falta añadir más indicadores en el propio nodo (en el filtro se pueden marcar varios).
- Los nombres de país del Banco Mundial no siempre coinciden con los de otros datasets (`Russian Federation` , `Slovak Republic` …): para unir tablas es más seguro usar el código ISO.

6 Flujo de trabajo en Orange



1. **Socioeconomic Indices**: región *Europe & Central Asia*, filtro «renew» y solo `EG.FEC.RNEW.ZS`, años 2010–2018 y *Aggregation by year* = *Mean* → *Send Selection*. Sin conexión: **File** con `renovables_eca_2010_2018_media`.
2. **Data Table**: un país por fila, con código y nombre.
3. **Geocoding** → *Encode region names into coordinates*, con `Country name` como nombre de país.
4. **Choropleth Map**: latitud, longitud y *Values* = el indicador. Revisa en *Unmatched Data* qué países no se han podido colocar.
5. **Año a año**: repite con agregación *None* (o con `renovables_eca_2010_2018_por_anio`) y, en *Choropleth Map*, cambia *Values* de un año a otro con las flechas del teclado.

7 Otras consideraciones

- **Animación**: pasando la tabla por años a formato largo (país, año, valor) se puede usar *Time Slice* para animar el mapa, como en la ficha de COVID-19.
- **Cruzar indicadores**: añade en el nodo el PIB por habitante o las emisiones de CO_2 y mira en un *Scatter Plot* si los países ricos tienen más renovables (en esta región, no necesariamente).
- **Cambio 2010–2018**: con *Feature Constructor*, resta 2018 menos 2010. La media de la región sube 2,4 puntos, pero algunos países bajan.
- Otras regiones del mismo nodo (*Latin America and the Caribbean*, *Africa*…) sirven para repetir el ejercicio con otro mapa.

En la carpeta `renovables_eca_2010_2018_media` ← `renovables_eca_2010_2018_media.csv` (derivado para este libro)

En la carpeta `renovables_eca_2010_2018_por_anio` ← `renovables_eca_2010_2018_por_anio.csv` (derivado para este libro)

6.21

No supervisado: clustering, exploración y datos geográficos

COVID-19: casos confirmados por país (JHU CSSE)

`06_exploracion_clustering_geo/covid19_jhu/`

Casos confirmados acumulados de COVID-19 por país y región, día a día de enero de 2020 a marzo de 2023: la serie de la Universidad Johns Hopkins, para mapas animados y análisis espacio-temporal.

Exploración y visualización · Predicción de series temporales · ⋮ Alta dimensionalidad · ⌖ Espacial · ? Valores faltantes · ◷ Temporal

> **En el curso:** Actividad 5.4 (Tema 5): mapa de países coloreado por casos, con Choropleth Map y con Time Slice. Quedó como opcional y no se hizo.

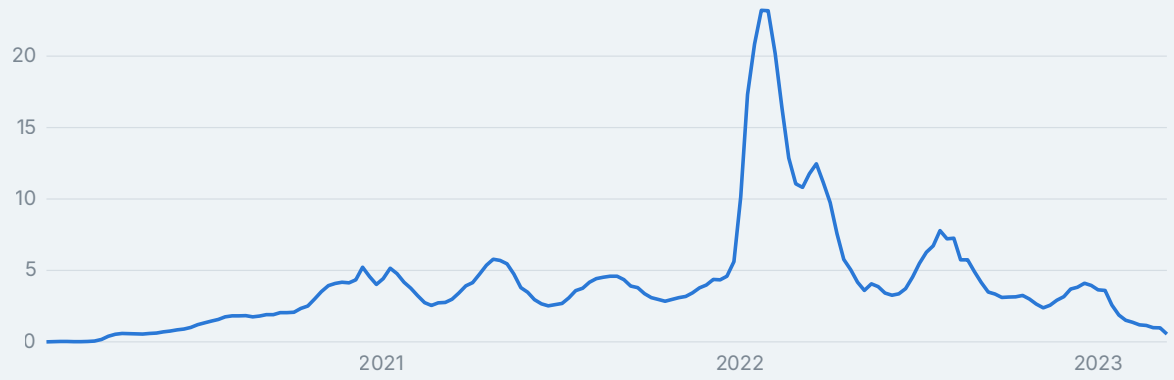
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
289	**1.147**	– (exploración)	**0,1 %**	**Intermedio**	**Geo y Timeseries**

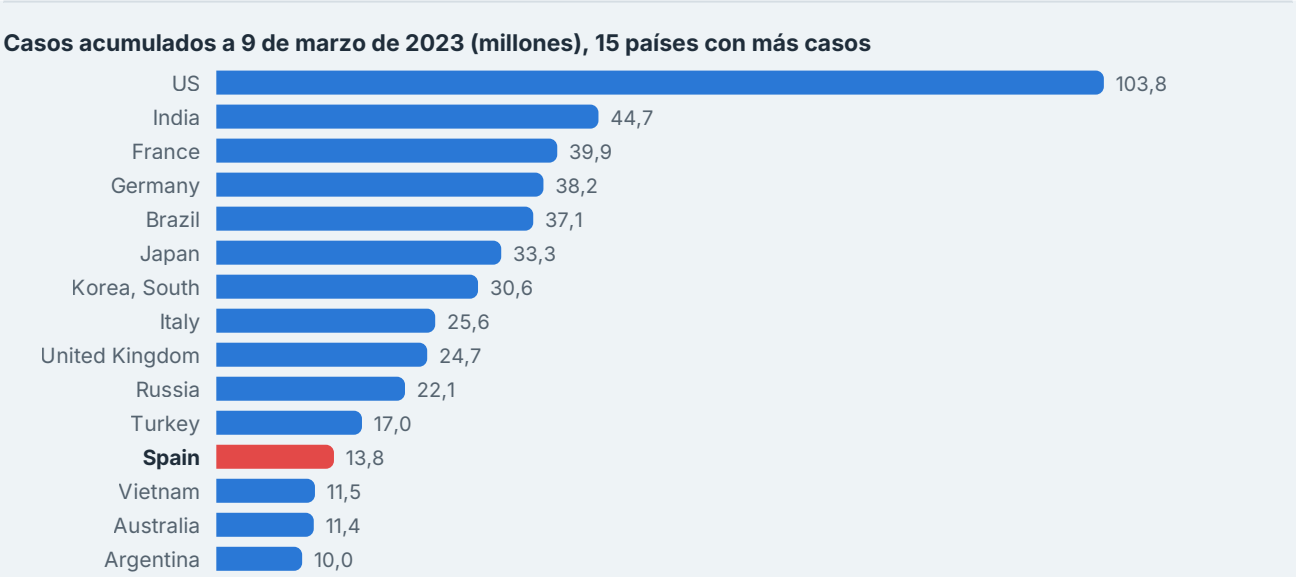
Fichero	Filas × col.	Descargar
`covid19_confirmados_global`	289 × 1.147	CSV 1,8 MB · XLSX
`covid19_confirmados_largo`	330.327 × 7	CSV 16,5 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/06_exploracion_clustering_geo/covid19_jhu/` seguido del nombre del fichero CSV.

Radiografía

Casos nuevos en el mundo por semana (millones)





1 Descripción general y estudios habituales

Es la tabla de **casos confirmados de COVID-19** que publicó el Centro de Ciencia e Ingeniería de Sistemas (CSSE) de la Universidad Johns Hopkins durante la pandemia. Cada fila es un país o una región (289 filas de 201 países y territorios) y cada columna es un día: 1.143 días, del 22 de enero de 2020 al 9 de marzo de 2023. El valor es el número **acumulado** de casos confirmados hasta ese día.

Aquí van dos ficheros: el original, en formato **ancho** (una columna por día), y una versión **larga** preparada para este libro (una fila por país y día, con los casos acumulados y los **nuevos casos** de cada día). Los estudios habituales son:

- **Mapas que cambian con el tiempo**: colorear los países por casos y animar la evolución.
- **Comparar curvas de países**, mejor en casos por habitante y en escala logarítmica.
- **Detectar olas** y su desfase entre regiones.
- **Practicar la transformación ancho ↔ largo**, que es imprescindible para usar los nodos de series temporales.

2 Contexto y fuente original

El repositorio de JHU CSSE alimentó el famoso panel de seguimiento de la pandemia. Reunía datos de la OMS, de los centros de control de enfermedades nacionales y de autoridades regionales, y se actualizó a diario hasta el **10 de marzo de 2023**, cuando dejó de recoger datos. El repositorio está archivado y sigue disponible en GitHub.

Las diapositivas del curso no indican de dónde sacar los datos. La actividad (mapa de países con *Choropleth Map*, directamente y con *Time Slice*) es la del blog de Orange *Data Mining COVID-19 Epidemics* (2020), que usa justamente este fichero. El gráfico de la diapositiva, con Estados Unidos en amarillo y la escala hasta 200.000, corresponde a esa época (abril de 2020).

Qué se ha preparado aquí. `covid19_confirmados_global` es el fichero original sin cambios. `covid19_confirmados_largo` lo pasa a formato largo y añade `nuevos_casos` (la diferencia con el día anterior). Las diapositivas hablan de «casos diarios reportados», pero el fichero original da casos acumulados; la columna nueva permite pintar los casos de cada día.

- JHU CSSE COVID-19 Data Repository (archivado en marzo de 2023): time_series_covid19_confirmed_global.csv

- Dong, E., Du, H. y Gardner, L. (2020). An interactive web-based dashboard to track COVID-19 in real time. The Lancet Infectious Diseases, 20(5), 533–534.
- «Data Mining COVID-19 Epidemics», partes 1 y 2, blog de Orange (2020)

3 Variable objetivo

No hay variable objetivo: es un dataset de exploración. La variable de interés son los **casos confirmados**: en el fichero ancho, cada columna de fecha; en el largo, `confirmados_acumulados` y `nuevos_casos`.

Al final de la serie suman 676,6 millones de casos. Los países con más casos son Estados Unidos (103,8 millones), India (44,7), Francia (39,9) y Alemania (38,2); España tiene 13,8. El máximo semanal mundial fue la semana que acabó el 23 de enero de 2022 (ola de ómicron), con 23,2 millones de casos nuevos.

4 Diccionario de columnas

Columnas de `covid19_confirmados_global` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Province/State`	texto	Provincia o región, solo en 8 países (Australia, Canadá, China, Dinamarca, Francia, Países Bajos, Nueva Zelanda y Reino Unido). Vacío en el resto.	Australian Capital Territory (1), New South Wales (1), Northern Territory (1), Queensland (1), South Australia (1), Tasmania (1) …
`Country/Region`	texto	País o territorio, con los nombres de JHU (`US`, `Korea, South`, `Taiwan*`, `Burma`…). Incluye dos cruceros y dos Juegos Olímpicos.	China (34), Canada (16), United Kingdom (15), France (12), Australia (8), Netherlands (5) …
`Lat`	numérica	Latitud del país o región. Vale 0 en los cruceros y falta en dos filas sin lugar («Repatriated Travellers» y «Unknown»).	-71,95 – 71,707
`Long`	numérica	Longitud. Igual que `Lat`.	-178,117 – 178,065
`1/22/20`	numérica	Una columna por día, del 22/01/2020 (`1/22/20`) al 09/03/2023 (`3/9/23`), en formato mes/día/año: casos confirmados **acumulados** hasta ese día.	0 – 444
…		y 1.142 columnas más del mismo tipo que la anterior.	

Columnas de `covid19_confirmados_largo` (valores observados en el fichero)

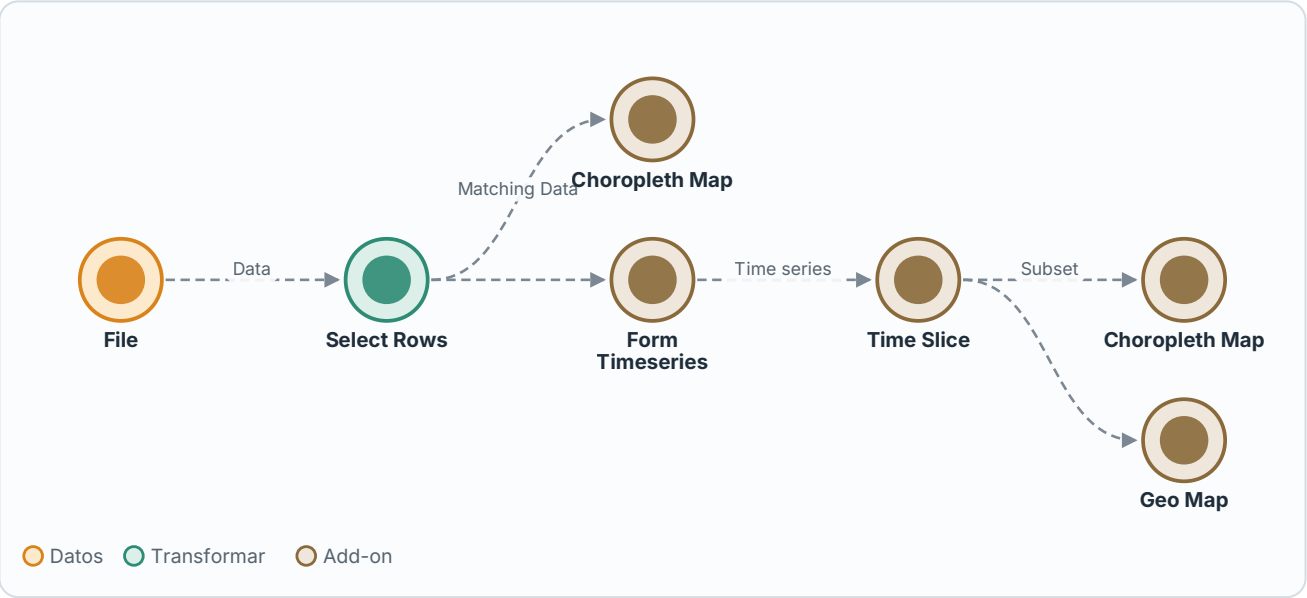
Columna	Tipo	Significado	Valores
`Country/Region`	texto	País o territorio (como en el fichero ancho).	China (38.862), Canada (18.288), United Kingdom (17.145), France (13.716), Australia (9.144), Netherlands (5.715) …

Columna	Tipo	Significado	Valores
`Province/State`	texto	Provincia o región, si la hay.	Australian Capital Territory (1.143), New South Wales (1.143), Northern Territory (1.143), Queensland (1.143), South Australia (1.143), Tasmania (1.143) …
`Lat`	numérica	Latitud.	-71,95 – 71,707
`Long`	numérica	Longitud.	-178,117 – 178,065
`date`	fecha/hora	Día (AAAA-MM-DD).	2020-01-22 (289), 2020-01-23 (289), 2020-01-24 (289), 2020-01-25 (289), 2020-01-26 (289), 2020-01-27 (289) …
`confirmados_acumulados`	numérica	Casos confirmados acumulados hasta ese día.	0 – 103.802.702
`nuevos_casos`	numérica	Casos nuevos ese día: diferencia con el día anterior. Vacío el primer día. Es negativo en 362 días, cuando una autoridad corrigió a la baja su cifra.	-349.116 – 1.354.505

5 Particularidades técnicas al modelar

- **Formato ancho**: los nodos de series temporales necesitan una fila por instante. Con el fichero original hay que usar *Transpose* (como en el blog de Orange) o directamente el fichero largo de esta carpeta.
- **Son acumulados, no casos del día**: colorear el mapa con una columna de fecha muestra el total hasta ese día. Para los casos diarios usa `nuevos_casos` del fichero largo, o resta dos columnas con *Feature Constructor*.
- **Los nombres de las columnas de fecha** (`1/22/20` …) Orange los lee como nombres de variables numéricas, no como fechas. Tras *Transpose*, la columna con esos nombres hay que convertirla en fecha con *Edit Domain*.
- **Países con varias filas**: Australia, Canadá, China, Francia, Reino Unido y otros vienen por provincias o territorios (Francia y Reino Unido incluyen sus territorios de ultramar). Para tener un valor por país hay que sumar con *Group By*. En *Choropleth Map*, la agregación *Sum* lo hace al pintar.
- **Filas que no son países**: los cruceros *Diamond Princess* y *MS Zaandam* (con coordenadas 0, 0), los Juegos de Tokio 2020 y Pekín 2022, la Antártida, y dos filas sin coordenadas. Conviene quitarlas antes de pintar.
- **Cifras no comparables**: dependen de cuánto testaba cada país y cuándo. Comparar casos absolutos entre países de distinto tamaño engaña; divide por la población (por ejemplo, uniendo con el dataset HDI con *Merge Data*, como en el blog de Orange) y usa escala logarítmica.
- **Correcciones a la baja**: 128 filas tienen algún día en que el acumulado baja (la mayor caída, 349.116 casos). En el fichero largo se ven como `nuevos_casos` negativos.

6 Flujo de trabajo en Orange



1. **File** con `covid19_confirmados_largo` (o con la URL del fichero).
2. **Select Rows**: quita los cruceros, los Juegos Olímpicos y las filas sin coordenadas.
3. **Opción 1, mapa estático**: filtra un día (*Select Rows* con `date`) → **Choropleth Map** con latitud y longitud, *Values* = `confirmados_acumulados` o `nuevos_casos` y agregación *Sum*.
4. **Opción 2, mapa animado**: **Form Timeseries** con `date` → **Time Slice** con una ventana de 7 días → **Choropleth Map** con *Values* = `nuevos_casos` y *Sum*. Abre a la vez Time Slice y el mapa y pulsa *play*.
5. **Geo Map** sobre la misma salida, con el tamaño del punto según los casos, para una vista por puntos.
6. Con el fichero ancho, el camino del blog de Orange es: *File* → *Transpose* (desde `Country/Region`) → *Edit Domain* (nombre de columna a fecha) → *Time Slice* → *Transpose* → *Choropleth Map*.

7 Otras consideraciones

- **Casos por millón de habitantes**: une con un dataset de población (el HDI de este libro trae la población de 2015) y compara países de verdad.
- **Curvas con Line Chart**: selecciona unos pocos países y mira las olas; en escala logarítmica se ve mejor el crecimiento exponencial del principio.
- **Muertes**: el mismo repositorio tiene `time_series_covid19_deaths_global.csv` con la misma estructura, para calcular la letalidad aparente por país y ola.
- Los datos terminan el 9 de marzo de 2023 y no se actualizarán: sirven para practicar, no para conclusiones actuales.

En la carpeta `covid19_confirmados_global` ← `time_series_covid19_confirmed_global.csv` (JHU CSSE COVID-19 (GitHub))

En la carpeta `covid19_confirmados_largo` ← `covid19_confirmados_largo.csv` (derivado para este libro)

7 Reglas de asociación (cesta de la compra)

3 datasets en el capítulo; en esta edición, 3 con ficha.

7.01
Reglas de asociación (cesta de la compra)

Market basket (ejemplo)

`07_reglas_asociacion/market_basket/`

Cinco cestas de la compra con seis productos (pan, leche, pañales, cerveza, huevos y cola): el ejemplo de libro para calcular a mano soporte, confianza y *lift*, incluida la famosa regla de los pañales y la cerveza.

Reglas de asociación · ◦ Juguete · ✎ Sintético · ◇ Solo categóricos

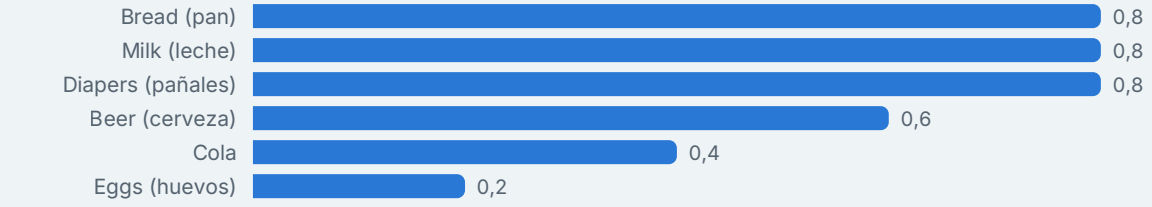
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
5	**6**	–	**40,0 %**	**Iniciación**	**Associate**

Fichero	Filas × col.	Descargar
`market_basket`	5 × 6	CSV 1 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/07_reglas_asociacion/market_basket/` seguido del nombre del fichero CSV.

Radiografía

Soporte de cada producto (fracción de las 5 cestas)



1 Descripción general y estudios habituales

Cada fila es una **compra** (una cesta) y cada columna un producto: `1` si se compró y vacío si no. Solo hay cinco cestas y seis productos, de modo que todos los cálculos de las reglas de asociación se pueden hacer a mano y comprobar después en Orange.

Los estudios habituales son:

- **Conjuntos frecuentes** (*frequent itemsets*) y su soporte.
- **Reglas de asociación** con su confianza y su *lift*.
- **Introducción al algoritmo Apriori / FP-Growth**.

2 Contexto y fuente original

Es el ejemplo de la tabla de transacciones del capítulo de análisis de asociación del libro *Introduction to Data Mining* de **Pang-Ning Tan, Michael Steinbach y Vipin Kumar**, uno de los manuales más usados. El equipo de **Orange** lo incluyó en su repositorio como ejemplo sintético. La «regla de los pañales y la cerveza» es una anécdota clásica de la minería de datos (padres que compran pañales y aprovechan para llevarse cerveza), aunque su origen real es dudoso.

- Market Basket en el repositorio de datasets de Orange

3 Variable objetivo

No tiene variable objetivo. El pan, la leche y los pañales están en 4 de las 5 cestas (soporte 0,8), la cerveza en 3, la cola en 2 y los huevos en 1. La regla **{cerveza} → {pañales}** tiene soporte 0,6 (3 cestas), **confianza 1** (las tres cestas con cerveza tienen pañales) y *lift* 1,25: comprar cerveza hace un 25 % más probable llevar pañales. En cambio, {pan} → {leche} tiene confianza 0,75 pero *lift* 0,94, menor que 1: comprar pan hace algo *menos* probable llevar leche.

4 Diccionario de columnas

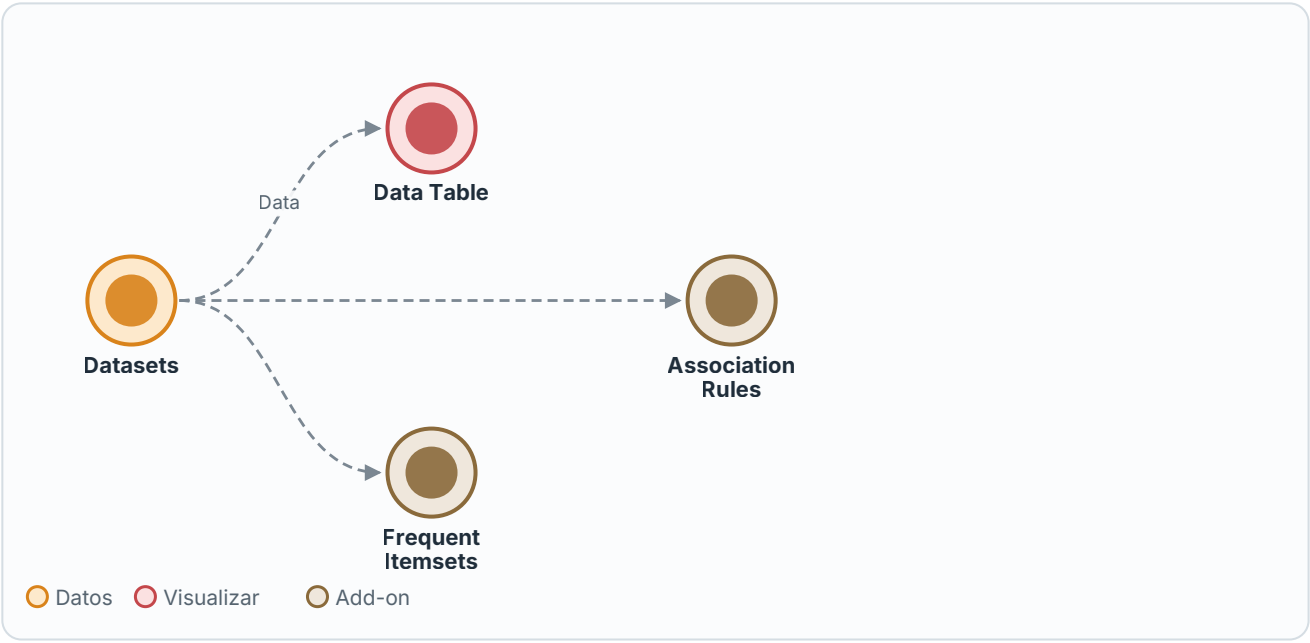
Columnas de `market_basket` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Bread`	categórica	Pan: `1` si está en la cesta, vacío si no.	1.0 (4)
`Milk`	categórica	Leche.	1.0 (4)
`Diapers`	categórica	Pañales.	1.0 (4)
`Beer`	categórica	Cerveza.	1.0 (3)
`Eggs`	categórica	Huevos.	1.0 (1)
`Cola`	categórica	Refresco de cola.	1.0 (2)

5 Particularidades técnicas al modelar

- **Vacío significa «no comprado»**, no «dato perdido». En las cestas, la ausencia es la norma.
- **Datos de juguete**: con cinco cestas, cualquier regla es anecdótica; sirve para entender las medidas, no para sacar conclusiones.
- **Confianza frente a *lift***: una regla puede tener confianza alta y *lift* menor que 1 si el consecuente es muy frecuente (como la leche). Es el error más habitual al interpretar reglas.
- **Formato de matriz**: Orange también acepta el formato de cestas (`.basket`), una línea por compra con los productos separados por comas.

6 Flujo de trabajo en Orange



1. Instala el add-on **Associate** (*Options* → *Add-ons*).
2. **Datasets** → «Market Basket» y **Data Table** para ver las cinco cestas.
3. Calcula a mano el soporte de {cerveza, pañales} y la confianza y el *lift* de {cerveza} → {pañales}.
4. **Frequent Itemsets** con soporte mínimo del 40 %: comprueba los conjuntos.
5. **Association Rules** con confianza mínima del 50 %: ordena por *lift* y compara con tus cálculos.

7 Otras consideraciones

- **Siguiente paso**: Online Retail y Foodmart, en este capítulo, con miles de cestas reales.
- **Ejercicio**: añade una sexta cesta con **Create Table** o una hoja de cálculo y observa cómo cambian las medidas.

En la carpeta `market_basket` ← `market-basket.tab` (datasets.biolab.si)

7.02
Reglas de asociación (cesta de la compra)

Foodmart 2000

`07_reglas_asociacion/foodmart/`

62.560 compras de una cadena de supermercados ficticia con 102 categorías de producto y la tienda donde se hicieron: reglas de asociación a gran escala en datos de ejemplo de Microsoft, donde casi ninguna regla supera el azar.

Reglas de asociación | Grande

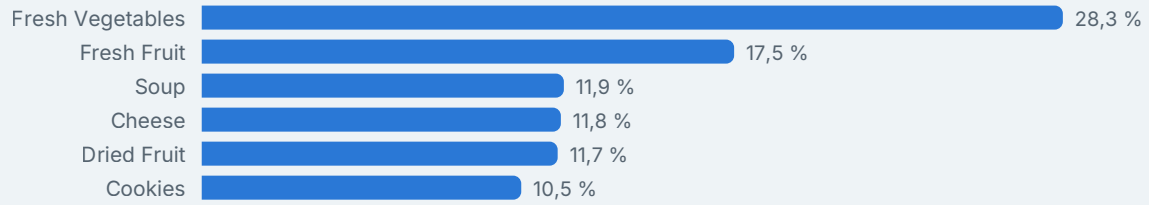
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
62.560	**126**	–	**0,0 %**	**Intermedio**	**Associate**

Fichero	Filas × col.	Descargar
`foodmart`	62.560 × 126	CSV 15,8 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/07_reglas_asociacion/foodmart/` seguido del nombre del fichero CSV.

Radiografía

Categorías más frecuentes (% de las 62.560 compras)



1 Descripción general y estudios habituales

Cada fila es una **compra** en un supermercado de la cadena ficticia **Foodmart**. Las 102 primeras columnas son categorías de producto (verduras frescas, fruta fresca, sopa, queso, galletas, cerveza, vino, pilas…) con el número de unidades compradas (0 si ninguna). Las 24 últimas (`STORE_ID_2` … `STORE_ID_24`) indican en qué tienda se hizo la compra: una vale 1 y las demás 0.

Los estudios habituales son:

- **Conjuntos frecuentes y reglas de asociación** con muchas compras.
- **Comparar tiendas**: ¿se compran cosas distintas en cada una?
- **Rendimiento** de los algoritmos con decenas de miles de cestas.

2 Contexto y fuente original

Foodmart 2000 es la base de datos de ejemplo que acompañaba a **Microsoft SQL Server Analysis Services**: una cadena de supermercados inventada con sus ventas, clientes y tiendas. Orange la toma, en

formato de cestas, de un repositorio de ejemplos de **Neo4j**. Los datos son sintéticos, generados para demostrar herramientas de análisis.

- Foodmart 2000 en el repositorio de ejemplos de Neo4j (fuente de Orange)
- Foodmart 2000 en el repositorio de datasets de Orange (formato .basket)

3 Variable objetivo

No tiene variable objetivo. Cada compra incluye de media 4,1 categorías (de 1 a 13). Las más frecuentes son las verduras frescas (28 % de las compras) y la fruta fresca (18 %).

Las reglas son **débiles**: con soporte mínimo del 1 %, el *lift* más alto es 1,16 ({vino} → {sopa}); lo demás está muy cerca de 1, es decir, de la independencia. Probablemente porque los datos se generaron al azar. Es una buena lección: no todas las cestas esconden patrones.

4 Diccionario de columnas

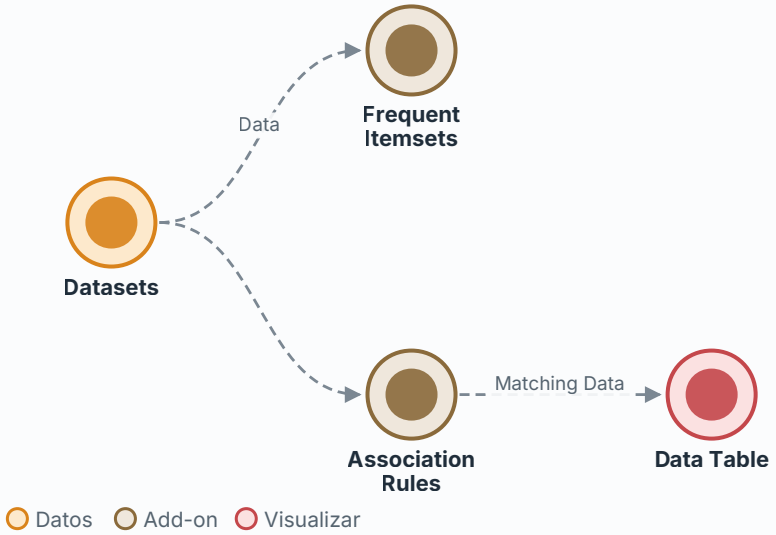
Columnas de `foodmart` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`STORE_ID_2`	numérica	1 si la compra se hizo en la tienda 2, 0 si no. Igual para cada tienda.	0 – 1
`Pasta`	numérica	Unidades de pasta en la compra (0 si ninguna). Igual para cada categoría de producto.	0 – 8
Soup	numérica	Sopa.	0 – 12
`Fresh Vegetables`	numérica	Verduras frescas (la categoría más frecuente).	0 – 18
`Milk`	numérica	Leche.	0 – 11
…		y 121 columnas más: el resto de categorías de producto (con el mismo formato) y las 24 tiendas (`STORE_ID_…`).	

5 Particularidades técnicas al modelar

- **Formato de cestas en Orange**: el original es un fichero `.basket` (una línea por compra, `Pasta=3, Soup=2, STORE_ID_2`). En este CSV se ha convertido a una matriz de 126 columnas con ceros. Para las reglas de asociación en Orange es más cómodo cargar el original con **Datasets** («Foodmart 2000»), que se lee como datos dispersos.
- **Las tiendas son columnas**: si se dejan, aparecen reglas del tipo {tienda 13} → {verduras}. Quítalas o úsalas para comparar tiendas.
- **Tiendas muy desiguales**: de 321 compras (tienda 5) a 6.197 (tienda 13).
- **Datos sintéticos**: los *lifts* cercanos a 1 indican que los productos se combinaron casi al azar; las reglas no reflejan hábitos reales.
- **Matriz grande y casi vacía**: 62.560 × 126, con un 96 % de ceros. El XLSX pesa 17 MB.

6 Flujo de trabajo en Orange



1. Instala el add-on **Associate**.
2. **Datasets** → «Foodmart 2000» (formato de cestas).
3. **Frequent Itemsets** con soporte mínimo del 1 %: casi todos los conjuntos son de uno o dos productos.
4. **Association Rules**: ordena por *lift*; ninguna regla pasa de 1,2.
5. Compara con Online Retail, donde hay reglas con *lift* de 4 a 5.

7 Otras consideraciones

- **Lección sobre el *lift***: un dataset grande no garantiza reglas interesantes. Comparar con Online Retail muestra la diferencia entre cestas reales y generadas.
- **Base de datos completa**: Foodmart tiene también tablas de clientes, productos y tiempo, útiles para enseñar bases de datos multidimensionales (OLAP).

En la carpeta `foodmart` ← `foodmart.basket` (datasets.biolab.si)

7.03
Reglas de asociación (cesta de la compra)

Online Retail (cestas)

`07_reglas_asociacion/retail_basket/`

914 facturas de una tienda británica de regalos en línea (primeros días de diciembre de 2010), con los productos agrupados en 47 tipos: reglas de asociación con cestas reales, devoluciones incluidas y fechas corregidas.

Reglas de asociación · Espacial · Temporal

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
914	**50**	–	**87,1 %**	**Intermedio**	**Associate**

Fichero	Filas × col.	Descargar
`retail_basket`	914 × 50	CSV 85 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/07_reglas_asociacion/retail_basket/` seguido del nombre del fichero CSV.

Radiografía

Reglas con más lift (facturas sin devoluciones, soporte ≥ 3 %)



1 Descripción general y estudios habituales

Cada fila es una **factura** de una tienda británica que vende por internet regalos y artículos de decoración (muchos de sus clientes son mayoristas). Las 47 columnas de producto son **tipos de artículo** (taza, portavelas, marco, cojín, botella, calentador de manos…) con el número de unidades compradas de ese tipo; vacío si no se compró. Además se conocen el número de factura, la fecha y hora y el país del cliente.

Los estudios habituales son:

- **Reglas de asociación** y conjuntos frecuentes con cestas reales.
- **Exploración** de las ventas por día, hora y país.
- **Agrupamiento de facturas** o de productos.

2 Contexto y fuente original

El dataset completo, *Online Retail*, lo publicaron **Daqing Chen, Sai Laing Sain y Kun Guo** (2012), con todas las transacciones de la tienda entre el 1 de diciembre de 2010 y el 9 de diciembre de 2011 (unas 25.900 facturas y más de 4.000 productos distintos), y está en el repositorio UCI. El equipo de **Orange** preparó esta versión reducida: solo las facturas del **1 al 9 de diciembre de 2010** y los productos agrupados en 47 tipos genéricos.

Corrección en este CSV: en el fichero de Orange, el día y el mes de `InvoiceDate` estaban intercambiados (la primera factura figuraba el 12 de enero en lugar del 1 de diciembre). Se han corregido todas las fechas.

- Chen, D., Sain, S. L. y Guo, K. (2012). Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining. Journal of Database Marketing & Customer Strategy Management, 19, 197–208.
- Online Retail en el repositorio UCI

3 Variable objetivo

No tiene variable objetivo. Cada factura incluye de mediana 2 tipos de producto (máximo 45). Los más frecuentes son las botellas (en el 29 % de las facturas), los portavelas (26 %) y los calentadores de manos (22 %).

Hay reglas con *lift* claramente mayor que 1: **{paraguas} → {toalla}** (*lift* 4,7), **{banderines} ↔ {guirnalda}** (4,6), **{manopla de horno} → {cuenco}** (confianza 0,59, *lift* 4,1) y **{calendario} → {cartel}** (confianza 0,68, *lift* 4,0). Son productos que se compran juntos porque pertenecen a la misma colección o al mismo uso.

4 Diccionario de columnas

Columnas de `retail_basket` (valores observados en el fichero)

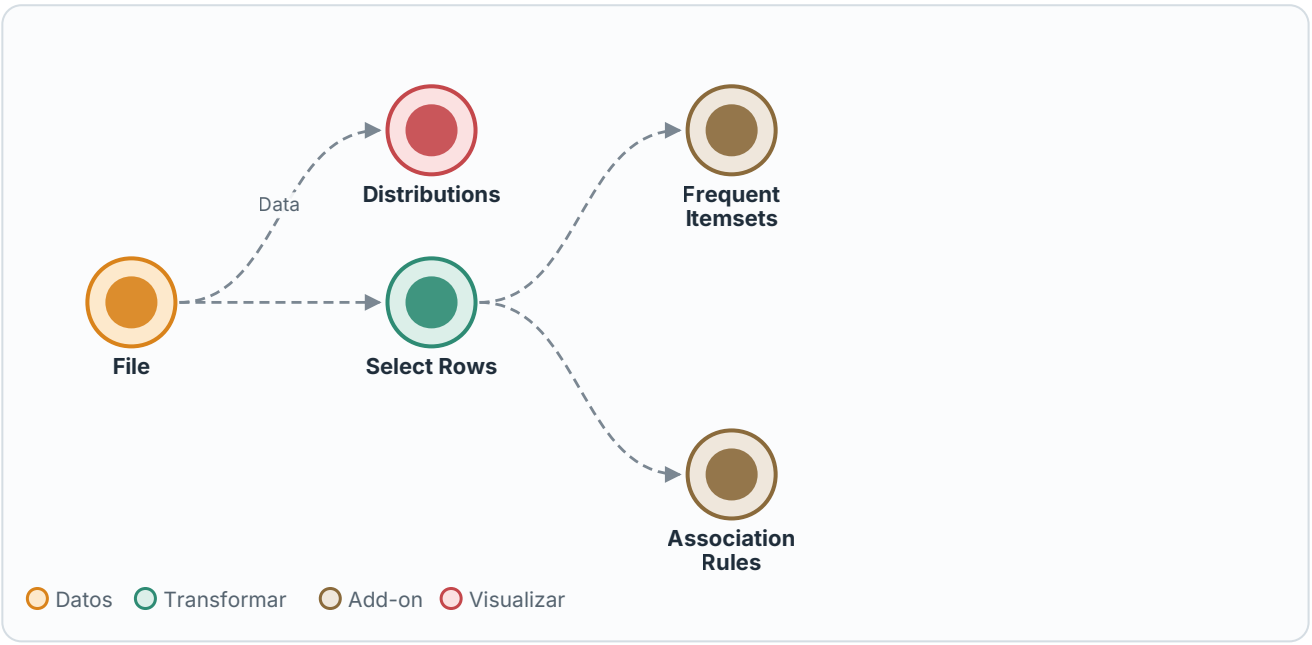
Columna	Tipo	Significado	Valores
`T-light Holder`	numérica	Portavelas: unidades compradas en la factura (vacío = ninguna). Igual para cada tipo de producto.	1 – 14
`Mug`	numérica	Tazas.	1 – 19
`Card holder`	numérica	Tarjeteros.	1 – 4
`Felt craft`	numérica	Manualidades de fieltro.	1 – 25
`Frame`	numérica	Marcos de fotos.	1 – 8
`Hand warmer`	numérica	Calentadores de manos.	1 – 11
`Bottle`	numérica	Botellas.	1 – 17
`InvoiceNo`	texto	Número de factura (meta). **Las que empiezan por `C` son devoluciones** (110).	536365 (1), 536366 (1), 536367 (1), 536368 (1), 536369 (1), 536370 (1) …
`InvoiceDate`	fecha/hora	Fecha y hora de la factura (meta). **Corregida** (día y mes estaban intercambiados).	2010-12-08 13:07:00 (3), 2010-12-09 10:04:00 (3), 2010-12-07 15:34:00 (3), 2010-12-07 15:48:00 (3), 2010-12-06 11:42:00 (3), 2010-12-01 15:08:00 (3) …
`Country`	categórica	País del cliente (meta): Reino Unido (849), Alemania, Francia, Irlanda (`EIRE`)…	United Kingdom (849), Germany (19), France (11), EIRE (11), Lithuania (4), Portugal (4) …

Columna	Tipo	Significado	Valores
…		y 40 columnas más de tipos de producto (calendario, guirnalda, lápices, velas, collar, tarjeta de felicitación…), con el mismo formato.	

5 Particularidades técnicas al modelar

- **Devoluciones mezcladas con compras**: 110 facturas empiezan por `C` y son anulaciones; aquí sus cantidades aparecen en positivo. Para las reglas de asociación conviene quitarlas (**Select Rows**).
- **Facturas vacías**: 208 facturas no tienen ningún producto de los 47 tipos (70 de ellas son devoluciones); el resto compraron artículos que no se agruparon. Hay que filtrarlas.
- **Cantidades, no presencia**: los valores son unidades (de 1 a 27). Para las reglas solo importa si el producto está o no.
- **Fechas intercambiadas en Orange**: si se usa el fichero de **Datasets**, todas las fechas caen en enero-septiembre de 2010 con día 12. En este CSV están corregidas (del 1 al 9 de diciembre; el día 4, sábado, no hay ventas).
- **Productos agrupados**: «Mug» reúne todas las tazas distintas del original. Las reglas son entre tipos, no entre artículos concretos.

6 Flujo de trabajo en Orange



1. Instala el add-on **Associate**.
2. **File** con el CSV corregido (o **Datasets** → «Online Retail», con las fechas mal).
3. **Select Rows**: quita las facturas cuyo número contiene `C`.
4. **Frequent Itemsets** con soporte mínimo del 3 %.
5. **Association Rules** con confianza mínima del 25 %; ordena por *lift* y busca productos de la misma colección.

7 Otras consideraciones

- **Dataset completo**: el original de UCI (541.909 líneas de productos, un año entero) permite estudiar estacionalidad y segmentación de clientes (RFM).
- **Recomendación**: las reglas con *lift* alto son la base de los sistemas «quienes compraron esto también compraron…».

En la carpeta `retail_basket` ← `retail-basket.tab` (datasets.biolab.si)

8 Análisis de supervivencia

9 datasets en el capítulo; en esta edición, 9 con ficha.

8.01
Análisis de supervivencia

Veterans' Administration Lung Cancer

`08_supervivencia/veteran/`

137 hombres con cáncer de pulmón avanzado de un ensayo clínico de la Administración de Veteranos de EE. UU.: el dataset clásico de análisis de supervivencia, donde el tratamiento nuevo no mejora nada pero el tipo de tumor y el estado general sí.

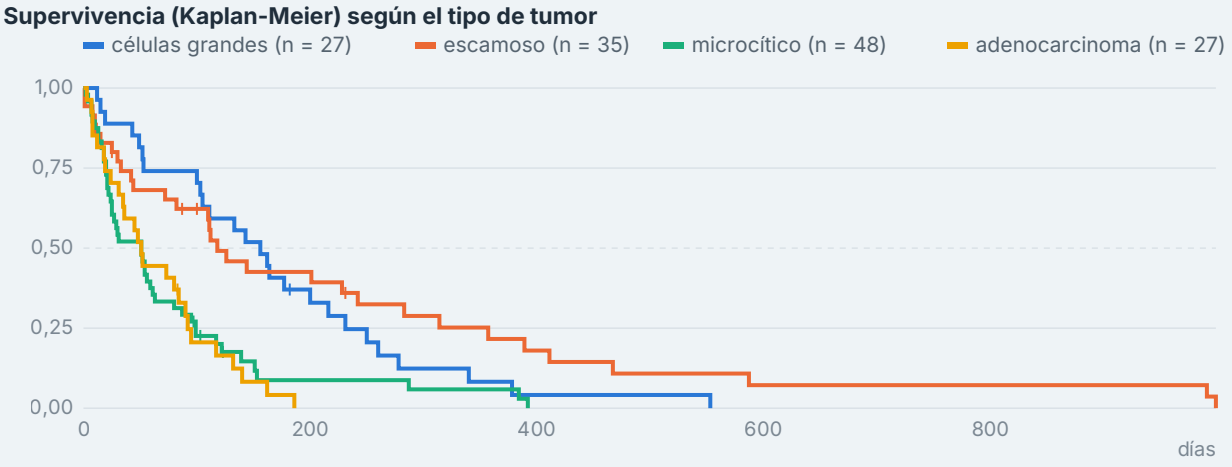
Análisis de supervivencia | ⊣ Datos censurados | ◈ Mixto num. + cat.

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
137	**8**	`Survival Time [days]`	**0,0 %**	**Intermedio**	**Survival Analysis**

Fichero	Filas × col.	Descargar
`veteran`	137 × 8	CSV 4 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/08_supervivencia/veteran/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Cada fila es un paciente con cáncer de pulmón avanzado e inoperable que participó en un ensayo con dos tratamientos de quimioterapia (estándar y experimental). Se registraron los **días de supervivencia** desde el

inicio del ensayo, si el paciente murió durante el seguimiento o seguía vivo al final (**censurado**), el tipo de célula del tumor, el estado general del paciente (escala de Karnofsky), su edad, los meses desde el diagnóstico y si había recibido tratamiento antes.

Los estudios habituales son:

- **Curvas de Kaplan-Meier** y comparación de grupos (prueba de rangos logarítmicos, *log-rank*).
- **Regresión de Cox** para estimar el efecto de cada variable sobre el riesgo de muerte.
- **Comprobación de supuestos** (riesgos proporcionales), que aquí no se cumplen para todas las variables.

2 Contexto y fuente original

Es el ensayo de la **Veterans Administration** que **John Kalbfleisch y Ross Prentice** usaron en su libro de análisis de supervivencia de 1980, y desde entonces viene con el paquete `survival` de R y con casi todos los programas de estadística. Orange lo toma de esa misma fuente.

- Kalbfleisch, J. D. y Prentice, R. L. (1980). The Statistical Analysis of Failure Time Data. Wiley (datos veteran del paquete survival de R).

3 Variable objetivo

El objetivo son **dos columnas**: `Survival Time [days]` (de 1 a 999 días) y `Survival Event` (1 = murió, 128 pacientes; 0 = seguía vivo al final del seguimiento, 9 pacientes censurados). La mediana de supervivencia es de unos 80 días.

El **tratamiento no cambia nada** (mediana de 103 días con el estándar y 52 con el experimental, sin diferencia significativa: p = 0,93). Lo que sí importa es el **tipo de tumor** (mediana de 156 días en el de células grandes y 118 en el escamoso, frente a 51 en el microcítico y el adenocarcinoma) y el **estado general**: con un Karnofsky de 50 o menos, la mediana es de 20 días; por encima de 50, de 112. En una regresión de Cox con todas las variables, el índice de concordancia es 0,74.

4 Diccionario de columnas

Columnas de `veteran` (valores observados en el fichero)

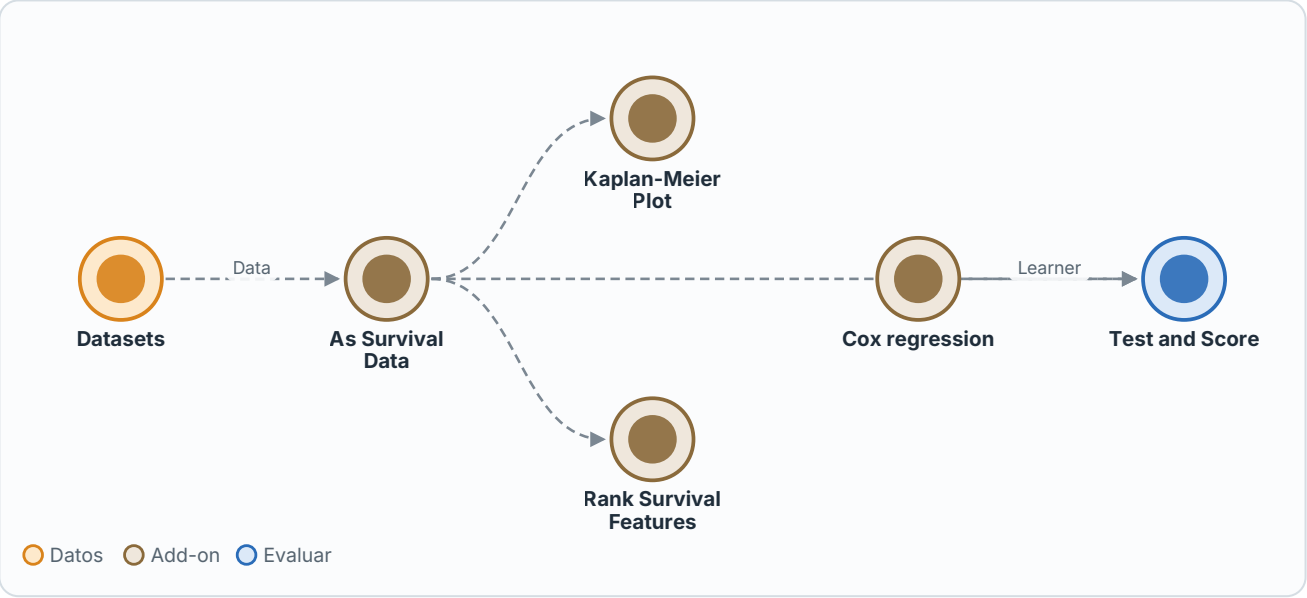
Columna	Tipo	Significado	Valores
`Survival Time [days]` objetivo	numérica	**Objetivo (tiempo)**: días desde el inicio del ensayo hasta la muerte o el final del seguimiento.	1 – 999
`Survival Event` objetivo	categórica	**Objetivo (evento)**: 1 = muerte; 0 = censurado (vivo al final del seguimiento).	1 (128), 0 (9)
`Time from diagnosis [months]`	numérica	Meses entre el diagnóstico y la entrada en el ensayo (meta).	1 – 87
`Age [years]`	numérica	Edad.	34 – 81
`Karnofsky performance score`	numérica	Estado general del paciente de 10 (moribundo) a 100 (normal). Mide cuánto puede valerse por sí mismo.	10 – 99

Columna	Tipo	Significado	Valores
`Prior Therapy`	categórica	Si había recibido tratamiento antes (1) o no (0). En el original de R se codifica como 10 y 0.	0 (97), 1 (40)
`Cell Type`	categórica	Tipo de célula del tumor: `squamous` escamoso, `smallcell` microcítico, `adeno` adenocarcinoma, `large` células grandes.	smallcell (48), squamous (35), adeno (27), large (27)
`Treatment`	categórica	Tratamiento: `standard` o `test` (experimental).	standard (69), test (68)

5 Particularidades técnicas al modelar

- **Dos columnas objetivo**: tiempo y evento. En Orange, el add-on **Survival Analysis** las necesita marcadas con el widget **As Survival Data**; si no, Orange las trata como atributos o como objetivo de regresión normal.
- **Pocas censuras** (9 de 137): casi todos los pacientes murieron. Por eso las medias y las medianas son parecidas con y sin tener en cuenta la censura, algo que no pasa en otros datasets.
- **Riesgos no proporcionales**: el efecto del Karnofsky es fuerte al principio y se diluye con el tiempo. La regresión de Cox lo resume en un solo número y puede engañar.
- **No es un problema de regresión**: tratar el tiempo como objetivo numérico y quitar el evento ignora que los 9 censurados vivieron *al menos* ese tiempo.
- **Ensayo aleatorizado**: el tratamiento se asignó al azar, así que su falta de efecto es una conclusión válida.

6 Flujo de trabajo en Orange



1. Instala el add-on **Survival Analysis**.
2. **Datasets** → «Veterans' Administration Lung Cancer» y **As Survival Data** (tiempo: `Survival Time [days]`; evento: `Survival Event`).
3. **Kaplan-Meier Plot** agrupando por `Treatment` (no hay diferencia) y por `Cell Type` (sí la hay).
4. **Rank Survival Features**: el Karnofsky y el tipo de tumor salen arriba.

5. **Cox regression** en **Test and Score**: el índice de concordancia mide lo bien que ordena a los pacientes.

7 Otras consideraciones

- **Lección clínica**: un ensayo aleatorizado sin efecto del tratamiento también es un resultado; los factores pronósticos (estado general y tipo de tumor) son lo que explica la supervivencia.
- **Comparar con Melanoma y GBSG2**: los tres son datasets clásicos de R con distinta proporción de censuras.

En la carpeta `veteran` ← `veteran.tab` (datasets.biolab.si)

8.02
Análisis de supervivencia

Melanoma (Odense)

`08_supervivencia/melanoma/`

205 pacientes operadas y operados de melanoma en Odense (Dinamarca) entre 1962 y 1977, seguidos hasta 1977: análisis de supervivencia con muchas censuras, donde la ulceración y el grosor del tumor marcan el pronóstico.

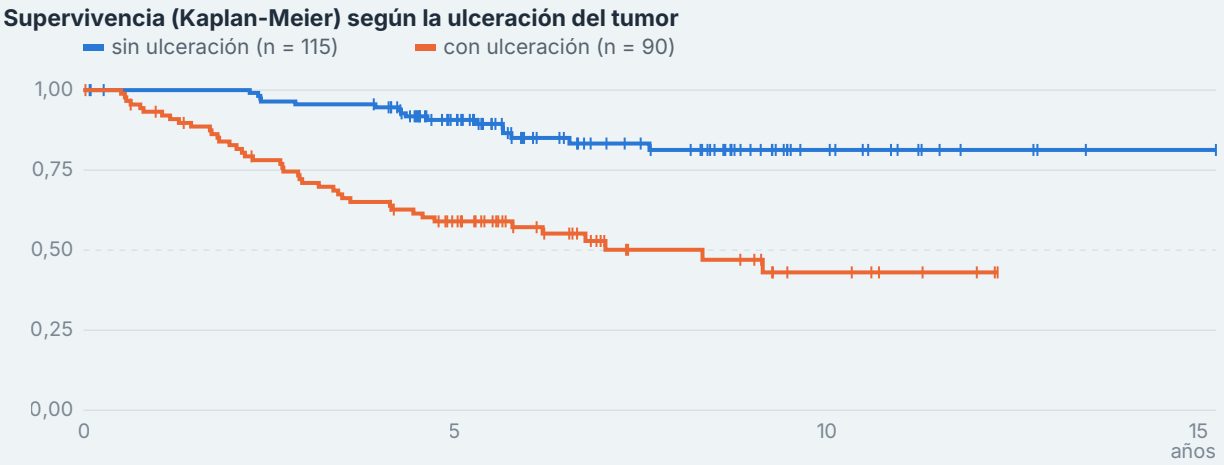
Análisis de supervivencia | ⊣ Datos censurados | ◈ Mixto num. + cat.

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
205	**7**	`Survival Time [days]`	**0,0 %**	**Intermedio**	**Survival Analysis**

Fichero	Filas × col.	Descargar
`melanoma`	205 × 7	CSV 5 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/08_supervivencia/melanoma/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Cada fila es un paciente al que se le extirpó un **melanoma maligno** (cáncer de piel) en el Hospital Universitario de Odense. Se conocen su sexo, su edad, el **grosor del tumor**, si el tumor estaba **ulcerado**, el año de la operación y los días que pasaron desde la operación hasta la muerte por melanoma o hasta el final del seguimiento.

Los estudios habituales son:

- **Curvas de Kaplan-Meier** según la ulceración, el sexo o el grosor.
- **Regresión de Cox** con variables numéricas (grosor, edad).
- **Riesgos competitivos**: algunos pacientes murieron por otras causas.

2 Contexto y fuente original

Los datos son del estudio de **P. K. Andersen, Ø. Borgan, R. D. Gill y N. Keiding** sobre modelos de supervivencia (1993), y se distribuyen con el paquete `MASS` de R (Venables y Ripley). En el original, el estado tiene tres valores: muerte por melanoma, vivo al final del estudio y muerte por otras causas. En la versión de Orange, el evento es **morir por melanoma**; las muertes por otras causas cuentan como censuras.

- Andersen, P. K., Borgan, Ø., Gill, R. D. y Keiding, N. (1993). Statistical Models Based on Counting Processes. Springer (datos Melanoma del paquete MASS de R).

3 Variable objetivo

El objetivo son `Survival Time [days]` (de 10 a 5.565 días, unos 15 años) y `Survival Event` (1 = muerte por melanoma, 57 pacientes; 0 = censurado, 148). Con tantas censuras, **la mediana de supervivencia no se alcanza**: más de la mitad seguían vivos al final.

La supervivencia a 5 años es del 77 % y a 10 años del 65 %. La **ulceración** separa claramente: a 5 años sobrevive el 91 % de los pacientes sin úlcera y el 59 % de los que la tenían. Los hombres tienen peor pronóstico que las mujeres (p = 0,01).

4 Diccionario de columnas

Columnas de `melanoma` (valores observados en el fichero)

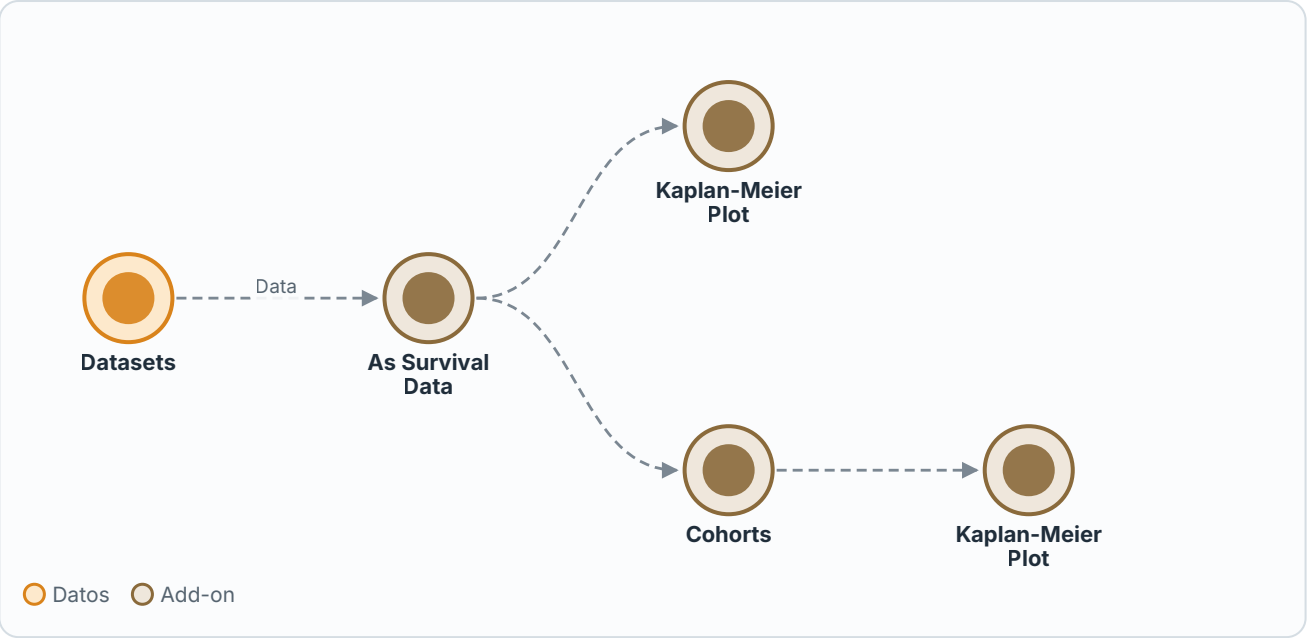
Columna	Tipo	Significado	Valores
Sex	categórica	Sexo: 1 = hombre (79), 0 = mujer (126).	0 (126), 1 (79)
`Tumor Thickness [mm]`	numérica	Grosor del tumor en milímetros (0,1–17,4).	0,1 – 17,42
`Ulceration`	categórica	Si el tumor estaba ulcerado (1) o no (0).	0 (115), 1 (90)
`Age of Patient [years]`	numérica	Edad en la operación (4–95).	4 – 95
`Survival Time [days]` objetivo	numérica	**Objetivo (tiempo)**: días desde la operación hasta la muerte o el final del seguimiento (1977).	10 – 5.565
`Survival Event` objetivo	categórica	**Objetivo (evento)**: 1 = muerte por melanoma; 0 = vivo o muerto por otra causa (censurado).	0 (148), 1 (57)
`Year of Operation`	numérica	Año de la operación (1962–1977, meta).	1.962 – 1.977

5 Particularidades técnicas al modelar

- **Muchas censuras** (72 %): la media del tiempo sin tener en cuenta la censura no significa nada. Hay que usar métodos de supervivencia.
- **Muertes por otras causas como censuras**: 14 pacientes murieron por otras causas y aquí cuentan como censurados. Es una simplificación habitual, pero técnicamente es un problema de **riesgos competitivos**.
- **Seguimiento desigual**: todos se siguieron hasta 1977, así que los operados en 1962 tienen hasta 15 años de seguimiento y los de 1977 muy poco. El año de operación explica buena parte de la censura.
- **Codificaciones numéricas** de `Sex` y `Ulceration` (0/1): conviene pasarlas a categóricas para el **Kaplan-Meier Plot**.

- **Grosor muy asimétrico**: el logaritmo del grosor funciona mejor en la regresión de Cox.

6 Flujo de trabajo en Orange



1. Instala el add-on **Survival Analysis**.
2. **Datasets** → «Melanoma» y **As Survival Data**.
3. **Kaplan-Meier Plot** por `Ulceration` (pásala antes a categórica con **Edit Domain** si hace falta).
4. **Cohorts**: divide a los pacientes en riesgo alto y bajo con un modelo de Cox, y compáralos con otro **Kaplan-Meier Plot**.
5. **Cox regression** con grosor, ulceración, edad y sexo.

7 Otras consideraciones

- **Riesgos competitivos**: el original permite distinguir muerte por melanoma de muerte por otras causas; es un buen ejemplo para explicar ese concepto.
- **Comparar con Veteran**: allí casi no hay censuras; aquí son mayoría.

En la carpeta `melanoma` ← `melanoma.tab` (datasets.biolab.si)

8.03
Análisis de supervivencia

German Breast Cancer Study Group 2

`08_supervivencia/gbsg2/`

686 pacientes con cáncer de mama con afectación ganglionar de un ensayo clínico alemán, seguidas hasta la recaída: análisis de supervivencia libre de recaída con factores pronósticos clásicos y el efecto de la terapia hormonal.

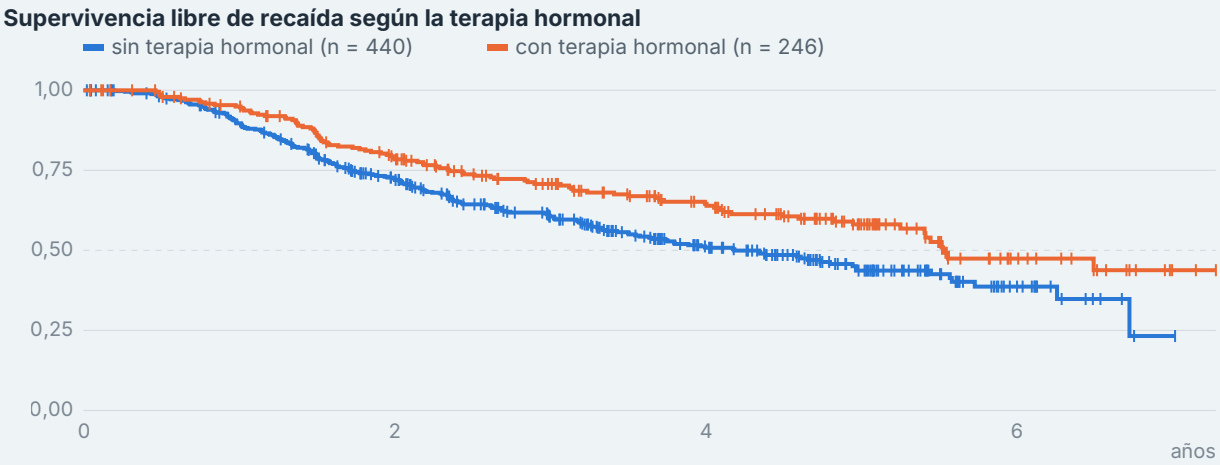
Análisis de supervivencia | ⊣ Datos censurados | ◈ Mixto num. + cat.

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
686	**10**	`Recurrence Free Survival Time [days]`	**0,0 %**	**Intermedio**	**Survival Analysis**

Fichero	Filas × col.	Descargar
`gbsg2`	686 × 10	CSV 21 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/08_supervivencia/gbsg2/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Cada fila es una paciente con cáncer de mama y **ganglios positivos** que participó en el ensayo del **German Breast Cancer Study Group 2**. Se conocen su edad, su estado menopáusico, el tamaño y el grado del tumor, el número de ganglios afectados, los receptores de progesterona y de estrógeno y si recibió **terapia hormonal** (tamoxifeno). El objetivo es el **tiempo hasta la recaída** (supervivencia libre de recaída).

Los estudios habituales son:

- **Kaplan-Meier** por terapia hormonal, grado o número de ganglios.

- **Regresión de Cox** con factores pronósticos.
- **Transformaciones de variables continuas** (polinomios fraccionarios, puntos de corte).

2 Contexto y fuente original

El ensayo, publicado por **Martin Schumacher y colaboradores** en 1994, comparaba en un diseño 2 × 2 la terapia hormonal y la duración de la quimioterapia. Los datos se hicieron populares con el trabajo de **Willi Sauerbrei y Patrick Royston** (1999) sobre cómo modelar variables continuas, y se distribuyen en el paquete `TH.data` de R (Torsten Hothorn), de donde los toma Orange.

- Schumacher, M. et al. (1994). Randomized 2 × 2 trial evaluating hormonal treatment and the duration of chemotherapy in node-positive breast cancer patients. Journal of Clinical Oncology, 12, 2086–2093.
- Datos GBSG2 del paquete TH.data de R

3 Variable objetivo

El objetivo son `Recurrence Free Survival Time [days]` (8 a 2.659 días, unos 7 años) y `Recurrence Event` (1 = recaída o muerte, 299; 0 = censurada, 387).

Las pacientes con **terapia hormonal** tardan más en recaer (mediana de 2.018 días frente a 1.528; p = 0,003). El **número de ganglios** es el factor más fuerte: con 1–3 ganglios, la mediana no se alcanza; con 4–9 es de 1.337 días y con 10 o más, de 747. En una regresión de Cox, los ganglios, el grado, el receptor de progesterona y la terapia hormonal son significativos, y el índice de concordancia es 0,69.

4 Diccionario de columnas

Columnas de `gbsg2` (valores observados en el fichero)

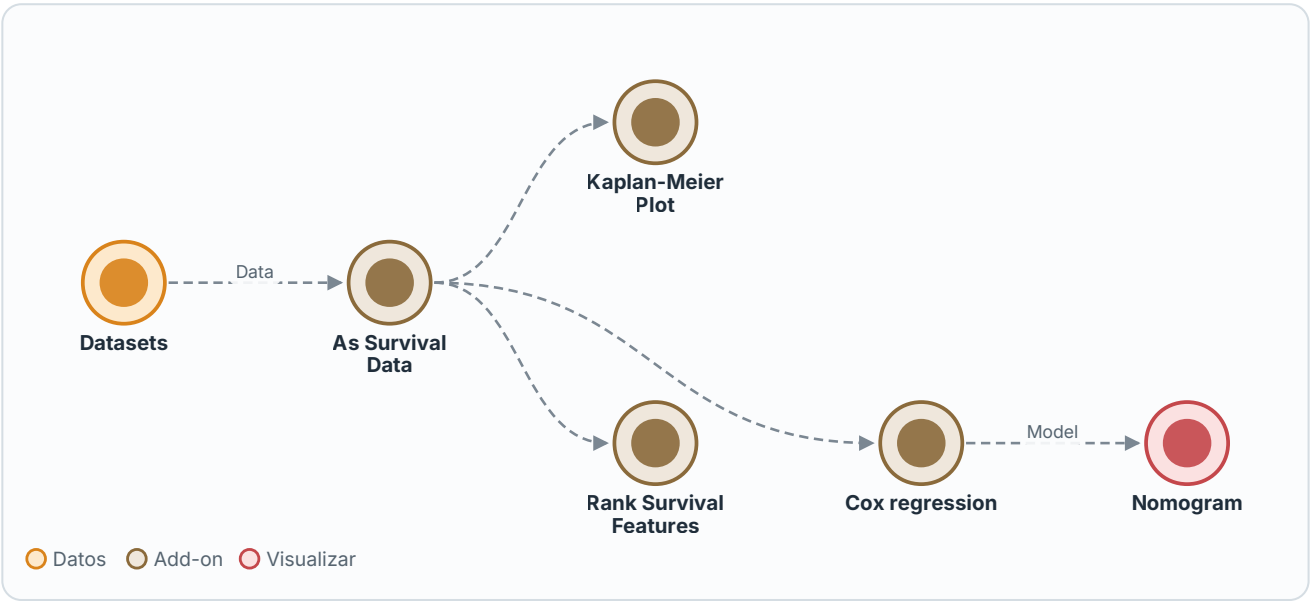
Columna	Tipo	Significado	Valores
`Number of Positive Nodes`	numérica	Ganglios linfáticos afectados (1–51).	1 – 51
`Age of the Patient [years]`	numérica	Edad (21–80).	21 – 80
`Tumor Grade`	categórica	Grado del tumor (1 a 3; 3 = más agresivo). Es ordinal aunque sea un número.	2 (444), 3 (161), 1 (81)
`Progesterone Receptor [fmol]`	numérica	Receptor de progesterona (fmol/mg de proteína). Muy asimétrico (0–2.380).	0 – 2.380
`Estrogen Receptor [fmol]`	numérica	Receptor de estrógeno (fmol/mg de proteína). Muy asimétrico (0–1.144).	0 – 1.144
`Tumor Size [mm]`	numérica	Tamaño del tumor (mm).	3 – 120
`Menopausal Status`	categórica	Estado menopáusico: `Pre` o `Post`.	Post (396), Pre (290)
`Hormonal Therapy`	categórica	Si recibió terapia hormonal (tamoxifeno): `yes` o `no`.	no (440), yes (246)
`Recurrence Free Survival Time [days]` `objetivo`	numérica	**Objetivo (tiempo)**: días hasta la recaída o el final del seguimiento.	8 – 2.659

Columna	Tipo	Significado	Valores
`Recurrence Event` `objetivo`	categórica	**Objetivo (evento)**: 1 = recaída (o muerte); 0 = censurada.	0 (387), 1 (299)

5 Particularidades técnicas al modelar

- **Supervivencia libre de recaída**, no supervivencia global: el evento es la recaída, no la muerte.
- **Variables muy asimétricas**: los receptores y los ganglios tienen colas largas; la relación con el riesgo no es lineal. Es el ejemplo clásico de Sauerbrei y Royston para transformarlas (logaritmo, polinomios fraccionarios).
- **Grado como número**: `Tumor Grade` (1–3) es ordinal; en la regresión de Cox puede tratarse como número o como categoría, con resultados algo distintos.
- **Terapia hormonal y menopausia relacionadas**: la mayoría de las pacientes tratadas son posmenopáusicas, así que al comparar curvas conviene ajustar por el estado menopáusico (por ejemplo, con la regresión de Cox).
- No hay valores ausentes.

6 Flujo de trabajo en Orange



1. Instala el add-on **Survival Analysis**.
2. **Datasets** → «German Breast Cancer Study Group 2» y **As Survival Data**.
3. **Kaplan-Meier Plot** por `Hormonal Therapy` y por `Tumor Grade`.
4. **Rank Survival Features**: los ganglios y el receptor de progesterona salen arriba.
5. **Cox regression**; prueba también con `log(Number of Positive Nodes)` creado en **Feature Constructor**.

7 Otras consideraciones

- **Puntos de corte clínicos**: agrupar los ganglios en 1–3, 4–9 y 10 o más es una práctica habitual; comparar con la variable continua enseña la pérdida de información al discretizar.
- **Comparar con METABRIC y SCAN-B**, también de cáncer de mama, con datos de expresión génica.

En la carpeta `gbsg2` ← `gbsg2.tab` (datasets.biolab.si)

8.04
Análisis de supervivencia

Political regimes (democracias y dictaduras)

`08_supervivencia/political_regimes/`

1.808 mandatos de jefes de gobierno de 200 países entre 1946 y 2008, con el tipo de régimen: análisis de supervivencia aplicado a la política (¿cuánto dura un gobernante en el poder?), con muertes en el cargo como censuras.

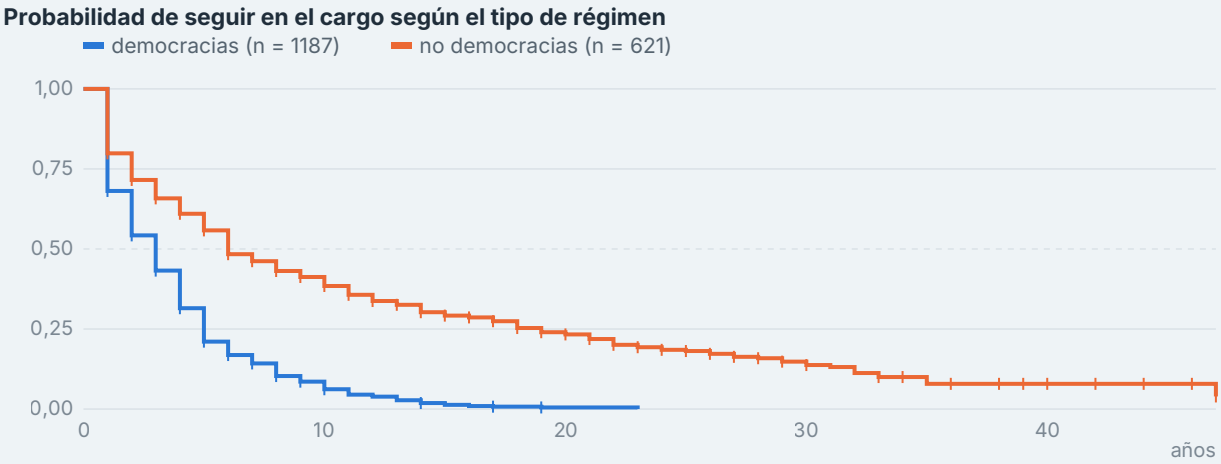
Análisis de supervivencia | ⊣ Datos censurados | ⌖ Espacial | ? Valores faltantes | ◷ Temporal

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
1.808	**11**	`Duration`	**0,0 %**	**Intermedio**	**Survival Analysis**

Fichero	Filas × col.	Descargar
`political_regimes`	1.808 × 11	CSV 168 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/08_supervivencia/political_regimes/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Cada fila es el **mandato de un jefe de gobierno efectivo** (presidente, primer ministro, dictador, monarca o junta militar) en un país, desde 1946 o la independencia hasta 2008. Se conoce el país, el nombre del gobernante, el año de inicio, la **duración en años**, si el mandato **terminó** en el periodo observado, la región y el continente, y el tipo de régimen: democracia parlamentaria, presidencial o mixta, o dictadura civil, militar o monarquía.

Los estudios habituales son:

- **Kaplan-Meier** por tipo de régimen: ¿duran más los dictadores?

- **Regresión de Cox** con el régimen, el continente y la época.
- **Exploración histórica y geográfica** de los regímenes.

2 Contexto y fuente original

Los datos proceden de la clasificación *Democracy and Dictatorship* de **José Antonio Cheibub, Jennifer Gandhi y James Vreeland** (2010), que clasifica cada país y año como democracia o dictadura y sus subtipos. La versión de una fila por gobernante viene con la biblioteca de Python **lifelines** (dataset `dd`), de donde la toma Orange.

- Cheibub, J. A., Gandhi, J. y Vreeland, J. R. (2010). Democracy and dictatorship revisited. Public Choice, 143(1–2), 67–101.
- Datasets de lifelines (dataset dd)

3 Variable objetivo

El objetivo son `Duration` (años en el cargo, de 1 a 47) y `Event` (1 = dejó el cargo, 1.468 mandatos; 0 = censurado, 340). Un mandato está censurado si el gobernante **seguía en el cargo en 2008** o **murió en él** (Franco, Enver Hoxha, varios gobernantes asesinados): en esos casos no se observó un relevo.

Los gobernantes democráticos duran menos (mediana de 3 años) que los no democráticos (6 años). Por tipo de régimen: mixto 2 años, parlamentario 3, presidencial 4, dictadura militar 5, civil 6 y **monarquía 29**. Los mandatos más largos son los de Hussein de Jordania y Fidel Castro (47 años) y Kim Il Sung (46).

4 Diccionario de columnas

Columnas de `political_regimes` (valores observados en el fichero)

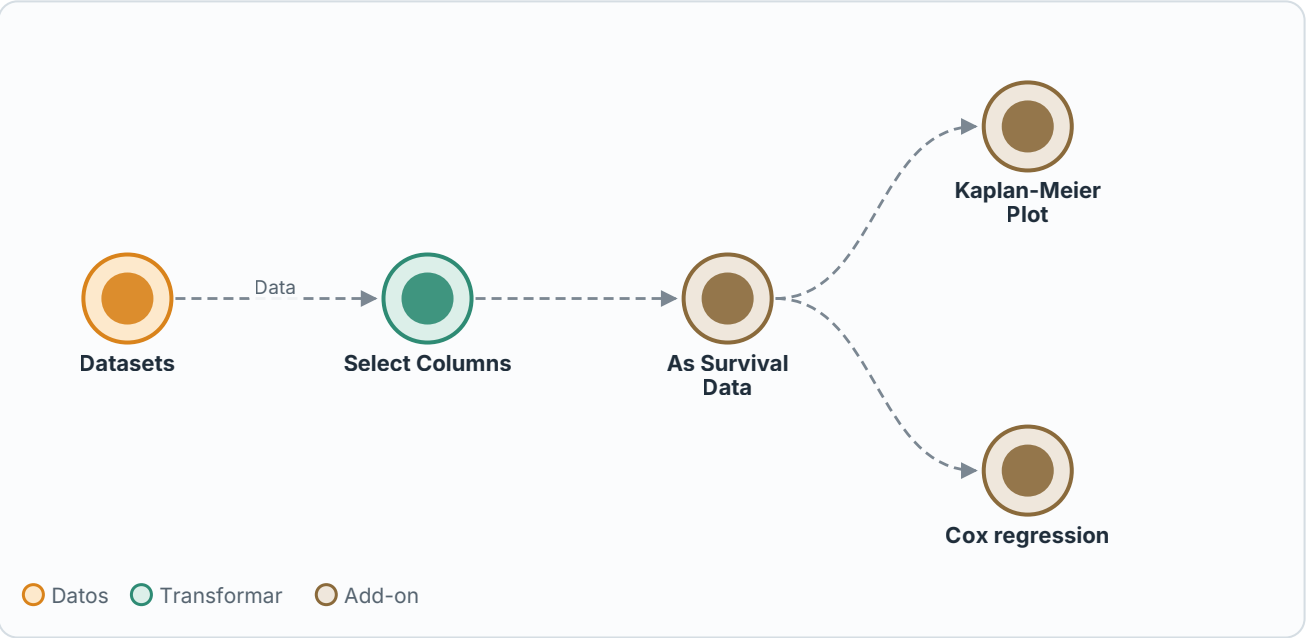
Columna	Tipo	Significado	Valores
`Duration` `objetivo`	numérica	**Objetivo (tiempo)**: años que duró el mandato (o hasta 2008).	1 – 47
`Event` `objetivo`	categórica	**Objetivo (evento)**: 1 = el gobernante dejó el cargo; 0 = censurado (seguía en 2008 o murió en el cargo).	1 (1.468), 0 (340)
`Country Name`	texto	País (meta).	Switzerland (63), Italy (33), France (32), Bolivia (27), Finland (26), Japan (26) …
`Effective Head of Government`	texto	Gobernante efectivo (meta). En 14 casos es `military` (junta militar). Hay 36 nombres con caracteres mal codificados (`Josï¿½ Luis Rodrï¿½guez Zapatero`).	military (14), Norodom Sihanouk (5), Rashid Karame (5), Olafur Thors (4), Jose Velasco Ibarra (4), Suleyman Demirel (4) …
`COW Country Code`	numérica	Código del país en *Correlates of War* (meta).	2 – 990
`POLITY IV Country Code`	numérica	Código del país en *Polity IV* (meta). 7 vacíos.	2 – 990

Columna	Tipo	Significado	Valores
`UN Geographic Region Name`	categórica	Región de la ONU (meta).	South America (191), Western Europe (164), Southern Europe (161), Northern Europe (148), Western Asia (142), Western Africa (118) …
`UN Continent Name`	categórica	Continente (meta).	Europe (576), Americas (412), Asia (398), Africa (314), Oceania (108)
`Democracy`	categórica	`Democracy` o `Non-democracy` (meta).	Democracy (1.187), Non-democracy (621)
`Regime`	categórica	Tipo de régimen (meta): `Parliamentary Dem`, `Presidential Dem`, `Mixed Dem`, `Civilian Dict`, `Military Dict`, `Monarchy`.	Parliamentary Dem (585), Civilian Dict (330), Presidential Dem (327), Mixed Dem (275), Military Dict (236), Monarchy (55)
`Start Year`	numérica	Año de inicio del mandato (meta).	1.946 – 2.008

5 Particularidades técnicas al modelar

- **Todo son metas salvo el objetivo**: en Orange, `Democracy`, `Regime`, el continente y el año están como metas. Para usarlos en un Kaplan-Meier o una regresión de Cox hay que pasarlos a atributos con **Select Columns**.
- **Censura con significado político**: morir en el cargo (por causas naturales o asesinado) cuenta como censura, no como fin del mandato. Es una decisión de los autores que conviene explicar.
- **Duración en años enteros**: mandatos de pocos meses cuentan como 1 año; hay muchos empates.
- **Un gobernante puede aparecer varias veces**, si tuvo mandatos separados o cambió el tipo de régimen (Adolfo Suárez, por ejemplo, aparece en dictadura civil y en democracia).
- **Codificación de caracteres** dañada en 36 nombres con acentos.
- **Nombres de personas**: son gobernantes y figuras públicas; los datos describen su actividad política.

6 Flujo de trabajo en Orange



1. Instala el add-on **Survival Analysis**.
2. **Datasets** → «Political regimes» (o **File** con el CSV).
3. **Select Columns**: pasa `Regime`, `Democracy`, `UN Continent Name` y `Start Year` a atributos.
4. **As Survival Data** con `Duration` y `Event`; **Kaplan-Meier Plot** por `Regime`.
5. **Cox regression** con régimen, continente y año de inicio.

7 Otras consideraciones

- **Supervivencia fuera de la medicina**: es un buen ejemplo para mostrar que el análisis de supervivencia sirve para cualquier «tiempo hasta un evento» (abandono de clientes, averías, mandatos).
- **Mapa**: con el add-on *Geo*, el tipo de régimen por país y época da mapas históricos muy expresivos.

En la carpeta `political_regimes` ← `political_regimes.tab` (datasets.biolab.si)

8.05
Análisis de supervivencia

Dental fillings (empastes)

`08_supervivencia/dental_fillings/`

Cuánto aguantan los empastes de 20 personas inventadas durante 10 años, según el material, el tiempo de cepillado y si son de perros o de gatos: el dataset de juguete de Orange para aprender análisis de supervivencia.

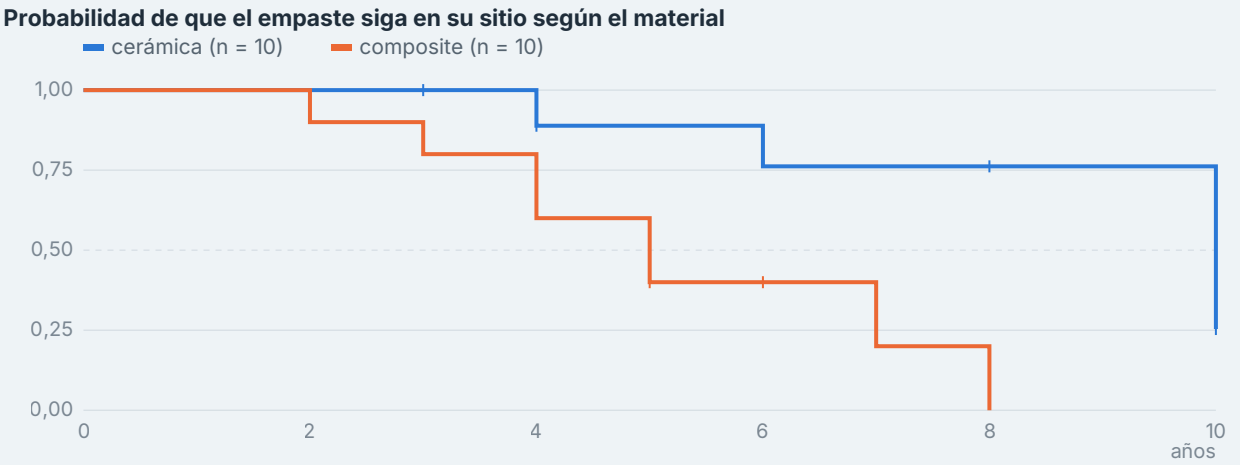
Análisis de supervivencia | ⊣ Datos censurados | ◦ Juguete | ◈ Mixto num. + cat. | ✎ Sintético

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
20	**6**	—	**0,0 %**	**Iniciación**	**Survival Analysis**

Fichero	Filas × col.	Descargar
`dental_fillings`	20 × 6	CSV 1 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/08_supervivencia/dental_fillings/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Cada fila es una persona (inventada) con un empaste. Se observó durante 10 años **cuánto tardó en caerse** el empaste. Algunos no se cayeron en ese tiempo o se perdió el contacto con la persona: son **censurados**. Además se conoce el material del empaste (composite o cerámica), los minutos de cepillado diario y si la persona prefiere los perros o los gatos, una variable que no debería influir y sirve de control.

Los estudios habituales son:

- **Introducción al análisis de supervivencia**: censura, curva de Kaplan-Meier, mediana de supervivencia.
- **Comparar dos grupos** con la prueba de rangos logarítmicos (*log-rank*).
- **Detectar variables sin efecto** (perros o gatos).

2 Contexto y fuente original

Lo creó el equipo de **Orange** en 2023 para sus materiales de enseñanza de análisis de supervivencia (cursos y libro en línea de Biolab). Es exactamente el mismo conjunto que `survival_data_extended` (ficha siguiente), con las columnas en otro orden.

- Material de Biolab: introducción al análisis de supervivencia
- SA: Dental Fillings en el repositorio de datasets de Orange

3 Variable objetivo

El objetivo son `Time` (años hasta que se cayó el empaste o terminó la observación, de 2 a 10) y `Event` (1 = se cayó, 12 empastes; 0 = censurado, 8). En el fichero de Orange, las dos columnas están como **metas**: hay que marcarlas con **As Survival Data**.

Los empastes **cerámicos duran más**: su mediana es de 10 años, frente a 5 en los de composite (p = 0,006 en la prueba de rangos logarítmicos). Ser «de perros» o «de gatos» no cambia nada (p = 0,99), como era de esperar.

4 Diccionario de columnas

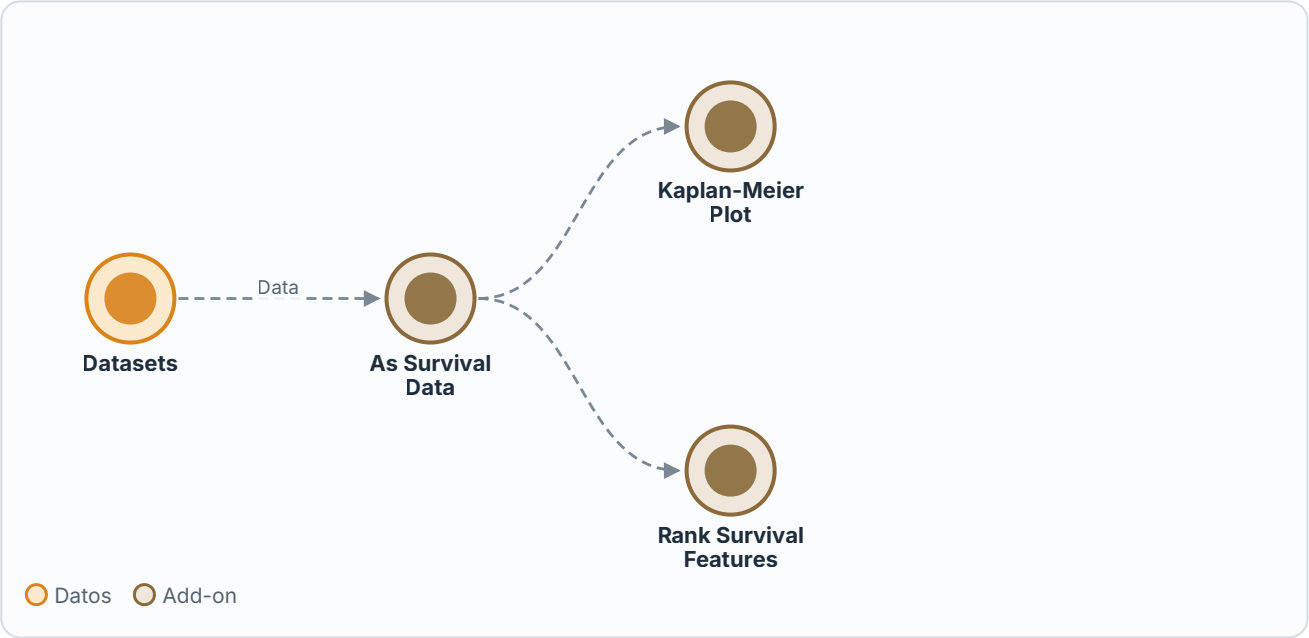
Columnas de `dental_fillings` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Type of material`	categórica	Material del empaste: `composite` o `ceramic`.	composite (10), ceramic (10)
`Brushing time`	numérica	Minutos de cepillado al día (4–15).	4 – 15
`Cat or dog person`	categórica	Si la persona prefiere los gatos (`Cat`) o los perros (`Dog`). Variable de control sin efecto.	Dog (10), Cat (10)
`Name`	texto	Nombre inventado (meta).	Anthony (1), Bert (1), Chloe (1), David (1), Elle (1), Fay (1) …
`Time`	numérica	**Tiempo**: años hasta que se cayó el empaste o terminó la observación (meta en Orange).	2 – 10
`Event`	categórica	**Evento**: 1 = el empaste se cayó; 0 = censurado (meta en Orange).	1 (12), 0 (8)

5 Particularidades técnicas al modelar

- **Tiempo y evento como metas**: en el fichero de Orange no están marcados como objetivo. **As Survival Data** los convierte en las variables de supervivencia.
- **Muy pocos datos** (20 personas): los resultados son para practicar, no para concluir nada sobre empastes.
- **Variable trampa**: «perro o gato» está para comprobar que el método no encuentra efectos donde no los hay.
- **Duplicado**: idéntico a `survival_data_extended`. Se mantienen los dos porque Orange los ofrece por separado.

6 Flujo de trabajo en Orange



1. Instala el add-on **Survival Analysis**.
2. **Datasets** → «SA: Dental Fillings Dataset».
3. **As Survival Data**: tiempo `Time`, evento `Event`.
4. **Kaplan-Meier Plot**: primero sin grupos (mediana de 7 años) y luego por `Type of material` y por `Cat or dog person`.
5. **Rank Survival Features**: el material sale arriba y «perro o gato», abajo.

7 Otras consideraciones

- **Calcular a mano**: con la tabla de 10 personas de Survival data (ficha siguiente) se puede construir la curva de Kaplan-Meier paso a paso.
- **Siguiente nivel**: Veteran, Melanoma y GBSG2, con datos clínicos reales.

En la carpeta `dental_fillings` ← `sa-edu-dental-fillings.tab` (datasets.biolab.si)

8.06
Análisis de supervivencia

Survival data (juguete)

`08_supervivencia/survival_toy/`

Los empastes de 10 personas inventadas (y la versión ampliada con 20): tiempo, evento y nombre, para construir a mano la primera curva de Kaplan-Meier y entender qué es un dato censurado.

Análisis de supervivencia | ⊣ Datos censurados | ◦ Juguete | ✎ Sintético

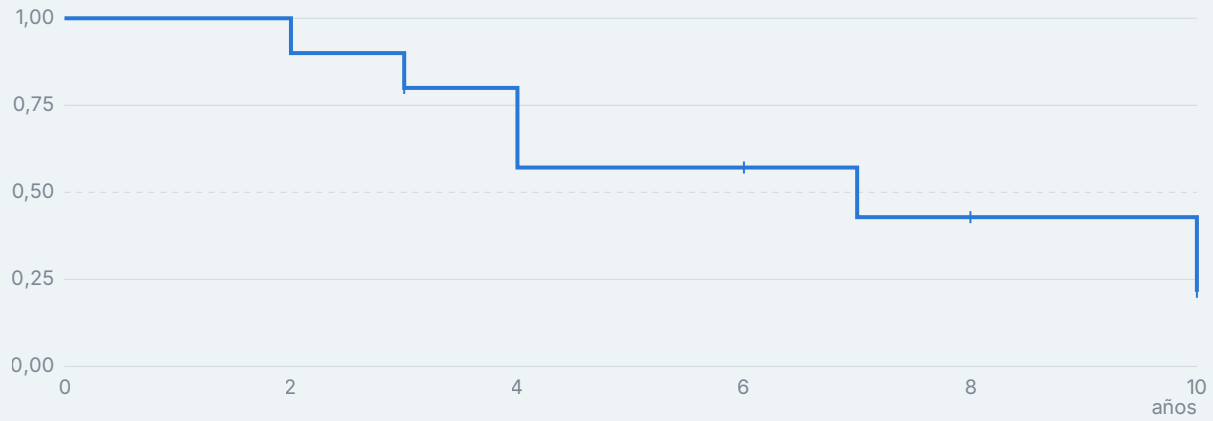
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
10	**3**	`Time, Event`	**0,0 %**	**Iniciación**	**Survival Analysis**

Fichero	Filas × col.	Descargar
`survival_data`	10 × 3	CSV 1 KB · XLSX
`survival_data_extended`	20 × 6	CSV 1 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/08_supervivencia/survival_toy/` seguido del nombre del fichero CSV.

Radiografía

Curva de Kaplan-Meier de las 10 personas (las rayitas verticales son censuras)



1 Descripción general y estudios habituales

Dos tablas del mismo ejemplo inventado sobre empastes dentales:

- `survival_data` : 10 personas, con solo tres columnas: el **tiempo** en años, si el empaste **se cayó** (evento) o no (censura) y el nombre.
- `survival_data_extended` : 20 personas (las 10 anteriores y 10 más) con el material del empaste, el tiempo de cepillado y si prefieren perros o gatos. Es idéntica a `dental_fillings` (ficha anterior).

Los estudios habituales son:

- **Construir a mano la curva de Kaplan-Meier** con la tabla de 10 personas.

- **Entender la censura**: qué cambia si se ignora o si se quitan los censurados.

2 Contexto y fuente original

Los preparó el equipo de **Orange** para la introducción al análisis de supervivencia de su libro en línea. La tabla de 10 personas es lo bastante pequeña para hacer todos los cálculos en la pizarra.

- Material de Biolab: introducción al análisis de supervivencia

3 Variable objetivo

El objetivo son `Time` (años, de 2 a 10) y `Event` (1 = se cayó el empaste; 0 = censurado), marcados como objetivo en las dos tablas.

En la tabla de 10 personas hay 6 eventos y 4 censuras. La curva de Kaplan-Meier baja a 0,9 a los 2 años, a 0,8 a los 3, a 0,57 a los 4, a 0,43 a los 7 y a 0,21 a los 10. La **mediana de supervivencia es de 7 años**. Si se calculara la media de los tiempos sin tener en cuenta la censura, saldría 5,7 años: demasiado baja, porque los censurados duraron *al menos* su tiempo.

4 Diccionario de columnas

Columnas de `survival_data` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Time` `objetivo`	numérica	**Objetivo (tiempo)**: años desde que se puso el empaste hasta que se cayó o terminó la observación.	2 – 10
`Event` `objetivo`	categórica	**Objetivo (evento)**: 1 = el empaste se cayó; 0 = censurado (no se cayó o se perdió el seguimiento).	1 (6), 0 (4)
`Name`	texto	Nombre inventado (meta).	Anthony (1), Bert (1), Chloe (1), David (1), Elle (1), Fay (1) …

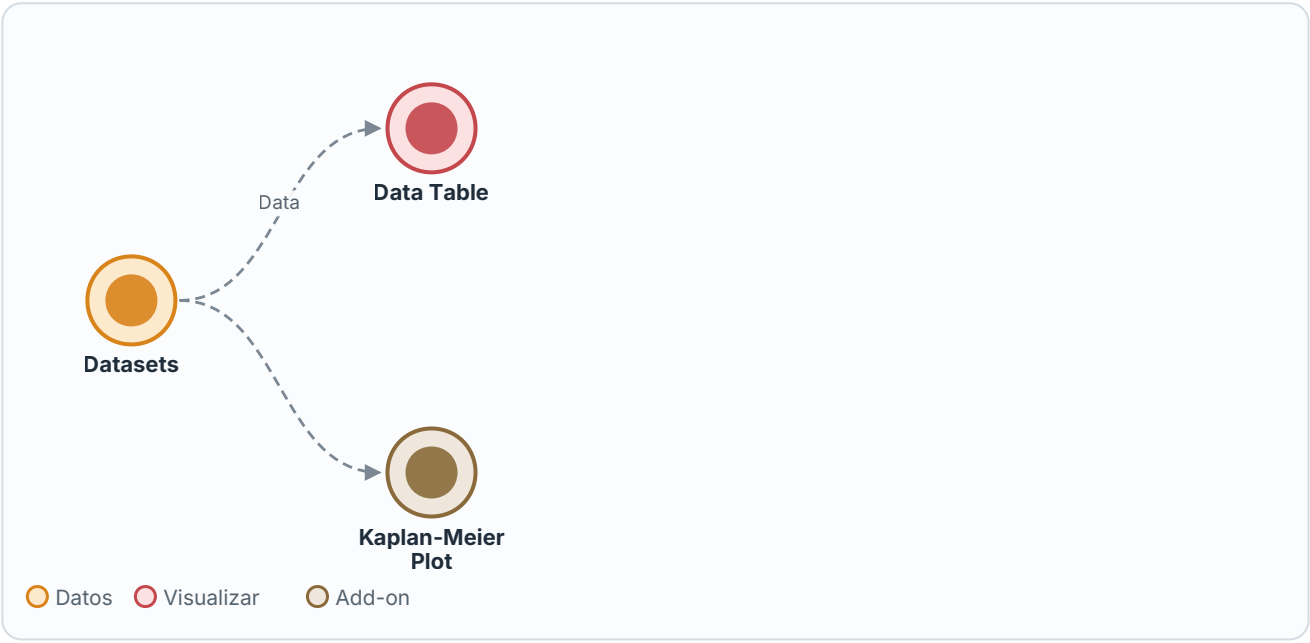
Columnas de `survival_data_extended` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Name`	texto	Nombre inventado (meta).	Anthony (1), Bert (1), Chloe (1), David (1), Elle (1), Fay (1) …
`Time` `objetivo`	numérica	**Objetivo (tiempo)**, como en la tabla anterior.	2 – 10
`Event` `objetivo`	categórica	**Objetivo (evento)**, como en la tabla anterior.	1 (12), 0 (8)
`Type of material`	categórica	Material del empaste: `composite` o `ceramic`.	composite (10), ceramic (10)
`Brushing time`	numérica	Minutos de cepillado al día.	4 – 15
`Cat or dog person`	categórica	Si prefiere los gatos o los perros (variable de control sin efecto).	Dog (10), Cat (10)

5 Particularidades técnicas al modelar

- **Empates**: dos personas en el año 3 (una con evento y otra censurada) y dos con evento en el año 4. Es el detalle que hay que entender para calcular bien la curva: en cada momento, primero se cuentan los eventos y luego se retiran los censurados.
- **La censura no es un dato perdido**: quitar a los censurados o tratarlos como eventos da curvas distintas y sesgadas.
- **Duplicado**: `survival_data_extended` es igual que `dental_fillings`, pero con `Time` y `Event` ya marcados como objetivo.

6 Flujo de trabajo en Orange



1. Instala el add-on **Survival Analysis**.
2. **Datasets** → «Toy survival data» y **Data Table** ordenada por `Time`.
3. Calcula a mano la curva: en cada tiempo con eventos, multiplica la supervivencia anterior por (1 − eventos / personas en riesgo).
4. **Kaplan-Meier Plot**: comprueba tus cálculos y la mediana (7 años).
5. Repite con la versión ampliada, agrupando por material.

7 Otras consideraciones

- **Ejercicio de sesgo**: calcula la media de `Time` solo con los eventos y con todos; compárala con la mediana de Kaplan-Meier.
- **Continuación**: SA: Dental Fillings (mismos datos ampliados) y luego Veteran.

En la carpeta	`survival_data` ← `survival_data.csv` (datasets.biolab.si)
En la carpeta	`survival_data_extended` ← `survival_data_extended.csv` (datasets.biolab.si)

8.07
Análisis de supervivencia

TCGA: cáncer de cuello uterino (CESC) y de mama (BRCA)

`08_supervivencia/tcga/`

Expresión de unos 23.000 genes y supervivencia de 306 tumores de cuello uterino (TCGA-CESC), más un enlace a los 1.119 de mama (TCGA-BRCA): análisis de supervivencia con muchas más variables que pacientes.

Análisis de supervivencia · ⋮ Alta dimensionalidad · ⊣ Datos censurados · ◈ Mixto num. + cat.

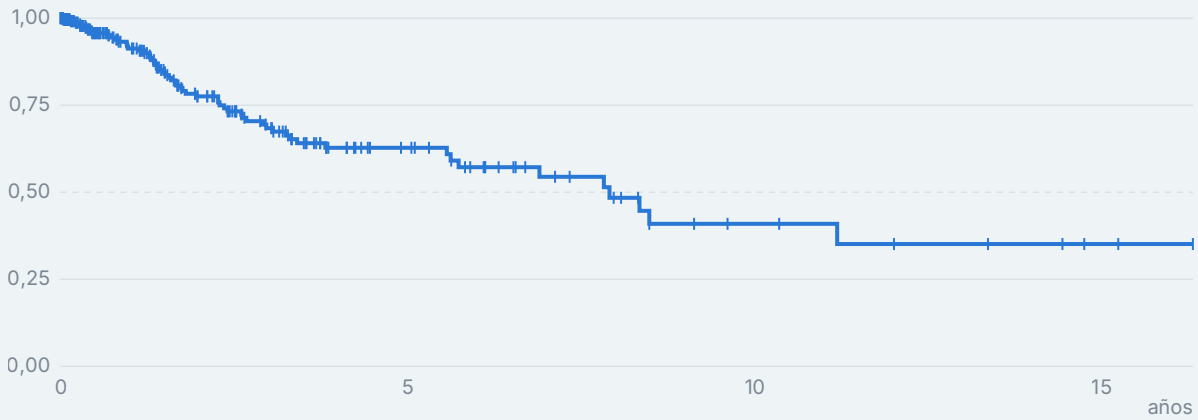
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
306	**23.371**	`Time, Event`	**0,0 %**	**Avanzado**	**Survival Analysis**

Fichero	Filas × col.	Descargar
`tcga_cesc`	306 × 23.371	CSV 49,5 MB · XLSX XLSX recortado a 16.384 columnas
`sa-edu-TCGA-BRCA.pkl`	1.119 × 22.829	Original de Orange no incluido (> 100 MB)

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/08_supervivencia/tcga/` seguido del nombre del fichero CSV.

Radiografía

Supervivencia global (Kaplan-Meier) de las 306 muestras de TCGA-CESC



1 Descripción general y estudios habituales

Dos datasets del programa **The Cancer Genome Atlas** (TCGA), preparados por Orange para enseñar análisis de supervivencia con datos genómicos:

- `tcga_cesc` (incluido): 306 muestras de **cáncer de cuello uterino** con la expresión de 23.368 genes (en TPM, transcritos por millón), el tiempo de seguimiento, el evento (muerte) y el identificador de la muestra.

- **TCGA-BRCA** (solo enlace): 1.119 muestras de **cáncer de mama** con 22.826 genes. El fichero original de Orange (`.pkl`, 206 MB) supera el límite de tamaño de esta colección incluso comprimido.

Los estudios habituales son:

- **Selección de genes pronósticos**: qué genes se asocian con la supervivencia.
- **Regresión de Cox regularizada** (Lasso) con más variables que pacientes.
- **Firmas génicas y grupos de riesgo** (cohortes alto y bajo).

2 Contexto y fuente original

TCGA es un proyecto del Instituto Nacional del Cáncer de Estados Unidos que secuenció miles de tumores de más de 30 tipos de cáncer. Orange toma los datos de expresión de la serie **GSE62944** de GEO, en la que **Mumtahena Rahman y colaboradores** (2015) reprocesaron de forma uniforme los datos de RNA-seq de TCGA, junto con el tiempo y el evento de supervivencia de cada paciente. Los nombres de los ficheros empiezan por `sa-edu` porque son parte del material de enseñanza de análisis de supervivencia de Biolab.

- GSE62944: datos de RNA-seq de TCGA reprocesados (GEO)
- SA: TCGA-BRCA en el repositorio de datasets de Orange (solo enlace, .pkl de 206 MB)

3 Variable objetivo

En `tcga_cesc`, el objetivo son `Time` (días de seguimiento, de 0 a 5.957, unos 16 años) y `Event` (1 = muerte, 59 pacientes, el 19 %; 0 = censurado, 247). Con tan pocos eventos, la mediana de supervivencia no se alcanza.

El reto es estadístico: hay **76 genes por cada paciente** y solo 59 eventos. Cualquier gen puede parecer pronóstico por azar; hay que corregir por comparaciones múltiples y validar con datos independientes. En el fichero `.pkl` de TCGA-BRCA, el tiempo y el evento no vienen marcados como objetivo.

4 Diccionario de columnas

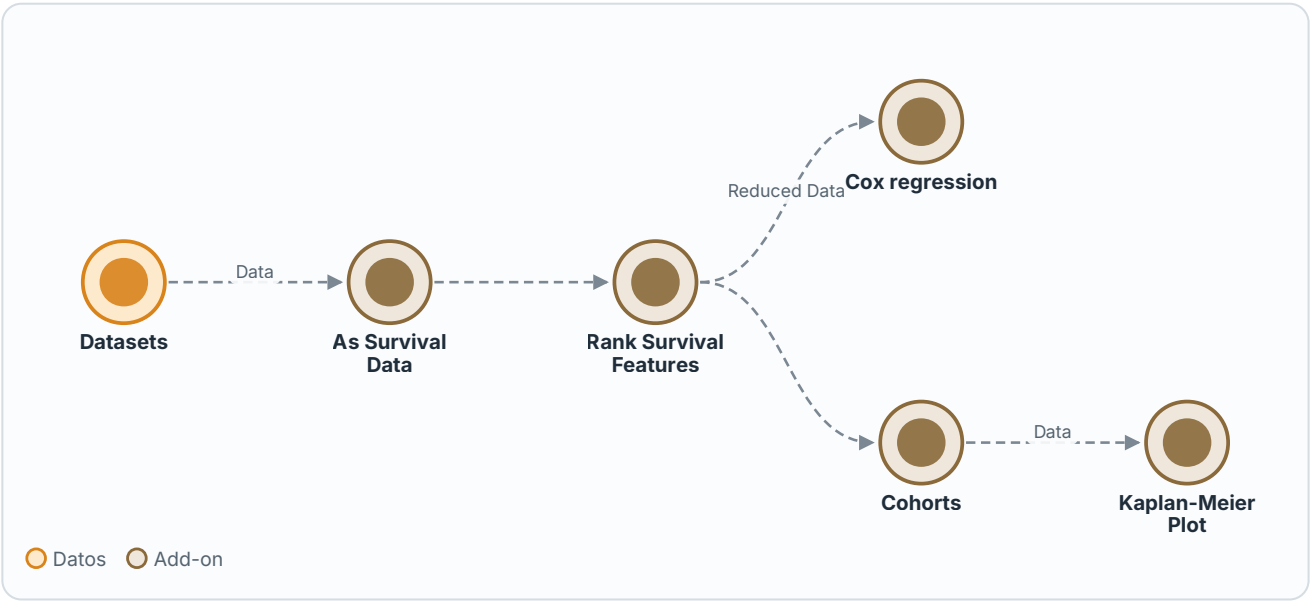
Columnas de `tcga_cesc` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`1/2-SBSRNA4`	numérica	Expresión del gen o transcrito `1/2-SBSRNA4` (TPM). Igual para cada gen, por orden alfabético.	
`A1BG`	numérica	Expresión del gen A1BG (TPM).	
`Time` objetivo	numérica	**Objetivo (tiempo)**: días desde el diagnóstico hasta la muerte o el último seguimiento. 28 muestras tienen 0.	
`Event` objetivo	categórica	**Objetivo (evento)**: 1 = muerte; 0 = censurado.	
`Sample`	texto	Código de la muestra de TCGA (meta), p. ej. `TCGA-C5-A3HE-01A-21R-A22U-07`; los 12 primeros caracteres identifican a la paciente.	
…		y 23.366 columnas más: una por gen (de `1/2-SBSRNA4` a `tAKR`, por orden alfabético), con su expresión en TPM.	

5 Particularidades técnicas al modelar

- **Ficheros grandes**: el CSV va comprimido en ZIP (49 MB) y el **XLSX está recortado a 16.384 columnas**, el máximo de Excel; el CSV tiene los 23.368 genes. Para trabajar con todos, usa el CSV o el fichero de Orange.
- **637 genes siempre valen 0**: Orange los lee como variables categóricas de un solo valor. No aportan nada; quítalos antes de analizar.
- **TPM**: cada muestra suma un millón de transcritos. Los valores son muy asimétricos; se suele usar log2(TPM + 1).
- **Dos pacientes tienen dos muestras** (306 muestras de 304 pacientes): para el análisis de supervivencia conviene quedarse con una por paciente.
- **Tiempo 0 en 28 muestras**: pacientes sin seguimiento. Algunos programas de supervivencia los rechazan.
- **Más variables que pacientes**: la regresión de Cox sin regularizar no converge; hay que seleccionar genes antes o usar Lasso.

6 Flujo de trabajo en Orange



1. Instala el add-on **Survival Analysis**.
2. **Datasets** → «SA: TCGA-CESC» (la descarga es grande) y **As Survival Data**.
3. **Rank Survival Features**: ordena los genes por su asociación con la supervivencia y quédate con los 10–20 mejores.
4. **Cox regression** con regularización Lasso sobre esos genes.
5. **Cohorts** (riesgo alto y bajo) → **Kaplan-Meier Plot**; para ser honesto, la selección de genes debe hacerse dentro de la validación cruzada.

7 Otras consideraciones

- **Sesgo de selección**: elegir genes con todos los datos y luego validar con los mismos datos da curvas espectacularmente separadas que no se repiten en datos nuevos. Es la lección principal de este dataset.
- **Comparar con METABRIC y SCAN-B**: cáncer de mama con miles de pacientes, donde las firmas son más estables.

En la carpeta `tcga_cesc` ← `sa-edu-TCGA-CESC.tab` (datasets.biolab.si)

Solo enlace (> 100 MB)	`sa-edu-TCGA-BRCA.pkl` (datasets.biolab.si)

8.08
Análisis de supervivencia

METABRIC (cáncer de mama)

`08_supervivencia/metabric/`

1.904 pacientes con cáncer de mama con 35 variables clínicas y la expresión de 24.368 genes: un estudio de referencia en supervivencia y subtipos moleculares. Solo ficha y enlace: el fichero supera los 100 MB.

Análisis de supervivencia | ⋮ Alta dimensionalidad | ⊣ Datos censurados

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
1.904	**24.403**	`Overall Survival Time [months]`, `Survival Event`	**0,0 %**	**Avanzado**	**Survival Analysis**

Fichero	Filas × col.	Descargar
`brca_metabric.pkl.gz`	1.904 × 24.403	Original de Orange no incluido (> 100 MB)

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/08_supervivencia/metabric/` seguido del nombre del fichero CSV.

1 Descripción general y estudios habituales

METABRIC (*Molecular Taxonomy of Breast Cancer International Consortium*) reúne tumores primarios de mama de 1.904 pacientes del Reino Unido y Canadá con un seguimiento de muchos años. Para cada paciente hay **35 variables clínicas** (edad, tamaño, grado y estadio del tumor, receptores hormonales y HER2, subtipo histológico, cirugía, tratamientos, celularidad, clasificación de tres genes, estado vital, recaída…) y la **expresión de 24.368 genes** medida con microarrays.

Los estudios habituales son:

- **Supervivencia global** y libre de recaída según variables clínicas y subtipos.
- **Firmas génicas pronósticas** con muchos pacientes.
- **Subtipos moleculares** (los 10 grupos integrativos del estudio original, PAM50).

En esta colección no se incluye el fichero: el `.pkl.gz` de Orange (143 MB) supera el límite de 100 MB incluso comprimido. Se puede abrir directamente en Orange con el widget **Datasets** o descargar desde el enlace.

2 Contexto y fuente original

El estudio lo publicaron **Christina Curtis y colaboradores** en *Nature* (2012) y describió 10 subgrupos de cáncer de mama con pronósticos distintos; trabajos posteriores (Pereira 2016, Rueda 2019) ampliaron las mutaciones y la dinámica de las recaídas. Orange toma los datos de **cBioPortal**: la expresión está en **z-scores** del logaritmo del ARNm, comparando cada gen con su distribución en todas las muestras (microarray Illumina Human v3).

- Curtis, C. et al. (2012). The genomic and transcriptomic architecture of 2,000 breast tumours reveals novel subgroups. Nature, 486, 346–352.

- METABRIC en cBioPortal (fuente de Orange)
- METABRIC en el repositorio de datasets de Orange (.pkl.gz, 143 MB)

3 Variable objetivo

En el fichero de Orange, el objetivo son `Overall Survival Time [months]` y `Survival Event` (1 = muerte, 1.103 pacientes; 0 = censurado, 801). Hay más variables de resultado entre las clínicas: `Relapse Event` (recaída) y `Vital Status`, que distingue la muerte por cáncer de mama de la muerte por otras causas.

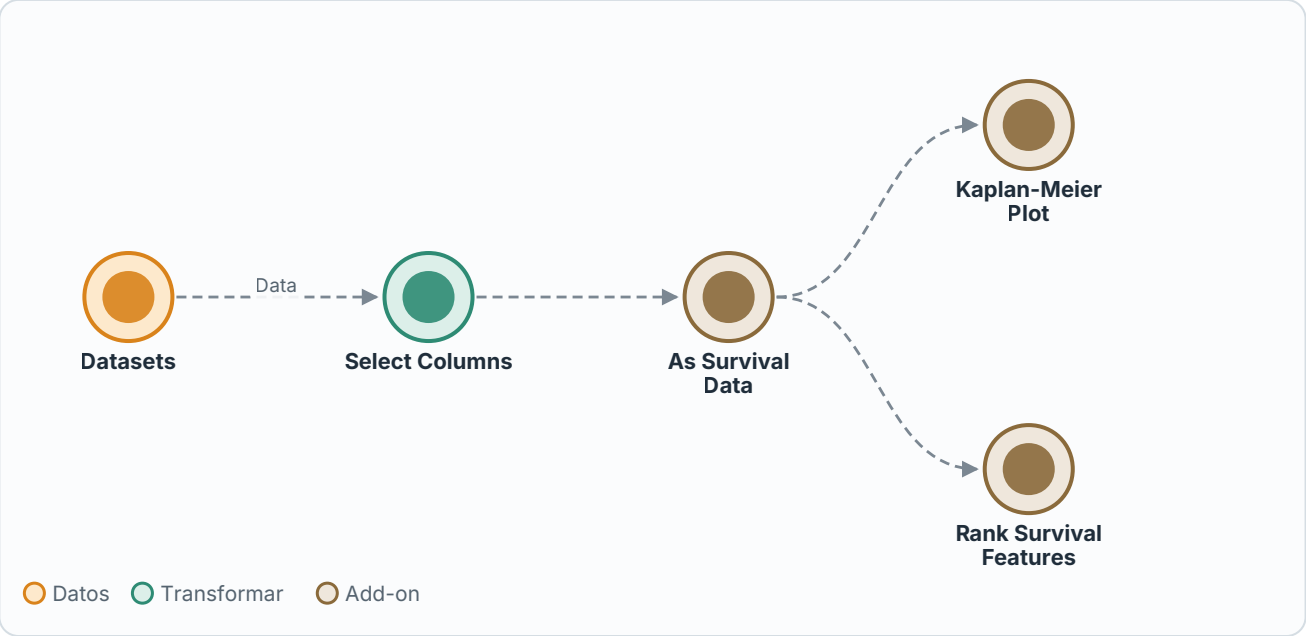
4 Diccionario de columnas

El fichero no se incluye en la colección, así que no hay diccionario columna a columna. Las variables clínicas y de supervivencia se describen en las secciones 1 y 3; el resto de columnas son genes.

5 Particularidades técnicas al modelar

- **Solo ficha**: el fichero no está en la carpeta `ciencia_de_datos`; ábrelo con **Datasets** en Orange.
- **Z-scores, no valores brutos**: cada gen está centrado y escalado respecto a todas las muestras. Sirve para comparar pacientes, no para comparar genes entre sí.
- **Fuga de información**: `Vital Status` y `Relapse Event` describen el desenlace. Si se predice la supervivencia, no deben usarse como atributos.
- **Muertes por otras causas**: muchas pacientes murieron por causas distintas del cáncer; para la supervivencia específica hay que recodificar el evento con `Vital Status`.
- **Pocos huecos** (0,2 % de celdas), sobre todo en variables clínicas (celularidad, estadio, tamaño) y en unos pocos genes.

6 Flujo de trabajo en Orange



1. Instala los add-ons **Survival Analysis** y **Bioinformatics**.
2. **Datasets** → «METABRIC» (descarga de 143 MB).
3. **Select Columns**: quita las variables de desenlace que no son el objetivo.
4. **Kaplan-Meier Plot** por receptor de estrógeno, grado o subtipo.
5. **Rank Survival Features** con los genes y **Cox regression** con los mejores.

7 Otras consideraciones

- **Validación externa**: entrenar una firma en METABRIC y comprobarla en SCAN-B (GSE96058) o TCGA-BRCA es un ejercicio realista.
- **cBioPortal** permite explorar los mismos datos en el navegador sin descargar nada.

Solo enlace (> 100 MB)	`brca_metabric.pkl.gz` (datasets.biolab.si)

8.09
Análisis de supervivencia

SCAN-B GSE96058 (cáncer de mama)

`08_supervivencia/gse96058/`

3.273 cánceres de mama de la cohorte poblacional sueca SCAN-B, con RNA-seq de unos 23.800 genes, biomarcadores clínicos, subtipos PAM50, tratamientos y supervivencia global. Solo ficha y enlace: el fichero supera los 100 MB.

Análisis de supervivencia | ⋮ Alta dimensionalidad | ⊣ Datos censurados

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
3.273	**23.804**	`overall survival days, overall survival event`	**0,0 %**	**Avanzado**	**Survival Analysis**

Fichero	Filas × col.	Descargar
`GSE96058.pkl.gz`	3.273 × 23.804	Original de Orange no incluido (> 100 MB)

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/08_supervivencia/gse96058/` seguido del nombre del fichero CSV.

1 Descripción general y estudios habituales

La cohorte **SCAN-B** (*Sweden Cancerome Analysis Network – Breast*) recogió de forma prospectiva tumores primarios de mama en varios hospitales suecos. El dataset GSE96058 incluye 3.273 tumores con la **expresión génica por RNA-seq**, los biomarcadores de rutina (receptores de estrógeno y progesterona, HER2, Ki67, grado de Nottingham), el tamaño y la afectación ganglionar, los tratamientos endocrino y de quimioterapia, el **subtipo PAM50** y la **supervivencia global**.

Los estudios habituales son:

- **Predecir los biomarcadores clínicos** a partir de la expresión génica (el objetivo del estudio original).
- **Supervivencia** según subtipos, tratamientos y genes.
- **Validación** de firmas génicas en una cohorte poblacional grande.

En esta colección no se incluye el fichero: el `.pkl.gz` de Orange (462 MB) supera el límite de 100 MB. Se puede abrir en Orange con **Datasets** o descargar desde el enlace.

2 Contexto y fuente original

Lo publicaron **Christian Brueffer y colaboradores** (2018) para comprobar si los clasificadores basados en RNA-seq predicen los cinco biomarcadores convencionales tan bien como la anatomía patológica. Los datos

de expresión están procesados; las lecturas brutas no se publican por privacidad. Orange preparó la versión en 2025.

- Brueffer, C. et al. (2018). Clinical Value of RNA Sequencing–Based Classifiers for Prediction of the Five Conventional Breast Cancer Biomarkers. JCO Precision Oncology, 2.
- GSE96058 en el repositorio de datasets de Orange (.pkl.gz, 462 MB)

3 Variable objetivo

En el fichero de Orange, el objetivo son `overall survival days` y `overall survival event` (1 = muerte, 336 pacientes, el 10 %; 0 = censurado, 2.937). Con tan pocos eventos y un seguimiento corto, la mediana de supervivencia no se alcanza. Los biomarcadores clínicos (`er status`, `pgr status`, `her2 status`, `ki67 status`, `nhg`) también pueden usarse como objetivos de clasificación.

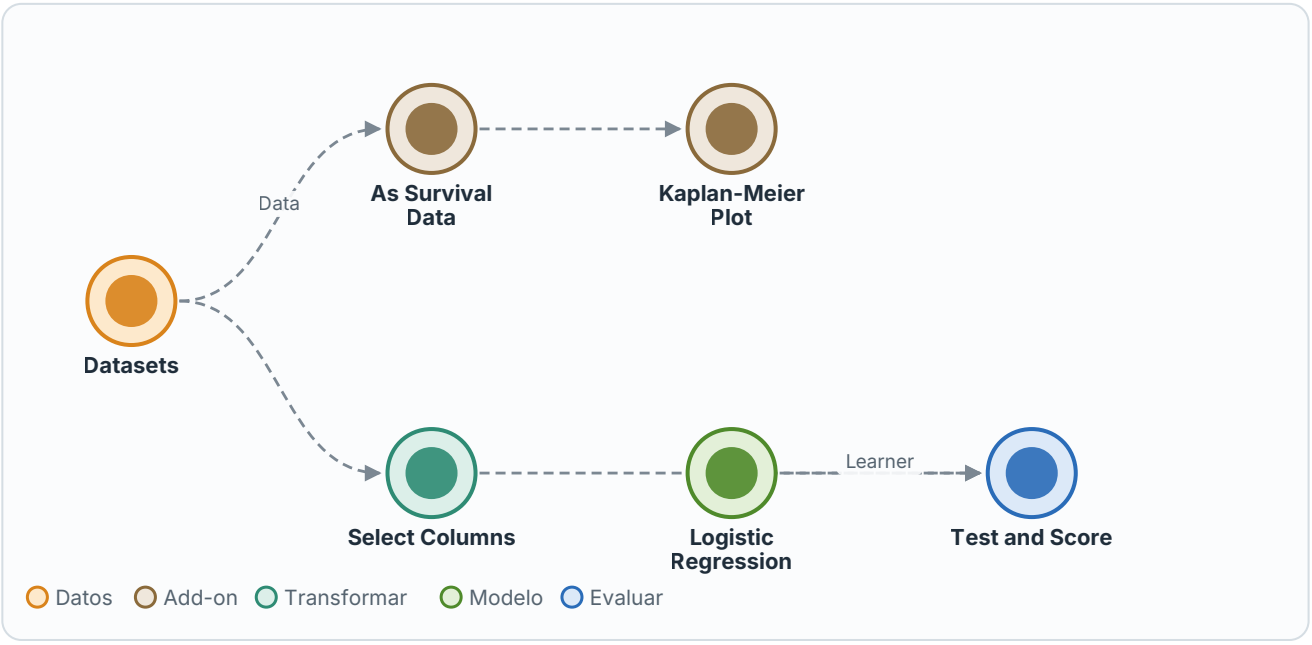
4 Diccionario de columnas

El fichero no se incluye en la colección, así que no hay diccionario columna a columna. Las variables clínicas y de supervivencia se describen en las secciones 1 y 3; el resto de columnas son genes.

5 Particularidades técnicas al modelar

- **Solo ficha**: el fichero no está en la carpeta `ciencia_de_datos`; ábrelo con **Datasets** en Orange.
- **Pocos eventos** (10 %): las curvas de supervivencia bajan poco y los modelos pronósticos tienen poca potencia.
- **Huecos en variables clínicas**: tamaño del tumor, ganglios, receptores, HER2, Ki67, grado y tratamientos tienen valores ausentes (no todos los centros los registraron).
- **Muchas variables**: unos 23.800 genes para 3.273 pacientes; la selección de variables y la regularización son imprescindibles.

6 Flujo de trabajo en Orange



1. Instala los add-ons **Survival Analysis** y **Bioinformatics**.
2. **Datasets** → «SCAN-B (GSE96058)» (descarga de 462 MB).
3. **As Survival Data** y **Kaplan-Meier Plot** por subtipo PAM50 o por tratamiento.

4. Para clasificación: **Select Columns** con `er status` como objetivo y los genes como atributos.
5. **Test and Score** con regresión logística regularizada: la expresión del gen del receptor de estrógeno (*ESR1*) debería ser de las variables más útiles.

7 Otras consideraciones

- **Validación externa** de firmas entrenadas en METABRIC o TCGA-BRCA.
- **Comparar RNA-seq y anatomía patológica**: es la pregunta del estudio original; reproducirla con los biomarcadores del fichero es un buen ejercicio de clasificación.

Solo enlace (> 100 MB) `GSE96058.pkl.gz` (datasets.biolab.si)

9 Series temporales y ventas

7 datasets en el capítulo; en esta edición, 7 con ficha.

9.01
Series temporales y ventas

Airline passengers (Box-Jenkins)

`09_series_temporales/airline_passengers/`

Pasajeros mensuales de líneas aéreas internacionales entre 1949 y 1960: la serie temporal de manual, con tendencia y estacionalidad creciente.

Predicción de series temporales · Temporal

> **En el curso:** Actividad 6.1 (Tema 6): ARIMA, diferenciación, descomposición estacional y evaluación con ventana deslizante.

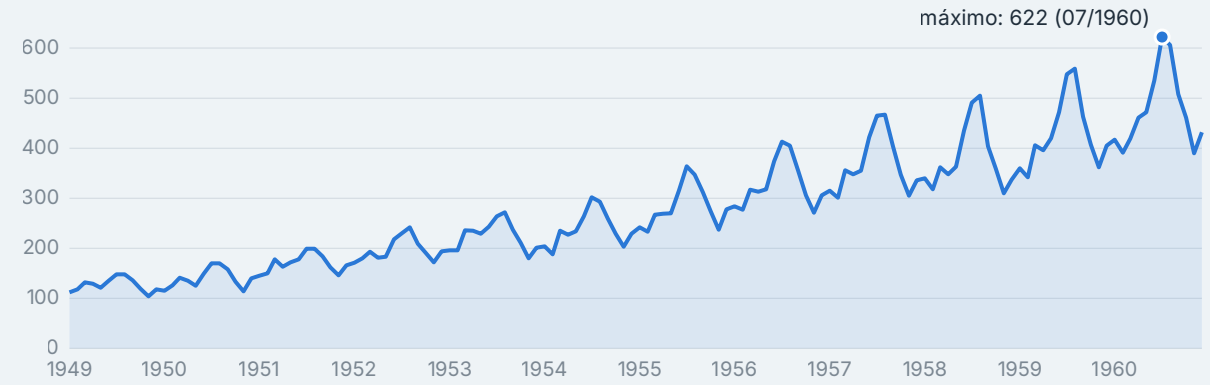
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
144	**2**	`Passengers`	**0,0 %**	**Intermedio**	**Timeseries**

Fichero	Filas × col.	Descargar
`airline_passengers`	144 × 2	CSV 2 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/09_series_temporales/airline_passengers/` seguido del nombre del fichero CSV.

Radiografía

Pasajeros al mes (miles), 1949–1960



1 Descripción general y estudios habituales

Son 144 valores mensuales, de enero de 1949 a diciembre de 1960: el total de pasajeros de líneas aéreas internacionales de cada mes, en **miles de pasajeros**. Solo hay dos columnas: la fecha y el número de pasajeros.

Es la serie con la que se enseñan los modelos de series temporales desde hace más de cincuenta años, porque reúne a la vista los tres ingredientes típicos: tendencia creciente, ciclo anual y una amplitud del ciclo que crece con el nivel. Los estudios habituales son:

- **Predecir los próximos meses** (predicción de series temporales) con ARIMA, suavizado exponencial o modelos con variables de retardo.
- **Descomponer** la serie en tendencia, estacionalidad y residuo, y comparar la descomposición aditiva con la multiplicativa.
- **Transformar para estabilizar**: diferenciar (para quitar la tendencia) y aplicar logaritmos (para que el ciclo no crezca).
- **Evaluar bien una predicción**, con validación que respeta el orden temporal.

2 Contexto y fuente original

La serie la popularizaron George Box y Gwilym Jenkins en su libro *Time Series Analysis: Forecasting and Control* (1970; 2.ª ed. 1976), donde aparece como «Serie G» y se usa para presentar el modelo ARIMA estacional $(0,1,1)\times(0,1,1)_{12}$ sobre el logaritmo de los datos, conocido desde entonces como **modelo de las aerolíneas** (*airline model*). La serie ya aparecía en un libro anterior de Robert G. Brown sobre suavizado y predicción de series (1962).

Viene incluida en R (`datasets::AirPassengers`) y en casi todas las librerías de series temporales. La versión del repositorio del curso estaba en ARFF (`seriestemp_airline.arff`) y CSV con el mismo contenido; aquí queda en CSV y XLSX con la fecha en formato ISO.

- Box, G. E. P. y Jenkins, G. M. (1976). Time Series Analysis: Forecasting and Control (ed. revisada). Holden-Day. Serie G. Documentación en R (datasets::AirPassengers).
- Brown, R. G. (1962). Smoothing, Forecasting and Prediction of Discrete Time Series. Prentice-Hall (fuente anterior de la serie).

3 Variable objetivo

La variable a predecir es `Passengers`, en miles de pasajeros al mes. Va de 104 (noviembre de 1949) a 622 (julio de 1960): el total anual se multiplica casi por cuatro en doce años, de 1,52 a 5,71 millones.

Cada año repite el mismo dibujo: máximo en julio y agosto, mínimo en noviembre y un repunte en diciembre. El ciclo es **multiplicativo**: en 1949 el mes más alto superaba al más bajo en un 42 %, y en 1960 en un 59 %, con una diferencia absoluta que pasa de 44 a 232 mil pasajeros.

4 Diccionario de columnas

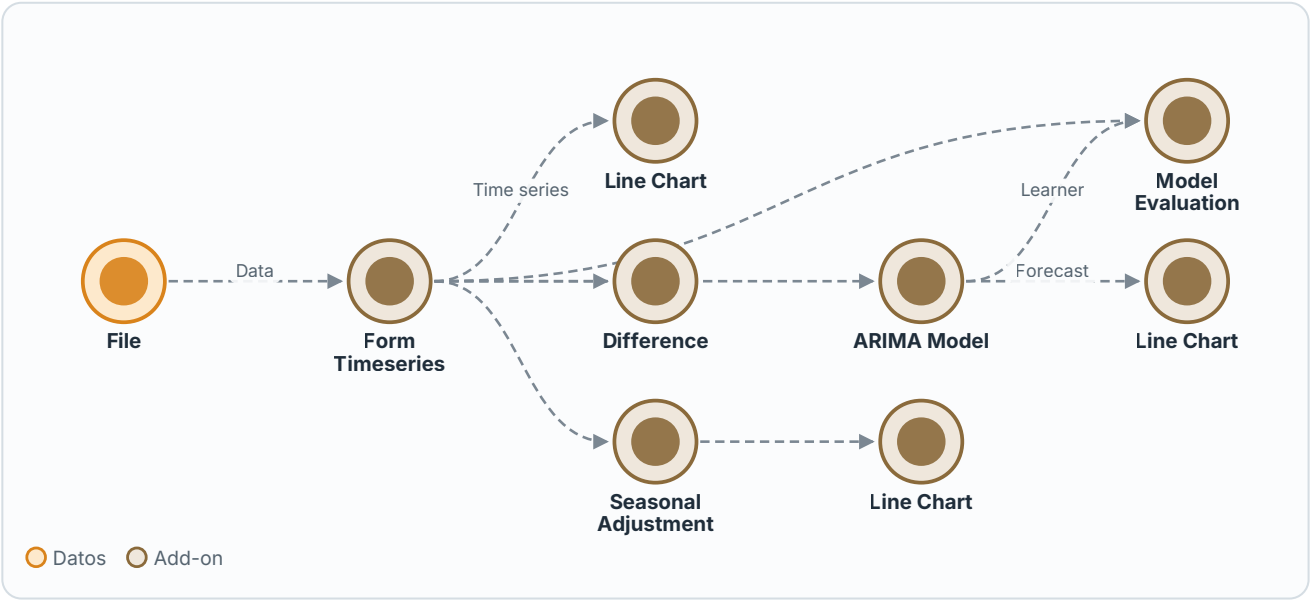
Columnas de `airline_passengers` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Passengers`	numérica	Total mensual de pasajeros de líneas aéreas internacionales, en miles. Es la variable a predecir.	104 – 622
`Date`	fecha/hora	Mes de la observación (primer día del mes, en formato AAAA-MM-DD).	1949-01-01 (1), 1949-02-01 (1), 1949-03-01 (1), 1949-04-01 (1), 1949-05-01 (1), 1949-06-01 (1) …

5 Particularidades técnicas al modelar

- **En Orange hay que convertir la tabla en serie temporal**: con el add-on *Timeseries*, el widget *Form Timeseries* (en versiones anteriores, *As Timeseries*) indica qué columna es la fecha. Además, en *File* hay que marcar `Passengers` como *target*: sin objetivo, *ARIMA Model* y *Model Evaluation* dan error.
- **No es estacionaria**: tiene tendencia y estacionalidad. Un ARIMA sin diferenciar predice mal (la predicción se aplana o baja). Diferencia una vez (*Difference*) para quitar la tendencia, y en el retardo 12 para quitar el ciclo anual, o incluye un término de 12 meses en el modelo.
- **El ciclo crece con el nivel**: usa descomposición **multiplicativa** en *Seasonal Adjustment*, o aplica el logaritmo antes de modelar (con *Feature Constructor*, `log(Passengers)`) para que el ciclo tenga amplitud constante.
- **Validación**: nunca validación cruzada aleatoria, porque mezcla el futuro con el pasado. *Model Evaluation* usa ventanas que avanzan en el tiempo. Con solo 144 meses, deja al menos 2 años (24 valores) para evaluar.
- **Serie corta**: 12 ciclos completos. Modelos con muchos parámetros (por ejemplo, un AR de orden 12 sin diferenciar) se ajustan bien a los datos conocidos y fallan fuera.
- El fichero original del curso era ARFF, que Orange 3 no abre por sí solo (en clase se usó el add-on *Orange ARFF*). Este CSV y el XLSX se abren directamente con *File*.

6 Flujo de trabajo en Orange



1. **File**: abre `airline_passengers.csv` y marca `Passengers` como *target*.
2. **Form Timeseries**: elige `Date` como variable de tiempo. → **Line Chart**: tendencia, ciclo anual y amplitud creciente.
3. **Difference** (orden 1, y después retardo 12) → Line Chart: la tendencia desaparece; si no se quita el ciclo, sigue ahí.
4. **Seasonal Adjustment** con periodo 12 y modelo multiplicativo → Line Chart: original, tendencia, componente estacional y residuo.
5. **ARIMA Model**: prueba órdenes con diferenciación (d = 1) y un término de 12 meses; conecta su salida *Forecast* a la entrada de previsión de un **Line Chart** para ver la predicción con su intervalo.
6. **Model Evaluation**: horizonte de 1 a 12 meses y ventana que avanza; compara MAE, RMSE y MAPE entre modelos.

7 Otras consideraciones

- **Para pasar a regresión**: con *Moving Transform* o creando retardos (pasajeros de hace 1, 2 y 12 meses) como columnas, la serie se convierte en un problema de regresión que pueden resolver Random Forest o regresión lineal. Comparar con ARIMA es un buen ejercicio.
- **El modelo de las aerolíneas**, ARIMA $(0,1,1)\times(0,1,1)_{12}$ sobre el logaritmo, es la referencia clásica: cualquier modelo que se proponga debería compararse con él.
- **Correlogram** muestra el pico de autocorrelación en el retardo 12, que justifica el término estacional.
- La serie termina en 1960: sirve para enseñar técnica, no para sacar conclusiones sobre el transporte aéreo actual.

En la carpeta	`airline_passengers` ← `seriestemp_airline.csv` (curso_ciencia_datos (GitHub))
Duplicado, no se copia	`seriestemp_airline.arff` (curso_ciencia_datos (GitHub))

9.02
Series temporales y ventas

Australian wine sales

`09_series_temporales/australian_wines/`

Ventas mensuales de seis tipos de vino australiano entre 1980 y 1994: seis series con tendencias opuestas y ciclos anuales distintos, para comparar modelos de predicción serie a serie.

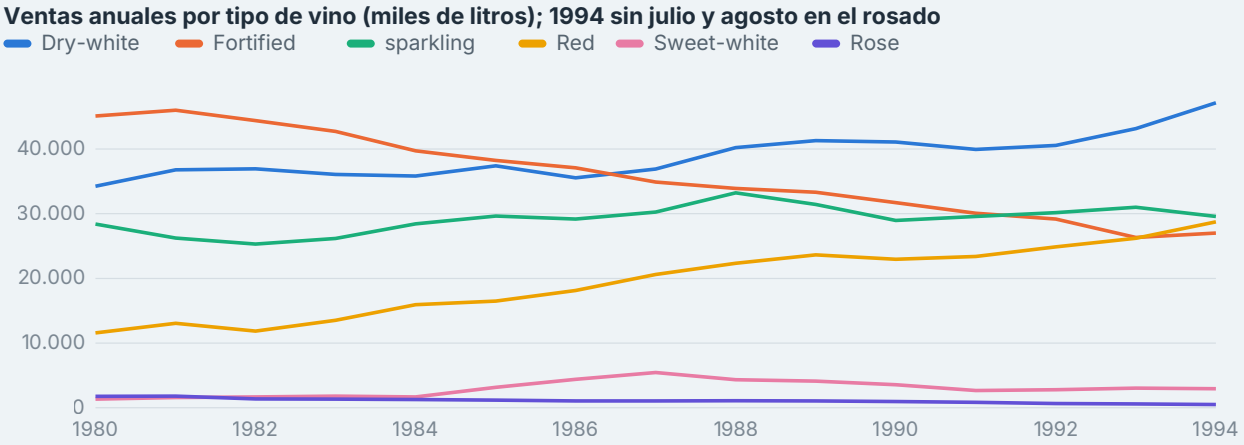
Predicción de series temporales · ? Valores faltantes · ⊕ Multiobjetivo · ◷ Temporal

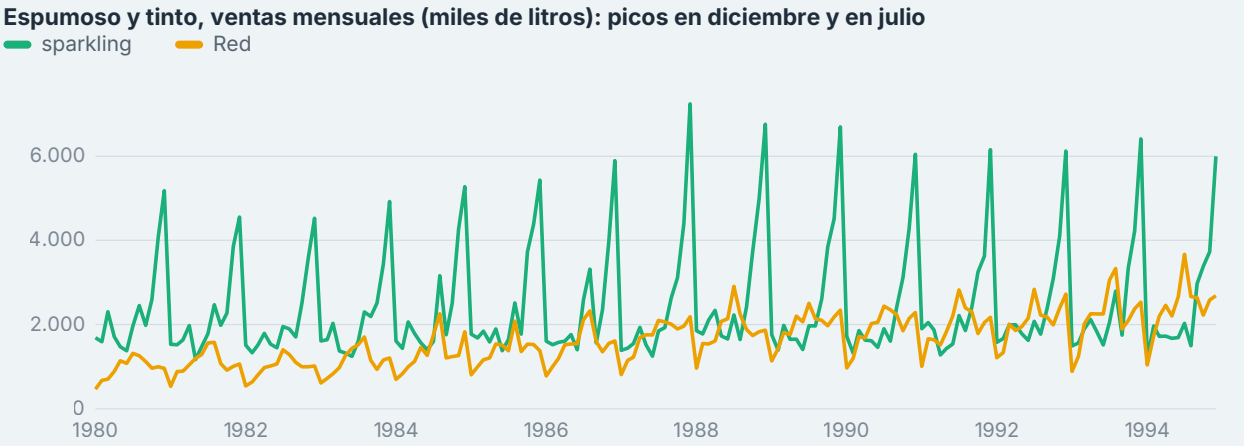
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
180	**7**	`6 series`	**0,2 %**	**Intermedio**	**Timeseries**

Fichero	Filas × col.	Descargar
`australian_wines`	180 × 7	CSV 7 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/09_series_temporales/australian_wines/` seguido del nombre del fichero CSV.

Radiografía





1 Descripción general y estudios habituales

Son 180 meses, de enero de 1980 a diciembre de 1994. Cada fila es un mes, con las ventas de seis tipos de vino en **miles de litros**: generoso (`Fortified`), tinto (`Red`), rosado (`Rose`), espumoso (`sparkling`), blanco dulce (`Sweet-white`) y blanco seco (`Dry-white`).

Lo interesante es que las seis series cuentan historias distintas con el mismo calendario: el generoso pierde un 40 % de ventas en quince años, el tinto se multiplica por 2,5, el rosado casi desaparece y el espumoso tiene un pico enorme cada diciembre. Los estudios habituales son:

- **Predecir el año siguiente** (predicción de series temporales) de cada serie, con métodos ingenuos, suavizado exponencial, ARIMA o redes neuronales, y comparar qué método funciona mejor en cada una.
- **Descomponer** tendencia y estacionalidad, y ver que el ciclo anual no es el mismo en todos los vinos.
- **Tratar valores faltantes** en una serie temporal (el rosado tiene dos meses sin dato).
- **Comparar series**: correlación entre tipos de vino y causalidad de Granger.

2 Contexto y fuente original

Los datos proceden de la Oficina Australiana de Estadística (ABS), que publicaba las ventas de vino de las bodegas australianas por tipo. Rob Hyndman los incluyó en su *Time Series Data Library* (TSDL) como ventas mensuales de las bodegas en botellas de un litro o menos, de enero de 1980 a julio de 1995.

Esta versión, recortada a diciembre de 1994, es el fichero `AustralianWines.csv` del libro de Galit Shmueli y Kenneth Lichtendahl *Practical Time Series Forecasting with R*, que lo usa en sus ejercicios (por ejemplo, para predecir el generoso con redes neuronales). La serie total de ventas de vino de ese mismo origen está en R como `forecast::wineind` .

En el repositorio del curso, la fecha venía como `MM-AA` (`01-80`), un formato que Orange no reconoce como fecha. Aquí se ha pasado a ISO (`1980-01-01`), así que Orange la lee directamente como variable de tiempo.

- Hyndman, R. J. Time Series Data Library: ventas mensuales de vino australiano, enero de 1980 a julio de 1995 (documentación del paquete Rssa de R).
- Shmueli, G. y Lichtendahl, K. C. (2016). Practical Time Series Forecasting with R: A Hands-On Guide (2.ª ed.). Axelrod Schnall. Fichero AustralianWines.csv, copiado en el repositorio del curso.

3 Variable objetivo

No hay una única variable objetivo: cada una de las seis columnas de vino es una serie que se puede predecir. En Orange se marca como *target* la que se quiera modelar (o varias, si se usa *VAR Model*).

Ventas anuales, en miles de litros, de 1980 a 1994:

- **Generoso** (`Fortified`): baja de 45.101 a 26.998.
- **Tinto** (`Red`): sube de 11.562 a 28.759 y en 1993 ya vende casi lo mismo que el generoso.
- **Rosado** (`Rose`): baja de 1.758 a 594 (1993).
- **Espumoso** (`sparkling`): estable, entre 25.300 y 33.200.
- **Blanco dulce** (`Sweet-white`): se triplica entre 1984 y 1987 (de 1.657 a 5.454) y luego baja a unos 3.000.
- **Blanco seco** (`Dry-white`): sube de 34.247 a 47.150; es el que más vende al final.

El ciclo anual también cambia: el generoso y el tinto venden más en **julio**, que es invierno en Australia; el espumoso, los blancos y el rosado, en **diciembre**. El espumoso de diciembre vende de media cuatro veces lo de junio, y su máximo es diciembre de 1987: 7.242.

4 Diccionario de columnas

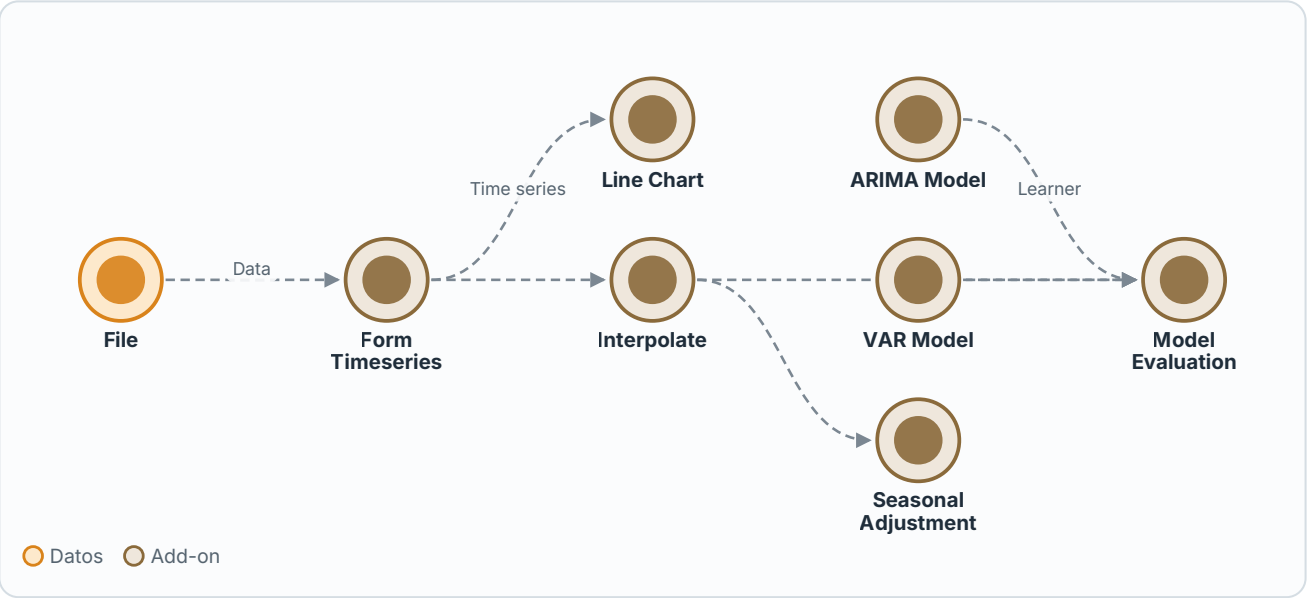
Columnas de `australian_wines` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Month`	fecha/hora	Mes (primer día del mes, AAAA-MM-DD). En el original era `MM-AA`.	1980-01-01 (1), 1980-02-01 (1), 1980-03-01 (1), 1980-04-01 (1), 1980-05-01 (1), 1980-06-01 (1) …
`Fortified`	numérica	Vino generoso (fortificado: jerez, oporto, moscatel), miles de litros vendidos en el mes.	1.154 – 5.618
`Red`	numérica	Vino tinto, miles de litros.	464 – 3.670
`Rose`	numérica	Vino rosado, miles de litros. Faltan julio y agosto de 1994.	30 – 267
`sparkling`	numérica	Vino espumoso, miles de litros. Pico cada diciembre. Es la única columna en minúscula.	1.170 – 7.242
`Sweet-white`	numérica	Vino blanco dulce, miles de litros.	85 – 662
`Dry-white`	numérica	Vino blanco seco, miles de litros.	1.954 – 5.725

5 Particularidades técnicas al modelar

- **Seis series en una tabla**: los modelos de una variable (*ARIMA Model*) se ajustan a la columna marcada como *target*. Para modelar otro vino, cambia el *target* en *File* o en *Select Columns*. *VAR Model* modela varias a la vez.
- **Dos meses sin dato en el rosado** (julio y agosto de 1994): ARIMA no admite huecos. Rellénalos con *Interpolate* (del add-on) o predice solo hasta junio de 1994.
- **Estacionalidad distinta en cada vino**: en el espumoso, el pico de diciembre es enorme y crece con el nivel; usa descomposición **multiplicativa** o el logaritmo. En el generoso, el ciclo es más suave.
- **Tendencias que cambian**: el blanco dulce sube y baja en pocos años (1985–1988); un modelo con tendencia lineal predice mal los años siguientes. Para estas series conviene una ventana de entrenamiento corta o un modelo con tendencia amortiguada.
- **Primero, el método ingenuo estacional** (repetir el mismo mes del año anterior). Medido fuera de Orange con *statsmodels*, entrenando hasta 1993 y prediciendo 1994, el error porcentual medio (MAPE) del ingenuo estacional es del 9 % en el generoso, el 14 % en el tinto, el 21 % en el espumoso y el 13 % en el blanco seco. El modelo de las aerolíneas (ARIMA $(0,1,1)\times(0,1,1)_{12}$ sobre el logaritmo) mejora en el tinto (9 %), el espumoso (16 %) y el blanco seco (9 %), pero no en el generoso (9 %) ni en el blanco dulce (20–21 %).
- **Validación temporal**: nunca validación cruzada aleatoria. Deja al menos el último año para evaluar.

6 Flujo de trabajo en Orange



1. **File**: abre `australian_wines.csv` y marca como *target* el vino que quieras predecir (por ejemplo, `Red`).
2. **Form Timeseries**: `Month` como variable de tiempo. → **Line Chart** con las seis series: tendencias opuestas.
3. **Interpolate** para rellenar los dos meses del rosado (necesario para ARIMA y VAR).
4. **Seasonal Adjustment** (periodo 12, multiplicativo para `sparkling`): compara el componente estacional de cada vino.
5. **ARIMA Model** con diferenciación (d = 1) y un término de 12 meses, y **VAR Model** con varias series.
6. **Model Evaluation** con horizonte de 12 meses: compara MAE y MAPE entre modelos y entre vinos.

7 Otras consideraciones

- **Ejercicio clásico**: predecir los 12 meses de 1994 de cada vino con un método distinto y comprobar que ningún método gana en todas las series.
- **Correlación engañosa**: con los totales anuales, tinto y generoso tienen correlación −0,98 (uno sube y el otro baja); mes a mes, −0,01, porque comparten el pico de julio. Con la diferencia de 12 meses (*Difference*), +0,18. Antes de correlacionar series o probar *Granger Causality*, hay que quitar tendencia y estacionalidad.
- **Unidad**: miles de litros vendidos por las bodegas australianas en botellas de hasta un litro; no es el consumo total de vino en Australia (quedan fuera, por ejemplo, el vino a granel y en caja).

En la carpeta `australian_wines` ← `seriestemp_AustralianWines.csv` (curso_ciencia_datos (GitHub))

9.03
Series temporales y ventas

Nacimientos y defunciones trimestrales

`09_series_temporales/births_deaths/`

Nacimientos y defunciones trimestrales de Nueva Zelanda por sexo, de 2000 a 2012: cuatro series cortas con estacionalidad trimestral, ideales para un primer ejercicio de predicción.

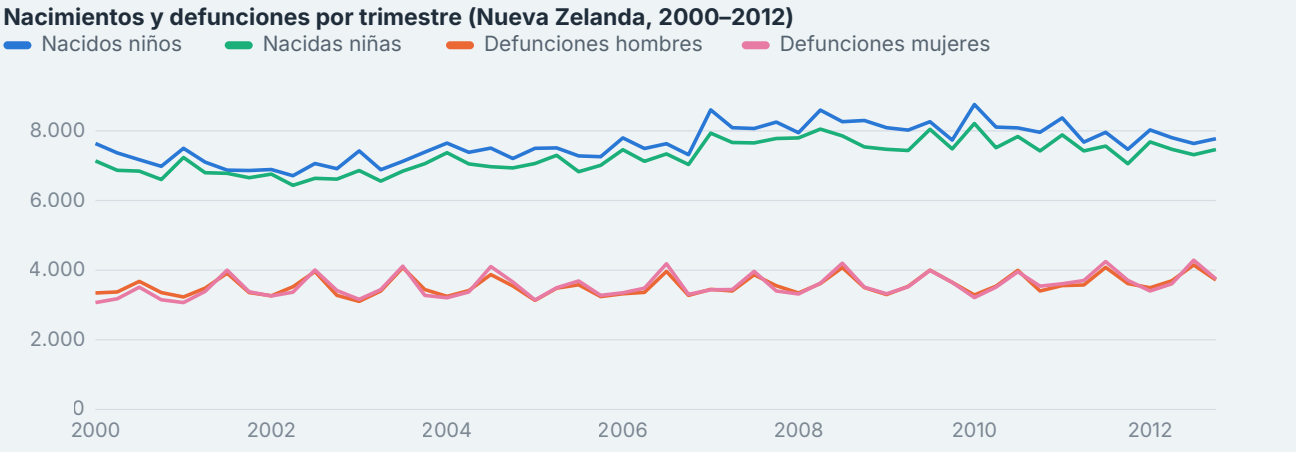
Predicción de series temporales · Juguete · Multiobjetivo · Temporal

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
52	**5**	`4 series`	**0,0 %**	**Iniciación**	**Timeseries**

Fichero	Filas × col.	Descargar
`births_deaths`	52 × 5	CSV 2 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/09_series_temporales/births_deaths/` seguido del nombre del fichero CSV.

Radiografía



1 Descripción general y estudios habituales

Son 52 trimestres, del primero de 2000 al último de 2012. Cada fila es un trimestre con cuatro recuentos: nacidos vivos niños y niñas, y defunciones de hombres y de mujeres.

El fichero del repositorio del curso no dice de qué país son. Los totales anuales coinciden con los **nacimientos y defunciones registrados en Nueva Zelanda** que publica Stats NZ: por ejemplo, en 2007, 64.044 nacimientos y 28.522 defunciones en el fichero, frente a 64.040 y 28.520 (cifras redondeadas a la decena) en la nota de prensa de Stats NZ.

Es una serie corta y limpia, sin valores faltantes. Los estudios habituales son:

- **Predecir los próximos trimestres** (predicción de series temporales) con métodos sencillos: ingenuo estacional, suavizado exponencial o ARIMA estacional con periodo 4.
- **Ver la estacionalidad**: las defunciones suben en el tercer trimestre (julio a septiembre, invierno en Nueva Zelanda).
- **Comparar series relacionadas**: niños frente a niñas (proporción de sexos al nacer) y hombres frente a mujeres.
- **Crecimiento natural**: construir nacimientos − defunciones y estudiar su evolución.

2 Contexto y fuente original

Stats NZ (la oficina estadística de Nueva Zelanda) publica cada trimestre los nacimientos y defunciones registrados, en la base de datos *Infoshare* (grupos *Births – VSB* y *Deaths – VSD*). Las cifras corresponden a la **fecha de registro**, no a la fecha del nacimiento o de la muerte. Stats NZ puede revisar las series en publicaciones posteriores, así que algunos trimestres pueden no coincidir exactamente con las cifras que se descarguen hoy.

En el repositorio del curso hay dos versiones con el mismo contenido: CSV y ARFF. El trimestre venía como texto (`2000Q1`), que Orange no reconoce como fecha; aquí se ha pasado a ISO con el primer día del trimestre (`2000-01-01` es el primer trimestre de 2000, `2000-04-01` el segundo, etc.).

- Stats NZ. Births and deaths (Infoshare: Births – VSB y Deaths – VSD).
- Stats NZ (18/02/2008). Births at 44-year high: 64.040 nacimientos y 28.520 defunciones registrados en 2007 (nota de prensa en Scoop).

3 Variable objetivo

Cualquiera de las cuatro columnas puede ser la serie a predecir; en Orange se marca como *target* la que se quiera.

- **Nacimientos**: unos 15.000 por trimestre. El total anual baja de 56.605 (2000) a 54.021 (2002), sube hasta el máximo de **64.343 en 2008** y queda en 61.178 en 2012.
- **Defunciones**: unas 7.000 por trimestre, con una subida lenta (de 26.660 en 2000 a 30.099 en 2012). El tercer trimestre tiene de media un 21 % más de defunciones que el primero.
- **Proporción de sexos al nacer**: 105 niños por cada 100 niñas de media (entre 101 y 110 según el trimestre).

4 Diccionario de columnas

Columnas de `births_deaths` (valores observados en el fichero)

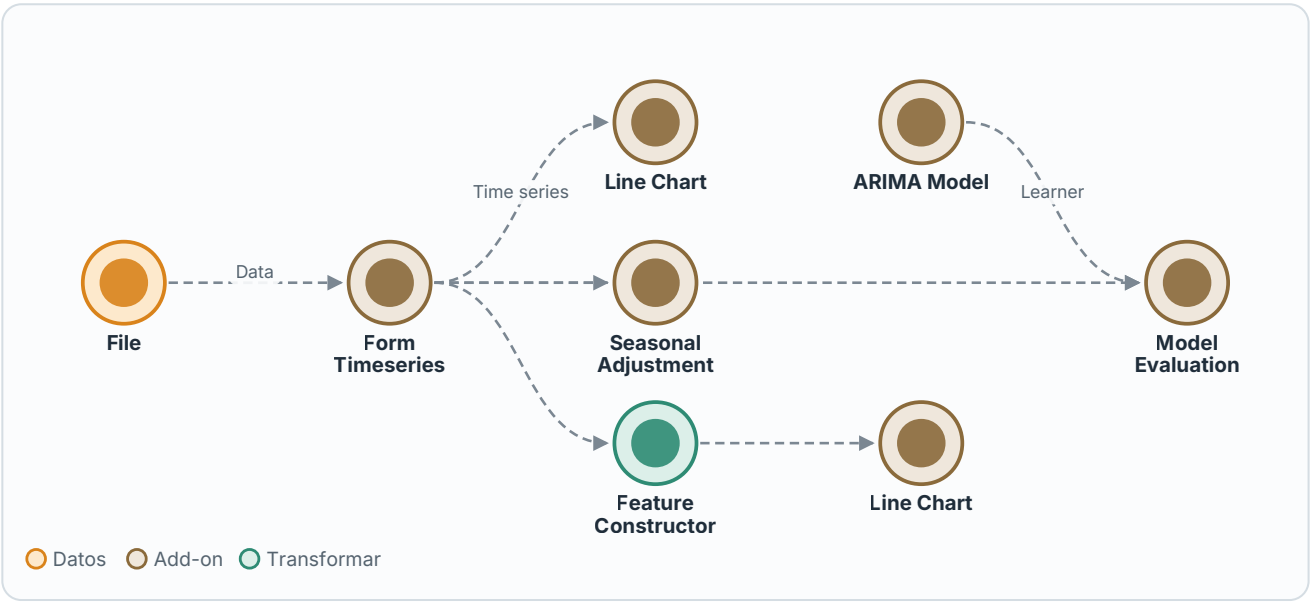
Columna	Tipo	Significado	Valores
`Quarter`	fecha/hora	Trimestre, como fecha de su primer día (AAAA-01-01 = 1.º, AAAA-04-01 = 2.º, AAAA-07-01 = 3.º, AAAA-10-01 = 4.º). En el original, `2000Q1` .	2000-01-01 (1), 2000-04-01 (1), 2000-07-01 (1), 2000-10-01 (1), 2001-01-01 (1), 2001-04-01 (1) …
`Male Live Births`	numérica	Nacidos vivos de sexo masculino registrados en el trimestre.	6.713 – 8.756
`Female Live Births`	numérica	Nacidos vivos de sexo femenino registrados en el trimestre.	6.438 – 8.212

Columna	Tipo	Significado	Valores
`Male Deaths`	numérica	Defunciones de hombres registradas en el trimestre.	3.103 – 4.149
`Female Deaths`	numérica	Defunciones de mujeres registradas en el trimestre.	3.070 – 4.287

5 Particularidades técnicas al modelar

- **Serie muy corta**: 52 trimestres, 13 ciclos. Si dejas el último año para evaluar (4 trimestres), quedan 48 para entrenar: suficiente para un ARIMA sencillo, no para modelos con muchos parámetros.
- **Periodo 4**, no 12: en *Seasonal Adjustment* y en el término estacional de *ARIMA Model* hay que poner 4.
- **Nombres con espacios** (`Male Live Births`): en *Feature Constructor* hay que escribirlos entre comillas o cambiarlos de nombre antes.
- **Fecha de registro**: un retraso en los registros mueve casos de un trimestre a otro. Parte del «ciclo» de los nacimientos (más en el primer trimestre) puede deberse a cómo se registran y no a cuándo se nace.
- **Métodos sencillos funcionan bien**: medido fuera de Orange con *statsmodels*, entrenando hasta 2011 y prediciendo 2012, el ingenuo estacional (repetir el trimestre del año anterior) tiene un error porcentual medio (MAPE) del 2,4–3,5 % y el ARIMA estacional $(0,1,1)\times(0,1,1)_4$ sobre el logaritmo, del 1,1–2,4 %, según la serie.

6 Flujo de trabajo en Orange



1. **File**: abre `births_deaths.csv` y marca como *target* una serie, por ejemplo `Male Deaths`.
2. **Form Timeseries**: `Quarter` como variable de tiempo. → **Line Chart**: las defunciones con pico en el 3.er trimestre.
3. **Seasonal Adjustment** con periodo 4: componente estacional y tendencia.
4. **Feature Constructor**: crea el crecimiento natural (nacimientos de ambos sexos menos defunciones) y míralo en un **Line Chart**.
5. **ARIMA Model** con término estacional de periodo 4 → **Model Evaluation** con horizonte de 1 a 4 trimestres.

7 Otras consideraciones

- **Primer ejercicio de series**: es más fácil de entender que el de las aerolíneas (sin tendencia fuerte ni ciclo que crece) y permite explicar el método ingenuo estacional antes que ARIMA.

En la carpeta	`births_deaths` ← `seriestemp_births_and_deaths.csv` (curso_ciencia_datos (GitHub))
Duplicado, no se copia	`seriestemp_births_and_deaths.arff` (curso_ciencia_datos (GitHub))

9.04
Series temporales y ventas

Sarampión en Nueva York (1928-1972)

`09_series_temporales/sarampion_nueva_york/`

Casos mensuales de sarampión declarados en Nueva York de 1928 a 1972: epidemias cada dos años, un ciclo anual muy marcado y la caída tras la vacuna de 1963. Una serie que los modelos lineales predicen mal.

Predicción de series temporales · Temporal

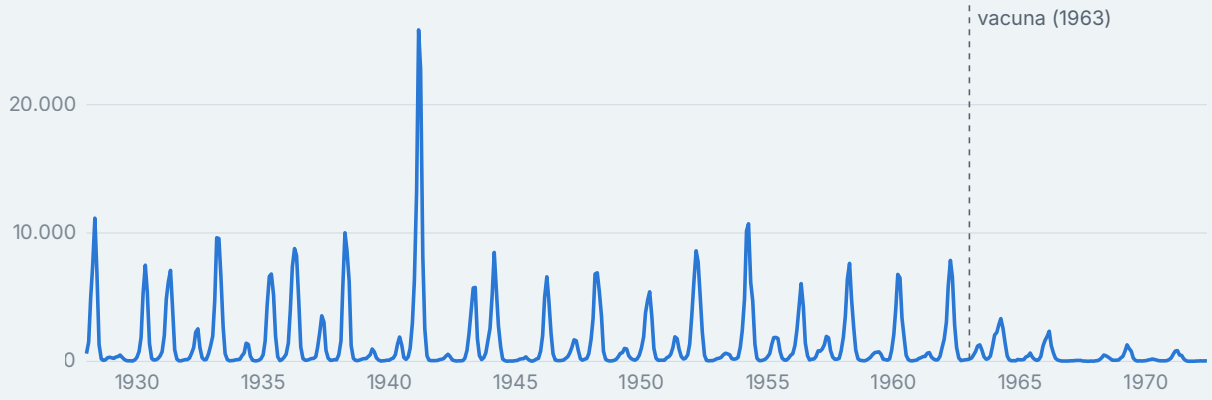
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
534	**2**	`measles`	**0,0 %**	**Avanzado**	**Timeseries**

Fichero	Filas × col.	Descargar
`sarampion_nueva_york`	534 × 2	CSV 6 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/09_series_temporales/sarampion_nueva_york/` seguido del nombre del fichero CSV.

Radiografía

Casos de sarampión al mes en Nueva York, 1928–1972



1 Descripción general y estudios habituales

Son 534 meses, de enero de 1928 a junio de 1972, con el número de casos de sarampión declarados cada mes en la ciudad de Nueva York. Solo hay dos columnas: el mes y los casos.

Es una serie clásica de epidemiología matemática: tiene un ciclo anual (las epidemias empiezan con el curso escolar y alcanzan el máximo en primavera), un ciclo de dos años (un año de epidemia grande y otro de epidemia pequeña) y un cambio de régimen al final, cuando llega la vacuna. Los estudios habituales son:

- **Predecir los próximos meses** (predicción de series temporales) y ver los límites de ARIMA con una serie no lineal.

- **Transformar**: la serie es muy asimétrica (la media mensual es 1.422 casos y la mediana, 347); el logaritmo es casi obligatorio.
- **Detectar periodicidades** con el correlograma y el periodograma: picos en 12 y 24 meses.
- **Cambio estructural**: comparar el periodo anterior a la vacuna con el posterior a 1963.
- **Modelos epidemiológicos** (SIR) y análisis no lineal, fuera de Orange.

2 Contexto y fuente original

Los datos los publicaron Wayne London y James Yorke en 1973, en dos artículos sobre los brotes recurrentes de sarampión, varicela y paperas en Nueva York y Baltimore. Desde entonces se han usado en muchos estudios: Schaffer y Kot (1985) propusieron que su dinámica podía ser caótica, y Sugihara y May (1990) los usaron para presentar un método de predicción no lineal. Karsten Hempel y David Earn (2015) ampliaron la serie a 1891–1984 con los boletines del Departamento de Salud de la ciudad.

La serie está en la *Time Series Data Library* de Rob Hyndman y en la colección de Hipel y McLeod (`MEASLNYC.1`). En el repositorio del curso estaba en ARFF (`seriestemp_sarampion_newyork.arff`), con el mes como fecha `yyyy-MM`; aquí queda igual en CSV y XLSX (`1928-01`), y Orange la lee como variable de tiempo.

- Yorke, J. A. y London, W. P. (1973). Recurrent outbreaks of measles, chickenpox and mumps. American Journal of Epidemiology, 98. Ficha de la colección de Hipel y McLeod.
- Hempel, K. y Earn, D. J. D. (2015). A century of transitions in New York City's measles dynamics. Journal of the Royal Society Interface, 12(106), 20150024.

3 Variable objetivo

La variable a predecir es `measles`, el número de casos declarados en el mes. Va de 11 a **25.826** (marzo de 1941), sin ningún mes a cero.

- **Ciclo anual**: de media, abril tiene 3.805 casos y septiembre, 80; casi 50 veces menos.
- **Ciclo de dos años**: entre 1945 y 1964, los años pares tienen epidemias grandes y los impares pequeñas (1946: 22.408 casos; 1947: 7.915; 1962: 29.671; 1963: 7.406). Antes de 1945 el patrón es más irregular; el año con más casos es 1941 (79.646).
- **La vacuna**: se autorizó en Estados Unidos en 1963. A partir de 1965 los casos bajan mucho: 529 en todo 1967 y 207 en la primera mitad de 1972.

4 Diccionario de columnas

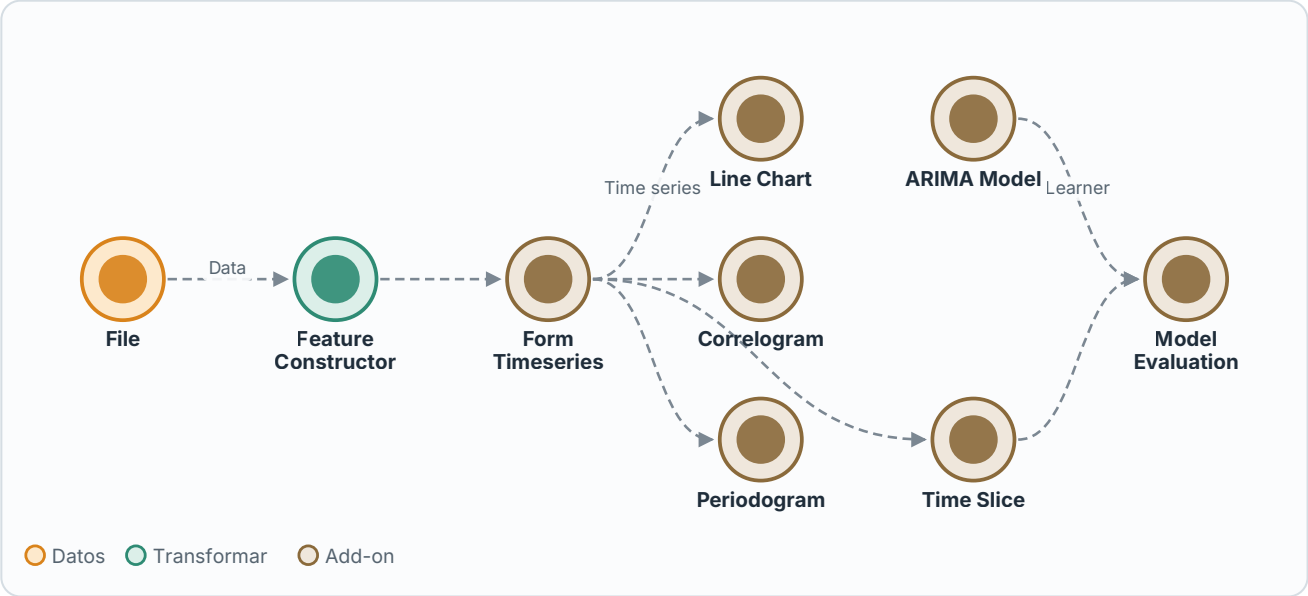
Columnas de `sarampion_nueva_york` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`time`	fecha/hora	Mes (AAAA-MM). Orange lo lee como fecha.	1928-01 (1), 1928-02 (1), 1928-03 (1), 1928-04 (1), 1928-05 (1), 1928-06 (1) …
`measles`	numérica	Casos de sarampión declarados en la ciudad de Nueva York en el mes. Es la variable a predecir.	11 – 25.826

5 Particularidades técnicas al modelar

- **Usa el logaritmo**: con los casos tal cual, las epidemias de 20.000 casos dominan cualquier ajuste y el error se concentra en los picos. Con *Feature Constructor*, `log(measles)` (no hay ceros, así que no hace falta sumar 1).
- **Dos periodicidades**: en el logaritmo, la autocorrelación es 0,40 a 12 meses y 0,68 a 24 meses. *Correlogram* y *Periodogram* lo muestran; un ARIMA estacional de periodo 12 no recoge el ciclo de dos años.
- **Cambio de régimen**: tras 1963 la serie baja de nivel y pierde el ciclo de dos años. Un modelo entrenado con todos los datos mezcla dos comportamientos; o se entrena con 1945–1962, o se modela el cambio.
- **Los modelos lineales fallan**: medido fuera de Orange con *statsmodels*, prediciendo los últimos 24 meses (julio de 1970 a junio de 1972), el modelo de las aerolíneas sobre el logaritmo tiene un error porcentual medio (MAPE) del 79 % y el ingenuo estacional, del 130 %. Las epidemias dependen de cuántos niños susceptibles se han acumulado, algo que un ARIMA no ve.

6 Flujo de trabajo en Orange



1. **File** con `sarampion_nueva_york.csv`.
2. **Feature Constructor**: crea `log_measles = log(measles)` y márcala como objetivo.
3. **Form Timeseries** con `time` como variable de tiempo. → **Line Chart** de los casos y del logaritmo.
4. **Correlogram** y **Periodogram**: picos en 12 y 24 meses.
5. **Time Slice** para quedarte con 1945–1962 (antes de la vacuna).
6. **ARIMA Model** con término de 12 meses → **Model Evaluation** con horizonte de 12 meses; compara con el periodo completo.

7 Otras consideraciones

- **Para el curso**: es el contraejemplo de la serie de las aerolíneas. Muestra que no todas las series se resuelven con tendencia + estacionalidad + ARIMA.
- **Datos declarados, no casos reales**: en la época prevacunal casi todos los niños pasaban el sarampión, pero solo una parte de los casos se declaraba. La serie mide declaraciones.
- **Ampliación**: Hempel y Earn (2015) publicaron la serie extendida (1891–1984, en parte semanal) con la población y los nacimientos de la ciudad, útil para modelos SIR.

En la carpeta

`sarampion_nueva_york` ← `seriestemp_sarampion_newyork.arff` (curso_ciencia_datos (GitHub))

9.05
Series temporales y ventas

Superstore sales

`09_series_temporales/superstore_sales/`

Líneas de pedido de una tienda ficticia de material de oficina en Canadá (2009–2012): ventas, beneficio, envío y cliente, para agregar en series de ventas, explorar por región y producto o predecir el beneficio.

Predicción de series temporales · Regresión · Exploración y visualización · Espacial · ? Valores faltantes · Mixto num. + cat. · Temporal

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
8.399	**21**	`Sales` o `Profit`	**0,0 %**	**Intermedio**	**Timeseries**

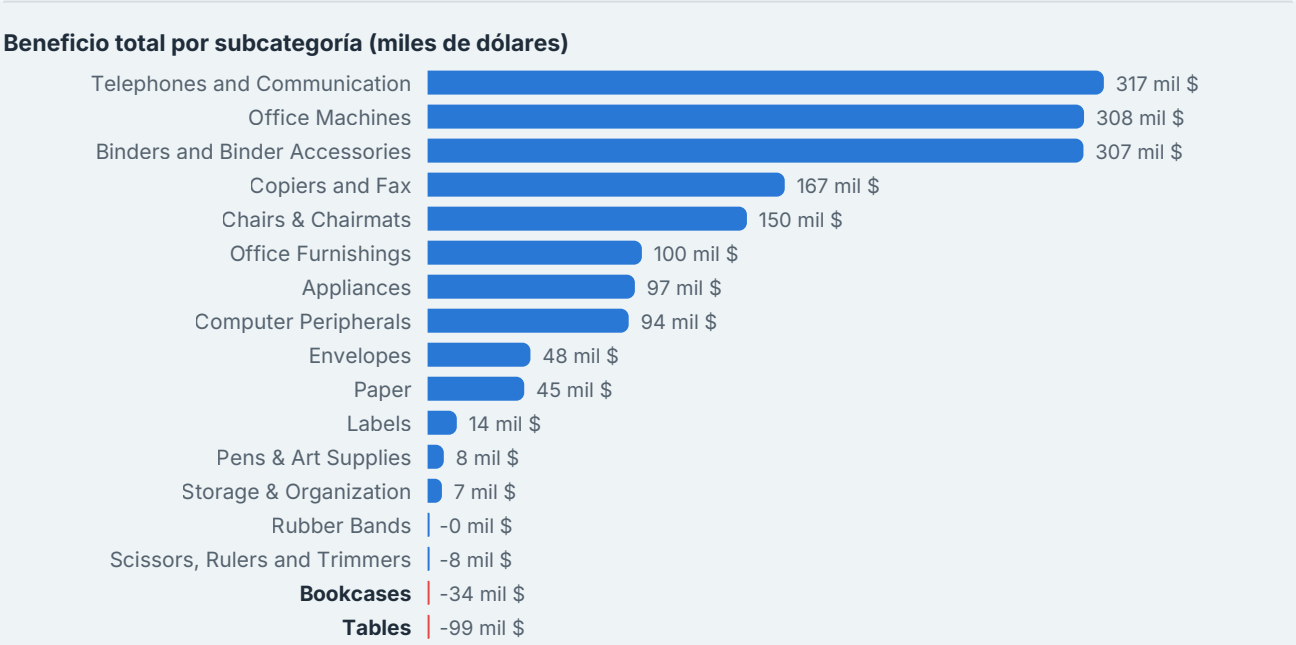
Fichero	Filas × col.	Descargar
`superstore_sales`	8.399 × 21	CSV 1,8 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/09_series_temporales/superstore_sales/` seguido del nombre del fichero CSV.

Radiografía

Ventas mensuales (miles de dólares), 2009–2012





1 Descripción general y estudios habituales

Son 8.399 líneas de pedido de 5.496 pedidos, del 1 de enero de 2009 al 30 de diciembre de 2012. Cada fila es un producto dentro de un pedido, con 21 columnas: importe de la venta, beneficio, cantidad, descuento, precio unitario, coste de envío, modo de envío, prioridad, provincia y región de Canadá, segmento del cliente, categoría, subcategoría y envase del producto, fechas de pedido y de envío, y nombres del cliente y del producto.

Hay 795 clientes, 1.262 productos en 3 categorías y 17 subcategorías, y las 13 provincias y territorios de Canadá. No es una serie temporal ya hecha: son transacciones con fecha que hay que **agregar** (por día, semana o mes) para obtener una serie. Los estudios habituales son:

- **Predecir las ventas** mensuales o semanales (predicción de series temporales) tras agregar las líneas.
- **Explorar** ventas y beneficio por región, provincia, segmento, categoría y subcategoría (exploración y visualización).
- **Predecir el beneficio** de una línea a partir de sus características (regresión).
- **Analizar los envíos**: días entre pedido y envío según la prioridad y el modo de envío.

2 Contexto y fuente original

Es la versión canadiense del ejemplo *Superstore Sales* que Tableau distribuía con versiones antiguas de su programa: las ubicaciones de Estados Unidos se cambiaron por provincias y regiones de Canadá. La empresa es ficticia y los datos están generados para enseñar a hacer cuadros de mando. No es el *Sample - Superstore* actual de Tableau, que tiene otras columnas y 9.994 filas de Estados Unidos.

En el repositorio del curso es `superstoreSales2.csv`. Las fechas venían como `M/D/AAAA` (`10/13/2010`), que Orange lee como texto; aquí se han pasado a ISO (`2010-10-13`) y Orange las lee como fechas.

- Tableau. Find good data sets: Superstore (ejemplo incluido en Tableau Desktop).
- gualbe/datasets: superstoreSales2.csv (versión canadiense de Superstore Sales usada en el curso).

3 Variable objetivo

No hay una variable objetivo fija. Las dos más usadas son:

- `Sales` (importe de la línea, en dólares): suma 14,9 millones en los cuatro años. Agregadas por mes forman una serie de 48 valores, entre 198.000 (junio de 2011) y 516.000 (enero de 2009) dólares, con estacionalidad débil.
- `Profit` (beneficio de la línea, en dólares): suma 1,52 millones, un 10,2 % de las ventas. Pero **el 51 % de las líneas da pérdidas** (mediana −1,50): pocas líneas muy rentables compensan muchas con pérdidas pequeñas. Por categoría, el margen es del 14,8 % en tecnología, el 13,8 % en material de oficina y el 2,3 % en muebles; las mesas (`Tables`) pierden 99.062 dólares y las estanterías (`Bookcases`), 33.582.

4 Diccionario de columnas

Columnas de `superstore_sales` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Row ID`	numérica	Número de línea (1 a 8.399). Identificador: no lo uses como atributo.	1 – 8.399
`Order ID`	numérica	Número de pedido (5.496 distintos; un pedido tiene de 1 a 6 líneas). Identificador.	3 – 59.973
`Order Priority`	categórica	Prioridad del pedido: `Critical` , `High` , `Medium` , `Low` o `Not Specified` .	High (1.768), Low (1.720), Not Specified (1.672), Medium (1.631), Critical (1.608)
`Order Quantity`	numérica	Unidades del producto en la línea (1 a 50).	1 – 50
`Sales`	numérica	Importe de la línea, en dólares. Casi igual a `Unit Price × Order Quantity` (correlación 0,996).	2,24 – 89.061,05
`Discount`	numérica	Descuento aplicado (proporción, de 0 a 0,25).	0 – 0,25
`Ship Mode`	categórica	Modo de envío: `Regular Air` , `Express Air` o `Delivery Truck` (este último, para cajas y bidones grandes).	Regular Air (6.270), Delivery Truck (1.146), Express Air (983)
`Profit`	numérica	Beneficio de la línea, en dólares (negativo = pérdida).	-14.140,7 – 27.220,69
`Unit Price`	numérica	Precio unitario del producto, en dólares.	0,99 – 6.783,02

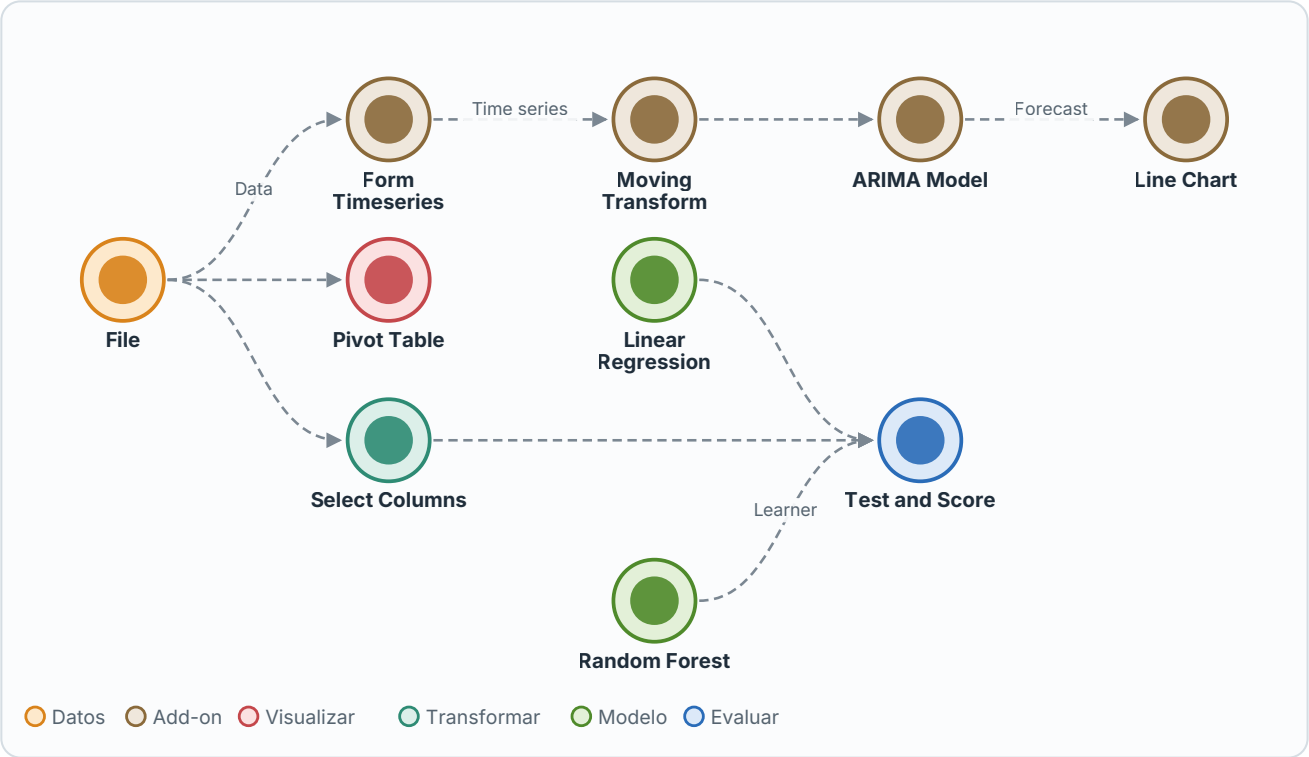
Columna	Tipo	Significado	Valores
`Shipping Cost`	numérica	Coste de envío de la línea, en dólares.	0,49 – 164,73
`Province`	categórica	Provincia o territorio de Canadá (13). `Saskachewan` está mal escrito en el original (Saskatchewan).	Ontario (1.826), British Columbia (1.126), Saskachewan (913), Alberta (865), Manitoba (793), Quebec (781) …
`Region`	categórica	Región de venta (8): agrupa provincias, p. ej. `West` = Alberta y Columbia Británica. `Prarie` está mal escrito (Prairie).	West (1.991), Ontario (1.826), Prarie (1.706), Atlantic (1.080), Quebec (781), Yukon (542) …
`Customer Segment`	categórica	Segmento del cliente: `Corporate`, `Home Office`, `Consumer` o `Small Business`.	Corporate (3.076), Home Office (2.032), Consumer (1.649), Small Business (1.642)
`Product Category`	categórica	Categoría del producto: `Office Supplies`, `Technology` o `Furniture`.	Office Supplies (4.610), Technology (2.065), Furniture (1.724)
`Product Sub-Category`	categórica	Subcategoría (17), p. ej. `Tables`, `Binders and Binder Accessories`, `Telephones and Communication`.	Paper (1.225), Binders and Binder Accessories (915), Telephones and Communication (883), Office Furnishings (788), Computer Peripherals (758), Pens & Art Supplies (633) …
`Product Container`	categórica	Envase: de `Small Pack` y `Wrap Bag` a `Jumbo Box` y `Jumbo Drum`.	Small Box (4.347), Wrap Bag (1.168), Small Pack (956), Jumbo Drum (624), Jumbo Box (532), Large Box (406) …
`Product Base Margin`	numérica	Margen base del producto (proporción). 63 vacíos (42 de muebles y 21 de material de oficina).	0,35 – 0,85
`Order Date`	fecha/hora	Fecha del pedido (AAAA-MM-DD). En el original, M/D/AAAA.	2012-03-28 (20), 2011-09-15 (20), 2010-12-12 (18), 2011-11-19 (17), 2010-02-27 (17), 2010-04-20 (17) …
`Customer Name`	texto	Nombre del cliente (795 distintos), del ejemplo de Tableau. Meta en Orange.	(no se muestran)

Columna	Tipo	Significado	Valores
`Product Name`	texto	Nombre del producto (1.262 distintos). Meta en Orange.	Global High-Back Leather Tilter, Burgundy (24), Fiskars Softgrip Scissors (22), Master Giant Foot Doorstop, Safety Yellow (22), BoxOffice By Design Rectangular and Half-Moon Meeting Roo… (22), Bevis 36 x 72 Conference Tables (22), Wilson Jones Hanging View Binder, White, 1" (21) …
`Ship Date`	fecha/hora	Fecha de envío (AAAA-MM-DD). En el original, M/D/AAAA.	2011-05-21 (19), 2012-03-30 (16), 2009-04-11 (16), 2009-10-09 (16), 2012-05-09 (15), 2012-10-04 (15) …

5 Particularidades técnicas al modelar

- **Hay que agregar antes de predecir**: cada fila es una línea de pedido, no un periodo. Con *Form Timeseries* (`Order Date` como tiempo) y después *Moving Transform* en modo *Aggregate time periods*, suma `Sales` por mes o semana (este modo sustituye al antiguo widget *Aggregate*). En 42 de los 1.460 días no hay pedidos, así que la serie diaria tiene huecos.
- **Identificadores como atributos**: Orange lee `Row ID` y `Order ID` como números. Ponlos como *meta* o quítalos: `Row ID` no significa nada y `Order ID` repite el pedido en varias líneas.
- `Sales` **y** `Profit` **van juntas**: si predices `Profit` con `Sales` como atributo, el modelo aprovecha el importe de la venta, que entra en el cálculo del beneficio y puede no conocerse cuando se quiere predecir. En validación cruzada de 5 bolsas con Orange, el bosque aleatorio da $R^2 = 0{,}76$ con `Sales` y 0,74 sin ella; la regresión lineal baja de 0,68 a 0,10. Además, el mismo producto aparece en muchas líneas, así que la validación por líneas es algo optimista.
- **Descuentos y pérdidas**: con descuento de hasta el 2 %, la mediana del beneficio es +6,44 dólares; con más del 8 %, −8,12.
- **Envíos raros**: la mediana es de 2 días, pero tres pedidos de finales de diciembre de 2010 tardan entre 31 y 92 días. La prioridad `Low` tarda de media 4,2 días; las demás, 1,4–1,5.
- **Incoherencias del ejemplo**: 21 pedidos tienen dos clientes distintos, y muchos clientes compran en varias provincias (hasta 7). Los pedidos se reparten casi por igual entre los siete días de la semana (unos 1.200 cada día, también sábados y domingos), otra señal de que los datos son generados.
- **Erratas en las categorías**: `Saskachewan` y `Prarie` se dejan como en el original; si cruzas con un mapa de Canadá, corrígelas antes.

6 Flujo de trabajo en Orange



1. **File**: abre `superstore_sales.csv`; pon `Row ID` y `Order ID` como *meta*.
2. **Series**: **Form Timeseries** con `Order Date` → **Moving Transform** (*Aggregate time periods*, meses, suma de `Sales`) → **ARIMA Model** → **Line Chart** con la predicción.
3. **Exploración**: **Pivot Table** con región o provincia en filas, categoría en columnas y suma de `Sales` y `Profit`. Las mesas y las estanterías salen con beneficio negativo.
4. **Regresión**: **Select Columns** con `Profit` como objetivo y sin fechas ni nombres → **Test and Score** con **Linear Regression** y **Random Forest**. Repite quitando `Sales`.

7 Otras consideraciones

- **Para cuadros de mando**: es un ejemplo pensado para Tableau; en Orange encaja mejor en exploración (*Pivot Table*, *Box Plot*, *Bar Plot*) que en predicción, porque la serie mensual tiene poca estructura (48 meses sin estacionalidad clara).
- **Nombres de cliente**: son parte del ejemplo de una empresa ficticia; aun así, en el diccionario no se muestran.
- **Margen negativo**: buen caso para discutir el beneficio por línea frente al beneficio por pedido o por cliente (agrupando con *Group By*).

En la carpeta `superstore_sales` ← `superstoreSales2.csv` (curso_ciencia_datos (GitHub))

9.06
Series temporales y ventas

Meteorología diaria de Huelva (humedad relativa)

`09_series_temporales/meteo_huelva/`

Datos diarios de una estación meteorológica de Huelva (2016–2024) para predecir la humedad relativa media, con errores de sensor reales que hay que limpiar antes de modelar.

Predicción de series temporales · Regresión · ? Valores faltantes · Temporal

> **En el curso:** Actividad 6.2 (Tema 6): se usó a propósito la versión sin corregir para enseñar a limpiar la serie y después ARIMA con d = 0.

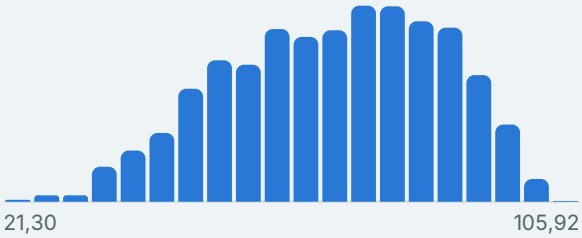
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
3.148	**17**	`H_R_Med`	**0,1 %**	**Intermedio**	**Timeseries**

Fichero	Filas × col.	Descargar
`meteo_huelva_hu002`	3.148 × 17	CSV 333 KB · XLSX
`meteo_huelva_hu002_corregido`	3.148 × 17	CSV 334 KB · XLSX

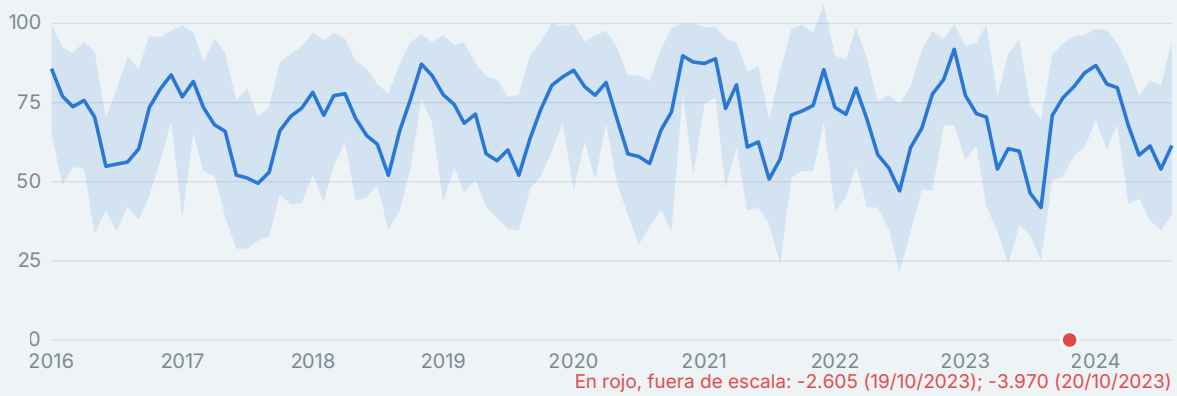
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/09_series_temporales/meteo_huelva/` seguido del nombre del fichero CSV.

Radiografía

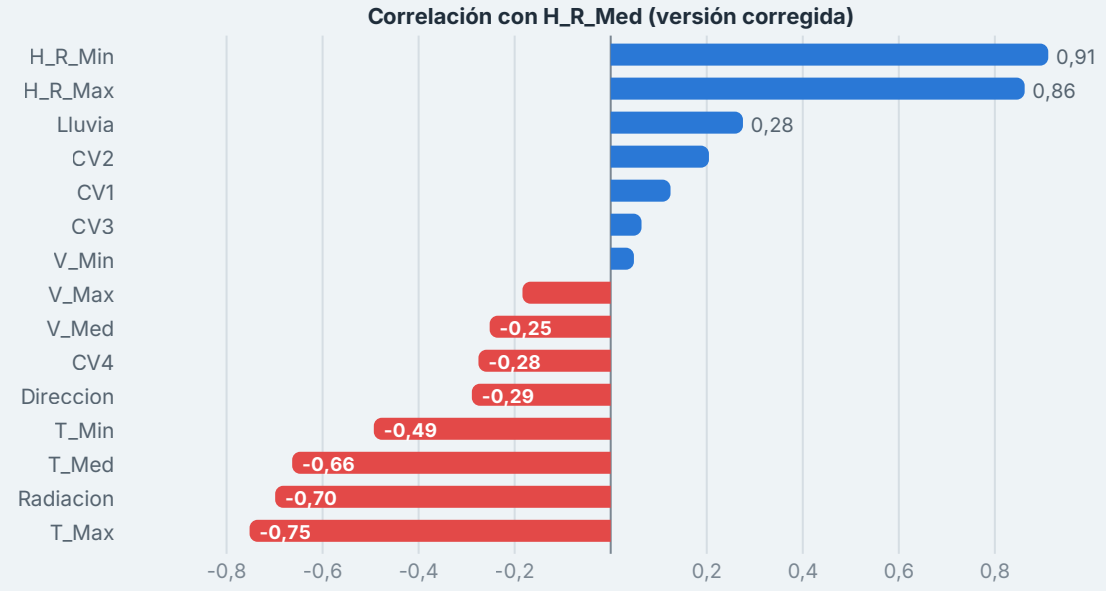
H_R_Med en meteo_huelva_hu002_corregido



Humedad relativa media (%), fichero original: media mensual y rango diario



Qué variables acompañan a la humedad media



1 Descripción general y estudios habituales

Son 3.148 días, del 1 de enero de 2016 al 19 de agosto de 2024, de la estación con código **HU002** (Huelva). Cada fila es un día con 16 medidas: temperaturas máxima, media y mínima, humedad relativa máxima, media y mínima, radiación, lluvia, velocidad del viento máxima, media y mínima, y cinco columnas sobre la dirección del viento.

Hay **dos versiones**: la original (`meteo_huelva_hu002`), con huecos y errores de sensor, y una corregida (`meteo_huelva_hu002_corregido`). Los estudios habituales son:

- **Predecir la humedad media de los próximos días** (predicción de series temporales) con ARIMA o con modelos que usen también las demás variables (VAR, o regresión con retardos).
- **Limpiar una serie real**: detectar códigos de error y valores imposibles, convertirlos en ausentes e interpolar.
- **Estudiar la estacionalidad anual** y la relación entre variables (la humedad baja cuando sube la temperatura).

2 Contexto y fuente original

Los datos están en la carpeta `weather` del repositorio de datasets del profesor, sin documentación: no se indica la red ni la ubicación exacta de la estación, ni las unidades. Por los valores, las temperaturas están en °C, la humedad en %, la lluvia en mm y el viento, muy probablemente, en km/h. La radiación (valores entre −3 y 2) no tiene unidad reconocible. En la misma carpeta hay una estación de Sevilla (`wea_SE001.csv`), con las mismas columnas, que no se usa en el curso.

Las columnas `CV1` a `CV4` suman unos 1.430 por día, casi los 1.440 minutos de un día: parecen los minutos (o registros de un minuto) con viento en cada uno de los cuatro cuadrantes. `Direccion` es un valor entre 1 y 4 que resume el cuadrante dominante del día. Qué cuadrante es cada número (norte, este…) no está documentado.

Qué cambia la versión corregida. Comparando los dos ficheros celda a celda:

- Rellena por interpolación lineal los 5 días sin humedad ni viento (del 27 al 31 de agosto de 2016).

- Sustituye los dos días con códigos de error en la humedad (19 y 20 de octubre de 2023) por valores interpolados.
- **Además, promedia parejas de días consecutivos** en `T_Max` y `H_R_Med`: en 836 filas (el 27 %), cada pareja de días toma la media de los dos. No es una corrección de errores, sino un suavizado que no se documenta.
- No toca la radiación negativa ni la humedad máxima por encima de 100 %.

- Fichero original: gualbe/datasets, carpeta weather (wea_HU002.csv)
- Versión corregida (la que enlazan las diapositivas del Tema 6): wea_HU002_corrected.csv

3 Variable objetivo

La variable a predecir es `H_R_Med`, la humedad relativa media del día en %. En la versión corregida va de 21,3 a 105,9, con media 69,6. En la original hay dos valores imposibles, **−2.604,87 y −3.970,18** (19 y 20 de octubre de 2023), que aplastan cualquier gráfico. En clase se vio un −3.287, que es la media de los dos.

Tiene un **ciclo anual muy marcado**: la media mensual va del 54 % de julio al 84 % de diciembre. No tiene tendencia (las medias anuales se mueven entre el 65 % y el 74 %) y la autocorrelación es alta: 0,83 con el día anterior y 0,43 con el mismo día del año anterior.

4 Diccionario de columnas

Columnas de `meteo_huelva_hu002` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
FECHA	fecha/hora	Día de la medida (AAAA-MM-DD 00:00:00). Faltan 6 días: 29 y 30/09/2016, 24 y 25/10/2016 y 13 y 14/08/2024.	2016-01-01 00:00:00 (1), 2016-01-02 00:00:00 (1), 2016-01-03 00:00:00 (1), 2016-01-04 00:00:00 (1), 2016-01-05 00:00:00 (1), 2016-01-06 00:00:00 (1) …
T_Max	numérica	Temperatura máxima del día (°C).	8,01 – 43,01
T_Med	numérica	Temperatura media del día (°C).	4,969 – 36,409
T_Min	numérica	Temperatura mínima del día (°C).	-0,142 – 31,37
H_R_Max	numérica	Humedad relativa máxima (%). 16 días de 2021 superan el 100 %, algo físicamente imposible: error del sensor.	33,64 – 108,7
H_R_Med `objetivo`	numérica	**Humedad relativa media (%)**: la variable a predecir. Dos códigos de error negativos en octubre de 2023.	-3.970,18 – 105,925
H_R_Min	numérica	Humedad relativa mínima (%). Vale −7.999 (código de error) los mismos dos días de octubre de 2023.	-7.999 – 100

Columna	Tipo	Significado	Valores
`Radiacion`	numérica	Radiación solar (unidad sin documentar). Tiene 8 días con valores negativos, imposibles.	-3,058 – 2,025
`Lluvia`	numérica	Precipitación del día (mm). El máximo, 138,8 mm, es del 23/09/2021.	0 – 138,8
`V_Max`	numérica	Velocidad máxima del viento (probablemente km/h).	3,881 – 68,09
`V_Med`	numérica	Velocidad media del viento.	0,399 – 18,163
`V_Min`	numérica	Velocidad mínima del viento (casi siempre 0).	0 – 4,234
`CV1`	numérica	Registros del día (≈ minutos) con viento del cuadrante 1.	0 – 1.412
`CV2`	numérica	Ídem, cuadrante 2.	0 – 1.074
`CV3`	numérica	Ídem, cuadrante 3.	0 – 1.403
`CV4`	numérica	Ídem, cuadrante 4.	0 – 1.269
`Direccion`	numérica	Dirección dominante del día, codificada entre 1 y 4 (puede tener decimales: es un promedio).	1 – 4

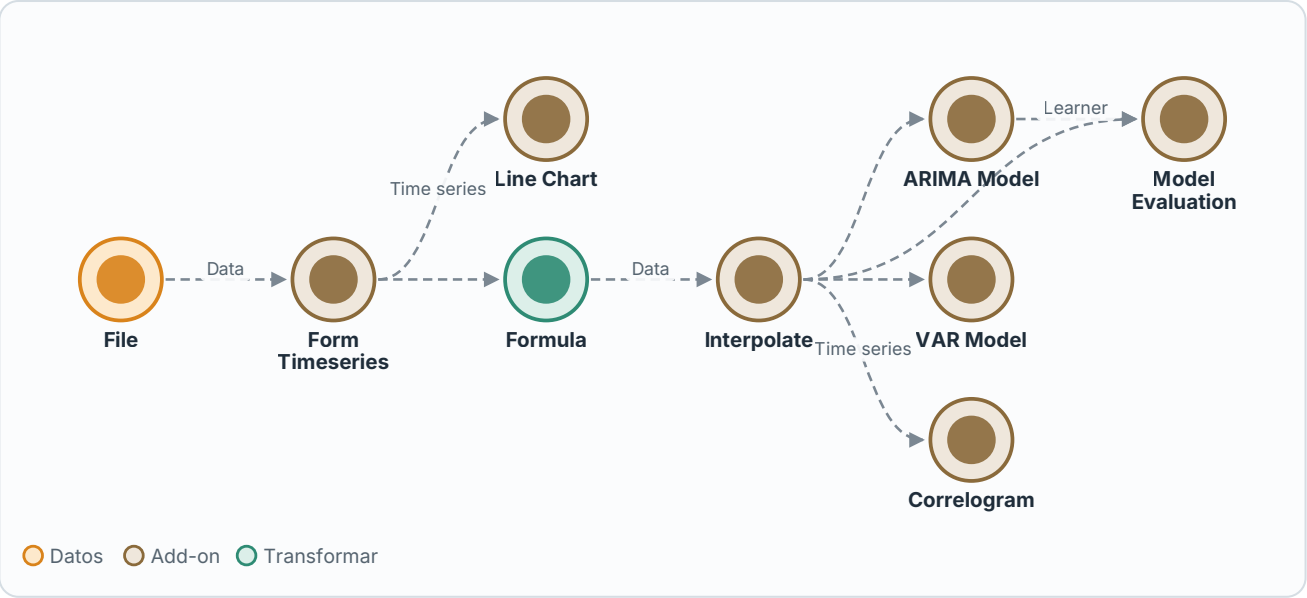
`meteo_huelva_hu002_corregido` tiene las mismas columnas con el mismo significado que `meteo_huelva_hu002`.

5 Particularidades técnicas al modelar

- **Tres tipos de error en la versión original**: 5 días sin humedad ni viento (agosto de 2016), dos días con códigos de error (−2.604,87 y −3.970,18 en la humedad media, −7.999 en la mínima) y valores imposibles que no son códigos: humedad máxima por encima de 100 % y radiación negativa. Hay que decidir qué hacer con cada uno.
- **Convertir los errores en ausentes** es el primer paso. En clase se hizo con *Select Rows* (`H_R_Med` menor que 0), *Select Columns* para ignorar esa columna en las filas malas y *Concatenate* con el resto. Con *Formula* o *Edit Domain* también se puede, y es más corto.
- **Interpolar, no imputar**: en una serie, *Interpolate* (del add-on *Timeseries*) rellena con los vecinos en el tiempo. *Impute* con la media pondría el 69,6 % en medio de agosto.
- **Faltan 6 fechas**, no solo valores: *Form Timeseries* acepta la serie, pero ARIMA supone pasos iguales y no sabe que entre el 28/09 y el 01/10/2016 hay dos días. Con huecos tan cortos el efecto es pequeño, pero conviene saberlo.
- **La versión corregida no es neutra**: promedia parejas de días en `T_Max` y `H_R_Med` (836 filas), lo que suaviza la serie y baja el error de cualquier modelo. Para comparar resultados entre alumnos, todos deben usar el mismo fichero.
- **No es estacionaria por el ciclo anual**, pero no tiene tendencia: por eso en clase se usó d = 0. Un ARIMA no modela un ciclo de 365 días; para eso hace falta una variable del día del año o quitar el ciclo antes.

- Validación: *Model Evaluation* con ventanas que avanzan; nunca validación cruzada aleatoria.

6 Flujo de trabajo en Orange



1. **File** con `meteo_huelva_hu002`: `FECHA` como *meta* y `H_R_Med` como *target*.
2. **Form Timeseries** con `FECHA` → **Line Chart**: los dos picos negativos de octubre de 2023 aplastan la gráfica.
3. **Formula** (o *Select Rows* + *Concatenate*, como en clase): pon como ausente `H_R_Med` cuando sea negativa, y lo mismo con `H_R_Min`, `H_R_Max` > 100 y `Radiacion` < 0.
4. **Interpolate** lineal → Line Chart de nuevo: ya se ve el ciclo anual.
5. **Correlogram**: ACF y PACF para elegir p y q.
6. **ARIMA Model** con d = 0 → **Model Evaluation** (horizonte de 1 a 15 días, ventana que avanza). Compara con un modelo trivial (el valor de ayer).
7. **VAR Model**: usa también temperatura, radiación y viento y compara el error con el ARIMA.

7 Otras consideraciones

- **Las anomalías que no se corrigieron en clase** (humedad máxima > 100 %, radiación negativa y el viento de octubre de 2023) son un buen ejercicio para casa: decidir si son errores y qué hacer con ellos.
- **Comparar las dos versiones** con *Line Chart* sobre `T_Max` muestra el suavizado de la corregida.
- **Para pasar a regresión**: crea retardos (humedad de ayer, de hace 7 días) y la temperatura del día, y prueba Random Forest. Ojo: usar la temperatura del mismo día para predecir la humedad de ese día solo sirve si en el momento de predecir ya se conoce.
- La estación de Sevilla (`wea_SE001.csv`, en la misma carpeta del repositorio) permite repetir el ejercicio con otra serie del mismo formato.

En la carpeta	`meteo_huelva_hu002` ← `weather/wea_HU002.csv` (gualbe/datasets (GitHub))
En la carpeta	`meteo_huelva_hu002_corregido` ← `weather/wea_HU002_corrected.csv` (gualbe/datasets (GitHub))

9.07
Series temporales y ventas

Ozono y contaminantes horarios en Aljarafe (Sevilla)

`09_series_temporales/ozono_aljarafe/`

Once años de medidas horarias de ozono, partículas, dióxido de nitrógeno, temperatura y viento en la estación de Aljarafe (Sevilla), para predecir el ozono de las próximas horas.

Predicción de series temporales · Regresión · Grande · Temporal

> **En el curso:** Actividad 6.3 (Tema 6), en las diapositivas con la versión corregida; no se llegó a hacer en clase.

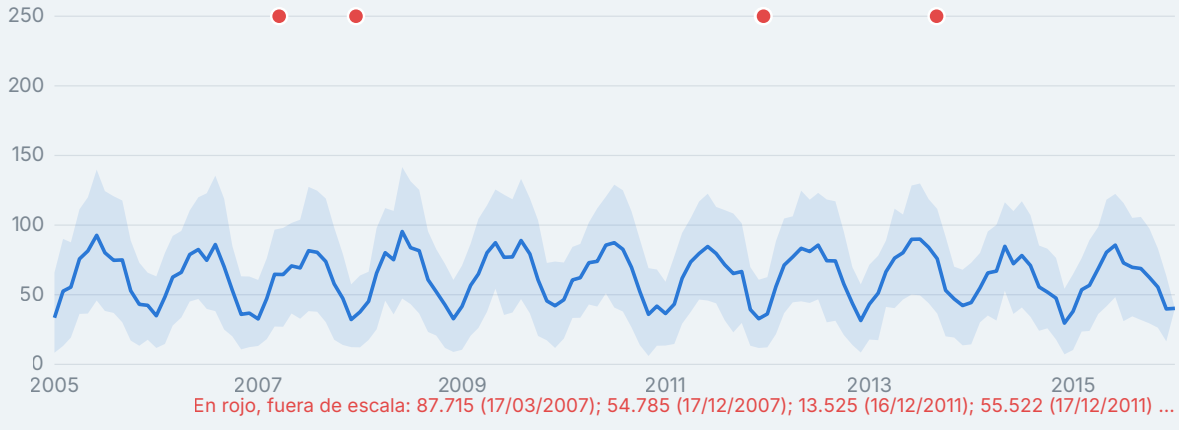
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
96.408	**6**	`ALJARAFE-03-AT_IN`	**0,0 %**	**Avanzado**	**Timeseries**

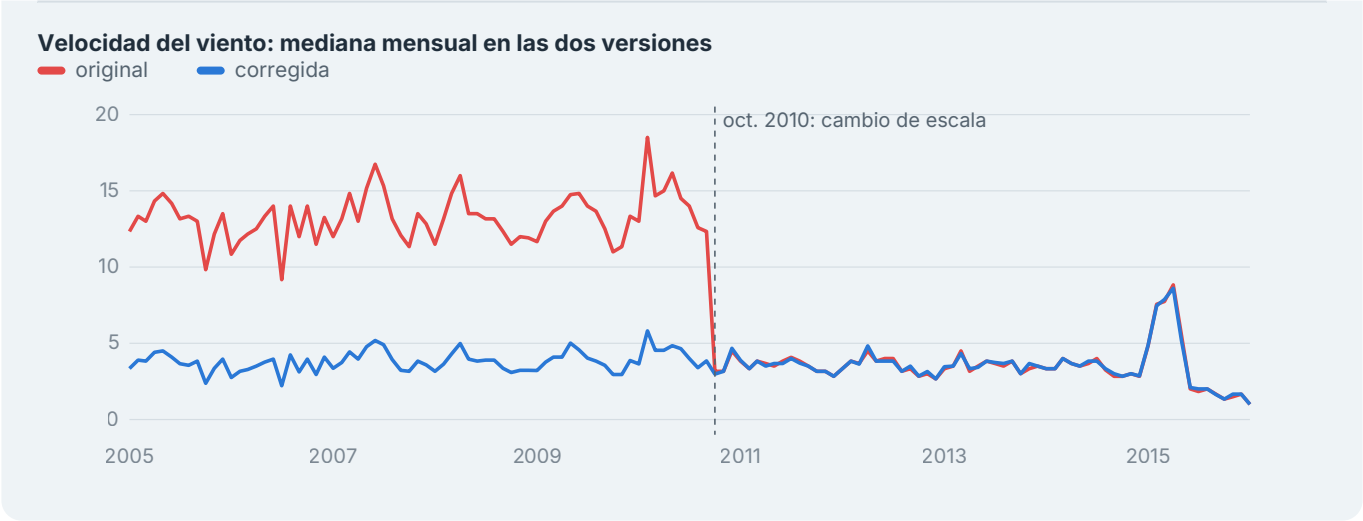
Fichero	Filas × col.	Descargar
`ozono_aljarafe`	96.408 × 6	CSV 5,3 MB · XLSX
`ozono_aljarafe_corregido`	96.408 × 6	CSV 5,1 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/09_series_temporales/ozono_aljarafe/` seguido del nombre del fichero CSV.

Radiografía

Ozono (µg/m³), versión corregida: media mensual y rango entre los percentiles 10 y 90





1 Descripción general y estudios habituales

Son **96.408 horas**, de la 1:00 del 1 de enero de 2005 a la medianoche del 31 de diciembre de 2015, sin ninguna hora perdida. Cada fila tiene cinco medidas de la estación de calidad del aire de **Aljarafe**, en las afueras de Sevilla: ozono (O_3), partículas PM10, dióxido de nitrógeno (NO_2), temperatura y velocidad del viento.

Hay **dos versiones**: la original (`ozono_aljarafe`) y una corregida (`ozono_aljarafe_corregido`), que es la que enlazan las diapositivas. Los estudios habituales son:

- **Predecir el ozono de las próximas horas o del día siguiente** (predicción de series temporales). Es el problema del artículo del que salen los datos.
- **Usar las otras variables como exógenas** (VAR, o regresión con retardos) y ver si mejoran la predicción.
- **Estudiar los ciclos**: el diario (el ozono se forma con la luz del sol) y el anual (más en primavera y verano).
- **Limpiar una serie larga con errores** de varios tipos.

2 Contexto y fuente original

Los datos vienen del trabajo de Gómez-Losada, Asencio-Cortés, Martínez-Álvarez y Riquelme (2018), publicado en *Environmental Modelling & Software*, que propone predecir el ozono horario con 24 horas de antelación usando solo valores pasados de ozono. El artículo usa cinco estaciones de Andalucía (Asomadilla en Córdoba, Ronda del Valle en Jaén y Aljarafe, Bermejales y Torneo en Sevilla) entre 2006 y 2015. Los datos los proporcionó la Consejería de Medio Ambiente y Ordenación del Territorio de la Junta de Andalucía, ya validados.

Aljarafe es una estación **suburbana de fondo**. El artículo comenta que puede recibir ozono transportado desde Huelva, con mucha actividad industrial, y que por eso de noche varía menos que en otras estaciones. El ozono se mide en µg/m³; las unidades de las demás columnas no se indican.

En el repositorio, la carpeta `ozone-forecasting` tiene también las otras cuatro estaciones y el PDF del artículo. Este libro solo incluye Aljarafe, que es la que se usa en el curso.

Qué cambia la versión corregida. Comparando los dos ficheros celda a celda:

- **PM10, NO_2 y temperatura**: sustituye los valores absurdos (por encima de 1.000, hasta 110.305) y unas 2.000 horas más de cada columna.
- **Viento**: hasta septiembre de 2010 la versión original está en otra escala (mediana de unos 13 frente a 3,5 desde octubre de 2010, compatible con un paso de km/h a m/s). La corregida reescala esos años con una transformación lineal que deja **1.327 horas con velocidad negativa**.

- **Ozono**: en 431 días, a partir de cierta hora, sustituye los valores del resto del día por un valor constante (5.960 horas en total), aunque los originales eran normales. **Y deja los cinco valores absurdos del ozono** (entre 13.525 y 87.715 µg/m³).
- Gómez-Losada, Á., Asencio-Cortés, G., Martínez-Álvarez, F. y Riquelme, J. C. (2018). A novel approach to forecast urban surface-level ozone considering heterogeneous locations and limited information. Environmental Modelling & Software, 110, 52–61.
- Ficheros originales: gualbe/datasets, carpeta ozone-forecasting (aljarafe.csv y aljarafe_corrected.csv)

3 Variable objetivo

La variable a predecir es `ALJARAFE-O3-AT_IN`, el ozono en µg/m³. Sin los cinco valores absurdos, va de 0 a 240,5, con mediana de 61,4.

Tiene **dos ciclos muy marcados**. El diario: mínimo hacia las 10 h (mediana 30) y máximo entre las 17 y las 19 h (mediana 89). El anual: mediana mensual de 35 en diciembre y 83 en junio. Hay 32 horas por encima de 180 µg/m³, el umbral de información a la población de la normativa europea.

4 Diccionario de columnas

Columnas de `ozono_aljarafe` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
FECHA_HORA	texto	Hora de la medida (DD/MM/AAAA HH:MM:SS). Cada valor corresponde a la hora que termina: la última fila es «01/01/2016 00:00:00». Orange la lee como texto.	01/01/2005 01:00:00 (1), 01/01/2005 02:00:00 (1), 01/01/2005 03:00:00 (1), 01/01/2005 04:00:00 (1), 01/01/2005 05:00:00 (1), 01/01/2005 06:00:00 (1) …
ALJARAFE-O3-AT_IN `objetivo`	numérica	**Ozono (µg/m³)**: la variable a predecir. Cinco valores absurdos, entre 13.525 y 87.715.	0 – 87.715
ALJARAFE-PM10-AT_IN	numérica	Partículas PM10. 55 horas por encima de 1.000 (máximo 110.305): errores.	5 – 110.305
ALJARAFE-NO2-AT_IN	numérica	Dióxido de nitrógeno. 62 horas por encima de 1.000; 55 horas con 0.	0 – 75.852
ALJARAFE-TMP Media-AT_IN	numérica	Temperatura media de la hora (°C). 74 horas por encima de 1.000.	-0,167 – 33.865
ALJARAFE-VV-AT_IN	numérica	Velocidad del viento. Cambia de escala en octubre de 2010 (probablemente de km/h a m/s); 28 horas por encima de 1.000.	0 – 15.415

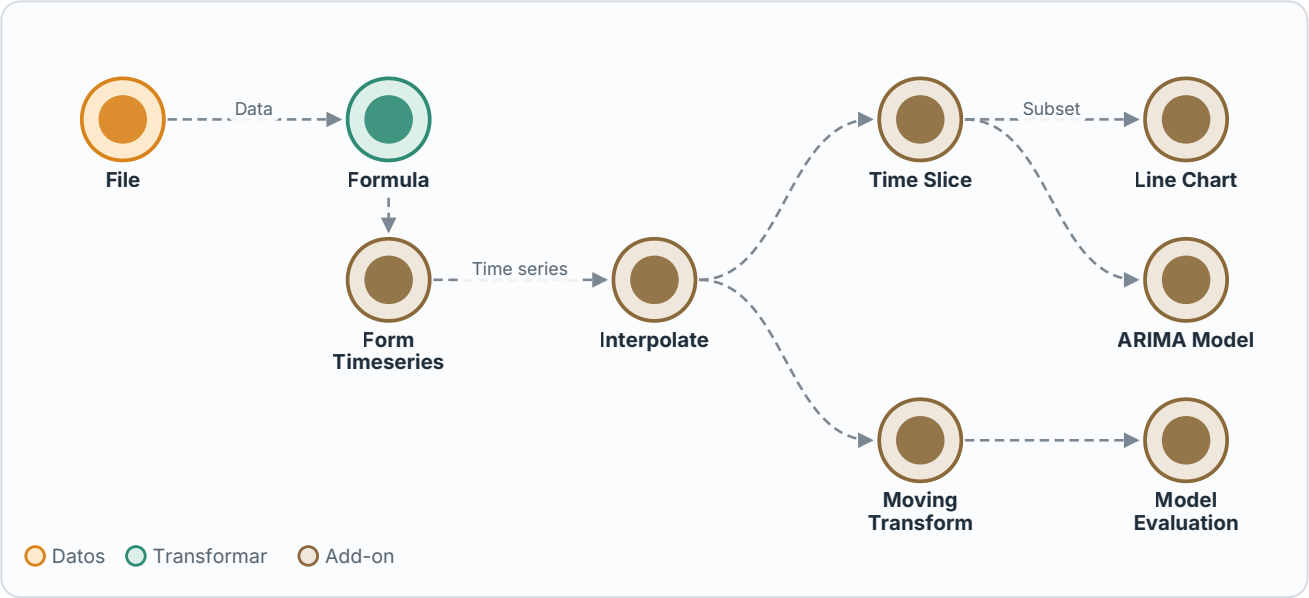
Columnas de `ozono_aljarafe_corregido` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
T	fecha/hora	Hora de la medida en formato ISO (AAAA-MM-DD HH:MM:SS). Orange la reconoce como fecha.	2005-01-01 01:00:00 (1), 2005-01-01 02:00:00 (1), 2005-01-01 03:00:00 (1), 2005-01-01 04:00:00 (1), 2005-01-01 05:00:00 (1), 2005-01-01 06:00:00 (1) …
`ALJARAFE-O3-AT_IN` objetivo	numérica	**Ozono (µg/m³)**. Mantiene los cinco valores absurdos y tiene 431 días con tramos rellenados con un valor constante.	0 – 87.715
`ALJARAFE-PM10-AT_IN`	numérica	PM10, sin los valores absurdos (máximo 612).	5 – 612
`ALJARAFE-NO2-AT_IN`	numérica	NO_2, sin los valores absurdos (máximo 159).	0 – 159,167
`ALJARAFE-TMP Media-AT_IN`	numérica	Temperatura (°C), entre −0,2 y 45,3.	-0,167 – 45,333
`ALJARAFE-VV-AT_IN`	numérica	Velocidad del viento, reescalada hasta septiembre de 2010. Tiene 1.327 valores negativos (todos de 2005 a 2010).	-0,956 – 27,053

5 Particularidades técnicas al modelar

- **Ninguna de las dos versiones está lista para modelar.** En las dos, el ozono tiene cinco valores entre 13.525 y 87.715 µg/m³ (17/03/2007, 17/12/2007, 16 y 17/12/2011 y 29/08/2013) que destrozan cualquier media, gráfico o modelo. Hay que convertirlos en ausentes e interpolarlos antes de nada.
- **La «corrección» del ozono borra datos buenos**: en 431 días sustituye las horas que quedan del día por un valor fijo. Esas horas pierden el ciclo diario, que es justo lo que el modelo tiene que aprender. Si se usa la versión original, hay que limpiar a mano PM10, NO_2, temperatura y viento; si se usa la corregida, conviene marcar o quitar esos días.
- **El viento cambia de escala en octubre de 2010** en el fichero original, y en el corregido tiene velocidades negativas. Si se usa como variable exógena, hay que unificar la escala y recortar los negativos a 0.
- **Fecha como texto en el original**: `FECHA_HORA` va en formato día/mes/año, que Orange lee como texto. Hay que convertirla con *Edit Domain* o usar la versión corregida, cuya columna `T` ya está en formato ISO.
- **Serie muy larga para Orange**: 96.408 horas hacen lentos *Line Chart*, ARIMA y *Model Evaluation*. Para practicar, recorta con *Time Slice* uno o dos años, o agrega por días con *Moving Transform* (media o máximo diario).
- **Dos ciclos a la vez** (24 horas y un año): un ARIMA simple no los recoge. Ayuda añadir la hora del día y el mes como variables, o predecir el máximo diario en lugar del valor horario.
- Validación: *Model Evaluation* con ventanas que avanzan; nunca validación cruzada aleatoria.

6 Flujo de trabajo en Orange



1. **File** con `ozono_aljarafe_corregido`: `T` como fecha y el ozono como *target*.
2. **Formula**: pon como ausente el ozono cuando supere 1.000, y el viento negativo como 0.
3. **Form Timeseries** con `T` → **Interpolate** lineal.
4. **Time Slice** para quedarte con un año (por ejemplo, 2014) → **Line Chart**: el ciclo diario se ve bien a esta escala.
5. **ARIMA Model** sobre ese año con un término de 24 horas → predice las 24 horas siguientes.
6. **Moving Transform** (agregar por día, máximo) → **Model Evaluation** con el ozono máximo diario: compara ARIMA con el valor del día anterior.

7 Otras consideraciones

- **Replicar la idea del artículo**: predecir el ozono de cada hora con el valor de esa misma hora el día anterior y hace dos días (retardos de 24 y 48 h) y una regresión lineal. Es sencillo y sirve de referencia.
- **Comparar estaciones**: en la carpeta `ozone-forecasting` del repositorio están Asomadilla, Bermejales, Ronda del Valle y Torneo con la misma estructura. Torneo es urbana de tráfico; Aljarafe, suburbana.
- **¿Ayudan las exógenas?** Compara un modelo solo con ozono pasado y otro con temperatura y NO_2 pasados (VAR o regresión con retardos).
- Antes de usar la versión corregida en un trabajo, revisa con *Line Chart* un día de los rellenados con valor fijo (por ejemplo, el 15/02/2005): se ve en seguida.

En la carpeta `ozono_aljarafe` ← `ozone-forecasting/aljarafe.csv` (gualbe/datasets (GitHub))

En la carpeta `ozono_aljarafe_corregido` ← `ozone-forecasting/aljarafe_corrected.csv` (gualbe/datasets (GitHub))

10 Minería de textos

6 datasets en el capítulo; en esta edición, 6 con ficha.

10.01
Minería de textos

BBC news (3 categorías)

`10_mineria_textos/bbc3/`

1.407 noticias de la BBC (2004–2005) de tres secciones: economía, espectáculos y deportes. El ejemplo más sencillo de clasificación de textos en inglés.

Minería de textos · Clasificación multiclase · ¶ Texto

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
1.407	**3**	`category`	**0,0 %**	**Iniciación**	**Text**

Fichero	Filas × col.	Descargar
`bbc3`	1.407 × 3	CSV 2,8 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/10_mineria_textos/bbc3/` seguido del nombre del fichero CSV.

Radiografía

category en bbc3



1 Descripción general y estudios habituales

Cada fila es una noticia completa de la web de BBC News, con su titular (`Title`), el texto (`Content`) y la sección (`category`): 510 de economía (`business`), 386 de espectáculos (`entertainment`) y 511 de deportes (`sport`). Las noticias tienen de 108 a 3.477 palabras (mediana, 282).

Estudios habituales: **clasificar textos** por tema con bolsa de palabras o *embeddings*, **agrupar** sin usar la sección (las tres se separan solas), **nubes de palabras** y **modelado de temas**.

2 Contexto y fuente original

Es parte del conjunto BBC de Derek Greene y Pádraig Cunningham (University College Dublin), publicado con su artículo de ICML 2006 sobre agrupamiento de documentos: 2.225 noticias de 2004–2005 en cinco

secciones. Orange se queda con tres (le faltan política y tecnología) y las tiene todas. Según la ficha de Orange, los datos son solo para uso no comercial e investigación, y el copyright de los textos es de la BBC.

- Greene, D. y Cunningham, P. (2006). Practical solutions to the problem of diagonal dominance in kernel document clustering. Proc. ICML 2006. Datos: ML Resources (UCD).

3 Variable objetivo

`category`: `sport` (36 %), `business` (36 %) y `entertainment` (27 %). Es una tarea fácil: medido fuera de Orange con *scikit-learn* (TF-IDF y regresión logística, validación cruzada de 10 bolsas), se acierta el 99,5 % de las noticias.

4 Diccionario de columnas

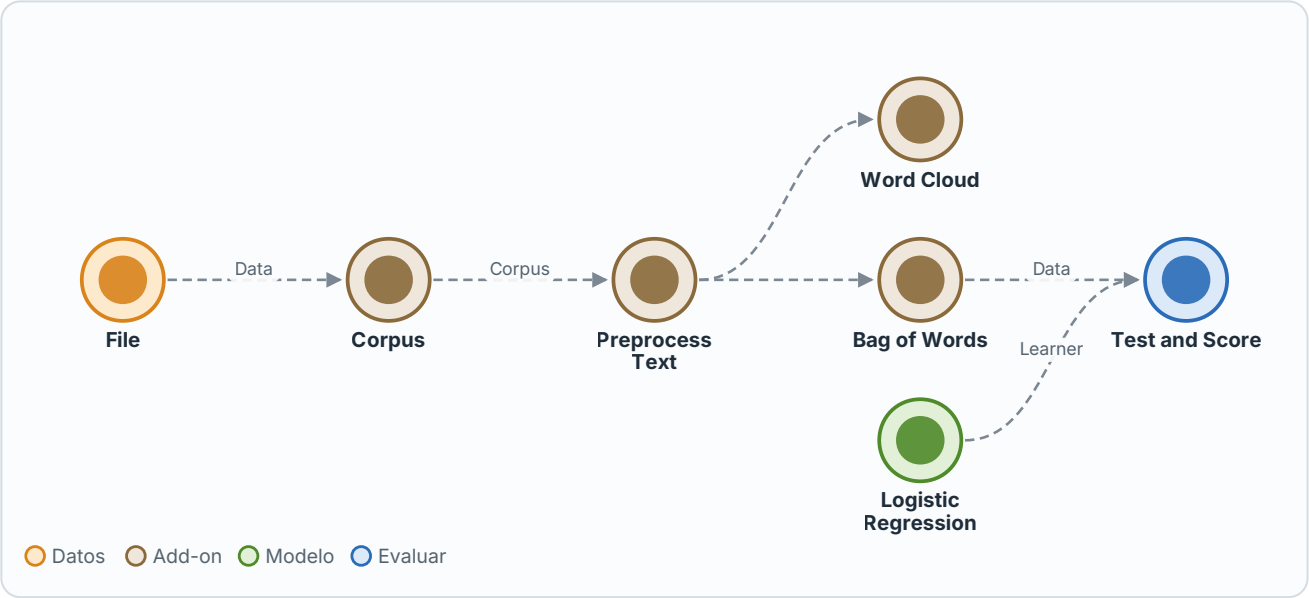
Columnas de `bbc3` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Title`	texto	Titular (meta).	SEC to rethink post-Enron rules (2), News Corp eyes video games market (2), Desailly backs Blues revenge trip (2), Wolves appoint Hoddle as manager (2), Russian film wins BBC world prize (2), Aviator 'creator' in Oscars snub (2) …
`Content`	texto	Texto completo de la noticia, en inglés, sin el titular (meta).	texto libre (mediana de 282 palabras)
`category` `objetivo`	categórica	Sección de la noticia: `business`, `entertainment` o `sport`. Objetivo.	sport (511), business (510), entertainment (386)

5 Particularidades técnicas al modelar

- **El texto es una meta**: en *File* las columnas de texto se leen como metas. Para analizarlas, pasa los datos por *Corpus* (add-on Text) y marca `Content` (y si quieres `Title`) como texto.
- **47 noticias están repetidas** (mismo texto, misma sección): heredadas del conjunto original. Inflan un poco la validación cruzada; quítalas con *Unique* o con *Select Rows*.
- **Preprocesado**: minúsculas, quitar palabras vacías en inglés y, si se quiere, lematizar. Con bolsa de palabras salen miles de columnas: los modelos lineales (*Logistic Regression*, SVM) funcionan mejor que un árbol.

6 Flujo de trabajo en Orange



1. **File** con `bbc3.csv` : marca `category` como *target* (en el CSV no viene marcada). → **Corpus** con `Content` como texto.
2. **Preprocess Text**: minúsculas, *tokenización* por palabras y palabras vacías en inglés. → **Word Cloud** por sección.
3. **Bag of Words** (TF-IDF) → **Test and Score** con **Logistic Regression**: acierto cercano al 100 %.
4. Variante no supervisada: **Document Embedding** → **Distances** → **Hierarchical Clustering** y comparar los grupos con `category` .

7 Otras consideraciones

- Es un buen primer ejercicio; para algo más difícil usa *SentiNews* (sentimiento) o *ParlaMint* (año del discurso).
- Noticias de 2004–2005: el vocabulario de economía y deporte es de esa época (Yukos, Greenspan).

En la carpeta `bbc3` ← `BBC3.tab` (datasets.biolab.si)

10.02
Minería de textos

ParlaMint-GB (1000 discursos)

`10_mineria_textos/parlamint_1000/`

1.000 intervenciones del Parlamento británico de 2019 y 2020, con orador, partido, cámara y un resumen generado por GPT: para clasificar discursos, compararlos por partido o ver el cambio que trajo la COVID-19.

Minería de textos · Clasificación multiclase · ? Valores faltantes · Temporal · Texto

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
1.000	**18**	`category`	**0,1 %**	**Intermedio**	**Text**

Fichero	Filas × col.	Descargar
`parlamint_1000`	1.000 × 18	CSV 1,8 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/10_mineria_textos/parlamint_1000/` seguido del nombre del fichero CSV.

Radiografía

category en parlamint_1000



1 Descripción general y estudios habituales

Cada fila es una intervención de un parlamentario en la Cámara de los Comunes (697) o en la de los Lores (303), entre el 7 de enero de 2019 y el 30 de diciembre de 2020. Además del texto (`content`, de 51 a 3.156 palabras; mediana, 108), trae el orador, su partido, su sexo, la cámara, la fecha, la legislatura y un resumen de 3 a 6 palabras (`Summary`).

Estudios habituales: **clasificar** el discurso (por año, cámara o partido), **comparar vocabularios** entre partidos o entre 2019 y 2020, **modelado de temas** y **análisis temporal** del debate.

2 Contexto y fuente original

Es una muestra del corpus ParlaMint-GB 2.1, parte del proyecto europeo ParlaMint (CLARIN), que reúne las actas de los parlamentos nacionales con metadatos homogéneos y anotación lingüística. Orange añadió la columna `Summary`, generada con GPT. ParlaMint divide las sesiones en el subcorpus de referencia y el subcorpus COVID, que empieza en noviembre de 2019.

- Erjavec, T. et al. (2022). The ParlaMint corpora of parliamentary proceedings. Language Resources and Evaluation.
- CLARIN ERIC. ParlaMint: muestras del corpus de Reino Unido (ParlaMint-GB).

3 Variable objetivo

`category` es el **año** de la intervención: 2019 (488) o 2020 (512). Coincide casi con `Subcorpus` (`COVID` en 2020 y en 7 intervenciones de noviembre y diciembre de 2019). Es más difícil que parece: medido fuera de Orange con *scikit-learn* (TF-IDF y regresión logística, validación cruzada de 10 bolsas), el acierto es del 62 % frente al 51 % de la clase mayoritaria. Solo el 18 % de las intervenciones de 2020 nombran el coronavirus, la COVID o la pandemia.

Otras variables sirven de objetivo: la cámara se acierta el 92,5 % de las veces (en los Lores se dice «noble Lord» o «my Lords»), y conservadores frente a laboristas, el 80 % (con un 74 % de conservadores).

4 Diccionario de columnas

Columnas de `parlamint_1000` (valores observados en el fichero)

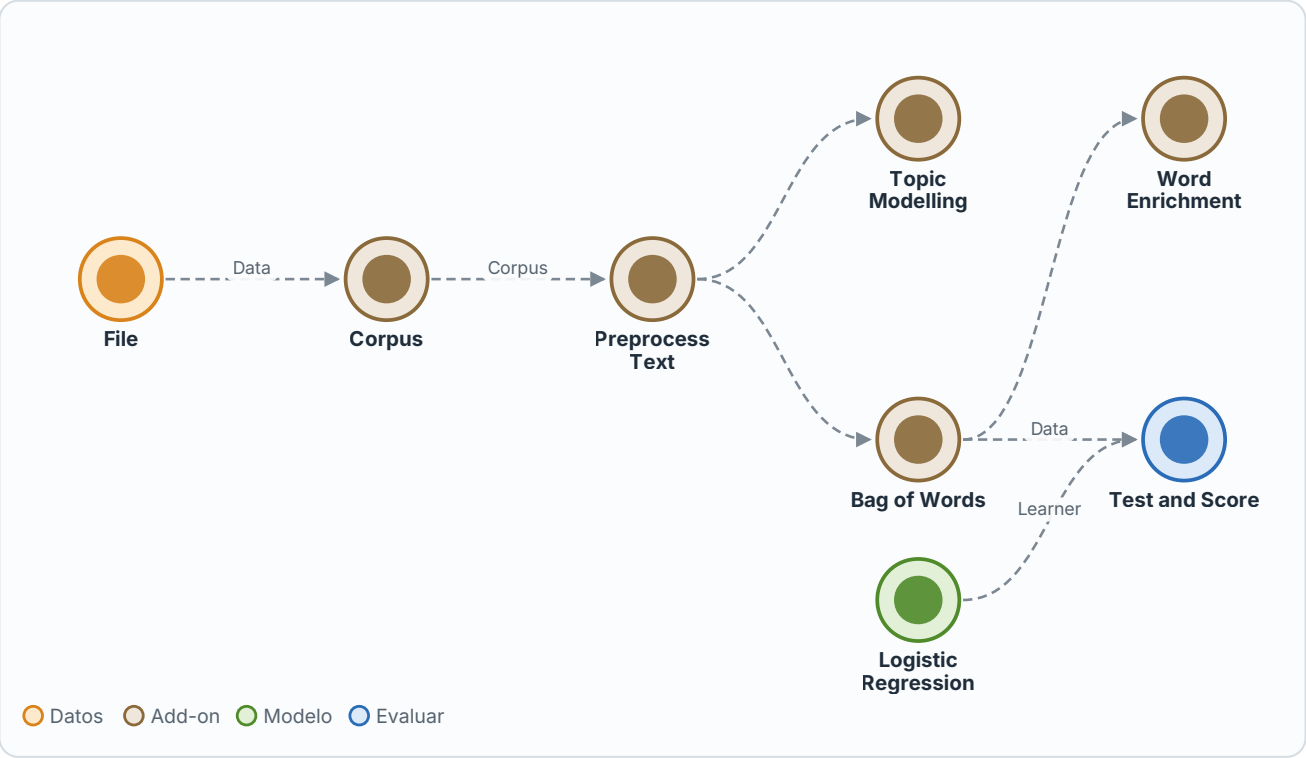
Columna	Tipo	Significado	Valores
`category` objetivo	categórica	Año de la intervención (2019 o 2020). Objetivo.	2020 (512), 2019 (488)
`name`	texto	Identificador de la sesión (p. ej. `ParlaMint-GB_2020-09-10-commons`).	ParlaMint-GB_2020-09-10-commons (8), ParlaMint-GB_2019-03-28-commons (8), ParlaMint-GB_2019-09-25-commons (8), ParlaMint-GB_2019-04-23-commons (7), ParlaMint-GB_2020-03-18-commons (7), ParlaMint-GB_2019-05-23-commons (7) …
`content`	texto	Texto de la intervención, en inglés.	texto libre (mediana de 108 palabras)
`utterance`	texto	Identificador de la intervención dentro del corpus.	(no se muestran)
`Title`	texto	Título de la sesión (`Minutes of the House of Commons, Daily Session …`).	Minutes of the House of Commons, Daily Session 2020-09-10 (8), Minutes of the House of Commons, Daily Session 2019-03-28 (8), Minutes of the House of Commons, Daily Session 2019-09-25 (8), Minutes of the House of Commons, Daily Session 2019-04-23 (7), Minutes of the House of Commons, Daily Session 2020-03-18 (7), Minutes of the House of Commons, Daily Session 2019-05-23 (7) …
`Speaker_name`	texto	Orador, como «Apellido, Nombres» (539 distintos).	Hancock, Matthew John David (16), Barclay, Stephen Paul (11), Johnson, Alexander Boris de Pfeffel (11), Rees-Mogg, Jacob William (9), Ahmad, Tariq (9), Tolhurst, Kelly Jane (8) …
`Summary`	texto	Resumen de 3 a 6 palabras generado con GPT (añadido por Orange).	Support for regional airports (2), HS2-HS1 link missed opportunity (1), Five-minute limit after speech (1), Clarifying foreign fishing boat regulations (1), Change law to prosecute terrorism (1), Fly-tipping concerns in constituency (1) …

Columna	Tipo	Significado	Valores
`From`	fecha/hora	Fecha de la sesión.	2019-02-19 00:00:00 (12), 2020-09-10 00:00:00 (11), 2019-05-23 00:00:00 (9), 2019-07-02 00:00:00 (8), 2019-09-25 00:00:00 (8), 2020-07-15 00:00:00 (8) …
`To`	fecha/hora	Fecha final de la sesión: igual a `From` en todas las filas.	2019-02-19 00:00:00 (12), 2020-09-10 00:00:00 (11), 2019-05-23 00:00:00 (9), 2019-07-02 00:00:00 (8), 2019-09-25 00:00:00 (8), 2020-07-15 00:00:00 (8) …
`House`	categórica	Cámara: `Lower house` (Comunes) o `Upper house` (Lores).	Lower house (697), Upper house (303)
`Term`	numérica	Legislatura: 57 (hasta noviembre de 2019) o 58 (desde diciembre de 2019).	57 – 58
`Subcorpus`	categórica	Subcorpus de ParlaMint: `COVID` (desde noviembre de 2019) o `Reference`.	COVID (519), Reference (481)
`Speaker_role`	categórica	Papel del orador: siempre `Regular`.	Regular (1.000)
`Speaker_type`	categórica	Tipo de orador: siempre `MP`.	MP (1.000)
`Speaker_party`	categórica	Siglas del partido (`CON`, `LAB`, `LD`, `SNP`, `CB` = independientes de los Lores…). 2 vacíos.	CON (596), LAB (210), LD (67), SNP (47), CB (34), DUP (19) …
`Speaker_party_name`	categórica	Nombre del partido.	Conservative (596), Labour (210), Liberal Democrat (67), Scottish National Party (47), Crossbench (34), Democratic Unionist Party (19) …
`Party_status`	categórica	Situación del partido: `Opposition` en 989 filas (también en los conservadores, que gobernaban) y vacía en 11. No sirve.	Opposition (989)
`Speaker_gender`	categórica	Sexo del orador: `M` (681) o `F` (319).	M (681), F (319)

5 Particularidades técnicas al modelar

- **El año se lee como número**: en el `.tab` de Orange `category` es categórica y objetivo, pero al abrir este CSV Orange la lee como numérica y sin papel de objetivo. En *File*, cámbiala a *categorical* y márcala como *target*; si no, *Test and Score* la trata como regresión. Lo mismo pasa con `Term`.
- **Fugas**: `From`, `To`, `Term`, `Subcorpus` y `name` revelan el año. Para clasificar por año, deja solo el texto.
- **Columnas sin información**: `Speaker_role` y `Speaker_type` son constantes, y `Party_status` dice `Opposition` hasta en el partido del Gobierno: no la uses.
- **Partidos combinados** (`CON;I`, `LD;NA`): probablemente, oradores que cambiaron de grupo en el periodo; agrúpalos antes de comparar partidos.
- **Intervenciones muy cortas**: la mitad tiene menos de 110 palabras; con tan poco texto, la bolsa de palabras es muy dispersa.

6 Flujo de trabajo en Orange



1. **File** con `parlamint_1000.csv` (comprueba que `category` es categórica) → **Corpus** con `content` como texto.
2. **Preprocess Text** con palabras vacías en inglés → **Topic Modelling** (LDA, unos 10 temas): aparece un tema de la pandemia.
3. **Bag of Words** → **Test and Score** con **Logistic Regression** para el año, solo con el texto.
4. **Word Enrichment** con las intervenciones de 2020 seleccionadas: palabras que distinguen un año del otro.

7 Otras consideraciones

- **Personas públicas**: los oradores son parlamentarios y las actas son públicas.
- El corpus completo ParlaMint-GB tiene muchas más intervenciones y años; esta muestra es para clase.
- `Summary` permite comparar la clasificación con el texto completo frente a la clasificación con un resumen de 5 palabras.

En la carpeta `parlamint_1000` ← `ParlaMint-1000.tab` (datasets.biolab.si)

10.03
Minería de textos

SentiNews (noticias eslovenas)

`10_mineria_textos/sentinews_si/`

2.000 noticias económicas y políticas de dos portales eslovenos (2007–2016), etiquetadas como positivas, neutras o negativas: análisis de sentimiento en un idioma distinto del inglés.

Minería de textos · Clasificación multiclase · ? Valores faltantes · ¶ Texto

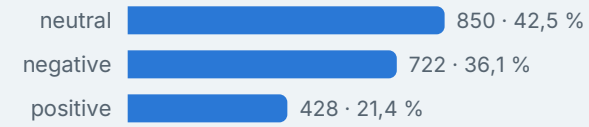
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
2.000	**8**	`sentiment`	**0,5 %**	**Intermedio**	**Text**

Fichero	Filas × col.	Descargar
`sentinews_si`	2.000 × 8	CSV 5,2 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/10_mineria_textos/sentinews_si/` seguido del nombre del fichero CSV.

Radiografía

sentiment en sentinews_si



1 Descripción general y estudios habituales

Cada fila es una noticia de 24ur o de Dnevnik (1.000 de cada uno), en esloveno, con título, palabras clave, texto, autor, fecha, dirección web y el sentimiento de la noticia entera. Las noticias son de 2007 a 2016, casi todas de 2008 a 2011, y tienen de 7 a 2.848 palabras (mediana, 312).

Estudios habituales: **clasificar el sentimiento**, **comparar** un clasificador entrenado con un diccionario de sentimiento (*Sentiment Analysis*) frente a uno aprendido, y **comparar los dos portales**.

2 Contexto y fuente original

Es una muestra de AutoSentiNews 1.0 (Jože Bučar, 2017, repositorio CLARIN.SI): 256.567 noticias de cinco portales eslovenos (24ur, Dnevnik, Finance, Rtvslo y Žurnal24), con contenido político, económico y financiero. En ese corpus, 10.427 noticias tienen sentimiento anotado a mano (el corpus SentiNews 1.0) y el resto, **anotado automáticamente**. La ficha de Orange no dice de cuáles son estas 2.000. Licencia CC BY-SA 4.0.

- Bučar, J. (2017). Automatically sentiment annotated Slovenian news corpus AutoSentiNews 1.0. CLARIN.SI.

3 Variable objetivo

`sentiment`: `neutral` (850), `negative` (722) y `positive` (428). Dnevnik tiene más neutras (473) y 24ur más negativas (401). Medido fuera de Orange con *scikit-learn* (TF-IDF y regresión logística, validación cruzada

de 10 bolsas), el acierto es del 82 % frente al 42,5 % de la clase mayoritaria. Si parte de las etiquetas son automáticas, el modelo aprende a imitar al anotador automático.

4 Diccionario de columnas

Columnas de `sentinews_si` (valores observados en el fichero)

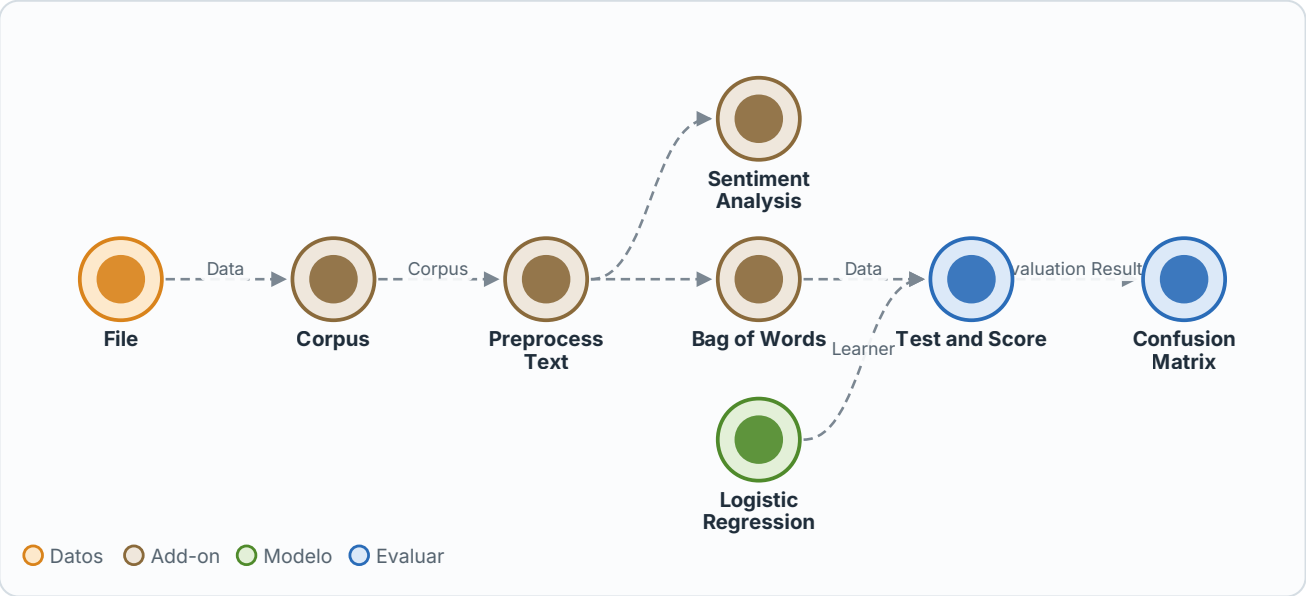
Columna	Tipo	Significado	Valores
`sentiment` `objetivo`	categórica	Sentimiento de la noticia: `positive`, `neutral` o `negative`. Objetivo.	neutral (850), negative (722), positive (428)
`url`	texto	Dirección de la noticia (meta).	(no se muestran)
`title`	texto	Titular, en esloveno (meta).	Novice (39), Ljubljanska borza: SBI TOP navzgor (2), Ljubljanska borza: SBI TOP zdrsnil za pol odstotka (2), Rekordna podražitev bencina (2), Geodetska uprava prenovila javni vpogled v podatke o nepr… (1), Nadzorniki Petrola pozno v večer o terjatvah do SCT (1) …
`keywords`	texto	Palabras clave de la noticia, separadas por comas (meta).	gospodarstvo, ekonomija (1.000), bencin, naftni, derivat, dizel, dizelsko, gorivo, 95-okta… (2), bencin, gorivo, trošarine, trošarina, nafta, kurilno, olj… (2), kriza, borza, lehman, brothers, nafta, delnice, cena (2), naftni, derivat, nafta, bencin, slovenija, dizel, pocenitev (2), mura, sod, nfd, predlog, finance, občina, tomaž, kuntarič (2) …
`content`	texto	Texto de la noticia, en esloveno (meta).	texto libre (mediana de 312 palabras)
`author`	texto	Autor (402 distintos; vacío en 78). La agencia de noticias aparece como `sta` (394) y `STA` (207).	(no se muestran)
`source`	categórica	Portal: `24ur` o `Dnevnik`.	24ur (1.000), Dnevnik (1.000)
`date`	fecha/hora	Fecha de publicación.	2009-04-21 00:00:00 (7), 2009-07-31 00:00:00 (6), 2009-09-15 00:00:00 (6), 2009-12-02 00:00:00 (5), 2010-07-20 00:00:00 (5), 2010-07-30 00:00:00 (5) …

5 Particularidades técnicas al modelar

- **Idioma esloveno**: en *Preprocess Text* hay que elegir palabras vacías y lematizador para el esloveno (UDPipe tiene modelo esloveno). Sin lematizar, cada palabra aparece en muchas formas (el esloveno tiene seis casos).

- **El diccionario de *Sentiment Analysis*** de Orange incluye métodos para esloveno, pero no coinciden con estas etiquetas: compáralos con el objetivo en una matriz de confusión.
- `source` **y** `date` **son atributos** al abrir el CSV: si solo quieres el texto, quítalos con *Select Columns*.
- **43 noticias tienen menos de 30 palabras**: apenas hay texto para decidir.
- `sta` **y** `STA` son la misma agencia (STA, agencia de prensa eslovena) escrita de dos formas.

6 Flujo de trabajo en Orange



1. **File** con `sentinews_si.csv`, `sentiment` como *target* → **Corpus** con `content` (y `title`) como texto.
2. **Preprocess Text** con palabras vacías y lematización en esloveno.
3. **Sentiment Analysis** (método para esloveno) y compara su puntuación con `sentiment` en un **Box Plot**.
4. **Bag of Words** → **Test and Score** con **Logistic Regression** → **Confusion Matrix**: la mayoría de los errores pasan por la clase neutra.

7 Otras consideraciones

- Los autores de las noticias no se muestran en el diccionario.
- Para trabajar con etiquetas anotadas a mano, el corpus SentiNews 1.0 (CLARIN.SI) es la referencia.

En la carpeta `sentinews_si` ← `SentiNews-SI.tab` (datasets.biolab.si)

10.04
Minería de textos

Medical transcriptions (mtsamples)

`10_mineria_textos/mtsamples/`

950 informes médicos de ejemplo en inglés (cardiología y neumología, neurología y traumatología): clasificar la especialidad a partir del texto, con una fuga en las palabras clave.

Minería de textos | Clasificación multiclase | ? Valores faltantes | ¶ Texto

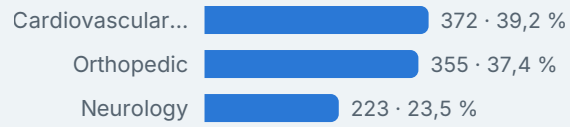
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
950	**5**	`medical_specialty`	**4,6 %**	**Intermedio**	**Text**

Fichero	Filas × col.	Descargar
`mtsamples`	950 × 5	CSV 3,5 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/10_mineria_textos/mtsamples/` seguido del nombre del fichero CSV.

Radiografía

medical_specialty en mtsamples



1 Descripción general y estudios habituales

Cada fila es una transcripción de un informe médico (ecocardiogramas, consultas, informes operatorios...), con una descripción breve, el nombre del ejemplo, las palabras clave y la especialidad. Los informes tienen una mediana de 423 palabras (hasta 2.460).

Estudios habituales: **clasificar textos** por especialidad, **extraer palabras clave** (*Keywords*), **modelado de temas** y **comparar** el texto completo con la descripción breve.

2 Contexto y fuente original

MTSamples (mtsamples.com) es una web con miles de transcripciones médicas de ejemplo, escritas para practicar la transcripción médica; no son historias clínicas de pacientes reales. Hay una versión con unas 5.000 transcripciones de 40 especialidades. Orange se queda con 950 de tres especialidades.

- MTSamples: transcribed medical transcription sample reports and examples.

3 Variable objetivo

`medical_specialty`: `Cardiovascular / Pulmonary` (372), `Orthopedic` (355) y `Neurology` (223). Medido fuera de Orange con *scikit-learn* (TF-IDF y regresión logística, validación cruzada de 10 bolsas), con el texto de la transcripción se acierta el 89 % frente al 39 % de la clase mayoritaria.

4 Diccionario de columnas

Columnas de `mtsamples` (valores observados en el fichero)

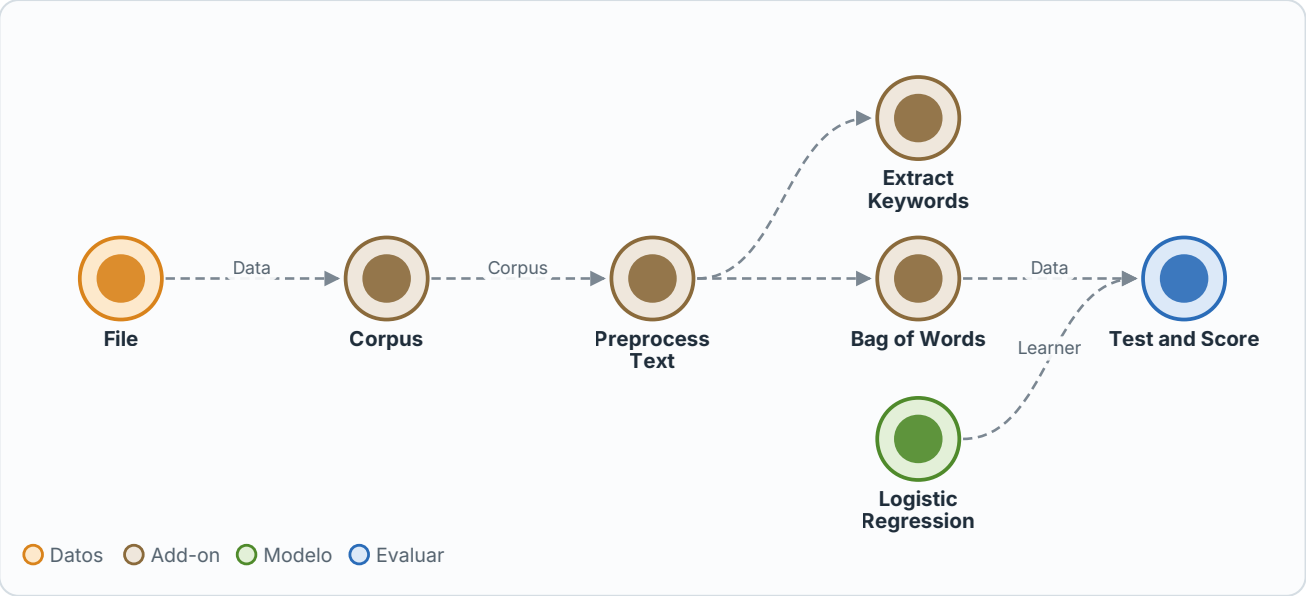
Columna	Tipo	Significado	Valores
`description`	texto	Descripción breve del informe (meta). Vacía en 1.	MRI C-spine to evaluate right shoulder pain - C5-6 disk h... (2), MRI Brain & MRI C-T spine: Multiple hemangioblastoma in V... (2), MRI Cervical Spine without contrast. (2), MRI C-spine: C4-5 Transverse Myelitis. (2), MRI left knee without contrast. (2), MRI L-S-Spine for Cauda Equina Syndrome secondary to L3-4... (2) …
`sample_name`	texto	Nombre del ejemplo en MTSamples, p. ej. `2-D Echocardiogram - 1` (meta).	Rotator Cuff Tear (2), Radiologic Exam - Spine (2), Bilateral Carotid Cerebral Angiogram (2), Laminectomy & Foraminotomy Followup (2), Lumbar Discogram (2), MRI Brain & T-spine - Demyelinating disease. (2) …
`transcription`	texto	Texto del informe, en inglés, con los apartados separados por comas (meta). Vacía en 1.	texto libre (mediana de 423 palabras)
`keywords`	texto	Palabras clave separadas por comas (meta). Vacías en 215. **Empiezan por la especialidad**.	texto libre (mediana de 22 palabras)
`medical_specialty` `objetivo`	categórica	Especialidad: `Cardiovascular / Pulmonary`, `Neurology` u `Orthopedic`. Objetivo.	Cardiovascular / Pulmonary (372), Orthopedic (355), Neurology (223)

5 Particularidades técnicas al modelar

- **Fuga en** `keywords`: en el 77 % de las filas, la primera palabra clave es la propia especialidad (`cardiovascular / pulmonary, …`). Si usas las palabras clave como texto, quita esa primera entrada.
- **37 informes están dos veces con especialidades distintas** (probablemente porque MTSamples publica algunos informes en varias secciones). Ningún modelo puede acertar los dos; además, en validación cruzada uno puede caer en entrenamiento y el otro en prueba.
- **Formato raro**: las líneas y los apartados del informe están unidos con comas (`2-D M-MODE: , ,1. Left atrial…`). Conviene limpiar la puntuación en *Preprocess Text*.

- **Vocabulario médico**: los lematizadores generales no conocen muchos términos; las palabras vacías en inglés sí sirven.
- **15 transcripciones tienen menos de 20 palabras**.

6 Flujo de trabajo en Orange



1. **File** con `mtsamples.csv`, `medical_specialty` como *target* → **Corpus** con `transcription` como texto (no `keywords`).
2. **Preprocess Text**: minúsculas, quitar puntuación y números, palabras vacías en inglés.
3. **Extract Keywords** (TF-IDF o YAKE!) por especialidad: *echocardiogram*, *seizure*, *fracture*…
4. **Bag of Words** → **Test and Score** con **Logistic Regression**.

7 Otras consideraciones

- Son textos de ejemplo, no datos de pacientes: se pueden usar en clase sin problemas de privacidad, aunque imitan informes reales.
- Con todas las especialidades del MTSamples original la tarea es mucho más difícil: muchas secciones (consultas, informes de alta) se solapan.

En la carpeta `mtsamples` ← `mtsamples.tab` (datasets.biolab.si)

10.05
Minería de textos

Cuentos de Grimm y Andersen (en esloveno)

`10_mineria_textos/cuentos_si/`

41 cuentos en esloveno, de magia o de animales (Grimm y cuentos populares eslovenos), y 3 de Andersen para clasificar: un corpus pequeño para empezar con minería de textos.

Minería de textos · Clasificación binaria · Juguete · Texto

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
41	**3**	`Kategorija`	**0,0 %**	**Iniciación**	**Text**

Fichero	Filas × col.	Descargar
`grimm_si`	41 × 3	CSV 166 KB · XLSX
`andersen_si`	3 × 2	CSV 20 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/10_mineria_textos/cuentos_si/` seguido del nombre del fichero CSV.

Radiografía

Kategorija en grimm_si



1 Descripción general y estudios habituales

Son dos ficheros. `grimm_si` tiene 41 cuentos con título (`Naslov`), texto (`Vsebina`) y tipo (`Kategorija`): 23 de magia (`magične`) y 18 de animales (`živalske`). Tienen de 98 a 2.485 palabras (mediana, 561). `andersen_si` tiene 3 cuentos de Andersen sin tipo: *El traje nuevo del emperador*, *La pequeña cerillera* y *El patito feo*.

Estudios habituales: **clasificar** cuentos en magia o animales, **predecir** el tipo de los tres de Andersen con el modelo entrenado, **nubes de palabras** por tipo y **agrupar** cuentos por parecido.

2 Contexto y fuente original

Los preparó el laboratorio de Orange (Universidad de Liubliana) para enseñar minería de textos. Según su ficha, son traducciones automáticas al esloveno de cuentos de los hermanos Grimm (*Janko in Metka* es Hansel y Gretel; *Sneguljčica*, Blancanieves), con algunos cuentos eslovenos añadidos, sobre todo de animales, como *Mojca Pokrajculja*. Los tipos siguen el índice internacional de cuentos ATU (Aarne-Thompson-Uther), aunque el código ATU no viene en el fichero. Es la versión eslovena de un ejemplo que Orange usa en inglés con cuentos de Grimm.

- Orange Data Mining. GrimmSI y AndersenSI (datasets.biolab.si, 2025).

3 Variable objetivo

`Kategorija`: `magične` (cuentos de magia, 23) o `živalske` (cuentos de animales, 18). Con tan pocos textos, la validación es inestable: medido fuera de Orange con *scikit-learn* (TF-IDF y regresión logística, validación cruzada de 5 bolsas), el acierto es del 76 % frente al 56 % de la clase mayoritaria. Los cuentos de Andersen no tienen tipo: son datos nuevos para predecir.

4 Diccionario de columnas

Columnas de `grimm_si` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Kategorija` `objetivo`	categórica	Tipo de cuento: `magične` (de magia) o `živalske` (de animales). Objetivo.	magične (23), živalske (18)
`Naslov`	texto	Título del cuento, en esloveno (meta).	Dva brata in čarovnica (1), Gospa Zima (1), Gospodična (1), Janko in Metka (1), Jorinda in Joringel (1), Kralj Matjaž in vile (1) …
`Vsebina`	texto	Texto del cuento, en esloveno (meta).	texto libre (mediana de 561 palabras)

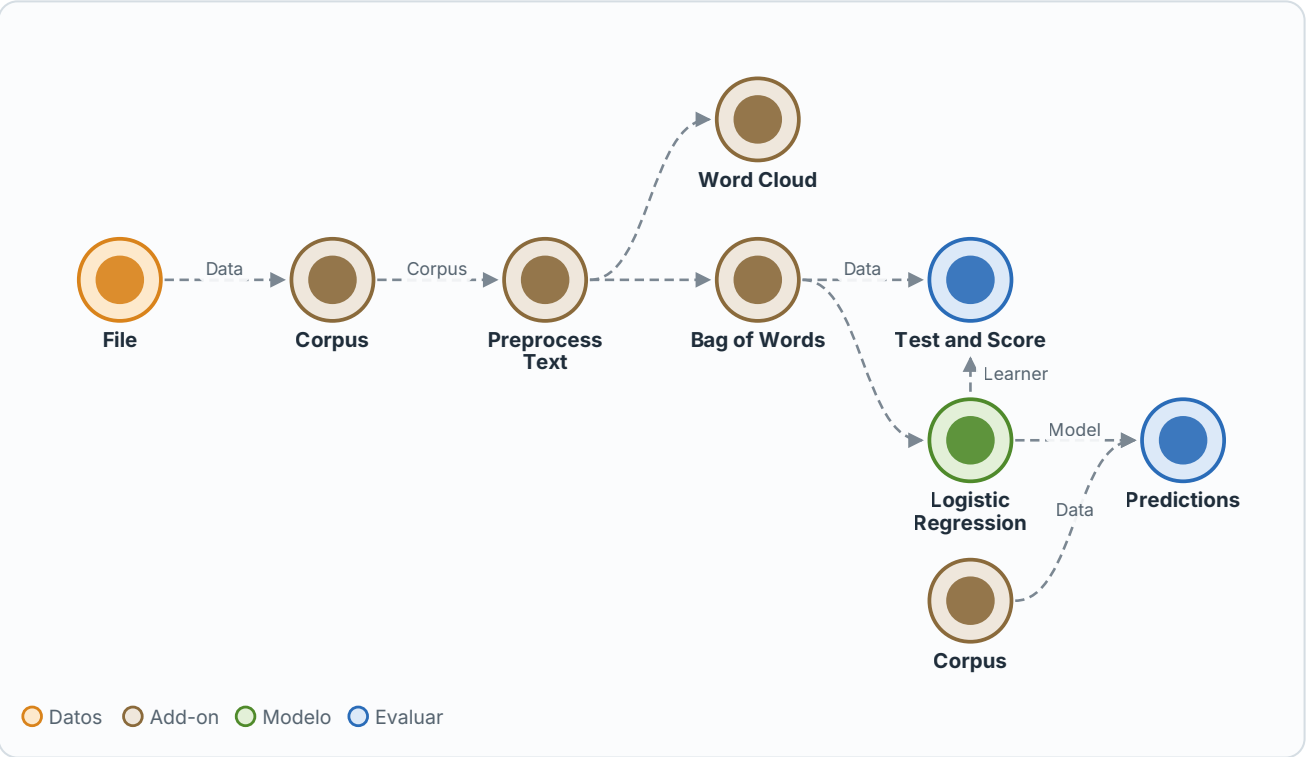
Columnas de `andersen_si` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Naslov`	texto	Título del cuento, en esloveno (meta).	Cesarjeva nova oblačila (1), Deklica z vžigalicami (1), Grdi raček (1)
`Vsebina`	texto	Texto del cuento, en esloveno (meta).	texto libre (mediana de 1.167 palabras)

5 Particularidades técnicas al modelar

- **Corpus muy pequeño**: 41 documentos y miles de palabras distintas. Usa *Leave one out* en *Test and Score* y modelos simples (*Logistic Regression*, *Naive Bayes*).
- **Esloveno**: en *Preprocess Text*, palabras vacías y lematizador (UDPipe) para el esloveno; sin lematizar, *volk*, *volka* y *volku* (lobo) son palabras distintas.
- **Traducción automática**: el estilo de los cuentos de Grimm y de los eslovenos es distinto, y un modelo puede aprender el origen además del tipo.
- **Letras con carón**: en el fichero de Orange, `magične` y `živalske` llevan el carón como carácter aparte (Unicode descompuesto), así que no coinciden con las mismas palabras escritas con el teclado. En este CSV y en el XLSX están normalizadas (NFC).
- **Andersen**: los tres cuentos deben acabar con las mismas columnas que los de entrenamiento. Conecta su *Corpus* a *Predictions* junto con el modelo; si Orange avisa de que faltan atributos, pásalos antes por el mismo *Preprocess Text* y *Bag of Words*.

6 Flujo de trabajo en Orange



1. **File** con `grimm_si.csv`, `Kategorija` como *target* → **Corpus** con `Vsebina` como texto.
2. **Preprocess Text** (esloveno) → **Word Cloud**: *lisica* (zorra) y *volk* (lobo) frente a *kralj* (rey) y *čarovnica* (bruja).
3. **Bag of Words** → **Test and Score** con **Logistic Regression** y *Leave one out*.
4. **Corpus** con `andersen_si.csv`, preprocesado igual → **Predictions** con el modelo: ¿de magia o de animales?

7 Otras consideraciones

- Es un ejemplo pensado para clase: el resultado de Andersen se discute (*El patito feo* tiene animales, pero no es una fábula).
- Si se prefiere trabajar en inglés, Orange tiene un ejemplo equivalente con cuentos de Grimm en inglés.

En la carpeta	`grimm_si` ← `GrimmSI.tab` (datasets.biolab.si)
En la carpeta	`andersen_si` ← `AndersenSI.tab` (datasets.biolab.si)

10.06
Minería de textos

Words y words-food

`10_mineria_textos/words/`

Dos listas de palabras sueltas en inglés: 150 palabras variadas y 108 alimentos (frutas, verduras y lácteos). Para ver cómo los embeddings de palabras agrupan por significado.

Minería de textos | Clasificación multiclase | ✎ Sintético | ¶ Texto

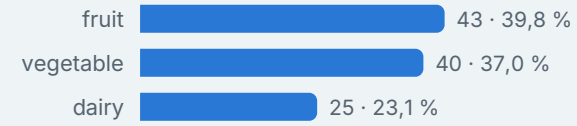
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
150	**1**	`— / category`	**0,0 %**	**Iniciación**	**Text**

Fichero	Filas × col.	Descargar
`words`	150 × 1	CSV 1 KB · XLSX
`words_food`	108 × 2	CSV 2 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/10_mineria_textos/words/` seguido del nombre del fichero CSV.

Radiografía

category en words_food



1 Descripción general y estudios habituales

No son documentos sino palabras sueltas. `words` tiene 150 palabras corrientes en inglés (*Apple*, *Arrow*, *Banana*…), ordenadas alfabéticamente, unas seis por letra. `words_food` tiene 108 nombres de alimentos con su tipo: 43 frutas, 40 verduras y 25 lácteos.

Estudios habituales: **embeddings de palabras** (*Document Embedding*) y **agrupamiento jerárquico** para ver que las palabras se agrupan por significado (animales, instrumentos, comida…); **proyecciones** (t-SNE) y, con `words_food`, **clasificar** alimentos o comprobar si los grupos coinciden con el tipo.

2 Contexto y fuente original

Son ficheros de ejemplo del laboratorio de Orange (Universidad de Liubliana). Según su ficha, `words` lo generó ChatGPT como lista de palabras aleatorias en orden alfabético; `words_food` son palabras para frutas, verduras y lácteos. Sirven para explicar los *embeddings* con ejemplos que todo el mundo entiende.

- Orange Data Mining. words.xlsx (palabras generadas con ChatGPT) y words-food.xlsx (datasets.biolab.si).

3 Variable objetivo

`words` no tiene objetivo: es para explorar y agrupar. En `words_food`, `category` es el tipo de alimento: `fruit` (43), `vegetable` (40) y `dairy` (25). Algunas asignaciones se pueden discutir: el aguacate es fruta, el tomate verdura, y el jengibre y el ajo son verduras.

4 Diccionario de columnas

Columnas de `words` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`words`	texto	Palabra en inglés, con mayúscula inicial (meta).	Apple (1), Arrow (1), Banana (1), Bat (1), Bed (1), Blanket (1) …

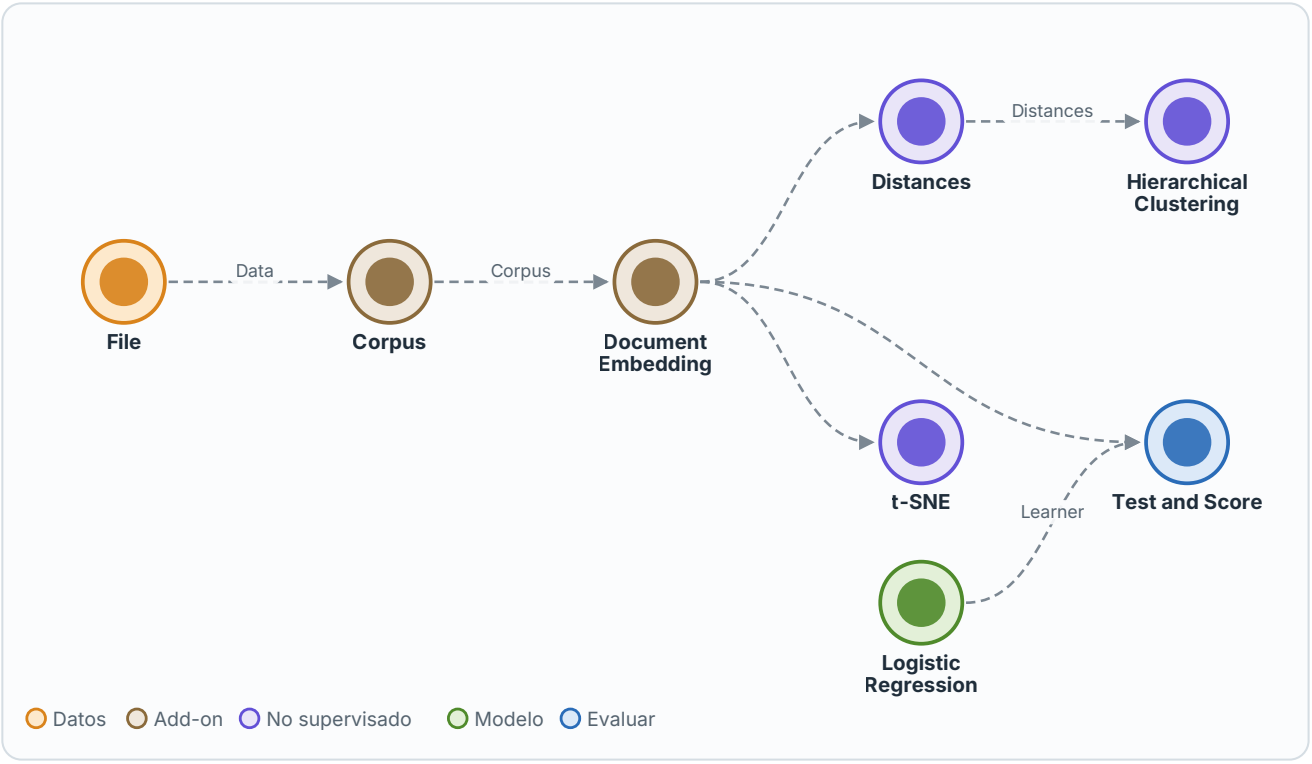
Columnas de `words_food` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`food`	texto	Nombre del alimento en inglés, en minúscula (meta).	grapefruit (1), cauliflower (1), green bean (1), gorgonzola (1), plum (1), munster (1) …
`category` `objetivo`	categórica	Tipo: `fruit`, `vegetable` o `dairy`. Objetivo.	fruit (43), vegetable (40), dairy (25)

5 Particularidades técnicas al modelar

- **Hace falta un *embedding***: con bolsa de palabras cada palabra es un documento de una sola palabra y no hay nada que comparar. *Document Embedding* (por ejemplo, *fastText* o SBERT del servidor de Orange) da un vector por palabra.
- **Requiere conexión**: los *embeddings* de Orange se calculan en un servidor externo.
- **Palabras ambiguas en `words`**: *Bat* (murciélago o bate), *Mouse* (ratón animal o del ordenador), *Orange* (fruta o color), *Yellow* (un color entre objetos). Salen en grupos inesperados y son buen tema de discusión.
- **Orden alfabético imperfecto**: *Earplugs* va antes que *Eagle* y *Handle* antes que *Hammer*, restos de la generación automática.
- **Palabras compuestas** en `words_food` (*sour cream*, *brussels sprouts*): el *embedding* trata la frase entera.

6 Flujo de trabajo en Orange



1. **File** con `words_food.csv` (o `words.csv`) → **Corpus** con la palabra como texto.
2. **Document Embedding** → **Distances** (coseno) → **Hierarchical Clustering**: frutas, verduras y lácteos salen en ramas distintas, con excepciones.
3. **t-SNE** coloreado por `category`.
4. Con `words_food`, **Test and Score** con **Logistic Regression** sobre los vectores del *embedding*.

7 Otras consideraciones

- Es un ejemplo para explicar qué es un *embedding*, no un problema real de clasificación.
- Las dos listas comparten palabras (*Apple*, *Banana*, *Lemon*, *Onion*, *Zucchini*...): se pueden unir para ver dónde cae la comida dentro de la lista general.

En la carpeta	`words` ← `words.xlsx` (datasets.biolab.si)
En la carpeta	`words_food` ← `words-food.xlsx` (datasets.biolab.si)

11 Análisis de imágenes

13 datasets en el capítulo; en esta edición, 13 con ficha.

11.01
Análisis de imágenes

Ánforas romanas

`11_imagenes/amphorae/`

164 dibujos de ánforas romanas de tres familias (Dressel, Gauloise y Keay) con su descripción morfológica: clasificar o agrupar por la forma de la imagen, por los rasgos descritos o por ambos.

Clasificación multiclase | Clustering | ? Valores faltantes | ▣ Imágenes | ◇ Solo categóricos

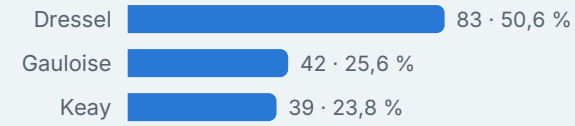
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
164	**16**	`Type`	**6,6 %**	**Intermedio**	**Image Analytics**

Fichero	Filas × col.	Descargar
`amphorae`	164 × 16	CSV 30 KB · XLSX
`amphorae_imagenes.zip`	164 imágenes	ZIP 27,2 MB

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/11_imagenes/amphorae/` seguido del nombre del fichero CSV.

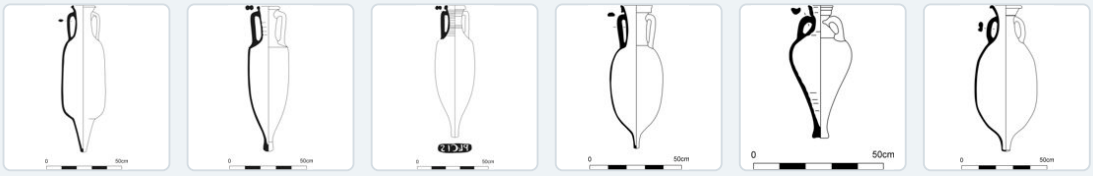
Radiografía

Type en amphorae

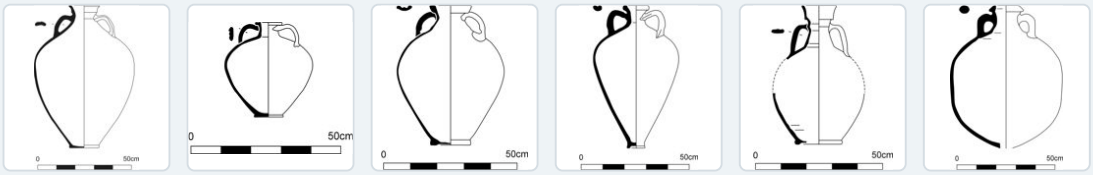


Algunos dibujos de cada familia (número total entre paréntesis)

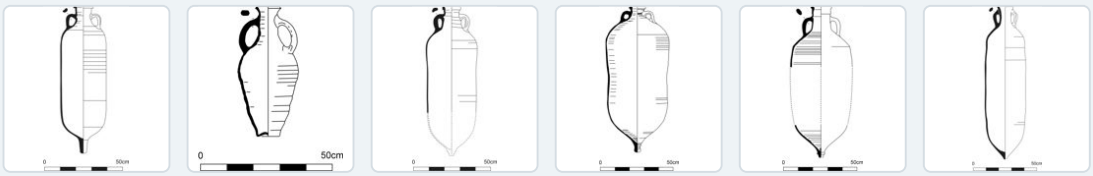
Dressel (83)



Gauloise (42)



Keay (39)



1 Descripción general y estudios habituales

Cada fila es un dibujo técnico de un ánfora (perfil y sección, con escala de 50 cm), con la familia (`Type`), el subtipo (`Subtype`, 72 distintos) y la descripción de su forma: borde, hombro, asas, cuello, cuerpo, base, pasta (`Fabric`), capacidad y medidas. Hay 83 Dressel, 42 Gauloise y 39 Keay.

Es un caso poco habitual de datos mixtos: se puede clasificar con la imagen, con los atributos descritos por los arqueólogos, o con los dos. Los estudios habituales son:

- **Clasificar la familia** a partir de los *embeddings* de los dibujos.
- **Comparar** la clasificación por imagen con la clasificación por atributos categóricos (árbol de decisión).
- **Agrupar** los dibujos y ver si los grupos coinciden con familias o subtipos.

2 Contexto y fuente original

Los dibujos y la descripción proceden de *Roman Amphorae: a digital resource* (Universidad de Southampton, 2005, actualizado en 2014), distribuido por el Archaeology Data Service, con fichas de cada tipo de ánfora, su bibliografía y sus imágenes. Orange se quedó con las tres familias mejor documentadas: las Dressel (clasificación de Heinrich Dressel, siglo XIX), las Gauloise (ánforas de la Galia) y las Keay (ánforas tardorromanas, tipología de Simon Keay, 1984).

- University of Southampton (2014). Roman Amphorae: a digital resource [data-set]. York: Archaeology Data Service. doi:10.5284/1028192

3 Variable objetivo

`Type`: `Dressel` (83), `Gauloise` (42) y `Keay` (39). `Subtype` (p. ej. `Dressel 14`, `Gauloise 12`, `Keay 62A`, `D&E`) es una clasificación más fina, con 72 valores y de 1 a 9 ánforas por subtipo.

La forma ayuda: los dibujos de las Gauloise, más bajas y panzudas, tienen una altura mediana de 1.618 píxeles (casi todos los dibujos miden 1.299 de ancho), frente a 2.360 en las Dressel y 2.747 en las Keay, más alargadas.

4 Diccionario de columnas

Columnas de `amphorae` (valores observados en el fichero)

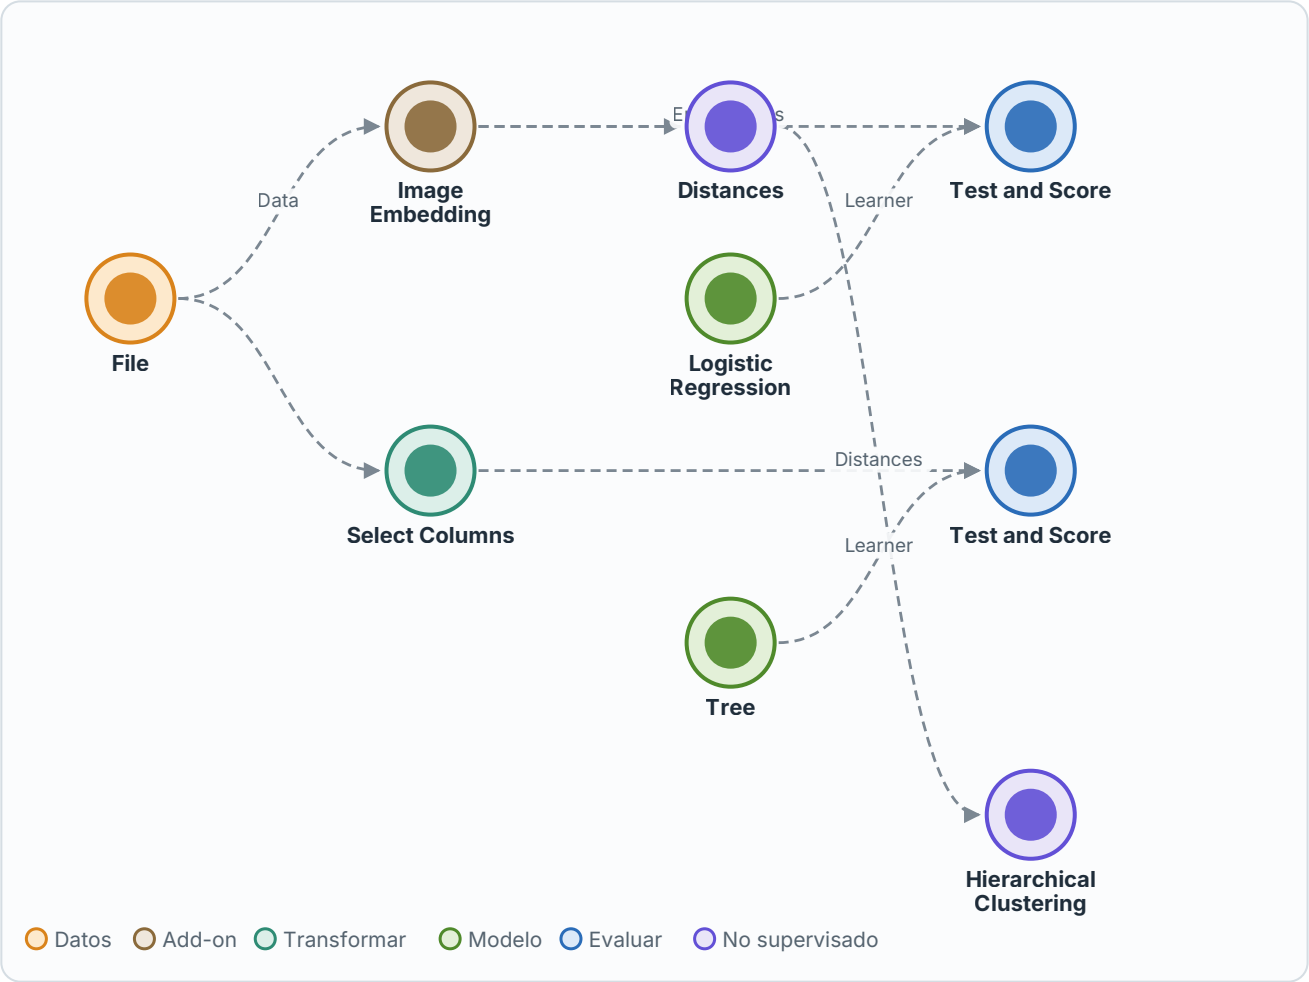
Columna	Tipo	Significado	Valores
`Fabric`	categórica	Pasta (arcilla) del ánfora: `gauloise`, `dressel`, `tunisian`, `cadiz`, `lyon`… 8 vacíos. **Casi delata la familia** (todas las `gauloise` son Gauloise; 34 de 35 `tunisian` son Keay).	gauloise (41), dressel (36), tunisian (35), lyon (11), cadiz (11), keay (8) …
`Rim diameter`	categórica	Diámetro del borde en cm, como intervalo de texto (`16-22`). 11 vacíos.	13-14 (13), 18-22 (11), 12-13 (10), 7-18 (9), 11-12 (8), 14-16 (8) …
`Rim type`	categórica	Tipo de borde: `everted`, `rounded`, `beaded`, `collar`, `flaring`…	everted (54), rounded (28), beaded (27), collar (26), flaring (19), triangular (4) …
`Shoulder type`	categórica	Tipo de hombro: `rounded`, `carinated` o `none/smooth`.	rounded (105), carinated (31), none/smooth (28)
`Handles in profile`	categórica	Forma de las asas de perfil: `curved`, `long vertical`, `ear-shaped`, `arched`, `peaked`…	curved (45), long vertical (43), ear-shaped (18), arched (15), peaked (14), ring (12) …
`Handles in section`	categórica	Sección de las asas: `ovoid/elliptical`, `grooved`, `bifid`, `round`, `ridged`…	ovoid/elliptical (69), grooved (46), bifid (24), round (11), ridged (10), semi-circular (4)
`Neck type`	categórica	Tipo de cuello: `cylindrical`, `hourglass`, `short/narrow`, `conical` o `broad/wide`.	cylindrical (64), hourglass (36), short/narrow (30), conical (21), broad/wide (12)
`Body type`	categórica	Tipo de cuerpo: `cylindrical`, `globular`, `tapered`, `ovoid` o `piriform`.	cylindrical (74), globular (36), tapered (21), ovoid (17), piriform (16)
`Base type`	categórica	Tipo de base: `spike/tapered`, `ringed`, `long hollow`, `knobbed`, `flat`…	spike/tapered (54), ringed (27), long hollow (20), knobbed (19), flat (15), rounded (11) …
`Capacity (avg l)`	categórica	Capacidad media en litros, como intervalo (`30-35`). 93 vacíos.	25-30 (10), 35-40 (9), 30-35 (8), 70-75 (8), 45-50 (7), 20-25 (7) …
`Type` `objetivo`	categórica	Familia: `Dressel`, `Gauloise` o `Keay`. Objetivo.	Dressel (83), Gauloise (42), Keay (39)
URL	texto	Dirección del dibujo en el servidor de Biolab. Incluye la familia en la ruta.	URL (164 distintas), p. ej. file.biolab.si/…/Dressel/DR101.jpg

Columna	Tipo	Significado	Valores
`Name`	texto	Nombre del fichero del dibujo (`DR101` …): empieza por `DR` en las tres familias.	DR101 (1), DR104 (1), DR105 (1), DR106 (1), DR109 (1), DR110 (1) …
`Subtype`	texto	Subtipo (72 valores), p. ej. `Dressel 14`. Determina la familia.	Gauloise 12 (9), Dressel 14 (7), Dressel 9&10 similis (6), Dressel 12 (5), Dressel 8 (5), Gauloise 4 (5) …
`Height (cm)`	texto	Altura en cm, como intervalo de texto. 23 vacíos.	24-50 (9), 90-110 (7), 85-87 (6), 103-105 (5), 80-90 (5), 60-69 (5) …
`Width (cm)`	texto	Anchura en cm, como intervalo de texto. 35 vacíos.	27-33 (7), 25-30 (7), 28-31 (7), 37-39 (6), 36-42 (5), 35-40 (5) …

5 Particularidades técnicas al modelar

- **La descripción es del subtipo, no de cada ánfora**: los 164 dibujos tienen solo 72 combinaciones distintas de atributos, una por subtipo. Con los atributos, una validación cruzada normal mete ánforas del mismo subtipo en entrenamiento y prueba, y el acierto sale inflado. Valida dejando fuera subtipos enteros, o usa solo la imagen.
- **Fugas**: `Subtype` y la ruta de `URL` contienen la familia, y `Fabric` casi también. Quítalos para clasificar.
- **Medidas como texto**: altura, anchura, diámetro y capacidad son intervalos (`90-110`); para usarlas como números, calcula el punto medio con *Feature Constructor* o en una hoja de cálculo.
- **Imágenes grandes y en escala de grises** (casi todas de 1.299 píxeles de ancho y hasta 3.342 de alto): *Image Embedding* las reduce, pero tarda más que con imágenes pequeñas. La regla de 50 cm aparece en todos los dibujos y no aporta nada.
- **Cargar las imágenes**: con *File* sobre el CSV (columna `URL`) o con *Import Images* sobre el ZIP, que tiene una subcarpeta por familia.

6 Flujo de trabajo en Orange



1. **File** con `amphorae.csv`, `Type` como *target*.
2. **Image Embedding** con la columna `URL` → **Test and Score** con **Logistic Regression**: clasificación solo por la imagen.
3. **Select Columns** sin `Subtype`, `Fabric`, `URL` ni `Name` → **Test and Score** con **Tree**: clasificación por los rasgos descritos. Compara con el paso 2 y piensa en la nota sobre los subtipos.
4. **Distances** (coseno) → **Hierarchical Clustering** → **Image Viewer**: ¿agrupa por familia o por silueta?

7 Otras consideraciones

- **Para arqueología**: el ADS tiene fichas mucho más completas (fotos, distribución, cronología, bibliografía) de cada tipo; esta selección es didáctica.
- **Nombres de pasta**: `dressel`, `gauloise` o `keay` como nombre de pasta indican la pasta típica de esa familia, no una medida independiente.

En la carpeta `amphorae` ← `amphorae.tab` (datasets.biolab.si)

11.02
Análisis de imágenes

Bone healing (consolidación de fracturas)

`11_imagenes/bone_healing/`

37 imágenes de microscopio de fracturas óseas en ratones, tomadas 7 o 14 días después de la lesión: clasificar el momento de la curación a partir de la imagen.

Clasificación binaria | Clustering | ? Valores faltantes | ▣ Imágenes | ◦ Juguete

> **En el curso:** Tema 4 (imágenes): citado en las diapositivas como «Bone breaks», entre los datasets para variar o ampliar las actividades.

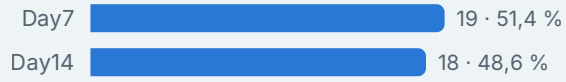
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
37	**9**	`Healing`	**0,9 %**	**Intermedio**	**Image Analytics**

Fichero	Filas × col.	Descargar
`bone_healing`	37 × 9	CSV 5 KB · XLSX
`bone_healing_imagenes.zip`	37 imágenes	ZIP 1,6 MB

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/11_imagenes/bone_healing/` seguido del nombre del fichero CSV.

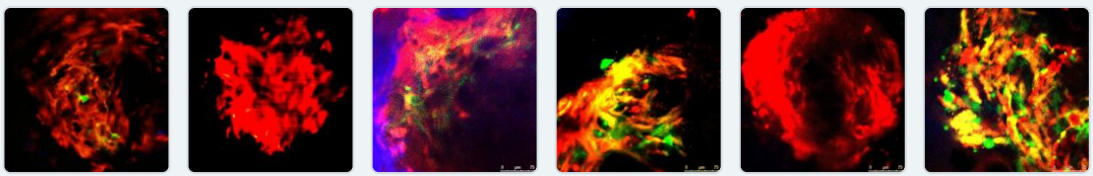
Radiografía

Healing en bone_healing



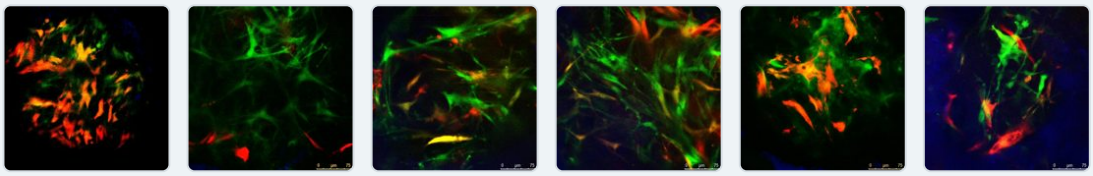
Seis imágenes de cada día (número total entre paréntesis)

D14 (18)



D14-0401-11-L1-inj | D14-0906-13-L1-Inj | D14-7_z33-m1 | D14-I 4-10_z43 | D14-Left injury 1_ | D14-Right injury 1

D7 (19)



D7-0503-12-2-b... | D7-I 2-4_z32 | D7-I 3-8_z041 | D7-I 4-5_z032 | D7-Injury left up | D7-Series018_z0...

1 Descripción general y estudios habituales

Cada fila es una imagen de microscopio de la zona de una fractura en un ratón de laboratorio, tomada 7 o 14 días después de la lesión. Los ratones son de líneas modificadas con marcadores fluorescentes (rojo y verde) que señalan las células madre del esqueleto y su descendencia, así que la imagen muestra cómo participan esas células en la reparación del hueso. Además de la imagen, la tabla trae la línea del ratón, su identificador, sexo, edad y fechas.

Es un ejemplo pequeño y real de **análisis de imágenes biomédicas** con embeddings. Los estudios habituales son:

- **Clasificar** el momento de la curación (día 7 o día 14) a partir de la imagen.
- **Agrupar** las imágenes por similitud y comprobar si los grupos coinciden con los días.
- **Comparar embedders**: los generalistas (SqueezeNet, Inception v3) frente a los de microscopía (DeepLoc).

2 Contexto y fuente original

Las imágenes son del laboratorio de **Dongsu Park** (Baylor College of Medicine, Houston). Se usaron en el artículo que presentó el add-on de imágenes de Orange: Godec et al. (2019), *Democratized image analytics by visual programming through integration of deep models and small-scale machine learning* (*Nature Communications*). Allí, el agrupamiento de los embeddings separaba bien las imágenes por días tras la lesión, y una regresión logística alcanzaba un F1 de 0,95.

Las líneas de ratón combinan el marcador Mx1/Tomato (rojo) con otro verde (αSMA-GFP, Nestin-GFP u Osteocalcin-GFP). La tabla viene en el widget *Datasets* de Orange con la URL de cada imagen; en esta carpeta, las imágenes están también en `bone_healing_imagenes.zip`, en una subcarpeta por día (`D7`, `D14`).

- Godec, P. et al. (2019). Democratized image analytics by visual programming through integration of deep models and small-scale machine learning. Nature Communications, 10, 4551.

3 Variable objetivo

La variable objetivo es `Healing`: `Day7` (19 imágenes) o `Day14` (18), los días transcurridos desde la fractura. Las clases están equilibradas, así que decir siempre la misma acierta un 51 %.

Con tan pocas imágenes, cada error en validación cruzada pesa casi 3 puntos de exactitud.

4 Diccionario de columnas

Columnas de `bone_healing` (valores observados en el fichero)

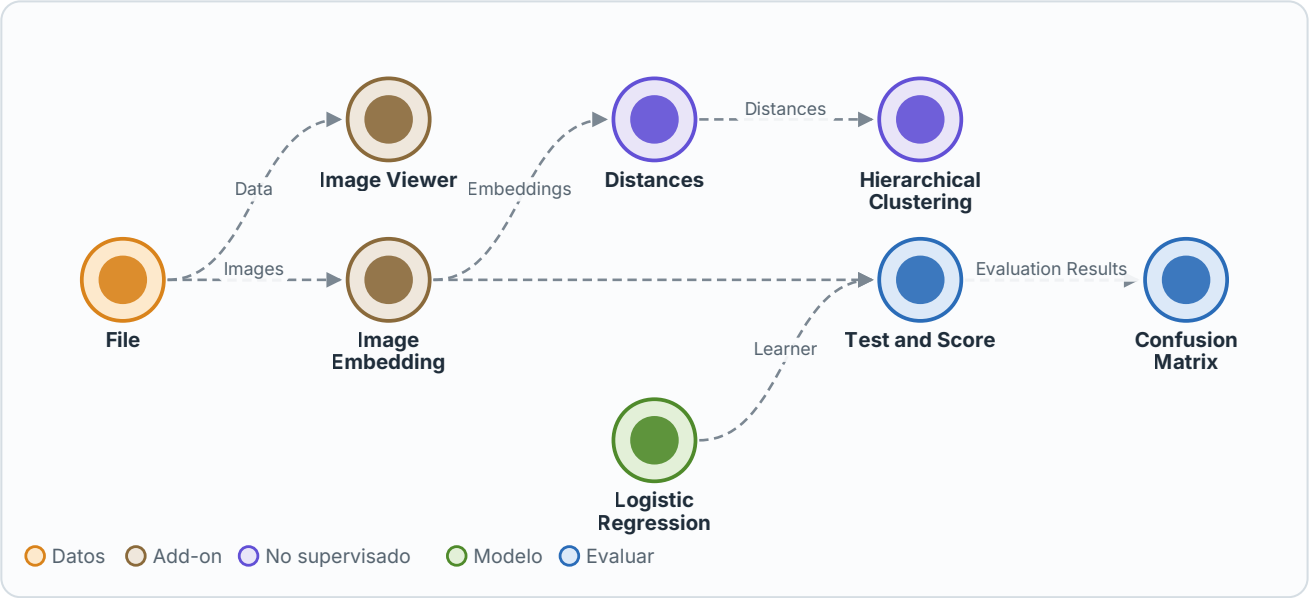
Columna	Tipo	Significado	Valores
`Healing` `objetivo`	categórica	Días desde la lesión: `Day7` o `Day14`. Es la variable objetivo.	Day7 (19), Day14 (18)
`Image Name`	texto	Nombre de la imagen en el experimento.	I 2-2_z27 (1), I 2-4_z32 (1), I 3-3_z042 (1), I 3-5_z29 (1), I 3-8_z041 (1), I 4-2_z027 (1) …
`Image`	texto	URL completa de la imagen. Dentro del ZIP, la misma imagen está en `bone_healing/D7/` o `bone_healing/D14/`.	URL (37 distintas), p. ej. file.biolab.si/…/D7/D7-I%202-2_z27.jpg

Columna	Tipo	Significado	Valores
`Strain`	texto	Línea del ratón: combinación de marcadores fluorescentes (`Mx1/Tom/Sma-Gfp`, `Mx1/Tom/Nestin-GFP`…). `Nes-GFP` y `Nestin-GFP` parecen el mismo marcador escrito de dos formas.	Mx1/Tom/Sma-Gfp (28), Mx1/Tom/Nestin-GFP (5), Mx1/Tom/Nes-GFP (2), Mx1/Tom/Ocn-GFP (1), Mx1/Tom (1)
`Mouse`	texto	Identificador del ratón. Hay 15 ratones distintos para 37 imágenes.	0920 IM0049 (13), 0898 (4), 701 (4), 335 IM0007 (2), 2501 (2), 2253 (2) …
`Gender`	categórica	Sexo del ratón: `Male` o `Female` (falta en una imagen).	Male (21), Female (15)
`Age`	numérica	Edad del ratón; la fuente no indica la unidad (por los valores, de 101 a 308, probablemente días).	101 – 308
`DOB`	texto	Fecha de nacimiento como código `MMDD-AA` (por ejemplo, `1023-15` es el 23 de octubre de 2015).	1023-15 (13), 1020-15 (4), 1120-10 (4), 0509-15 (2), 0128-15 (2), 0124-12 (2) …
`Image Date`	texto	Fecha de la imagen, con el mismo código `MMDD-AA`.	0413-16 (9), 0616-16 (4), 0420-16 (4), 0401-11 (4), 1212-16 (3), 1103-15 (2) …

5 Particularidades técnicas al modelar

- **Fuga de información por la línea del ratón**: algunas líneas aparecen solo en un día (`Nestin-GFP` solo en el día 14, `Nes-GFP` solo en el día 7). Si `Strain`, `Mouse` o las fechas entran en el modelo, la clase se adivina sin mirar la imagen. Para un estudio de imagen, deja solo los embeddings (las demás columnas como *meta*).
- **Varias imágenes por ratón**: hay 37 imágenes de 15 ratones (uno solo aporta 13). En validación cruzada, imágenes del mismo ratón caen en entrenamiento y en prueba, y el modelo puede reconocer al ratón en vez de la fase de curación. El resultado es optimista; lo correcto sería separar por ratón.
- **Fechas mal leídas**: Orange interpreta `DOB` e `Image Date` (códigos `MMDD-AA`) como fechas y las convierte mal. En *File*, cámbialas a texto.
- **Elige bien el embedder**: los modelos generalistas se entrenaron con fotos cotidianas. *DeepLoc* está pensado para microscopía celular y conviene compararlo.
- Las imágenes son de 500 × 500 píxeles en JPEG.

6 Flujo de trabajo en Orange



1. **File** (URL del CSV o **Datasets** → «Bone Healing»): `Healing` como *target*; `Strain`, `Mouse`, `Gender`, `Age` y las fechas como *meta*.
2. **Image Viewer**: compara a ojo imágenes de los dos días.
3. **Image Embedding**: prueba *SqueezeNet*, *Inception v3* y *DeepLoc*.
4. **Distances** (coseno) → **Hierarchical Clustering**: ¿separan los dos grupos principales los días?
5. **Logistic Regression** + **Test and Score** sobre los embeddings; **Confusion Matrix** para ver qué imágenes fallan.

7 Otras consideraciones

- **Es un dataset de investigación real**: viene de un artículo publicado, lo que permite comparar los resultados propios con los del artículo.
- **Discusión metodológica**: con 37 imágenes de 15 ratones, ¿cuántos datos hacen falta para una conclusión fiable? Es un buen caso para hablar de validación por grupos (por ratón) y de tamaño muestral.
- El mismo flujo de *Traffic Signs* sirve aquí cambiando solo la entrada.

En la carpeta `bone_healing` ← `bone-healing.xlsx` (datasets.biolab.si)

11.03
Análisis de imágenes

Dictyostelium: desarrollo

`11_imagenes/dicty_development/`

152 fotos de placas con la ameba social Dictyostelium en desarrollo (36 cepas mutantes, de 8 a 36 horas): clasificar la fase de agregación a partir de la imagen.

Clasificación multiclase · Clustering · ? Valores faltantes · ▣ Imágenes · ◷ Temporal

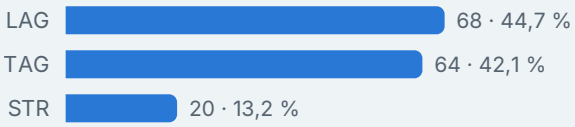
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
152	**7**	`Stage`	**2,4 %**	**Intermedio**	**Image Analytics**

Fichero	Filas × col.	Descargar
`dicty_development`	152 × 7	CSV 15 KB · XLSX
`dicty_development_imagenes.zip`	152 imágenes	ZIP 2,4 MB

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/11_imagenes/dicty_development/` seguido del nombre del fichero CSV.

Radiografía

Stage en dicty_development



Algunas placas de cada fase (número total entre paréntesis)

LAG (68)



10_08hr 15_12hr 1_12hr 26_12hr 30_10hr 3_12hr

STR (20)



11_10hr 16_08hr 18_08hr 20_10hr 26_10hr 30_08hr

TAG (64)



10_16hr 15_16hr 1_20hr 25_36hr 30_12hr 3_24hr

1 Descripción general y estudios habituales

Dictyostelium discoideum es una ameba que vive aislada mientras tiene comida y, cuando le falta, se agrega con otras para formar un organismo multicelular que acaba en un cuerpo fructífero. Cada fila es una foto de una placa con cientos de agregados, de una cepa (`Strain`) a una hora concreta (`Time` , de 8 a 36 horas), con la fase principal que se ve (`Stage`) y, a veces, una fase secundaria.

Los estudios habituales son **clasificar la fase** con *embeddings* de imágenes, **agrupar** las fotos por parecido y **seguir el desarrollo** de una misma cepa en el tiempo.

2 Contexto y fuente original

Las imágenes son del laboratorio de Gad Shaulsky (Baylor College of Medicine, Houston), que colabora con el de Blaž Zupan (Universidad de Liubliana), creadores de Orange. Las cepas `NTG#1` a `NTG#36` son mutantes obtenidos con el mutágeno químico NTG (nitrosoguanidina), del trabajo de Li et al. (2016) sobre descubrimiento de genes por mutagénesis química y secuenciación del genoma.

- Li, C.-L. F., Santhanam, B., Webb, A. N., Zupan, B. y Shaulsky, G. (2016). Gene discovery by chemical mutagenesis and whole-genome sequencing in Dictyostelium. Genome Research, 26(9), 1268–1276.

3 Variable objetivo

`Stage` es la fase principal de la placa: `LAG` (agregados sueltos, *loose aggregates*, 68), `TAG` (agregados compactos, *tight aggregates*, 64) y `STR` (corrientes de células, *streams*, 20). En el desarrollo normal, el orden es STR → LAG → TAG.

La hora predice mucho: a las 8 horas no hay ninguna placa en `TAG` y desde las 16 horas casi todas lo están (46 de 57). Las cepas mutantes no siguen todas el mismo ritmo, y eso es lo que hace interesante la imagen.

4 Diccionario de columnas

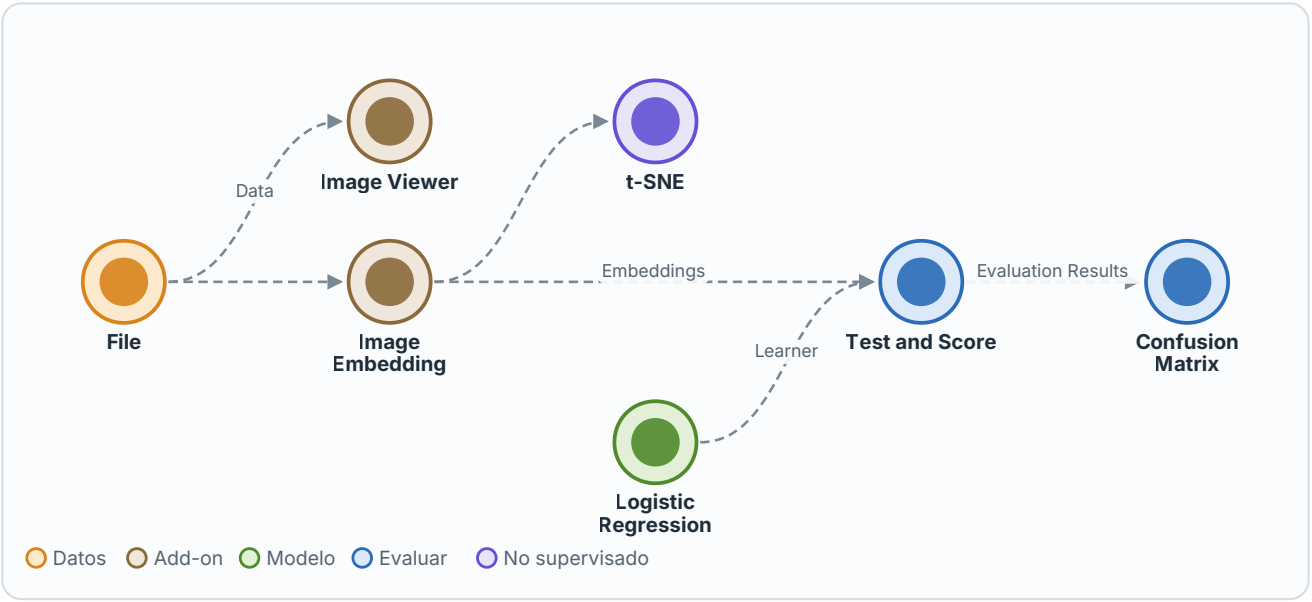
Columnas de `dicty_development` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Stage` objetivo	categórica	Fase principal: `STR`, `LAG` o `TAG`. Objetivo.	LAG (68), TAG (64), STR (20)
`Strain`	texto	Cepa mutante, de `NTG#1` a `NTG#36` (de 1 a 7 fotos por cepa).	NTG#3 (7), NTG#10 (7), NTG#8 (7), NTG#6 (7), NTG#19 (7), NTG#25 (7) …
`Time`	numérica	Horas desde el inicio del desarrollo: 8, 10, 12, 16, 20, 24 o 36.	8 – 36
`id`	texto	Identificador de la foto: número de cepa y hora (`1_10hr`).	1_10hr (1), 1_12hr (1), 1_16hr (1), 1_20hr (1), 1_24hr (1), 1_36hr (1) …
`Secondary Stage`	texto	Fase secundaria visible en la placa, a veces combinada (`TAG-STR`, `LAG-TIM`): incluye fases posteriores como `TIM`, `FNG`, `ECU`, `FB`. Vacía en 25.	STR (51), LAG (38), TIM (15), TAG (4), TAG-STR (3), LAG-TIM (3) …
`strain/time`	texto	Cepa y hora juntas (`NTG#1/10hr`): repite `Strain` y `Time`.	NTG#1/10hr (1), NTG#1/12hr (1), NTG#1/16hr (1), NTG#1/20hr (1), NTG#1/24hr (1), NTG#1/36hr (1) …
`image`	texto	Dirección de la foto en el servidor de Biolab. Incluye la fase en la ruta.	URL (152 distintas), p. ej. file.biolab.si/…/STR/1_10hr.jpg

5 Particularidades técnicas al modelar

- **Varias fotos por cepa**: la misma cepa aparece a distintas horas, y sus placas se parecen (mismo fondo, misma densidad). En validación cruzada normal, fotos de la misma cepa caen en entrenamiento y prueba. Para medir cómo generaliza a cepas nuevas, valida dejando fuera cepas enteras.
- **El color del fondo depende de la cepa, no de la fase**: las placas de las cepas 29 y 36 son más anaranjadas que las demás. Un modelo puede aprender el fondo; con pocas cepas por fase, es un riesgo.
- **Fugas**: `Time` y `Secondary Stage` informan sobre la fase, y la ruta de `image` la contiene. Al abrir el CSV, Orange pone `Stage`, `Time` y `Secondary Stage` como atributos; marca `Stage` como *target* y deja las otras dos como *meta*.
- **Clases desequilibradas**: solo 20 placas en `STR`.
- **Imágenes iguales en tamaño** (312 × 231 píxeles), todas en color.

6 Flujo de trabajo en Orange



1. **File** con `dicty_development.csv`: `Stage` como *target*; `Time` y `Secondary Stage` como *meta*.
2. **Image Viewer** para ver las placas por fase.
3. **Image Embedding** → **t-SNE** coloreado por `Stage` y, después, por `Strain`: ¿se agrupan por fase o por cepa?
4. **Test and Score** con **Logistic Regression** → **Confusion Matrix**: mira si los errores se dan entre fases vecinas (STR–LAG y LAG–TAG), como cabría esperar.

7 Otras consideraciones

- **Ejemplo de biología del desarrollo**: sirve para explicar que las clases son fases de un proceso continuo y que las fronteras entre ellas son discutibles (de ahí la fase secundaria).
- **Para regresión**: se puede intentar predecir `Time` a partir de la imagen y ver qué cepas van adelantadas o retrasadas.

En la carpeta `dicty_development` ← `dicty-development.xlsx` (datasets.biolab.si)

11.04
Análisis de imágenes

Hojas del parque de Luxemburgo

`11_imagenes/luxembourg_leaves/`

79 fotos de hojas de otoño recogidas en un parque de Luxemburgo, de 8 árboles: agrupar sin etiquetas, clasificar con etiquetas y probar con una partición de entrenamiento y prueba ya hecha.

Clasificación multiclase · Clustering · Imágenes · Juguete

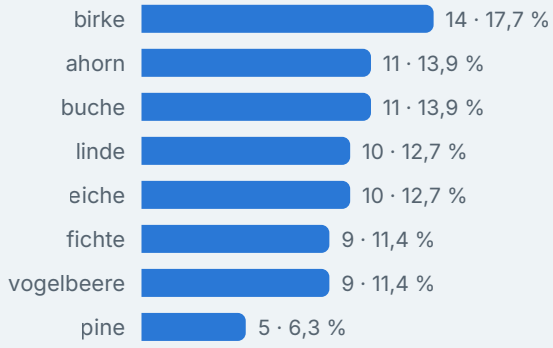
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
79	**2**	`category`	**0,0 %**	**Iniciación**	**Image Analytics**

Fichero	Filas × col.	Descargar
`luxembourg_leaves`	79 × 2	CSV 6 KB · XLSX
`luxembourg_leaves_classified`	79 × 3	CSV 7 KB · XLSX
`luxembourg_leaves_train`	40 × 3	CSV 3 KB · XLSX
`luxembourg_leaves_test`	39 × 3	CSV 3 KB · XLSX
`luxembourg_leaves_imagenes.zip`	79 imágenes	ZIP 18,6 MB

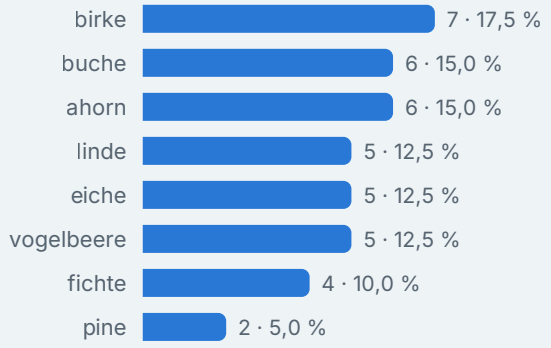
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/11_imagenes/luxembourg_leaves/` seguido del nombre del fichero CSV.

Radiografía

category en luxembourg_leaves_classified



category en luxembourg_leaves_train



Tres hojas de cada especie (número total entre paréntesis)

ahorn (11)


IMG_0924


IMG_0927


IMG_0930

birke (14)


IMG_1004


IMG_1008


IMG_1012

buche (11)


IMG_0938


IMG_0941


IMG_0944

eiche (10)


IMG_0956


IMG_0959


IMG_0962

fichte (9)


IMG_0973


IMG_0976


IMG_0979

linde (10)

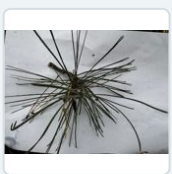

IMG_0911

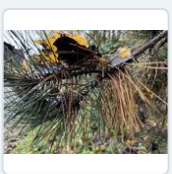

IMG_0914


IMG_0917

pine (5)


IMG_0997


IMG_0998


IMG_0999

vogelbeere (9)


IMG_0987


IMG_0990


IMG_0993

1 Descripción general y estudios habituales

Cada foto es una hoja (o una ramita, en los árboles de aguja) fotografiada casi siempre sobre papel blanco, de uno de ocho árboles. Hay cuatro ficheros con las mismas 79 fotos:

- `luxembourg_leaves`: solo el nombre y la dirección de cada foto, **sin la especie**, para agrupar.
- `luxembourg_leaves_classified`: las 79 con la especie (`category`).
- `luxembourg_leaves_train` (40) y `luxembourg_leaves_test` (39): una partición fija de la anterior, sin fotos repetidas entre las dos.

Los estudios habituales son **agrupar** las hojas por parecido y descubrir las especies, **clasificar** con *embeddings* y **predecir** la especie de hojas nuevas (las del conjunto de prueba o fotos propias).

2 Contexto y fuente original

Es un dataset educativo del laboratorio de Orange, de otoño de 2024. Las fichas de Orange no coinciden en el lugar: una habla de un parque del barrio de Kirchberg, en la ciudad de Luxemburgo, y otras de un parque cercano al centro. Las especies se nombran en alemán (`ahorn`, `birke`…), salvo `pine`, en inglés.

- Orange Data Mining. Luxembourg autumn leaves (datasets.biolab.si, 2024).

3 Variable objetivo

`category` (en los tres ficheros con especie) tiene ocho valores: `birke` (abedul, 14), `ahorn` (arce, 11), `buche` (haya, 11), `eiche` (roble, 10), `linde` (tilo, 10), `fichte` (pícea, 9), `vogelbeere` (serbal, 9) y `pine` (pino, 5).

En la partición, el entrenamiento tiene entre 2 y 7 hojas por especie, y la prueba entre 3 y 7.

4 Diccionario de columnas

Columnas de `luxembourg_leaves` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`image name`	texto	Nombre de la foto (`IMG_0977`).	IMG_0977 (1), IMG_0976 (1), IMG_0973 (1), IMG_0975 (1), IMG_0979 (1), IMG_0980 (1) …
`image`	texto	Dirección de la foto en el servidor de Biolab. **Incluye la especie en la ruta**, aunque el fichero sea «sin clasificar».	URL (79 distintas), p. ej. file.biolab.si/…/fichte/IMG_0977.jpeg

Columnas de `luxembourg_leaves_classified` (valores observados en el fichero)

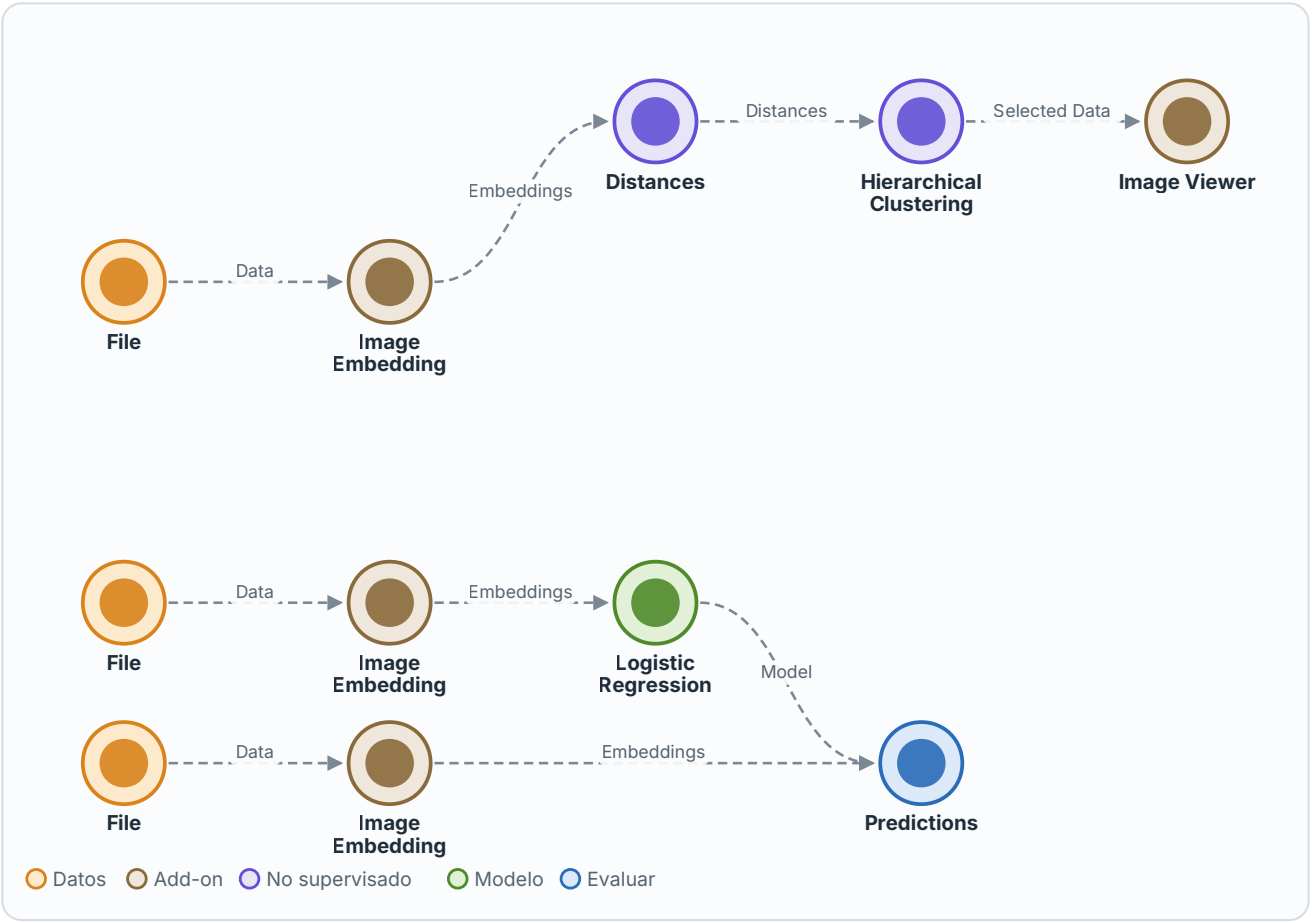
Columna	Tipo	Significado	Valores
`category` objetivo	categórica	Especie del árbol, en alemán salvo `pine`. Objetivo.	birke (14), ahorn (11), buche (11), linde (10), eiche (10), fichte (9) …

Columna	Tipo	Significado	Valores
`image name`	texto	Nombre de la foto.	IMG_0977 (1), IMG_0976 (1), IMG_0973 (1), IMG_0975 (1), IMG_0979 (1), IMG_0980 (1) …
`image`	texto	Dirección de la foto (con la especie en la ruta).	URL (79 distintas), p. ej. file.biolab.si/…/fichte/IMG_0977.jpeg

5 Particularidades técnicas al modelar

- **El fichero sin clasificar no es ciego**: la dirección de cada foto contiene la carpeta de la especie (`…/luxembourg-leaves/fichte/IMG_0977.jpeg`). Si se enseña agrupamiento, conviene no mostrar la columna `image` .
- **Pocas fotos por especie** (5 a 14): con la partición fija, una sola hoja mal clasificada cambia mucho el acierto. La validación cruzada o *Leave one out* sobre el fichero completo da una estimación más estable.
- **El fondo no es siempre igual**: las hojas grandes de arce y roble se salen del papel y se ve la hierba alrededor, y al menos dos de las cinco fotos de pino están hechas en el propio árbol, con fondo de bosque. El *embedding* puede aprender el fondo además de la hoja.
- **Color de otoño**: la misma especie aparece verde, amarilla o marrón; conviene que el modelo se fije en la forma más que en el color.
- **Fotos pequeñas** (320 × 240 píxeles, una en vertical): *Image Embedding* es rápido.
- **Nombres mezclados**: siete especies en alemán y `pine` en inglés. Para presentarlo en clase, se pueden traducir con *Edit Domain*.

6 Flujo de trabajo en Orange



1. **Sin etiquetas**: **File** con `luxembourg_leaves.csv` → **Image Embedding** → **Distances** (coseno) → **Hierarchical Clustering** → **Image Viewer**: ¿cuántos grupos salen y qué árbol es cada uno?
2. **Con etiquetas**: **File** con `luxembourg_leaves_train.csv` (`category` como *target*) → **Image Embedding** → **Logistic Regression**.
3. **File** con `luxembourg_leaves_test.csv` → **Image Embedding** → **Predictions** con el modelo: acierto por especie y hojas mal clasificadas.
4. Para fotos propias: **Import Images** sobre una carpeta con hojas fotografiadas igual (sobre papel blanco).

7 Otras consideraciones

- **Muy bueno para un taller práctico**: los alumnos pueden fotografiar sus propias hojas y comprobar si el modelo reconoce la especie.
- La pícea (`fichte`) y el pino (`pine`) son ramitas con agujas, no hojas planas: son las fotos más distintas del resto.

En la carpeta	`luxembourg_leaves` ← `luxembourg-leaves.xlsx` (datasets.biolab.si)
En la carpeta	`luxembourg_leaves_classified` ← `luxembourg-leaves-classified.xlsx` (datasets.biolab.si)
En la carpeta	`luxembourg_leaves_train` ← `luxembourg-leaves-train.tab` (datasets.biolab.si)
En la carpeta	`luxembourg_leaves_test` ← `luxembourg-leaves-test.tab` (datasets.biolab.si)

11.05
Análisis de imágenes

Competencia de ovocitos

`11_imagenes/oocyte_competence/`

131 imágenes de fluorescencia del núcleo de ovocitos de ratón, de dos tipos según cómo se dispone la cromatina: clasificación binaria de imágenes biomédicas con clases equilibradas.

Clasificación binaria · ▣ Imágenes

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
131	**3**	`Competence`	**0,0 %**	**Intermedio**	**Image Analytics**

Fichero	Filas × col.	Descargar
`oocyte_competence`	131 × 3	CSV 9 KB · XLSX
`oocyte_competence_imagenes.zip`	131 imágenes	ZIP 475 KB

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/11_imagenes/oocyte_competence/` seguido del nombre del fichero CSV.

Radiografía

Competence en oocyte_competence



Núcleos SN y NSN (número total entre paréntesis)

NSN (62)



SN (69)



1 Descripción general y estudios habituales

Cada imagen es el núcleo de un ovocito de ratón completamente crecido, teñido con un colorante fluorescente que marca el ADN (Hoechst 33342). Según cómo se dispone la cromatina, el ovocito es de uno de dos tipos: **SN** (69 imágenes) o **NSN** (62). Son imágenes en escala de grises de unos 265 × 265 píxeles.

Los estudios habituales son **clasificar** el tipo de ovocito con *embeddings*, **agrupar** las imágenes y ver si los dos tipos se separan solos, y **buscar** las imágenes dudosas.

2 Contexto y fuente original

Las imágenes son de la Universidad de Pavía (Italia), cuyo laboratorio de biología del desarrollo (Zuccotti, Garagna, Redi y colaboradores) estudia desde hace años estos dos tipos de ovocito. En los ovocitos SN (*surrounded nucleolus*), un anillo de cromatina rodea el nucléolo; en los NSN (*not surrounded nucleolus*), la cromatina está más dispersa. La diferencia importa porque, tras madurarlos y fecundarlos, solo los SN pueden desarrollarse a término, mientras que los NSN se detienen en el estadio de dos células: de ahí el nombre «competencia» del objetivo.

- Universidad de Pavía, repositorio IRIS (2016). Time-lapse imaging of chromatin and cytoplasmic movements occurring during the GV-to-MII transition: in search for markers of mouse oocytes developmental competence (M. Zuccotti, L. Fassina, V. Merico, S. Garagna et al.).
- Orange Data Mining. Mammalian Oocyte Developmental Competence (datasets.biolab.si, 2018).

3 Variable objetivo

`Competence`: `SN` (69), ovocitos con capacidad de desarrollo, y `NSN` (62), sin ella. Las clases están casi equilibradas, aunque en el ovario los SN son mayoría: la selección es del laboratorio, no una muestra natural.

4 Diccionario de columnas

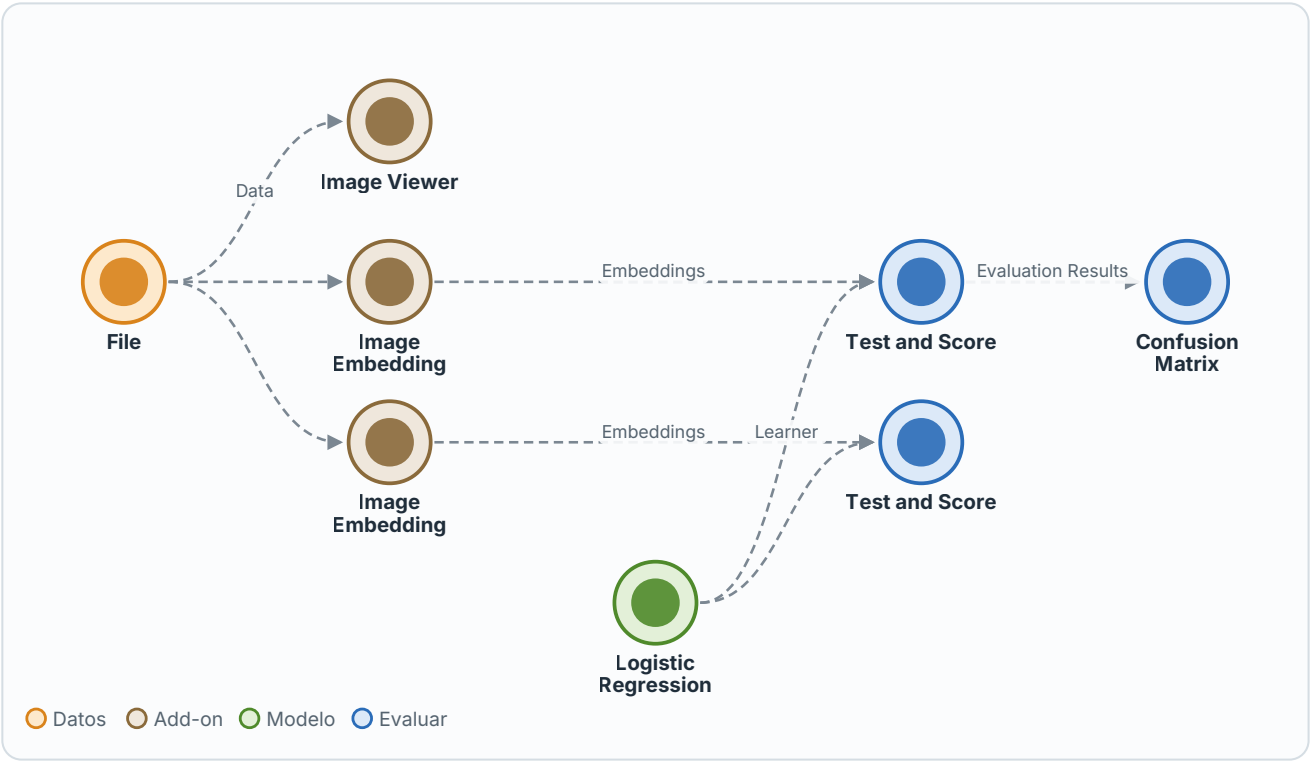
Columnas de `oocyte_competence` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Competence` `objetivo`	categórica	Tipo de ovocito: `SN` (cromatina en anillo alrededor del nucléolo) o `NSN` (cromatina dispersa). Objetivo.	SN (69), NSN (62)
`Image Name`	texto	Nombre de la imagen: **empieza por el tipo** (`NSN_37`, `SN_10`). Uno tiene un espacio de más (`SN _1`).	NSN_37 (1), NSN_23 (1), NSN_22 (1), NSN_36 (1), NSN_34 (1), NSN_21 (1) …
`Image`	texto	Dirección de la imagen en el servidor de Biolab (con el tipo en la ruta).	URL (131 distintas), p. ej. file.biolab.si/…/NSN/NSN_37.jpg

5 Particularidades técnicas al modelar

- **El nombre delata la clase**: `Image Name` y la ruta de `Image` empiezan por `SN` o `NSN`. No los uses como atributos (en *File* deben quedar como *meta*).
- **Diferencia sutil**: el anillo de cromatina se ve bien en unas imágenes y poco en otras; los *embeddings* de redes entrenadas con fotos cotidianas (*ImageNet*) no están pensados para esto. Compara varios (*Inception v3*, *SqueezeNet*, *Painters*, *DeepLoc*): *DeepLoc* se entrenó con imágenes de microscopía de levadura.
- **Imágenes en escala de grises** y casi del mismo tamaño (de 264 a 266 píxeles de lado).
- **Pocas imágenes**: 131 en total; usa validación cruzada.

6 Flujo de trabajo en Orange



1. **File** con `oocyte_competence.csv`, `Competence` como *target* y los nombres como *meta*.
2. **Image Viewer** para ver los dos tipos de núcleo.
3. **Image Embedding** con dos redes distintas (por ejemplo, *Inception v3* y *DeepLoc*).
4. **Test and Score** con **Logistic Regression** para cada *embedding*: ¿qué red describe mejor estas imágenes?
5. **Confusion Matrix** → **Image Viewer** con los errores: mira si son núcleos con el anillo poco marcado.

7 Otras consideraciones

- **Interés práctico**: clasificar los ovocitos sin manipularlos (solo con la imagen) ayudaría en reproducción asistida, aunque aquí la tinción fluorescente ya es una manipulación.
- Buen contraste con *Bone Healing* o *YPL+*: tres conjuntos de imágenes de microscopía con problemas distintos.

En la carpeta `oocyte_competence` ← `oocyte-competence.xlsx` (datasets.biolab.si)

11.06
Análisis de imágenes

Perros de razas tibetanas

`11_imagenes/tibetan_dogs/`

72 fotos de perros de cinco razas tibetanas y del pequinés (12 por raza): un conjunto pequeño y divertido para clasificar razas parecidas y probar con fotos propias.

Clasificación multiclase · Clustering · ▣ Imágenes · ◦ Juguete

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
72	**6**	`category`	**0,0 %**	**Iniciación**	**Image Analytics**

Fichero	Filas × col.	Descargar
`tibetan_dogs`	72 × 6	CSV 7 KB · XLSX
`tibetan_dogs_imagenes.zip`	72 imágenes	ZIP 580 KB

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/11_imagenes/tibetan_dogs/` seguido del nombre del fichero CSV.

Radiografía

category en tibetan_dogs



Cuatro fotos de cada raza (12 por raza)

lhasa_apso (12)


lhasa_apso-01


lhasa_apso-04

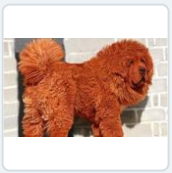

lhasa_apso-07


lhasa_apso-10

mastiff (12)


mastiff-01


mastiff-04


mastiff-07


mastiff-10

pekingese (12)


pekingese-01

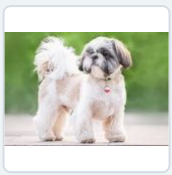

pekingese-04

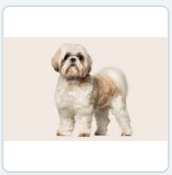

pekingese-07


pekingese-10

shih_tzu (12)

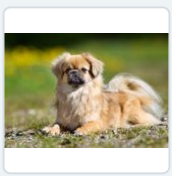

shih_tzu-01

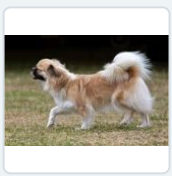

shih_tzu-04

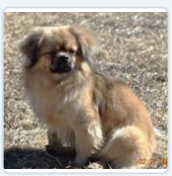

shih_tzu-07


shih_tzu-10

spaniel (12)


spaniel-01


spaniel-04


spaniel-07


spaniel-10

terrier (12)


terrier-01


terrier-04


terrier-07


terrier-10

1 Descripción general y estudios habituales

Cada fila es una foto de un perro, sacada de internet, con su raza, el nombre del fichero, la dirección y el tamaño de la imagen. Hay 12 fotos de cada una de seis razas: spaniel tibetano, terrier tibetano, mastín tibetano, lhasa apso, shih tzu y pequinés. El pequinés no es tibetano, pero está incluido porque se confunde a menudo con el spaniel tibetano.

Los estudios habituales son **clasificar la raza** con *embeddings*, **agrupar** las fotos y ver qué razas se mezclan, y **predecir la raza** de fotos nuevas de perros.

2 Contexto y fuente original

Es un dataset educativo del laboratorio de Orange (2024). Según su ficha, está pensado para clasificar, agrupar y enseñar la predicción de la raza de fotos de perros cualquiera sacadas de internet. No indica de dónde son las fotos.

- Orange Data Mining. Tibetan Dogs (datasets.biolab.si, 2024).

3 Variable objetivo

`category`: `lhasa_apso`, `mastiff`, `pekingese`, `shih_tzu`, `spaniel` y `terrier`, 12 fotos cada una. Clases perfectamente equilibradas: el acierto por azar es de una entre seis (17 %).

Las razas pequeñas de pelo largo (lhasa apso, shih tzu, terrier tibetano) se parecen mucho entre sí; el mastín, grande y casi siempre oscuro, debería ser el más fácil de reconocer. La matriz de confusión lo confirma o lo desmiente.

4 Diccionario de columnas

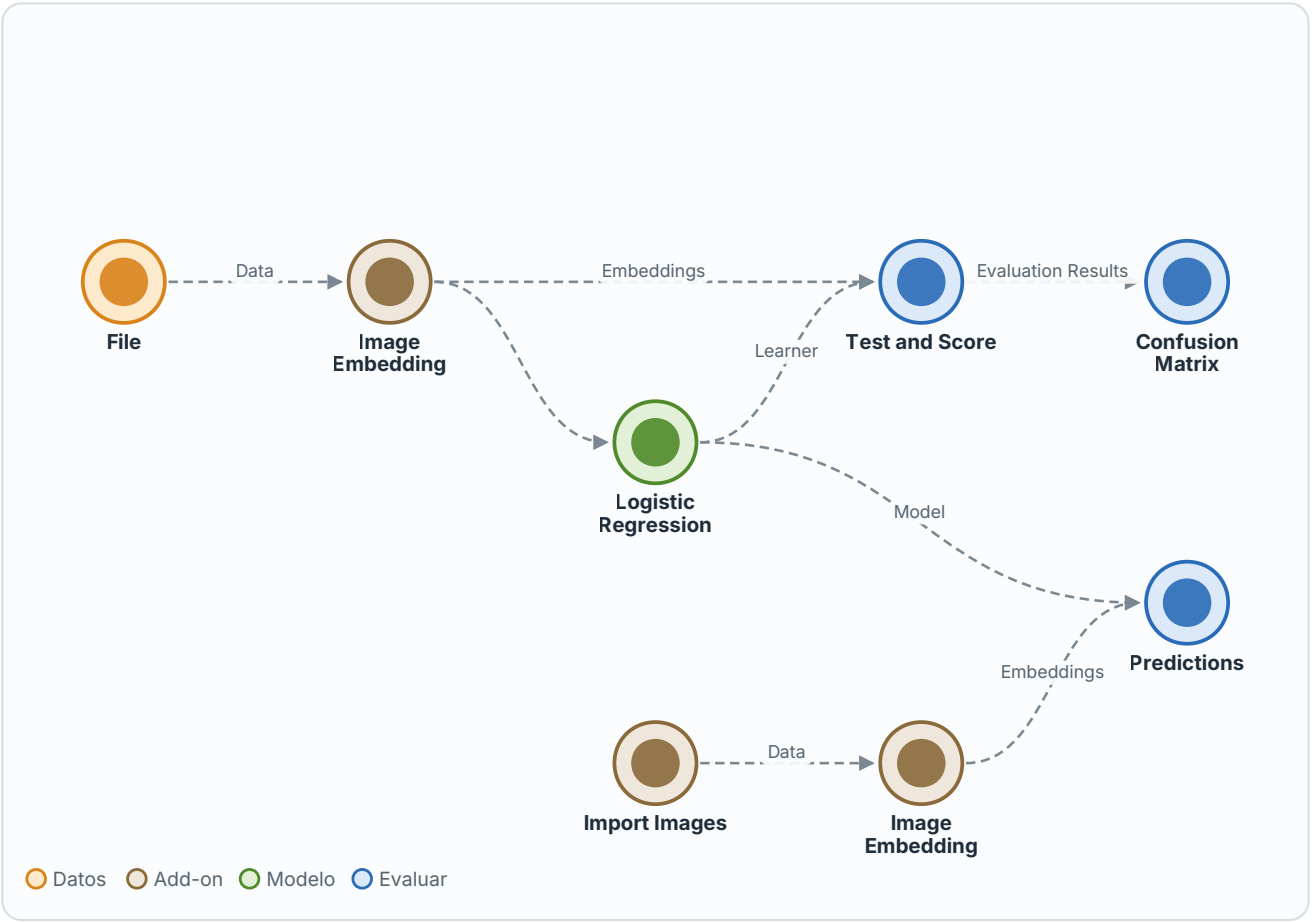
Columnas de `tibetan_dogs` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`category` objetivo	categórica	Raza: `lhasa_apso`, `mastiff`, `pekingese`, `shih_tzu`, `spaniel` o `terrier`. Objetivo.	pekingese (12), spaniel (12), shih_tzu (12), terrier (12), mastiff (12), lhasa_apso (12)
`image name`	texto	Nombre del fichero: **raza y número** (`pekingese-08`).	pekingese-08 (1), pekingese-09 (1), pekingese-11 (1), pekingese-07 (1), pekingese-12 (1), pekingese-06 (1) …
`image`	texto	Dirección de la foto en el servidor de Biolab (con la raza en la ruta).	URL (72 distintas), p. ej. file.biolab.si/…/pekingese/pekingese-08.jpg
`size`	numérica	Tamaño del fichero de imagen, en bytes.	3.407 – 13.434
`width`	numérica	Ancho de la imagen, en píxeles (183 a 318).	183 – 318
`height`	numérica	Alto de la imagen, en píxeles (159 a 275).	159 – 275

5 Particularidades técnicas al modelar

- `size`, `width` y `height` **pasan a atributos** al abrir el CSV (en el fichero de Orange son *meta*). No describen al perro: ponlos como *meta* en *File*, o el modelo los mezclará con el *embedding* (las fotos de terrier son, de media, más altas: 219 píxeles frente a unos 195 en las demás).
- **El nombre delata la raza**: `image name` y la ruta de `image` la contienen.
- **Fotos variadas**: primeros planos, perros enteros, fondos de estudio y de jardín, algunos con lazos o arreglados para exposición. Es lo normal con fotos de internet y hace la tarea más realista.
- **Muy pocas fotos** (12 por raza): usa validación cruzada o *Leave one out*.
- **Fotos pequeñas** (unos 260 × 200 píxeles): *Image Embedding* es rápido.

6 Flujo de trabajo en Orange



1. **File** con `tibetan_dogs.csv`: `category` como *target*; `size`, `width` y `height` como *meta*.
2. **Image Embedding** → **Test and Score** con **Logistic Regression** → **Confusion Matrix**: qué razas se confunden.
3. Entrena **Logistic Regression** con todas las fotos.
4. **Import Images** con una carpeta de fotos propias de perros → **Image Embedding** → **Predictions**.

7 Otras consideraciones

- **Fotos de internet**: el ZIP de esta carpeta las incluye para trabajar sin conexión, como el resto de imágenes de Orange; si se publican fuera del curso, conviene revisar sus derechos.
- Es un buen ejemplo para hablar de clases parecidas y de lo que pasa cuando se le enseña al modelo un perro de una raza que no conoce: siempre responde con una de las seis.

En la carpeta `tibetan_dogs` ← `tibetan-dogs.xlsx` (datasets.biolab.si)

11.07
Análisis de imágenes

Señales de tráfico

`11_imagenes/traffic_signs/`

70 iconos de señales de tráfico en tres grupos, para practicar con embeddings de imágenes: agrupar, buscar atípicos y clasificar.

Clasificación multiclase | Clustering | ▣ Imágenes | ◦ Juguete

> **En el curso:** Actividad 4.2 (Tema 4, imágenes), variante de agrupar por similitud cargando la tabla desde su URL; en las diapositivas, para la Actividad 4.3 (atípicos).

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
70	**3**	`category`	**0,0 %**	**Iniciación**	**Image Analytics**

Fichero	Filas × col.	Descargar
`traffic_signs`	70 × 3	CSV 7 KB · XLSX
`traffic_signs_imagenes.zip`	70 imágenes	ZIP 1,2 MB

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/11_imagenes/traffic_signs/` seguido del nombre del fichero CSV.

Radiografía

category en traffic_signs



Algunas señales de cada categoría (número total entre paréntesis)

regulatory (19)



warning (28)



yield (23)



1 Descripción general y estudios habituales

Cada fila es una señal de tráfico dibujada como icono (imagen limpia, sin fondo de calle), con su categoría, su nombre en inglés y la dirección de la imagen. Hay 70 señales repartidas en tres categorías.

Es el dataset de imágenes más ligero de Orange: pocas imágenes, pequeñas y muy distintas entre sí, ideal para entender el flujo de trabajo con imágenes sin esperas. Los estudios habituales son:

- **Agrupar por similitud** (clustering jerárquico sobre los embeddings) y ver si los grupos coinciden con las categorías.
- **Detectar atípicos**: qué señales encajan peor en su categoría, con *Silhouette Plot* o *Outliers*.
- **Clasificar** la categoría con regresión logística sobre los embeddings.
- **Buscar parecidas**: dada una señal, cuáles se le parecen más (*Neighbors*).

2 Contexto y fuente original

El dataset está en el widget *Datasets* de Orange desde 2017, sin fuente indicada para los iconos. Se presentó en la entrada del blog de Orange *Outliers in Traffic Signs* (Blaž Zupan, 2017), donde se calculan los embeddings de las imágenes y se usa *Silhouette Plot* para encontrar las señales que peor encajan en su grupo.

La tabla trae, para cada señal, la URL de su imagen en el servidor de Biolab. En esta carpeta, además, todas las imágenes están en `traffic_signs_imagenes.zip`, organizadas en una subcarpeta por categoría, para trabajar sin conexión.

- «Outliers in Traffic Signs», blog de Orange (B. Zupan, 2017)

3 Variable objetivo

La variable objetivo es `category`: `warning` (28 señales), `yield` (23) y `regulatory` (19).

Las etiquetas no siguen la clasificación habitual de las señales, y conviene saberlo antes de interpretar resultados:

- `regulatory` sí son señales de obligación (sentido obligatorio, carril bici, rotonda…).
- `warning` reúne sobre todo **prohibiciones** (prohibido el paso, giro prohibido, stop…), que normalmente no se llaman señales de advertencia.
- `yield` reúne las **señales de peligro** triangulares (curvas, desprendimientos, paso de animales…), aunque «yield» significa «ceda el paso». La propia señal de ceda el paso (`Give Way`) está en `warning`.

Para la máquina da igual el nombre del grupo, pero para explicar los resultados hay que tenerlo en cuenta.

4 Diccionario de columnas

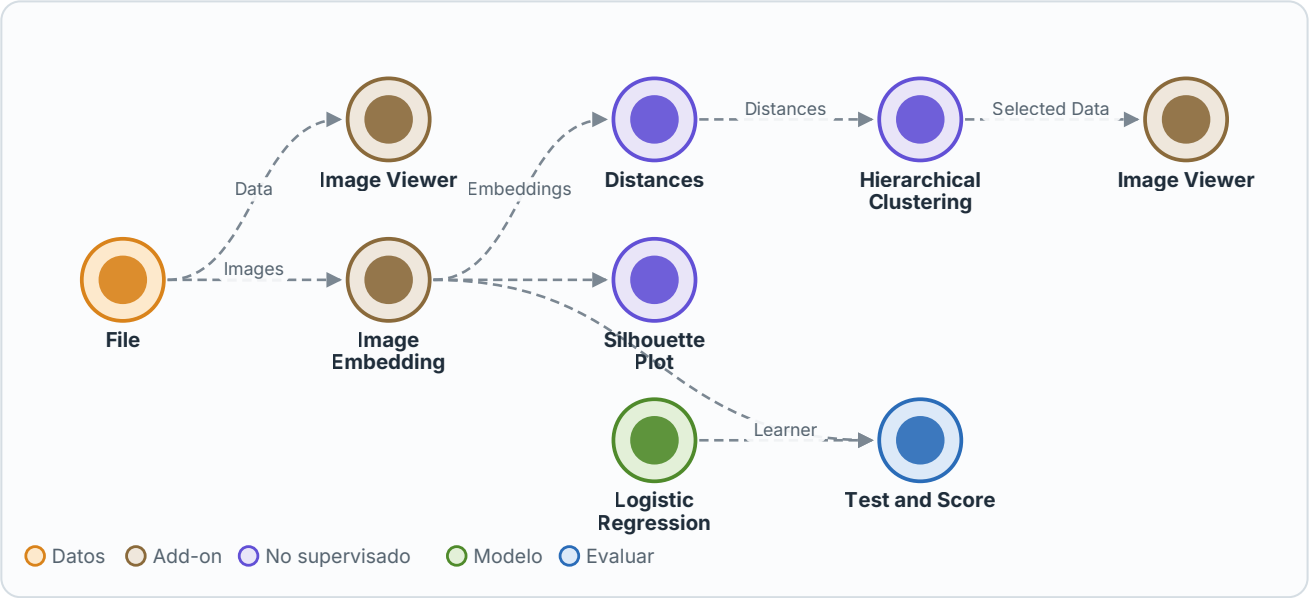
Columnas de `traffic_signs` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`category` objetivo	categórica	Categoría de la señal: `regulatory`, `warning` o `yield` (ver la sección 3 sobre su significado real). Es la variable objetivo.	warning (28), yield (23), regulatory (19)
`sign`	texto	Nombre de la señal, en inglés. Algunos tienen erratas del original (`Childreen Crossing`, `Wild Animals Corssing`, `No Watter Pollutants`).	Turn Left (1), Go Left (1), Turn Right (1), Pedestrian Lane (1), Go Right or Left (1), Snow Chains (1) …
`image`	texto	URL completa de la imagen en el servidor de Biolab. Dentro del ZIP, la misma imagen está en `traffic_signs/<categoría>/<nombre>`.	URL (70 distintas), p. ej. file.biolab.si/…/regulatory/Turn%20Left.png

5 Particularidades técnicas al modelar

- **Tres formas de cargarlo en Orange**: 1. *File* con la URL «raw» del CSV de GitHub: la columna `image` ya trae las direcciones de las imágenes. Revisa en *File* que `image` sea de tipo texto y rol *meta*, y que `category` sea *target*. 2. *Import Images* sobre la carpeta descomprimida del ZIP: Orange crea la categoría a partir del nombre de cada subcarpeta. *Import Images* no admite URL. 3. *Datasets*, buscando «traffic».
- **Formato distinto según la categoría**: todas las imágenes de `warning` están en JPEG y las de las otras dos en PNG. Un modelo podría aprender el formato o el fondo en lugar de la forma de la señal. Es poco probable con embeddings, pero es un buen ejemplo de fuga de información a vigilar.
- **Pocas imágenes por clase** (19 a 28): usa validación cruzada, no una partición fija.
- **Los embeddings necesitan cálculo**: *Image Embedding* con *SqueezeNet* funciona sin internet; *Inception v3* y otros se calculan en el servidor de Orange y requieren conexión.

6 Flujo de trabajo en Orange



1. **File** con la URL del CSV (o **Import Images** sobre la carpeta descomprimida) → **Image Viewer** para ver las señales.
2. **Image Embedding** (*SqueezeNet* si no hay conexión): cada imagen pasa a ser un vector de números.
3. **Distances** (distancia coseno) → **Hierarchical Clustering**: corta en 3 grupos y mira cada grupo en **Image Viewer**.
4. **Silhouette Plot** con `category` como agrupación: las señales con silueta negativa son las que peor encajan en su categoría.
5. **Logistic Regression** + **Test and Score** sobre los embeddings, con validación cruzada.

7 Otras consideraciones

- **El flujo se reutiliza tal cual con otras imágenes**: cambiando solo la entrada, sirve para *Domestic Animals*, *Bone Healing* o cualquier carpeta propia.
- **Save Images** guarda las imágenes en subcarpetas según el grupo o la predicción: antes hay que poner la columna por la que se quiere separar como *target* (con *Select Columns*).
- **Para explicar errores**, conecta la imagen mal clasificada a *Neighbors* y mira con qué otras señales la confunde el modelo.

En la carpeta `traffic_signs` ← `traffic-signs.tab` (datasets.biolab.si)

11.08
Análisis de imágenes

Localización de proteínas de levadura (YPL+)

`11_imagenes/yplp/`

2.569 imágenes de microscopía de levadura con una proteína marcada con GFP, y el compartimento de la célula donde está: clasificación de imágenes biológicas con siete clases muy desequilibradas.

Clasificación multiclase · ⚖ Desbalanceado · ? Valores faltantes · ▣ Imágenes

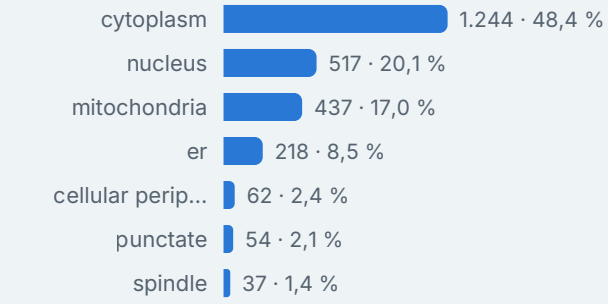
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
2.569	**4**	`Loc`	**3,4 %**	**Avanzado**	**Image Analytics**

Fichero	Filas × col.	Descargar
`yplp`	2.569 × 4	CSV 179 KB · XLSX
`yplp_imagenes.zip`	2.569 imágenes	ZIP 38,5 MB

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/11_imagenes/yplp/` seguido del nombre del fichero CSV.

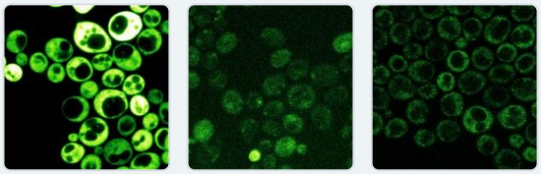
Radiografía

Loc en yplp



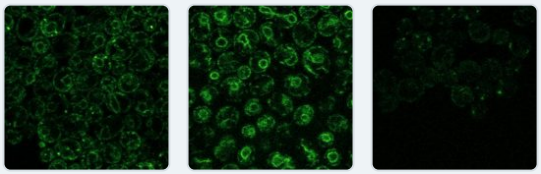
Tres imágenes de cada localización

cytoplasm (1244)



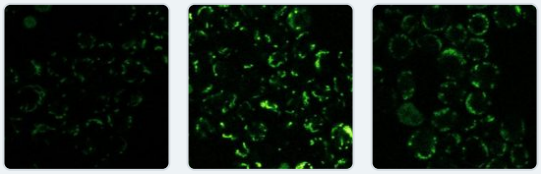
YAL005C YGL125W YLR264W

er (218)



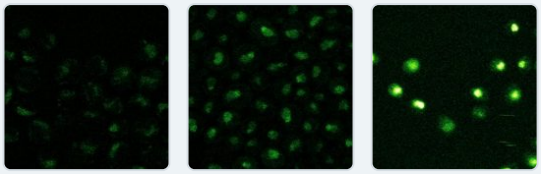
YAL007C YGL047W YLR066W

mitochondria (437)



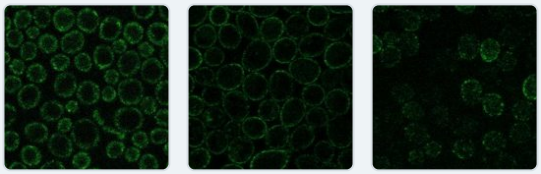
YAL008W YGR015C YML030W

nucleus (517)



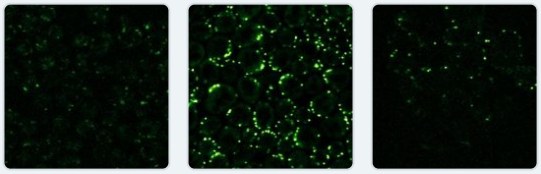
YAL009W YGL019W YML010W

cellular periphery (62)



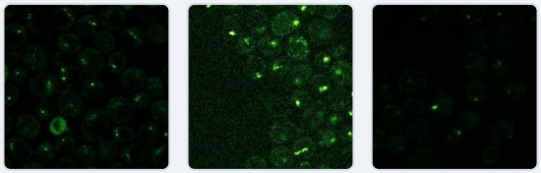
YAL029C YFL034C-B YNL142W

punctate (54)



YBR015C YDR479C YLL006W

spindle (37)



YBR211C YIR010W YML043C

1 Descripción general y estudios habituales

Cada fila es una proteína de la levadura *Saccharomyces cerevisiae*: su gen (`Gene`, nombre sistemático como `YAL005C`), su nombre común (`Name`), el compartimento de la célula donde se localiza (`Loc`) y una imagen de microscopía confocal en la que la proteína, unida a la proteína fluorescente verde (GFP), brilla en ese compartimento. Las imágenes son de 299 × 299 píxeles, con varias células cada una.

Los estudios habituales son **clasificar la localización** a partir de la imagen y **comparar *embeddings***: Orange tiene uno (*DeepLoc*) entrenado precisamente con imágenes de localización de proteínas en levadura.

2 Contexto y fuente original

Las imágenes son de YPL+.db (*Yeast Protein Localization Plus*), la base de datos de imágenes del grupo de Sepp Kohlwein en la Universidad de Graz (Austria), alojada en Yeastgenome.org. Las células proceden de la colección de proteínas fusionadas con GFP de Huh et al. (2003) y de una colección de proteínas del metabolismo de lípidos. Orange solo incluyó proteínas con una única localización y localizaciones con al menos 30 proteínas distintas.

- YPL+.db: Yeast Protein Localization Plus Database (Universidad de Graz; alojada en Yeastgenome.org).
- Kals, M. et al. (2005). YPL.db2: the Yeast Protein Localization database, version 2.0. Yeast, 22(3), 213–218.

3 Variable objetivo

`Loc` tiene siete valores muy desequilibrados: `cytoplasm` (citoplasma, 1.244, el 48 %), `nucleus` (núcleo, 517), `mitochondria` (mitocondrias, 437), `er` (retículo endoplásmico, 218), `cellular periphery` (periferia celular, 62), `punctate` (puntos dispersos, 54) y `spindle` (huso, 37).

Un clasificador que siempre diga «citoplasma» acierta casi la mitad; hay que mirar el acierto por clase o el AUC.

4 Diccionario de columnas

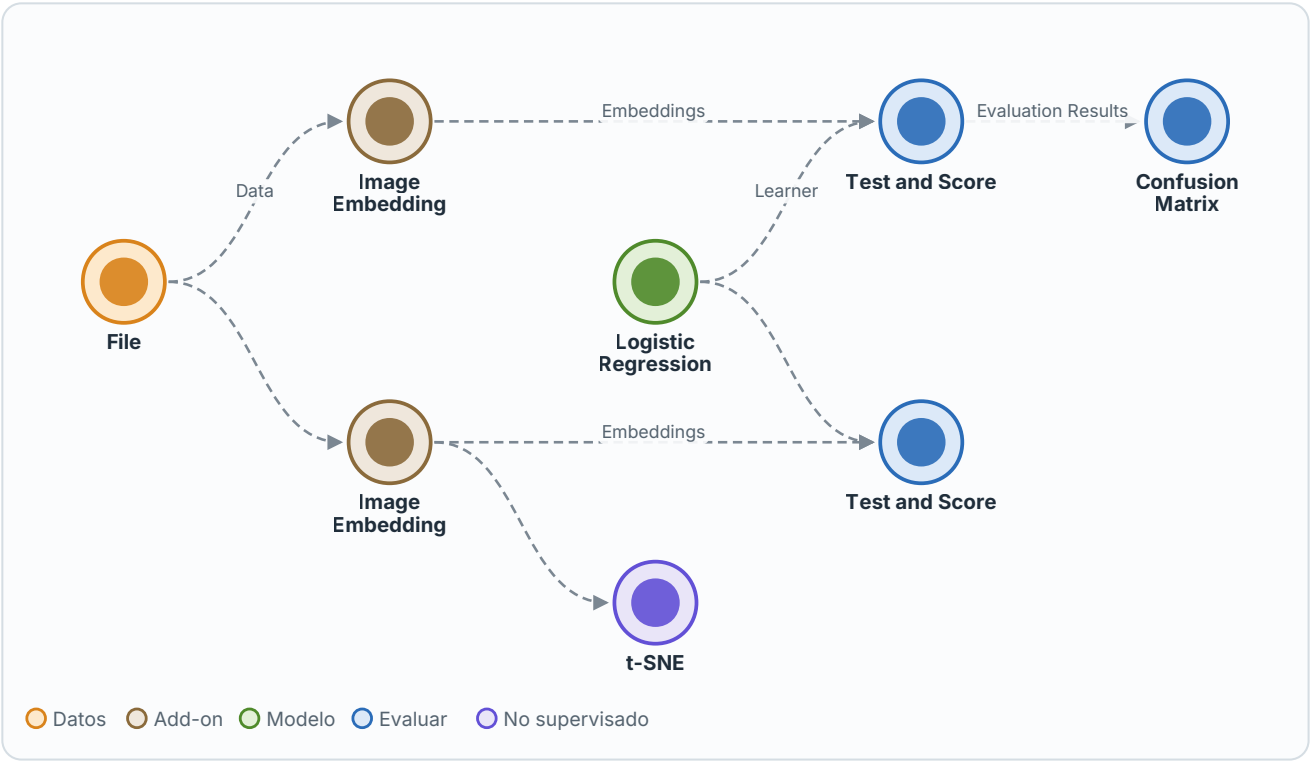
Columnas de `yplp` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Gene`	texto	Nombre sistemático del gen (ORF), p. ej. `YAL005C`. Identifica la proteína y la imagen.	YAL005C (1), YAL007C (1), YAL008W (1), YAL009W (1), YAL010C (1), YAL012W (1) …
`Name`	texto	Nombre común de la proteína (`SSA1`, `ERP2`…). Vacío en 345 (genes sin nombre común).	RPP1B (2), MLH2 (2), DPS1 (2), PBP2 (2), SMC2 (2), SML1 (2) …
`Loc` `objetivo`	categórica	Compartimento celular donde se localiza la proteína. Objetivo.	cytoplasm (1.244), nucleus (517), mitochondria (437), er (218), cellular periphery (62), punctate (54) …
`Image`	texto	Dirección de la imagen en el servidor de Biolab (`…/yplp/<Gene>.jpg`).	URL (2.569 distintas), p. ej. file.biolab.si/images/yplp/YAL005C.jpg

5 Particularidades técnicas al modelar

- **Clases muy desequilibradas**: de 1.244 imágenes de citoplasma a 37 de huso. Usa validación cruzada estratificada y mira la matriz de confusión; en *Logistic Regression* puede ayudar equilibrar las clases.
- **15 parejas de imágenes idénticas**: 30 proteínas distintas comparten la misma imagen (mismo fichero, byte a byte), siempre con la misma localización. Son errores de origen; en validación cruzada, si una cae en entrenamiento y la otra en prueba, el acierto se infla un poco.
- **El ZIP no tiene subcarpetas por clase**: todas las imágenes están juntas y se llaman como el gen. *Import Images* no puede sacar la localización de las carpetas: carga el CSV con *File* y usa la columna `Image`.
- **El *embedding* importa**: *DeepLoc* (entrenado con imágenes de levadura) frente a *Inception v3* (fotos cotidianas) es una buena comparación.
- **GFP puede alterar la localización**, como advierte la propia base de datos: las etiquetas son las observadas con la proteína marcada.

6 Flujo de trabajo en Orange



1. **File** con `yplp.csv`, `Loc` como *target*.
2. **Image Embedding** dos veces: con *DeepLoc* y con *Inception v3* (las 2.569 imágenes tardan unos minutos y necesitan conexión).
3. **Test and Score** con **Logistic Regression** para cada *embedding* (validación estratificada): compara el acierto y el AUC.
4. **Confusion Matrix**: mira dónde van a parar las clases pequeñas (huso, puntos).
5. **t-SNE** coloreado por `Loc`: qué localizaciones forman grupos y cuáles se mezclan.

7 Otras consideraciones

- **Escala real**: con 2.569 imágenes, solo *Satellite* es mayor en este capítulo; vale para explicar el coste de calcular *embeddings* en el servidor.
- Se puede enlazar con bases de datos genéticas por `Gene` (por ejemplo, Saccharomyces Genome Database) para añadir la función de cada proteína.

En la carpeta	`yplp` ← `yplp.xlsx` (datasets.biolab.si)

11.09
Análisis de imágenes

Animales domésticos

`11_imagenes/domestic_animals/`

20 imágenes de animales de granja y domésticos, sin etiquetas: el ejemplo mínimo para agrupar imágenes por similitud.

Clustering · ▣ Imágenes · ◦ Juguete

> **En el curso:** Actividad 4.2b (Tema 4, agrupar imágenes por similitud), prevista en las diapositivas.

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
20	**2**	–	**0,0 %**	**Iniciación**	**Image Analytics**

Fichero	Filas × col.	Descargar
`domestic_animals`	20 × 2	CSV 1 KB · XLSX
`domestic_animals_imagenes.zip`	20 imágenes	ZIP 889 KB

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/11_imagenes/domestic_animals/` seguido del nombre del fichero CSV.

Radiografía

Las 20 imágenes



1 Descripción general y estudios habituales

Son 19 dibujos de animales domésticos y de granja (gato, perro, conejo, vaca, ternero, buey, caballo, potro, cabra, cabrito, oveja, cordero, gallina, gallo, pollito, pato, patito, ganso y pavo) y una fotografía de una vaca, «Milka». No hay categorías: la única información es el nombre del fichero.

Es el ejemplo con el que Orange presenta el **clustering de imágenes**, porque los grupos que salen (aves, rumiantes, crías…) se entienden a simple vista. Los estudios habituales son:

- **Agrupar por similitud** con embeddings y clustering jerárquico.
- **Buscar la imagen más parecida** a una dada (*Neighbors*), por ejemplo a la foto de la vaca.
- **Comparar embedders**: cómo cambian los grupos con *SqueezeNet*, *Inception v3* o *Painters*.

2 Contexto y fuente original

Las imágenes se usaron en la entrada del blog de Orange *Image Analytics: Clustering* (Ajda Pretnar, 2017): se importan las 19 imágenes, se calculan sus embeddings, se miden las distancias con el coseno y se agrupan con clustering jerárquico. La foto de «Milka» se añadió como prueba: una vaca real frente a dibujos, para ver si el modelo la sitúa junto a la vaca dibujada.

En el repositorio del curso estaban en `domestic-animals.zip`, con carpetas de sistema de macOS que aquí se han quitado. El ZIP de esta carpeta solo tiene las 20 imágenes, y el CSV las lista con su nombre.

- «Image Analytics: Clustering», blog de Orange (A. Pretnar, 2017)

3 Variable objetivo

No tiene variable objetivo: es un ejercicio no supervisado. El «acierto» se juzga mirando si los grupos tienen sentido: aves juntas, bóvidos juntos, crías con sus adultos…

Si se quiere practicar la clasificación, se puede crear una etiqueta a mano (por ejemplo, ave o mamífero) con *Edit Domain* o *Feature Constructor*, pero con 20 imágenes los resultados no serán fiables.

4 Diccionario de columnas

Columnas de `domestic_animals` (valores observados en el fichero)

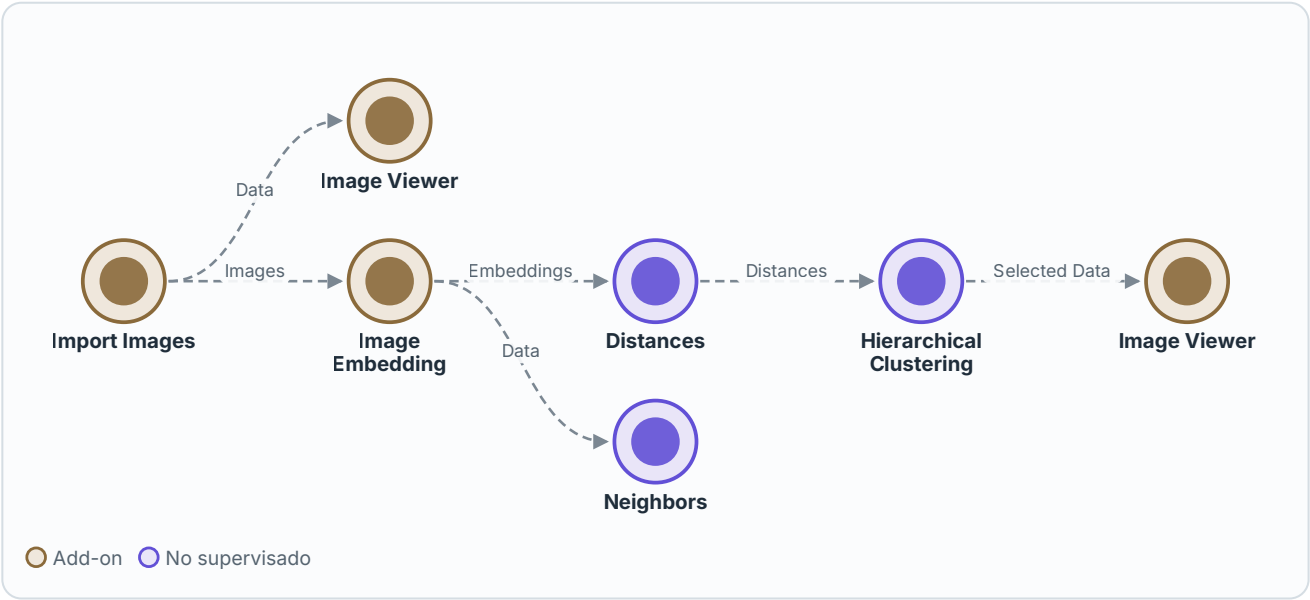
Columna	Tipo	Significado	Valores
`image name`	texto	Nombre del animal, tomado del nombre del fichero (`cat`, `cow`, `Milka` …).	Milka (1), calf (1), cat (1), chick (1), cow (1), dog (1) …
`image`	texto	Nombre del fichero de imagen dentro del ZIP (`domestic_animals/<fichero>`).	Milka.jpg (1), calf.png (1), cat.png (1), chick.png (1), cow.png (1), dog.png (1) …

5 Particularidades técnicas al modelar

- **No hay URL**: estas imágenes no están en el servidor de Orange como las de los otros datasets de imágenes. La forma de cargarlas es descomprimir el ZIP y usar **Import Images** sobre la carpeta. Selecciona la carpeta sin entrar en ella; arrastrar el ZIP al lienzo no funciona.
- **Una foto entre dibujos**: «Milka» es una fotografía y las demás son dibujos con fondo blanco. Los embeddings captan también el estilo, así que la foto puede acabar sola en su grupo. Es un buen ejemplo para comentarlo.

- **Pocas imágenes y de tamaños distintos** (de unos 85 píxeles de ancho a 800 de alto en la foto): *Image Embedding* las redimensiona, así que no hace falta prepararlas.
- Con 20 imágenes, el dendrograma completo se ve entero: es más instructivo que cortar en un número fijo de grupos.

6 Flujo de trabajo en Orange



1. **Import Images** sobre la carpeta descomprimida → **Image Viewer** para verlas.
2. **Image Embedding** (*SqueezeNet* sin conexión, *Inception v3* con conexión).
3. **Distances** con distancia **coseno** → **Hierarchical Clustering**: selecciona una rama del dendrograma y mírala en **Image Viewer**.
4. **Neighbors**: elige la foto de Milka como referencia y mira qué animales salen más cerca.
5. Repite con otro embedder y compara los grupos.

7 Otras consideraciones

- **Es el ejercicio más rápido de imágenes**: con 20 imágenes, los embeddings tardan segundos incluso con los modelos del servidor.
- **Ampliación**: añade a la carpeta fotos propias de animales y comprueba si se agrupan con los dibujos o entre sí.
- El mismo flujo, con *Save Images* al final, guarda cada grupo en su propia subcarpeta.

En la carpeta `domestic_animals` ← `domestic-animals.zip` (curso_ciencia_datos (GitHub))

11.10
Análisis de imágenes

Photographers (fotos personales por temas)

`11_imagenes/photographers/`

Fotos personales de un miembro del equipo de Orange: 70 clasificadas en cinco temas (ciudad, comida, montaña, atardecer e invierno) y 49 sin clasificar, para agrupar y clasificar fotos con embeddings.

Clasificación multiclase · Clustering · ▣ Imágenes · ◦ Juguete

> **En el curso:** Actividad 4.2a (Tema 4, sesión 2): clustering de las 49 fotos de prueba con SqueezeNet, distancia coseno y 4 grupos, y Save Images para guardarlos en carpetas.

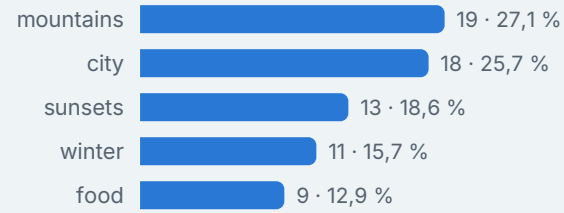
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
70	**6**	`category`	**0,0 %**	**Iniciación**	**Image Analytics**

Fichero	Filas × col.	Descargar
`photographers_train`	70 × 6	CSV 5 KB · XLSX
`photographers_test`	49 × 5	CSV 3 KB · XLSX
`photographers_test_imagenes.zip`	49 imágenes	ZIP 82,3 MB
`photographers_train_imagenes.zip`	70 imágenes	ZIP 104,5 MB

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/11_imagenes/photographers/` seguido del nombre del fichero CSV.

Radiografía

category en photographers_train



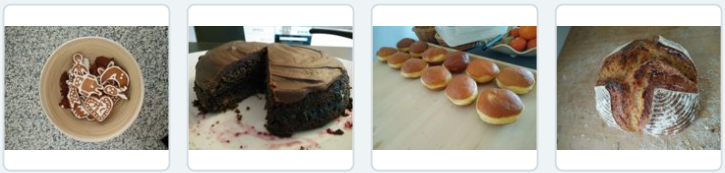
Cuatro fotos de cada categoría (entrenamiento)

city (18)



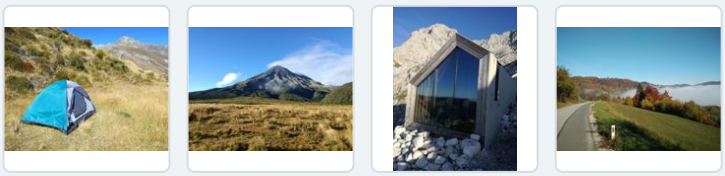
0001 0005 0009 0013

food (9)



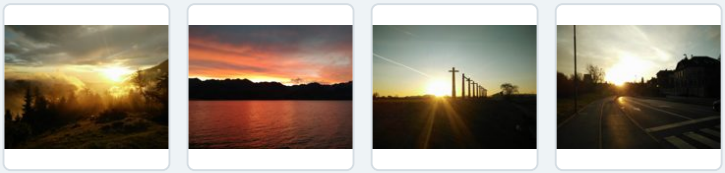
0001 0003 0005 0007

mountains (19)



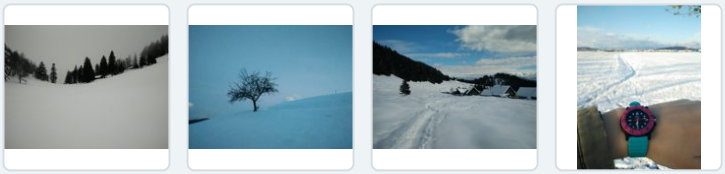
0001 0005 0009 0013

sunsets (13)



0001 0004 0007 0010

winter (11)



0001 0003 0005 0007

1 Descripción general y estudios habituales

Son fotos hechas con el móvil o con una cámara compacta entre 2014 y 2022, en dos conjuntos:

- **Entrenamiento** (`photographers_train`): 70 fotos en cinco carpetas, que dan la clase: `city` (18), `food` (9), `mountains` (19), `sunsets` (13) y `winter` (11).
- **Prueba** (`photographers_test`): 49 fotos sin clasificar, de los mismos temas.

La idea es la de cualquiera con miles de fotos en el móvil: **ordenarlas automáticamente**. Los estudios habituales son:

- **Agrupar por similitud** las fotos sin clasificar (clustering jerárquico sobre embeddings) y guardar cada grupo en su carpeta.
- **Entrenar un clasificador** con las 70 fotos etiquetadas y usarlo para clasificar las 49 nuevas.
- **Ver el mapa de fotos** con *Image Grid* o t-SNE.

2 Contexto y fuente original

Las fotos son de Primož Godec, del laboratorio de bioinformática de la Universidad de Liubliana (los autores de Orange), que las usó en la entrada del blog *Editing the photographs collection with the help of machine learning* (2022). Allí agrupa sus fotos con *Image Grid* y entrena una regresión logística con *Inception v3*: en validación cruzada obtiene un AUC de 0,992 y una precisión de 0,943.

En el repositorio del curso están en dos ZIP. En esta carpeta van los mismos ficheros, sin carpetas de sistema de macOS, con un CSV por conjunto que lista cada foto como lo hace *Import Images* (nombre, ruta, tamaño en bytes, ancho, alto y, en el de entrenamiento, la categoría).

Ojo con la privacidad: 96 de las 119 fotos conservan en sus metadatos EXIF la **posición GPS** donde se hicieron, además del modelo del teléfono y la fecha. Orange no los usa, pero cualquiera que descargue las fotos puede verlos.

- «Editing the photographs collection with the help of machine learning», blog de Orange (P. Godec, 2022)
- ZIP originales en gualbe/datasets (image-classification)

3 Variable objetivo

En el conjunto de entrenamiento, la clase es `category`, el nombre de la carpeta: `city`, `food`, `mountains`, `sunsets` o `winter`. Está algo desequilibrada: hay el doble de fotos de montaña que de comida.

El conjunto de prueba **no tiene clase**: sirve para agrupar sin supervisión o para aplicar el modelo entrenado. En clase salieron cuatro grupos fáciles de nombrar: ciudades, paisajes nevados o atardeceres, comidas y naturaleza.

4 Diccionario de columnas

Columnas de `photographers_train` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`image name`	texto	Nombre del fichero sin extensión (`0001`, `0002`…). Se repite entre carpetas: no identifica la foto por sí solo.	0001 (5), 0002 (5), 0003 (5), 0004 (5), 0005 (5), 0006 (5) …
`image`	texto	Ruta de la foto dentro del ZIP (`photographers_train/<categoría>/<fichero>.jpg`).	photographers_train/city/0001.jpg (1), photographers_train/city/0002.jpg (1), photographers_train/city/0003.jpg (1), photographers_train/city/0004.jpg (1), photographers_train/city/0005.jpg (1), photographers_train/city/0006.jpg (1) …
`size`	numérica	Tamaño del fichero en bytes (entre 0,2 y 4,3 MB).	314.948 – 4.322.480
`width`	numérica	Ancho en píxeles (casi todas de 12 megapíxeles: 4.160 × 3.120).	1.456 – 4.618
`height`	numérica	Alto en píxeles.	1.456 – 4.160
`category` `objetivo`	categórica	**Clase**: tema de la foto, tomado de la carpeta.	mountains (19), city (18), sunsets (13), winter (11), food (9)

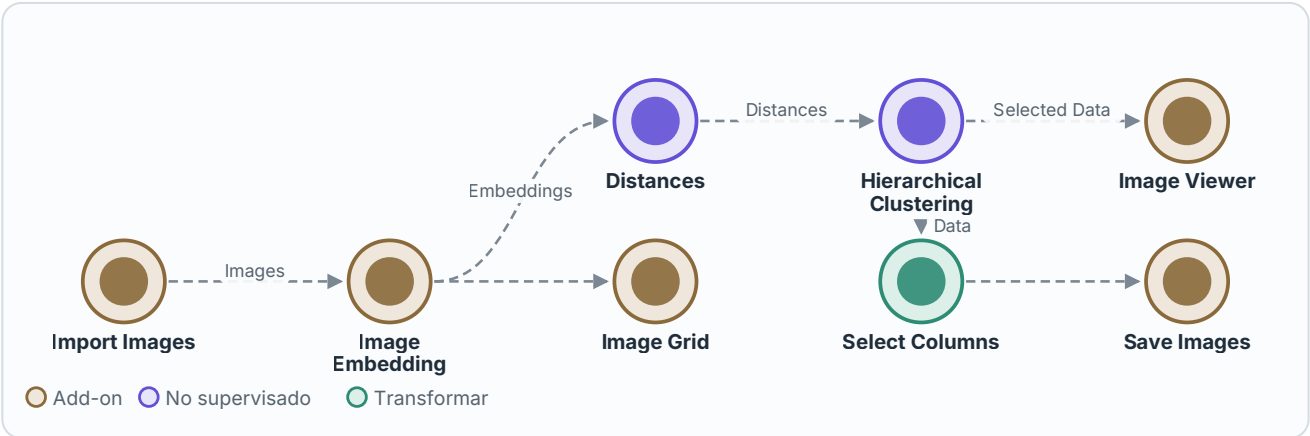
Columnas de `photographers_test` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`image name`	texto	Nombre del fichero sin extensión (`0001` … `0049`).	0001 (1), 0002 (1), 0003 (1), 0004 (1), 0005 (1), 0006 (1) …
`image`	texto	Ruta de la foto dentro del ZIP (`photographers_test/<fichero>.jpg`).	photographers_test/0001.jpg (1), photographers_test/0002.jpg (1), photographers_test/0003.jpg (1), photographers_test/0004.jpg (1), photographers_test/0005.jpg (1), photographers_test/0006.jpg (1) …
`size`	numérica	Tamaño del fichero en bytes.	240.455 – 4.008.578
`width`	numérica	Ancho en píxeles.	2.736 – 4.320
`height`	numérica	Alto en píxeles.	2.736 – 4.160

5 Particularidades técnicas al modelar

- **Hay que descomprimir y usar Import Images**: selecciona la carpeta sin entrar en ella. Arrastrar el ZIP o la carpeta al lienzo no funciona. Con la carpeta de entrenamiento, *Import Images* crea la columna `category` a partir de las subcarpetas.
- **Fotos muy grandes**: 12 megapíxeles y 1,5 MB de media. *Image Embedding* las reduce, pero subirlas al servidor tarda; con *SqueezeNet* (local) va más rápido. El ZIP de entrenamiento ocupa casi 100 MB.
- **Dos fotos están en los dos conjuntos**: `city/0018` es la `0049` de prueba y `mountains/0015` es la `0038`. Si se evalúa el modelo con las fotos de prueba (etiquetándolas a mano), esas dos dan un acierto regalado.
- **Pocas fotos para clasificar**: 70 en cinco clases, con solo 9 de comida. Usa validación cruzada estratificada y no te fíes de diferencias pequeñas entre modelos.
- **Save Images** guarda los grupos en subcarpetas, pero necesita que la variable de grupo sea la clase: en clase hizo falta un *Select Columns* que quitara `Selected` y pusiera `Cluster` como *target*; si no, crea una sola carpeta «Yes». En JPG es mucho más rápido que en PNG.
- Las clases se solapan: un atardecer en la montaña nevada puede ser de tres categorías. Los errores del clasificador suelen tener sentido al mirarlos.

6 Flujo de trabajo en Orange



1. **Import Images** sobre la carpeta de prueba descomprimida (49 fotos) → *Data Table* e *Image Viewer* para verlas.
2. **Image Embedding** con *SqueezeNet* (local) o *Inception v3* (servidor).

3. **Distances** (coseno) → **Hierarchical Clustering**: corta en 4 grupos y mira cada rama en **Image Viewer**.
4. **Image Grid**: coloca las fotos en una cuadrícula según su parecido.
5. **Select Columns** (`Cluster` como *target*) → **Save Images**: guarda cada grupo en su subcarpeta, en JPG.
6. **Clasificación**: repite *Import Images* + *Image Embedding* con la carpeta de entrenamiento → *Test and Score* con regresión logística → *Predictions* sobre las fotos de prueba.

7 Otras consideraciones

- **Comparar embedders**: con *SqueezeNet* e *Inception v3* los grupos cambian. Es un buen ejercicio mirar qué fotos cambian de grupo y por qué.
- **Etiquetar a mano el conjunto de prueba** (con *Edit Domain* o en una hoja) permite medir de verdad el acierto del clasificador en fotos nuevas. Quita antes las dos repetidas.
- **Tus propias fotos**: el ejercicio funciona igual con una carpeta de fotos del alumno. Conviene avisar de los metadatos GPS si se van a compartir.
- Si quieres publicar o compartir estas fotos, puedes quitar los metadatos EXIF antes con cualquier editor de imágenes.

En la carpeta	`photographers_train` ← `image-classification/photographers-train-images.zip` (gualbe/datasets (GitHub))
En la carpeta	`photographers_test` ← `image-classification/photographers-test-images-unsupervised.zip` (gualbe/datasets (GitHub))

11.11
Análisis de imágenes

Hollywood faces (caras de 17 famosos)

`11_imagenes/hollywood_faces/`

1.800 fotos de caras de 17 actores y actrices de Hollywood, recortadas y casi todas de 240 × 240 píxeles: el ejercicio de reconocimiento facial del curso, con embeddings de OpenFace.

Clasificación multiclase · Clustering · ▣ Imágenes

> **En el curso:** Actividades 4.4a y 4.4b (Tema 4, sesión 3): clasificador de 5 personajes con OpenFace y Naive Bayes, y test ciego con el modelo guardado. Aparece también en el trabajo final, para clustering.

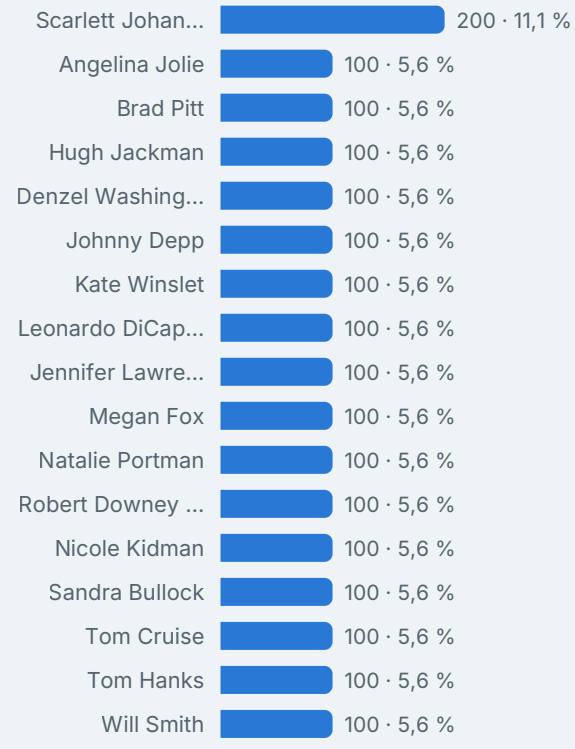
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
1.800	**6**	`category`	**0,0 %**	**Intermedio**	**Image Analytics**

Fichero	Filas × col.	Descargar
`hollywood_faces`	1.800 × 6	CSV 172 KB · XLSX

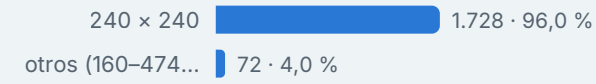
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/11_imagenes/hollywood_faces/` seguido del nombre del fichero CSV.

Radiografía

category en hollywood_faces



Tamaño de las fotos



1 Descripción general y estudios habituales

Son fotos de caras de **17 personas famosas** del cine, ya recortadas: Angelina Jolie, Brad Pitt, Denzel Washington, Hugh Jackman, Jennifer Lawrence, Johnny Depp, Kate Winslet, Leonardo DiCaprio, Megan Fox, Natalie Portman, Nicole Kidman, Robert Downey Jr, Sandra Bullock, Scarlett Johansson, Tom Cruise, Tom Hanks y Will Smith. Hay 100 fotos de cada una, salvo Scarlett Johansson, que tiene 200. La persona es el nombre de la carpeta.

Los estudios habituales son:

- **Reconocimiento facial** (clasificación multiclase): decir quién sale en una foto nueva.
- **Agrupar caras** sin usar la etiqueta y ver si los grupos coinciden con las personas.
- **Comparar embedders**: uno especializado en caras (*OpenFace*) frente a los generalistas.

2 Contexto y fuente original

Es una copia del dataset *Celebrity Face Image Dataset* publicado en Kaggle por el usuario vishesh1412, que anuncia más de 1.800 imágenes de 18 personas. La copia del repositorio del curso tiene 17 carpetas, y la de Scarlett Johansson con el doble de ficheros. Kaggle no indica la licencia en la página del dataset ni el origen de las fotos, que parecen recopiladas de internet.

Lo que hay en esta carpeta. Al tratarse de fotos de personas reales, no se han vuelto a empaquetar aquí: el CSV describe cada foto (nombre, ruta, tamaño, ancho, alto y persona) y las imágenes se descargan del ZIP original del repositorio del curso (`image-classification/hollywood-faces-images.zip`, 37 MB). La columna `image` da la ruta de cada foto dentro de ese ZIP.

Duplicados. Comparando el contenido de los ficheros hay **89 fotos repetidas** exactamente: 88 en la carpeta de Scarlett Johansson (que en realidad tiene 112 fotos distintas) y 1 en la de Denzel Washington.

- Celebrity Face Image Dataset, Kaggle (vishesh1412)
- ZIP usado en el curso: gualbe/datasets, image-classification/hollywood-faces-images.zip

3 Variable objetivo

La clase es `category`: el nombre de la persona. Hay 17 clases, equilibradas (100 fotos cada una) salvo Scarlett Johansson (200, de ellas 88 copias).

En clase se usaron solo las cinco primeras por orden alfabético (Angelina Jolie, Brad Pitt, Denzel Washington, Hugh Jackman y Jennifer Lawrence: 500 fotos) para ahorrar tiempo. Con *OpenFace* y Naive Bayes se llegó a un **97,7 % de acierto** (MCC 0,97) en validación cruzada de 10 bolsas; el árbol de decisión se quedó en un 90 %.

4 Diccionario de columnas

Columnas de `hollywood_faces` (valores observados en el fichero)

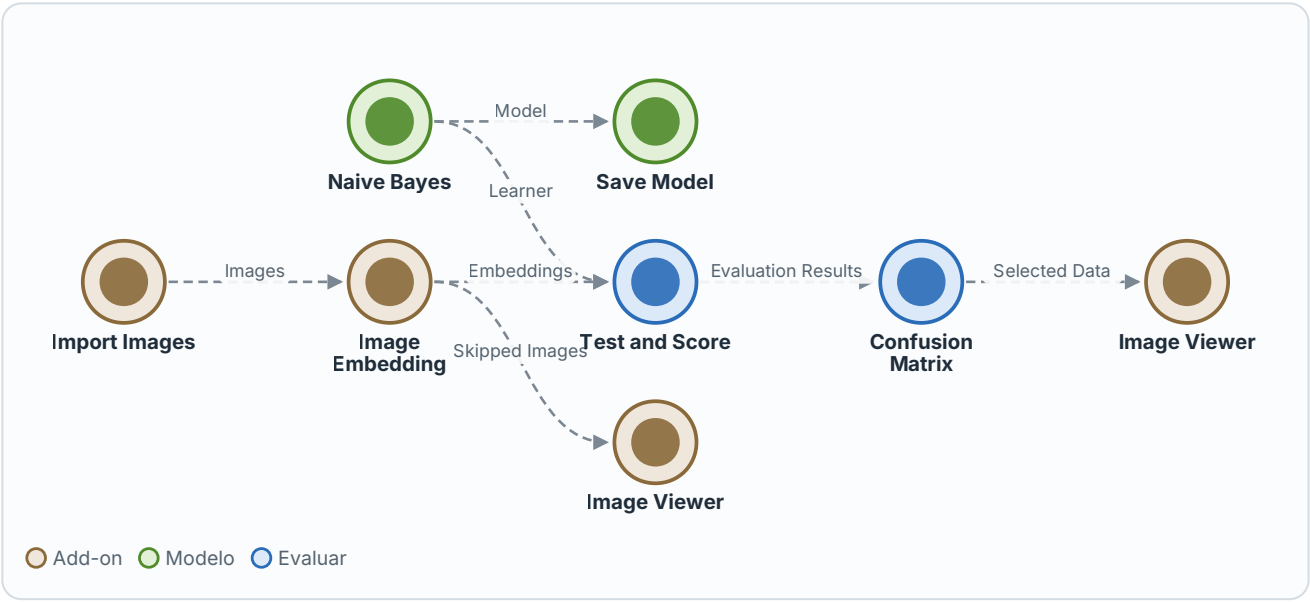
Columna	Tipo	Significado	Valores
`image name`	texto	Nombre del fichero sin extensión (`001_fe3347c0` …): un número y un código.	001_fe3347c0 (1), 002_8f8da10e (1), 003_57612506 (1), 004_f61e7d0c (1), 005_582c121a (1), 006_9135205d (1) …

Columna	Tipo	Significado	Valores
`image`	texto	Ruta de la foto dentro del ZIP original (`hollywood-faces-images/<persona>/<fichero>.jpg`).	hollywood-faces-images/Angelina Jolie/001_fe3347c0.jpg (1), hollywood-faces-images/Angelina Jolie/002_8f8da10e.jpg (1), hollywood-faces-images/Angelina Jolie/003_57612506.jpg (1), hollywood-faces-images/Angelina Jolie/004_f61e7d0c.jpg (1), hollywood-faces-images/Angelina Jolie/005_582c121a.jpg (1), hollywood-faces-images/Angelina Jolie/006_9135205d.jpg (1) …
`size`	numérica	Tamaño del fichero en bytes (unos 20 KB).	5.754 – 120.427
`width`	numérica	Ancho en píxeles: 240 en el 96 % de las fotos.	160 – 474
`height`	numérica	Alto en píxeles.	156 – 592
`category` `objetivo`	categórica	**Clase**: la persona que sale en la foto, tomada del nombre de la carpeta.	Scarlett Johansson (200), Angelina Jolie (100), Brad Pitt (100), Hugh Jackman (100), Denzel Washington (100), Johnny Depp (100) …

5 Particularidades técnicas al modelar

- **Los duplicados inflan la evaluación**: con las 17 personas, las 88 copias de Scarlett Johansson hacen que en validación cruzada la misma foto caiga a la vez en entrenamiento y en prueba. Quítalas antes con el widget *Unique* sobre las columnas del embedding (dos fotos idénticas dan el mismo vector) o deja fuera esa carpeta, como se hizo en clase.
- **Usa OpenFace**: es el embedder entrenado con caras y da 128 características; los generalistas (*SqueezeNet*, 1.000; *Inception v3*, 2.048) reconocen peor a las personas y tardan más.
- **OpenFace descarta fotos**: en clase, 19 de las 500 no se procesaron (no detecta bien una cara). Se ven conectando la salida *Skipped Images* a un *Image Viewer*.
- **Etiquetas con ruido**: en clase apareció una foto etiquetada como Brad Pitt en la que no sale él. Con datos recopilados de internet es normal; los errores del modelo ayudan a encontrarlas.
- **El modelo guardado debe usarse con el mismo embedder**: al cargar un `.pkcls` con *Load Model*, las fotos nuevas tienen que pasar por *Image Embedding* con *OpenFace* o el modelo no las entiende.
- **Reconocimiento facial y personas reales**: son caras de personas identificables, recopiladas sin su consentimiento expreso. Es buen momento para hablar de los riesgos de estos sistemas: el Reglamento europeo de IA, por ejemplo, prohíbe crear bases de datos de reconocimiento facial con fotos recopiladas de internet de forma indiscriminada.

6 Flujo de trabajo en Orange



1. Descarga y descomprime el ZIP original; deja solo las carpetas de las personas que vayas a usar (en clase, las cinco primeras).
2. **Import Images** sobre la carpeta → *Data Table* e *Image Viewer* para comprobar las categorías.
3. **Image Embedding** con *OpenFace* → mira con *Skipped Images* qué fotos ha descartado.
4. **Test and Score** con validación cruzada estratificada de 10 bolsas: Naive Bayes, árbol y *Gradient Boosting* (conecta la salida *Learner*). Ordena por MCC.
5. **Confusion Matrix** → selecciona los errores → **Image Viewer**: ¿a quién se parece cada error?
6. **Test ciego** (actividad 4.4b): aparta una foto de cada persona, entrena Naive Bayes con el resto, guárdalo con **Save Model** y, en otro flujo, *Load Model* → *Predictions* con las fotos apartadas pasadas por *OpenFace*.

7 Otras consideraciones

- **Clustering** (como en el trabajo final): *Distances* (coseno) → *Hierarchical Clustering* con 5 grupos sobre los embeddings de OpenFace, y compara los grupos con `category` en una tabla cruzada (*Distributions* o *Pivot Table*).
- **Neighbors** sobre una foto mal clasificada enseña con qué otras caras la confunde el modelo.
- Con las 17 personas (sin las copias) el problema es bastante más difícil: es un buen ejercicio de ampliación.
- En clase se vio que un modelo cargado desde `.pkcls` en *Predictions* no siempre muestra las probabilidades por clase; conviene comprobarlo con la versión de Orange que se use.

En la carpeta `hollywood_faces` ← `image-classification/hollywood-faces-images.zip` (gualbe/datasets (GitHub))

11.12
Análisis de imágenes

Paintings (15 cuadros de 14 pintores)

`11_imagenes/paintings/`

15 cuadros de 14 pintores, dos de ellos de Claude Monet: el ejercicio de buscar imágenes parecidas con el embedder Painters y el nodo Neighbors.

Clustering · ▣ Imágenes · ◦ Juguete

> **En el curso:** Actividad 4.1 (Tema 4, imágenes similares), prevista en las diapositivas con este conjunto. Solo se explicó de palabra.

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
15	**5**	`— (sin clase)`	**0,0 %**	**Iniciación**	**Image Analytics**

Fichero	Filas × col.	Descargar
`paintings`	15 × 5	CSV 1 KB · XLSX
`paintings_imagenes.zip`	15 imágenes	ZIP 2,2 MB

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/11_imagenes/paintings/` seguido del nombre del fichero CSV.

Radiografía

Los 15 cuadros


Albert Edelfelt


Antoine Vollon


Anton Karinger


Canaletto


Claude Monet


Dario de Regoyos


Dominik Skutecky


Jan Hackaert


Johann Christian V


Jonas Zeuner


Monet


Nikola Petrov


Peder Severin Kroy


Rudolf Bernt


Samuel Frederick B

1 Descripción general y estudios habituales

Son 15 reproducciones de cuadros, desde el siglo XVII hasta principios del XX: paisajes, vistas de ciudades y escenas de calle. Cada fichero se llama como su autor: Albert Edelfelt, Antoine Vollon, Anton Karinger, Canaletto, Dario de Regoyos, Dominik Skutecký, Jan Hackaert, Johann Christian Vollerdt, Jonas Zeuner, Nikola Petrov, Peder Severin Krøyer, Rudolf Bernt, Samuel Frederick Brocas y **Claude Monet**, que tiene dos (`Monet.jpg`, un jardín con lirios, y `Claude Monet.jpg`, un camino junto al mar).

No hay categorías: es un conjunto para practicar la **búsqueda de imágenes parecidas**. Los estudios habituales son:

- **Encontrar el cuadro más parecido a uno dado**: partiendo de un Monet, ¿sale el otro Monet entre los más cercanos?
- **Agrupar los cuadros** por estilo con clustering jerárquico.
- **Comparar embedders**: *Painters*, entrenado para reconocer pintores, frente a uno generalista como *Inception v3*.

2 Contexto y fuente original

El conjunto lo prepararon Ajda Pretnar y Primož Godec, del laboratorio de bioinformática de la Universidad de Liubliana, para un taller de análisis de imágenes con Orange en el congreso AIUCD 2018 (humanidades digitales). El ejercicio era justamente este: dado un cuadro de Monet, encontrar el otro con el embedder *Painters* y el nodo *Neighbors*.

El embedder *Painters* de Orange se entrenó con 79.433 cuadros de 1.584 pintores y ganó la competición de Kaggle *Painter by Numbers*. Por eso sus vectores recogen el estilo del pintor más que el tema del cuadro.

Todos los pintores murieron antes de 1930, así que las obras son de dominio público. En esta carpeta van las 15 imágenes en un ZIP (sin carpetas de sistema de macOS) y un CSV que las lista como *Import Images*.

- «Image Analytics Workshop at AIUCD 2018», blog de Orange (A. Pretnar, 2018)
- Documentación del widget Image Embedding (embedder Painters)

3 Variable objetivo

No hay variable objetivo. La única información es el nombre del pintor, en `image name`. El «acierto» se comprueba a mano: si, tomando `Monet` como referencia, el vecino más cercano es `Claude Monet`, el embedder ha captado el estilo.

Se puede crear una etiqueta (por ejemplo, el siglo o el movimiento) con *Edit Domain*, pero con 15 cuadros no tiene sentido entrenar un clasificador.

4 Diccionario de columnas

Columnas de `paintings` (valores observados en el fichero)

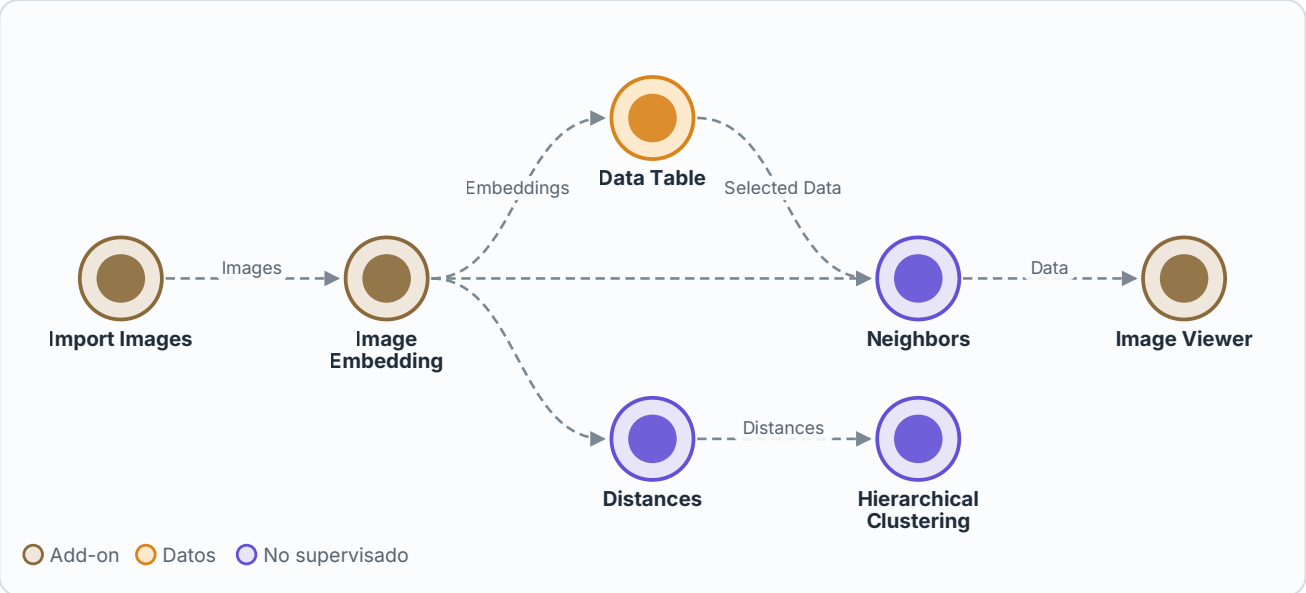
Columna	Tipo	Significado	Valores
`image name`	texto	Nombre del fichero: el pintor (`Canaletto`, `Monet`, `Claude Monet`…).	Albert Edelfelt (1), Antoine Vollon (1), Anton Karinger (1), Canaletto (1), Claude Monet (1), Dario de Regoyos (1) …

Columna	Tipo	Significado	Valores
`image`	texto	Ruta del cuadro dentro del ZIP (`paintings/<pintor>.jpg`).	paintings/Albert Edelfelt.jpg (1), paintings/Antoine Vollon.jpg (1), paintings/Anton Karinger.jpg (1), paintings/Canaletto.jpg (1), paintings/Claude Monet.jpg (1), paintings/Dario de Regoyos.jpg (1) …
`size`	numérica	Tamaño del fichero en bytes (de 20 a 730 KB).	17.360 – 726.251
`width`	numérica	Ancho en píxeles (de 384 a 1.024).	384 – 1.024
`height`	numérica	Alto en píxeles (de 226 a 849).	226 – 849

5 Particularidades técnicas al modelar

- **Elige bien el embedder**: con *Painters* los dos Monet quedan cerca; con un embedder generalista (*SqueezeNet*, *Inception v3*) pesa más el tema (agua, ciudad, campo) que el estilo, y el resultado cambia. Ese contraste es lo más instructivo del ejercicio.
- **Neighbors necesita dos entradas**: los datos con todos los embeddings y la imagen de referencia. La referencia se elige en una *Data Table* conectada a *Image Embedding* y se envía a la entrada *Reference* de *Neighbors*. Usa la distancia **coseno** y desmarca *Exclude references* para ver también la imagen de partida.
- **Muy pocas imágenes**: con 15, cualquier método de agrupamiento da grupos de 2 o 3. Mira el dendrograma completo en lugar de cortar en un número fijo de grupos.
- Las imágenes tienen tamaños y proporciones distintos: no importa, *Image Embedding* las redimensiona.
- Hay que descomprimir el ZIP y usar *Import Images* sobre la carpeta (seleccionándola sin entrar en ella).

6 Flujo de trabajo en Orange



1. **Import Images** sobre la carpeta descomprimida (15 cuadros).
2. **Image Embedding** con *Painters*.
3. **Data Table**: selecciona la fila de `Monet` .

4. **Neighbors**: datos desde *Image Embedding* y referencia desde la *Data Table*; distancia coseno, 2 o 3 vecinos y sin excluir la referencia → **Image Viewer**: ¿aparece `Claude Monet`?
5. **Distances** (coseno) → **Hierarchical Clustering**: ¿qué cuadros se agrupan?
6. Repite con *Inception v3* y compara.

7 Otras consideraciones

- **Añadir cuadros**: incorpora a la carpeta otras obras de los mismos pintores (por ejemplo, desde Wikimedia Commons) y comprueba si *Painters* las agrupa con su autor.
- **Monet frente a Manet**: el blog de Orange tiene otra actividad, con más cuadros, para distinguir a los dos pintores con un clasificador.
- Es un ejercicio rápido (segundos) que funciona bien como introducción antes de los conjuntos grandes del tema.

En la carpeta `paintings` ← `image-classification/paintings-images-unsupervised.zip` (gualbe/datasets (GitHub))

11.13
Análisis de imágenes

Satellite (imágenes de satélite en 4 clases)

`11_imagenes/satellite/`

5.631 imágenes de satélite en cuatro clases (nubes, desierto, zona verde y agua), para clasificar imágenes con embeddings. Cada clase viene de una fuente distinta y eso la delata.

Clasificación multiclase · Clustering · ▣ Imágenes

> **En el curso:** Actividad 4.4 (Tema 4, clasificar imágenes), opción b de las diapositivas. No se practicó: en clase se usó Hollywood faces.

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
5.631	**6**	`category`	**0,0 %**	**Intermedio**	**Image Analytics**

Fichero	Filas × col.	Descargar
`satellite`	5.631 × 6	CSV 369 KB · XLSX
`satellite_imagenes.zip`	5.631 imágenes	ZIP 23,4 MB

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/11_imagenes/satellite/` seguido del nombre del fichero CSV.

Radiografía

category en satellite



Clase: tamaño (px) y color



Seis imágenes de cada clase

cloudy (1500)



train_10021 train_15077 train_20247 train_2655 train_32802 train_39946

desert (1131)



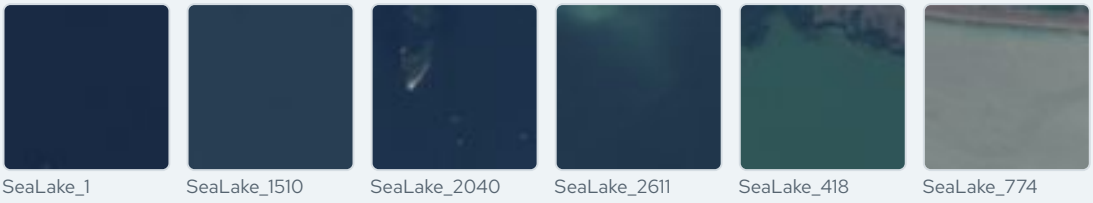
desert(1) desert(181) desert(345) desert(511) desert(673) desert(827)

green_area (1500)



Forest_1404 Forest_2123 Forest_2607 Forest_323 Forest_549 Forest_774

water (1500)



SeaLake_1 SeaLake_1510 SeaLake_2040 SeaLake_2611 SeaLake_418 SeaLake_774

1 Descripción general y estudios habituales

Son recortes cuadrados de imágenes de satélite clasificados en cuatro carpetas: `cloudy` (1.500, nubes), `desert` (1.131, desierto), `green_area` (1.500, zonas verdes) y `water` (1.500, agua). Las clases se distinguen a simple vista, así que es un problema fácil para empezar con la clasificación de imágenes. Los estudios habituales son:

- **Clasificar el tipo de terreno** (clasificación multiclase) con embeddings y un modelo sencillo.
- **Agrupar sin etiquetas** y comprobar si salen las cuatro clases.
- **Detectar atajos**: averiguar si el modelo aprende el terreno o algo más simple, como el tamaño de la imagen.

2 Contexto y fuente original

Es una copia del dataset *Satellite Image Classification* de Kaggle (usuario mahmoudreda55), que se presenta como *Satellite Remote Sensing Image - RSI-CB256*. RSI-CB es un banco de imágenes de teledetección construido con datos colaborativos (Li et al., 2020), con recortes de 256 × 256 píxeles.

Pero las clases no vienen de la misma fuente. Mirando los ficheros:

Clase	Imágenes	Tamaño	Color	Nombre de los ficheros
`cloudy`	1.500	256 × 256	CMYK	`train_10021.jpg`

Clase	Imágenes	Tamaño	Color	Nombre de los ficheros
`desert`	1.131	256 × 256	RGB	`desert(1).jpg`
`green_area`	1.500	64 × 64	RGB	`Forest_1404.jpg`
`water`	1.500	64 × 64	RGB	`SeaLake_1.jpg`

Los nombres `Forest_…` y `SeaLake_…` y el tamaño de 64 × 64 coinciden con el formato de **EuroSAT**, un conjunto de recortes de imágenes del satélite Sentinel-2. La descripción de Kaggle solo dice que se mezclaron capturas de Google Maps con datos de sensores.

En esta carpeta van las imágenes en un ZIP (con la misma estructura de carpetas) y un CSV que las lista como *Import Images*.

- Satellite Image Classification, Kaggle (mahmoudreda55)
- Li, H. et al. (2020). RSI-CB: A Large-Scale Remote Sensing Image Classification Benchmark Using Crowdsourced Data. Sensors, 20(6), 1594.
- Helber, P. et al. (2019). EuroSAT: A Novel Dataset and Deep Learning Benchmark for Land Use and Land Cover Classification (repositorio).

3 Variable objetivo

La clase es `category`, el nombre de la carpeta: `cloudy`, `desert`, `green_area` o `water`. Está casi equilibrada; `desert` tiene algo menos (1.131 frente a 1.500).

Con cualquier embedder, un modelo lineal acierta casi siempre. **El problema es saber por qué**: el tamaño, el modelo de color y hasta el nombre del fichero separan las clases por sí solos. Un modelo puede acertar sin «mirar» el terreno.

4 Diccionario de columnas

Columnas de `satellite` (valores observados en el fichero)

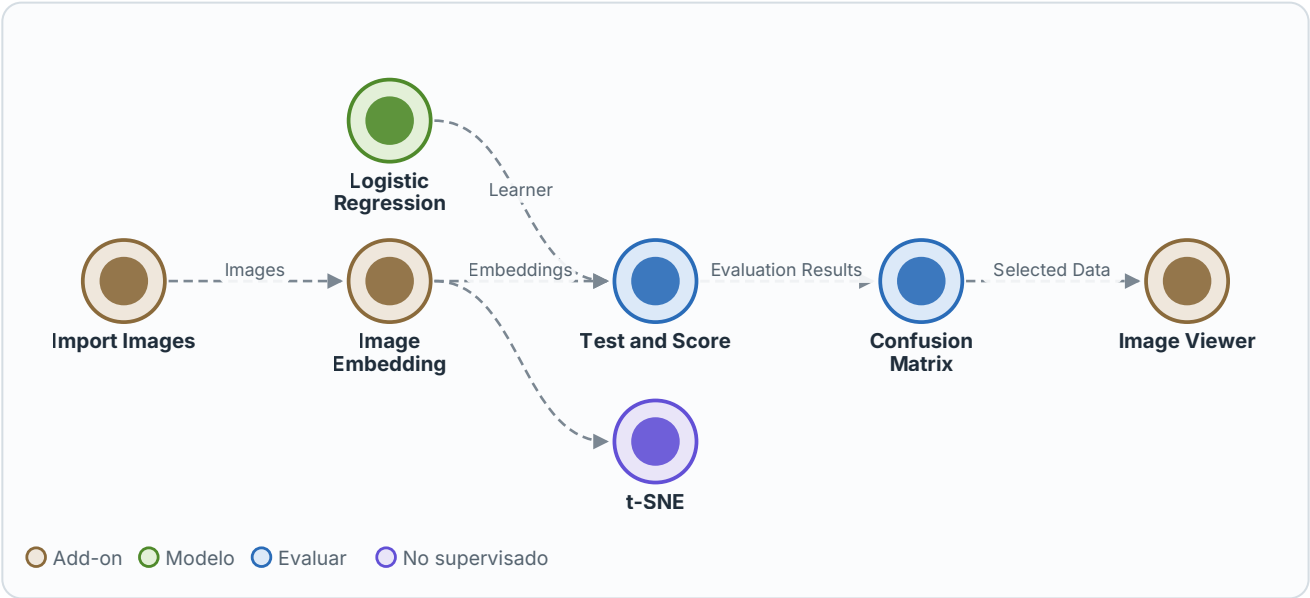
Columna	Tipo	Significado	Valores
`image name`	texto	Nombre del fichero sin extensión. **Delata la clase** (`train_…`, `desert(…)`, `Forest_…`, `SeaLake_…`).	train_10021 (1), train_10043 (1), train_10070 (1), train_10081 (1), train_10096 (1), train_101 (1) …
`image`	texto	Ruta de la imagen dentro del ZIP (`satellite/<clase>/<fichero>.jpg`).	satellite/cloudy/train_10021.jpg (1), satellite/cloudy/train_10043.jpg (1), satellite/cloudy/train_10070.jpg (1), satellite/cloudy/train_10081.jpg (1), satellite/cloudy/train_10096.jpg (1), satellite/cloudy/train_101.jpg (1) …
`size`	numérica	Tamaño del fichero en bytes (de 1 a 23 KB).	993 – 22.621
`width`	numérica	Ancho en píxeles: 256 en `cloudy` y `desert`, 64 en `green_area` y `water`. **Separa las clases por sí solo.**	64 – 256

Columna	Tipo	Significado	Valores
`height`	numérica	Alto en píxeles (igual que el ancho).	64 – 256
`category` `objetivo`	categórica	**Clase**: tipo de terreno, tomado de la carpeta.	cloudy (1.500), green_area (1.500), water (1.500), desert (1.131)

5 Particularidades técnicas al modelar

- **Fuga de información por el formato**: el tamaño (`width` , `height`) separa en dos bloques las cuatro clases, y el modelo de color (CMYK solo en `cloudy`) y el nombre del fichero terminan de identificarlas. *Import Images* pone esas columnas como *meta*, así que no entran en el modelo, pero no hay que pasarlas nunca a *feature*.
- **El atajo sobrevive al embedding**: *Image Embedding* redimensiona todas las imágenes al mismo tamaño, pero las de 64 × 64 quedan borrosas al ampliarse y las de 256 × 256 no. Un modelo puede aprender la nitidez en lugar del terreno. Para comprobarlo, prueba el modelo con imágenes de otra fuente.
- **39 imágenes repetidas** en `desert` : son copias exactas con « (1)» en el nombre (`desert(64).jpg` y `desert(64) (1).jpg`). Quítalas para que no aparezcan a la vez en entrenamiento y en prueba.
- **Imágenes en CMYK**: las de `cloudy` están en CMYK, poco habitual en JPEG. Algunos visores las muestran con tonos rosados; *Image Embedding* las procesa sin problema.
- Con 5.631 imágenes, el embedding en el servidor tarda unos minutos; con *SqueezeNet* en local va más rápido.

6 Flujo de trabajo en Orange



1. Descomprime el ZIP y usa **Import Images** sobre la carpeta `satellite` : la clase sale de las subcarpetas.
2. **Image Embedding** (*SqueezeNet* en local o *Inception v3* en el servidor).
3. **Test and Score** con regresión logística y validación cruzada estratificada.
4. **Confusion Matrix** → errores → **Image Viewer**: ¿qué imágenes confunde, y por qué?
5. **t-SNE** coloreado por `category` : las cuatro clases salen separadas. Colorea por `width` : el mapa se parte por el tamaño de la imagen.

7 Otras consideraciones

- **Comprobar el atajo**: reduce todas las imágenes a 64 × 64 (con cualquier editor por lotes) y repite. Si el acierto apenas baja, el modelo sí miraba el terreno.
- **Un clasificador «tramposo»**: entrena un árbol de decisión solo con `width` (pasándola a *feature*) y compara su acierto con el del modelo de imágenes. Es una forma muy visual de explicar la fuga de información.
- **Agrupar**: *Distances* (coseno) y *Hierarchical Clustering* con 4 grupos; ¿coinciden los grupos con las clases?
- Para un problema más realista de satélite, EuroSAT tiene diez clases de uso del suelo, todas de la misma fuente.

En la carpeta `satellite` ← `image-classification/satellite-images.zip` (gualbe/datasets (GitHub))

12 Espectroscopía

4 datasets en el capítulo; en esta edición, 4 con ficha.

12.01
Espectroscopía

TKI resistance (espectroscopía IR)

`12_espectroscopia/tki_resistance/`

280 espectros infrarrojos de células madre de ratón con la proteína de la leucemia mieloide crónica (normal, mutada o ninguna): ¿se distingue la mutación resistente a los fármacos con la espectroscopía?

Clasificación multiclase | ⋮ Alta dimensionalidad

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
280	**468**	`Cell line`	**0,0 %**	**Avanzado**	**Spectroscopy**

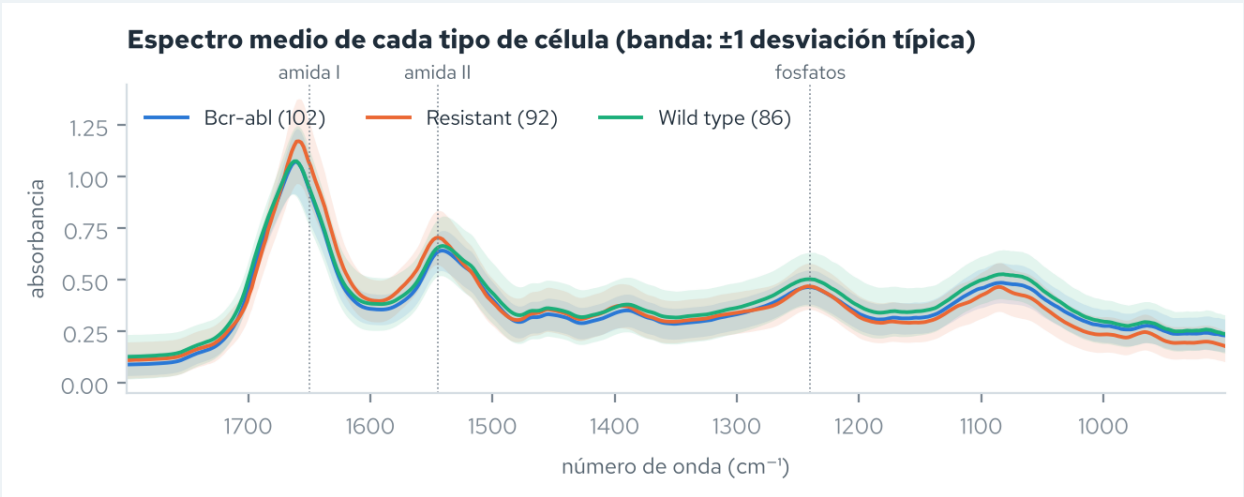
Fichero	Filas × col.	Descargar
`tki_resistance_spectroscopy`	280 × 468	CSV 1,3 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/12_espectroscopia/tki_resistance/` seguido del nombre del fichero CSV.

Radiografía

Cell line en tki_resistance_spectroscopy





1 Descripción general y estudios habituales

Cada fila es el espectro infrarrojo de una célula, medido con radiación de sincrotrón: la absorbancia en 467 números de onda entre 900 y 1.800 cm^{-1} (la «huella dactilar» bioquímica: proteínas, ácidos nucleicos, azúcares y fosfatos). La columna `Cell line` dice qué gen llevan las células.

Estudios habituales: **clasificar** el tipo de célula a partir del espectro, **preprocesar** espectros (corrección de línea base, normalización, derivadas) y **buscar las bandas** que distinguen los grupos.

2 Contexto y fuente original

Es el estudio de Christophe Sandt y colaboradores (2018) en la línea SMIS del sincrotrón SOLEIL (Francia). En la leucemia mieloide crónica, la proteína BCR-ABL está siempre activa; los fármacos inhibidores de tirosina quinasa (TKI) la bloquean, pero la mutación T315I la hace resistente a casi todos. Los autores introdujeron en células madre embrionarias de ratón (mES GS2) un vector vacío, BCR-ABL normal o BCR-ABL con T315I, y midieron células sueltas en transflexión, a 12 × 12 μm^2.

- Sandt, C. et al. (2018). Direct and rapid identification of T315I-mutated BCR-ABL expressing leukemic cells using infrared microspectroscopy. Biochemical and Biophysical Research Communications, 503(3), 1861–1867.

3 Variable objetivo

`Cell line`: `Bcr-abl` (102 células con BCR-ABL normal), `Resistant` (92, con la mutación T315I) y `Wild type` (86; por los vectores del estudio, probablemente las células con el vector vacío). Medido fuera de Orange con *scikit-learn* (regresión logística con los datos estandarizados, validación cruzada de 10 bolsas), se acierta el 92,5 %: las 92 resistentes se reconocen todas, y los errores son entre `Bcr-abl` y `Wild type` (21 células).

4 Diccionario de columnas

Columnas de `tki_resistance_spectroscopy` (valores observados en el fichero)

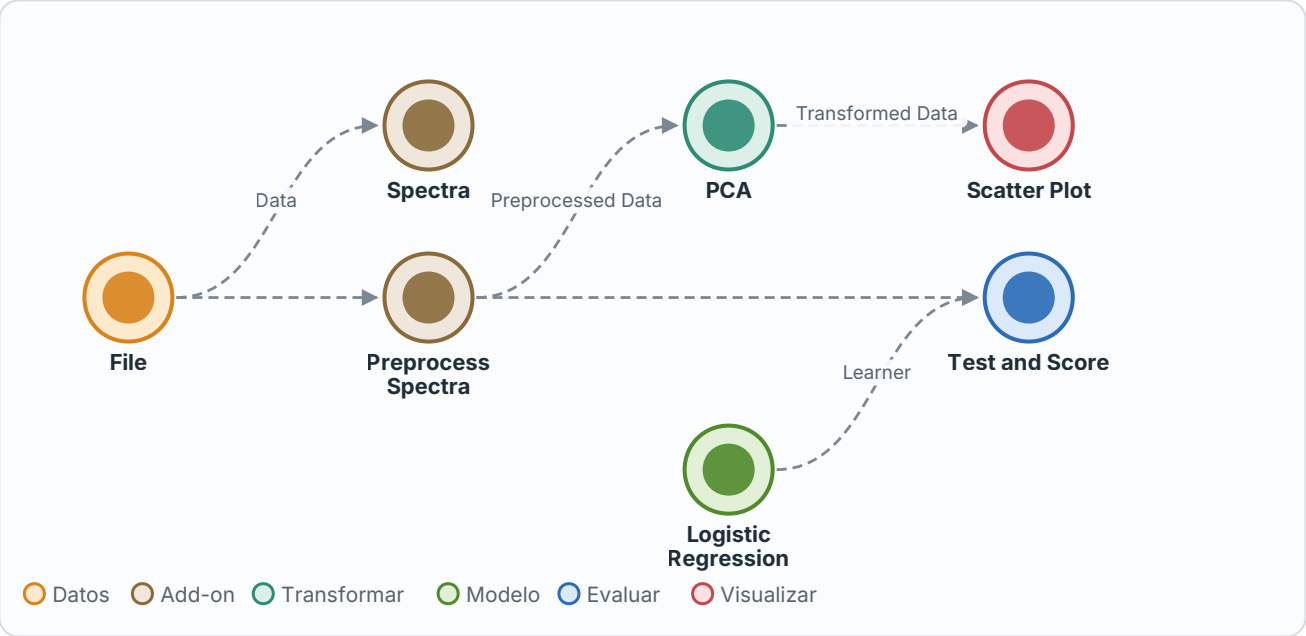
Columna	Tipo	Significado	Valores
1799.323	numérica	Absorbancia a 1.799,3 cm^{-1} (primera columna).	-0,202 – 0,378
`Cell line` objetivo	categórica	Tipo de célula: `Bcr-abl`, `Resistant` (T315I) o `Wild type` (probablemente, vector vacío). Objetivo.	Bcr-abl (102), Resistant (92), Wild type (86)
…		y 466 columnas más: absorbancia en cada número de onda, de 1.799,3 a 900,7 cm^{-1} (paso de unos 1,93 cm^{-1}).	

5 Particularidades técnicas al modelar

- **Una columna fuera de su sitio en el original**: en el fichero de Orange, `1496.553` era la primera columna. Aquí está en su posición, entre `1498.482` y `1494.625` (anotado en el catálogo).
- **Las resistentes se separan demasiado bien**: un acierto perfecto en un grupo puede deberse a la mutación o a diferencias de preparación (cultivo, portaobjetos, día de medida). El artículo comprueba la firma en otra línea celular; con estos datos solo se puede discutir.

- **Preprocesado**: con el add-on *Spectroscopy*, *Preprocess Spectra* ofrece corrección de línea base, normalización (vectorial o por la amida I), derivadas de Savitzky-Golay y recorte de rangos. Normalizar compensa el grosor distinto de cada célula.
- **Muchas columnas muy correlacionadas** (467 números de onda vecinos): usa modelos con regularización, PCA o PLS antes de clasificar.

6 Flujo de trabajo en Orange



1. **File** con `tki_resistance_spectroscopy.csv`, `Cell line` como *target*.
2. **Spectra**: espectros coloreados por tipo de célula.
3. **Preprocess Spectra**: línea base y normalización vectorial (y, si se quiere, segunda derivada).
4. **PCA** → **Scatter Plot** de las dos primeras componentes, coloreado por `Cell line`.
5. **Test and Score** con **Logistic Regression** sobre los espectros preprocesados.

7 Otras consideraciones

- El add-on se llama *Spectroscopy* (en Orange, *Options* → *Add-ons*); sin él, los datos se pueden tratar como una tabla numérica normal, pero no hay widgets de espectros.
- Los datos los recopiló Christophe Sandt (SOLEIL).

En la carpeta `tki_resistance_spectroscopy` ← `TKI-resistance-spectroscopy.tab` (datasets.biolab.si)

12.02
Espectroscopía

Hair (FTIR hiperespectral)

12_espectroscopia/hair_spectroscopy/

Imagen infrarroja de varios cortes de pelo humano (65 × 50 píxeles, un espectro por píxel, de 800 a 4.000 cm^{-1}): separar pelo y fondo y buscar la médula y los lípidos agrupando espectros.

Clustering | Exploración y visualización | Alta dimensionalidad | Espacial

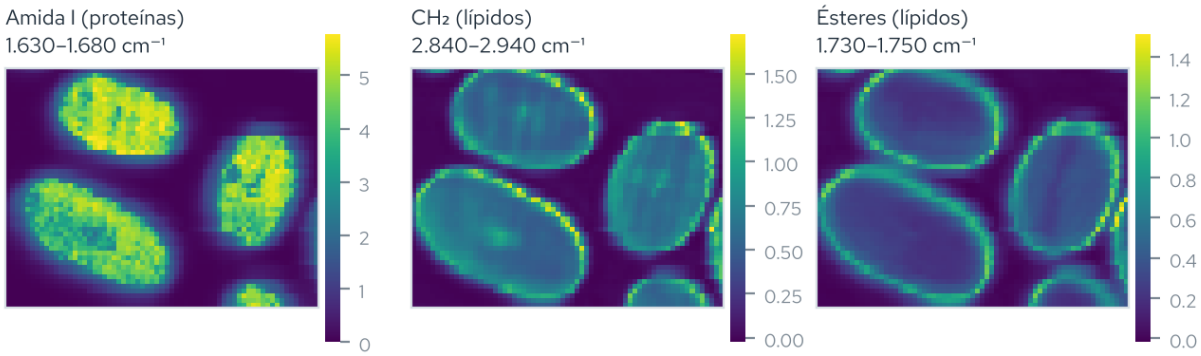
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
3.250	**833**	–	**0,0 %**	**Avanzado**	**Spectroscopy**

Fichero	Filas × col.	Descargar
`hair_spectroscopy`	3.250 × 833	CSV 18,8 MB · XLSX

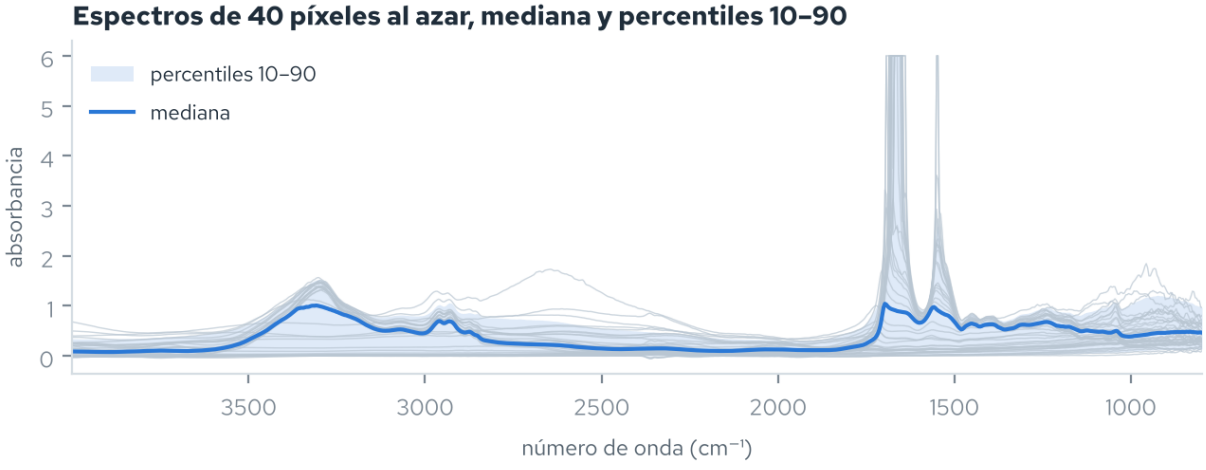
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/12_espectroscopia/hair_spectroscopy/` seguido del nombre del fichero CSV.

Radiografía

Imagen de tres bandas (área media en cada píxel)



Espectros de 40 píxeles al azar, mediana y percentiles 10–90



1 Descripción general y estudios habituales

Es una **imagen hiperespectral** de cortes transversales de pelo (en el mapa se ven unos cuatro, algunos cortados por el borde): cada fila es un píxel, con su posición (`map_x`, `map_y`, de 3 en 3) y su espectro infrarrojo completo (831 números de onda entre 798 y 4.000 cm^{-1}). Hay 3.250 píxeles en una rejilla de 65 × 50, que incluye los cortes y el fondo de alrededor.

Estudios habituales: **dibujar la imagen** de bandas de proteínas (queratina) y de lípidos, **separar el pelo del fondo**, **agrupar** píxeles para encontrar la médula (el canal central del pelo) y **comparar** su espectro con el de la corteza.

2 Contexto y fuente original

Los datos son del estudio de Christophe Sandt y Ferenc Borondics (2021) sobre la composición química del pelo humano, centrado en la médula, medido con microespectroscopía FTIR de sincrotrón (SOLEIL) sobre ventanas de ZnS, en transmisión. Según el artículo, la médula tiene de 3 a 20 veces más lípidos que la corteza que la rodea, y los autores proponen clasificar las médulas en cuatro o cinco grupos según su composición lipídica.

- Sandt, C. y Borondics, F. (2021). A new typology of human hair medullas based on lipid composition analysis by synchrotron FTIR microspectroscopy. Analyst, 146, 3942–3954.

3 Variable objetivo

No hay variable objetivo: es un problema no supervisado. Hay que separar primero el fondo (unos 1.400 píxeles, el 43 %, tienen la amida I por debajo de 0,5) y después distinguir dentro de cada corte la corteza, rica en proteínas, de la médula, donde se concentran los lípidos.

En las imágenes de las bandas de lípidos sin preprocesar, lo que más destaca es el borde de cada corte, no el centro: para ver la médula hace falta normalizar (por ejemplo, a la amida I) y agrupar.

4 Diccionario de columnas

Columnas de `hair_spectroscopy` (valores observados en el fichero)

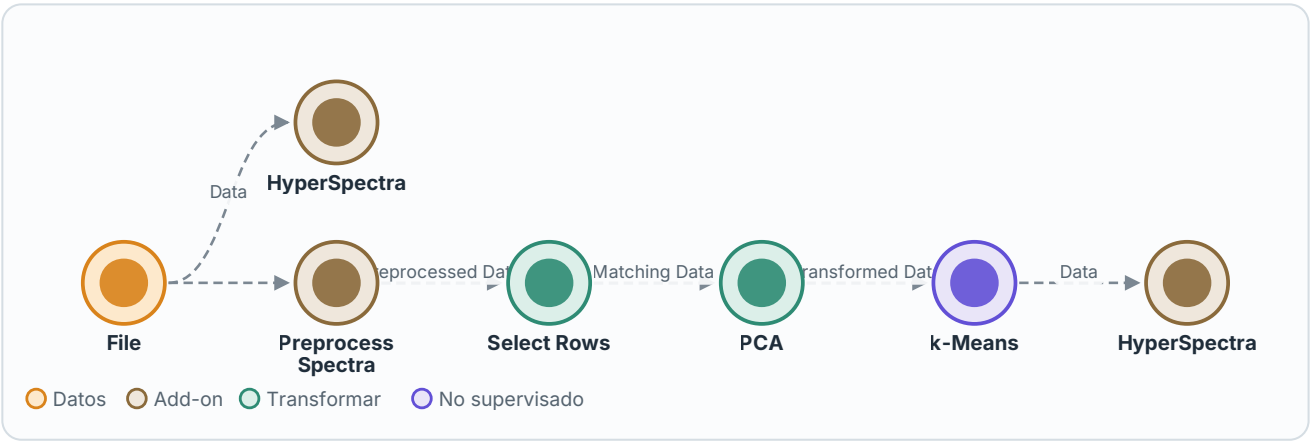
Columna	Tipo	Significado	Valores
`798.40`	numérica	Absorbancia a 798,4 cm^{-1} (primera columna).	-0,005 – 6
`map_x`	numérica	Posición horizontal del píxel en el mapa (de 3 en 3).	20 – 212
`map_y`	numérica	Posición vertical del píxel en el mapa (de 3 en 3).	18 – 165
…		y 830 columnas más: absorbancia en cada número de onda, hasta 3.999,7 cm^{-1} (paso de unos 3,86 cm^{-1}).	

5 Particularidades técnicas al modelar

- **Absorbancia saturada**: los valores tienen un tope de 6,0, y 1.103 píxeles llegan a él en algún número de onda, sobre todo en la amida I (1.635–1.697 cm^{-1}) y en el extremo de 798–883 cm^{-1}. En esos tramos la señal está cortada: recórtalos o usa otras bandas.
- **Fondo**: unos 1.400 píxeles apenas absorben (fuera del pelo). Quítalos antes de agrupar, por ejemplo con *Select Rows* sobre una banda de proteínas.

- **Valores negativos** (el 8 % de las celdas, muy cerca de 0): ruido en el fondo tras restar la referencia.
- `map_x` **y** `map_y` entran como atributos al abrir el CSV: ponlos como *meta*.
- **Fichero grande para Orange**: 3.250 × 833. *HyperSpectra* y *PCA* van bien; *Hierarchical Clustering* sobre todos los píxeles es lento (usa *k-Means*).

6 Flujo de trabajo en Orange



1. **File** con `hair_spectroscopy.csv`: `map_x` y `map_y` como *meta*.
2. **HyperSpectra**: imagen de la amida I (dónde está el pelo) y de la banda de lípidos (dónde está la médula).
3. **Preprocess Spectra**: recorta los tramos saturados, corrige la línea base y normaliza.
4. **Select Rows** para quitar el fondo → **PCA** → **k-Means** (3 o 4 grupos) → **HyperSpectra** coloreando por grupo.

7 Otras consideraciones

- Para ver la médula, la banda de los lípidos (CH_2 hacia 2.850 y 2.920 cm^{-1}, ésteres hacia 1.740) es la más clara.
- Es un pelo de una persona, pero no hay ningún dato personal: solo la química del corte.

En la carpeta `hair_spectroscopy` ← `hair-spectroscopy.tab` (datasets.biolab.si)

12.03
Espectroscopía

Liver cirrhosis (FTIR hiperespectral)

`12_espectroscopia/liver_cirrhosis/`

Imagen infrarroja de un corte de hígado con cirrosis (49 × 22 píxeles, un espectro por píxel): agrupar espectros para separar los nódulos del tejido fibroso, sin etiquetas.

Clustering · Exploración y visualización · Alta dimensionalidad · Espacial

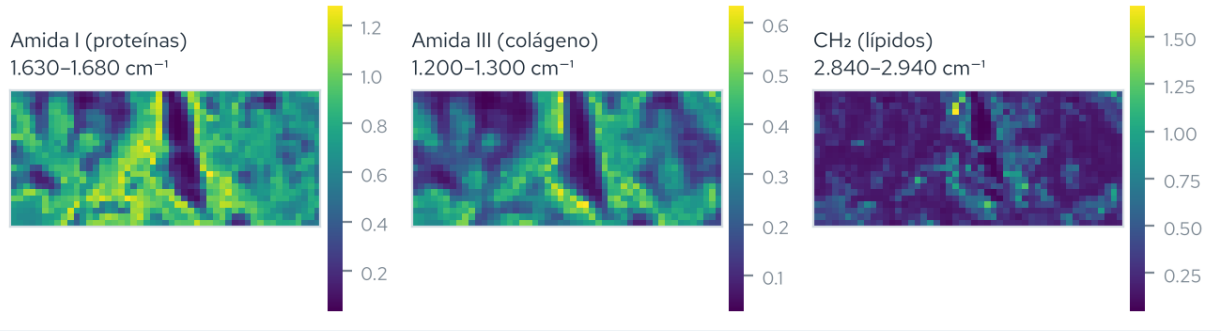
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
1.078	**546**	–	**0,0 %**	**Avanzado**	**Spectroscopy**

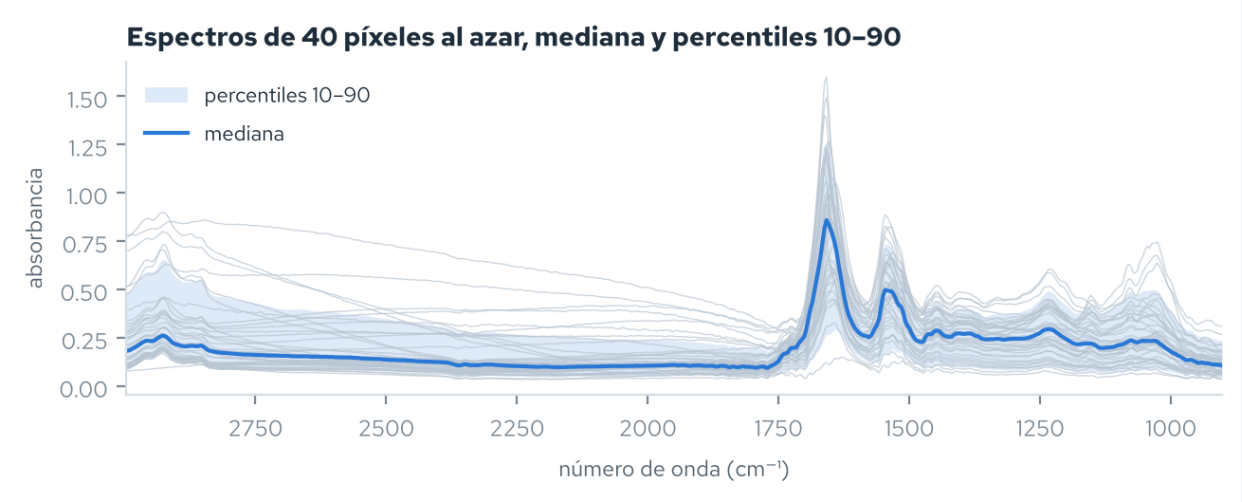
Fichero	Filas × col.	Descargar
`liver_cirrhosis`	1.078 × 546	CSV 3,5 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/12_espectroscopia/liver_cirrhosis/` seguido del nombre del fichero CSV.

Radiografía

Imagen de tres bandas (área media en cada píxel)





1 Descripción general y estudios habituales

Es una **imagen hiperespectral**: cada fila es un píxel de 8 × 8 µm² de un corte de hígado, con su posición (`map_x` , `map_y`) y su espectro infrarrojo (544 números de onda entre 903 y 2.997 cm⁻¹). Hay 1.078 píxeles en una rejilla de 49 × 22, sin huecos.

Estudios habituales: **dibujar la imagen** de una banda o de un compuesto (proteínas, lípidos, colágeno), **agrupar** los píxeles por su espectro y ver los grupos sobre el mapa, y **reducir dimensiones** con PCA.

2 Contexto y fuente original

En la cirrosis, partes del hígado quedan aisladas en nódulos rodeados de tejido fibroso rico en colágeno. Este mapa se tomó en la intersección de varios nódulos, con FTIR en transflexión sobre un corte de 10 µm de grosor. La imagen la adquirió Christophe Sandt (sincrotrón SOLEIL); la ficha de Orange no cita publicación.

- Orange Data Mining. Liver cirrhosis – spectral image (datasets.biolab.si, 2018; datos de C. Sandt).

3 Variable objetivo

No hay variable objetivo: es un problema no supervisado. La pregunta es si los espectros separan por sí solos el tejido de los nódulos del tejido fibroso que los rodea, y qué bandas los distinguen.

4 Diccionario de columnas

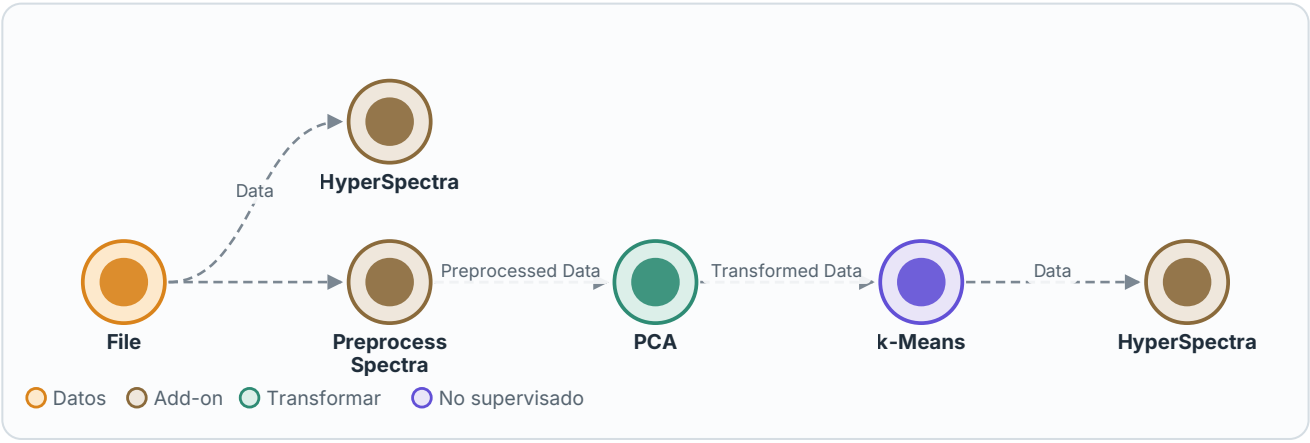
Columnas de `liver_cirrhosis` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`902.537`	numérica	Absorbancia a 902,5 cm⁻¹ (primera columna).	0,029 – 0,413
`map_x`	numérica	Posición horizontal del píxel en el mapa (µm, de 8 en 8).	-211,302 – 172,698
`map_y`	numérica	Posición vertical del píxel en el mapa (µm, de 8 en 8).	-62,666 – 105,334
…		y 543 columnas más: absorbancia en cada número de onda, hasta 2.996,9 cm⁻¹ (paso de unos 3,86 cm⁻¹).	

5 Particularidades técnicas al modelar

- `map_x` y `map_y` **no son espectro**: al abrir el CSV entran como atributos numéricos. Ponlos como *meta* antes de agrupar o de hacer PCA; si no, la posición pesa en las distancias.
- **Imagen y no tabla**: con el add-on *Spectroscopy*, *HyperSpectra* dibuja la imagen a partir de `map_x` y `map_y` y permite elegir una banda o un píxel.
- **Sin la zona de 2.000 a 2.800 cm^{-1} no hay información**: es una región sin bandas biológicas; recórtala antes de agrupar.
- **Preprocesado**: corrección de línea base y normalización (por ejemplo, a la amida I) para que el grosor del corte no domine las diferencias.

6 Flujo de trabajo en Orange



1. **File** con `liver_cirrhosis.csv`: `map_x` y `map_y` como *meta*.
2. **HyperSpectra**: imagen de la amida I y de la región del colágeno.
3. **Preprocess Spectra**: recorte a 900–1.800 y 2.800–3.000 cm^{-1}, línea base y normalización.
4. **PCA** (unas 10 componentes) → **k-Means** con 2 a 4 grupos → **HyperSpectra** coloreando por el grupo: ¿coinciden con nódulos y fibras?

7 Otras consideraciones

- Es la imagen hiperespectral más pequeña de este capítulo (la de *Hair* tiene tres veces más píxeles): se procesa en segundos.
- Para enlazarlo con *Liver spectroscopy*: ese conjunto tiene espectros etiquetados por compuesto (colágeno, glucógeno, lípidos, ADN) que ayudan a interpretar los grupos.

En la carpeta `liver_cirrhosis` ← `liver-cirrhosis.tab` (datasets.biolab.si)

12.04
Espectroscopía

Liver cells (FTIR)

12_espectroscopia/liver_spectroscopy/

731 espectros infrarrojos de zonas de tejido de hígado, etiquetados por el compuesto que domina (colágeno, glucógeno, lípidos o ADN): clasificación de espectros fácil y bien separada.

Clasificación multiclase

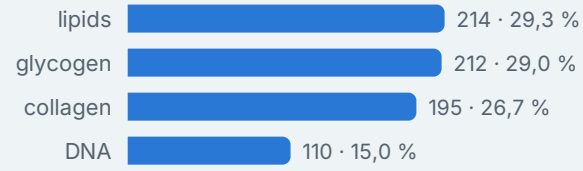
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
731	**235**	`type`	**0,0 %**	**Intermedio**	**Spectroscopy**

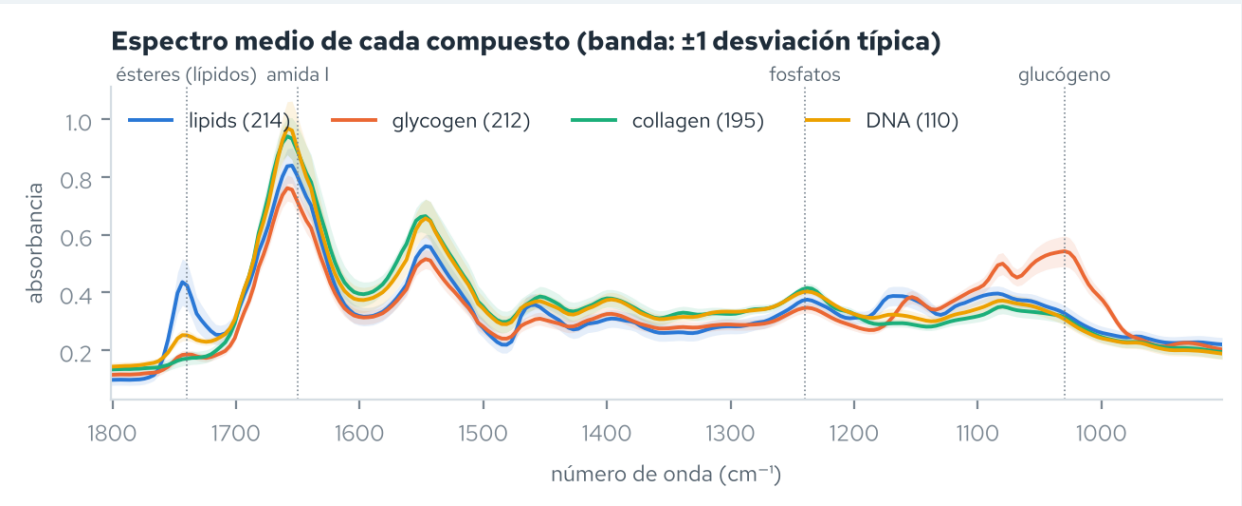
Fichero	Filas × col.	Descargar
`liver_spectroscopy`	731 × 235	CSV 1,0 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/12_espectroscopia/liver_spectroscopy/` seguido del nombre del fichero CSV.

Radiografía

type en liver_spectroscopy





1 Descripción general y estudios habituales

Cada fila es un espectro infrarrojo (FTIR) de una zona de una célula o del tejido de hígado, con la absorbancia en 234 números de onda entre 902 y 1.801 cm^{-1}, y una etiqueta con el compuesto químico mayoritario en esa zona.

Estudios habituales: **clasificar** el compuesto a partir del espectro, **relacionar bandas con moléculas** (por qué el glucógeno, los lípidos o el colágeno se ven distintos) y **explicar el modelo** viendo qué números de onda pesan más.

2 Contexto y fuente original

Los datos los recopiló Christophe Sandt (sincrotrón SOLEIL) y están en Orange desde 2017. La ficha de Orange no cita publicación. Es un conjunto de enseñanza: con espectros etiquetados por su componente principal, la relación entre bandas y moléculas se ve muy bien.

- Orange Data Mining. Liver spectroscopy (datasets.biolab.si, 2017; datos de C. Sandt).

3 Variable objetivo

`type`: `lipids` (214), `glycogen` (212), `collagen` (195) y `DNA` (110). Es una tarea muy fácil: medido fuera de Orange con *scikit-learn* (validación cruzada de 10 bolsas), la regresión logística acierta el 98,6 % y el bosque aleatorio el 98,5 %. Los pocos errores son sobre todo entre `DNA` y `collagen`.

4 Diccionario de columnas

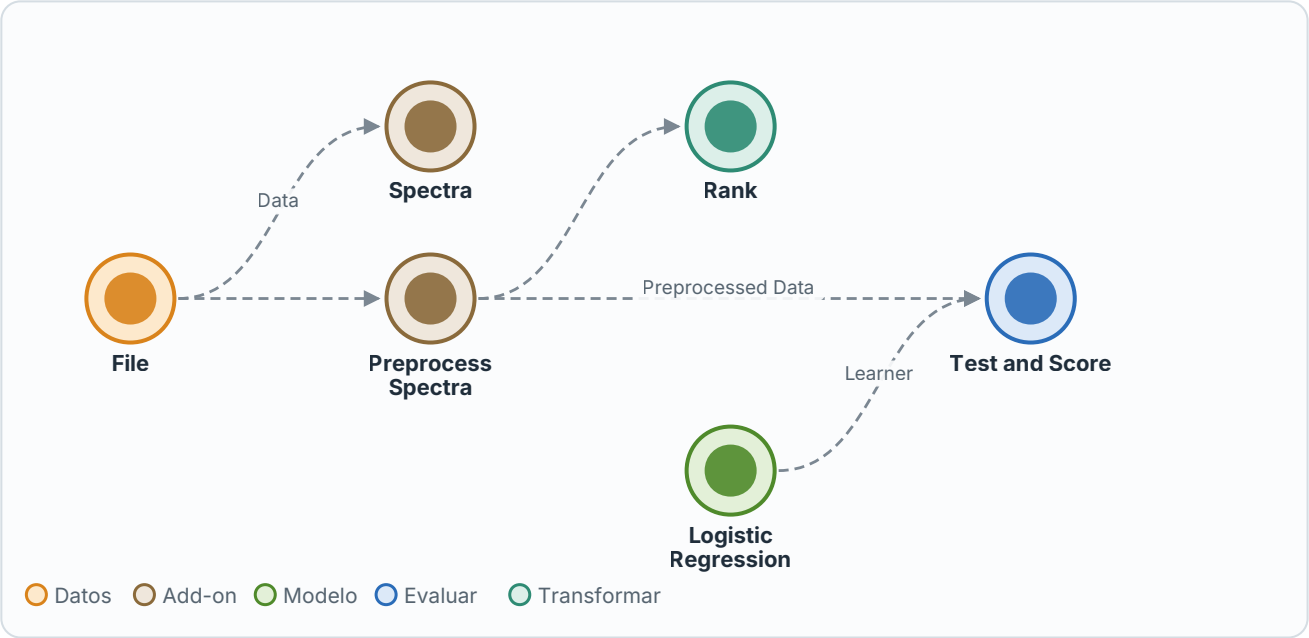
Columnas de `liver_spectroscopy` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
1801.264	numérica	Absorbancia a 1.801,3 cm^{-1} (primera columna).	0,046 – 0,166
type `objetivo`	categórica	Compuesto mayoritario en la zona medida: `collagen`, `glycogen`, `lipids` o `DNA`. Objetivo.	lipids (214), glycogen (212), collagen (195), DNA (110)
…		y 233 columnas más: absorbancia en cada número de onda, de 1.801,3 a 902,6 cm^{-1} (paso de unos 3,86 cm^{-1}).	

5 Particularidades técnicas al modelar

- **Etiquetas por compuesto mayoritario**: cada espectro mezcla varios compuestos; la etiqueta dice cuál domina, no que sea el único.
- **Bandas que lo explican**: los lípidos absorben a unos 1.740 cm^{-1} (ésteres), el glucógeno entre 1.000 y 1.100, el ADN hacia 1.240 y 1.080 (fosfatos) y el colágeno tiene un patrón propio en la amida III (1.200–1.300).
- **Preprocesado**: *Preprocess Spectra* con normalización (vectorial o a la amida I) antes de comparar grupos.
- **Columnas correlacionadas**: 234 números de onda vecinos; PCA o modelos regularizados funcionan bien.

6 Flujo de trabajo en Orange



1. **File** con `liver_spectroscopy.csv`, `type` como *target*.
2. **Spectra** coloreado por `type`: busca las bandas que cambian entre compuestos.
3. **Preprocess Spectra** (línea base y normalización) → **Test and Score** con **Logistic Regression**.
4. **Rank**: qué números de onda separan mejor los compuestos; compáralos con las bandas de la sección 5.

7 Otras consideraciones

- Es un buen primer ejercicio de espectroscopía: se aprende a leer espectros antes de pasar a imágenes hiperespectrales (*Liver cirrhosis*, *Hair*).

En la carpeta `liver_spectroscopy` ← `liver-spectroscopy.tab` (datasets.biolab.si)

13 Expresión génica (bulk)

4 datasets en el capítulo; en esta edición, 4 con ficha.

13.01
Expresión génica (bulk)

GDS360: resistencia a docetaxel en cáncer de mama

`13_expresion_genica/gds360/`

Expresión de 9.485 genes en biopsias de 24 pacientes con cáncer de mama, sensibles o resistentes al docetaxel: el caso típico de «muchos más genes que pacientes».

Clasificación binaria · ⋮ Alta dimensionalidad · ∘ Juguete

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
24	**9.486**	`disease state`	**0,0 %**	**Avanzado**	**Bioinformatics**

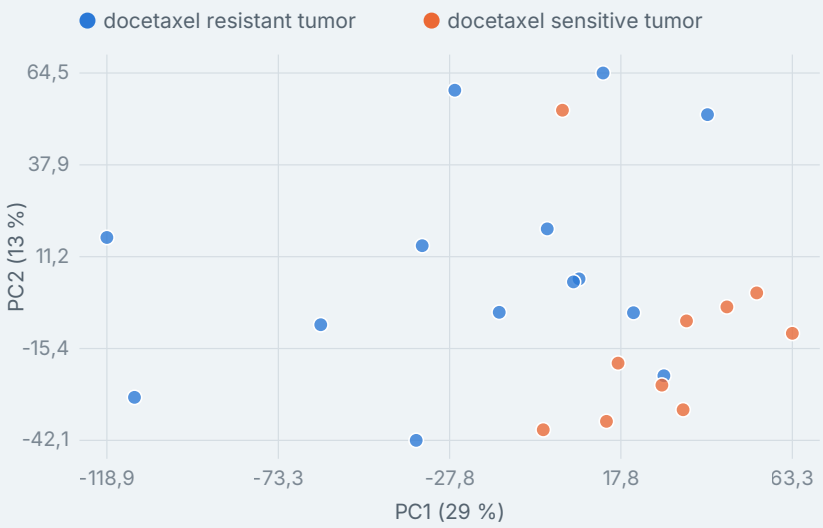
Fichero	Filas × col.	Descargar
`gds360`	24 × 9.486	CSV 1,7 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/13_expresion_genica/gds360/` seguido del nombre del fichero CSV.

Radiografía

disease state en gds360





1 Descripción general y estudios habituales

Cada fila es una biopsia de un tumor de mama tomada antes del tratamiento con docetaxel (un quimioterápico), con la expresión de 9.485 genes medida con un microarray de Affymetrix. La columna `disease state` dice si el tumor respondió: sensible (menos del 25 % de tumor residual) o resistente (más del 25 %).

Estudios habituales: **predecir la respuesta** al fármaco con la expresión, **seleccionar genes** que distinguen las dos clases y **visualizar** las muestras (PCA, agrupamiento jerárquico, mapas de calor).

2 Contexto y fuente original

Es el conjunto GDS360 de Gene Expression Omnibus (GEO), del estudio de Jenny Chang y colaboradores (Baylor College of Medicine), que buscaron un perfil de expresión que predijera la respuesta al docetaxel en cáncer de mama localmente avanzado. Orange lo descarga de GEO con el add-on *Bioinformatics* (widget *GEO Data Sets*).

- Chang, J. C. et al. (2005). Patterns of resistance and incomplete response to docetaxel by gene expression profiling in breast cancer patients. Journal of Clinical Oncology, 23(6), 1169–1177. Datos: NCBI GEO, GDS360.

3 Variable objetivo

`disease state`: `docetaxel resistant tumor` (14) y `docetaxel sensitive tumor` (10). Con solo 24 muestras, el acierto que se mida variará mucho de una partición a otra.

Medido fuera de Orange con *scikit-learn* (expresión en $\log_2$, validación cruzada de 5 bolsas repetida 10 veces), la regresión logística regularizada acierta el 79 % y el bosque aleatorio el 85 %, frente al 58 % de la clase mayoritaria.

4 Diccionario de columnas

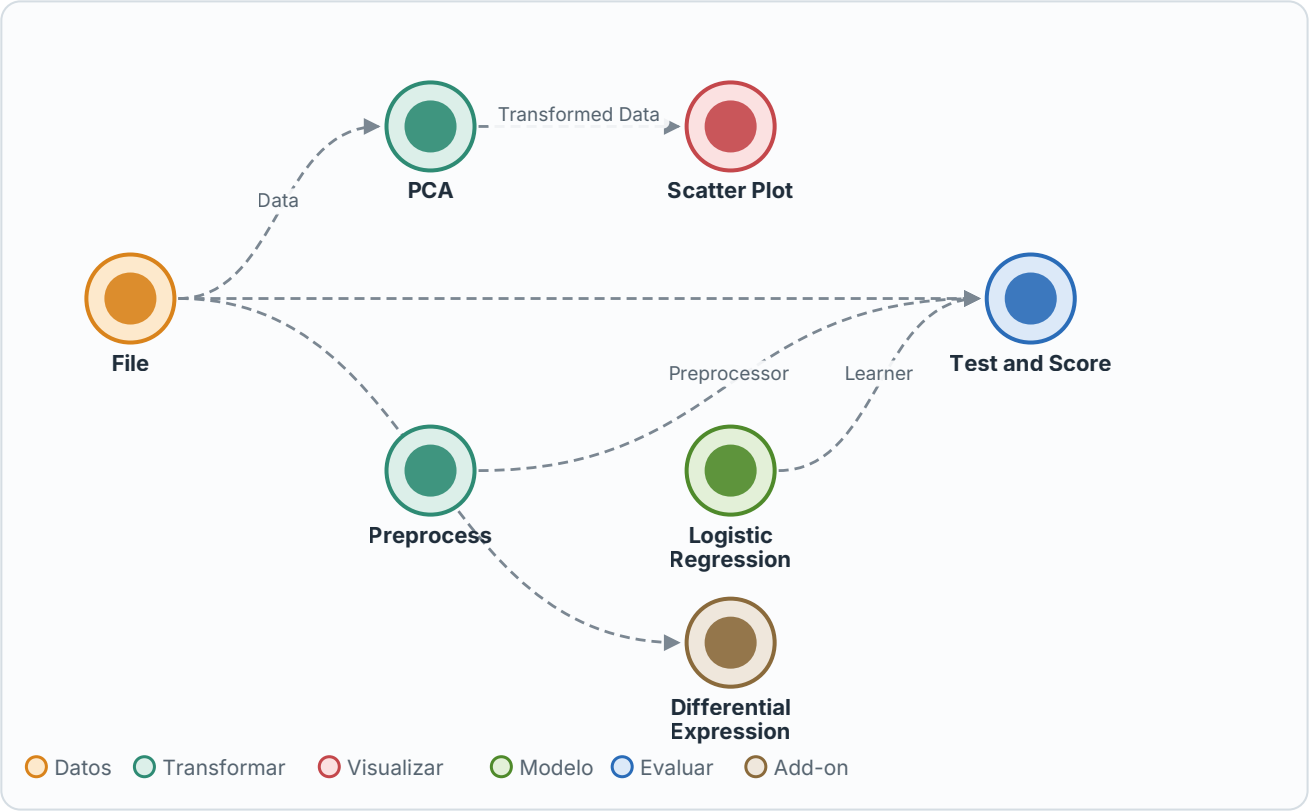
Columnas de `gds360` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`--Control`	numérica	Columna sin gen asociado; probablemente agrupa las sondas de control del chip. No es un gen: quítala.	403,512 – 995,558
`1949_at`	numérica	Ejemplo de sonda de Affymetrix sin símbolo de gen (hay 85 columnas así).	5,898 – 27,434
`disease state` objetivo	categórica	Respuesta al docetaxel: `docetaxel resistant tumor` o `docetaxel sensitive tumor`. Objetivo.	docetaxel resistant tumor (14), docetaxel sensitive tumor (10)
…		y 9.483 columnas más: expresión de cada gen (símbolo del gen o, si no lo tiene, identificador de la sonda de Affymetrix).	

5 Particularidades técnicas al modelar

- **Muchas más columnas que filas** (9.485 genes, 24 muestras): cualquier modelo puede memorizar las muestras. Hay que regularizar, reducir dimensiones o seleccionar pocos genes.
- **Selección de genes dentro de la validación**: si eliges los 50 mejores genes con todos los datos y luego validas, el acierto sube del 79 % al 92 %, pero es una fuga. En Orange, pon el selector (*Preprocess* con *Select relevant features*) dentro de *Test and Score*, no antes.
- **Escala original**: las intensidades van de 6 a 9.342; conviene pasar a $\log_2$ (con *Python Script* o antes de cargar el fichero) antes de comparar genes.
- **La primera componente principal separa casi las dos clases** (29 % de la varianza) y las resistentes tienen una mediana de expresión algo menor. Puede ser biología o diferencias en el procesado de las muestras; con estos datos no se puede saber.
- **Filas ordenadas por clase** (primero las 14 resistentes): no uses particiones sin barajar.
- **6 genes constantes** y la columna `--Control`, que no es un gen.

6 Flujo de trabajo en Orange



1. **File** con `gds360.csv`, `disease state` como *target*; quita `--Control`. (O carga GDS360 directamente con **GEO Data Sets**.)
2. **PCA** → **Scatter Plot** coloreado por la respuesta.
3. **Test and Score** con **Logistic Regression** y, como *Preprocessor*, **Preprocess** con selección de los 50 genes más relevantes: así la selección se repite en cada partición.
4. **Differential Expression** (add-on *Bioinformatics*) para ver qué genes cambian más entre clases.

7 Otras consideraciones

- **Comparación honesta**: haz la selección fuera y dentro de la validación y compara; es el mejor ejemplo del libro para explicar la fuga por selección de atributos.

En la carpeta `gds360` ← `GDS360.tab` (datasets.biolab.si)

13.02
Expresión génica (bulk)

GDS3713: linfocitos B de fumadores

`13_expresion_genica/gds3713/`

Expresión de 3.000 genes elegidos al azar en linfocitos B de 79 mujeres, fumadoras o no: clasificación binaria con clases equilibradas y muchos más genes que muestras.

Clasificación binaria · ⋮ Alta dimensionalidad · ◦ Juguete

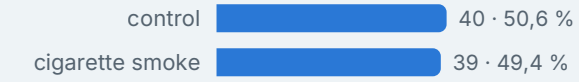
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
79	**3.001**	`stress`	**0,0 %**	**Intermedio**	**Bioinformatics**

Fichero	Filas × col.	Descargar
`gds3713_small`	79 × 3.001	CSV 1,8 MB · XLSX

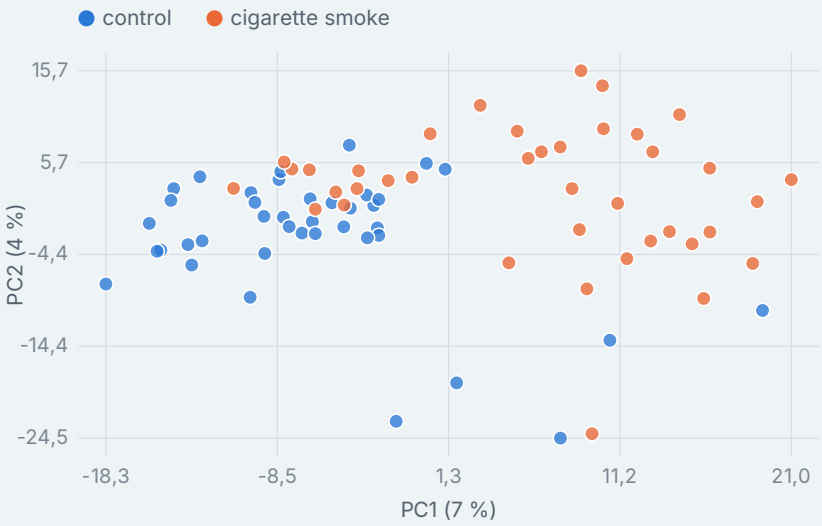
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/13_expresion_genica/gds3713/` seguido del nombre del fichero CSV.

Radiografía

stress en gds3713_small



PCA de las 79 muestras (log_2)



1 Descripción general y estudios habituales

Cada fila es una muestra de linfocitos B de sangre periférica de una mujer sana, blanca, de Estados Unidos: 39 fumadoras y 40 no fumadoras. Las columnas son la expresión de 3.000 genes medida con un microarray de Affymetrix y la columna `stress`, que dice si la persona fuma.

Estudios habituales: **clasificar** fumadoras y no fumadoras, **seleccionar genes** asociados al tabaco y **comparar** la selección dentro y fuera de la validación cruzada.

2 Contexto y fuente original

El estudio es de Feng Pan, Hong-Wen Deng y colaboradores (Creighton University, 2010), que compararon con el microarray HG-U133A los perfiles de expresión de los linfocitos B de fumadoras y no fumadoras (GEO: GSE18723, conjunto GDS3713). Orange conservó solo **3.000 genes elegidos al azar** de los del chip para que el fichero sea pequeño (de ahí el nombre `small`).

- Pan, F. et al. (2010). Impact of female cigarette smoking on circulating B cells in vivo: the suppressed ICOSLG, TCF3, and VCAM1 gene functional network may inhibit normal cell function. Immunogenetics, 62(4), 237–251. Datos: NCBI GEO, GDS3713.

3 Variable objetivo

`stress`: `control` (40, no fumadoras) y `cigarette smoke` (39, fumadoras). Clases casi perfectamente equilibradas.

Medido fuera de Orange con *scikit-learn* (expresión en $\log_2$, validación cruzada de 5 bolsas repetida 10 veces), la regresión logística regularizada acierta el 90 %, el bosque aleatorio el 82 % y kNN el 77 %. Es mucho para un efecto que se esperaría sutil: ver la sección 5.

4 Diccionario de columnas

Columnas de `gds3713_small` (valores observados en el fichero)

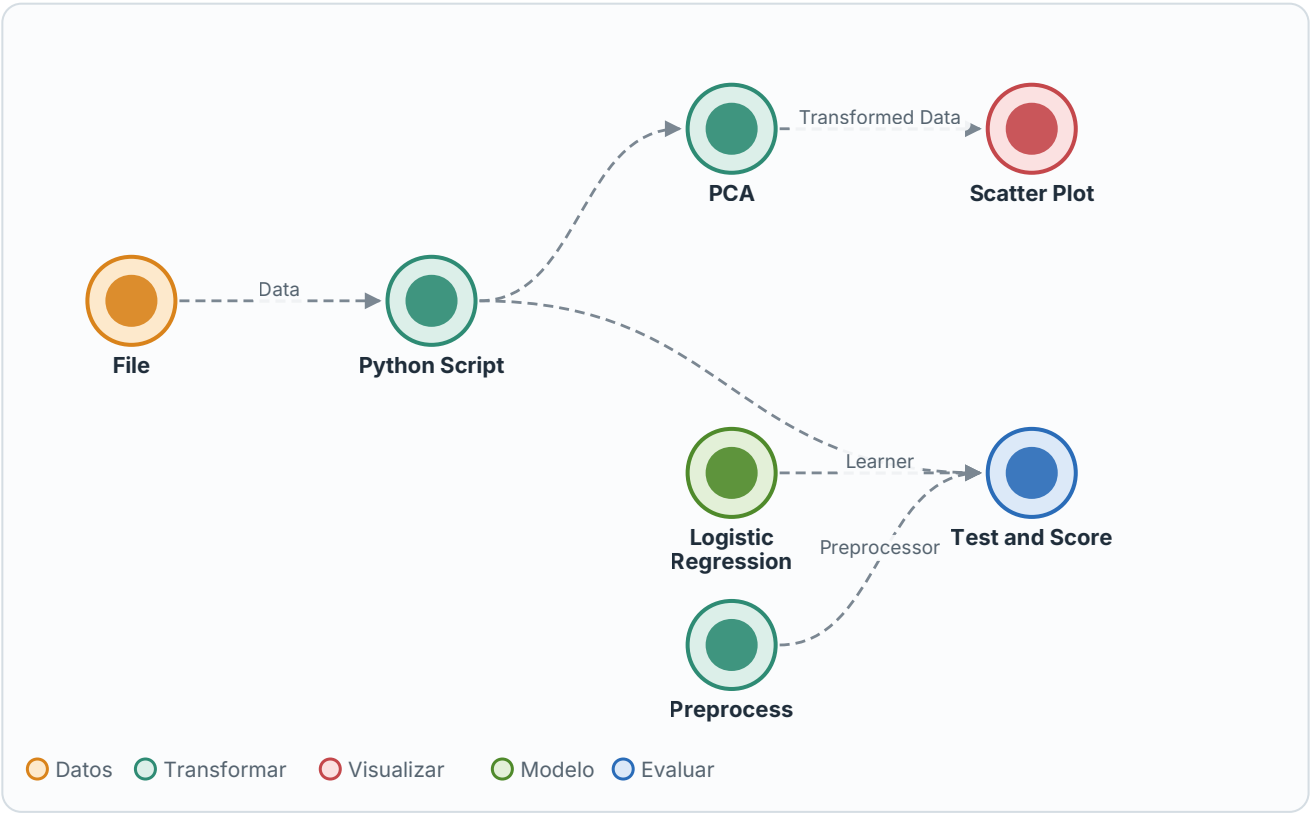
Columna	Tipo	Significado	Valores
`--Control`	numérica	Columna sin gen asociado; probablemente agrupa las sondas de control del chip. No es un gen: quítala.	1.290,193 – 3.852,206
`stress` objetivo	categórica	Exposición: `cigarette smoke` (fumadora) o `control` (no fumadora). Objetivo.	control (40), cigarette smoke (39)
…		y 2.999 columnas más: expresión de cada gen (símbolo del gen o identificador de la sonda de Affymetrix), intensidad en escala original.	

5 Particularidades técnicas al modelar

- **Diferencia global entre grupos**: con 3.000 genes al azar, 249 tienen p < 0,001 en una prueba t (por azar se esperarían 3), la mediana de expresión por muestra es algo menor en las fumadoras y la primera componente principal ya separa los dos grupos. La diferencia se mantiene tras normalizar cada muestra (por mediana o por cuantiles). Puede ser un efecto real del tabaco o una diferencia de procesado entre grupos (por ejemplo, de lote); los datos no traen la fecha ni el lote de cada chip para comprobarlo.
- **Fuga por selección de genes**: elegir los 50 mejores genes con todas las muestras y validar después da un 92 %; hacerlo dentro de cada partición, un 83 %. En Orange, la selección va como *Preprocessor* de *Test and Score*.
- **Escala original**: intensidades de 0,5 a 56.361; pasa a $\log_2$ antes de comparar genes o calcular distancias (con *Python Script* o antes de cargar el fichero).
- **Filas ordenadas por clase** (primero las 39 fumadoras).

- **Genes al azar**: no están los genes que el artículo destaca necesariamente; no sirve para reproducir sus listas.

6 Flujo de trabajo en Orange



1. **File** con `gds3713_small.csv`, `stress` como *target*, sin `--Control`.
2. **Python Script**: pasa todos los genes a $\log_2$ (una línea con `numpy.log2`; *Feature Constructor* obligaría a crear 3.000 columnas a mano).
3. **PCA** → **Scatter Plot** coloreado por `stress`.
4. **Test and Score** con **Logistic Regression**, primero con todos los genes y después con **Preprocess** (50 genes más relevantes) como *Preprocessor*.

7 Otras consideraciones

- Junto con *GDS360*, sirve para enseñar que un buen acierto con microarrays no basta: hay que preguntarse si el efecto es biológico o técnico.

En la carpeta `gds3713_small` ← `GDS3713-small.tab` (datasets.biolab.si)

13.03
Expresión génica (bulk)

GDS4168: linfocitos B en leucemia linfática crónica

13_expresion_genica/gds4168/

Expresión de 16.465 genes en linfocitos B de 41 pacientes con leucemia linfática crónica y 11 personas sanas: separar enfermos y sanos es fácil; lo interesante es qué genes lo explican.

Clasificación binaria · Alta dimensionalidad · Juguete

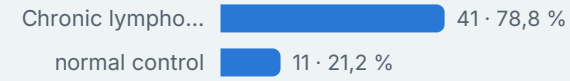
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
52	**16.468**	`class`	**0,0 %**	**Intermedio**	**Bioinformatics**

Fichero	Filas × col.	Descargar
`gds4168`	52 × 16.468	CSV 5,2 MB · XLSX XLSX recortado a 16.384 columnas

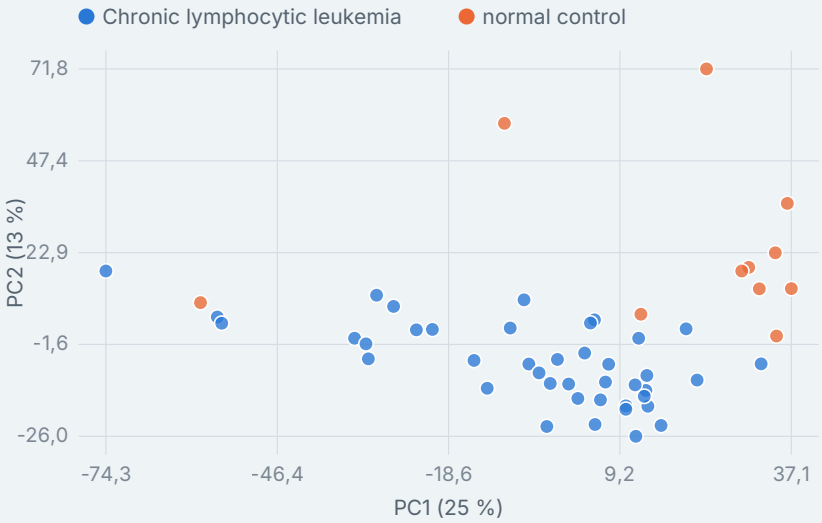
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/13_expresion_genica/gds4168/` seguido del nombre del fichero CSV.

Radiografía

class en gds4168



PCA de las 52 muestras (log_2)



1 Descripción general y estudios habituales

Cada fila es una muestra de linfocitos B de sangre periférica: 41 de pacientes con leucemia linfática crónica (LLC, la leucemia más frecuente en adultos de países occidentales) y 11 de personas sanas. Las columnas son

la expresión de 16.465 genes (en $\log_2$) más la clase, el identificador de la muestra en GEO y una copia de la clase.

Estudios habituales: **clasificar** LLC frente a sanos, **buscar genes diferenciales** (expresión diferencial, enriquecimiento de rutas) y **visualizar** con PCA o mapas de calor.

2 Contexto y fuente original

Es el conjunto GDS4168 de Gene Expression Omnibus, del estudio de Alejandro Gutiérrez y colaboradores (Clínica Mayo, 2010) sobre el gen LEF-1 como factor de supervivencia en la LLC y en su fase previa (linfocitosis B monoclonal).

- Gutierrez, A. Jr. et al. (2010). LEF-1 is a prosurvival factor in chronic lymphocytic leukemia and is expressed in the preleukemic state of monoclonal B-cell lymphocytosis. Blood, 116(16), 2975–2983. Datos: NCBI GEO, GDS4168.

3 Variable objetivo

`class`: `Chronic lymphocytic leukemia` (41) y `normal control` (11). Las clases están desequilibradas (79 % de LLC). Es una tarea fácil: medido fuera de Orange con *scikit-learn* (validación cruzada de 5 bolsas repetida 10 veces), la regresión logística regularizada acierta el 98 % y el bosque aleatorio el 98 %. Mira mejor la sensibilidad para los sanos, que son pocos.

Genes conocidos de la LLC salen como se espera: `CD5` (5,95 frente a 4,03 en $\log_2$) y `ROR1` (6,28 frente a 4,27) están más expresados en los enfermos.

4 Diccionario de columnas

Columnas de `gds4168` (valores observados en el fichero)

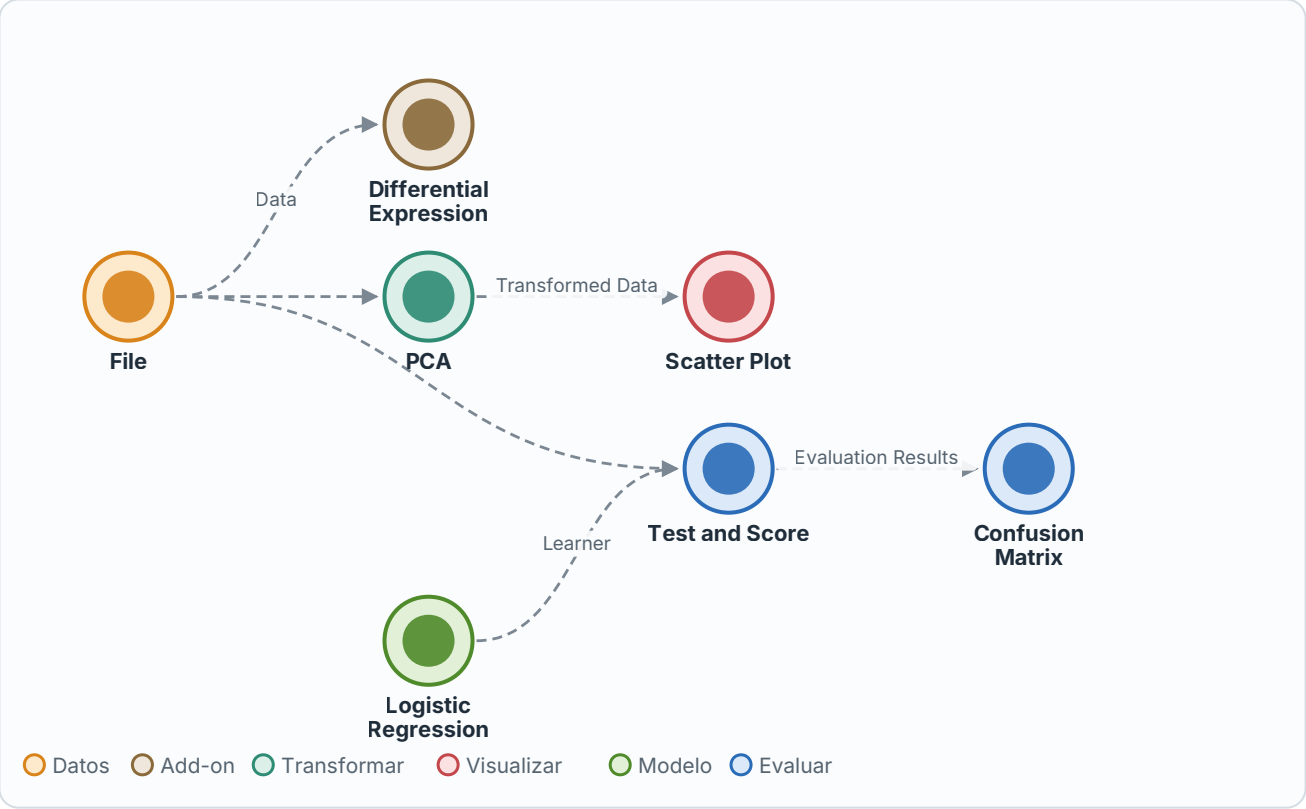
Columna	Tipo	Significado	Valores
`--Control`	numérica	Columna sin gen asociado; probablemente agrupa las sondas de control del chip. No es un gen: quítala.	6,34 – 7,915
`class` objetivo	categórica	Grupo: `Chronic lymphocytic leukemia` o `normal control`. Objetivo.	Chronic lymphocytic leukemia (41), normal control (11)
`sample_id`	texto	Identificador de la muestra en GEO (`GSM559433` …), meta.	GSM559433 (1), GSM559434 (1), GSM559436 (1), GSM559437 (1), GSM559438 (1), GSM559440 (1) …
`disease state`	texto	Copia exacta de `class` (meta). Si se usa como atributo, es una fuga.	Chronic lymphocytic leukemia (41), normal control (11)
…		y 16.464 columnas más: expresión en $\log_2$ de cada gen (símbolo del gen o identificador de la sonda de Affymetrix).	

5 Particularidades técnicas al modelar

- **Más de 16.384 columnas**: el XLSX está recortado a las primeras 16.384 (el límite de Excel); el CSV tiene todas.

- `disease state` **repite la clase**: en el fichero de Orange es *meta*, pero al abrir el CSV puede entrar como atributo. Déjala como *meta* o quítala.
- **Ya está en $\log_2$** (valores de 0,9 a 15,9), al contrario que GDS360 y GDS3713.
- **Clases desequilibradas y pocas muestras sanas**: usa validación estratificada y mira la matriz de confusión.
- **Filas ordenadas por clase** (primero los 41 pacientes).
- **Muchos genes cambian**: 738 tienen $p < 0{,}001$ en una prueba t (por azar se esperarían unos 16). Para seleccionar genes, corrige por comparaciones múltiples (FDR).

6 Flujo de trabajo en Orange



1. **File** con `gds4168.csv`: `class` como *target*; `sample_id` y `disease state` como *meta*; quita `--Control`.
2. **Differential Expression**: genes más distintos entre LLC y sanos; ten en cuenta las comparaciones múltiples.
3. **PCA** → **Scatter Plot** coloreado por `class`.
4. **Test and Score** con **Logistic Regression** → **Confusion Matrix**: errores en los sanos.

7 Otras consideraciones

- **Para enlazar con rutas biológicas**: el add-on *Bioinformatics* tiene *Gene Set Enrichment* para ver qué funciones tienen los genes seleccionados.
- En versiones anteriores del catálogo de esta carpeta, el título decía «lupus» por error; el conjunto es de leucemia linfática crónica.

En la carpeta `gds4168` ← `GDS4168.tab` (datasets.biolab.si)

13.04
Expresión génica (bulk)

Brown et al.: expresión génica de levadura

`13_expresion_genica/brown_selected/`

186 genes de la levadura de panadería con su expresión en 79 condiciones (ciclo celular, esporulación, choques de temperatura…) y su función: ribosoma, proteasoma o respiración. Un clásico para agrupar y clasificar genes.

Clasificación multiclase · Clustering · ⚖ Desbalanceado · ? Valores faltantes

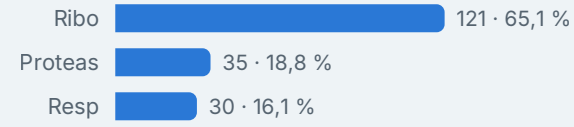
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
186	**81**	`function`	**1,4 %**	**Iniciación**	**Bioinformatics**

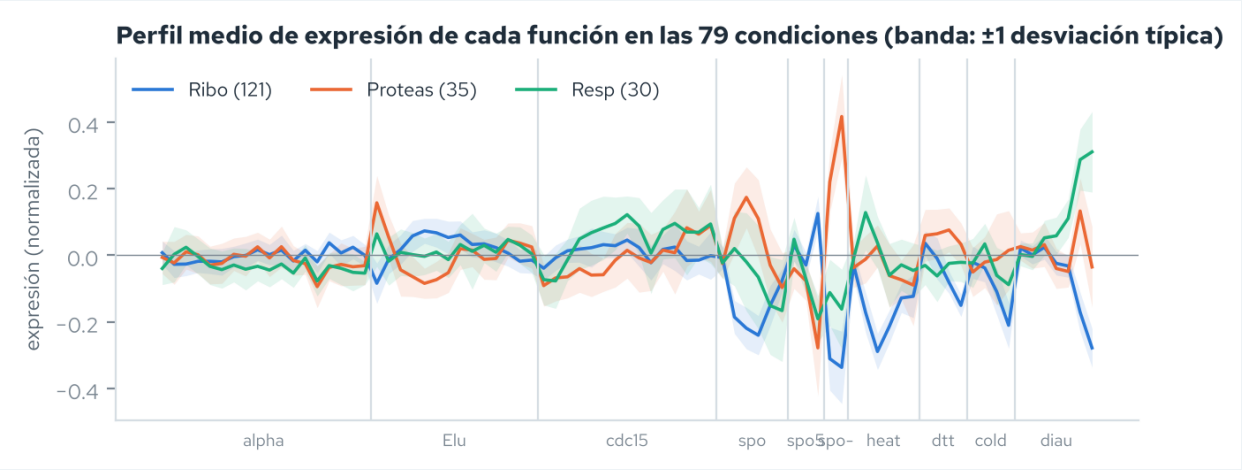
Fichero	Filas × col.	Descargar
`brown_selected`	186 × 81	CSV 97 KB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/13_expresion_genica/brown_selected/` seguido del nombre del fichero CSV.

Radiografía

function en brown_selected





1 Descripción general y estudios habituales

Aquí las filas son **genes**, no muestras: 186 genes de *Saccharomyces cerevisiae*, cada uno con su expresión relativa en 79 experimentos de microarray y con su función conocida (`function`). Los experimentos son series temporales: el ciclo celular sincronizado de tres formas (`alpha`, `cdc15`, `Elu`), la esporulación (`spo`), choques de calor (`heat`) y de frío (`cold`), el reductor DTT (`dtt`) y el cambio diáuxico (`diau`, al agotarse la glucosa).

Estudios habituales: **agrupar genes** por su perfil de expresión (agrupamiento jerárquico, mapas de calor), **clasificar la función** de un gen a partir de su perfil y **visualizar** con proyecciones (se usó en el material de VizRank, la búsqueda de proyecciones informativas de Orange).

2 Contexto y fuente original

Los perfiles de expresión son los de Michael Eisen, Patrick Brown y colaboradores (1998), del laboratorio de Pat Brown en Stanford. Michael P. S. Brown y colaboradores (2000) los usaron para clasificar genes por función con máquinas de vectores de soporte. El laboratorio de Orange seleccionó tres clases funcionales bien definidas y los usó en sus trabajos de visualización (VizRank).

- Brown, M. P. S. et al. (2000). Knowledge-based analysis of microarray gene expression data by using support vector machines. PNAS, 97(1), 262–267.
- Eisen, M. B., Spellman, P. T., Brown, P. O. y Botstein, D. (1998). Cluster analysis and display of genome-wide expression patterns. PNAS, 95(25), 14863–14868.

3 Variable objetivo

`function`: `Ribo` (proteínas del ribosoma, 121), `Proteas` (proteasoma, 35) y `Resp` (respiración, 30). Las clases están desequilibradas, pero los perfiles son tan distintos que todo funciona: medido fuera de Orange con *scikit-learn* (validación cruzada de 10 bolsas), la regresión logística y kNN aciertan el 98,9 %, y SVM y el bosque aleatorio el 99,5 %. Sin usar la clase, *k-Means* con 3 grupos reproduce casi exactamente las tres funciones (índice de Rand ajustado de 0,98).

4 Diccionario de columnas

Columnas de `brown_selected` (valores observados en el fichero)

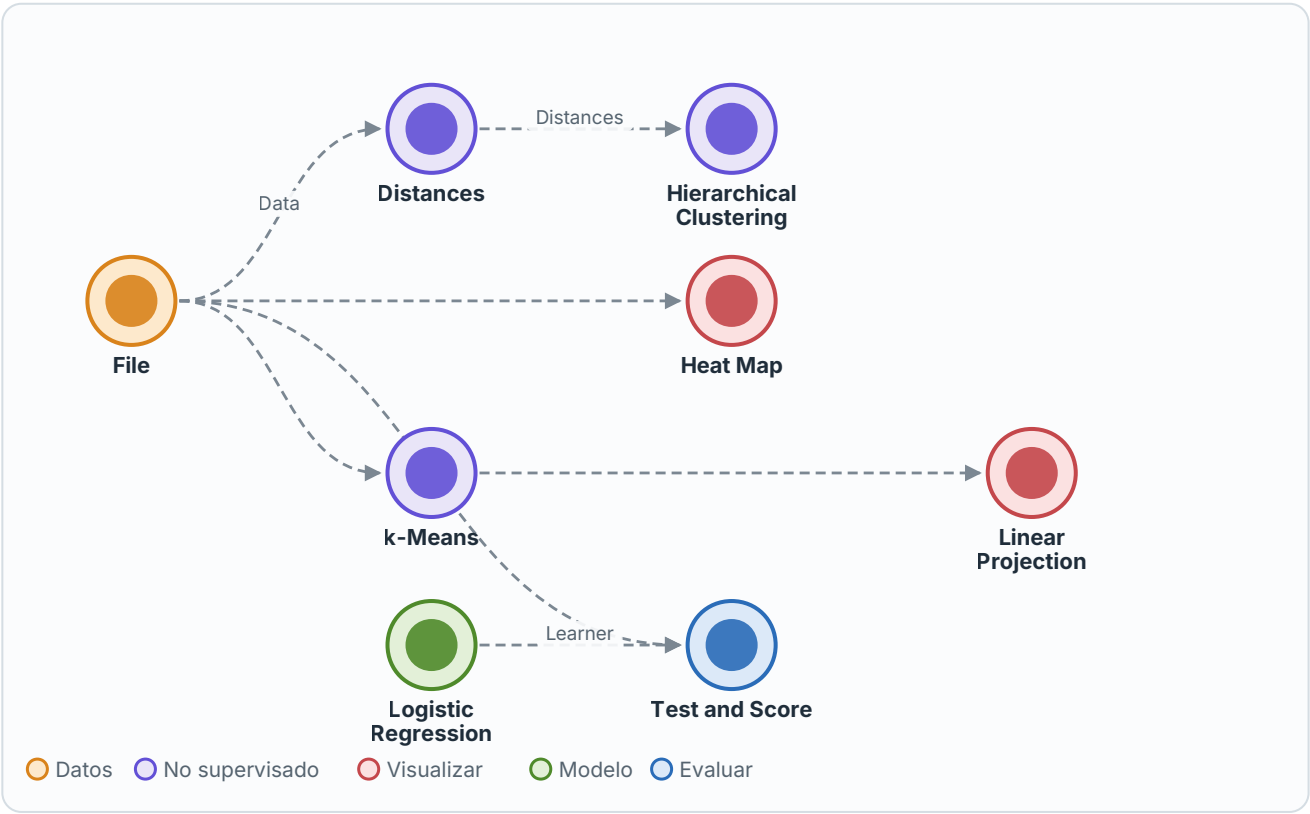
Columna	Tipo	Significado	Valores
`alpha 0`	numérica	Expresión relativa del gen en el minuto 0 tras sincronizar el ciclo celular con factor alfa (logaritmo de la razón frente a la referencia, con el perfil de cada gen normalizado a longitud 1).	-0,16 – 0,198
`function` `objetivo`	categórica	Función del gen: `Ribo` (ribosoma), `Proteas` (proteasoma) o `Resp` (respiración). Objetivo.	Ribo (121), Proteas (35), Resp (30)
gene	texto	Nombre sistemático del gen (ORF), p. ej. `YGR270W` (meta).	YGR270W (1), YIL075C (1), YDL007W (1), YER094C (1), YFR004W (1), YDR427W (1) …
…		y 78 columnas más: expresión relativa del gen en cada condición (ver la columna `alpha 0`).	

5 Particularidades técnicas al modelar

- **Filas = genes**: es al revés que GDS360 o GDS4168. Aquí se agrupan genes con perfiles parecidos (genes que se expresan juntos suelen tener funciones relacionadas).
- **Perfiles normalizados**: cada gen tiene su vector de expresión escalado a longitud 1 (como en Brown et al., 2000), por eso los valores van solo de −0,55 a 0,57. Usa distancia de coseno o de Pearson.

- **214 valores faltantes** repartidos en 116 genes (como mucho 5 por gen): *Impute* o modelos que los admitan.
- **Las columnas tienen orden**: dentro de cada serie, la columna es un tiempo. Para el mapa de calor, no reordenes las columnas.
- **Las condiciones que más separan**: en la esporulación (`spo-`) y en el choque de calor los genes del ribosoma bajan con fuerza; en el cambio diáuxico suben los de la respiración.

6 Flujo de trabajo en Orange



1. **File** con `brown_selected.csv`, `function` como *target*.
2. **Distances** (Pearson) → **Hierarchical Clustering**: los genes se agrupan por función.
3. **Heat Map** ordenando las filas por grupo: se ven las condiciones que separan las funciones.
4. **k-Means** (3 grupos) → **Linear Projection** o **Scatter Plot** coloreado por `function`.
5. **Test and Score** con **Logistic Regression** y kNN: acierto cercano al 99 %.

7 Otras consideraciones

- Es uno de los conjuntos históricos de Orange; aparece en tutoriales de agrupamiento y de visualización.
- El fichero completo de Eisen et al. tiene unos 2.500 genes con función anotada; esta selección se queda con tres clases claras para que el ejemplo funcione bien.

En la carpeta `brown_selected` ← `brown-selected.tab` (datasets.biolab.si)

14 Single-cell

12 datasets en el capítulo; en esta edición, 12 con ficha.

14.01
Single-cell

Células dendríticas y monocitos (Villani 2017)

`14_single_cell/dc_cells/`

Más de mil células de sangre humana, una por fila, con la expresión de 26.593 genes: distinguir cinco tipos de células dendríticas y monocitos solo por sus genes.

Clasificación multiclase · Clustering · ⋮ Alta dimensionalidad

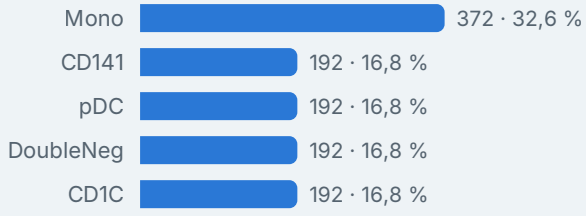
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
1.140	**26.595**	`Sample ID`	**0,0 %**	**Avanzado**	**Single Cell y Bioinformatics**

Fichero	Filas × col.	Descargar
`dc_expmatrix_dcnmono`	1.140 × 26.595	CSV 82,8 MB · XLSX XLSX recortado a 16.384 columnas
`dc_expmatrix_deeper_characterization`	1.244 × 26.595	CSV 86,7 MB · XLSX XLSX recortado a 16.384 columnas

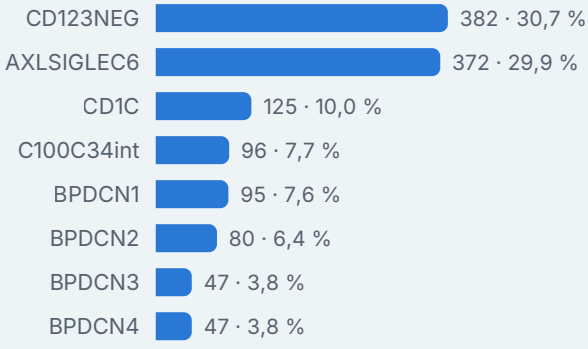
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/14_single_cell/dc_cells/` seguido del nombre del fichero CSV.

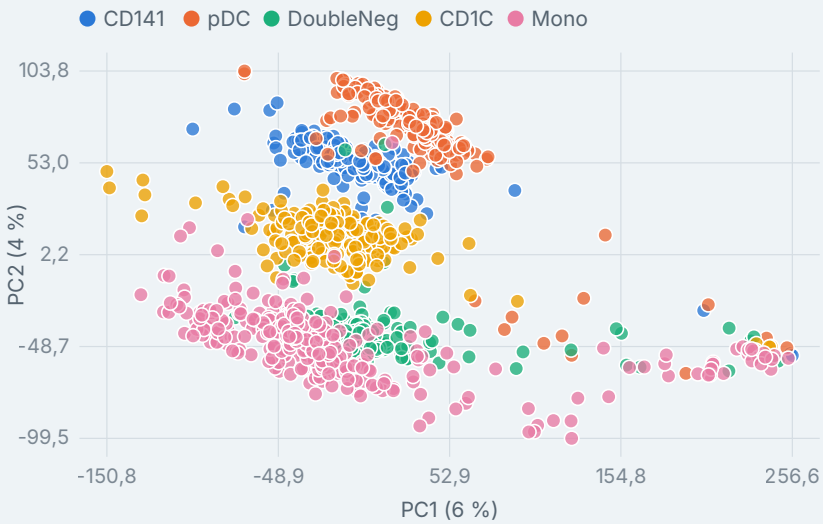
Radiografía

Sample ID en dc_expmatrix_dcnmono



Sample ID en dc_expmatrix_deeper_characterization





1 Descripción general y estudios habituales

Son dos ficheros de **RNA-seq de célula única**. Cada fila es una célula y cada columna, la expresión de un gen. Al final hay dos columnas más: el tipo de célula (`Sample ID`) y un identificador.

- `dc_expmatrix_dcnmono`: 1.140 células de cinco tipos. Hay 372 monocitos y 192 células de cada uno de estos tipos: dendríticas CD141⁺, dendríticas CD1C⁺, dendríticas plasmocitoides (pDC) y «doble negativas».
- `dc_expmatrix_deeper_characterization`: 1.244 células de ocho subpoblaciones que el estudio caracterizó más a fondo.

Estudios habituales: **clasificar** tipos celulares, **agrupar** sin etiquetas (t-SNE, Louvain) y comparar los grupos con los tipos, y **buscar genes marcadores** de cada tipo.

2 Contexto y fuente original

Los datos son del estudio de Alexandra-Chloé Villani y colaboradores (Instituto Broad, 2017). Secuenciaron con Smart-seq2 unas 2.400 células de sangre humana separadas por citometría, y describieron tipos nuevos de células dendríticas y monocitos. Uno de ellos es el grupo `AXL⁺SIGLEC6⁺` del segundo fichero.

- Villani, A.-C. et al. (2017). Single-cell RNA-seq reveals new types of human blood dendritic cells, monocytes, and progenitors. Science, 356(6335), eaah4573. Datos: NCBI GEO, GSE94820.

3 Variable objetivo

`Sample ID`: el tipo de célula según cómo se separó con el citómetro. Lo medimos fuera de Orange con *scikit-learn*: log, estandarización, PCA de 50 componentes y regresión logística, con validación cruzada de 5 bolsas.

- En `dcnmono` se acierta el 94 %; la clase mayoritaria solo da el 33 %. Las confusiones casi siempre son entre CD1C⁺ y doble negativas.
- En `deeper_characterization` se acierta el 89 %. Se confunden sobre todo `C100C34int` con `CD123NEG` y `CD1C` con `AXLSIGLEC6`.

4 Diccionario de columnas

Columnas de `dc_expmatrix_dcnmono` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Sample ID` `objetivo`	categórica	Tipo de célula: `Mono`, `CD141`, `CD1C`, `DoubleNeg` o `pDC`. Objetivo.	Mono (372), CD141 (192), pDC (192), DoubleNeg (192), CD1C (192)
`Cell ID`	texto	Identificador de la célula (`CD141_P10_S73`): empieza por el tipo, así que no lo uses como atributo.	CD141_P10_S73 (1), CD141_P10_S74 (1), CD141_P10_S75 (1), CD141_P10_S76 (1), CD141_P10_S77 (1), CD141_P10_S78 (1) …
…		y 26.593 columnas más: expresión de cada gen (símbolo HGNC) en la célula.	

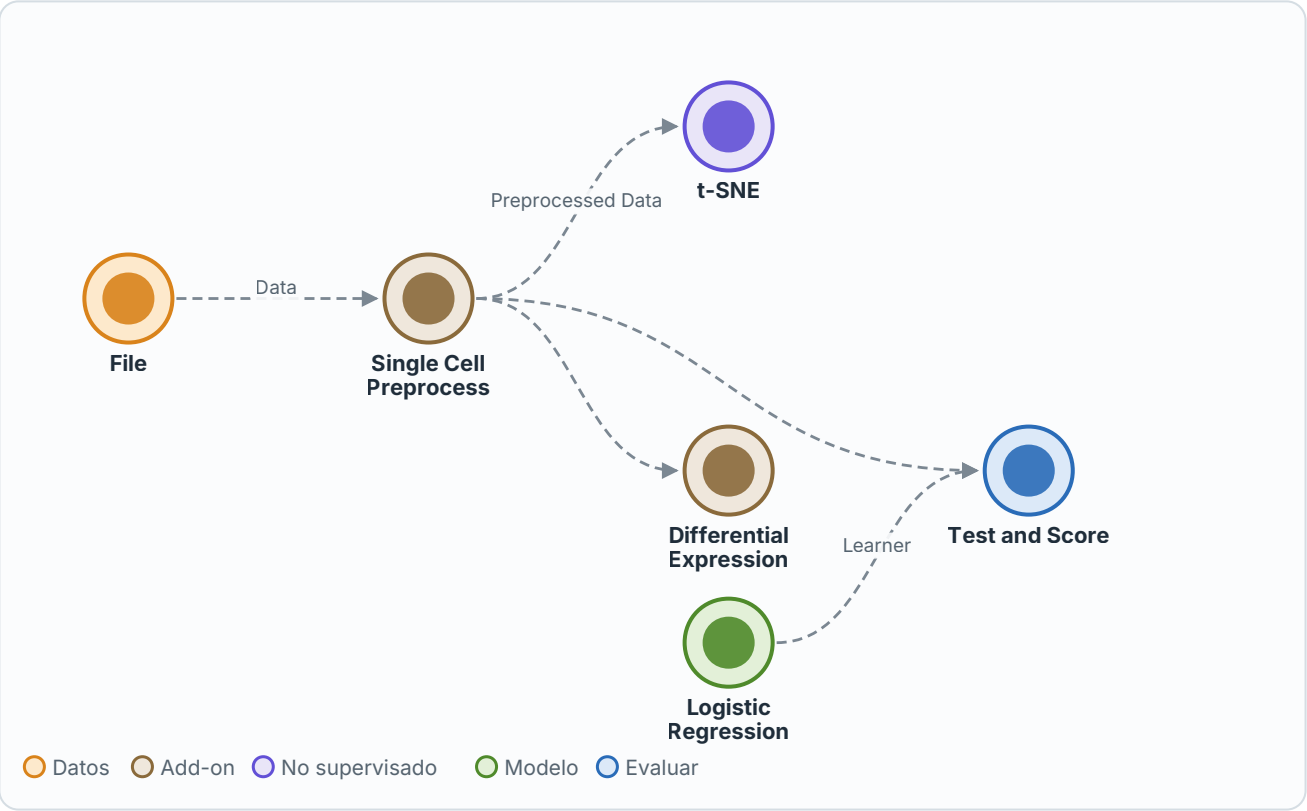
Columnas de `dc_expmatrix_deeper_characterization` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Sample ID` `objetivo`	categórica	Subpoblación caracterizada en el estudio (`CD123NEG`, `AXLSIGLEC6`, `CD1C`, `C100C34int`, `BPDCN1` a `BPDCN4`). Objetivo.	CD123NEG (382), AXLSIGLEC6 (372), CD1C (125), C100C34int (96), BPDCN1 (95), BPDCN2 (80) …
`Cell ID`	texto	Identificador de la célula; también empieza por la subpoblación. Déjala como *meta*.	CD1C_CD32B_S10_S58 (1), CD1C_CD32B_S11_S59 (1), CD1C_CD32B_S12_S60 (1), CD1C_CD32B_S13_S61 (1), CD1C_CD32B_S14_S62 (1), CD1C_CD32B_S15_S63 (1) …
…		y 26.593 columnas más: expresión de cada gen (símbolo HGNC) en la célula.	

5 Particularidades técnicas al modelar

- **Más de 16.384 columnas**: los dos XLSX están recortados a las primeras 16.384, que es el límite de Excel. Los CSV tienen todas las columnas.
- **No son recuentos brutos**, aunque así lo diga la descripción de Orange. Cada célula suma cerca de un millón, así que los valores ya están normalizados (tipo CPM o TPM). No vuelvas a normalizar por tamaño de biblioteca; basta con aplicar el logaritmo.
- **Muy disperso**: el 81 % de los valores son ceros, y 4.116 genes valen cero en todas las células. Filtra los genes antes de usar el PCA.
- `Cell ID` **revela la clase**: el prefijo es el tipo de célula. Déjala como *meta*.
- **Filas ordenadas por tipo**: si separas una parte para test, usa validación estratificada o baraja las filas.

6 Flujo de trabajo en Orange



1. **File** con `dc_expmatrix_dcnmono.csv`: `Sample ID` como *target*, `Cell ID` como *meta*.
2. **Single Cell Preprocess**: logaritmo y selección de los genes más variables. No hace falta normalizar por biblioteca.
3. **t-SNE** coloreado por `Sample ID`: los monocitos y las pDC forman islas claras.
4. **Differential Expression** (add-on *Bioinformatics*), con `Sample ID` como grupo: genes característicos de cada tipo.
5. **Test and Score** con **Logistic Regression**: cerca del 94 % de acierto.

7 Otras consideraciones

- **Del mismo capítulo**: `aml_single_cell` y `galen2019_aml` también son células de la sangre o la médula, y se puede probar si los marcadores de un estudio sirven en otro.

En la carpeta `dc_expmatrix_dcnmono` ← `DC_expMatrix_DCnMono.tab.gz` (datasets.biolab.si)

En la carpeta `dc_expmatrix_deeper_characterization` ← `DC_expMatrix_deeper.characterization.tab.gz` (datasets.biolab.si)

14.02
Single-cell

AML: médula ósea con leucemia mieloide aguda

`14_single_cell/aml_single_cell/`

Células de médula ósea de un paciente con leucemia mieloide aguda y de dos donantes sanos: ejemplo clásico de que un clasificador puede aprender quién es el donante en lugar de la enfermedad.

Clasificación multiclase · Clustering · ⋮ Alta dimensionalidad

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
1.000	**1.004**	`Type`	**0,0 %**	**Avanzado**	**Single Cell y Bioinformatics**

Fichero	Filas × col.	Descargar
`aml_1k`	1.000 × 1.004	CSV 3,0 MB · XLSX
`aml_8k`	8.390 × 1.004	CSV 25,1 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/14_single_cell/aml_single_cell/` seguido del nombre del fichero CSV.

Radiografía

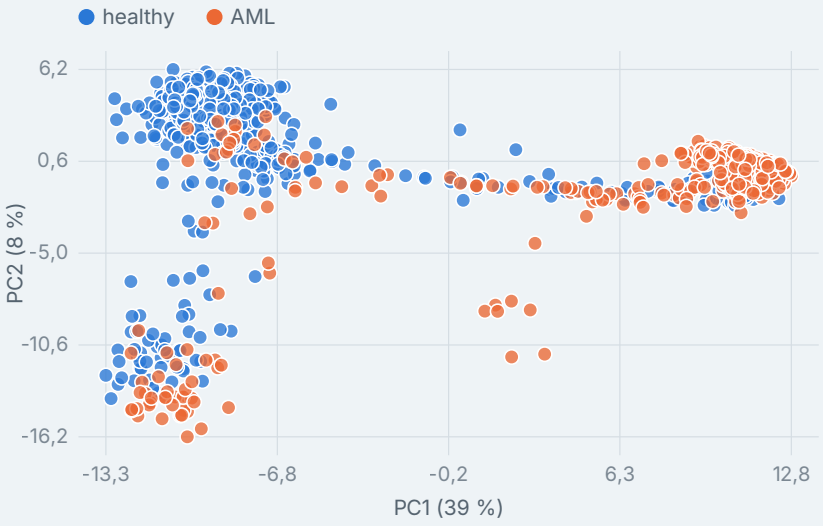
Type en aml_1k



Type en aml_8k



PCA de las 1.000 células (expresión ya en log)



1 Descripción general y estudios habituales

Cada fila es una célula mononuclear de médula ósea. Las columnas son la expresión de los **1.000 genes más dispersos**, ya normalizada y en escala logarítmica. Al final están el tipo de muestra (`Type`: `AML` o `healthy`), la réplica y dos identificadores.

- `aml_1k`: muestra de 1.000 células (473 AML y 527 sanas).
- `aml_8k`: 8.390 células (3.933 AML y 4.457 sanas).

Estudios habituales: **visualizar** con t-SNE, **agrupar** células, **buscar genes marcadores** y **clasificar** AML frente a sano.

2 Contexto y fuente original

Son los datos de ejemplo del programa Loupe Cell Browser de 10x Genomics. Reúnen tres muestras públicas de 10x: la médula de un paciente con AML antes de un trasplante (AML027) y la de dos donantes sanos. Proceden del artículo de Grace Zheng y colaboradores (2017) que presentó la plataforma de gotas de 10x.

- Zheng, G. X. Y. et al. (2017). Massively parallel digital transcriptional profiling of single cells. Nature Communications, 8, 14049. Datos: 10x Genomics (AML027 y donantes sanos), versión de Loupe Cell Browser.

3 Variable objetivo

`Type`: `AML` frente a `healthy`. Con log, PCA de 50 componentes y regresión logística, se acierta el 93 % (5 bolsas, *scikit-learn*). Parece un éxito, pero **hay un problema de diseño**: todas las células AML vienen de una sola persona, y las sanas de otras dos. El modelo puede estar aprendiendo diferencias entre personas o entre lotes de procesado, y no la leucemia.

Hay un indicio en `Replicate`: todas las células AML tienen réplica 1, y las sanas se reparten entre 1 (234) y 2 (293).

4 Diccionario de columnas

Columnas de `aml_1k` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
Type `objetivo`	categórica	Origen de la célula: `AML` (paciente con leucemia) o `healthy` (donante sano). Objetivo.	healthy (527), AML (473)
`Replicate`	categórica	Réplica (1 o 2). Las AML son todas de la 1, así que **delata la clase**: déjala como *meta*.	1 (707), 2 (293)
`ID`	texto	Identificador interno de la célula (cadena hexadecimal), meta.	6681b0788fc2b2e21975e26f588cc7a9 (1), 7c1e27874a82e7d5c1c877fa2cba7ba7 (1), b9d78fbc8b1bf9aa478e1fbd93ac883c (1), 841c0e79f017a8ece40b2532f82a9c7a (1), 08c51bbdc6bb95fc17cd3965e6d6c4fb (1), 6f99d492809e8fb7fba9e292140138d9 (1) …

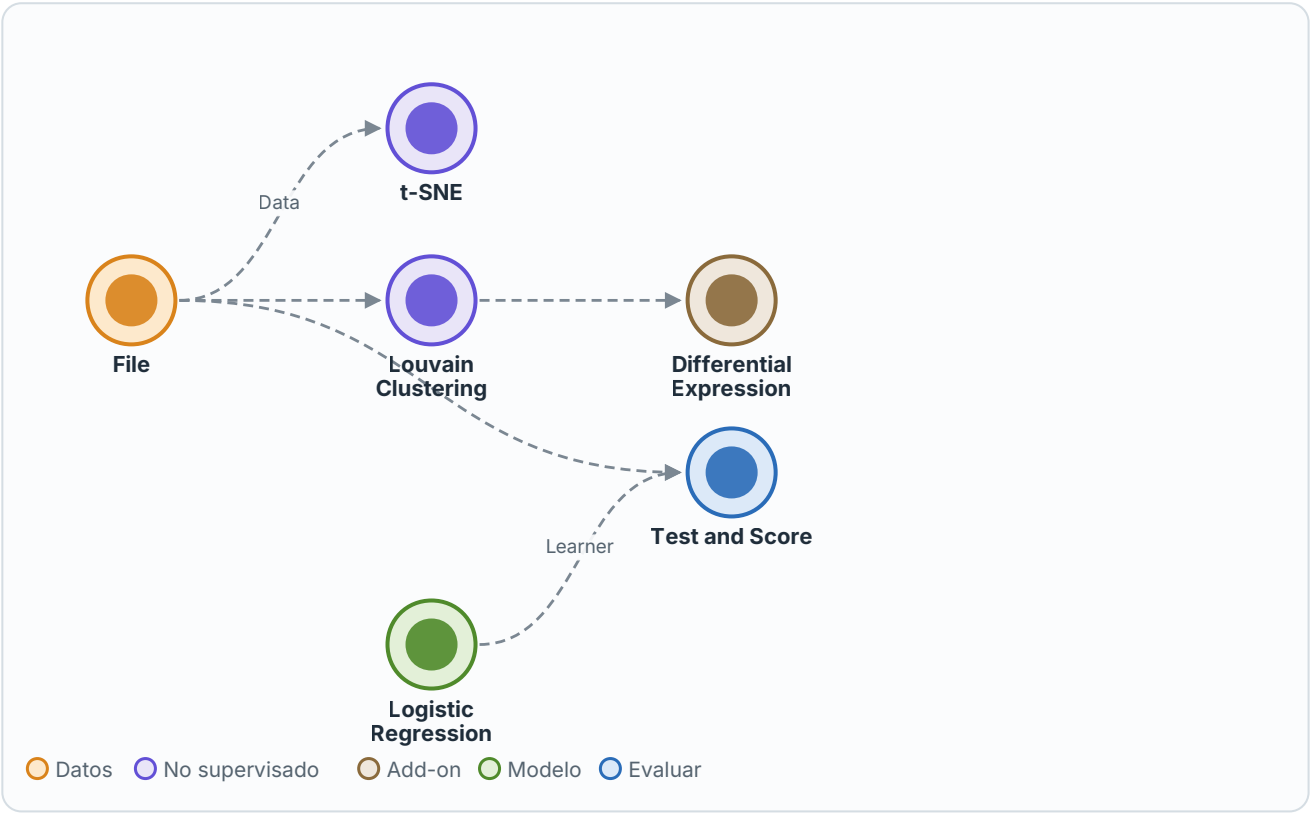
Columna	Tipo	Significado	Valores
`Barcode`	texto	Código de barras de 10x de la célula (`ACGGGAGATGACCA-1`), meta.	ACGGGAGATGACCA-1 (1), GAACAGCTGCTTAG-1 (1), TCTTACGAAAAAGC-1 (1), CGAGCCGACTCTAT-1 (1), GCAAACTGTTGGCA-1 (1), AACTCACTCATGAC-1 (1) …
…		y 1.000 columnas más: expresión normalizada en log de cada gen (símbolo HGNC).	

`aml_8k` tiene las mismas columnas con el mismo significado que `aml_1k`.

5 Particularidades técnicas al modelar

- **Variable de confusión**: la enfermedad va unida al donante y al lote. No saques conclusiones sobre la AML sin una validación que separe donantes, algo que aquí no se puede hacer porque solo hay un paciente.
- **Ya está normalizado y en log** (máximo 11), con el 94 % de ceros. No apliques otra vez el logaritmo.
- **Solo 1.000 genes**, los más dispersos. Algunos marcadores clásicos pueden no estar.
- En el servidor de Orange también existe `single-cell-aml-1k`, que es el mismo conjunto en otro formato.

6 Flujo de trabajo en Orange



1. **File** con `aml_1k.csv`: `Type` como *target*; `Replicate`, `ID` y `Barcode` como *meta*.
2. **t-SNE** coloreado por `Type` y luego por `Replicate`: fíjate en que las dos sanas no se mezclan del todo.
3. **Louvain Clustering** y **Differential Expression** por grupo (add-on *Bioinformatics*): los genes de cada grupo ayudan a reconocer linfocitos, monocitos, eritroides…
4. **Test and Score**: acierto alto, pero piensa qué está aprendiendo el modelo.

7 Otras consideraciones

- **Para clase**: es un buen ejemplo para hablar de **fugas por diseño**, cuando la etiqueta coincide con la persona o el lote. `galen2019_aml` permite comparar varios días del mismo paciente con un donante sano.

En la carpeta	`aml_1k` ← `aml-1k.tab.gz` (datasets.biolab.si)
En la carpeta	`aml_8k` ← `aml-8k.tab.gz` (datasets.biolab.si)
Duplicado, no se copia	`single-cell-aml-1k.pkl.gz` (datasets.biolab.si)

14.03
Single-cell

Páncreas humano (Baron 2016)

`14_single_cell/baron2016_pancreas/`

Un mapa de los tipos de células del páncreas humano: 8.569 células de cuatro donantes, con 13 tipos (células alfa, beta, acinares…), y una muestra pequeña de un solo donante para practicar.

Clasificación multiclase · Clustering · ⋮ Alta dimensionalidad · ⚖ Desbalanceado

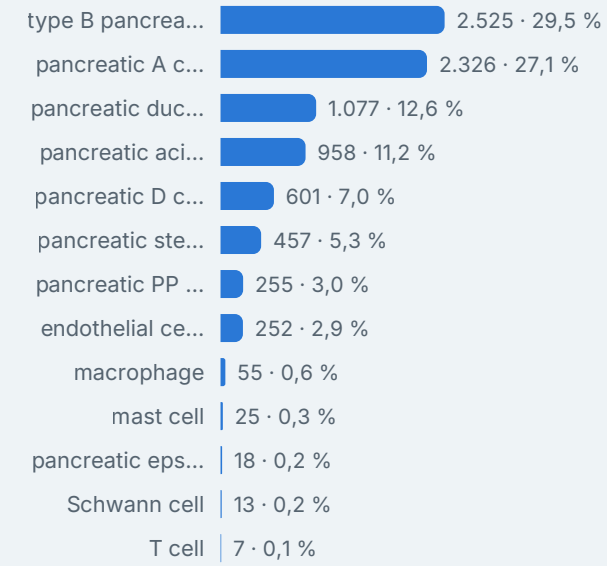
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
8.569	**20.130**	`class`	**0,0 %**	**Avanzado**	**Single Cell**

Fichero	Filas × col.	Descargar
`baron2016_pancreas_human`	8.569 × 20.130	CSV 24,5 MB sin XLSX: estimado 423 MB > 100 MB
`baron2016_pancreas_human_sample`	1.631 × 5.015	CSV 16,6 MB · XLSX

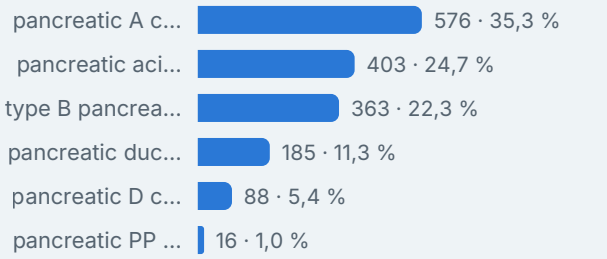
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/14_single_cell/baron2016_pancreas/` seguido del nombre del fichero CSV.

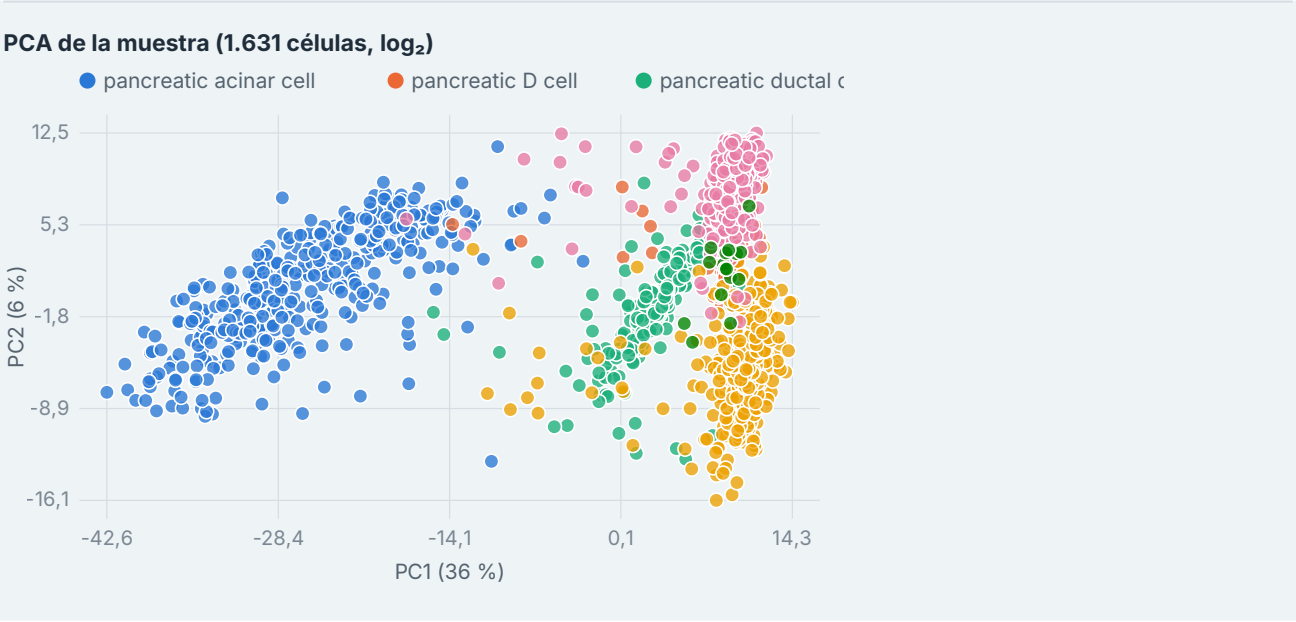
Radiografía

class en baron2016_pancreas_human



class en baron2016_pancreas_human_sample





1 Descripción general y estudios habituales

Son recuentos de **RNA-seq de célula única** (inDrop) de islotes pancreáticos humanos. Cada fila es una célula y cada columna, un gen. Al final hay cuatro columnas: el tipo celular y tres identificadores (de célula, de lote y de donante).

- `baron2016_pancreas_human`: 8.569 células de 4 donantes, 20.125 genes y 13 tipos. El tipo más frecuente son las células beta (2.525) y el menos frecuente, los linfocitos T (7).
- `baron2016_pancreas_human_sample`: 1.631 células de un solo donante (`human3`), 5.010 genes y 6 tipos.

Estudios habituales: **clasificar** tipos celulares, **agrupar** y anotar, **genes marcadores** y **efecto de lote** entre donantes.

2 Contexto y fuente original

Es el atlas de páncreas humano y de ratón de Maayan Baron y colaboradores (Harvard, 2016), uno de los conjuntos de referencia más usados para probar métodos de anotación automática y de integración entre estudios.

- Baron, M. et al. (2016). A single-cell transcriptomic map of the human and mouse pancreas reveals inter- and intra-cell population structure. Cell Systems, 3(4), 346–360. Datos: NCBI GEO, GSE84133.

3 Variable objetivo

`class`: tipo celular. En la muestra hay seis: alfa (`pancreatic A cell`, 576), acinares (403), beta (`type B pancreatic cell`, 363), ductales (185), delta (88) y PP (16).

Con normalización por biblioteca, log, PCA de 50 componentes y regresión logística, se acierta el **98 %** (5 bolsas, *scikit-learn*). Los pocos errores son delta tomadas por beta y PP tomadas por alfa.

4 Diccionario de columnas

Columnas de `baron2016_pancreas_human_sample` (valores observados en el fichero)

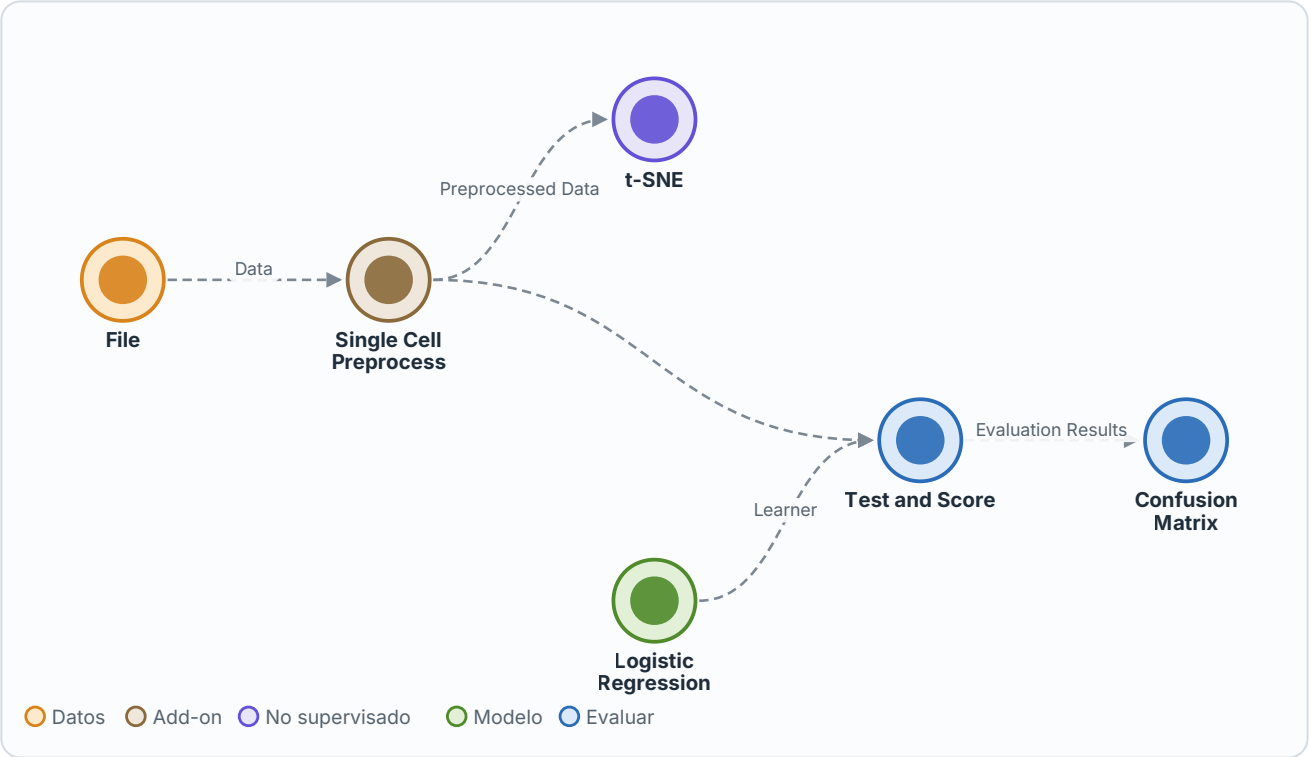
Columna	Tipo	Significado	Valores
`class` objetivo	categórica	Tipo celular asignado en el estudio. Objetivo.	pancreatic A cell (576), pancreatic acinar cell (403), type B pancreatic cell (363), pancreatic ductal cell (185), pancreatic D cell (88), pancreatic PP cell (16)
`barcode`	texto	Código de barras inDrop de la célula. Puede repetirse entre bibliotecas.	TGACTCAGAAT-GGGAGGTA (2), ACGTGGATA-ATGCGGAT (2), ATCATGAGG-AGATGGCT (2), AAGCTACGG-GGCCTAAG (2), GAGGGAGGTA-GAAGTGCC (2), GAAGGAAGAC-TCCCAATC (2) …
`Cell ID`	texto	Identificador único (`human3_lib1.final_cell_0001`), meta.	human3_lib1.final_cell_0001 (1), human3_lib1.final_cell_0002 (1), human3_lib1.final_cell_0003 (1), human3_lib1.final_cell_0004 (1), human3_lib1.final_cell_0005 (1), human3_lib1.final_cell_0006 (1) …
`Batch ID`	texto	Biblioteca de secuenciación (`human3_lib1` , `human3_lib2`), meta.	human3_lib1 (819), human3_lib2 (812)
`Patient`	texto	Donante (`human1` a `human4` ; en la muestra, solo `human3`), meta.	human3 (1.631)
…		y 5.010 columnas más: recuento de lecturas (UMI) de cada gen (símbolo HGNC).	

`baron2016_pancreas_human` tiene las mismas columnas con el mismo significado que `baron2016_pancreas_human_sample`.

5 Particularidades técnicas al modelar

- **Recuentos brutos**: normaliza por tamaño de biblioteca y aplica el logaritmo (*Single Cell Preprocess*) antes de usar el PCA o t-SNE.
- **El conjunto completo es grande**: su CSV está comprimido en ZIP y no tiene XLSX (pasaría de 100 MB). Para clase, usa la muestra.
- **Clases muy desequilibradas** en el conjunto completo: cuatro tipos tienen menos de 30 células (mastocitos 25, épsilon 18, Schwann 13 y linfocitos T 7). Mira la matriz de confusión.
- **Cuatro donantes** en el completo: los grupos pueden separarse por donante. Prueba *Batch Effect Removal* con `Patient`.

6 Flujo de trabajo en Orange



1. **File** con `baron2016_pancreas_human_sample.csv`: `class` como *target*; identificadores como *meta*.
2. **Single Cell Preprocess**: normalización por biblioteca, log y genes más variables.
3. **t-SNE** coloreado por `class`: islas claras para cada tipo.
4. **Test and Score** con **Logistic Regression** → **Confusion Matrix**.

7 Otras consideraciones

- **Para transferir etiquetas**: entrena con Baron y prueba con `xin2016_pancreas`, que es otro estudio y otra técnica (solo comparten alfa, beta, delta y PP). Así se ve cómo cae el acierto entre estudios.

En la carpeta	`baron2016_pancreas_human` ← `baron2016_pancreas_human.pkl.gz` (datasets.biolab.si)
En la carpeta	`baron2016_pancreas_human_sample` ← `baron2016_pancreas_human_sample.tab.gz` (datasets.biolab.si)

14.04
Single-cell

Páncreas humano y diabetes tipo 2 (Xin 2016)

`14_single_cell/xin2016_pancreas/`

Células de islotes pancreáticos humanos (alfa, beta, delta y PP) de donantes con y sin diabetes tipo 2: un páncreas medido con otra técnica, ideal para comparar con Baron 2016.

Clasificación multiclase · Clustering · ⋮ Alta dimensionalidad · ⚖ Desbalanceado

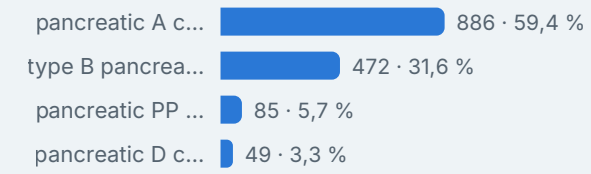
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
1.492	**35.900**	`class`	**0,0 %**	**Avanzado**	**Single Cell**

Fichero	Filas × col.	Descargar
`xin2016_pancreas_human`	1.492 × 35.900	CSV 68,6 MB sin XLSX: estimado 141 MB > 100 MB
`xin2016_pancreas_human_sample`	500 × 4.648	CSV 16,5 MB · XLSX

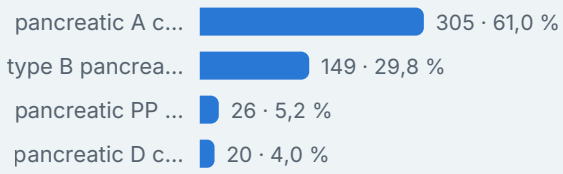
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/14_single_cell/xin2016_pancreas/` seguido del nombre del fichero CSV.

Radiografía

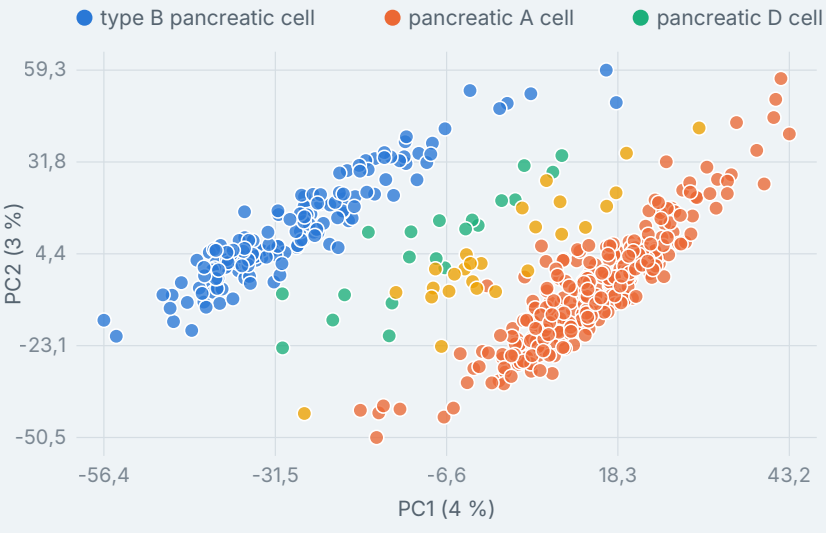
class en xin2016_pancreas_human



class en xin2016_pancreas_human_sample



PCA de la muestra (500 células, $\log_2$)



1 Descripción general y estudios habituales

Cada fila es una célula de islote pancreático, cada columna la expresión de un gen y la última columna, el tipo celular.

- `xin2016_pancreas_human`: 1.492 células y 35.899 genes. Hay 886 alfa, 472 beta, 85 PP y 49 delta.
- `xin2016_pancreas_human_sample`: 500 células y 4.647 genes. Hay 305 alfa, 149 beta, 26 PP y 20 delta.

Estudios habituales: **clasificar** tipos celulares, **marcadores** y **transferir etiquetas** desde otro atlas.

2 Contexto y fuente original

Es el estudio de Yurong Xin y colaboradores (Regeneron, 2016). Secuenciaron con Fluidigm C1 células de islotes de donantes con y sin diabetes tipo 2, y encontraron 245 genes con expresión alterada en la diabetes.

- Xin, Y. et al. (2016). RNA sequencing of single human islet cells reveals type 2 diabetes genes. Cell Metabolism, 24(4), 608–615. Datos: NCBI GEO, GSE81608.

3 Variable objetivo

`class`: alfa, beta, delta o PP. En la muestra, con log, PCA de 50 componentes y regresión logística, se acierta el **96 %** (5 bolsas, *scikit-learn*). La clase mayoritaria da el 61 %. Los errores son PP tomadas por alfa y delta tomadas por beta.

No hay columna de diabetes ni de donante, aunque la descripción de Orange hable de donantes con y sin diabetes tipo 2. Con estos ficheros no se puede estudiar la diabetes; para eso hace falta la información de GEO.

4 Diccionario de columnas

Columnas de `xin2016_pancreas_human_sample` (valores observados en el fichero)

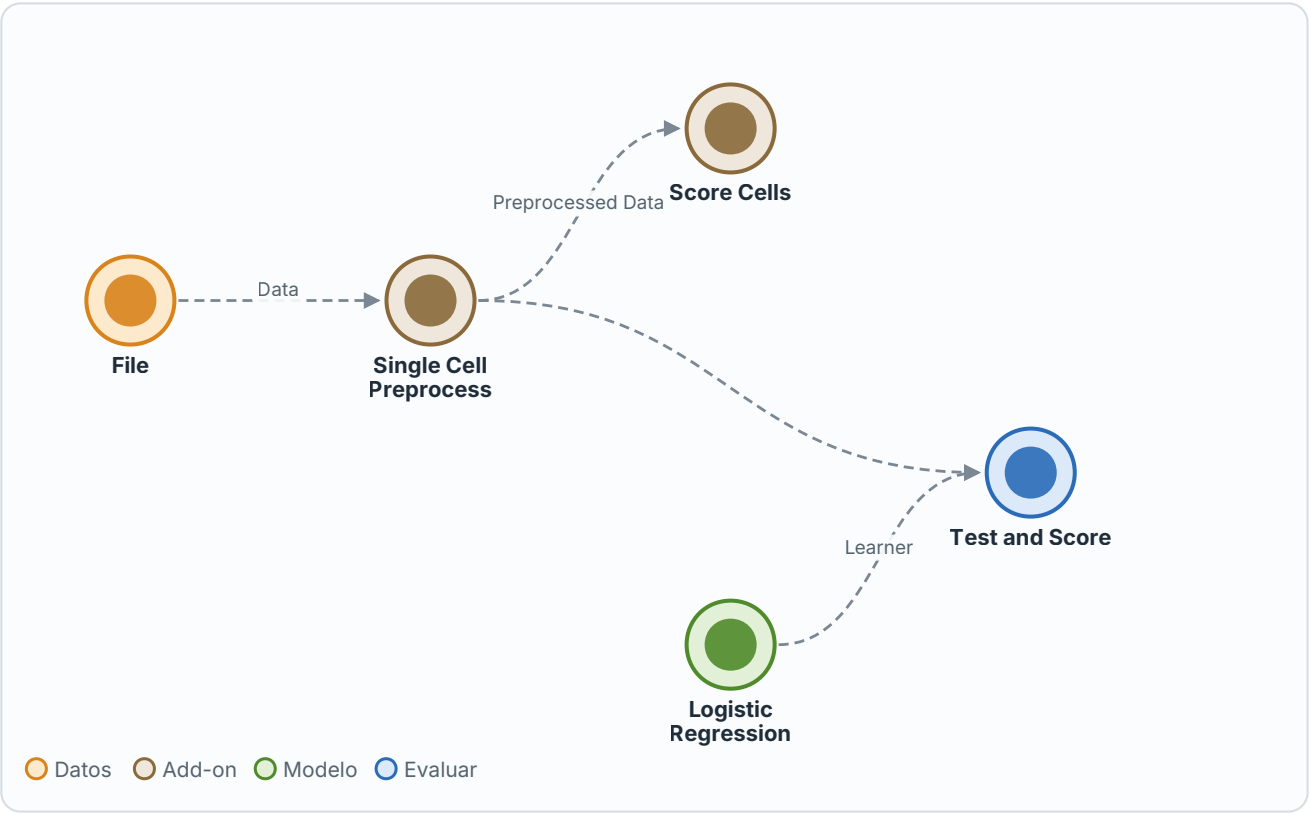
Columna	Tipo	Significado	Valores
`class` `objetivo`	categórica	Tipo celular: `pancreatic A cell` (alfa), `type B pancreatic cell` (beta), `pancreatic D cell` (delta) o `pancreatic PP cell`. Objetivo.	pancreatic A cell (305), type B pancreatic cell (149), pancreatic PP cell (26), pancreatic D cell (20)
…		y 4.647 columnas más: expresión normalizada (tipo RPKM) de cada gen (símbolo HGNC).	

`xin2016_pancreas_human` tiene las mismas columnas con el mismo significado que `xin2016_pancreas_human_sample`.

5 Particularidades técnicas al modelar

- **Valores no enteros** (tipo RPKM): no son recuentos. Basta con aplicar el logaritmo.
- **El completo está en ZIP y sin XLSX** (pasaría de 100 MB). La muestra sí tiene XLSX.
- **Clases desequilibradas**: delta y PP son pocas. Mira la sensibilidad de cada clase.
- **Sin identificadores**: no hay columna de célula ni de donante.

6 Flujo de trabajo en Orange



1. **File** con `xin2016_pancreas_human_sample.csv` : `class` como *target*.
2. **Single Cell Preprocess**: logaritmo y genes variables.
3. **Score Cells** con marcadores conocidos (`GCG` alfa, `INS` beta, `SST` delta, `PPY` PP) y comprueba que cada tipo destaca en el suyo.
4. **Test and Score** con **Logistic Regression**.

7 Otras consideraciones

- **Entre estudios**: entrena con `baron2016_pancreas` (inDrop) y prueba con este (Fluidigm). Selecciona primero los genes comunes a los dos conjuntos.

En la carpeta	`xin2016_pancreas_human` ← `xin2016_pancreas_human.tab.gz` (datasets.biolab.si)
En la carpeta	`xin2016_pancreas_human_sample` ← `xin2016_pancreas_human_sample.tab.gz` (datasets.biolab.si)

14.05
Single-cell

PBMC estimuladas con interferón beta (Kang 2018)

`14_single_cell/pbmc_kang2018/`

Células de sangre (PBMC) de ocho pacientes con lupus, sin tratar o estimuladas con interferón beta durante 6 horas: ver cómo responde cada tipo de célula a un mismo estímulo.

Clasificación binaria · Clustering · Alta dimensionalidad · Grande

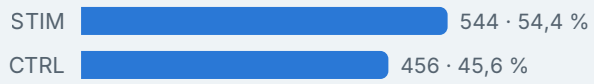
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
13.019	**35.637**	`Source ID`	**0,0 %**	**Avanzado**	**Single Cell**

Fichero	Filas × col.	Descargar
`pbmc_kang2018_raw_control`	13.019 × 35.637	CSV 18,1 MB sin XLSX: estimado 644 MB > 100 MB
`pbmc_kang2018_raw_stimulated`	12.875 × 35.637	CSV 18,4 MB sin XLSX: estimado 637 MB > 100 MB
`pbmc_kang2018_sample`	1.000 × 1.502	CSV 30,7 MB · XLSX

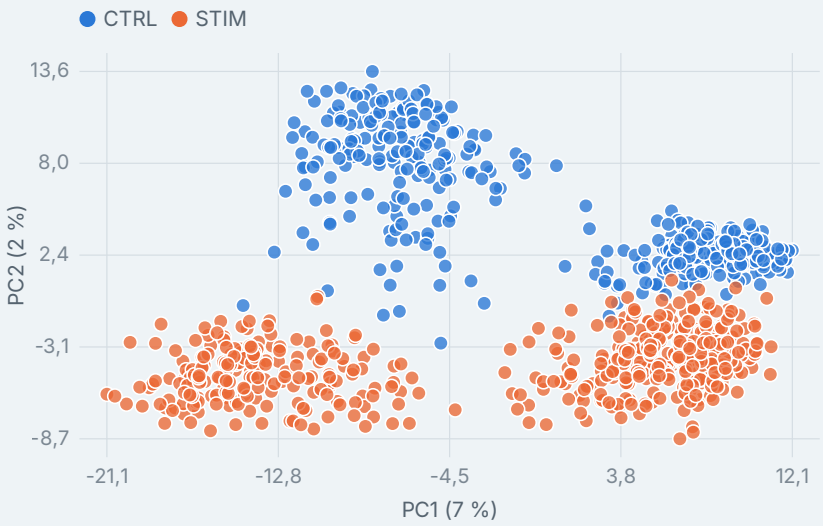
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/14_single_cell/pbmc_kang2018/` seguido del nombre del fichero CSV.

Radiografía

Source ID en pbmc_kang2018_sample



PCA de la muestra (1.000 células, ya estandarizada)



1 Descripción general y estudios habituales

Son tres ficheros. Cada fila es una célula y cada columna, un gen.

- `pbmc_kang2018_raw_control`: 13.019 células sin tratar. Tiene recuentos brutos de 35.635 genes.
- `pbmc_kang2018_raw_stimulated`: 12.875 células estimuladas con interferón beta (IFN-β). Tiene los mismos genes.
- `pbmc_kang2018_sample`: 1.000 células (456 de control y 544 estimuladas) y 1.500 genes muy variables. Los datos ya están normalizados a CPM, en log y estandarizados.

Estudios habituales: **comparar condiciones** (genes que responden al interferón), **integrar** o corregir lotes entre condiciones, **agrupar** tipos celulares y **clasificar** control frente a estimulada.

2 Contexto y fuente original

Es el estudio de Hyun Min Kang y colaboradores (UCSF, 2018), que presentó *demuxlet*. La técnica mezcla las células de varias personas en un mismo experimento y usa sus variantes genéticas para saber de quién es cada célula. Después Butler y colaboradores (2018) lo usaron como ejemplo de **integración entre condiciones** en Seurat.

- Kang, H. M. et al. (2018). Multiplexed droplet single-cell RNA-sequencing using natural genetic variation. Nature Biotechnology, 36(1), 89–94. Datos: NCBI GEO, GSE96583.
- Butler, A. et al. (2018). Integrating single-cell transcriptomic data across different conditions, technologies, and species. Nature Biotechnology, 36(5), 411–420.

3 Variable objetivo

- **En la muestra**, el objetivo es `Source ID` (`CTRL` o `STIM`). Con PCA de 50 componentes y regresión logística se acierta el **99 %** (5 bolsas, *scikit-learn*). El interferón cambia mucho la expresión. En `ISG15`, `IFI6` y `MX1`, los valores estandarizados son de unos −0,8 en el control y +0,8 en las estimuladas.
- **En los ficheros brutos**, la columna `Treatment` tiene un solo valor en cada fichero. Para clasificar, únelos antes con *Concatenate*.

4 Diccionario de columnas

Columnas de `pbmc_kang2018_raw_control` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Treatment` objetivo	categórica	Condición; vale `CTRL` en todo este fichero y `STIM` en el de estimuladas.	
`cell_ID`	texto	Código de barras de la célula, meta.	
…		y 35.635 columnas más: expresión de cada gen (símbolo HGNC).	

Columnas de `pbmc_kang2018_sample` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Source ID` objetivo	categórica	Condición: `CTRL` (sin tratar) o `STIM` (6 h con IFN-β). Objetivo.	STIM (544), CTRL (456)

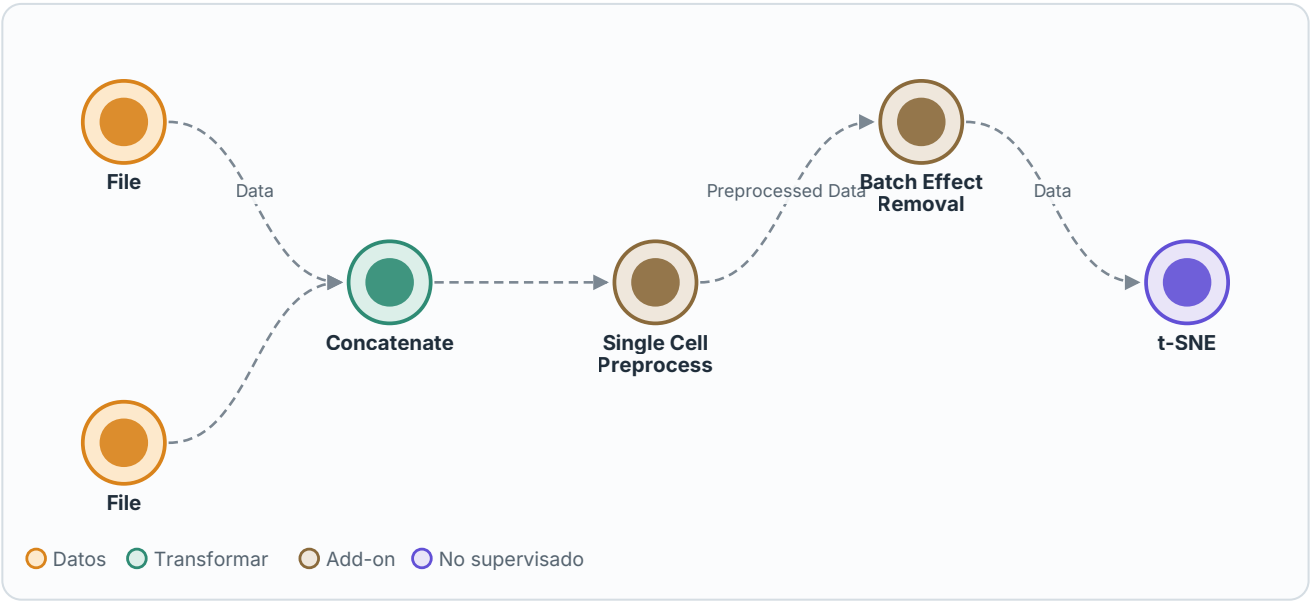
Columna	Tipo	Significado	Valores
`cell_ID`	texto	Código de barras de la célula, meta.	CCCATGTGCCGAAT.1 (1), AGGCTAACAGATGA.1 (1), AACGTTCTTACTTC.1 (1), TAATGCCTCCATAG.1 (1), TTCATGACGAGATA.1 (1), ATCTGGGACATTCT.1 (1) …
…		y 1.500 columnas más: expresión de cada gen (símbolo HGNC).	

`pbmc_kang2018_raw_stimulated` tiene las mismas columnas con el mismo significado que `pbmc_kang2018_raw_control`.

5 Particularidades técnicas al modelar

- **Dos normalizaciones distintas**: la muestra está estandarizada, con valores negativos de −12,9 a 10. Los completos son recuentos enteros, con un 98 % de ceros. No mezcles unos con otros.
- **Los completos son grandes**: van en ZIP y no tienen XLSX, porque pasarían de 600 MB.
- **Sin tipo celular ni paciente**: los ficheros no dicen qué tipo de célula es ni de qué paciente viene. Tendrás que agruparlas y anotarlas (*Annotator* o *Score Cells* con marcadores como `CD14`, `MS4A1`, `CD3E` o `NKG7`).
- **Condición = lote**: control y estimuladas se procesaron por separado. Parte de la diferencia puede ser técnica.

6 Flujo de trabajo en Orange



1. Dos **File** con los ZIP (descomprime antes) y **Concatenate** para unir las dos condiciones.
2. **Single Cell Preprocess**: normaliza por biblioteca, aplica log y quédate con los genes más variables.
3. **t-SNE** coloreado por `Treatment`, primero sin corregir y luego tras **Batch Effect Removal**. Así ves si los tipos celulares se alinean entre condiciones.
4. Para empezar rápido, usa `pbmc_kang2018_sample.csv`: ya está preprocesado.

7 Otras consideraciones

- **Expresión diferencial por tipo celular**: agrupa, anota y compara `CTRL` frente a `STIM` dentro de cada grupo. Así ves qué genes del interferón suben en monocitos y cuáles en linfocitos.

En la carpeta	`pbmc_kang2018_raw_control` ← `pbmc_kang2018_raw_control.pkl.gz` (datasets.biolab.si)
En la carpeta	`pbmc_kang2018_raw_stimulated` ← `pbmc_kang2018_raw_stimulated.pkl.gz` (datasets.biolab.si)
En la carpeta	`pbmc_kang2018_sample` ← `pbmc_kang2018_sample.tab.gz` (datasets.biolab.si)

14.06
Single-cell

Médula ósea en AML y sana (van Galen 2019)

`14_single_cell/galen2019_aml/`

Médula ósea de un paciente con leucemia mieloide aguda antes y después de la quimioterapia, y la de un donante sano, célula a célula: explorar sin etiquetas y comparar muestras.

Clustering · Exploración y visualización · ⋮ Alta dimensionalidad · ◷ Temporal

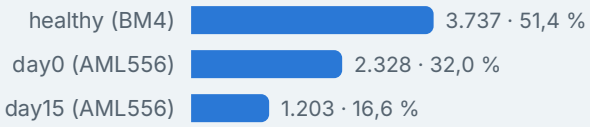
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
2.328	**27.701**	–	**0,0 %**	**Avanzado**	**Single Cell**

Fichero	Filas × col.	Descargar
`galen2019_aml_bone_marrow_day0`	2.328 × 27.701	CSV 4,9 MB sin XLSX: estimado 113 MB > 100 MB
`galen2019_aml_bone_marrow_day15`	1.203 × 27.701	CSV 66,9 MB · XLSX XLSX recortado a 16.384 columnas
`galen2019_healthy_bone_marrow`	3.737 × 27.701	CSV 8,8 MB sin XLSX: estimado 182 MB > 100 MB

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/14_single_cell/galen2019_aml/` seguido del nombre del fichero CSV.

Radiografía

Células por fichero



1 Descripción general y estudios habituales

Son tres ficheros de **recuentos de RNA-seq de célula única** (Seq-Well), todos con los mismos 27.699 genes. Cada fila es una célula.

- `galen2019_aml_bone_marrow_day0`: paciente AML556 antes de la quimioterapia, 2.328 células.
- `galen2019_aml_bone_marrow_day15`: el mismo paciente 15 días después, 1.203 células.
- `galen2019_healthy_bone_marrow`: donante sano (BM4), 3.737 células.

No hay tipo celular ni clase. Estudios habituales: **agrupar** y anotar tipos celulares, **comparar** las muestras (qué poblaciones desaparecen con el tratamiento) y **puntuar** células con marcadores de células malignas.

2 Contexto y fuente original

Es el estudio de Peter van Galen y colaboradores (Broad y Dana-Farber, 2019). Secuenciaron unas 38.000 células de 40 muestras de médula (16 pacientes con AML y 5 donantes sanos), y describieron una jerarquía de células malignas parecida a la normal. También vieron que las células malignas diferenciadas frenan la respuesta inmune. Orange ofrece solo un paciente y un donante.

- van Galen, P. et al. (2019). Single-cell RNA-seq reveals AML hierarchies relevant to disease progression and immunity. Cell, 176(6), 1265–1281. Datos: NCBI GEO, GSE116256.

3 Variable objetivo

Sin objetivo: es para exploración no supervisada. Una tarea supervisada sencilla es unir las muestras con *Concatenate*. Así se crea una columna con el fichero de origen, que puede servir de clase: «¿de qué muestra viene esta célula?». Ten en cuenta que muestra, día y lote van juntos.

4 Diccionario de columnas

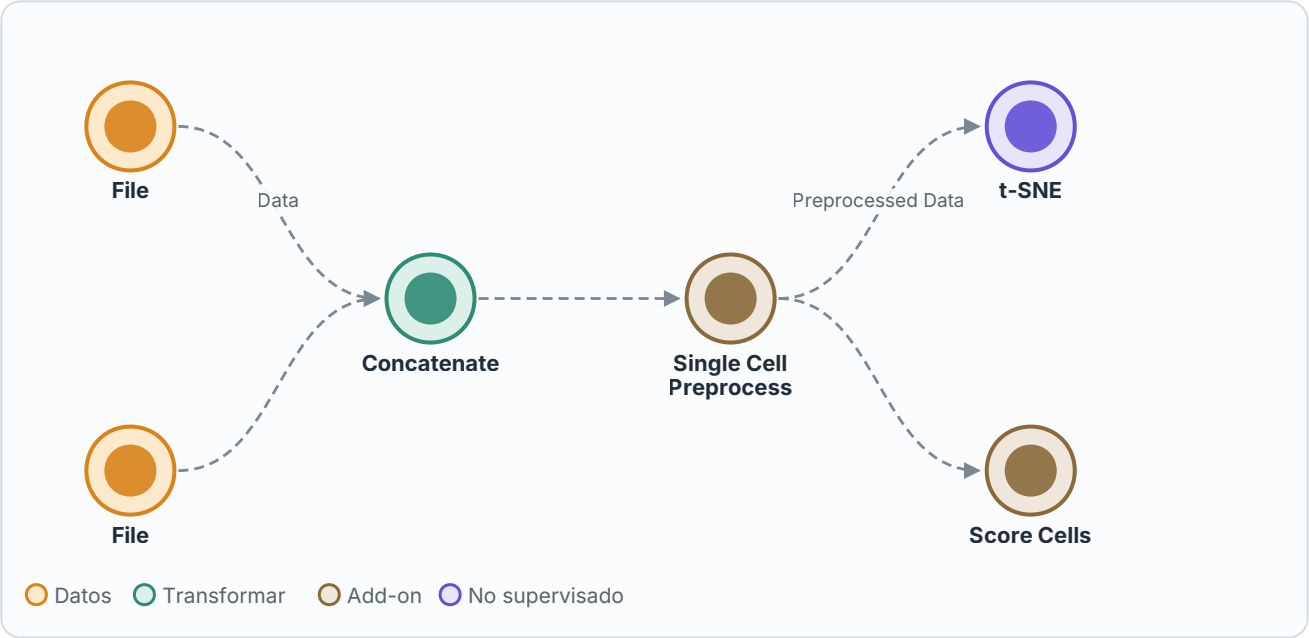
Columnas de `galen2019_aml_bone_marrow_day15` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`index`	texto	Identificador de la célula: muestra y código de barras (`AML556-D15_AAAAAGGTGCTN`), meta.	AML556-D15_AAAAAGGTGCTN (1), AML556-D15_AAAAAGGTTTCT (1), AML556-D15_AAAACCTCGGTN (1), AML556-D15_AAACACTAAGGN (1), AML556-D15_AAACAGCTACAA (1), AML556-D15_AAACCTCCGGGA (1) …
`source`	categórica	Fichero original de la muestra (`AML556-D15.dem.txt`); un solo valor por fichero, meta.	AML556-D15.dem.txt (1.203)
…		y 27.699 columnas más: recuento (UMI) de cada gen (símbolo HGNC).	

5 Particularidades técnicas al modelar

- **No hay día 31**: Orange ofrece también `galen2019_AML_bone_marrow_day31` , pero es una copia exacta del día 15 (mismas 1.203 células; su `source` dice `AML556-D15.dem.txt`). Por eso no se incluye en esta colección. El día 31 real está en GEO (GSM3587967).
- **Recuentos brutos**, con entre el 95 % y el 97 % de ceros: normaliza por biblioteca y aplica log.
- **Ficheros grandes**: day0 y la muestra sana van en ZIP y sin XLSX. El XLSX de day15 está recortado a 16.384 columnas.
- **Un solo paciente**: lo que veas entre días puede ser del paciente y no general.

6 Flujo de trabajo en Orange



1. Dos **File** (descomprime los ZIP) y **Concatenate**, con la opción de añadir el nombre del fichero de origen.
2. **Single Cell Preprocess**: normaliza, aplica log y quédate con los genes variables.
3. **t-SNE** coloreado por origen: qué poblaciones son propias del paciente y cuáles se comparten con el sano.
4. **Score Cells** con marcadores de progenitores (`CD34`) o de monocitos (`CD14`).

7 Otras consideraciones

- **Comparar con** `aml_single_cell` : es otra técnica (10x) y otro paciente con AML.

En la carpeta	`galen2019_aml_bone_marrow_day0` ← `galen2019_AML_bone_marrow_day0.pkl.gz` (datasets.biolab.si)
En la carpeta	`galen2019_aml_bone_marrow_day15` ← `galen2019_AML_bone_marrow_day15.pkl.gz` (datasets.biolab.si)
En la carpeta	`galen2019_healthy_bone_marrow` ← `galen2019_healthy_bone_marrow.pkl.gz` (datasets.biolab.si)
Duplicado, no se copia	`galen2019_AML_bone_marrow_day31.pkl.gz` (datasets.biolab.si)

14.07
Single-cell

Linfocitos T CD8+ agotados (Miller 2019)

`14_single_cell/miller2019_cd8/`

Linfocitos T CD8⁺ «agotados» de ratón, de una infección viral crónica y de un tumor: buscar sin etiquetas las subpoblaciones progenitora y terminal que responden de forma distinta a la inmunoterapia.

Clustering | Exploración y visualización | ⋮ Alta dimensionalidad

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
9.197	**22.193**	–	**0,0 %**	**Avanzado**	**Single Cell**

Fichero	Filas × col.	Descargar
`miller2019_chronically_infected_cd8`	9.197 × 22.193	CSV 19,5 MB sin XLSX: estimado 449 MB > 100 MB
`miller2019_tumor_infiltrating_cd8`	11.805 × 22.193	CSV 40,9 MB sin XLSX: estimado 587 MB > 100 MB

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/14_single_cell/miller2019_cd8/` seguido del nombre del fichero CSV.

Radiografía

Células por fichero



1 Descripción general y estudios habituales

Hay dos ficheros grandes de **recuentos de 10x** con los mismos 22.191 genes de ratón. Cada fila es una célula.

- `miller2019_chronically_infected_cd8`: 9.197 linfocitos T CD8⁺ de ratones con infección crónica por LCMV (clon 13).
- `miller2019_tumor_infiltrating_cd8`: 11.805 linfocitos T CD8⁺ que infiltran tumores B16-OVA.

No hay etiquetas. Estudios habituales: **agrupar**, **puntuar células** con firmas de agotamiento, **comparar** infección y tumor, y estudiar **trayectorias** de diferenciación.

2 Contexto y fuente original

Es el estudio de Brian Miller y colaboradores (Dana-Farber, 2019) sobre el agotamiento de los linfocitos T. Hay dos subpoblaciones. Los **progenitores agotados** (`Tcf7`⁺, `Slamf6`⁺) se renuevan y responden al bloqueo de

PD-1. Los **terminalmente agotados** (`Havcr2`$^+$, es decir, Tim-3$^+$) matan mejor a las células tumorales, pero no responden a ese bloqueo.

- Miller, B. C. et al. (2019). Subsets of exhausted CD8+ T cells differentially mediate tumor control and respond to checkpoint blockade. Nature Immunology, 20(3), 326–336. Datos: NCBI GEO, GSE122712 y GSE122675.

3 Variable objetivo

Sin objetivo. Una tarea guiada es puntuar cada célula con dos firmas:

- progenitora: `Tcf7`, `Slamf6`;
- terminal: `Havcr2`, `Gzmb`, `Cx3cr1`.

Después agrupa las células y mira cómo se reparten las dos puntuaciones. Si unes los dos ficheros con *Concatenate*, el origen (infección o tumor) sirve de clase. Ojo: también es el lote.

4 Diccionario de columnas

Columnas de `miller2019_tumor_infiltrating_cd8` (valores observados en el fichero)

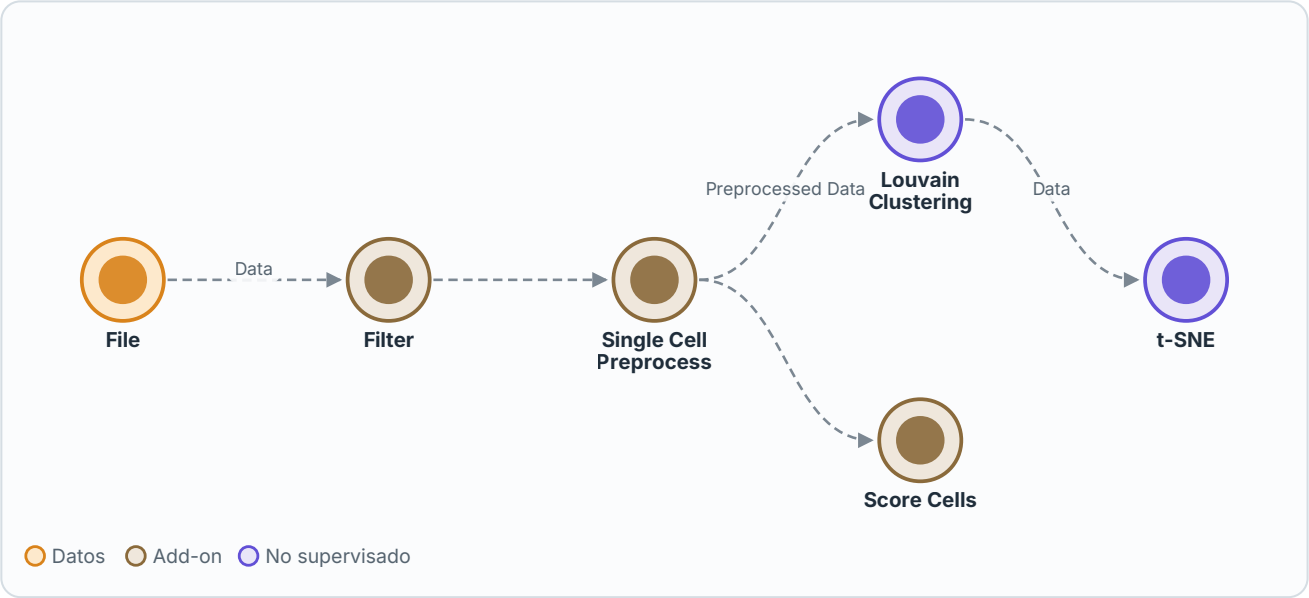
Columna	Tipo	Significado	Valores
`Barcodes`	texto	Código de barras 10x de la célula (`AAACCTGCAGAGCCAA-1`), meta.	
`source`	categórica	Vale `matrix.mtx` en todas las filas: no aporta nada. Quítala.	
…		y 22.191 columnas más: recuento (UMI) de cada gen (símbolo MGI de ratón).	

`miller2019_chronically_infected_cd8` tiene las mismas columnas con el mismo significado que `miller2019_tumor_infiltrating_cd8`.

5 Particularidades técnicas al modelar

- **Muy grandes**: los dos van en ZIP y no tienen XLSX, porque pasarían de 400 MB. Para probar rápido, filtra genes poco expresados nada más cargar (*Filter* del add-on *Single Cell*).
- **Recuentos brutos**: normaliza por biblioteca y aplica log.
- `source` **es inútil**: tiene un solo valor, el nombre del fichero de 10x.
- **Los códigos de barras pueden repetirse** entre los dos ficheros: si los unes, el identificador ya no es único.

6 Flujo de trabajo en Orange



1. **File** con el CSV descomprimido; `source` se puede quitar.
2. **Filter**: quita las células con pocos genes y los genes presentes en pocas células.
3. **Single Cell Preprocess**: normaliza por biblioteca, aplica log y quédate con los genes variables.
4. **Louvain Clustering** y **t-SNE**, y colorea por la expresión de `Tcf7` y de `Havcr2`.
5. **Score Cells** con las firmas progenitora y terminal.

7 Otras consideraciones

- **Del mismo capítulo**: `pbmc_kang2018` también es de linfocitos, pero humanos y de sangre, con un estímulo controlado.

En la carpeta	`miller2019_chronically_infected_cd8` ← `miller2019_chronically_infected_CD8.pkl.gz` (datasets.biolab.si)
En la carpeta	`miller2019_tumor_infiltrating_cd8` ← `miller2019_tumor_infiltrating_CD8.pkl.gz` (datasets.biolab.si)

14.08
Single-cell

Células madre hematopoyéticas de ratón (Nestorowa 2016)

`14_single_cell/nestorowa_hspc/`

Progenitores hematopoyéticos de médula de ratón secuenciados uno a uno (Smart-seq2): sin etiquetas, sirve para estudiar el ciclo celular y la diferenciación hacia los distintos linajes de la sangre.

Clustering · Exploración y visualización · ⋮ Alta dimensionalidad

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
774	**23.930**	–	**0,0 %**	**Avanzado**	**Single Cell**

Fichero	Filas × col.	Descargar
`nestorowa_forcellcycle`	774 × 23.930	CSV 44,3 MB · XLSX XLSX recortado a 16.384 columnas

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/14_single_cell/nestorowa_hspc/` seguido del nombre del fichero CSV.

1 Descripción general y estudios habituales

Hay un fichero con 774 células y 23.929 genes de ratón (recuentos de lecturas). Cada fila es una célula. Solo hay una columna más, el identificador (`cell_ID`).

No hay etiquetas. Estudios habituales: **asignar la fase del ciclo celular** con genes marcadores (de ahí el nombre `forcellcycle`), **agrupar**, y **ordenar** las células en trayectorias de diferenciación.

2 Contexto y fuente original

Es el mapa de células madre y progenitoras hematopoyéticas de Sonia Nestorowa y colaboradores (Cambridge, 2016). En el estudio completo hay 1.656 células, separadas por citometría en varias regiones (*gates*). La descripción de Orange habla de esas 1.656, pero el fichero tiene 774. Todos los identificadores empiezan por `Prog_`, así que parece ser solo la región de progenitores.

- Nestorowa, S. et al. (2016). A single-cell resolution map of mouse hematopoietic stem and progenitor cell differentiation. Blood, 128(8), e20–e31. Datos: NCBI GEO, GSE81682.

3 Variable objetivo

Sin objetivo. Hay dos tareas guiadas:

- **Ciclo celular**: puntúa cada célula con genes de fase S (`MCM2`, `PCNA`) y de G2/M (`MKI67`, `CCNB1`). `cell_cycle_ccp` tiene datos de referencia con la fase conocida.
- **Linajes**: puntúa con marcadores de eritroides (`GATA1`), neutrófilos (`MPO`, `ELANE`) y progenitores multipotentes (`FLT3`, `CD34`).

4 Diccionario de columnas

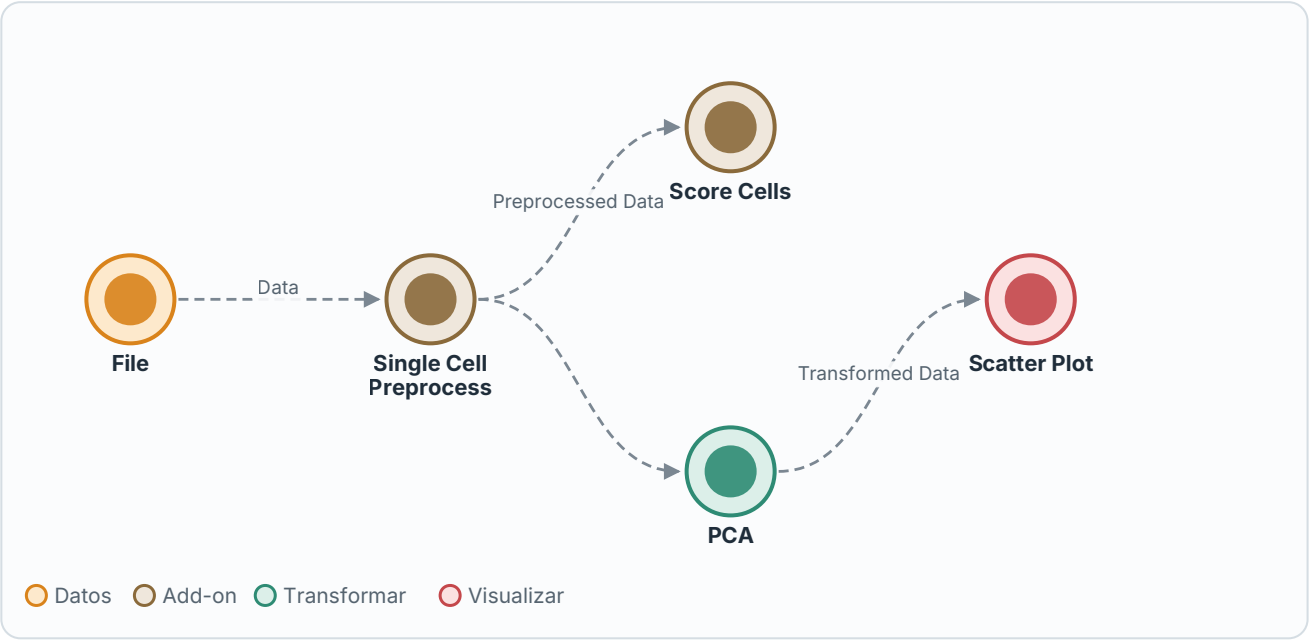
Columnas de `nestorowa_forcellcycle` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`cell_ID`	texto	Identificador de la célula (`Prog_013`), meta.	Prog_013 (1), Prog_019 (1), Prog_031 (1), Prog_037 (1), Prog_008 (1), Prog_014 (1) …
…		y 23.929 columnas más: recuento de lecturas de cada gen (símbolo de ratón escrito en mayúsculas).	

5 Particularidades técnicas al modelar

- **Genes de ratón en mayúsculas** (`GATA1` , `CD34`), aunque lo habitual en ratón es `Gata1` . Tenlo en cuenta al buscar marcadores o al cruzar con otros conjuntos.
- **Muchas lecturas por célula** (cerca de 1,8 millones de media), como es normal en Smart-seq2: normaliza por biblioteca y aplica log.
- **Subconjunto**: no está el estudio completo, así que no esperes ver las células madre de largo plazo.
- **Más de 16.384 columnas**: el XLSX está recortado; el CSV tiene todas.

6 Flujo de trabajo en Orange



1. **File** con `nestorowa_forcellcycle.csv` .
2. **Single Cell Preprocess**: normaliza, aplica log y quédate con los genes variables.
3. **Score Cells** con genes del ciclo y **PCA** → **Scatter Plot**, coloreado por la puntuación. Mira si el ciclo explica alguna componente principal.

7 Otras consideraciones

- **Para validar el método del ciclo**: aplica primero las mismas puntuaciones a `cell_cycle_ccp` (Buettner), donde se conoce la fase, y luego a este conjunto.

En la carpeta `nestorowa_forcellcycle` ← `nestorawa_forcellcycle.pkl.gz` (datasets.biolab.si)

14.09
Single-cell

Neuronas de proyección de Drosophila (Li 2017)

`14_single_cell/li2017_neurons/`

Neuronas de proyección olfativas del cerebro de la mosca Drosophila: 1.842 células con 13.898 genes, y metadatos que dicen con qué línea genética se marcó cada una.

Clustering · Exploración y visualización · ⋮ Alta dimensionalidad · ? Valores faltantes

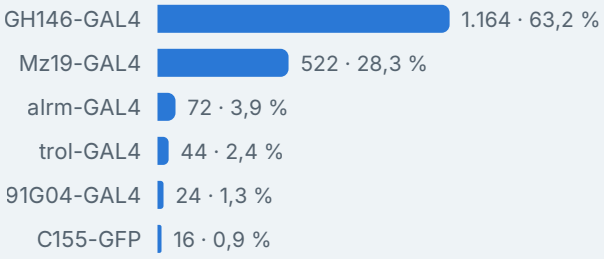
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
1.842	**13.920**	–	**0,0 %**	**Avanzado**	**Single Cell y Bioinformatics**

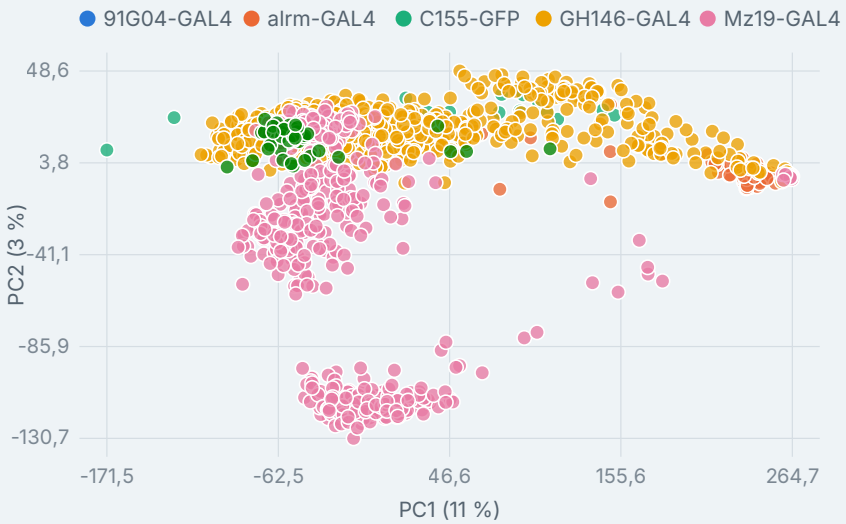
Fichero	Filas × col.	Descargar
`dm_proj_neurons_li2017`	1.842 × 13.920	CSV 73,5 MB · XLSX

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/14_single_cell/li2017_neurons/` seguido del nombre del fichero CSV.

Radiografía

Células por genotipo (línea GAL4)





1 Descripción general y estudios habituales

Cada fila es una neurona del cerebro de pupa de *Drosophila melanogaster* y cada columna, la expresión de un gen en TPM. Al principio hay 22 columnas de metadatos con el formato de Expression Atlas: tipo celular, genotipo, calidad, sexo…

Las células se marcaron con distintas líneas GAL4, que iluminan grupos concretos de neuronas o glía. Por eso el genotipo indica de qué tipo es cada célula.

Estudios habituales: **agrupar** subtipos neuronales, **marcadores** de cada subtipo y **clasificar** por genotipo.

2 Contexto y fuente original

Es el estudio de Hongjie Li y colaboradores (Stanford, 2017). Clasificaron por transcriptoma los subtipos de neuronas de proyección olfativa, cada uno ligado a un glomérulo del lóbulo antenal, y encontraron factores de transcripción y moléculas de superficie propios de cada subtipo. Los datos vienen de Expression Atlas (E-GEOD-100058).

- Li, H. et al. (2017). Classifying Drosophila olfactory projection neuron subtypes by single-cell RNA sequencing. Cell, 171(5), 1206–1220. Datos: NCBI GEO, GSE100058 (Expression Atlas E-GEOD-100058).

3 Variable objetivo

Orange no marca objetivo, pero `Sample Characteristic[genotype]` sirve como clase. Tiene seis valores: `GH146-GAL4` (1.164), `Mz19-GAL4` (522), `alrm-GAL4` (72, astrocitos), `trol-GAL4` (44), `91G04-GAL4` (24) y `C155-GFP` (16).

Con log, PCA de 50 componentes y regresión logística se acierta el **96 %** (5 bolsas, *scikit-learn*). Pero las clases pequeñas fallan mucho: `91G04` acierta 11 de 24 y `C155` 10 de 16, porque casi siempre se confunden con `GH146`. Es lógico: GH146 marca un conjunto amplio de neuronas de proyección que incluye a las otras.

4 Diccionario de columnas

Columnas de `dm_proj_neurons_li2017` (valores observados en el fichero)

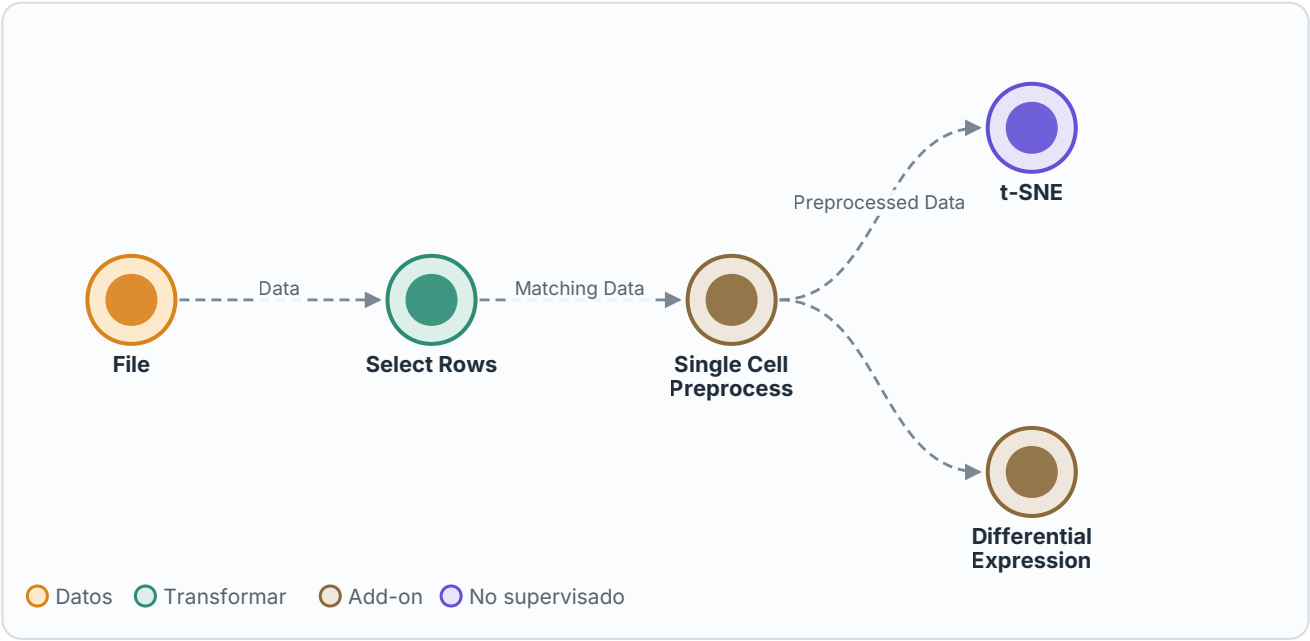
Columna	Tipo	Significado	Valores
`Barcodes`	texto	Identificador de la lectura en SRA (`SRR5686410`), meta.	SRR5686410 (1), SRR5686409 (1), SRR5686408 (1), SRR5686407 (1), SRR5686406 (1), SRR5686405 (1) …
`source`	categórica	Fichero de origen de Expression Atlas; un solo valor.	E-GEOD-100058.expression_tpm.mtx (1.842)
`Factor Value[single cell identifier]`	texto	Identificador de la célula en el experimento, meta.	N289Barcode_706-521 (1), N289Barcode_705-521 (1), N289Barcode_704-521 (1), N289Barcode_703-521 (1), N289Barcode_702-521 (1), N289Barcode_729-510 (1) …
`Sample Characteristic[cell type]`	categórica	Tipo celular según la línea de marcaje: neurona de proyección (a veces con el glomérulo que inerva), astrocito o neurona.	olfactory projection neuron (1.164), olfactory projection neuron innervating DA1, VA1d or DC3 … (522), astrocyte (72), olfactory projection neuron innervating VM2 glomerulus (44), olfactory projection neuron innvervating DC2 glomerulus (24), neuron (16)
`Sample Characteristic[genotype]`	categórica	Línea GAL4 con la que se marcó la célula (`GH146-GAL4` , `Mz19-GAL4` …). La mejor candidata a clase.	GH146-GAL4 (1.164), Mz19-GAL4 (522), alrm-GAL4 (72), trol-GAL4 (44), 91G04-GAL4 (24), C155-GFP (16)
`Sample Characteristic[single cell quality]`	categórica	Control de calidad: `OK` (1.837) o `not OK` (5). Quita estas cinco.	OK (1.837), not OK (5)
`Factor Value[cell type]`	categórica	Copia exacta de `Sample Characteristic[cell type]` .	olfactory projection neuron (1.164), olfactory projection neuron innervating DA1, VA1d or DC3 … (522), astrocyte (72), olfactory projection neuron innervating VM2 glomerulus (44), olfactory projection neuron innvervating DC2 glomerulus (24), neuron (16)
…		y 13.913 columnas más: 15 de metadatos (casi todas constantes o vacías) y, el resto, la expresión en TPM de cada gen (símbolo de FlyBase).	

5 Particularidades técnicas al modelar

- **Columnas de metadatos vacías**: cinco columnas «Ontology Term» no tienen ni un valor. Ellas son las 9.210 celdas faltantes del conjunto; los genes no tienen huecos. Quítalas.

- **Muchas columnas constantes**: el estadio (`pupal stage`), el órgano (`brain`), el sexo y el organismo valen lo mismo en todas las células.
- **Errata del original**: el tipo celular de las 24 células `91G04` dice «innervating» en vez de *innervating*.
- **TPM**: ya está normalizado por longitud y profundidad. Basta con aplicar log.
- **Genotipo y tipo celular son redundantes**: no uses uno para predecir el otro.

6 Flujo de trabajo en Orange



1. **File** con `dm_proj_neurons_li2017.csv`. Marca el genotipo como *target* y quita las columnas «Ontology Term» vacías.
2. **Select Rows**: quédate con las células de calidad `OK`.
3. **Single Cell Preprocess**: log y genes variables, sin normalizar por biblioteca.
4. **t-SNE** coloreado por genotipo: los astrocitos (`alrm`) se separan solos.
5. **Differential Expression** por genotipo (add-on *Bioinformatics*): `acj6` y `vvl` son factores de transcripción clásicos de estas neuronas, y `repo` marca la glía.

7 Otras consideraciones

- **Un caso fuera de mamíferos**: la mayoría de conjuntos de este capítulo son de humano o de ratón.

En la carpeta `dm_proj_neurons_li2017` ← `dm_proj_neurons_li2017.pkl.gz` (datasets.biolab.si)

14.10
Single-cell

Retina de ratón, Drop-seq (Macosko 2015)

`14_single_cell/macosko_retina/`

Células de retina de ratón medidas con Drop-seq, la técnica que popularizó la secuenciación de células en gotas: solo un tercio lleva etiqueta de tipo bipolar, y el resto es para descubrir.

Clasificación multiclase · Clustering · ⋮ Alta dimensionalidad · ? Valores faltantes

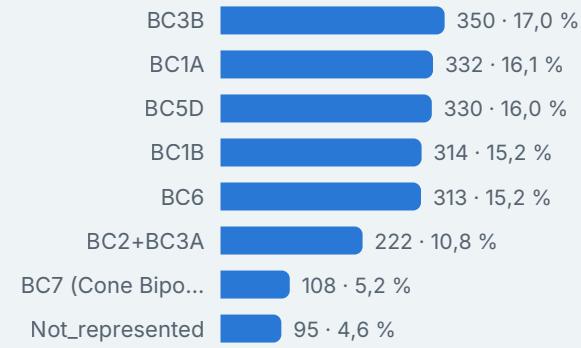
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
6.243	**6.862**	`Cluster ID`	**0,0 %**	**Avanzado**	**Single Cell**

Fichero	Filas × col.	Descargar
`cdp_expression_macosko`	6.243 × 6.862	CSV 85,9 MB sin XLSX: estimado 130 MB > 100 MB

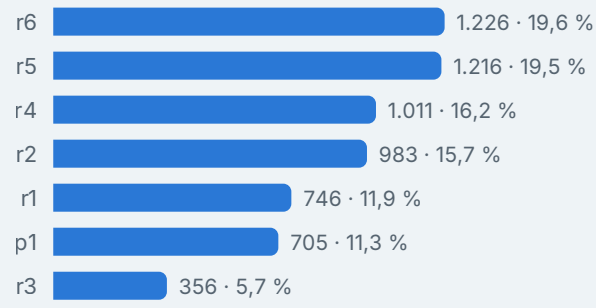
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/14_single_cell/macosko_retina/` seguido del nombre del fichero CSV.

Radiografía

Cluster ID en cdp_expression_macosko



Células por lote (prefijo de Cell ID)



1 Descripción general y estudios habituales

Hay un fichero de **recuentos de Drop-seq**: 6.243 células de retina de ratón y 6.860 genes, los que aparecen en al menos el 5 % de las células. Al final hay dos columnas, el tipo (`Cluster ID`) y el identificador de la célula.

`Cluster ID` es el tipo de célula **bipolar** (`BC1A`, `BC6` …) según el estudio original. Solo lo tienen 2.064 células (33 %); en las demás está vacío.

Estudios habituales: **agrupar** y descubrir tipos, **clasificar** con las células etiquetadas y **transferir etiquetas** desde un atlas de referencia (`shekhar_bipolar`).

2 Contexto y fuente original

Es el artículo de Evan Macosko y colaboradores (Harvard y Broad, 2015) que presentó **Drop-seq**. La técnica encapsula cada célula en una gota con una bola marcada con un código de barras, y así permite secuenciar miles de células a la vez. Lo demostraron con unas 44.000 células de retina de ratón. El prefijo `cdp` es el que usa Orange para estos datos y para los de Shekhar, que se suelen trabajar juntos.

- Macosko, E. Z. et al. (2015). Highly parallel genome-wide expression profiling of individual cells using nanoliter droplets. Cell, 161(5), 1202–1214. Datos: NCBI GEO, GSE63473.

3 Variable objetivo

`Cluster ID`, en las 2.064 células etiquetadas. Hay 7 grupos bipolares (de 108 a 350 células) y `Not_represented` (95).

Con normalización, log, PCA de 50 componentes y regresión logística se acierta el **91 %** (5 bolsas, *scikit-learn*). La clase mayoritaria da el 17 %. El tipo más difícil es `BC7`: 21 de sus 108 células se confunden con `BC6`.

4 Diccionario de columnas

Columnas de `cdp_expression_macosko` (valores observados en el fichero)

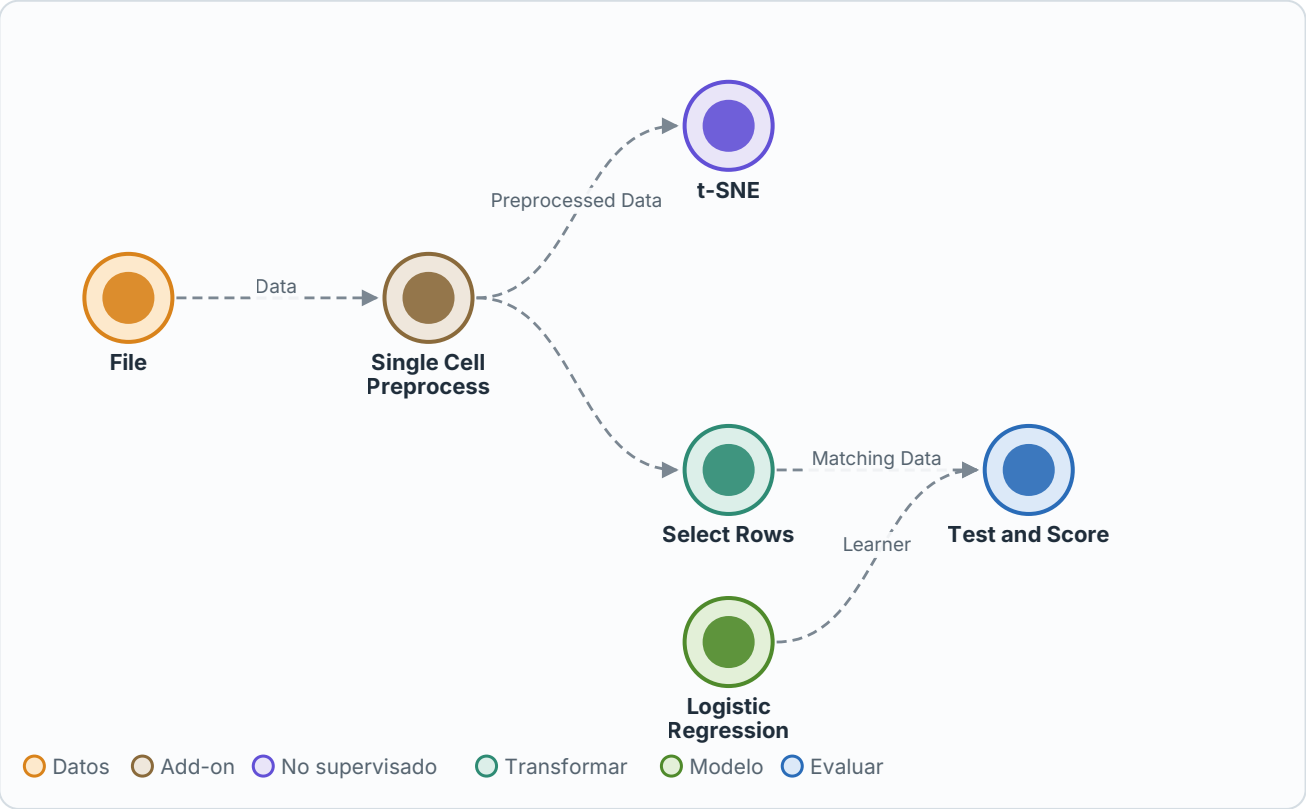
Columna	Tipo	Significado	Valores
`Cluster ID` objetivo	categórica	Tipo de célula bipolar del estudio (`BC1A` … `BC7`, `BC2+BC3A`, `Not_represented`); vacío en el 67 %. Objetivo.	BC3B (350), BC1A (332), BC5D (330), BC1B (314), BC6 (313), BC2+BC3A (222) …
`Cell ID`	texto	Lote y código de barras (`r1_GATTTCCTCTGA`). El prefijo (`r1` … `r6`, `p1`) parece la réplica: úsalo como lote.	r1_GATTTCCTCTGA (1), r1_GAAGGCTGGAAC (1), r1_TAGATTATTCAT (1), r1_TCAACACGCTCT (1), r1_CCCACTTCTTTG (1), r1_CCAATTTCTAAT (1) …
…		y 6.860 columnas más: recuento (UMI) de cada gen (símbolo de ratón en mayúsculas).	

5 Particularidades técnicas al modelar

- **Etiqueta incompleta**: 4.179 células sin `Cluster ID`. Para clasificar, quédate con las etiquetadas (*Select Rows*, «is defined»). Para descubrir tipos, usa todas.

- `Not_represented` **es un caso especial**: todas sus células son del lote `r1`. Puede ser un artefacto de lote y no un tipo celular.
- **Recuentos brutos y pocos por célula** (unos 2.500 de media): normaliza por biblioteca y aplica log.
- **Sin XLSX**: pasaría de 100 MB. El CSV no está comprimido (unos 85 MB).
- **Genes en mayúsculas** (`VSX2` , `PRKCA`), aunque es ratón.

6 Flujo de trabajo en Orange



1. **File** con `cdp_expression_macosko.csv` : `Cluster ID` como *target*, `Cell ID` como *meta*.
2. **Single Cell Preprocess**: normaliza, aplica log y quédate con los genes variables.
3. **t-SNE** coloreado por `Cluster ID` : las células sin etiqueta (gris), ¿forman grupos propios?
4. **Select Rows** («Cluster ID is defined») → **Test and Score** con **Logistic Regression**.

7 Otras consideraciones

- **Transferir etiquetas**: entrena con `shekhar_bipolar` (13 tipos, todas las células etiquetadas) y predice aquí las células sin etiqueta. Antes, quédate con los genes comunes a los dos conjuntos.

En la carpeta `cdp_expression_macosko` ← `cdp_expression_macosko.tab.gz` (datasets.biolab.si)

14.11
Single-cell

Células bipolares de retina de ratón (Shekhar 2016)

`14_single_cell/shekhar_bipolar/`

El atlas de las neuronas bipolares de la retina de ratón: 12.606 células en 13 tipos, todas etiquetadas. Es la referencia natural para anotar Macosko 2015.

Clasificación multiclase | Clustering | Alta dimensionalidad | Desbalanceado | Grande

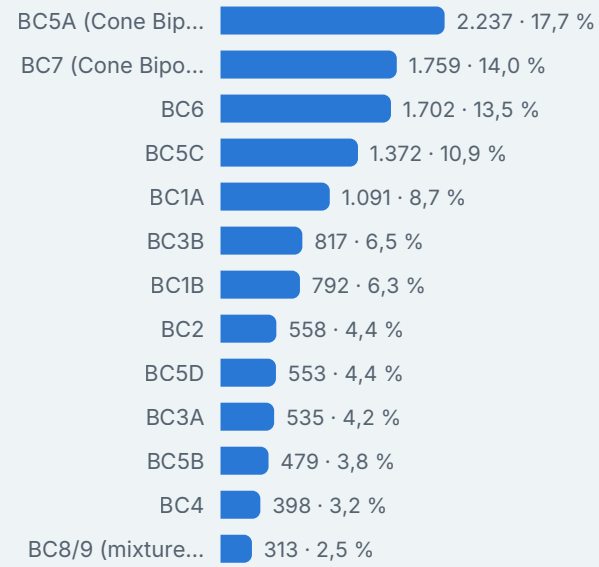
Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
12.606	**4.982**	`Cluster ID`	**0,0 %**	**Avanzado**	**Single Cell y Bioinformatics**

Fichero	Filas × col.	Descargar
`cdp_expression_shekhar`	12.606 × 4.982	CSV 11,5 MB sin XLSX: estimado 187 MB > 100 MB

Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/14_single_cell/shekhar_bipolar/` seguido del nombre del fichero CSV.

Radiografía

Cluster ID en cdp_expression_shekhar



1 Descripción general y estudios habituales

Hay un fichero de **recuentos de Drop-seq**: 12.606 células bipolares de retina de ratón y 4.980 genes, los que aparecen en al menos el 5 % de las células. Al final hay dos columnas, el tipo (`Cluster ID`) y el identificador.

Los 13 tipos van desde `BC5A` (2.237 células) hasta la mezcla `BC8/9` (313).

Estudios habituales: **clasificar** tipos, **marcadores** de cada tipo y servir de **referencia** para anotar otros conjuntos.

2 Contexto y fuente original

Es el estudio de Karthik Shekhar y colaboradores (Harvard y Broad, 2016). Enriquecieron las células bipolares de la retina con un ratón transgénico y las secuenciaron con Drop-seq. Encontraron 15 tipos, dos de ellos nuevos, y comprobaron su morfología. Se cita a menudo como ejemplo de **clasificación completa** de una familia de neuronas.

- Shekhar, K. et al. (2016). Comprehensive classification of retinal bipolar neurons by single-cell transcriptomics. Cell, 166(5), 1308–1323. Datos: NCBI GEO, GSE81905.

3 Variable objetivo

`Cluster ID`: 13 tipos de célula bipolar. Con normalización, log, PCA de 50 componentes y regresión logística se acierta el **98 %** (5 bolsas, *scikit-learn*). La clase mayoritaria da el 18 %. Todos los tipos superan el 94 %; los más difíciles son `BC4` y `BC8/9`.

Es más fácil que Macosko porque hay más células por tipo y el estudio enriqueció las bipolares.

4 Diccionario de columnas

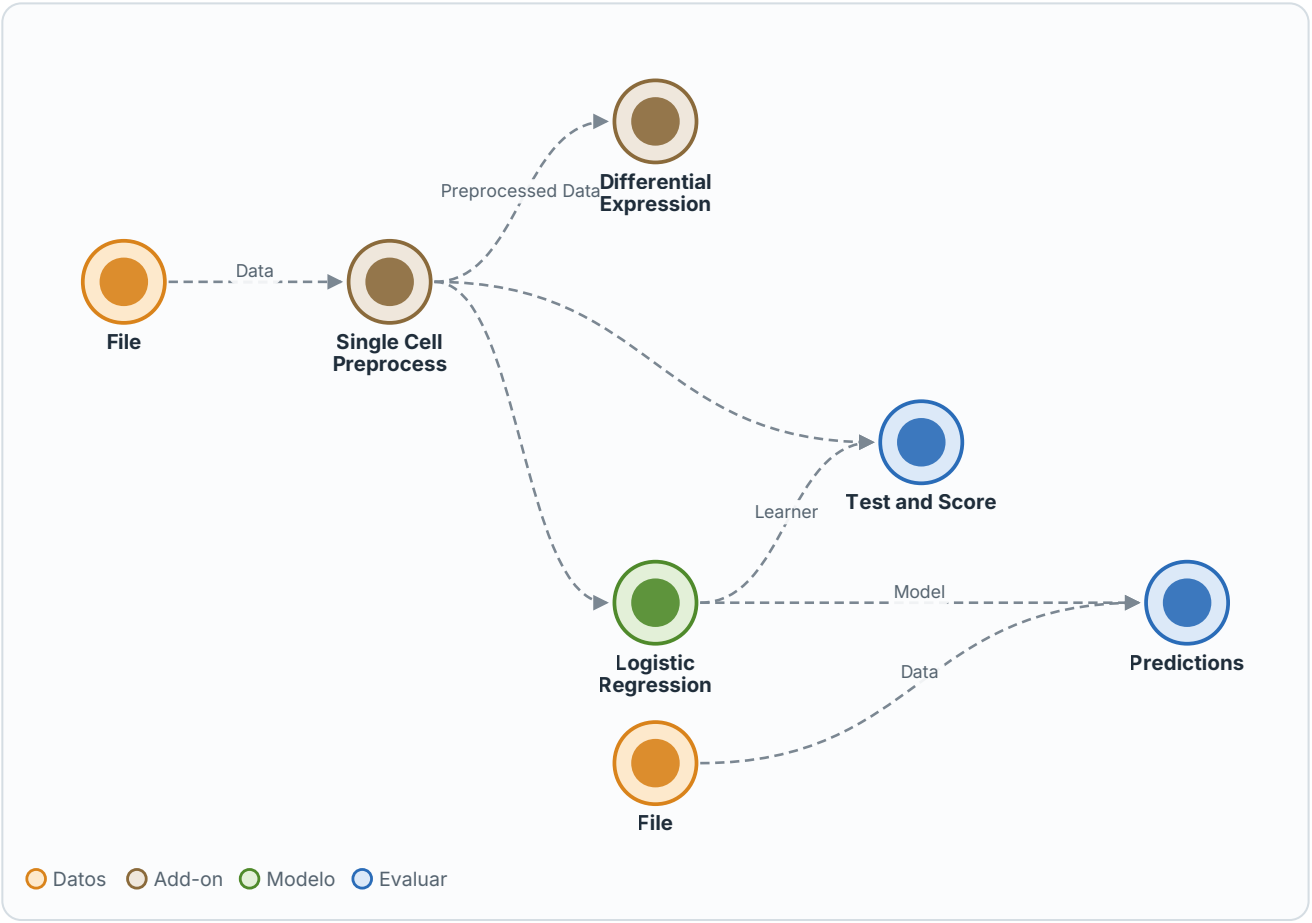
Columnas de `cdp_expression_shekhar` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`Cluster ID` objetivo	categórica	Tipo de célula bipolar (`BC1A` … `BC8/9`); algunos llevan una aclaración entre paréntesis. Objetivo.	
`Cell ID`	texto	Lote y código de barras (`Bipolar1_CCCACAAGACTA`). Hay seis lotes, de `Bipolar1` a `Bipolar6` .	
…		y 4.980 columnas más: recuento (UMI) de cada gen (símbolo de ratón en mayúsculas).	

5 Particularidades técnicas al modelar

- **Faltan las bipolares de bastón** (RBC), aunque el estudio sí las describe. Aquí solo hay bipolares de cono. Si transfieres etiquetas a otro conjunto, las RBC no tendrán clase.
- **Grande**: el CSV va en ZIP y no hay XLSX, porque pasaría de 180 MB.
- **Recuentos brutos**: normaliza por biblioteca y aplica log.
- **Seis lotes** (`Bipolar1` a `Bipolar6`): comprueba que los grupos no se separan por lote.
- **Etiquetas largas**: `BC5A (Cone Bipolar cell 5A)` y `BC5A` son el mismo tipo. Si cruzas con Macosko, unifica los nombres.

6 Flujo de trabajo en Orange



1. **File** con el CSV descomprimido: `Cluster ID` como *target*.
2. **Single Cell Preprocess**: normaliza, aplica log y quédate con los genes variables.
3. **Differential Expression** (add-on *Bioinformatics*), con `Cluster ID` como grupo: genes característicos de cada tipo bipolar.
4. **Test and Score** con **Logistic Regression**: cerca del 98 %.
5. **Predictions** sobre `macosko_retina`, con los genes comunes y el mismo preprocesado.

7 Otras consideraciones

- **Del mismo capítulo**: `macosko_retina` es la misma retina con la misma técnica, pero menos células y la mayoría sin etiqueta.

En la carpeta `cdp_expression_shekhar` ← `cdp_expression_shekhar.tab.gz` (datasets.biolab.si)

14.12
Single-cell

Ciclo celular: conjuntos de referencia (ccp)

`14_single_cell/cell_cycle_ccp/`

Cinco conjuntos pequeños de ratón para practicar la asignación de la fase del ciclo celular: en tres se conoce la fase (G1, S o G2/M) y en dos no.

Clasificación multiclase · Clustering · ⋮ Alta dimensionalidad · ∘ Juguete

Filas	Columnas	Variable objetivo	Faltantes	Nivel	Add-on de Orange
81	**38.293**	`cycleStageName`	**0,0 %**	**Avanzado**	**Single Cell**

Fichero	Filas × col.	Descargar
`ccp_tcells_all_genes`	81 × 38.293	CSV 21,5 MB · XLSX XLSX recortado a 16.384 columnas
`ccp_tcells_cycle_genes`	81 × 553	CSV 601 KB · XLSX
`ccp_liver_all_genes`	5 × 20.683	CSV 381 KB · XLSX XLSX recortado a 16.384 columnas
`ccp_liver_cycle_genes`	5 × 537	CSV 9 KB · XLSX
`ccp_mescbulk_all_genes`	4 × 38.294	CSV 901 KB · XLSX XLSX recortado a 16.384 columnas
`ccp_mescbulk_cycle_genes`	4 × 554	CSV 14 KB · XLSX
`ccp_buettner_all_genes`	182 × 38.294	CSV 16,3 MB · XLSX XLSX recortado a 16.384 columnas
`ccp_buettner_cycle_genes`	182 × 564	CSV 331 KB · XLSX
`ccp_mescquartz_all_genes`	35 × 36.808	CSV 3,3 MB · XLSX XLSX recortado a 16.384 columnas
`ccp_mescquartz_cycle_genes`	35 × 562	CSV 54 KB · XLSX

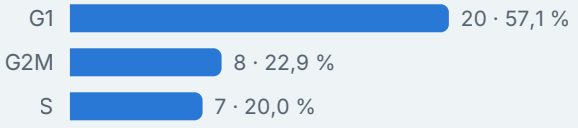
Para abrirlo en Orange sin descargarlo, pega en el widget *File* (campo *URL*): `https://raw.githubusercontent.com/gualbe/datasets/main/ciencia_de_datos/14_single_cell/cell_cycle_ccp/` seguido del nombre del fichero CSV.

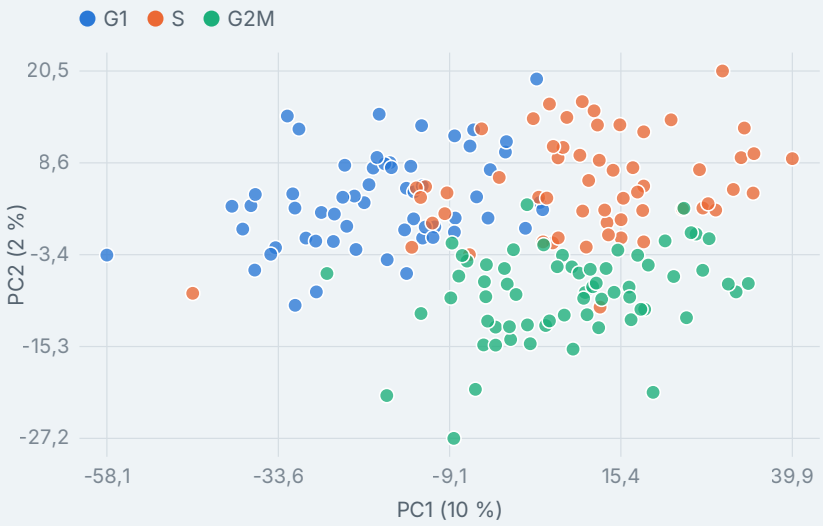
Radiografía

cycleStageName en ccp_buettner_cycle_genes



cycleStageName en ccp_mescquartz_cycle_genes





1 Descripción general y estudios habituales

Hay diez ficheros: cinco conjuntos, y cada uno viene en dos versiones. `all_genes` tiene todos los genes (de 20.683 a 38.293). `cycle_genes` tiene unos 550 genes ligados al ciclo celular según Gene Ontology. Cada fila es una célula, o una muestra en el caso del conjunto *bulk*.

Conjunto	Filas	Fase conocida	Medida
`buettner`: células madre embrionarias (mESC), Fluidigm C1	182	sí: G1 59, S 58, G2M 65	recuentos normalizados
`mescquartz`: mESC, Quartz-seq	35	sí: G1 20, S 7, G2M 8	FPKM
`mescbulk`: mESC en masa, separadas por fase	4	sí: Asy, G1, S, G2M	recuentos
`tcells`: linfocitos T CD4⁺ (TH2)	81	no	normalizado con ERCC
`liver`: células de hígado, Smart-seq	5	no (se esperan en G1)	recuentos

Estudios habituales: **clasificar** la fase con los conjuntos etiquetados y **aplicar** el modelo a los que no lo están.

2 Contexto y fuente original

Es la colección que usaron Antonio Scialdone y colaboradores (EMBL-EBI, 2015) para presentar *cyclone*. Ese método asigna la fase del ciclo a cada célula comparando pares de genes, y se entrena con células separadas por fase. Los datos vienen de varios estudios: Buettner et al. 2015, Sasagawa et al. 2013 (Quartz-seq), Mahata et al. 2014 (linfocitos T) y Deng et al. 2014 (hígado).

- Scialdone, A. et al. (2015). Computational assignment of cell-cycle stage from single-cell transcriptome data. Methods, 85, 54–61.
- Buettner, F. et al. (2015). Computational analysis of cell-to-cell heterogeneity in single-cell RNA-sequencing data reveals hidden subpopulations of cells. Nature Biotechnology, 33(2), 155–160. Datos: ArrayExpress E-MTAB-2805.
- Sasagawa, Y. et al. (2013). Quartz-Seq: a highly reproducible and sensitive single-cell RNA sequencing method, reveals non-genetic gene-expression heterogeneity. Genome Biology, 14, R31. Datos: NCBI GEO, GSE42268.

3 Variable objetivo

`cycleStageName` : G1, S o G2M, en los conjuntos etiquetados.

- En `buettner_cycle_genes` (182 células), con normalización, log, PCA y regresión logística se acierta el **93 %** (5 bolsas, *scikit-learn*). Los errores se reparten entre las tres fases.
- Los marcadores se comportan como se espera. La mediana de `Ccnb1` es de 1.404 en G1, 2.696 en S y 5.187 en G2M, y la de `Cdk1` también sube hacia G2M.

`mescquartz` (35 células) sirve como **test externo**: es otra técnica y otro laboratorio. `mescbulk` tiene solo cuatro filas y no da para entrenar.

4 Diccionario de columnas

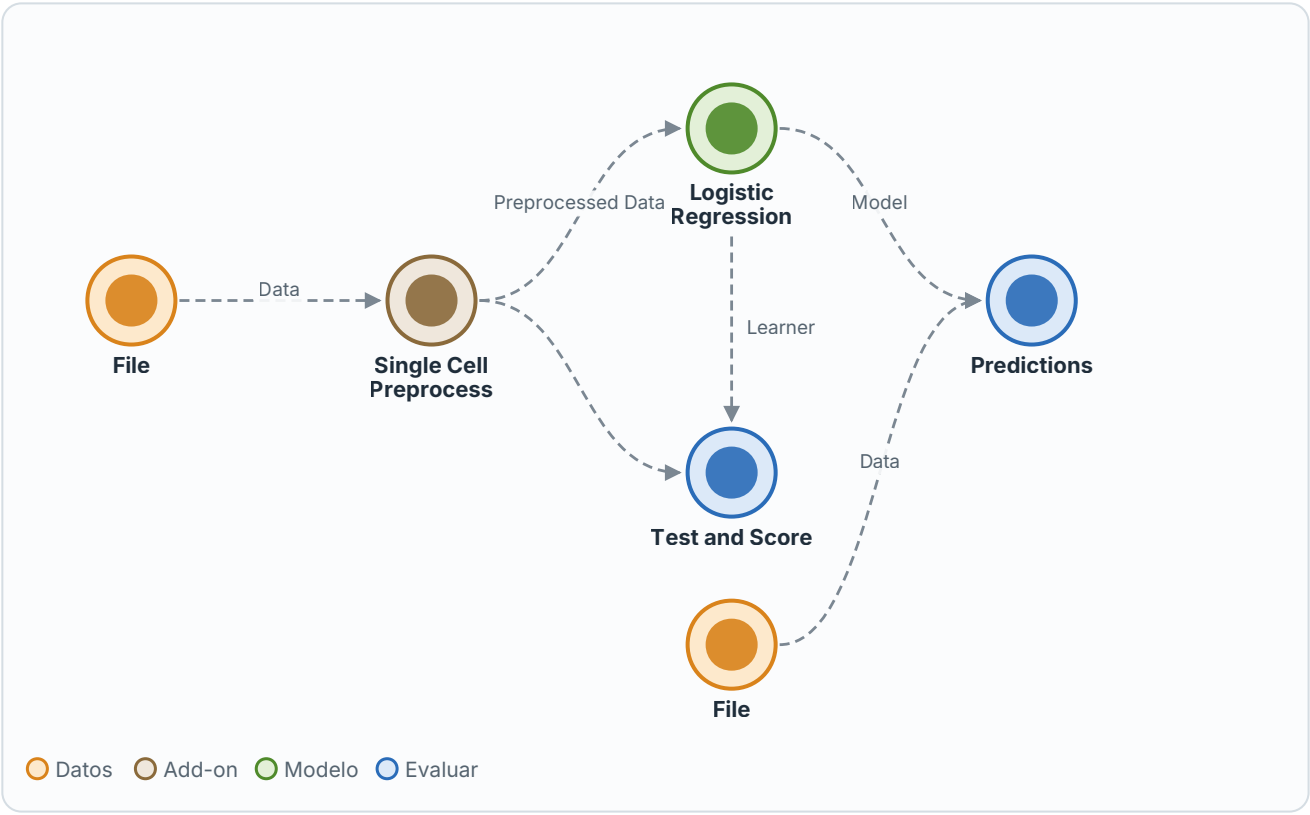
Columnas de `ccp_buettner_cycle_genes` (valores observados en el fichero)

Columna	Tipo	Significado	Valores
`cycleStageName` `objetivo`	categórica	Fase del ciclo celular según la separación por citometría: `G1` , `S` o `G2M` (en `mescbulk` , también `Asy` , población sin separar). Objetivo.	G2M (65), G1 (59), S (58)
…		y 563 columnas más: expresión de cada gen (símbolo MGI o identificador Ensembl ENSMUSG… si no tiene símbolo).	

5 Particularidades técnicas al modelar

- **Medidas distintas en cada conjunto** (recuentos, FPKM, normalizado con ERCC): para pasar un modelo de uno a otro, usa log y estandarización, o métodos basados en rangos.
- **Genes distintos en cada conjunto**: el número de genes del ciclo va de 537 a 563, según cuántos detectó cada estudio. Para aplicar un modelo a otro conjunto, quédate con los genes comunes.
- **Muy pocas filas** en `liver` (5) y `mescbulk` (4): son para ilustrar, no para entrenar.
- **Filas ordenadas por fase** en Buettner: baraja las filas o usa validación estratificada.
- **Muchas columnas**: los XLSX de `all_genes` están recortados a 16.384 columnas.

6 Flujo de trabajo en Orange



1. **File** con `ccp_buettner_cycle_genes.csv`: `cycleStageName` como *target*.
2. **Single Cell Preprocess**: normaliza y aplica log; con unos 550 genes no hace falta seleccionar más.
3. **Test and Score** con **Logistic Regression**: cerca del 93 %.
4. **Predictions** sobre `ccp_tcells_cycle_genes` (sin fase) o `ccp_mescquartz_cycle_genes` (con fase, como test externo). Usa el mismo preprocesado y los genes comunes.

7 Otras consideraciones

- **Aplicación real**: el ciclo celular suele ser una fuente de variación «molesta» en los datos de célula única. Saber la fase de cada célula sirve para corregirla. Pruébalo con `nestorowa_hspc`, cuyos nombres de gen van en mayúsculas.

En la carpeta	`ccp_tcells_all_genes` ← `ccp_data_Tcells_normCounts.counts.all_genes.tab.gz` (datasets.biolab.si)
En la carpeta	`ccp_tcells_cycle_genes` ← `ccp_data_Tcells_normCounts.counts.cycle_genes.tab.gz` (datasets.biolab.si)
En la carpeta	`ccp_liver_all_genes` ← `ccp_data_liver.counts.all_genes.tab.gz` (datasets.biolab.si)
En la carpeta	`ccp_liver_cycle_genes` ← `ccp_data_liver.counts.cycle_genes.tab.gz` (datasets.biolab.si)
En la carpeta	`ccp_mescbulk_all_genes` ← `ccp_data_mESCbulk.counts.all_genes.tab.gz` (datasets.biolab.si)
En la carpeta	`ccp_mescbulk_cycle_genes` ← `ccp_data_mESCbulk.counts.cycle_genes.tab.gz` (datasets.biolab.si)
En la carpeta	`ccp_buettner_all_genes` ← `ccp_normCountsBuettnerEtAl.counts.all_genes.tab.gz` (datasets.biolab.si)

En la carpeta	`ccp_buettner_cycle_genes` ← `ccp_normCountsBuettnerEtAl.counts.cycle_genes.tab.gz` (datasets.biolab.si)
En la carpeta	`ccp_mescquartz_all_genes` ← `ccp_normCounts_mESCquartz.counts.all_genes.tab.gz` (datasets.biolab.si)
En la carpeta	`ccp_mescquartz_cycle_genes` ← `ccp_normCounts_mESCquartz.counts.cycle_genes.tab.gz` (datasets.biolab.si)

Índice por etiquetas

Clasificación binaria

1.02 Tennis / Weather (Quinlan) · p. 20
1.03 Sailing · p. 24
1.05 Naughty or nice · p. 30
1.08 Titanic (supervivientes) · p. 41
1.10 MONK's problems · p. 49
1.11 Mushroom (setas) · p. 53
1.13 Congressional Voting Records 1984 · p. 63
1.14 Bicycle rides (gravel vs mountain) · p. 67
2.01 Pima Indians Diabetes · p. 71
2.02 Heart Disease (Cleveland) · p. 75
2.03 Breast Cancer (Ljubljana) · p. 79
2.04 Breast Cancer Wisconsin (original) · p. 83
2.05 Breast Cancer Wisconsin Diagnostic (WDBC) · p. 87
2.06 Prostate Cancer (Kaggle) · p. 92
2.07 Cervical Cancer Risk Factors (cáncer de útero) · p. 96
2.08 Stroke Prediction (ictus) · p. 100
2.12 BUPA Liver Disorders · p. 117
3.01 Adult (Census Income) · p. 127
3.02 Bank Marketing (bank-additional) · p. 132
3.03 German Credit · p. 137
3.04 COMPAS (reincidencia a dos años) · p. 143
3.05 Telco Customer Churn · p. 149
3.06 IBM HR Employee Attrition · p. 153
3.07 Kickstarter · p. 159
4.02 Ionosphere · p. 172
4.05 E. coli promoter gene sequences · p. 183
10.05 Cuentos de Grimm y Andersen (en esloveno) · p. 418
11.02 Bone healing (consolidación de fracturas) · p. 429
11.05 Competencia de ovocitos · p. 442
13.01 GDS360: resistencia a docetaxel en cáncer de mama · p. 491
13.02 GDS3713: linfocitos B de fumadores · p. 495
13.03 GDS4168: linfocitos B en leucemia linfática crónica · p. 498
14.05 PBMC estimuladas con interferón beta (Kang 2018) · p. 519

Clasificación multiclase

1.01 Iris (Fisher) · p. 16
1.04 Lenses (lentes de contacto) · p. 27
1.06 Gnomes (gnomos) · p. 33
1.07 Zoo · p. 36
1.09 Car Evaluation · p. 45
1.12 Soybean (enfermedades de la soja) · p. 58
2.09 Dermatology · p. 104
2.10 Lymphography · p. 109
2.11 Primary Tumor · p. 113
2.13 Mice Protein Expression (ratones con síndrome de Down) · p. 120
3.08 NBA players · p. 164
4.01 Glass Identification · p. 168
4.03 Vehicle Silhouettes · p. 175
4.04 Wine (cultivares italianos) · p. 179
4.06 Poker Hand · p. 186
5.06 Abalone · p. 211
5.11 Wine Quality (vinho verde) · p. 229
6.05 Climate of European cities (Köppen) · p. 266
6.08 Food nutrition info · p. 277
6.09 Pittsburgh Bridges · p. 281
10.01 BBC news (3 categorías) · p. 405
10.02 ParlaMint-GB (1000 discursos) · p. 408
10.03 SentiNews (noticias eslovenas) · p. 412
10.04 Medical transcriptions (mtsamples) · p. 415
10.06 Words y words-food · p. 421
11.01 Ánforas romanas · p. 424
11.03 Dictyostelium: desarrollo · p. 433
11.04 Hojas del parque de Luxemburgo · p. 437
11.06 Perros de razas tibetanas · p. 445
11.07 Señales de tráfico · p. 449
11.08 Localización de proteínas de levadura (YPL+) · p. 453
11.10 Photographers (fotos personales por temas) · p. 461
11.11 Hollywood faces (caras de 17 famosos) · p. 466
11.13 Satellite (imágenes de satélite en 4 clases) · p. 474
12.01 TKI resistance (espectroscopía IR) · p. 479
12.04 Liver cells (FTIR) · p. 488
13.04 Brown et al.: expresión génica de levadura · p. 501
14.01 Células dendríticas y monocitos (Villani 2017) · p. 504
14.02 AML: médula ósea con leucemia mieloide aguda · p. 508
14.03 Páncreas humano (Baron 2016) · p. 512
14.04 Páncreas humano y diabetes tipo 2 (Xin 2016) · p. 516
14.10 Retina de ratón, Drop-seq (Macosko 2015) · p. 535
14.11 Células bipolares de retina de ratón (Shekhar 2016) · p. 538
14.12 Ciclo celular: conjuntos de referencia (ccp) · p. 541

Regresión

2.14 Health survey (encuesta de hábitos) · p. 124
5.01 Boston Housing · p. 190
5.02 California Housing · p. 194
5.03 Ames Iowa Housing · p. 198
5.04 Auto MPG · p. 203
5.05 Automobile (imports-85) · p. 207
5.06 Abalone · p. 211
5.07 Body Fat (Brozek) · p. 214
5.08 Advertising (ISLR) · p. 218
5.09 Diabetes (progresión, Efron et al.) · p. 221
5.10 Forest Fires (Montesinho) · p. 225
5.11 Wine Quality (vinho verde) · p. 229
5.12 Energy Efficiency (ENB2012) · p. 234
5.13 Hitters (salarios de béisbol, ISLR) · p. 238
5.14 Multitarget synthetic · p. 242
9.05 Superstore sales · p. 389
9.06 Meteorología diaria de Huelva (humedad relativa) · p. 395
9.07 Ozono y contaminantes horarios en Aljarafe (Sevilla) · p. 400

Clustering

2.13 Mice Protein Expression (ratones con síndrome de Down) · p. 120
2.14 Health survey (encuesta de hábitos) · p. 124
3.08 NBA players · p. 164
4.04 Wine (cultivares italianos) · p. 179
6.01 Grades (notas de estudiantes) · p. 245
6.02 Mathematics and football · p. 249
6.03 Human Development Index (HDI) · p. 252
6.04 Clima mensual por continentes · p. 260
6.05 Climate of European cities (Köppen) · p. 266
6.06 Frecuencias de letras por idioma · p. 270
6.07 Machine learning conferences · p. 274
6.08 Food nutrition info · p. 277
6.10 Banking crises · p. 284
6.11 UL Rector Elections 2009 · p. 287
6.12 Slovenian National Assembly (votaciones) · p. 290
6.13 Slovenian surnames · p. 294
6.17 Philadelphia crime · p. 308
6.18 EWBA: vertederos ilegales en Eslovenia · p. 312
6.19 Accidentes de tráfico en Eslovenia 2016 · p. 317
6.20 Renovables por país (Socioeconomic Indices, Banco Mundial) · p. 324
11.01 Ánforas romanas · p. 424
11.02 Bone healing (consolidación de fracturas) · p. 429
11.03 Dictyostelium: desarrollo · p. 433
11.04 Hojas del parque de Luxemburgo · p. 437
11.06 Perros de razas tibetanas · p. 445
11.07 Señales de tráfico · p. 449
11.09 Animales domésticos · p. 458
11.10 Photographers (fotos personales por temas) · p. 461
11.11 Hollywood faces (caras de 17 famosos) · p. 466
11.12 Paintings (15 cuadros de 14 pintores) · p. 470
11.13 Satellite (imágenes de satélite en 4 clases) · p. 474
12.02 Hair (FTIR hiperespectral) · p. 482
12.03 Liver cirrhosis (FTIR hiperespectral) · p. 485
13.04 Brown et al.: expresión génica de levadura · p. 501
14.01 Células dendríticas y monocitos (Villani 2017) · p. 504
14.02 AML: médula ósea con leucemia mieloide aguda · p. 508
14.03 Páncreas humano (Baron 2016) · p. 512
14.04 Páncreas humano y diabetes tipo 2 (Xin 2016) · p. 516
14.05 PBMC estimuladas con interferón beta (Kang 2018) · p. 519
14.06 Médula ósea en AML y sana (van Galen 2019) · p. 523
14.07 Linfocitos T CD8+ agotados (Miller 2019) · p. 526
14.08 Células madre hematopoyéticas de ratón (Nestorowa 2016) · p. 529
14.09 Neuronas de proyección de Drosophila (Li 2017) · p. 531
14.10 Retina de ratón, Drop-seq (Macosko 2015) · p. 535
14.11 Células bipolares de retina de ratón (Shekhar 2016) · p. 538
14.12 Ciclo celular: conjuntos de referencia (ccp) · p. 541

Reglas de asociación

7.01 Market basket (ejemplo) · p. 333
7.02 Foodmart 2000 · p. 336
7.03 Online Retail (cestas) · p. 339

Análisis de supervivencia

8.01 Veterans' Administration Lung Cancer · p. 343
8.02 Melanoma (Odense) · p. 347
8.03 German Breast Cancer Study Group 2 · p. 350
8.04 Political regimes (democracias y dictaduras) · p. 353
8.05 Dental fillings (empastes) · p. 357
8.06 Survival data (juguete) · p. 360
8.07 TCGA: cáncer de cuello uterino (CESC) y de mama (BRCA) · p. 363
8.08 METABRIC (cáncer de mama) · p. 367
8.09 SCAN-B GSE96058 (cáncer de mama) · p. 370

Predicción de series temporales

6.21 COVID-19: casos confirmados por país (JHU CSSE) · p. 328
9.01 Airline passengers (Box-Jenkins) · p. 373
9.02 Australian wine sales · p. 377
9.03 Nacimientos y defunciones trimestrales · p. 381
9.04 Sarampión en Nueva York (1928-1972) · p. 385
9.05 Superstore sales · p. 389
9.06 Meteorología diaria de Huelva (humedad relativa) · p. 395
9.07 Ozono y contaminantes horarios en Aljarafe (Sevilla) · p. 400

Minería de textos

10.01 BBC news (3 categorías) · p. 405
10.02 ParlaMint-GB (1000 discursos) · p. 408
10.03 SentiNews (noticias eslovenas) · p. 412
10.04 Medical transcriptions (mtsamples) · p. 415
10.05 Cuentos de Grimm y Andersen (en esloveno) · p. 418
10.06 Words y words-food · p. 421

Exploración y visualización

2.14 Health survey (encuesta de hábitos) · p. 124
6.01 Grades (notas de estudiantes) · p. 245
6.03 Human Development Index (HDI) · p. 252
6.04 Clima mensual por continentes · p. 260
6.06 Frecuencias de letras por idioma · p. 270
6.07 Machine learning conferences · p. 274
6.09 Pittsburgh Bridges · p. 281
6.10 Banking crises · p. 284
6.11 UL Rector Elections 2009 · p. 287
6.12 Slovenian National Assembly (votaciones) · p. 290
6.13 Slovenian surnames · p. 294
6.14 Slovenska naselja (localidades de Eslovenia) · p. 298
6.15 Celine (países y continentes) · p. 301
6.16 Cyber security breaches (EE. UU.) · p. 304
6.17 Philadelphia crime · p. 308
6.18 EWBA: vertederos ilegales en Eslovenia · p. 312
6.19 Accidentes de tráfico en Eslovenia 2016 · p. 317
6.20 Renovables por país (Socioeconomic Indices, Banco Mundial) · p. 324
6.21 COVID-19: casos confirmados por país (JHU CSSE) · p. 328
9.05 Superstore sales · p. 389
12.02 Hair (FTIR hiperespectral) · p. 482
12.03 Liver cirrhosis (FTIR hiperespectral) · p. 485
14.06 Médula ósea en AML y sana (van Galen 2019) · p. 523
14.07 Linfocitos T CD8+ agotados (Miller 2019) · p. 526
14.08 Células madre hematopoyéticas de ratón (Nestorowa 2016) · p. 529
14.09 Neuronas de proyección de Drosophila (Li 2017) · p. 531

? Valores faltantes

1.06 Gnomes (gnomos) · p. 33
1.07 Zoo · p. 36
1.11 Mushroom (setas) · p. 53
1.12 Soybean (enfermedades de la soja) · p. 58
1.13 Congressional Voting Records 1984 · p. 63
2.01 Pima Indians Diabetes · p. 71
2.02 Heart Disease (Cleveland) · p. 75
2.03 Breast Cancer (Ljubljana) · p. 79
2.07 Cervical Cancer Risk Factors (cáncer de útero) · p. 96
2.08 Stroke Prediction (ictus) · p. 100
2.09 Dermatology · p. 104
2.11 Primary Tumor · p. 113
2.13 Mice Protein Expression (ratones con síndrome de Down) · p. 120
3.01 Adult (Census Income) · p. 127
3.02 Bank Marketing (bank-additional) · p. 132
3.04 COMPAS (reincidencia a dos años) · p. 143
3.05 Telco Customer Churn · p. 149
3.08 NBA players · p. 164
5.03 Ames Iowa Housing · p. 198
5.04 Auto MPG · p. 203
5.05 Automobile (imports-85) · p. 207
5.13 Hitters (salarios de béisbol, ISLR) · p. 238
6.03 Human Development Index (HDI) · p. 252
6.04 Clima mensual por continentes · p. 260
6.05 Climate of European cities (Köppen) · p. 266
6.06 Frecuencias de letras por idioma · p. 270
6.09 Pittsburgh Bridges · p. 281
6.10 Banking crises · p. 284
6.12 Slovenian National Assembly (votaciones) · p. 290
6.14 Slovenska naselja (localidades de Eslovenia) · p. 298
6.15 Celine (países y continentes) · p. 301
6.16 Cyber security breaches (EE. UU.) · p. 304
6.18 EWBA: vertederos ilegales en Eslovenia · p. 312
6.19 Accidentes de tráfico en Eslovenia 2016 · p. 317
6.21 COVID-19: casos confirmados por país (JHU CSSE) · p. 328
8.04 Political regimes (democracias y dictaduras) · p. 353
9.02 Australian wine sales · p. 377
9.05 Superstore sales · p. 389
9.06 Meteorología diaria de Huelva (humedad relativa) · p. 395
10.02 ParlaMint-GB (1000 discursos) · p. 408
10.03 SentiNews (noticias eslovenas) · p. 412
10.04 Medical transcriptions (mtsamples) · p. 415
11.01 Ánforas romanas · p. 424
11.02 Bone healing (consolidación de fracturas) · p. 429
11.03 Dictyostelium: desarrollo · p. 433
11.08 Localización de proteínas de levadura (YPL+) · p. 453
13.04 Brown et al.: expresión génica de levadura · p. 501
14.09 Neuronas de proyección de Drosophila (Li 2017) · p. 531
14.10 Retina de ratón, Drop-seq (Macosko 2015) · p. 535

⚖ Desbalanceado

1.07 Zoo · p. 36
1.09 Car Evaluation · p. 45
1.12 Soybean (enfermedades de la soja) · p. 58
2.08 Stroke Prediction (ictus) · p. 100
2.09 Dermatology · p. 104
2.10 Lymphography · p. 109
2.11 Primary Tumor · p. 113
3.02 Bank Marketing (bank-additional) · p. 132
3.06 IBM HR Employee Attrition · p. 153
4.01 Glass Identification · p. 168
4.06 Poker Hand · p. 186
5.11 Wine Quality (vinho verde) · p. 229
11.08 Localización de proteínas de levadura (YPL+) · p. 453
13.04 Brown et al.: expresión génica de levadura · p. 501
14.03 Páncreas humano (Baron 2016) · p. 512
14.04 Páncreas humano y diabetes tipo 2 (Xin 2016) · p. 516
14.11 Células bipolares de retina de ratón (Shekhar 2016) · p. 538

◷ Temporal

3.04 COMPAS (reincidencia a dos años) · p. 143
5.10 Forest Fires (Montesinho) · p. 225
6.10 Banking crises · p. 284
6.16 Cyber security breaches (EE. UU.) · p. 304
6.17 Philadelphia crime · p. 308
6.18 EWBA: vertederos ilegales en Eslovenia · p. 312
6.19 Accidentes de tráfico en Eslovenia 2016 · p. 317
6.21 COVID-19: casos confirmados por país (JHU CSSE) · p. 328
7.03 Online Retail (cestas) · p. 339
8.04 Political regimes (democracias y dictaduras) · p. 353
9.01 Airline passengers (Box-Jenkins) · p. 373
9.02 Australian wine sales · p. 377
9.03 Nacimientos y defunciones trimestrales · p. 381
9.04 Sarampión en Nueva York (1928-1972) · p. 385
9.05 Superstore sales · p. 389
9.06 Meteorología diaria de Huelva (humedad relativa) · p. 395
9.07 Ozono y contaminantes horarios en Aljarafe (Sevilla) · p. 400
10.02 ParlaMint-GB (1000 discursos) · p. 408
11.03 Dictyostelium: desarrollo · p. 433
14.06 Médula ósea en AML y sana (van Galen 2019) · p. 523

Espacial

5.02 California Housing · p. 194
5.10 Forest Fires (Montesinho) · p. 225
6.03 Human Development Index (HDI) · p. 252
6.04 Clima mensual por continentes · p. 260
6.05 Climate of European cities (Köppen) · p. 266
6.13 Slovenian surnames · p. 294
6.14 Slovenska naselja (localidades de Eslovenia) · p. 298
6.16 Cyber security breaches (EE. UU.) · p. 304
6.17 Philadelphia crime · p. 308
6.18 EWBA: vertederos ilegales en Eslovenia · p. 312
6.19 Accidentes de tráfico en Eslovenia 2016 · p. 317
6.20 Renovables por país (Socioeconomic Indices, Banco Mundial) · p. 324
6.21 COVID-19: casos confirmados por país (JHU CSSE) · p. 328
7.03 Online Retail (cestas) · p. 339
8.04 Political regimes (democracias y dictaduras) · p. 353
9.05 Superstore sales · p. 389
12.02 Hair (FTIR hiperespectral) · p. 482
12.03 Liver cirrhosis (FTIR hiperespectral) · p. 485

Imágenes

11.01 Ánforas romanas · p. 424
11.02 Bone healing (consolidación de fracturas) · p. 429
11.03 Dictyostelium: desarrollo · p. 433
11.04 Hojas del parque de Luxemburgo · p. 437
11.05 Competencia de ovocitos · p. 442
11.06 Perros de razas tibetanas · p. 445
11.07 Señales de tráfico · p. 449
11.08 Localización de proteínas de levadura (YPL+) · p. 453
11.09 Animales domésticos · p. 458
11.10 Photographers (fotos personales por temas) · p. 461
11.11 Hollywood faces (caras de 17 famosos) · p. 466
11.12 Paintings (15 cuadros de 14 pintores) · p. 470
11.13 Satellite (imágenes de satélite en 4 clases) · p. 474

Texto

3.07 Kickstarter · p. 159
4.05 E. coli promoter gene sequences · p. 183
6.06 Frecuencias de letras por idioma · p. 270
6.16 Cyber security breaches (EE. UU.) · p. 304
10.01 BBC news (3 categorías) · p. 405
10.02 ParlaMint-GB (1000 discursos) · p. 408
10.03 SentiNews (noticias eslovenas) · p. 412
10.04 Medical transcriptions (mtsamples) · p. 415
10.05 Cuentos de Grimm y Andersen (en esloveno) · p. 418
10.06 Words y words-food · p. 421

Alta dimensionalidad

6.21 COVID-19: casos confirmados por país (JHU CSSE) · p. 328
8.07 TCGA: cáncer de cuello uterino (CESC) y de mama (BRCA) · p. 363
8.08 METABRIC (cáncer de mama) · p. 367
8.09 SCAN-B GSE96058 (cáncer de mama) · p. 370
12.01 TKI resistance (espectroscopía IR) · p. 479
12.02 Hair (FTIR hiperespectral) · p. 482
12.03 Liver cirrhosis (FTIR hiperespectral) · p. 485
13.01 GDS360: resistencia a docetaxel en cáncer de mama · p. 491
13.02 GDS3713: linfocitos B de fumadores · p. 495
13.03 GDS4168: linfocitos B en leucemia linfática crónica · p. 498
14.01 Células dendríticas y monocitos (Villani 2017) · p. 504
14.02 AML: médula ósea con leucemia mieloide aguda · p. 508
14.03 Páncreas humano (Baron 2016) · p. 512
14.04 Páncreas humano y diabetes tipo 2 (Xin 2016) · p. 516
14.05 PBMC estimuladas con interferón beta (Kang 2018) · p. 519
14.06 Médula ósea en AML y sana (van Galen 2019) · p. 523
14.07 Linfocitos T CD8+ agotados (Miller 2019) · p. 526
14.08 Células madre hematopoyéticas de ratón (Nestorowa 2016) · p. 529
14.09 Neuronas de proyección de Drosophila (Li 2017) · p. 531
14.10 Retina de ratón, Drop-seq (Macosko 2015) · p. 535
14.11 Células bipolares de retina de ratón (Shekhar 2016) · p. 538
14.12 Ciclo celular: conjuntos de referencia (ccp) · p. 541

Grande

3.01 Adult (Census Income) · p. 127
4.06 Poker Hand · p. 186
5.02 California Housing · p. 194
6.13 Slovenian surnames · p. 294
6.18 EWBA: vertederos ilegales en Eslovenia · p. 312
6.19 Accidentes de tráfico en Eslovenia 2016 · p. 317
7.02 Foodmart 2000 · p. 336
9.07 Ozono y contaminantes horarios en Aljarafe (Sevilla) · p. 400
14.05 PBMC estimuladas con interferón beta (Kang 2018) · p. 519
14.11 Células bipolares de retina de ratón (Shekhar 2016) · p. 538

Juguete

1.02 Tennis / Weather (Quinlan) · p. 20
1.03 Sailing · p. 24
1.04 Lenses (lentes de contacto) · p. 27
1.05 Naughty or nice · p. 30
1.06 Gnomes (gnomos) · p. 33
1.14 Bicycle rides (gravel vs mountain) · p. 67
2.14 Health survey (encuesta de hábitos) · p. 124
6.01 Grades (notas de estudiantes) · p. 245
6.02 Mathematics and football · p. 249
6.04 Clima mensual por continentes · p. 260
6.05 Climate of European cities (Köppen) · p. 266
6.07 Machine learning conferences · p. 274
6.08 Food nutrition info · p. 277
6.11 UL Rector Elections 2009 · p. 287
6.12 Slovenian National Assembly (votaciones) · p. 290
6.20 Renovables por país (Socioeconomic Indices, Banco Mundial) · p. 324
7.01 Market basket (ejemplo) · p. 333
8.05 Dental fillings (empastes) · p. 357
8.06 Survival data (juguete) · p. 360
9.03 Nacimientos y defunciones trimestrales · p. 381
10.05 Cuentos de Grimm y Andersen (en esloveno) · p. 418
11.02 Bone healing (consolidación de fracturas) · p. 429
11.04 Hojas del parque de Luxemburgo · p. 437
11.06 Perros de razas tibetanas · p. 445
11.07 Señales de tráfico · p. 449
11.09 Animales domésticos · p. 458
11.10 Photographers (fotos personales por temas) · p. 461
11.12 Paintings (15 cuadros de 14 pintores) · p. 470
13.01 GDS360: resistencia a docetaxel en cáncer de mama · p. 491
13.02 GDS3713: linfocitos B de fumadores · p. 495
13.03 GDS4168: linfocitos B en leucemia linfática crónica · p. 498
14.12 Ciclo celular: conjuntos de referencia (ccp) · p. 541

Solo categóricos

1.02 Tennis / Weather (Quinlan) · p. 20
1.03 Sailing · p. 24
1.04 Lenses (lentes de contacto) · p. 27
1.06 Gnomes (gnomos) · p. 33
1.07 Zoo · p. 36
1.08 Titanic (supervivientes) · p. 41
1.09 Car Evaluation · p. 45
1.10 MONK's problems · p. 49
1.11 Mushroom (setas) · p. 53
1.12 Soybean (enfermedades de la soja) · p. 58
1.13 Congressional Voting Records 1984 · p. 63
2.03 Breast Cancer (Ljubljana) · p. 79
2.11 Primary Tumor · p. 113
4.05 E. coli promoter gene sequences · p. 183
6.12 Slovenian National Assembly (votaciones) · p. 290
6.15 Celine (países y continentes) · p. 301
7.01 Market basket (ejemplo) · p. 333
11.01 Ánforas romanas · p. 424

◈ Mixto num. + cat.

2.02 Heart Disease (Cleveland) · p. 75
2.07 Cervical Cancer Risk Factors (cáncer de útero) · p. 96
2.08 Stroke Prediction (ictus) · p. 100
2.09 Dermatology · p. 104
2.10 Lymphography · p. 109
2.13 Mice Protein Expression (ratones con síndrome de Down) · p. 120
2.14 Health survey (encuesta de hábitos) · p. 124
3.01 Adult (Census Income) · p. 127
3.02 Bank Marketing (bank-additional) · p. 132
3.03 German Credit · p. 137
3.04 COMPAS (reincidencia a dos años) · p. 143
3.05 Telco Customer Churn · p. 149
3.06 IBM HR Employee Attrition · p. 153
3.07 Kickstarter · p. 159
3.08 NBA players · p. 164
4.06 Poker Hand · p. 186
5.03 Ames Iowa Housing · p. 198
5.04 Auto MPG · p. 203
5.05 Automobile (imports-85) · p. 207
5.06 Abalone · p. 211
5.10 Forest Fires (Montesinho) · p. 225
5.13 Hitters (salarios de béisbol, ISLR) · p. 238
6.07 Machine learning conferences · p. 274
6.09 Pittsburgh Bridges · p. 281
6.10 Banking crises · p. 284
6.14 Slovenska naselja (localidades de Eslovenia) · p. 298
6.16 Cyber security breaches (EE. UU.) · p. 304
6.17 Philadelphia crime · p. 308
6.18 EWBA: vertederos ilegales en Eslovenia · p. 312
6.19 Accidentes de tráfico en Eslovenia 2016 · p. 317
8.01 Veterans' Administration Lung Cancer · p. 343
8.02 Melanoma (Odense) · p. 347
8.03 German Breast Cancer Study Group 2 · p. 350
8.05 Dental fillings (empastes) · p. 357
8.07 TCGA: cáncer de cuello uterino (CESC) y de mama (BRCA) · p. 363
9.05 Superstore sales · p. 389

✎ Sintético

1.02 Tennis / Weather (Quinlan) · p. 20
1.03 Sailing · p. 24
1.05 Naughty or nice · p. 30
1.06 Gnomes (gnomos) · p. 33
1.09 Car Evaluation · p. 45
1.10 MONK's problems · p. 49
2.14 Health survey (encuesta de hábitos) · p. 124
3.06 IBM HR Employee Attrition · p. 153
4.06 Poker Hand · p. 186
5.14 Multitarget synthetic · p. 242
6.01 Grades (notas de estudiantes) · p. 245
6.02 Mathematics and football · p. 249
7.01 Market basket (ejemplo) · p. 333
8.05 Dental fillings (empastes) · p. 357
8.06 Survival data (juguete) · p. 360
10.06 Words y words-food · p. 421

⚑ Sesgo y equidad

3.01 Adult (Census Income) · p. 127
3.03 German Credit · p. 137
3.04 COMPAS (reincidencia a dos años) · p. 143
5.01 Boston Housing · p. 190

⊣ Datos censurados

8.01 Veterans' Administration Lung Cancer · p. 343
8.02 Melanoma (Odense) · p. 347
8.03 German Breast Cancer Study Group 2 · p. 350
8.04 Political regimes (democracias y dictaduras) · p. 353
8.05 Dental fillings (empastes) · p. 357
8.06 Survival data (juguete) · p. 360
8.07 TCGA: cáncer de cuello uterino (CESC) y de mama (BRCA) · p. 363
8.08 METABRIC (cáncer de mama) · p. 367
8.09 SCAN-B GSE96058 (cáncer de mama) · p. 370

⊕ Multiobjetivo

2.07 Cervical Cancer Risk Factors (cáncer de útero) · p. 96
5.12 Energy Efficiency (ENB2012) · p. 234
5.14 Multitarget synthetic · p. 242
6.09 Pittsburgh Bridges · p. 281
9.02 Australian wine sales · p. 377
9.03 Nacimientos y defunciones trimestrales · p. 381

Anexo A. De cada fichero original a su ficha

Todos los ficheros de las dos fuentes del libro (el servidor de datasets de Orange y la carpeta `curso_ciencia_datos` de GitHub), por orden alfabético, con el fichero que les corresponde en la carpeta `ciencia_de_datos` y su ficha. Sirve para encontrar la ficha de un dataset que hayas abierto con el widget *Datasets* de Orange. Los duplicados y las traducciones no se copian: remiten a la ficha de la versión incluida.

Fichero original	Fuente	En la carpeta	Ficha
`abalone.tab`	datasets.biolab.si	`abalone`	5.06 Abalone · 211
`adult.tab`	datasets.biolab.si	`adult`	3.01 Adult (Census Income) · 127
`advertising.xlsx`	datasets.biolab.si	`advertising`	5.08 Advertising (ISLR) · 218
`ames-iowa-housing.xlsx`	datasets.biolab.si	`ames_housing`	5.03 Ames Iowa Housing · 198
`aml-1k.tab.gz`	datasets.biolab.si	`aml_1k`	14.02 AML: médula ósea con leucemia mieloide aguda · 508
`aml-8k.tab.gz`	datasets.biolab.si	`aml_8k`	14.02 AML: médula ósea con leucemia mieloide aguda · 508
`amphorae.tab`	datasets.biolab.si	`amphorae`	11.01 Ánforas romanas · 424
`AndersenSI.tab`	datasets.biolab.si	`andersen_si`	10.05 Cuentos de Grimm y Andersen (en esloveno) · 418
`animaux.tab`	datasets.biolab.si	traducción, no se copia	1.07 Zoo · 36
`attrition-predict.tab`	datasets.biolab.si	`attrition_predict`	3.06 IBM HR Employee Attrition · 153
`attrition-train.tab`	datasets.biolab.si	`attrition_train`	3.06 IBM HR Employee Attrition · 153
`auto-mpg.tab`	datasets.biolab.si	`auto_mpg`	5.04 Auto MPG · 203
`bank-additional.tab`	datasets.biolab.si	`bank_additional`	3.02 Bank Marketing (bank-additional) · 132
`banking-crises.tab`	datasets.biolab.si	`banking_crises`	6.10 Banking crises · 284
`baron2016_pancreas_human.pkl.gz`	datasets.biolab.si	`baron2016_pancreas_human`	14.03 Páncreas humano (Baron 2016) · 512
`baron2016_pancreas_human_sample.tab.gz`	datasets.biolab.si	`baron2016_pancreas_human_sample`	14.03 Páncreas humano (Baron 2016) · 512
`BBC3.tab`	datasets.biolab.si	`bbc3`	10.01 BBC news (3 categorías) · 405
`bicycle-gravel-vs-mountain.xlsx`	datasets.biolab.si	`bicycle_gravel_vs_mountain`	1.14 Bicycle rides (gravel vs mountain) · 67
`bicycle-time-distance.xlsx`	datasets.biolab.si	`bicycle_time_distance`	1.14 Bicycle rides (gravel vs mountain) · 67
`body-fat-brozek.xlsx`	datasets.biolab.si	`body_fat_brozek`	5.07 Body Fat (Brozek) · 214
`bone-healing.xlsx`	datasets.biolab.si	`bone_healing`	11.02 Bone healing (consolidación de fracturas) · 429
`books-norm.tab`	datasets.biolab.si	traducción, no se copia	6.06 Frecuencias de letras por idioma · 270
`brca_metabric.pkl.gz`	datasets.biolab.si	solo enlace (> 100 MB)	8.08 METABRIC (cáncer de mama) · 367
`breast-cancer-wisconsin.tab`	datasets.biolab.si	`breast_cancer_wisconsin`	2.04 Breast Cancer Wisconsin (original) · 83
`breast-cancer.tab`	datasets.biolab.si	`breast_cancer`	2.03 Breast Cancer (Ljubljana) · 79
`bridges.tab`	datasets.biolab.si	`bridges`	6.09 Pittsburgh Bridges · 281
`brown-selected.tab`	datasets.biolab.si	`brown_selected`	13.04 Brown et al.: expresión génica de levadura · 501
`bupa.tab`	datasets.biolab.si	`bupa`	2.12 BUPA Liver Disorders · 117

Fichero original	Fuente	En la carpeta	Ficha
calidad_vino_tinto_regresion(descripcion).txt	curso_ciencia_datos (GitHub)	duplicado, no se copia	5.11 Wine Quality (vinho verde) · 229
calidad_vino_tinto_regresion.arff	curso_ciencia_datos (GitHub)	duplicado, no se copia	5.11 Wine Quality (vinho verde) · 229
calidad_vino_tinto_regresion.csv	curso_ciencia_datos (GitHub)	duplicado, no se copia	5.11 Wine Quality (vinho verde) · 229
california_housing.xlsx	datasets.biolab.si	california_housing	5.02 California Housing · 194
cancer_utero.arff	curso_ciencia_datos (GitHub)	duplicado, no se copia	2.07 Cervical Cancer Risk Factors (cáncer de útero) · 96
cancer_utero.csv	curso_ciencia_datos (GitHub)	cancer_utero	2.07 Cervical Cancer Risk Factors (cáncer de útero) · 96
car.tab	datasets.biolab.si	car	1.09 Car Evaluation · 45
ccp_data_liver.counts.all_genes.tab.gz	datasets.biolab.si	ccp_liver_all_genes	14.12 Ciclo celular: conjuntos de referencia (ccp) · 541
ccp_data_liver.counts.cycle_genes.tab.gz	datasets.biolab.si	ccp_liver_cycle_genes	14.12 Ciclo celular: conjuntos de referencia (ccp) · 541
ccp_data_mESCbulk.counts.all_genes.tab.gz	datasets.biolab.si	ccp_mescbulk_all_genes	14.12 Ciclo celular: conjuntos de referencia (ccp) · 541
ccp_data_mESCbulk.counts.cycle_genes.tab.gz	datasets.biolab.si	ccp_mescbulk_cycle_genes	14.12 Ciclo celular: conjuntos de referencia (ccp) · 541
ccp_data_Tcells_normCounts.counts.all_genes.tab.gz	datasets.biolab.si	ccp_tcells_all_genes	14.12 Ciclo celular: conjuntos de referencia (ccp) · 541
ccp_data_Tcells_normCounts.counts.cycle_genes.tab.gz	datasets.biolab.si	ccp_tcells_cycle_genes	14.12 Ciclo celular: conjuntos de referencia (ccp) · 541
ccp_normCounts_mESCquartz.counts.all_genes.tab.gz	datasets.biolab.si	ccp_mescquartz_all_genes	14.12 Ciclo celular: conjuntos de referencia (ccp) · 541
ccp_normCounts_mESCquartz.counts.cycle_genes.tab.gz	datasets.biolab.si	ccp_mescquartz_cycle_genes	14.12 Ciclo celular: conjuntos de referencia (ccp) · 541
ccp_normCountsBuettnerEtAl.counts.all_genes.tab.gz	datasets.biolab.si	ccp_buettner_all_genes	14.12 Ciclo celular: conjuntos de referencia (ccp) · 541
ccp_normCountsBuettnerEtAl.counts.cycle_genes.tab.gz	datasets.biolab.si	ccp_buettner_cycle_genes	14.12 Ciclo celular: conjuntos de referencia (ccp) · 541
cdp_expression_macosko.tab.gz	datasets.biolab.si	cdp_expression_macosko	14.10 Retina de ratón, Drop-seq (Macosko 2015) · 535
cdp_expression_shekhar.tab.gz	datasets.biolab.si	cdp_expression_shekhar	14.11 Células bipolares de retina de ratón (Shekhar 2016) · 538
celine.xlsx	datasets.biolab.si	celine	6.15 Celine (países y continentes) · 301
climate-asia.xlsx	datasets.biolab.si	weather_asia_selected	6.04 Clima mensual por continentes · 260
climate-europe.tab	datasets.biolab.si	climate_europe	6.05 Climate of European cities (Köppen) · 266
compas-scores-two-years.tab	datasets.biolab.si	compas_scores_two_years	3.04 COMPAS (reincidencia a dos años) · 143
conferences.tab	datasets.biolab.si	conferences	6.07 Machine learning conferences · 274
covid19_confirmados_largo.csv	derivado para este libro	covid19_confirmados_largo	6.21 COVID-19: casos confirmados por país (JHU CSSE) · 328
cyber-security-breaches.tab	datasets.biolab.si	cyber_security_breaches	6.16 Cyber security breaches (EE. UU.) · 304
DC_expMatrix_DCnMono.tab.gz	datasets.biolab.si	dc_expmatrix_dcnmono	14.01 Células dendríticas y monocitos (Villani 2017) · 504
DC_expMatrix_deeper.characterization.tab.gz	datasets.biolab.si	dc_expmatrix_deeper_characterization	14.01 Células dendríticas y monocitos (Villani 2017) · 504

Fichero original	Fuente	En la carpeta	Ficha
dermatology.tab	datasets.biolab.si	dermatology	2.09 Dermatology · 104
diabetes.arff	curso_ciencia_datos (GitHub)	duplicado, no se copia	2.01 Pima Indians Diabetes · 71
diabetes.csv	curso_ciencia_datos (GitHub)	pima_diabetes	2.01 Pima Indians Diabetes · 71
diabetes.xlsx	datasets.biolab.si	diabetes_sklearn	5.09 Diabetes (progresión, Efron et al.) · 221
diabetes_missing.csv	curso_ciencia_datos (GitHub)	pima_diabetes_missing	2.01 Pima Indians Diabetes · 71
dicty-development.xlsx	datasets.biolab.si	dicty_development	11.03 Dictyostelium: desarrollo · 433
dm_proj_neurons_li2017.pkl.gz	datasets.biolab.si	dm_proj_neurons_li2017	14.09 Neuronas de proyección de Drosophila (Li 2017) · 531
domestic-animals.zip	curso_ciencia_datos (GitHub)	domestic_animals	11.09 Animales domésticos · 458
ENB2012_data_procesados.csv	curso_ciencia_datos (GitHub)	duplicado, no se copia	5.12 Energy Efficiency (ENB2012) · 234
ewba-slovenia-illegal-dumpsites.tab	datasets.biolab.si	ewba_illegal_dumpsites	6.18 EWBA: vertederos ilegales en Eslovenia · 312
food-nutrition-info.tab	datasets.biolab.si	food_nutrition_info	6.08 Food nutrition info · 277
foodmart.basket	datasets.biolab.si	foodmart	7.02 Foodmart 2000 · 336
forestfires.csv	curso_ciencia_datos (GitHub)	duplicado, no se copia	5.10 Forest Fires (Montesinho) · 225
forestfires.tab	datasets.biolab.si	forestfires	5.10 Forest Fires (Montesinho) · 225
galen2019_AML_bone_marrow_day0.pkl.gz	datasets.biolab.si	galen2019_aml_bone_marrow_day0	14.06 Médula ósea en AML y sana (van Galen 2019) · 523
galen2019_AML_bone_marrow_day15.pkl.gz	datasets.biolab.si	galen2019_aml_bone_marrow_day15	14.06 Médula ósea en AML y sana (van Galen 2019) · 523
galen2019_AML_bone_marrow_day31.pkl.gz	datasets.biolab.si	duplicado, no se copia	14.06 Médula ósea en AML y sana (van Galen 2019) · 523
galen2019_healthy_bone_marrow.pkl.gz	datasets.biolab.si	galen2019_healthy_bone_marrow	14.06 Médula ósea en AML y sana (van Galen 2019) · 523
gbsg2.tab	datasets.biolab.si	gbsg2	8.03 German Breast Cancer Study Group 2 · 350
GDS360.tab	datasets.biolab.si	gds360	13.01 GDS360: resistencia a docetaxel en cáncer de mama · 491
GDS3713-small.tab	datasets.biolab.si	gds3713_small	13.02 GDS3713: linfocitos B de fumadores · 495
GDS4168.tab	datasets.biolab.si	gds4168	13.03 GDS4168: linfocitos B en leucemia linfática crónica · 498
german-credit-data.tab	datasets.biolab.si	german_credit	3.03 German Credit · 137
glass.tab	datasets.biolab.si	glass	4.01 Glass Identification · 168
gnomes.xlsx	datasets.biolab.si	gnomes	1.06 Gnomes (gnomos) · 33
grades-two.tab	datasets.biolab.si	grades_two	6.01 Grades (notas de estudiantes) · 245
grades.xlsx	datasets.biolab.si	grades	6.01 Grades (notas de estudiantes) · 245
GrimmSI.tab	datasets.biolab.si	grimm_si	10.05 Cuentos de Grimm y Andersen (en esloveno) · 418
GSE96058.pkl.gz	datasets.biolab.si	solo enlace (> 100 MB)	8.09 SCAN-B GSE96058 (cáncer de mama) · 370
hair-spectroscopy.tab	datasets.biolab.si	hair_spectroscopy	12.02 Hair (FTIR hiperespectral) · 482
hdi-edu.tab	datasets.biolab.si	hdi_edu	6.03 Human Development Index (HDI) · 252
hdi-slo.tab	datasets.biolab.si	traducción, no se copia	6.03 Human Development Index (HDI) · 252

Fichero original	Fuente	En la carpeta	Ficha
HDI.tab	datasets.biolab.si	hdi	6.03 Human Development Index (HDI) · 252
health_survey.tab	curso_ciencia_datos (GitHub)	health_survey	2.14 Health survey (encuesta de hábitos) · 124
healthcare-dataset-stroke-data.csv	curso_ciencia_datos (GitHub)	stroke	2.08 Stroke Prediction (ictus) · 100
heart_disease.tab	datasets.biolab.si	heart_disease	2.02 Heart Disease (Cleveland) · 75
Hitters.csv	curso_ciencia_datos (GitHub)	hitters	5.13 Hitters (salarios de béisbol, ISLR) · 238
housing.tab	datasets.biolab.si	housing	5.01 Boston Housing · 190
hrm-employee-attrition.xlsx	datasets.biolab.si	hrm_employee_attrition	3.06 IBM HR Employee Attrition · 153
image-classification/hollywood-faces-images.zip	gualbe/datasets (GitHub)	hollywood_faces	11.11 Hollywood faces (caras de 17 famosos) · 466
image-classification/paintings-images-unsupervised.zip	gualbe/datasets (GitHub)	paintings	11.12 Paintings (15 cuadros de 14 pintores) · 470
image-classification/photographers-test-images-unsupervised.zip	gualbe/datasets (GitHub)	photographers_test	11.10 Photographers (fotos personales por temas) · 461
image-classification/photographers-train-images.zip	gualbe/datasets (GitHub)	photographers_train	11.10 Photographers (fotos personales por temas) · 461
image-classification/satellite-images.zip	gualbe/datasets (GitHub)	satellite	11.13 Satellite (imágenes de satélite en 4 clases) · 474
imports-85.tab	datasets.biolab.si	imports_85	5.05 Automobile (imports-85) · 207
ionosphere.tab	datasets.biolab.si	ionosphere	4.02 Ionosphere · 172
iris.arff	curso_ciencia_datos (GitHub)	duplicado, no se copia	1.01 Iris (Fisher) · 16
iris.tab	datasets.biolab.si	iris	1.01 Iris (Fisher) · 16
kaggle-breast-cancer.csv	curso_ciencia_datos (GitHub)	breast_cancer_wdbc	2.05 Breast Cancer Wisconsin Diagnostic (WDBC) · 87
kaggle-Prostate_Cancer.csv	curso_ciencia_datos (GitHub)	prostate_cancer	2.06 Prostate Cancer (Kaggle) · 92
kickstarter.tab	datasets.biolab.si	kickstarter	3.07 Kickstarter · 159
lenses.tab	datasets.biolab.si	lenses	1.04 Lenses (lentes de contacto) · 27
letter-frequencies-books.csv	datasets.biolab.si	letter_frequencies_books	6.06 Frecuencias de letras por idioma · 270
letter-frequencies.csv	datasets.biolab.si	letter_frequencies	6.06 Frecuencias de letras por idioma · 270
liver-cirrhosis.tab	datasets.biolab.si	liver_cirrhosis	12.03 Liver cirrhosis (FTIR hiperespectral) · 485
liver-spectroscopy.tab	datasets.biolab.si	liver_spectroscopy	12.04 Liver cells (FTIR) · 488
luxembourg-leaves-classified.xlsx	datasets.biolab.si	luxembourg_leaves_classified	11.04 Hojas del parque de Luxemburgo · 437
luxembourg-leaves-test.tab	datasets.biolab.si	luxembourg_leaves_test	11.04 Hojas del parque de Luxemburgo · 437
luxembourg-leaves-train.tab	datasets.biolab.si	luxembourg_leaves_train	11.04 Hojas del parque de Luxemburgo · 437
luxembourg-leaves.xlsx	datasets.biolab.si	luxembourg_leaves	11.04 Hojas del parque de Luxemburgo · 437
lymphography.tab	datasets.biolab.si	lymphography	2.10 Lymphography · 109
market-basket.tab	datasets.biolab.si	market_basket	7.01 Market basket (ejemplo) · 333

Fichero original	Fuente	En la carpeta	Ficha
matematika-nogomet.xlsx	datasets.biolab.si	traducción, no se copia	6.02 Mathematics and football · 249
mathematics-football.xlsx	datasets.biolab.si	mathematics_football	6.02 Mathematics and football · 249
Mathematik-Fußball.xlsx	datasets.biolab.si	traducción, no se copia	6.02 Mathematics and football · 249
mathématiques-football.xlsx	datasets.biolab.si	traducción, no se copia	6.02 Mathematics and football · 249
melanoma.tab	datasets.biolab.si	melanoma	8.02 Melanoma (Odense) · 347
miller2019_chronically_infected_CD8.pkl.gz	datasets.biolab.si	miller2019_chronically_infected_cd8	14.07 Linfocitos T CD8+ agotados (Miller 2019) · 526
miller2019_tumor_infiltrating_CD8.pkl.gz	datasets.biolab.si	miller2019_tumor_infiltrating_cd8	14.07 Linfocitos T CD8+ agotados (Miller 2019) · 526
monks-1.tab	datasets.biolab.si	monks_1	1.10 MONK's problems · 49
monks-2.tab	datasets.biolab.si	monks_2	1.10 MONK's problems · 49
monks-3.tab	datasets.biolab.si	monks_3	1.10 MONK's problems · 49
mtsamples.tab	datasets.biolab.si	mtsamples	10.04 Medical transcriptions (mtsamples) · 415
multitarget-synthetic.tab	datasets.biolab.si	multitarget_synthetic	5.14 Multitarget synthetic · 242
mushrooms.xlsx	curso_ciencia_datos (GitHub)	mushrooms	1.11 Mushroom (setas) · 53
météo-afrique.xlsx	datasets.biolab.si	traducción, no se copia	6.04 Clima mensual por continentes · 260
météo-amérique-du-nord.xlsx	datasets.biolab.si	traducción, no se copia	6.04 Clima mensual por continentes · 260
météo-amérique-du-sud.xlsx	datasets.biolab.si	traducción, no se copia	6.04 Clima mensual por continentes · 260
météo-asie.xlsx	datasets.biolab.si	traducción, no se copia	6.04 Clima mensual por continentes · 260
météo-capitals.xlsx	datasets.biolab.si	traducción, no se copia	6.04 Clima mensual por continentes · 260
nains.xlsx	datasets.biolab.si	traducción, no se copia	1.06 Gnomes (gnomos) · 33
naughty-nice.tab	datasets.biolab.si	naughty_nice	1.05 Naughty or nice · 30
nba.tab	datasets.biolab.si	nba	3.08 NBA players · 164
nestorawa_forcellcycle.pkl.gz	datasets.biolab.si	nestorowa_forcellcycle	14.08 Células madre hematopoyéticas de ratón (Nestorowa 2016) · 529
oocyte-competence.xlsx	datasets.biolab.si	oocyte_competence	11.05 Competencia de ovocitos · 442
ozone-forecasting/aljarafe.csv	gualbe/datasets (GitHub)	ozono_aljarafe	9.07 Ozono y contaminantes horarios en Aljarafe (Sevilla) · 400
ozone-forecasting/aljarafe_corrected.csv	gualbe/datasets (GitHub)	ozono_aljarafe_corregido	9.07 Ozono y contaminantes horarios en Aljarafe (Sevilla) · 400
palcki.xlsx	datasets.biolab.si	traducción, no se copia	1.06 Gnomes (gnomos) · 33
ParlaMint-1000.tab	datasets.biolab.si	parlamint_1000	10.02 ParlaMint-GB (1000 discursos) · 408
pbmc_kang2018_raw_control.pkl.gz	datasets.biolab.si	pbmc_kang2018_raw_control	14.05 PBMC estimuladas con interferón beta (Kang 2018) · 519
pbmc_kang2018_raw_stimulated.pkl.gz	datasets.biolab.si	pbmc_kang2018_raw_stimulated	14.05 PBMC estimuladas con interferón beta (Kang 2018) · 519
pbmc_kang2018_sample.tab.gz	datasets.biolab.si	pbmc_kang2018_sample	14.05 PBMC estimuladas con interferón beta (Kang 2018) · 519
philadelphia-crime.csv.xz	datasets.biolab.si	philadelphia_crime	6.17 Philadelphia crime · 308
pima-diabetes.xlsx	datasets.biolab.si	duplicado, no se copia	2.01 Pima Indians Diabetes · 71

Fichero original	Fuente	En la carpeta	Ficha
podnebje-afrika.xlsx	datasets.biolab.si	traducción, no se copia	6.04 Clima mensual por continentes · 260
podnebje-azija-klimogrami.xlsx	datasets.biolab.si	traducción, no se copia	6.04 Clima mensual por continentes · 260
podnebje-azija.xlsx	datasets.biolab.si	traducción, no se copia	6.04 Clima mensual por continentes · 260
podnebje-juzna-amerika.xlsx	datasets.biolab.si	traducción, no se copia	6.04 Clima mensual por continentes · 260
podnebje-severna-amerika.xlsx	datasets.biolab.si	traducción, no se copia	6.04 Clima mensual por continentes · 260
podnebje.tab	datasets.biolab.si	traducción, no se copia	6.05 Climate of European cities (Köppen) · 266
pogostosti-crk.tab	datasets.biolab.si	traducción, no se copia	6.06 Frecuencias de letras por idioma · 270
poker-hand.tab	datasets.biolab.si	poker_hand	4.06 Poker Hand · 186
political_regimes.tab	datasets.biolab.si	political_regimes	8.04 Political regimes (democracias y dictaduras) · 353
priimki-slovenija.tab	datasets.biolab.si	traducción, no se copia	6.13 Slovenian surnames · 294
priimki-v-obcinah.tab	datasets.biolab.si	traducción, no se copia	6.13 Slovenian surnames · 294
primary-tumor.tab	datasets.biolab.si	primary_tumor	2.11 Primary Tumor · 113
promoters.tab	datasets.biolab.si	promoters	4.05 E. coli promoter gene sequences · 183
ratones_sindrome_down.arff	curso_ciencia_datos (GitHub)	duplicado, no se copia	2.13 Mice Protein Expression (ratones con síndrome de Down) · 120
ratones_sindrome_down.csv	curso_ciencia_datos (GitHub)	ratones_sindrome_down	2.13 Mice Protein Expression (ratones con síndrome de Down) · 120
ratones_sindrome_down.xls	curso_ciencia_datos (GitHub)	duplicado, no se copia	2.13 Mice Protein Expression (ratones con síndrome de Down) · 120
regresion_calidad_vino_tinto.arff	curso_ciencia_datos (GitHub)	duplicado, no se copia	5.11 Wine Quality (vinho verde) · 229
regresion_consumo_energetico.arff	curso_ciencia_datos (GitHub)	duplicado, no se copia	5.12 Energy Efficiency (ENB2012) · 234
regresion_consumo_energetico.csv	curso_ciencia_datos (GitHub)	energy_efficiency	5.12 Energy Efficiency (ENB2012) · 234
regresion_consumo_energetico.xlsx	curso_ciencia_datos (GitHub)	duplicado, no se copia	5.12 Energy Efficiency (ENB2012) · 234
regresion_housing.arff	curso_ciencia_datos (GitHub)	duplicado, no se copia	5.01 Boston Housing · 190
renovables_eca_2010_2018_media.csv	derivado para este libro	renovables_eca_2010_2018_media	6.20 Renovables por país (Socioeconomic Indices, Banco Mundial) · 324
renovables_eca_2010_2018_por_anio.csv	derivado para este libro	renovables_eca_2010_2018_por_anio	6.20 Renovables por país (Socioeconomic Indices, Banco Mundial) · 324
retail-basket.tab	datasets.biolab.si	retail_basket	7.03 Online Retail (cestas) · 339
sa-edu-dental-fillings.tab	datasets.biolab.si	dental_fillings	8.05 Dental fillings (empastes) · 357
sa-edu-TCGA-BRCA.pkl	datasets.biolab.si	solo enlace (> 100 MB)	8.07 TCGA: cáncer de cuello uterino (CESC) y de mama (BRCA) · 363
sa-edu-TCGA-CESC.tab	datasets.biolab.si	tcga_cesc	8.07 TCGA: cáncer de cuello uterino (CESC) y de mama (BRCA) · 363
sailing.tab	datasets.biolab.si	sailing	1.03 Sailing · 24
SentiNews-SI.tab	datasets.biolab.si	sentinews_si	10.03 SentiNews (noticias eslovenas) · 412

Fichero original	Fuente	En la carpeta	Ficha
seriestemp_airline.arff	curso_ciencia_datos (GitHub)	duplicado, no se copia	9.01 Airline passengers (Box-Jenkins) · 373
seriestemp_airline.csv	curso_ciencia_datos (GitHub)	airline_passengers	9.01 Airline passengers (Box-Jenkins) · 373
seriestemp_AustralianWines.csv	curso_ciencia_datos (GitHub)	australian_wines	9.02 Australian wine sales · 377
seriestemp_births_and_deaths.arff	curso_ciencia_datos (GitHub)	duplicado, no se copia	9.03 Nacimientos y defunciones trimestrales · 381
seriestemp_births_and_deaths.csv	curso_ciencia_datos (GitHub)	births_deaths	9.03 Nacimientos y defunciones trimestrales · 381
seriestemp_sarampion_newyork.arff	curso_ciencia_datos (GitHub)	sarampion_nueva_york	9.04 Sarampión en Nueva York (1928-1972) · 385
single-cell-aml-1k.pkl.gz	datasets.biolab.si	duplicado, no se copia	14.02 AML: médula ósea con leucemia mieloide aguda · 508
slovenia-traffic-accidents-2016-events.tab	datasets.biolab.si	slovenia_traffic_accidents_events	6.19 Accidentes de tráfico en Eslovenia 2016 · 317
slovenia-traffic-accidents-2016-persons.tab	datasets.biolab.si	slovenia_traffic_accidents_persons	6.19 Accidentes de tráfico en Eslovenia 2016 · 317
slovenian surnames by municipality.tab	datasets.biolab.si	slovenian_surnames_by_municipality	6.13 Slovenian surnames · 294
slovenian-national-assembly-eng.tab	datasets.biolab.si	slovenian_national_assembly	6.12 Slovenian National Assembly (votaciones) · 290
slovenian-surnames.tab	datasets.biolab.si	slovenian_surnames	6.13 Slovenian surnames · 294
slovenska-naselja.tab	datasets.biolab.si	slovenska_naselja	6.14 Slovenska naselja (localidades de Eslovenia) · 298
soybean.arff	curso_ciencia_datos (GitHub)	soybean	1.12 Soybean (enfermedades de la soja) · 58
superstoreSales2.csv	curso_ciencia_datos (GitHub)	superstore_sales	9.05 Superstore sales · 389
survival_data.csv	datasets.biolab.si	survival_data	8.06 Survival data (juguete) · 360
survival_data_extended.csv	datasets.biolab.si	survival_data_extended	8.06 Survival data (juguete) · 360
telecom-customer-churn.xlsx	datasets.biolab.si	telecom_churn	3.05 Telco Customer Churn · 149
tennis.arff	curso_ciencia_datos (GitHub)	tennis_numerico	1.02 Tennis / Weather (Quinlan) · 20
tennis.csv	curso_ciencia_datos (GitHub)	tennis	1.02 Tennis / Weather (Quinlan) · 20
tibetan-dogs.xlsx	datasets.biolab.si	tibetan_dogs	11.06 Perros de razas tibetanas · 445
tiere.tab	datasets.biolab.si	traducción, no se copia	1.07 Zoo · 36
time_series_covid19_confirmed_global.csv	JHU CSSE COVID-19 (GitHub)	covid19_confirmados_global	6.21 COVID-19: casos confirmados por país (JHU CSSE) · 328
titanic.arff	curso_ciencia_datos (GitHub)	titanic_numerico	1.08 Titanic (supervivientes) · 41
titanic.tab	datasets.biolab.si	titanic	1.08 Titanic (supervivientes) · 41
TKI-resistance-spectroscopy.tab	datasets.biolab.si	tki_resistance_spectroscopy	12.01 TKI resistance (espectroscopía IR) · 479
traffic-signs.tab	datasets.biolab.si	traffic_signs	11.07 Señales de tráfico · 449
UL Rector Elections 2009.xlsx	datasets.biolab.si	ul_rector_elections_2009	6.11 UL Rector Elections 2009 · 287
vehicle.tab	datasets.biolab.si	vehicle	4.03 Vehicle Silhouettes · 175
veteran.tab	datasets.biolab.si	veteran	8.01 Veterans' Administration Lung Cancer · 343
voting.tab	datasets.biolab.si	voting	1.13 Congressional Voting Records 1984 · 63

Fichero original	Fuente	En la carpeta	Ficha
vreme-prestolnice.xlsx	datasets.biolab.si	traducción, no se copia	6.04 Clima mensual por continentes · 260
weather-africa.xlsx	datasets.biolab.si	weather_africa	6.04 Clima mensual por continentes · 260
weather-capitals.xlsx	datasets.biolab.si	weather_europe_capitals	6.04 Clima mensual por continentes · 260
weather-north-america.xlsx	datasets.biolab.si	weather_north_america	6.04 Clima mensual por continentes · 260
weather-south-america.xlsx	datasets.biolab.si	weather_south_america	6.04 Clima mensual por continentes · 260
weather/wea_HU002.csv	gualbe/datasets (GitHub)	meteo_huelva_hu002	9.06 Meteorología diaria de Huelva (humedad relativa) · 395
weather/wea_HU002_corrected.csv	gualbe/datasets (GitHub)	meteo_huelva_hu002_corregido	9.06 Meteorología diaria de Huelva (humedad relativa) · 395
wetter-afrika.xlsx	datasets.biolab.si	traducción, no se copia	6.04 Clima mensual por continentes · 260
wetter-asien.xlsx	datasets.biolab.si	weather_asia	6.04 Clima mensual por continentes · 260
wetter-hauptstädten.xlsx	datasets.biolab.si	traducción, no se copia	6.04 Clima mensual por continentes · 260
wetter-nordamerika.xlsx	datasets.biolab.si	traducción, no se copia	6.04 Clima mensual por continentes · 260
wetter-sudamerika.xlsx	datasets.biolab.si	traducción, no se copia	6.04 Clima mensual por continentes · 260
wine.arff	curso_ciencia_datos (GitHub)	duplicado, no se copia	4.04 Wine (cultivares italianos) · 179
wine.tab	datasets.biolab.si	wine	4.04 Wine (cultivares italianos) · 179
winequality-red.tab	datasets.biolab.si	wine_quality_red	5.11 Wine Quality (vinho verde) · 229
winequality-white.tab	datasets.biolab.si	wine_quality_white	5.11 Wine Quality (vinho verde) · 229
words-food.xlsx	datasets.biolab.si	words_food	10.06 Words y words-food · 421
words.xlsx	datasets.biolab.si	words	10.06 Words y words-food · 421
xin2016_pancreas_human.tab.gz	datasets.biolab.si	xin2016_pancreas_human	14.04 Páncreas humano y diabetes tipo 2 (Xin 2016) · 516
xin2016_pancreas_human_sample.tab.gz	datasets.biolab.si	xin2016_pancreas_human_sample	14.04 Páncreas humano y diabetes tipo 2 (Xin 2016) · 516
yplp.xlsx	datasets.biolab.si	yplp	11.08 Localización de proteínas de levadura (YPL+) · 453
zivali-v-finscini.tab	datasets.biolab.si	traducción, no se copia	1.07 Zoo · 36
zivali-z-neznanimi.tab	datasets.biolab.si	traducción, no se copia	1.07 Zoo · 36
zivali.tab	datasets.biolab.si	traducción, no se copia	1.07 Zoo · 36
zoo-finnish.tab	datasets.biolab.si	traducción, no se copia	1.07 Zoo · 36
zoo-missing.tab	datasets.biolab.si	zoo_missing	1.07 Zoo · 36
zoo.tab	datasets.biolab.si	zoo	1.07 Zoo · 36
zwerge.xlsx	datasets.biolab.si	traducción, no se copia	1.06 Gnomes (gnomos) · 33

Anexo B. Formatos de fichero en Orange

Los ficheros de esta colección

- **CSV**: UTF-8, separador «,», punto decimal, una sola fila de cabecera con los nombres originales de las columnas, vacío para los valores faltantes y fechas en formato ISO (`2010-12-01`). Es el formato para abrir en Orange.
- **XLSX**: los mismos datos en la hoja `datos`, más la hoja `variables` (tipo, rol en Orange y significado en español de cada columna) y la hoja `ficha` (fuente, cita y enlace). Si el fichero tiene más de 16.384 columnas, el XLSX se corta en esa columna, que es el límite de Excel; y si pasaría de 100 MB, no hay XLSX.
- **ZIP**: un CSV de más de 100 MB va comprimido; descomprímelo antes de abrirlo. Los conjuntos de imágenes tienen un ZIP con las imágenes además del CSV con sus URL.

Abrir un fichero

- **File**: abre CSV, XLSX y los formatos propios de Orange, desde el disco o desde una URL. En un XLSX deja elegir la hoja: usa `datos`.
- **CSV File Import**: da control total sobre el separador, el signo decimal, la codificación y el tipo de cada columna. Úsalo con CSV que no sigan las convenciones de arriba, por ejemplo los que guarda Excel en español (separador «;» y coma decimal).
- **Datasets**: descarga directamente los conjuntos del servidor de Orange en su formato original. El anexo A dice qué ficha corresponde a cada uno.

Tipos y roles

Orange da a cada columna un **tipo** (numérica, categórica, texto o fecha y hora) y un **rol** (atributo, objetivo o *target*, meta o ignorada). Un CSV no guarda esa información, así que Orange la deduce de los valores. Revísala siempre en *File* (se cambia haciendo doble clic) o en *Edit Domain*. Los errores más habituales que señalan las fichas son:

- Categorías codificadas con números que se leen como numéricas (el año en ParlaMint, códigos de clase en varios conjuntos de clasificación).
- Columnas numéricas con muy pocos valores distintos que se leen como categóricas (los 637 genes que valen siempre 0 en TCGA).
- Identificadores y nombres que quedan como atributos y delatan la clase: deben ser *meta*.
- Coordenadas, tamaños de imagen o columnas de procedencia que se cuelan como atributos (`map_x` y `map_y` en los mapas de espectros).
- Fechas que no están en ISO y se leen como texto: en esta colección se han pasado a ISO, y así *File* las reconoce como fecha.

Los formatos originales de Orange

- **.tab**: texto separado por tabuladores con una cabecera de tres filas: los nombres; el tipo (`continuous`, `discrete`, `string` o `time`); y el rol (`class`, `meta` o `ignore`, o vacío para un atributo). Es el único formato de texto que guarda tipos y roles.
- **Prefijos en la cabecera**: Orange también entiende, en un CSV o un XLSX de una sola fila de cabecera, nombres del tipo `cD#clase`: una letra de rol (`c` objetivo, `m` meta, `i` ignorar) y una de tipo (`C` numérica, `D` categórica, `S` texto, `T` fecha) antes de `#`. Es útil para preparar ficheros propios que se abran ya bien configurados.

- **.tab.gz**, **.csv.gz** y **.pkl.gz**: tablas comprimidas, o guardadas directamente como objeto de Orange (*pickle*), sobre todo en los conjuntos de expresión génica y célula única. *Datasets* y *File* las abren tal cual.
- **.basket**: transacciones en formato disperso, una cesta por línea con los productos separados por comas (y `producto=cantidad` si hay cantidades). Lo usan los conjuntos de reglas de asociación.

Anexo C. Add-ons de Orange

Los add-ons amplían Orange con widgets para un tipo de datos o de análisis. Se instalan desde **Opciones → Complementos** (*Options → Add-ons*): marca el add-on, acepta y reinicia Orange. Sus widgets aparecen después en una sección propia de la caja de herramientas. 62 de las 135 fichas no necesitan ningún add-on.

Add-on	Para qué sirve	Widgets que usan las fichas	Fichas
Image Analytics	Carga imágenes desde una carpeta o desde URL y las convierte en vectores numéricos (*Image Embedding*) con redes neuronales preentrenadas. La mayoría de los modelos de *Image Embedding* se calculan en un servidor del equipo de Orange (hace falta conexión a internet); *SqueezeNet* funciona sin conexión.	Image Embedding, Image Viewer, Import Images, Image Grid, Save Images	13: 11.01, 11.02, 11.03, 11.04, 11.05, 11.06, 11.07, 11.08, 11.09, 11.10, 11.11, 11.12, 11.13
Geo	Mapas: puntos sobre un mapa (*Geo Map*), coropletas por país o región (*Choropleth Map*) y geocodificación de nombres de lugares (*Geocoding*).	Geo Map, Choropleth Map, Geocoding	12: 5.02, 6.03, 6.04, 6.05, 6.13, 6.14, 6.16, 6.17, 6.18, 6.19, 6.20, 6.21
Single Cell	Datos de RNA-seq de célula única: preprocesado (normalización por biblioteca, logaritmo, genes variables), filtrado de células y genes, corrección del efecto de lote y puntuación de células con listas de genes. Al instalarlo se instala también *Bioinformatics*.	Single Cell Preprocess, Score Cells, Batch Effect Removal, Filter	12: 14.01, 14.02, 14.03, 14.04, 14.05, 14.06, 14.07, 14.08, 14.09, 14.10, 14.11, 14.12
Survival Analysis	Datos censurados: indica qué columnas son el tiempo y el evento (*As Survival Data*), dibuja curvas de Kaplan-Meier, ajusta la regresión de Cox y ordena las variables por su relación con la supervivencia.	Kaplan-Meier Plot, As Survival Data, Rank Survival Features, Cox regression, Cohorts	9: 8.01, 8.02, 8.03, 8.04, 8.05, 8.06, 8.07, 8.08, 8.09
Timeseries	Series temporales: convierte una tabla con una columna de fecha en serie (*Form Timeseries*), dibuja y descompone series, ajusta modelos ARIMA y VAR y los compara con validación por origen móvil.	Line Chart, Form Timeseries, ARIMA Model, Model Evaluation, Time Slice, Seasonal Adjustment, Interpolate, VAR Model, Correlogram, Moving Transform, Difference, Periodogram	8: 6.21, 9.01, 9.02, 9.03, 9.04, 9.05, 9.06, 9.07
Bioinformatics	Expresión génica: expresión diferencial entre grupos, bases de datos de genes marcadores, conjuntos de genes y acceso a GEO.	Differential Expression	8: 13.01, 13.02, 13.03, 13.04, 14.01, 14.02, 14.09, 14.11
Text	Minería de textos: corpus, preprocesado (tokenización, minúsculas, palabras vacías), bolsa de palabras, *embeddings* de documentos, nubes de palabras, modelos de temas y análisis de sentimiento.	Corpus, Preprocess Text, Bag of Words, Word Cloud, Topic Modelling, Word Enrichment, Sentiment Analysis, Extract Keywords, Document Embedding	6: 10.01, 10.02, 10.03, 10.04, 10.05, 10.06
Spectroscopy	Espectros e imágenes hiperespectrales: lectura de formatos de espectrómetro, gráficos de espectros, mapas de bandas (*HyperSpectra*) y preprocesado (línea base, normalización, derivadas, recorte de rango).	Preprocess Spectra, HyperSpectra, Spectra	4: 12.01, 12.02, 12.03, 12.04

Add-on	Para qué sirve	Widgets que usan las fichas	Fichas
Associate	Cestas de la compra y transacciones: conjuntos frecuentes y reglas de asociación con soporte, confianza y *lift*.	Frequent Itemsets, Association Rules	3: 7.01, 7.02, 7.03
Explain	Explicación de modelos con valores SHAP: qué variables pesan más y en qué sentido.	Explain Model	2: 2.05, 2.06
Fairness	Sesgo y equidad: medidas de sesgo del conjunto de datos y modelos con corrección de sesgo.	Dataset Bias	1: 3.01
World Happiness	Descarga indicadores socioeconómicos por país (Banco Mundial y World Happiness Report).	Socioeconomic Indices	1: 6.20

Anexo D. Glosario de métricas

Las medidas que aparecen en las fichas, con el nombre que les da Orange (en *Test and Score* y otros widgets) cuando lo tienen.

Clasificación

Acierto (CA, *classification accuracy*)
Proporción de casos bien clasificados. Con clases desbalanceadas engaña: compáralo siempre con la clase mayoritaria.

Clase mayoritaria
El acierto que se obtiene prediciendo siempre la clase más frecuente (el modelo *Constant* de Orange). Es la línea base mínima que debe superar cualquier modelo.

Matriz de confusión
Tabla de clase real frente a clase predicha (widget *Confusion Matrix*). Muestra qué clases se confunden entre sí, algo que el acierto global oculta.

Precisión (Prec)
De los casos que el modelo predice como positivos, qué proporción lo es de verdad.

Sensibilidad o exhaustividad (Recall)
De los positivos reales, qué proporción detecta el modelo. Su complemento en la clase negativa es la **especificidad**.

F1
Media armónica de precisión y sensibilidad: solo es alta si las dos lo son.

AUC
Área bajo la curva ROC (widget *ROC Analysis*). Es la probabilidad de que un positivo al azar reciba una puntuación más alta que un negativo al azar: 0,5 es azar y 1, separación perfecta. No depende del umbral de decisión.

MCC
Coeficiente de correlación de Matthews, de −1 a 1. Tiene en cuenta las cuatro casillas de la matriz de confusión y es más fiable que el acierto con clases desbalanceadas.

LogLoss
Pérdida logarítmica: penaliza mucho las probabilidades muy seguras y equivocadas. Cuanto menor, mejor.

Matriz de costes
Peso distinto para cada tipo de error, cuando no cuestan lo mismo (en German Credit, aceptar a un moroso cuesta cinco veces más que rechazar a un buen cliente).

Regresión

MSE y RMSE
Error cuadrático medio y su raíz. El RMSE está en las unidades del objetivo y castiga mucho los errores grandes.

MAE
Error absoluto medio, también en las unidades del objetivo; menos sensible a los casos extremos que el RMSE.

R^2 (R2)

Proporción de la variabilidad del objetivo que explica el modelo. 1 es perfecto, 0 equivale a predecir siempre la media, y un valor negativo es peor que la media.

MAPE

Error porcentual absoluto medio, habitual en series temporales. No sirve si el objetivo toma valores cercanos a 0.

Agrupamiento y reducción de dimensión

Silueta

Para cada caso, compara la distancia media a su grupo con la del grupo vecino más cercano. Va de −1 a 1; cuanto más alta, más compactos y separados están los grupos. *k-Means* la usa para elegir el número de grupos.

ARI (índice de Rand ajustado)

Concordancia entre un agrupamiento y unas etiquetas conocidas, corregida por azar: 0 es azar y 1, coincidencia total.

Varianza explicada

En el PCA, el porcentaje de la variabilidad total que recoge cada componente principal.

Reglas de asociación

Soporte

Proporción de cestas que contienen un conjunto de productos.

Confianza

De las cestas que contienen el antecedente de la regla, la proporción que contiene también el consecuente.

Lift

Confianza dividida entre el soporte del consecuente. Mayor que 1: los productos aparecen juntos más de lo esperado por azar; 1: son independientes; menor que 1: se evitan.

Supervivencia

Censura

Caso en que el evento no se ha observado al acabar el seguimiento: solo se sabe que el tiempo hasta el evento es mayor que el registrado.

Curva de Kaplan-Meier y mediana de supervivencia

Estimación de la proporción que sigue sin el evento en cada momento, teniendo en cuenta la censura. La mediana es el tiempo en que la curva baja del 50 %.

Prueba de rangos logarítmicos (*log-rank*)

Contrasta si las curvas de supervivencia de varios grupos difieren. Un p-valor pequeño indica diferencia.

Cociente de riesgos (*hazard ratio*)

En la regresión de Cox, cuánto multiplica el riesgo instantáneo del evento cada variable: mayor que 1 aumenta el riesgo y menor que 1 lo reduce.

Índice de concordancia (C-index)

Equivalente al AUC para supervivencia: proporción de parejas de casos que el modelo ordena bien según quién sufre antes el evento. 0,5 es azar.

Validación y errores de diseño

Validación cruzada de *k* bolsas

Divide los datos en *k* partes, entrena con *k* − 1 y prueba con la restante, *k* veces. La versión estratificada mantiene la proporción de clases en cada parte; la repetida promedia varias divisiones al azar.

Validación por grupos

Cuando hay varias filas del mismo individuo (ratón, paciente, cepa), todas deben quedar en la misma parte. Si no, el modelo reconoce al individuo y el acierto sale inflado (Mice Protein, Bone Healing).

Validación por origen móvil

En series temporales, se entrena con el pasado y se prueba con el periodo siguiente, avanzando en el tiempo (widget *Model Evaluation*). La línea base es el modelo ingenuo estacional: repetir el valor del mismo mes del año anterior.

Fuga de información (*leakage*)

Un atributo que contiene la respuesta o que no estaría disponible al predecir (`duration` en Bank Marketing, `is_recid` en COMPAS), o un paso hecho con todos los datos antes de validar (elegir genes con todo el conjunto en GDS360). Da aciertos que no se repiten con datos nuevos.

Variable de confusión

Factor que va unido a la clase sin ser su causa, como el donante o el lote de procesado en los datos de célula única. El modelo puede aprender ese factor en lugar de la clase.

p-valor y comparaciones múltiples

Al contrastar miles de genes, un umbral de $p < 0{,}001$ deja pasar por azar unos 0,001 × número de genes: con 3.000 genes, unos 3. Hay que corregir (Bonferroni, FDR) o comparar con lo esperado.